

제1권 품질관리 프레임워크를 중심으로

AI 데이터 품질관리 가이드 v4.0

I 개요

제1장 추진 배경 및 목적

- 1. 추진 배경 14
- 2. 목적 15

제2장 품질관리 가이드라인 구성

- 1. 제 1 권 AI 데이터 품질관리 가이드 구성 16

제3장 인공지능 학습용 데이터 이해

- 1. 인공지능 학습용 데이터 18
- 2. 인공지능 학습용 데이터 특성 19
- 3. 인공지능 학습용 데이터 생애주기 21

제4장 인공지능 학습용 데이터 품질관리 이해

- 1. 인공지능 학습용 데이터 품질관리 원칙 23
- 2. 인공지능 학습용 데이터 구축 과정 23
- 3. 인공지능 학습용 데이터 품질관리 범위 25
- 4. 인공지능 학습용 데이터 품질검사 활동 26

II 품질관리 체계

제1장 품질관리 프레임워크

- 1. 품질관리 프레임워크 구성 29
- 2. 품질관리 이해관계자 정의 34
- 3. 품질관리 조직 체계 36

제2장 품질관리 프로세스 및 산출물

- 1. 준비·계획 단계(100) 38
- 2. 구축 단계(200) 41
- 3. 운영·활용 단계(300) 55
- 4. 단계별 산출물 60

제3장 품질 자가점검 및 품질검증

- 1. 개요 62
- 2. 품질 자가점검 63
- 3. 제 3 자 품질검증 71

III | 부록

부록 1. 품질관리 기준

1. 품질관리 지표	81
2. 구축 공정 적정성 품질관리 지표	84
3. 데이터 적합성 품질관리 지표	94
4. 가공데이터 정확성 품질관리 지표	108
5. 학습모델 적합성 품질관리 지표	115

부록 2. 품질지표 설정 가이드

1. 품질지표 설정 개요	160
2. 학습데이터 유형	161
3. 품질지표 설정 가이드	169

부록 3. 데이터 가공 가이드

1. 텍스트, 음성 데이터 가공	224
2. 이미지, 영상 데이터 가공	232
3. 3D 데이터 가공	236

부록 4. 개인정보보호 가이드

1. 인공지능 개인정보보호 개요	237
2. 생애주기별 개인정보보호 가이드라인	240

IV | 참고자료

제1장 용어 정의	257
-----------	-----

제2장 참고 문헌	270
-----------	-----

제1권

AI 데이터 품질관리 가이드 개정 이력

개정 이력			
연번	버전	발간일	주요 변경 내용
1	v1.0	'21.02	- 최초 발간 - 인공지능 학습용 데이터의 생애주기 기반 품질관리 체계 및 기준 제시 ※ 문서명: 『인공지능 학습용 데이터 품질관리 가이드라인 v1.0』의 1권. 인공지능 학습용 데이터 품질관리 가이드라인
2	v2.0	'22.02	- 품질관리 프레임워크 최초 개발 - 데이터 유형에 따른 품질지표 선정 측면의 '품질관리 프레임워크' 최초 개발 - 클라우드 소싱 기반 작업자 관리 등 데이터 품질과 연관된 인력 관리 내용 추가 ※ 문서명: 『인공지능 학습용 데이터 품질관리 가이드라인 v2.0』의 1권. 품질관리 안내서
3	v3.0	'23.02	- 품질관리 프레임워크 전면 개정 - 데이터 구축 공정 및 산출물, 품질관리 활동을 기반으로 품질관리 프레임워크 전면 개정 1-Cycle 자가점검 프로세스 및 개인정보보호 관리 기준 제시 ※ 문서명: 『인공지능 학습용 데이터 품질관리 가이드라인 v3.0』의 1권. 품질관리 가이드라인
4	v3.1	'24.01	- 생성형AI(LLM 등) 관련 내용 추가 - 데이터 구축 단계별 프로세스 및 산출물, 이해관계자별 역할 현행화 1-Cycle 자가점검 프로세스, 품질지표 사례, 개인정보보호 기준 현행화 ※ 문서명: 『인공지능 학습용 데이터 품질관리 가이드라인 v3.1』의 1권. 품질관리 가이드라인
5	v3.5	'25.02	- 생성형AI 관련 내용을 제3권으로 이동 및 품질관리 지표 내용 개선 - 생성형AI 관련 내용 전부를 “제3권 생성형AI 데이터 품질관리 가이드”로 분리 - 품질특성 및 검사 항목 용어 재정의(형식성, 다양성 등) - 합성데이터 생성 참조모델 발표, 개인정보보호 가이드 개정에 따른 관련 내용 현행화 ※ 문서명: 『AI 데이터 품질관리 가이드라인 v3.5』의 1권. AI 데이터 품질관리 가이드 (부제: 품질관리 프레임워크 중심)
6	v4.0	'26.02	- 품질관리 프레임워크 내 자가점검 활동 및 데이터 가공 방안 내용 개선 - 품질관리 프레임워크의 자가점검 프로세스 내 '중간데이터 보완점검' 절차 신설 - 텍스트/오디오 유형의 데이터 가공 시 품질관리 방안 내용 개선 - 개인정보보호법 및 관련법령 개정에 따른 내용 현행화 ※ 문서명: 『AI 데이터 품질관리 가이드라인 v4.0』의 1권. AI 데이터 품질관리 가이드 (부제: 품질관리 프레임워크 중심)

AI 데이터 품질관리 가이드라인 v4.0 요약

※ p.2~13는 가이드라인 v4.0의 권별 구성 안내로, 1권의 주요 내용은 p.14 부터 확인 가능

AI 데이터 품질관리 가이드라인 v4.0 구성

- “가이드라인 v3.5”를 기반으로 2025년 초거대AI 확산 생태계 조성사업의 데이터 특성(LLM, LMM, 합성, 추론)을 반영하여 고도화한 “AI 데이터 품질관리 가이드라인 v4.0(2026)” 구성
 - “1권. AI 데이터 품질관리 가이드 v4.0 (부제: 품질관리 프레임워크 중심)”
 - “2권. AI 데이터 구축 가이드 v4.0 (부제: 구축사례 중심)”
 - “3권. 생성형AI 데이터 품질관리 가이드 v2.5 (부제: LLM, LMM, 합성데이터 중심)”
 - “4권. 신기술 AI 데이터 품질관리 가이드 v1.0 (부제: 추론형 AI 데이터 중심)”
- AI 데이터 품질관리 가이드라인 권별 주요 핵심 Point

가이드라인	항목	주요내용
1권	인공지능 학습용데이터 품질관리 프레임워크	• 구축공정별 품질관리 프로세스 및 산출물 • 품질관리 이해관계자 • 품질관리 조직 체계
	품질 자가점검 및 품질검증	• 구축공정별 품질자가점검 수행 방안 안내
	인공지능 학습용데이터 품질지표 설정 기준	• 인공지능 학습용 데이터 품질지표 설정 방안안내
2권	데이터 구축사례	• 획득/수집, 정제, 가공, 학습 단계별 데이터 구축 사례 수록 - LLM, LMM, 합성, 추론형 데이터
	데이터 품질관리 사례	• 데이터 품질관리 사례 수록 - LLM, LMM, 합성, 추론형 데이터
	데이터 품질오류 유형 분석	• 실제 데이터 구축 사례를 기반으로 데이터 품질 오류 유형 분석 • 품질항목별 오류 예시, 개선방안 제시

가이드라인	항목	주요내용
3권	생성형 AI(합성데이터) 품질관리 프레임워크	• 기존 인공지능 품질관리 프레임워크를 기반으로 합성데이터 생애주기 맞춤형 프레임워크 제시 - 구축공정별 품질관리 프로세스 및 산출물 중심
	데이터 구축공정별 품질관리 고려사항	• 생성형 AI 데이터(LLM, LMM, 합성)의 데이터 획득/수집, 정제, 가공, 학습 단계별 품질관리 고려사항 제시
	생성형 AI 주요 기술	• 생성형 AI 데이터(LLM, LMM, 합성)의 주요 기술, AI 모델 • 거대멀티모달(LMM) 데이터인 이미지 캡션 데이터 구축 기술 소개
	생성형 AI 품질관리 지표 및 설정 방법	• 생성형 AI 데이터(LLM, LMM, 합성)의 데이터 품질관리 지표 기준 및 설정 방법 제시
4권	추론형 AI 데이터 품질관리 프레임워크	• 추론형 AI 데이터 구축 생애주기 특성을 고려한 품질관리 프레임워크 제시 • 추론형 AI 데이터 구축을 위한 품질관리 활동 및 방안 제시
	추론형 AI 품질특성 및 품질관리	• 추론형 AI의 품질 특성 • 품질특성을 고려한 품질관리 방안 제시
	추론형 AI 주요 기술 및 모델	• 추론형 AI 관련 최신 기술, AI모델 소개

제1권

AI 데이터 품질관리 가이드

- AI 데이터의 체계적인 품질관리를 위한 ‘품질관리 프레임워크’ 정립

- 데이터 구축사업 전반의 내용과 품질관리에 대한 이해를 도울 수 있도록 ‘품질관리 프레임워크’를 제시



[그림 1] 데이터 품질관리 프레임워크 구조

- ‘품질관리 프레임워크’의 프로세스 기반 품질관리 활동 및 산출물 정의

- 데이터 구축 프로세스별 품질관리 활동과 그에 따른 산출물을 정의하여 각 구축 공정 간에 품질관리 활동이 유기적으로 연결될 수 있도록 설계
- 모든 구축 공정을 반복적으로 수행함으로써 데이터의 품질을 개선하는 활동인 1-Cycle 자가점검에 대한 이해와 데이터 구축량에 따른 품질관리 활동 제시
- 목표 달성을 위해 반복 개선한 최종 결과물의 품질을 측정하기 위하여 검증 기준 수립부터 검증 수행 및 보완까지의 제3자 기관을 통한 품질검증 절차를 제시

- 데이터의 품질 수준 측정을 위한 품질관리 지표 및 품질지표 선정을 위한 방향성 제시

- 데이터의 객관적인 품질 수준 측정을 위한 다양한 품질관리 지표를 제시
- AI 임무, 가공 유형 등 구축하고자 하는 데이터의 특성에 따른 품질지표 선정 절차 제시

[제1권] AI 데이터 품질관리 가이드 v3.5과 v4.0 비교

● 2025년 2월에 발간된 '[제1권] 품질관리 가이드 v3.5'과 내용 구성 비교

(제1권) AI 데이터 품질관리 가이드 v3.5
AI 데이터 품질관리 가이드라인 v3.5



(제1권) AI 데이터 품질관리 가이드 v4.0
AI 데이터 품질관리 가이드라인 v4.0



[그림 2] [제1권] AI 데이터 품질관리 가이드 v3.5과 v4.0 비교

변경점	v3.5	v4.0
전체	2022~24년 구축 데이터 품질관리 현황	2025년 구축 데이터 품질관리 현황
품질관리 프레임워크 고도화	1-Cycle 자가점검 프로세스 - 과제조정위원회 자가점검 - 샘플데이터 자가점검 (1%) - 초기데이터 자가점검 (5~10%) - 중간데이터 자가점검 (30%) - 최종데이터 자가점검 (100%)	1-Cycle 자가점검 프로세스 - 샘플데이터 1-Cycle 자가점검 - 초기데이터 1-Cycle 자가점검 (5~10%) - 중간데이터 1-Cycle 자가점검 (30%) - 중간데이터 보완점검 (50%) - 최종데이터 1-Cycle 자가점검 (100%)
품질관리 프로세스 고도화	1-Cycle 자가점검 품질관리 산출물 1-Cycle 자가점검 결과서 - 자가점검 체크리스트 - 과제조정위원회 자가점검 체크리스트 - 샘플데이터 자가점검 체크리스트 - 초기데이터 자가점검 체크리스트 - 중간데이터 자가점검 체크리스트 - 최종데이터 자가점검 체크리스트	1-Cycle 자가점검 품질관리 산출물 1-Cycle 자가점검 결과서 - 중간데이터 보완점검 결과서 - 자가점검 체크리스트 - 샘플데이터 자가점검 체크리스트 - 초기데이터 자가점검 체크리스트 - 중간데이터 자가점검 체크리스트 - 중간데이터 보완점검 체크리스트 - 최종데이터 자가점검 체크리스트

변경점	v3.5	v4.0
품질관리 프로세스 고도화	데이터 가공단계 고려사항 • 가공단계 고려사항 정의	데이터 가공단계 고려사항 • 이미지/비디오, 텍스트/오디오 등 데이터 유형별 고려사항 고도화
데이터 가공 가이드	가공 예시 중심 안내	음성, 텍스트 전사 가공 규칙 고도화 • 전사정보의 저장 • 화자정보의 전사 • 시간정보의 전사 • 발성내용의 전사 • 추가정보의 전사 • 전사규칙에 사용된 꼬리표
개정안 수록	부록4. 개인정보보호가이드 - 비정형데이터 가명처리 기준 개정안 (2024.02, 개인정보보호위원회)	부록4. 개인정보보호가이드 - 생성형 AI 개발·활용을 위한 개인정보 처리 안내서 (2025.08, 개인정보보호위원회) - 개정된 개인정보보호 관련 법령 반영 (2025.10.01., 데이터 산업진흥 및 이용촉진에 관한 기본법 등)

[표 1] [제1권] AI 데이터 품질관리 가이드 v3.5과 v4.0 비교

- 기존 1-Cycle 자가점검 수행 체계 (AI데이터 품질관리 가이드 v3.5)를
‘25년 초거대AI 확산 생태계 조성사업에 적용한 결과를 분석하여 1-Cycle 자가점검 체계 개선

구분	대상	근거	개선내용
폐지	과제조정위원회 자가점검	- 사업 협약 이전 단계로 규정상 자가점검 요구의 어려움 - 실제 개방될 데이터를 기반으로 자가점검 수행 필요	과제조정위원회 자가점검 폐지
개선	샘플데이터 1-Cycle 자가점검	- 사업 착수 이후 실제 구축한 데이터 및 샘플데이터 1-Cycle 자가점검 결과 기반으로 품질지표기준서 v1.00이 논의되어야 하나 1% 수량 확보 기간에 따라 자가점검 및 지표 설정 지연 - 실제 구축 데이터를 기반으로 데이터 구축 계획 적정성, 품질목표 조기 점검 필요성 제기	샘플데이터 자가점검 대상 수량 조정
개선	중간데이터 1-Cycle 자가점검	중간데이터 1-Cycle 자가점검 결과에 대한 데이터 오류, 개선조치 미흡으로 최종검증 진행시 자가점검에서 발견되는 오류 반복 확인	중간데이터 보완점검 신설


[표 2] 1-Cycle 자가점검 체계 개선 배경

제2권

AI 데이터 구축 가이드

- 데이터 구축 공정 기반 데이터 구축 실무 사례 제시

- '25년 데이터 구축사업의 실무 사례를 획득부터 학습까지의 전 공정 단계별로 상세히 제시
- 데이터 특성(LLM, LMM, 합성, 추론)에 따라 NIA의 지침 및 요구사항에 기반한 구축 과정을 집약
- 데이터 구축기관의 역량 강화와 AI 데이터 구축 과정을 설명하는 실질적인 가이드라인을 제공




실제 데이터 구축 사례를 기반으로 구축공정별 생성형 AI 데이터 구축 가이드 제공

[그림 3] [제2권] 데이터 구축 사례 안내

- 데이터 품질관리 중심의 1-Cycle 자가점검 사례 제시

- '25년 데이터 구축사업의 데이터 유형에 따른 단계별 1-Cycle 자가점검 수행사례를 제시



[그림 4] [제2권] 데이터 품질관리 사례 안내


- 데이터 구축과정에서 발생된 오류 유형 분석 및 사전 예방 방안 제시

- '25년 데이터 구축사업 수행 중 발생한 주요 품질 오류 유형과 분석 결과 수록
- 데이터 구축 단계에 발생가능한 유사 문제의 사전 예방 및 지속적 품질 개선을 위한 대응방안 제공

[제2권] AI 데이터 구축 가이드 v3.5과 v4.0 비교

● 2025년 2월에 발간된 '[제2권] AI 데이터 구축 가이드 v3.5'과 내용 구성 비교

(제2권) AI 데이터 구축 가이드 v3.5
AI 데이터 품질관리 가이드라인 v3.5



(제2권) AI 데이터 구축 가이드 v4.0
AI 데이터 품질관리 가이드라인 v4.0



[그림 5] [제2권] AI 데이터 구축 가이드 v3.5과 v4.0 비교


변경점	변경 상세	
	v3.5	v4.0
데이터 구축사례	제1장 데이터 구축사례 [LLM] 사례 데이터 [LMM] 사례 데이터 [합성] 사례 데이터	제1장 데이터 구축사례 [데이터 획득/수집] [데이터 정제] [데이터 가공] [데이터 학습]
데이터 품질관리 사례	제2장 데이터 품질관리 사례 [LLM] 사례 데이터 [LMM] 사례 데이터 [합성] 사례 데이터	제2장 데이터 품질관리 사례 [LLM] 사례 데이터 [LMM] 사례 데이터 [합성] 사례 데이터 [추론] 사례 데이터

[표 3] [제2권] AI 데이터 구축 가이드 v3.5과 v4.0 비교

제3권

생성형AI 데이터 품질관리 가이드

- 생성형AI 데이터 품질관리를 위한 전반적인 가이드 제시
 - 생성형AI 데이터의 특징 및 품질관리 방법·절차 제시
 - 생성형AI 데이터의 구축 및 활용 시 품질관리 활동 및 산출물 등 제시
- 생성형AI 데이터 생애주기 기반 구축 절차 및 방법 제시
 - 생성형AI 데이터의 생애주기는 AI 데이터의 일반적인 생애주기인 ‘준비·계획’, ‘구축’, ‘운영·활용’ 단계를 따르며, 합성데이터 생성의 경우 별도 수록
 - 데이터 구축 단계(획득/수집, 정제, 가공, 학습)에 따른 고려사항 및 유의사항 제시



[그림 6] 합성데이터의 품질관리 프로세스

- 생성형AI 데이터의 특성을 반영한 품질관리 지표 제시
 - 생성형AI 데이터의 구조, 학습 방법 등을 고려한 지표 기준 설정 사례 제공
- 생성형AI 데이터 주요기술 제시
 - 이미지 캡서닝 방식과 그에 사용되는 생성 모델, 이미지 캡션 품질관리 관점의 캡서닝 기술 수록
 - 최신 트렌드를 반영한 생성형AI 주요 모델 및 기술 수록

[제3권] 생성형AI 데이터 품질관리 가이드 v2.0과 v2.5 비교

● 2025년 2월에 발간된 '[제3권] 생성형AI 데이터 품질관리 가이드 v2.0'과 내용 구성 비교

(제3권) 생성형 AI 데이터 품질관리 가이드 v2.0
AI 데이터 품질관리 가이드라인 v3.5I.
개요제1장 추진 배경 및 목적
제2장 품질관리 가이드라인 구성
제3장 생성형 AI 데이터 이해
제4장 생성형 AI 데이터 품질관리 이해

II.

생성형 AI
데이터
품질관리 체계제1장 데이터 구축 사례
제2장 품질관리 프로세스 및 산출물

III.

생성형 AI
주요 기술제1장 이미지 캡셔닝 기술
제2장 생성형 AI 주요 모델 및 기술IV.
부록부록 1. 품질관리 지표 기준
부록 2. 품질지표 설정 가이드(제3권) 생성형 AI 데이터 품질관리 가이드 v2.5
AI 데이터 품질관리 가이드라인 v4.0I.
개요제1장 추진 배경 및 목적
제2장 품질관리 가이드라인 구성
제3장 생성형 AI 데이터 이해
제4장 생성형 AI 데이터 품질관리 이해

II.

생성형 AI
데이터
품질관리 체계제1장 품질관리 프레임워크
제2장 품질관리 프로세스 및 산출물
제3장 구축과정별 품질관리 고려사항
1. 데이터 획득/수집 단계
2. 데이터 정제 단계
3. 데이터 가공 단계
4. 데이터 학습 단계구축과정별
품질관리 방안
확대25년
최신 기술
동향 반영

III.

생성형 AI
주요 기술제1장 이미지 캡셔닝 기술
제2장 생성형 AI 주요 모델 및 기술IV.
부록부록 1. 품질관리 지표 기준
부록 2. 품질지표 설정 가이드

[그림 7] [제3권] 생성형AI 데이터 품질관리 가이드 v2.0과 v2.5 비교

변경점	v2.0	v2.5
신규작성	-	- 가공단계 품질확보 고려사항 - 거대멀티모달 모델(LMM) - 거대언어모델 (LLM) - 합성데이터
생성형 AI 최신기술 반영	- 생성형AI 주요기술 - 제1장 이미지 캡셔닝 기술 - 제2장 생성형AI 주요 모델 및 기술	- 생성형AI 주요 신규 기술 반영 - 제1장 이미지 캡셔닝 기술 고도화 - 제2장 생성형AI 주요 모델·기술 고도화
품질특성	LLM, LMM, 합성데이터 품질특성 구성	LLM, LMM, 합성데이터 품질특성 고도화
품질측정항목	24년 데이터 구축사업 기준 학습 TASK 분야별 품질측정 항목	25년 데이터 구축사업 기준 학습 TASK 분야별 품질측정 항목 - 정형 합성데이터 추가 반영


변경점	v2.0	v2.5
품질특성 검사 항목 고도화	• 의미 정확성	• 의미 정확성 검사항목 고도화 • 의미 정확성 검사항목별 예시 및 상세 검사기준 반영
	• 유사성 - 내용 중복성(LLM) - 내용 유사성 - 도메인 유사성	• 유사성 - 내용 중복성(LLM) - 의미적 유사성(LLM) - 도메인 유사성
	• 합성데이터 유용성 - 모델성능 비교 - 이미지 생성 성능	• 합성데이터 유용성 검사항목 고도화 [비정형 데이터] - 모델성능 비교 - 이미지생성(VTT) - 이미지 품질(FID) [정형 데이터] - 일차원 분포 유사성 - 2차원 관계 유사성 - 구별 불가능성 - 모형성능 유사성
	• 합성데이터 안정성 - 구조적 유사성 - 지각적 유사성 - 주관적 검증	• 합성데이터 안전성 검사항목 고도화 [비정형 데이터] - 구조적 유사성 - 지각적 유사성 - 주관적 검증 [정형 데이터] - 구별 위험도 - 연결 위험도 - 추론 위험도
전체	• 24년 구축사업 기준	• 25년 구축사업 기준으로 전체 내용 최신·현행화

[표 4] [제3권] 생성형AI 데이터 품질관리 가이드 v2.0과 v2.5 비교

제4권

신기술 AI 데이터 품질관리 가이드

- 신기술 AI 데이터 품질관리를 위한 전반적인 가이드 제시
 - 생성형 AI 분야에서 대두되는 신기술인 “추론형 AI”를 위한 데이터 품질관리 가이드 제시
 - 추론형 AI 데이터의 특징 및 품질관리 방법·절차 제시
 - 추론형 AI 데이터의 구축 및 활용 시 품질관리 활동 및 산출물 등 제시
- 데이터 생애주기 기반 품질관리 활동 제시
 - 추론 경로 및 사고과정이 학습 성능에 영향을 주는 핵심정보로서 추론형 AI 데이터의 품질 특성을 고려한 품질관리 활동을 정의
 - 사고과정 및 판단 근거를 충실하게 반영했는지 점검하기 위해 가공데이터 품질검사를 2단계 구조로 세분화하여 수행



[그림 8] 추론형 AI 데이터의 품질관리 프로세스

- 추론형 AI 데이터의 특성을 반영한 품질관리 지표 제시
 - 추론형 AI 데이터의 구조, 학습 방법 등을 고려한 지표 기준 설정 사례 제공
- 추론형 AI 데이터 주요기술 제시
 - 추론형 AI 방식과 모델, 추론형 AI 주요 기술수록

[제4권] 신기술 AI 데이터 품질관리 가이드 v1.0 구성

● '[제4권] 신기술 AI 데이터 품질관리 가이드 v1.0' 주요 내용 및 구성

구분	v1.0	
I. 개요	제1장 추진 배경 및 목적	1. 추진배경 2. 신기술 AI 데이터 품질관리 가이드의 목적
	제2장 가이드라인 구성 및 범위	1. 가이드라인 구성 개요 2. 가이드라인 적용범위 (추론형 AI 데이터 생애주기)
	제3장 추론형 AI 데이터 이해	1. 추론형 AI 정의 2. 추론형 AI 특징 3. 주요 추론형 AI 데이터셋 동향 4. 추론형 AI 데이터 생성 및 품질관리 기술
	제4장 추론형 AI 데이터 품질관리의 이해	1. 추론형 AI 데이터 품질관리 필요성 2. 추론형 AI 데이터 품질관리 개념 및 정의 3. 추론형 AI 데이터 품질관리 목적과 기대효과 4. 추론형 AI 데이터 품질관리 활동
II. 추론형 AI 데이터 품질관리 체계	제1장 품질특성 및 고려사항	1. 추론형 AI 데이터의 특성 2. 추론형 AI 데이터 특성별 고려사항 3. 추론형 AI 데이터 품질특성
	제2장 추론형 AI 데이터 품질관리	1. 품질관리 프레임워크 구성 2. 추론형 AI 데이터 품질관리 활동 3. 추론형 AI 데이터의 품질관리 프로세스 및 산출물 4. 추론형 AI 데이터 가공 단계 품질관리 활동
III. 추론형 AI 주요기술	제1장 추론형 AI 기법	1. 개요 2. 추론형 AI 기본 구조 3. 추론형 AI 강화 기법 4. 도메인/표현 확장 적용기법
	제2장 추론형 AI 주요 모델	1. 개요 2. LLM 데이터 추론모델 3. LMM 데이터 추론모델 4. 합성데이터 추론모델 5. 액션중심 데이터 추론모델 6. 추론형 AI 데이터의 주요 벤치마크 데이터셋
IV. 부록	부록1. 품질관리 지표 기준	1. 품질관리 지표 2. 구축공정 적정성 품질관리 지표 3. 데이터 적합성 품질관리 지표 4. 가공데이터 정확성 품질관리 지표 5. 학습모델 적합성 품질관리 지표
	부록2. 품질지표 설정가이드	1. 의미정확성 품질지표 설정 가이드 2. 유효성 품질지표 설정 가이드

[표 5] [제4권] 신기술 AI 데이터 품질관리 가이드 v1.0 주요내용 구성

AI 데이터 품질관리 가이드라인 v4.0

제1권

품질관리 프레임워크를 중심으로

AI 데이터 품질관리 가이드 v4.0

I

개요

제1장 | 추진 배경 및 목적

제2장 | 품질관리 가이드라인 구성

제3장 | 인공지능 학습용 데이터 이해

제4장 | 인공지능 학습용 데이터 품질관리 이해

제1장


추진 배경 및 목적

1

추진 배경

● 정부의 인공지능 학습용 데이터 기반 정책 추진

- 대규모 인공지능 학습용 데이터 구축 및 개방을 목표로 지능 데이터 기반 정책 추진
- 인공지능 학습용 데이터를 구축하고 민간에 개방함으로써 인공지능 기반의 산업 생태계 확산 추진
- 초거대AI 경쟁력 강화 방안, 서비스 산업의 디지털 전략 등 초거대AI 모델 구축, 활용 계획의 구체화



[그림 1-1] 인공지능 학습용 데이터 품질관리 체계 수립 추진 배경

● 인공지능 학습용 데이터 품질관리 체계 수립 필요

- 2017년부터 매년 인공지능 학습용 데이터 구축사업을 통한 대규모 데이터 개방 추진
- 개방된 인공지능 학습용 데이터의 품질관리 강화를 통한 활용도 제고 필요
- 품질관리에 대한 체계 수립 필요에 따라 사업수행기관¹⁾, 산·학·연계의 인공지능 및 품질관리 전문가들의 의견을 반영한 '품질관리 가이드라인' 배포


1) 사업수행기관 = 주관기관 + 참여기관

- (주관기관) 과제를 주관하여 수행하는 대표 기관(기업)

- (참여기관) 주관기관과 공동으로 해당 과제에 참여하여 사업을 수행하는 기관(기업)

2 목적

- 인공지능 학습용 데이터 품질의 중요성이 점차 강조되고 있으나, 구체적인 품질관리 방법이나 절차 등에 대해서는 다양한 시각이 존재하므로 이에 대한 방향 제시 필요



[그림 1-2] 인공지능 학습용 데이터 품질관리 체계 수립 배경 및 목적

- ‘초거대AI 확산 생태계 조성 사업’ 수행기관의 품질관리 역량 강화
 - 사업수행기관의 품질관리 역량을 강화하여 고품질의 학습용 데이터 확보
 - 인공지능 학습용 데이터 구축 단계부터 품질관리 체계 확보
 - 사업수행기관의 담당자들에게 품질관리에 필요한 실무 차원의 안내서(지침) 제공
- 데이터 구축 체계화를 통한 고품질의 인공지능 학습용 데이터 확보
 - 데이터 품질관리에 대한 이해를 바탕으로 생애주기 전반의 일관된 품질관리 기준 제공
 - 인공지능 학습용 데이터 품질관리 프레임워크 개발을 통한 체계적인 구축 절차 제시
- 인공지능 기반의 데이터 산업 생태계 지원
 - ‘AI-Hub’ 플랫폼에 개방된 데이터의 품질관리를 통한 원활한 활용 지원

제2장

품질관리 가이드라인 구성

- ‘AI 데이터 품질관리 가이드라인 v4.0’ 구성

- 『제1권 AI 데이터 품질관리 가이드 v4.0 (부제: 품질관리 프레임워크 중심)』,
- 『제2권 AI 데이터 구축 가이드 v4.0 (부제: 구축 사례 중심)』,
- 『제3권 생성형AI 데이터 품질관리 가이드 v2.5 (부제: LLM, LMM, 합성데이터 중심)』
- 『제4권 신기술AI 데이터 품질관리 가이드 v1.0 (부제: 추론형AI 데이터 중심)』
- 본 책자는 『제1권 AI 데이터 품질관리 가이드 v4.0』으로 해당 구성 내용 기술

1

제1권 AI 데이터 품질관리 가이드 구성

- I. 개요

- 인공지능 학습용 데이터 특성과 생애주기에 대한 이해
- 데이터 구축사업 전반 및 품질관리에 대한 이해

- II. 품질관리 체계

- ‘품질관리 프레임워크’에서 단계별 프로세스와 품질관리 활동 및 산출물 등을 체계적으로 구성
- 데이터 구축사업의 이해관계자 및 품질관리 조직의 역할 및 책임 정의
- 품질관리 활동의 중요한 요소인 1-Cycle 자가점검에 대한 프로세스 및 주요 점검 항목 수록

- III. 부록

- 인공지능 학습용 데이터 품질 수준 측정을 위한 품질관리 지표 제시
- 데이터 유형별(이미지, 텍스트 등) 품질지표 설정 방향을 제시하는 가이드 수록
- 데이터 구조를 결정하는 가공데이터 설계 및 구축을 지원하기 위한 데이터 가공 가이드 수록
- 데이터의 권리 확보 이슈를 방지하기 위한 생애주기별 개인정보보호 가이드라인 제시

- IV. 참고자료

- 용어 정의
- 참고 문헌

목 차	제 목	소 제 목
I 개요	제1장 추진 배경 및 목적	1. 추진 배경 2. 목적
	제2장 품질관리 가이드라인 구성	1. 제1권 AI 데이터 품질관리 가이드 구성
	제3장 인공지능 학습용 데이터 이해	1. 인공지능 학습용 데이터
		2. 인공지능 학습용 데이터 특성
		3. 인공지능 학습용 데이터 생애주기
	제4장 인공지능 학습용 데이터 품질관리 이해	1. 인공지능 학습용 데이터 품질관리 원칙
		2. 인공지능 학습용 데이터 구축 과정
		3. 인공지능 학습용 데이터 품질관리 범위
		4. 인공지능 학습용 데이터 품질검사 활동
II 품질관리 체계	제1장 품질관리 프레임워크	1. 품질관리 프레임워크 구성
		2. 품질관리 이해관계자 정의
		3. 품질관리 조직 체계
	제2장 품질관리 프로세스 및 산출물	1. 준비·계획 단계(100)
		2. 구축 단계(200)
		3. 운영·활용 단계(300)
		4. 단계별 산출물
	제3장 품질 자가점검 및 품질검증	1. 개요
		2. 품질 자가점검
		3. 제3자 품질검증
III 부록	부록 1 품질관리 기준	1. 품질관리 지표
		2. 구축 공정 적정성 품질관리 지표
		3. 데이터 적합성 품질관리 지표
		4. 가공데이터 정확성 품질관리 지표
		5. 학습모델 적합성 품질관리 지표
	부록 2 품질지표 설정 가이드	1. 품질지표 설정 개요
		2. 학습데이터 유형
		3. 품질지표 설정 가이드
	부록 3 데이터 가공 가이드	1. 텍스트, 음성 데이터 가공
		2. 이미지, 영상 데이터 가공
		3. 3D 데이터 가공
	부록 4 개인정보보호 가이드	1. 인공지능 개인정보보호 개요
		2. 생애주기별 개인정보보호 가이드라인
IV 참고자료	제1장 용어 정의	
	제2장 참고 문헌	

[표 I-1] 제1권 AI 데이터 품질관리 가이드 구성

제3장

인공지능 학습용 데이터 이해

1

인공지능 학습용 데이터

● 인공지능 학습용 데이터(AI Dataset)

- 머신러닝(Machine Learning), 딥러닝(Deep Learning) 등 AI모델 학습을 위해 활용되는 데이터를 총칭
- 특히 ‘인공지능 학습용 데이터 구축’ 사업의 경우, 비정형 또는 반정형 데이터를 수집하고 참값(GT, Ground Truth) 어노테이션을 통해 가공하여, 지도 학습(Supervised Learning), 비지도 학습(Unsupervised Learning) 및 초거대(생성형) AI에 쓰이는 데이터를 구축하는데 초점

● 품질(Quality)

- 사전적으로는 “물건의 성질과 바탕”이라고 정의하고 있으며, 데이터 관점에서는 일반적으로 ‘사용하기에 적절한 수준(Fit for use)’이라고 통용
- 즉, 품질의 개념은 품질의 대상이 무엇인가에 따라 달라질 수 있음
- ‘인공지능 학습용 데이터 품질’이란, 인공지능 학습용 데이터 구축과정 및 데이터의 품질기준(다양성, 정확성 등)을 확보(달성)하여 사용자에게 유용한 가치를 줄 수 있는 데이터의 수준이라고 정의할 수 있음

● 품질관리(Quality Management)

- 인공지능 학습용 데이터 품질을 확보하는데 필요한 조직, 절차, 품질기준, 품질관리 방법이나 활동 등을 정의하여 점검하고 조치하는 일련의 활동

● 품질관리 활동에서의 품질검사, 품질검증, 품질관리에 대한 정의

구분	품질검사 (Quality Inspection)	품질검증 (Quality Verification)	품질관리 (Quality Management)
정의	인공지능 학습용 데이터 구축 및 모델 관점에서 주요 품질 문제를 식별하고 문제의 근원적 원인을 파악하여 개선 기회를 도출하는 기법을 의미	인공지능 학습용 데이터의 품질 보장을 위해 구축한 데이터의 품질을 제3자가 품질검증	인공지능 학습용 데이터의 구축 시 생산되는 데이터(원천, 가공 등)와 구축공정의 품질을 확보하기 위한 제반 활동
중점	데이터의 결함을 예방하고 오류를 방지하는데 중점	데이터의 부적합, 결함을 감지하고 시정 조치 활동에 중점	데이터의 특성을 고려한 품질관리 기준을 수립하여 지속 가능한 품질 확보에 중점
대상	특정 주요 지표 및 절차	특정 주요 지표 및 절차	원칙, 대상, 기준, 조직, 절차 등
주체	사업수행기관	품질검증기관	사업관리기관, 품질검증기관, 사업수행기관

[표 1-2] 품질검사/품질검증/품질관리 정의

2 인공지능 학습용 데이터 특성

- 인공지능 학습용 데이터의 품질관리는 데이터 특성을 파악하여 적합한 품질관리 체계를 구축하는 것이 핵심이며, 특히 데이터베이스에 저장되는 구조화된 데이터의 경우, 인공지능 학습용 데이터 특성을 고려한 차별화된 품질관리 체계 구성이 필요

2.1 인공지능 학습용 데이터의 특성

- 특정 인공지능 모델의 학습을 목적으로, 사전에 정의된 임무(Task)에 따라 체계적으로 구축되는 데이터
- 지도 학습의 특징에 따라 이미지, 텍스트 등 비정형데이터를 대상으로 가공작업을 통해 참값(GT²⁾)을 부여하며, 가공 항목에 따라 쓰임이 정해지는 등 품질이 엄격히 통제되어야 하는 특성을 가짐
- 인공지능 학습용으로 구축되는 데이터는 사용자의 아이디어에 따라 무한한 활용 가능성을 가진다는 특성을 가짐

2.2 머신러닝의 주요 학습 방식에 따른 데이터의 특성

구 분	지도 학습 (Supervised learning)	비지도 학습 (Unsupervised learning)	강화 학습 (Reinforcement Learning)
학습 방법	• 정답(Label)이 있는 데이터로 학습	• 정답(Label) 없이 패턴을 학습	• 보상(Reward)을 기반으로 학습
주요 Task	• Classification (분류) • Regression (회귀) • Object Detection (객체 탐지) • Semantic Segmentation (의미론적 분할)	• Clustering (군집화) • Association Rule Learning (연관 규칙 학습) • Dimensionality Reduction (차원 축소) • Anomaly Detection (이상 탐지)	• Game AI (게임 AI) • Robotics Control (로봇 제어) • Real-time Decision Making (실시간 의사결정) • Autonomous Systems (자율 시스템)
학습 데이터	• 참값(GT)과 입력 데이터와 쌍을 이루는 데이터	• 참값(GT)이 없는 입력 데이터	• 참값(GT) 없이 에이전트와 환경 간 상호작용을 통해 축적되는 데이터
데이터 구조	• 입력과 출력의 쌍	• 구조화되지 않은 입력	• 상태(State) - 행동(Action) - 보상(Reward) - 정책(Policy) - 에피소드(Episode)의 순차적 데이터
학습 목적	• 예측 모델 생성 (Task Driven)	• 데이터 구조 및 패턴 발견 (Data Driven)	• 최적의 의사결정 정책 (Learn from Mistakes)

[표 1-3] 지도 학습-비지도 학습-강화 학습 비교

2) GT = Ground Truth (모델의 성능을 평가하거나 학습을 진행하기 위해 사용되는 정답, 참값을 의미)

- 지도 학습 (Supervised Learning)

- 입력과 정답(Label) 간의 관계를 학습하여 미지의 데이터를 예측하는 머신러닝 기법으로, 주어진 정답(Label)을 기반으로 모델이 학습하며 새로운 입력에 대한 정확한 예측을 수행함

구분	내용
학습의 특징	• 입력 데이터와 정답(Label)이 명확히 존재하며, 지도된 학습을 통해 모델이 예측 수행 • 모델 학습과정에서 오차(손실 함수)를 최소화하기 위해 정답(Label)과의 차이를 줄이는 방향으로 최적화 • 충분한 양의 정답데이터가 필요하며, 가공 품질이 모델의 성능에 직접적인 영향을 미침
학습에 적합한 데이터	• 충분한 양의 정답(Label) 데이터 • 특정한 분포나 특징에 편향되지 않고, 다양한 조건과 환경에서 수집된 다양한 데이터 • 노이즈가 적고, 정확한 정답(Label) 데이터

[표 1-4] 지도 학습

- 비지도 학습 (Unsupervised Learning)

- 비지도 학습은 정답(Label) 없이 데이터를 학습하는 머신러닝 기법으로, 데이터의 분포와 구조를 파악하여 유사한 데이터끼리 군집화하거나 패턴을 식별하는데 주로 사용됨

구분	내용
학습의 특징	• 특정 결과를 예측하는 것이 아닌, 주로 데이터셋 내의 숨겨진 패턴을 발견을 목표 • 지도 학습에 충분한 정답(Label) 데이터가 없는 경우 유용한 접근 방식임
학습에 적합한 데이터	• 군집화(Clustering) 또는 차원 축소(Dimensionality Reduction)와 같은 기법을 적용할 수 있게 그룹화할 수 있는 구조적 특징이 존재하는 데이터 • 패턴을 추출하고 군집을 형성하기 위한 충분한 양의 데이터 • 특정한 분포나 특징에 편향되지 않고, 다양한 조건과 환경에서 수집된 다양한 데이터 • 노이즈가 최소화된 데이터

[표 1-5] 비지도 학습

- 강화 학습 (Reinforcement Learning)

- 강화 학습은 에이전트가 주어진 상태(State)에서 행동(Action)을 선택하고, 이에 따른 보상(Reward)을 받아 정책(Policy)을 최적화하는 기법

구분	내용
학습의 특징	• 정답(Label) 없이 에이전트의 행동에 대한 평가인 보상(Reward)에 따라 학습됨 • 강화 학습용 데이터는 이전 상태와 행동에 의해 영향을 받으며, 다음 상태와 행동에 영향을 미치기 때문에 시간에 의존적인 특성을 가짐
학습용 데이터 특성	• 강화 학습용 데이터는 상태(State) - 행동(Action) - 보상(Reward)으로 구성 • 데이터는 미리 주어진 데이터셋이 아니라, 에이전트와 환경 간 상호작용을 통해 축적됨 • 현재 상태(State)와 행동(Action)이 다음 상태(State)와 보상(Reward)에 영향을 미치는 시계열적 데이터 구조

[표 1-6] 강화 학습


3 인공지능 학습용 데이터 생애주기

I

개
요

3.1 인공지능 학습용 데이터 생애주기 개요

- 인공지능 학습용 데이터의 품질관리 활동을 식별하기 위해서는 데이터의 생애주기를 분석하여 생애주기를 기반으로 품질관리 범주 식별 필요
- 인공지능 학습용 데이터를 구축하여 민간에 개방하기까지의 생애주기는 다음과 같음




[그림 1-3] 인공지능 데이터 생애주기

- 데이터 구축 공정에 따라 크게 '준비·계획', '구축', '운영·활용' 영역으로 구분되며, 각 영역에서는 품질관리의 주체를 식별하고 세부 활동을 정의하여 업무를 수행하는 과정에서 생기는 의사소통의 어려움이나 혼란 방지

3.2 생애주기 기반 품질관리 체계

- 고품질의 인공지능 학습용 데이터를 확보하고, 지속적인 품질을 유지하거나 품질향상을 위한 인공지능 학습용 데이터의 품질관리 체계를 생애주기 기반으로 제시하면 다음과 같음



[그림 1-4] 인공지능 학습용 데이터 품질관리 체계

- (품질관리 대상) 인공지능 학습용 데이터 구축사업 및 AI-Hub를 통해 민간에 개방하는 인공지능 학습용 데이터셋 대상
- (품질관리 기준) 품질관리 원칙의 준수에 대한 객관적인 검증지표를 말하며, 구축 공정 품질기준과 데이터 자체의 품질기준으로 나눔
- (품질관리 조직) 인공지능 학습용 데이터의 품질확보 및 품질관리 활동을 수행하는 조직을 의미하며, 역할 및 책임을 부여하고 품질관리 활동을 수행
- (품질관리 절차) 인공지능 학습용 데이터의 품질을 검사하고, 저품질이나 오류 등의 원인을 분석해서 개선조치를 하는 일련의 활동을 의미
- (생애주기별 품질관리 활동) 계획, 구축, 운영·활용 단계의 각 영역에서 수행해야 할 품질관리 활동 정의
- (품질관리 도구 및 지원 인프라) 품질검사나 품질관리 활동을 수행하는 데 사용하는 도구(Tool)나 기술(Technology), 플랫폼(Platform) 등을 의미

제4장

인공지능 학습용 데이터 품질관리 이해

1 인공지능 학습용 데이터 품질관리 원칙


- 고품질의 인공지능 학습용 데이터 확보를 위해서는 원시데이터, 원천데이터, 가공데이터 자체의 품질 확보와 사용자 요구에 맞춰 품질을 지속적으로 유지하거나 향상시키기 위한 품질관리 체계 확보 필요
- 인공지능 학습용 데이터의 품질관리가 지향하는 상위 수준의 ‘품질관리 원칙’ 필요
- 인공지능 학습용 데이터의 품질관리 원칙을 크게 품질관리 측면과 데이터 측면으로 구분하여 제시

구분	원칙
품질관리 측면	• 인공지능 학습용 데이터의 전 생애주기의 품질 보장 • 상시적이고 지속적인 인공지능 학습용 데이터 품질개선 가능 • 데이터 품질관리를 위한 조직을 구성하고, 정해진 역할과 책임에 따라 수행 • 조직의 품질관리 역량을 확보하도록 품질관리 교육 등 지원체계 확보
데이터 측면	• 인공지능 학습용 데이터를 학습하는 데 필요한 요구사항 충족 • 법률적 제약 없이 누구나 활용 가능 • 학습 목적에 부합하도록 획득/수집되어야 하며, 데이터는 중복 없이 원하는 목적에 따라 정제 • 인공지능 학습용 데이터에 부여하는 참값(Ground Truth) 등의 가공 정보의 정확성 확보 • 인공지능 학습모델을 통해 목표로 하는 유효성 확보

[표 1-7] 품질관리 원칙

2 인공지능 학습용 데이터 구축 과정

- 인공지능 학습용 데이터 구축 과정은 다양한 유형의 데이터가 사전에 정의된 목적에 따라 구축되기 때문에 세부적으로는 상이할 수 있으나, 구축계획 수립, 데이터 획득/수집, 데이터 정제, 데이터 가공, 데이터 학습 순서로 반복하여 진행
- 인공지능 학습용 데이터 구축 과정에서 확보된 품질이 학습데이터 전체의 품질을 결정하기 때문에, 인공지능 학습용 데이터의 품질관리를 위해서는 데이터 구축 시 수행되는 구축공정의 이해 필요
- 구축계획 수립 단계
 - 인공지능이 기계학습을 통해 해결하고자 하는 문제를 명확하게 정의하고, 문제 해결에 필요한 인공지능 학습용 데이터를 구체적으로 정의하고 설계하는 활동
 - 구축계획서에는 ‘구축 개요’, ‘데이터 구축’, ‘품질 자가점검 계획’ 등 데이터 구축 목적과의 일관성 확보를 위한 세부내용을 작성하고, 특히 사업공고문의 요구사항을 반영하여 명확하고 구체적으로 작성



[그림 1-5] 인공지능 학습용 데이터 구축과정

● 데이터 획득/수집 단계

- 인공지능의 기계학습에 필요한 데이터를 현실 세계에서 직접 생산하거나, 이미 보유하고 있는 조직이나 시스템 등으로부터 인공지능 학습에 필요한 데이터를 확보하는 등, 법률적 제약이 없도록 목적에 따른 ‘원시데이터’를 확보하는 활동 수행
- 데이터 획득/수집 시 일부 범주에만 치우치지 않도록 다양한 시간, 공간, 집단 수준 등이 포함되어야 함
- 원시데이터를 직접 획득하거나 수집하는 경우, 특성을 고려하여 원시데이터의 품질을 확보
- ‘원시데이터’는 기계학습을 목적으로 획득 또는 수집한 ‘이미지’, ‘비디오’, ‘오디오’, ‘텍스트’ 등의 데이터를 의미

● 데이터 정제 단계

- 획득한 원시데이터를 학습에 필요한 형식 및 크기로 조정하고, 데이터 중복제거, 개인 정보 비식별화 처리 등의 과정을 통해 ‘원천데이터’를 확보하는 활동 수행
- 이 단계에서 확보된 ‘원천데이터’는 데이터 가공되지 않은 상태의 데이터이며, 원천데이터는 원시 데이터를 데이터 가공작업을 수행하기 위해 정제 작업을 수행한 데이터를 의미

● 데이터 가공 단계

- 인공지능의 학습에 활용할 수 있도록 기능이나 목적에 부합하는 라벨을 원천데이터에 부착하는 ‘가공’ 작업 수행
- 여기서 생성된 ‘가공데이터’는 원천데이터에 부여한 ‘참값(Ground Truth)’, 파일 형식, 해상도 등의 데이터 속성과 설명, 주석 등이 포함된 ‘어노테이션’의 집합을 의미
- 어노테이션 정보는 데이터 확장을 고려하여 가공 용어 정의 및 분류체계의 표준을 준수

※ 데이터 구축 시 임무 유형 및 목적에 따라 가공단계를 생략할 수 있음

● 데이터 학습 단계

- ‘학습 데이터셋’을 이용하여 사전에 정의된 인공지능 모델을 학습시키고, 학습된 시모델의 성능을 향상시키거나 보정하는 활동 수행
- ‘학습 데이터셋’은 ‘원천데이터’와 ‘가공데이터’ 쌍을 의미
- 데이터 학습 유효성 평가를 위한 정확도, 정밀도, 재현율 등 성능지표 확인

3 인공지능 학습용 데이터 품질관리 범위

- 인공지능 학습용 데이터의 생애주기를 기반으로 분류한 품질관리 범위는 다음과 같음
- 구축 프로세스 품질관리
 - 데이터 획득/수집, 데이터 정제, 데이터 가공 등 구축 과정에서 원하는 수준의 데이터 품질을 보장하기 위하여 품질관리 제반 활동을 수행하는지 모니터링 및 발견된 문제점 보완
- 구축 데이터 품질관리
 - 구축사업을 통해 생성되는 원시데이터, 원천데이터, 가공데이터 등 데이터 자체의 품질을 검사하고, 발견된 오류를 개선하는 활동
- 개방데이터 품질관리
 - AI-Hub에 적재된 데이터를 대상으로 운영·활용 단계에서 학습용 데이터셋의 품질을 향상시키는 활동을 지속적으로 수행하고, 품질 개선의견이 제기되는 경우 이에 적극적으로 대응 및 조치


단 계	품질관리 범위	수행 내용
준비·계획 단계 구축 단계	구축 프로세스	● 구축사업에 참여하는 사업수행기관이 자체적으로 품질관리 수행 ● 민간에 개방된 학습 데이터셋의 품질 개선의견이 제기된 경우, 사업수행기관이 품질개선 활동 직접 수행
	구축 데이터	
운영·활용 단계	개방데이터	● 데이터 개방을 위해 개방 전 점검 활동 수행 ● AI-Hub를 통해 개방된 데이터의 지속적인 품질관리를 위해 사업수행기관과 사업관리기관이 함께 품질관리 활동 수행 ● 사업관리기관은 사용자로부터의 데이터 품질에 대한 개선의견을 검토하고, 해당 데이터를 구축한 사업수행기관에 품질개선을 요청하며, 사업수행기관은 이를 반영하여 품질개선 수행

[표 1-8] 품질관리 범위에 따른 세부 수행 내용

4 인공지능 학습용 데이터 품질검사 활동

4.1 품질검사 수행절차

- 사업수행기관 및 참여기관의 품질관리자가 구축공정별 품질관리를 위해 수행해야 하는 품질검사 및 개선절차는 다음과 같음



[그림 1-6] 인공지능 학습용 데이터 품질검사 및 개선절차

- 구축공정별 품질관리를 위해 수행해야 할 품질검사 영역별 세부 수행 내용을 다음과 같이 정의

번호	품질검사 수행 절차	수행 내용
1	검사대상 정의	- 원시데이터, 원천데이터, 가공데이터 등의 검사대상을 선정 - 해당 데이터가 요구되는 품질 수준에 부합하는 상태인지를 판단하기 위한 품질검사 계획을 수립
2	품질검사 실시	정의된 검사대상에 대해 준비성, 완전성, 유용성, 적합성, 정확성, 유효성 등의 품질관리 지표에 대해 품질점검 체크리스트와 같은 검사기법 등을 적용하여 품질검사 실시
3	검사 결과 분석	품질검사 결과를 바탕으로 주요 품질문제를 식별하고 문제의 근본적 원인을 파악하여 품질문제를 해결하기 위한 개선 기회를 도출하는 단계
4	개선수행	품질문제 해결을 위해 개선계획 및 방안을 정의하고 우선순위를 결정하며, 결정된 우선순위에 따라 데이터 보정, 추가 작업 등 개선 영역별 품질개선 활동 수행
5	품질통제	개선 수행 결과의 확인 및 점검을 통해 품질목표를 재설정하여 품질문제 재발 방지 및 고품질 데이터를 유지하기 위한 품질관리 활동 수행 단계

[표 1-9] 품질검사 수행절차별 수행 내용

4.2 품질검사 수행 범위

- 인공지능 학습용 데이터 구축사업은 구축계획 수립, 데이터 획득/수집, 데이터 정제, 데이터 가공 및 데이터 개방의 생애주기(Life Cycle)를 가지며, 이에 따라 품질특성과 생애주기 관점에서 각 품질검사 활동을 수행하며, 이에 따른 각 절차의 수행 범위는 다음과 같음

품질특성		생애주기(Life Cycle)				
		구축계획 수립	데이터 획득/수집	데이터 정제	데이터 가공	데이터 학습
구축 공정 적정성	준비성	●	●	●	●	
	완전성		●	●	●	
	유용성	●				●
데이터 적합성	기준 적합성	●	●	●		
	다양성	●	●	●	●	
가공 데이터 정확성	의미 정확성				●	
	구문 정확성				●	
학습모델 적합성	알고리즘 적정성					●
	유효성					●

※ 생애주기별 품질검사 적용지표를 활용하여 인공지능 학습용 데이터 구축사업과 사업수행기관 실정에 적합한 지표 선정

※ LLM, LMM, 합성의 품질특성은 『제3권. 생성형AI 데이터 품질관리 가이드』 수록

[표 I-10] 생애주기별 품질검사

- 각 품질관리 지표의 적용은 본 『제1권. AI 데이터 품질관리 가이드』에 제시된 검사 지표 및 방법에 해당 사항을 선택하여 적용

※ 데이터 구축의 경우 목적과 특성에 따라 검사기준 또는 단계별 품질검사 방법 추가 가능

(「제3권 부록1. 생성형AI 데이터 품질관리 기준」 참조)

4.3 품질검사 수행 방법

- (육안 검사) 사람의 육안으로 데이터의 오류, 손상 또는 데이터 자체의 이상 유무를 검사하는 품질검사의 기본적인 방법
- (도구 검사) 정제 도구, 품질검사 도구, 체크리스트 등 다양한 방법으로 검사


4.4 품질검사 절차 및 범위

- 사업관리기관에서는 인공지능 학습용 데이터 품질보장을 위해, 사업수행기관이 실시한 품질관리 활동을 객관적으로 확인하는 제3자 품질검증 활동을 수행하고 있음
- 인공지능 학습용 데이터 품질확보를 위한 품질검사 절차는 구축 수행기관 자체적으로 수행하는 자가점검과 제3자 기관이 수행하는 품질검증으로 구성되며 절차는 다음과 같음



[그림 1-7] 인공지능 학습용 데이터 품질점검 및 품질검증 절차

- 인공지능 학습용 데이터 품질검증 범위는 다음 그림과 같이 생애주기별 품질검사 적용지표를 기준으로 구축한 학습용 데이터 및 학습모델을 대상으로 함



[그림 1-8] 인공지능 학습용 데이터 품질검증 범위

AI 데이터 품질관리 가이드라인 v4.0

제1권

품질관리 프레임워크를 중심으로

AI 데이터 품질관리 가이드 v4.0

II

품질관리 체계

제1장 | 품질관리 프레임워크

제2장 | 품질관리 프로세스 및 산출물

제3장 | 품질 자가점검 및 품질검증


제1장

품질관리 프레임워크

1

품질관리 프레임워크 구성

- 인공지능 학습용 데이터의 품질확보를 위한 품질관리 프레임워크의 구성 요소는 다음과 같음



[그림 II-1] 품질관리 프레임워크 구성요소


조 직	구 분	내 용
-	단계	준비·계획, 구축, 운영·활용 3단계 사업 단계
사업수행기관	프로세스	준비·계획, 데이터 획득/수집, 데이터 정제, 데이터 가공, 데이터 학습 및 운영·활용 등 인공지능 학습용 데이터 계획, 구축, 운영의 사업 모든 단계와 관련된 프로세스
	산출물	사업수행 프로세스별 활동을 통해 생산되는 데이터 및 문서 등 산출물
	품질관리 활동	- 사업수행 단계별 품질관리 활동에 대한 정의 - 사업수행 일정별로 수행하는 자가점검 활동 - 제3자 품질검증 활동 정의
사업관리기관	품질관리 활동	사업발주 및 사업관리기관의 품질 관련 활동 정의

[표 II-1] 품질관리 프레임워크 구성 항목



[그림 11-2] 인공지능 학습용 데이터 품질관리 프레임워크

- 인공지능 학습용 데이터의 구축 및 운영단계는 준비·계획, 구축, 운영·활용 3단계로 구성되며, 각 단계별 프로세스 정의는 다음과 같음




[그림 II-3] 품질관리 프레임워크 프로세스 및 데이터 산출물

단 계	프로세스	프로세스 정의
100. 준비·계획	110. 구축계획 수립	- 구축목적의 일치성과 일관성 확보를 위한 구체적 계획 수립 - 사업수행기관의 컨소시엄 간 업무와 역할 정의 - 품질지표 및 목표, 품질점검 기준 수립 단계
200. 구축	210. 데이터 획득/수집	- 기계학습에 필요한 데이터를 획득/수집하는 단계로 원시데이터 생성 - 데이터 획득/수집에 대한 프로세스 및 원시데이터에 대한 품질관리
	220. 데이터 정제	- 데이터 획득/수집 프로세스로 생성된 원시데이터 중복제거, 비식별화 등 정제 작업을 진행하는 단계로 정제 작업을 수행한 원천데이터 생성 - 데이터 정제에 대한 프로세스 및 원천데이터 품질관리
	230. 데이터 가공	- 정제 프로세스에서 생성된 원천데이터에 기능이나 목적에 부합되게 가공데이터를 부여하여 인공지능 학습할 수 있는 형태로 가공하는 단계 - 데이터 가공을 거쳐 가공데이터가 생성 - 데이터 가공에 대한 프로세스 및 가공데이터 품질관리
	240. 데이터 학습	- 데이터 정제단계의 원천데이터와 데이터 가공단계의 가공데이터 묶음이 학습 데이터셋으로, 이용하여 학습시키고 학습된 AI모델의 성능을 보정하는 단계 - 데이터 학습에 대한 프로세스 및 학습용 데이터 품질관리
300. 운영·활용	310. 데이터 운영·활용	- 데이터 개방 전 개방을 위한 점검 활동 - AI-Hub에 적재되어 개방되는 학습용 데이터에 대한 품질관리 - 개방용 데이터 운영, 활용 지원을 위한 하자 및 유지보수 단계

[표 II-2] 품질관리 프레임워크 프로세스 정의

- 인공지능 학습용 데이터의 구축 및 운영단계별 프로세스 수행을 위한 품질관리 활동은 다음과 같음



[그림 II-4] 품질관리 프레임워크 프로세스별 품질관리 활동

단계	프로세스	품질관리 활동
100. 준비·계획	110. 구축계획 수립	1101. 사업수행 및 구축계획 수립
		1102. 데이터 구축 절차, 조직 구성
		1103. 임무 정의에 대한 적절성 검토
		1104. 품질목표 및 점검기준 수립
200. 구축	210. 데이터 획득/수집	2101. 획득/수집 방법 및 기준 현행화
		2102. 데이터 법적 근거 검토
		2103. 획득/수집 도구 및 저장환경 검토
		2104. 원시데이터 품질검사
	220. 데이터 정제	2201. 정제방법 및 기준 현행화
		2202. 개인정보/민감정보 비식별화 등 법적 준거 확보
		2203. 정제 도구 및 저장환경 검토
		2204. 원천데이터 품질검사
	230. 데이터 가공	2301. 가공 방법 및 기준 현행화
		2302. 가공 도구 및 저장환경 검토
		2303. 가공데이터 품질검사
	240. 데이터 학습	2401. 구축목적-AI모델 합치성 확인
		2402. 학습결과 확인 및 최적화
		2403. 품질검증결과 보완조치
300. 운영·활용	310. 데이터 운영·활용	3101. 데이터 개방을 위한 점검 활동
		3102. 개방용 데이터 하자 및 유지보수
		3103. 사용자 품질개선 의견 반영

[표 II-3] 사업수행기관의 단계별 품질관리 활동

- 데이터 구축 분량에 따른 사업 일정별 자가점검 활동에 대한 정의와 제3자 품질검증 활동은 다음과 같음



[그림 II-5] 품질자가점검 및 품질검증 활동

- 품질 자가점검 활동 중 초기데이터 1-Cycle 자가점검, 중간데이터 1-Cycle 자가점검은 필수적으로 수행하고, 그 외 자가점검 활동은 구축사업의 규모나 범위, 일정 등에 따라 선택적으로 수행


사업일정	자가점검 활동	활동 내용	품질검증(제3자)
사업 착수	샘플데이터 1-Cycle 자가점검	- 사업 착수 이후 사업수행계획서와 샘플데이터(각 클래스당 최소 1건) 기준으로 데이터 설계를 위한 자가점검 수행 - 샘플데이터 1-Cycle 자가점검을 통해 품질지표/목표 검토 - 사업수행계획 기반 데이터 구축 공정의 적정성 검토 및 품질지표 수립을 위한 준비	사업수행계획서 및 과제조정위원회 결과를 기반으로 사업수행기관과 품질지표에 대한 기준 합의
구축 초기시점	초기데이터 1-Cycle 자가점검	초기데이터(5~10% 이내)를 대상으로 데이터 획득/수집, 정제, 가공, 학습까지의 전 공정에 대한 자가점검 수행	수행기관의 1-Cycle 자가점검 결과보고서 v1.0을 대상으로 사전 품질검증 진행
중간 시점	중간데이터 1-Cycle 자가점검	중간데이터(30% 이상)를 대상으로 데이터 획득/수집, 정제, 가공, 학습까지의 전 공정에 대한 자가점검 수행 ※ 구축 범위는 사업 유형, 규모, 범위 및 일정에 따라 변경 가능	-
	중간데이터 보완점검	- 중간데이터(30%)와 보완된 기준으로 신규 구축한 데이터 (20%)를 포함한 분량(50%)을 대상으로 자가점검 수행 - 중간데이터 1-Cycle 자가점검 결과 도출된 오류 항목을 중심으로 점검 및 데이터 보완 ※ 구축 범위는 사업 유형, 규모, 범위 및 일정에 따라 변경 가능	-
최종 시점	최종데이터 1-Cycle 자가점검	사업 최종 시점에 전체 학습용 데이터를 대상으로 전체 공정에 대한 품질점검 활동	최종데이터에 대한 제3자 품질검증 진행

※ 자가점검 활동별 자가점검 데이터량은 활동 내용에 제시된 범위 내에서 사업 일정 및 데이터 특성에 따라 선택

[표 II-4] 사업 일정에 따른 자가점검 활동 및 품질검증

2 품질관리 이해관계자 정의

- 인공지능 학습용 데이터 구축사업의 조직구조는 사업발주기관인 사업관리기관, 사업수행을 위한 사업수행기관과 제3자 품질검증을 위한 품질검증기관으로 구성되어 있음



[그림 II-6] 품질관리 이해관계자 관계

이해관계자	조직	내용
사업관리기관 (NIA)	사업운영 파트 (PMO)	- 사업자 선정, 과제조정, 협약체결, 사업수행관리, 최종 산출물 관리 등 사업 총괄 관리 - 데이터 구축 진척 현황 및 공정 관리
	품질관리 파트 (품질컨설팅)	- 품질관리팀에 품질컨설팅 조직 구성 - 품질컨설팅과 품질교육 담당 - 사업수행기관의 품질관리 역량 강화 및 품질 관련 이슈 사항 해결 - 사업담당자의 품질관리 지원 - 수행 업체 품질관리 산출물 가이드 및 검토
사업수행기관	품질관리조직	- 준비·계획 단계에서 품질조직을 구성 - 구축단계별 품질관리 활동을 수행하여 관련 산출물 제출 - 구축공정 가이드라인 현행화 - 데이터 품질관리 산출물 개선
품질검증기관	제3자 품질검증기관	사업수행기관과 품질지표 기준을 합의하고, 합의된 지표를 기준으로 품질검증을 실시하여 품질검증 결과 확인

[표 II-5] 품질관리 이해관계자 조직 정의

- 사업관리기관, 사업수행기관, 품질검증기관(제3자)의 품질 관련 상세 활동 및 역할은 다음과 같음

사업수행기관	사업관리기관		품질검증기관
	사업운영 파트	품질관리 파트	
[준비·계획] - 데이터 구축계획설계 - 품질관리 조직 구성 - 데이터 법적 근거 및 비식별화 방안 수립 - 임무 정의에 따른 품질목표 및 지표 설정 - SI모델 설계 [구축] - 구축공정별 세부사항 수립 - 데이터 법적 근거 및 비식별화 조치 - 구축공정별 저작도구 및 저장환경 확보 - 구축공정별 산출물 작성 및 현행화 - 구축목적에 따른 SI모델 최적화 [자가점검 계획] - 샘플데이터 1-Cycle 자가점검 [자가점검 실행] - 샘플/초기/중간/최종 데이터 1-Cycle 자가점검 - 중간데이터 보완점검 [데이터 품질관리] - 품질점검 관리 - 품질 산출물 개선 [운영·활용] - 개방 전/후 보완조치 - 품질검증 결과 - 사용자 품질개선 의견 등	PMO [구축 진척 관리] - 데이터 구축 공정 및 진척현황 점검 - 계획 대비 구축 현황 적정성 검토 [공정 이슈 점검] - 데이터 공정 과정 중 구축 지연 등 이슈 해소 [산출물 관리] - 각 공정별 필수 산출물 작성 점검 - 산출물 검토	품질컨설팅 [품질관리체계 마련] - 품질관리 프로세스/프레임워크 정립 - 품질관리 가이드라인 - 품질지표 설정 가이드 - 품질관리 교육 시행 [품질관리 컨설팅] - 구축공정별 품질관리 및 품질이슈 해소 지원 - 자가점검 지원 - 품질 산출물 작성 지원 - 품질 자문지원단 운영 - 검증 제반문서 작성 지원 - 품질지표 기준서 - 검증 제반문서 [품질 산출물 검토] - 구축공정별 1-Cycle 자가점검 산출물 적정성 검토 - 미흡, 보완 필요한 품질 산출물에 대한 보완요청	[품질 표준화 연구] - 신규 데이터 유형의 품질지표 선제 연구 - 다양한 산업 분야에 따른 데이터 규격 마련 - 데이터 품질관리 표준 제정 [품질지표 기준마련] - 품질지표 기준마련 및 기준서 합의 - 품질지표 기준서 v1.0 - 품질지표 기준서 v2.0 [품질검증] - 초기데이터 사전검증 - 미달성 과제 대상 보완조치 결과 확인 - 최종데이터 검증 수행 - 품질검증결과서 발급

[표 II-6] 품질관리 이해관계자 역할 및 책임

3 품질관리 조직 체계


- 사업수행기관은 구축되는 데이터의 실질적 품질관리 활동을 담당하는 ‘품질관리 조직’을 구성
- ‘품질관리 조직’은 데이터 작업자, 모델설계자, 외부기관 또는 전문가 등으로 구성하며 각 수행조직의 역할과 책임을 공식화하고, 품질관리 업무가 원활히 수행되는지 ‘총괄책임자’ 또는 ‘실무책임자’ 주도하에 수시로 확인 및 관리

3.1 품질관리 조직 구성 시 고려사항

- 사업수행기관(주관기관, 참여기관)의 유기적인 관계를 지닌 조직 구성
- 명확한 업무 분장을 통한 책임 소재를 파악할 수 있는 업무수행조직 구성
- 사업수행기관(주관기관, 참여기관) 간의 보고체계 구축
- 데이터 획득/수집 기관, 정제 및 가공 기관, 학습모델 개발 기관 등이 상이할 경우, 각 공정별로 참여 조직 구성
- 인공지능 학습용 데이터의 품질확보 및 구축 후 데이터 운영·활용 체제로의 원활한 전환 고려

3.2 품질관리 조직의 주요 업무 내용

- 품질관리 계획의 수립 및 보완
- 품질관리를 위한 협의체 구성 및 운영
- 구축 프로세스의 품질검사 및 개선
- 인공지능 학습용 데이터의 품질검사 및 개선
- 사업수행기관의 품질관리 역량 강화를 위한 품질관리 교육 실시
- 데이터 운영·활용 단계에서 발견된 품질 개선의견 조치



[그림 II-7] 구축사업 사업수행기관 품질관리 조직 구성(안)

3.3 품질관리 조직 내 구성원별 역할

조 직	역 할
총괄책임자	해당 인공지능 학습용 데이터 구축사업의 공모과제 책임자가 되며, 구축사업 착수 이전에 데이터 품질관리 실무를 총괄하는 '실무책임자' 지정
실무책임자	- 인공지능 학습용 데이터 구축사업의 품질관리 실무를 총괄하며, 타 업무와 겹직을 하지 않고, 품질관리 업무만을 전담하여 수행 - 구축하는 인공지능 학습용 데이터의 품질관리 계획을 수립하고, 품질관리 실무 수행조직을 운영하여 품질관리 활동을 수행하고, 품질관리 실무와 관련된 협의체 구성 및 운영 담당
품질관리 실무 협의회	- 인공지능 학습용 데이터의 품질관리 관련 실무차원의 주요사항을 검토하고, 조직간 협의 사항 조정, 조율 등을 위한 '품질관리 실무 협의회'를 설치·운영 - 사업수행기관의 품질관리 계획의 적정성 등을 평가하여 보완하고, 구축과정에서 발견된 데이터 품질 이슈를 논의하여 해결방안을 제시하는 등 상호 간의 의사소통 및 품질관리 실무를 협의하는 역할 담당 - 구축공정별 실무 담당자, AI모델 설계자, 외부 품질전문가 등 참여
구축 프로세스 품질담당	- 데이터 획득/수집, 정제, 가공 등 구축과정별로 구분하여 담당자를 지정할 수 있으며, 인공지능 학습용 데이터의 구축과정이나 구축 규모, 구축 난이도 등을 고려해서 담당자 지정 - 품질관리계획에 명시된 품질관리 활동의 준수 여부를 확인하고, 품질 이슈 발생 시 이를 기록하고 개선하는 활동을 수행하며, 즉각적인 조치가 불가능하거나 협의가 필요한 사항은 실무책임자에게 보고하는 등 역할 수행
구축 데이터 품질담당	구축과정에서 생성되는 '원시데이터', '원천데이터', '가공데이터'의 품질을 확보하기 위해 품질계획에 수립된 검사기준과 절차 등에 따라 품질을 검사하고, 개선하는 활동 수행
활용 품질담당	- 구축 이후에 AI-Hub를 통해 민간에 개방한 인공지능 학습용 데이터의 품질요류가 발견된 경우, 이를 전달받아 조치하는 역할 수행 '활용 품질담당'은 구축과정에서 '구축 데이터 품질담당'의 역할을 지원하며, 실제 구축 과정에서의 품질관리 경험을 통해 활용 단계에서도 품질 활동을 지원할 수 있도록 '품질 관리계획서' 및 사용자에게 제공되는 '활용 가이드라인'에 담당자 명시

[표 II-7] 구축사업 수행기관 조직 구성원별 역할 정의

3.4 품질관리 조직 관점의 품질점검 수행

- 품질관리 수행조직(구축공정 담당자, AI모델 설계자, 외부 품질전문가 등)을 구성하여 점검 진행
- 객관성 확보를 위해 외부 품질기관에 병행 처리하여 품질점검 진행
- 품질검사 관련 총괄책임자, 실무책임자 주도하에 품질점검 수시 확인 및 검사
- 데이터 외부 활용(AI-Hub 개방) 전, 품질관리 조직을 통한 최종 결과 보고 및 반영 등 수행

제2장

품질관리 프로세스 및 산출물


1 준비·계획 단계(100)

1.1 구축계획 수립(110)

- 인공지능 학습용 데이터 유형별로 데이터 구축에 필요한 절차 및 구성요소를 제시하여 데이터 구축 과정에서 시행착오를 줄이고 체계적인 계획을 수립하는 단계
- 자료 준비 및 사업수행계획서 작성 등 사업수행을 위한 계획과 데이터를 목적에 맞게 구체적으로 설계
- 구축목적의 일치성과 일관성 확보를 위한 구축 계획서를 작성하여 사업 종료 시까지 현행화

1.1.1 구축계획 수립(110) 프로세스

100. 준비·계획



[그림 II-8] 구축계획 수립 프로세스

1.1.2 구축계획 수립(110) 프로세스 품질관리 활동 및 산출물

프로세스	품질관리 활동	주요 내용	산출물
110. 구축계획 수립	1101. 사업수행 및 구축계획 수립	- 구축목적 및 범위, 수행계획 수립, 품질관리방안 검토 - 품질목표 수준의 적정성 및 품질관리기준 정의 검토	사업수행계획서 - 구축계획서 - 품질관리계획서
	1102. 데이터 구축 절차, 조직 구성	- 데이터 명세 정보 및 데이터 구성 정의 - 데이터 구축을 위한 절차, 조직, 도구, 담당자 등 검토 - 데이터셋 개요, 구성 내역, 설계기준 및 분포 현황, 구조, 구축 과정, 검수 및 품질활동 내역 검토	
	1103. 임무 정의에 대한 적절성 검토	구축목적의 일치성과 일관성 확보를 위한 계획 검토	구축과정 가이드라인 (임무 정의)
	1104. 품질목표 및 점검기준 수립	사업수행기관이 제출한 수행계획서 등 관련 자료를 토대로 품질지표 기준을 수립하고, 목표에 대해 합의 (사업수행기관 ↔ 제3자 품질검증기관, 사업관리기관)	품질지표 기준서

[표 II-8] 구축계획 수립단계 품질관리 활동 및 산출물

1.1.3 산출물 정의

※ 제출 여부 - M : 필수 제출 산출물, O : 조건 해당 시 필수 제출 산출물

산출물명	산출물 정의	제출 여부	유형
사업수행계획서 - 구축계획서 - 품질관리계획서	- 사업수행계획서: 사업 공모 시 제출한 사업수행계획에 대한 공식 산출물 - 구축계획서: 데이터 구축공정, 구축 데이터 정의, 데이터 검사 등 - 품질관리계획서: 품질지표 및 기준, 검사절차, 품질교육 등 - 과제조정위원회 검토의견, 품질지표 합의 등에 따라 구축계획서 및 품질관리계획서 수정	M	문서
구축공정 가이드라인 (임무 정의)	- 구축목적의 일치성과 일관성 확보를 위해 구축계획 단계에서 임무 정의 및 공정별 가이드라인 초안 작성 - 구축공정별로 산출물 현행화 및 변경 관리	M	문서
품질지표 기준서	- 품질검증을 위한 필수 산출물로 협약 후 품질검증기관과의 협의에 의해 세부 내용이 결정되는 산출물 - 최종 제출 시 품질관리계획서의 붙임으로 제출	M	문서

[표 II-9] 구축계획 수립단계 산출물 정의

1.1.4 고려사항

- 구축계획 수립 단계의 고려사항

항 목	고려사항
목적성 확보	데이터 구축 시 목적에 대한 명확한 정의를 위한 절차
법·제도 준수	원시데이터 획득/수집 시 관련 법·제도적 규정 등을 반드시 준수하여야 함
구축량 확인	데이터 구축 목표 수량과 방법에 대한 검토
사실적 획득/수집 환경 구성	원시데이터를 인위적인 환경이나 조건에서 획득/수집해야 하는 경우, 사실적인 획득/수집 환경을 현실적 가능성에 맞게 계획 수립


[표 II-10] 구축계획 수립단계의 고려사항

- 품질관리계획서 작성 시 고려사항

품질관리계획서 작성 시 고려사항
- 데이터의 품질목표 및 근거 - 품질관리 조직 구성 및 역할과 책임 - 데이터 품질검사 절차 및 구축단계별 품질검사 기준과 방법 - 데이터 품질관리를 위한 협의체 구성 및 운영 - 데이터 품질관리를 위한 참여기관의 품질관리 교육계획 수립 및 실시 - 데이터 품질검사에 따른 개선조치 및 사후관리 방안 - 그 밖의 데이터 품질관리에 필요하다고 요청한 사항

[표 II-11] 품질관리계획서 작성 시 고려사항

- 수립된 품질관리 계획은 구축 과정에서 데이터의 품질에 영향을 미치는 상황이 발생하였거나, 사업 관리기관이 보완을 요구한 경우, 품질관리협의회 등을 통해 적정성 등을 종합적으로 검토하여 수정
- 계획 단계에서 작성한 ‘품질관리계획서’를 기반으로 구축단계 품질관리에서 품질관리 조직이 자체적인 품질검사 활동을 구축 프로세스 측면, 구축 데이터 측면, 활용 측면에서 수행



[그림 II-9] 인공지능 학습용 데이터 구축사업 품질관리 체계

2 구축 단계(200)

2.1 데이터 획득/수집(210)

- 인공지능의 학습에 필요한 데이터를 현실 세계에서 직접 획득/수집 또는 생성하거나, 이미 보유하고 있는 조직이나 시스템 등으로부터 법률적 제약이 없도록 목적에 따른 원시데이터를 확보하는 활동
- 인공지능 학습용 데이터의 전체 품질 수준은 구축단계에서 80~90%가 좌우될 만큼 중요
 - 이유 1 : 인공지능 학습용 데이터가 인공지능 학습에 필요한 데이터 요구사항을 기반으로 구축되는 목적성을 갖기 때문에 데이터 품질 수준이 중요
 - 이유 2 : 한번 구축된 인공지능 학습용 데이터는 자체적인 품질 이슈가 발견되지 않는 한 민간에 데이터가 그대로 개방되어 배포됨에 따라 품질 수준 중요
- 이 단계에서는 정제 및 가공단계에서의 데이터 구축 요구사항을 우선 파악 후 데이터 가공의 목적에 맞는 데이터 환경을 구축하는 것이 중요
- 구축 단계의 품질관리는 인공지능 학습용 데이터 자체의 품질확보와 함께 인공지능 학습용 데이터를 생성하는 구축공정 단계별 프로세스 측면의 품질관리 필요

2.1.1 데이터 획득/수집(210) 프로세스

200. 구축



[그림 II-10] 데이터 획득/수집 프로세스

2.1.2 데이터 획득/수집(210) 프로세스 품질관리 활동 및 산출물

프로세스	품질관리 활동	주요 검토 내용	산출물
210. 데이터 획득/수집	2101. 획득/수집 방법 및 기준 현행화	- 데이터 획득 및 확보 방법, 절차, 법 제도적 적절성 - 획득항목 및 구축량 획득/수집 단계의 품질기준 및 조직, 절차, 도구 - 데이터 획득 방법 및 기준, 교육, 검사에 대한 체계 수립 - 데이터 획득 기준 변경 관리	구축공정 가이드라인 (획득/수집)
	2102. 데이터 법적 근거 검토	- 법 제도 준수(개인정보, 초상권, 저작권) 근거자료 확보 - 데이터 획득/수집의 공정성 위배 방지 방안	개인정보 자율점검표
	2103. 수집 도구 및 저장환경 검토	- 획득/수집에 사용될 도구 확보 및 사용 방법 - 획득/수집 데이터 저장환경 구축	수집 도구
			수집 도구 사용설명서
	2104. 원시데이터 품질검사	- 원시데이터가 인공지능을 활용하여 문제를 해결하는데 요구되는 분류 다양성, 신뢰성, 충분성, 균일성, 사실성, 공정성, 형식성 등 기준에 적합하게 구성되어 있는지 확인 - 데이터에 대한 클래스 분포, 인스턴스 분포, 분석 가능 항목의 통계적 분포 확인	원시데이터
			품질관리보고서
			품질검사 도구

[표 II-12] 데이터 획득/수집 단계 품질관리 활동 및 산출물

2.1.3 산출물 정의

※ 제출 여부 - M : 필수 제출 산출물, O : 조건 해당 시 필수 제출 산출물

산출물명	산출물 정의	제출 여부	유형
구축공정 가이드라인 (획득/수집)	데이터 획득/수집의 대상, 절차, 기준, 조직 및 획득 방법과 도구, 검사 등 정의하는 가이드라인(지침) 제시	M	문서
개인정보 자율점검표	개인정보보호법, 저작권, 지식재산권, 초상권 등을 고려한 데이터 획득/수집이 이루어지는지에 대한 점검표	M	문서
수집 도구 및 사용설명서	- 데이터 획득/수집을 위해 필요한 장비 또는 수집 도구 - 예를 들어 카메라, 비디오, 마이크, 크롤링 도구, 센서, 수집 앱 등 수집 도구에 대한 사용설명서 및 저장환경 등	O	문서/기타
원시데이터	획득/수집 단계에서 생성된 데이터	O	데이터
품질관리보고서	품질검사 기준, 조직, 절차, 검사 결과 등 작성	M	문서
품질검사 도구	- 획득된 데이터의 적합성(기준 적합성, 다양성)을 중점으로 검사하여 결과를 확인할 수 있는 도구 정의 - 품질검사 도구는 Application 또는 점검표(육안 검사 결과표 등) 등을 정의할 수 있음	O	Application

[표 II-13] 데이터 획득/수집 단계 산출물 정의

2.1.4 고려사항

- 데이터 획득/수집 단계 품질확보를 위한 고려사항

항 목	고려사항
법·제도 준수	• 원시데이터 획득 시 관련 법·제도적 규정 등을 반드시 준수하여야 함 • 개인정보보호가 필요한 항목 획득 시, 개인정보보호법 등에 따라 적절한 법적, 기술적 절차를 거친 데이터를 활용하며, 그렇지 않은 데이터는 정제 과정에서 처리될 수 있도록 함 • 의료 데이터의 경우는 IRB(의학연구윤리심의위원회)와 데이터 공개에 대한 해당 기관의 동의(DRB)를 사전 획득 필요 • 지적재산권 이슈가 있는 경우 반드시 해결방안을 마련하여 획득해야 함
데이터 다양성 확보	• 인공지능 학습모델이 현실을 잘 반영하고 본래의 구축목적에 달성할 수 있도록, 획득하는 데이터가 일부 범주에만 치우치지 않고 다양한 시간·공간·집단 수준 등이 포함되도록 함
데이터 편향 방지 및 윤리 준수	• 인공지능 학습모델이 인간의 비윤리 또는 편견을 학습하지 않고 사회적 윤리를 준수할 수 있도록 비윤리적 내용, 편견, 편향된 데이터의 획득/수집은 지양
사업수행계획서 및 데이터 구축요건 일치	• 사업수행계획서에 정의한 데이터 구축 기준에 맞추어 데이터를 획득/수집하도록 모니터링 및 검사
사실적 획득/수집 환경 구성	• 원시데이터를 인위적인 환경이나 조건에서 획득해야 하는 경우, 실제 환경이나 상황적 특성을 최대한 반영한 획득/수집 환경 구성
데이터 동기화	• 다중 속성의 데이터 소스 간 정교한 동기화를 위한 절차 마련

[표 II-14] 데이터 획득/수집 단계 고려사항

- 원시데이터를 수집하거나 직접 원시데이터를 생성하는 경우, 검사 항목을 고려해서 원시데이터의 품질을 확보해야 함

검사 항목	내 용
분류 다양성	• 학습 목적에 부합하도록 실제 세상의 데이터와 유사한 특성을 가진 데이터 확보해야 함 - 사물, 사람, 장소, 시간, 환경, 언어 특성 등 학습에 유용한 모든 특성 정보를 포함할 수 있도록 고려 - 사물, 사람, 장소, 시간, 환경, 언어 특성 등의 특성 정보가 학습에 유용한 범위에서 다양하게 수집
신뢰성	• 데이터는 반드시 신뢰할 수 있는 출처로부터 수집해야 함
충분성	• 데이터에 포함된 카테고리 및 인스턴스 등 특성 정보는 학습에 유용한 수량이어야 함
균일성	• 분류/탐지/인식/이해/예측 등 카테고리별 인스턴스 수량의 균일성, 적정 비율을 확보해야 함
사실성	• 원시데이터를 인위적인 환경과 조건하에 수집해야 하는 경우, 반드시 실제 환경과 상황 특성을 반영해야 함
공평성	• 원시데이터는 지역, 사회 및 인종적 편견 등 활용 의도와 무관한 편향적인 특성이 제거되고, 윤리적으로 공평해야 함


[표 II-15] 원시데이터의 검사 항목

2.2 데이터 정제(220)

- 획득한 원시데이터를 학습에 필요한 형식으로 맞추거나 불필요한 중복을 제거하며, 개인정보를 비식별화하여 처리하는 등 일련의 전처리 과정을 통해 ‘원천데이터’를 확보하는 활동
- 원시데이터 획득 시 정제기준을 명확하게 정의하고, 구축목적에 따라 적절한 데이터 선별을 위한 명확한 정제기준을 수립하며, 기준 미달 또는 활용 불가능한 데이터의 효과적인 제거 방법 수립

2.2.1 데이터 정제(220) 프로세스

200. 구축



[그림 II-11] 데이터 정제 프로세스

2.2.2 데이터 정제(220) 프로세스 품질관리 활동 및 산출물

프로세스	품질관리 활동	주요 검토 내용	산출물
220. 데이터 정제	2201. 정제방법 및 기준 현행화	- 구축목적에 적절한 데이터 선별을 위한 정제기준 수립 - 정제단계 품질기준 및 조직, 절차, 도구 - 데이터 정제방법 및 정제 결과에 대한 교육 및 훈련 - 데이터 정제 결과에 대한 검사절차와 기준 수립 - 데이터 정제기준 변경 관리	구축공정 가이드라인 (정제)
	2202. 개인정보/민감정보 비식별화 등 법적 준거 확보	개인정보보호 등 비식별화 기준 및 방안 등 법적 준거 확보	
	2203. 정제 도구 및 저장환경 검토	- 정제단계에 사용될 저작도구 확보 및 사용 방법 - 정제 데이터 저장환경 구축	저작도구(정제)
	2204. 원천데이터 품질검사	- 사용하기 적합한 데이터 여부 품질검사 - 원천데이터 품질검사를 위한 검사 도구 및 검사 결과 - 품질검사 결과에 따른 보완조치	사용설명서 원천데이터 품질관리보고서 품질검사 도구

[표 II-16] 데이터 정제단계 품질관리 활동 및 산출물

2.2.3 산출물 정의

※ 제출 여부 - M : 필수 제출 산출물, O : 조건 해당 시 필수 제출 산출물

산출물명	산출물 정의	제출 여부	유형
구축공정 가이드라인(정제)	- 데이터 정제 단계의 원천데이터 포맷, 데이터 정제 규모, - 절차, 기준, 조직, 방법, 도구 등 정의하고 가이드라인 제시	M	문서
저작도구(정제) 및 사용설명서	- 원시데이터 획득 시 중복제거, 개인정보 비식별화 등 정제 작업을 위한 도구 - 정제 도구에 대한 사용설명서 및 저장환경 등	M	문서/ Application
원천데이터	원시데이터를 가공 공정에 활용하기 위해 필요한 전처리 등 정제 작업을 수행한 데이터로 가공이 부여되지 않은 상태의 데이터	M	데이터
품질관리보고서	품질검사 기준, 조직, 절차, 검사 결과 등 작성	M	문서
품질검사 도구	- 획득된 데이터의 적합성과 중복성을 검사하고 그 결과를 확인 및 점검할 수 있는 도구 정의 - 품질검사 도구는 Application 또는 점검표(육안 검사 결과표) 등을 정의할 수 있음	O	Application

[표 II-17] 데이터 정제단계 산출물 정의

2.2.4 고려사항

- 정제단계 품질관리를 위한 고려사항

항 목	고려사항
정제기준의 명확성	데이터 사용 목적에 적합한 정제기준 수립 여부 검사
데이터 중복성 방지	데이터 정제 후 정보 비교 후 중복도 여부 검사
정제 가이드라인	정제 작업을 위한 정제 가이드라인 작성 및 관리 여부 검사
정제 도구	정제 작업에 사용될 소프트웨어(S/W) 도구 확보 및 사용 방법 숙지
정제 작업 방식	데이터 특성 및 활용 목적에 맞는 적절한 정제 방식 선정 여부 및 선정 기준 타당성 여부 검사

[표 II-18] 데이터 정제단계 고려사항

2.3 데이터 가공(230)

- AI모델의 기능이나 목적에 맞게 원천데이터에 적절한 라벨을 추가하는 과정
- 어노테이션 정보는 데이터 확장을 고려하여 항목명, 타입, 필수 구분, 항목 설명을 포함해야 하며 가공 용어 및 분류체계는 표준을 준수해야 함
- 가공 방법에 따른 도구 사용 및 작업 방식에 의한 모든 산출 데이터는 CSV, JSON 등 표준화된 포맷으로 제공하며 이에 대한 품질검사 진행

2.3.1 데이터 가공(230) 프로세스



[그림 II-12] 데이터 가공 프로세스

2.3.2 데이터 가공(230) 프로세스 품질관리 활동 및 산출물

프로세스	품질관리 활동	주요 검토 내용	산출물
230. 데이터 가공	2301. 가공 방법 및 기준 현행화	- 가공 방법 및 기준 정의 - 학습에 필요한 가공작업 및 어노테이션 설정 - 데이터 형식 및 데이터값 범위 기준 마련 - 데이터 유형별 객체 구분 작업 - 데이터 가공 방법 및 기준, 교육, 검사체계 수립 - 데이터 가공 기준 변경 관리	구축공정 가이드라인 (가공)
			저작도구(가공)
			사용설명서
	2302. 가공 도구 및 저장환경 검토	- 가공에 사용될 저작도구 확보 및 사용 방법 - 데이터 가공 기준 변경 관리 - 가공데이터 저장환경 구축	가공데이터
			품질관리보고서
			품질검사 도구
	2303. 가공데이터 품질검사	- 정확성(의미 정확성, 구문 정확성)을 중점으로 검사 - 가공데이터 품질검사를 위한 검사 도구 및 검사 결과 - 품질검사 결과에 따른 보완 조치	

[표 II-19] 데이터 가공단계 품질관리 활동 및 산출물

2.3.3 산출물 정의

※ 제출 여부 - M : 필수 제출 산출물, O : 조건 해당 시 필수 제출 산출물

산출물명	산출물 정의	제출 여부	유형
구축공정 가이드라인(가공)	데이터 가공단계의 품질지표, 어노테이션 포맷, 가공 대상, 절차, 기준, 방법, 도구, 검사 등 정의하는 가이드라인 제시	M	문서
저작도구(가공) 및 사용설명서	- 데이터 가공 저작도구는 데이터 학습 전 원천데이터에 특정 값을 부여하는 도구 - 가공 도구에 대한 사용설명서 및 저장환경 등	M	문서/ Application
가공데이터	원천데이터에 부여한 '참값', 파일 형식이나 해상도 등의 속성, 설명이나 주석 등이 포함된 '어노테이션'의 집합 등 가공된 데이터	M	데이터
품질관리보고서	품질검사 기준, 조직, 절차, 검사 결과 등 작성	M	문서
품질검사 도구	- 가공데이터의 정확성(구문 정확성, 의미 정확성)을 검사할 수 있는 도구 정의 - 품질검사 도구는 Application 또는 점검표(육안 검사 결과표) 등을 정의할 수 있음 ※ 자동검사 후 육안 검사 실시 시 사용하는 도구 모두 정의	O	Application

[표 II-20] 데이터 가공단계 산출물 정의

2.3.4 고려사항

- 가공 단계의 품질관리를 위해서는 가공작업을 위한 매뉴얼을 확보하고, 가공 도구를 확보하여, 해당 데이터의 특성을 고려해서 가공작업 방식을 정해야 함
- 데이터 가공작업에 필요한 규격은 다음의 사항을 반드시 포함하도록 고려해야 함

항 목	고려사항
가공 정의	가공 유형, 가공 구성 항목, 속성값, 타입 등을 정의해야 함
구축공정 가이드라인 (가공)	- 목적에 맞게 작성된 구축공정 가이드라인(가공)에 대한 타당성 고려 - 참값(Ground Truth) 가공, 가공 오류, 모호한 가공 처리, 예외처리 가공작업 등을 사전에 정의 하여 통과 및 반려 기준을 마련해야 함 - 목적에 맞는 어노테이션 항목 구성 여부 검사 후 작업자 전달 - 작업자가 효율적으로 작업할 수 있는 환경 구성
가공 도구	가공작업에 사용하는 플랫폼 및 SW 도구의 기능 및 사용 방법을 기술해야 하며 플랫폼 또는 SW 도구 선택 시 데이터 보안 준수 여부를 확인해야 함

[표 II-21] 데이터 가공단계 고려사항

● 데이터 특성별 가공 시 품질확보 측면 고려사항

특 성	고려사항	내용
이미지/ 비디오	객체 분류 체계의 일관성	표준화된 분류체계(또는 MECE*원칙을 준용하여 자체 정의한 분류체계)에 따라 클래스(class)를 정의해야 함
	객체 식별 단위의 명확화	- 바운딩 박스는 이미지 내에서 특정객체의 위치정보를 추출하는 것으로 대상 객체 전체를 감싸는 형태로 공백을 최소화해야 함 - 시멘틱세그멘테이션(Semantic Segmentation)은 객체 영역을 픽셀 단위로 표시하는 작업으로 동일 카테고리의 객체가 중첩되어 있는 경우를 구별하지 않음 - 인스턴스 세그멘테이션(Instance Segmentation)은 각 객체 영역을 픽셀 단위로 구분 표시함
	동일 객체의 프레임 간 정합성 (비디오)	트래킹(Tracking) 어노테이션시 동일 객체에 대한 ID를 일관되게 유지해야 하며, Object Re-identification 정확도를 고려해야함
텍스트/ 오디오	전사 기준 일관성	- 표준 발성에서 벗어나거나 동일 전사에 대해 복수 발음이 가능한 경우, 발음 전사와 철자 전사를 병행해야 하며 ETRI 전사 규칙을 준수해야 함 ※ ETRI 전사 규칙: 한국전자통신연구원(ETRI)에서 음성 데이터를 텍스트로 변환하는 과정에 대한 전사 규칙
	텍스트-오디오 정렬의 정확성	- 발화시작·종료 시간 기준 자막 또는 텍스트 정렬 오차를 최소화 해야함 - 문장/발화 단위 기준 정렬 일치율을 확보해야함

[표 II-22] 가공데이터의 고려사항 (예시)

- 데이터 가공작업은 데이터 특성 및 활용 목적을 고려하여 클라우드소싱, 아웃소싱, 내부조직 활용 등 데이터 가공 작업자 구성방식 선택
- 데이터 가공 작업자 구성방식에 따른 특성에 따른 고려사항은 다음과 같음

작업자 구성방식	특성	고려사항
클라우드 소싱	- 다수의 작업자가 단기간에 대량의 데이터 획득/수집 및 가공 하는 방식 - 단순 반복형·비정형 등의 분야에서 대량의 데이터 구축시 효율적 - 개인정보보호 및 기밀성 수준이 낮은 데이터 작업에도 적합	- 작업자별 편차로 일관성 있는 데이터 확보 필요 - 구축공정별 가이드라인을 수립하여 편차 최소화 필요 - 교차검사 및 전문가 검토를 통한 데이터 검수 및 보완작업 수행
아웃소싱	해당 분야에 대한 전문적인 지식과 숙련도를 요구하는 작업 (예: 의료, 법률, 특허, 금융 등)	- 전문성 차이에 따른 데이터 표현·이해 불일치로 인한 품질 저하 주의 필요 - 품질검수자와 데이터 구축 작업자 간의 피드백 구조 명확화 필요 - 구축공정별 가이드라인을 통한 작업자 사전 공유 및 일관성 확보 필요
내부조직	- 인공지능 및 모델 학습에 대한 높은 수준의 이해가 필요한 직업 - 가공결과에 대한 긴밀한 피드백을 요구하는 경우에 적합	내부조직, 클라우드 소싱 및 아웃소싱 조직 간의 연계 및 피드백 방안 수립


[표 II-23] 데이터 특성 및 활용 목적을 고려한 데이터 가공 작업자 구성 및 고려사항

2.4 데이터 학습(240)

- 데이터 학습 단계에서는 원천데이터와 가공데이터의 묶음인 ‘학습 데이터셋’을 이용하여 사전에 정의된 인공지능 모델을 학습시키고, 학습된 AI모델의 성능을 향상시키거나 보정하는 활동 수행

2.4.1 데이터 학습(240) 프로세스

200. 구축



[그림 II-13] 데이터 학습 프로세스

2.4.2 데이터 학습(240) 프로세스 품질관리 활동 및 산출물

프로세스	품질관리 활동	주요 검토 내용	산출물
240. 데이터 학습	2401. 구축목적-AI모델 합치성 확인	- 데이터를 인공지능 모델로 학습할 때 영역별 품질검사 기준을 확인하여 합치성 검토 - 구축목적에 부합하는 AI모델 선정 확인 - AI모델 구축/운영 및 테스트를 위한 환경 구축 정보 - AI모델 정보/라이선스 가이드	AI모델 설명서
	2402. 학습 결과 확인 및 최적화	- 학습용 데이터가 AI모델로 학습시켰을 때 목표로 했던 수준의 성능 달성이 가능한지 검사 - AI모델(알고리즘) 성능 검사 - 모델 단계 유효성 검사 - 학습모델, 활용 서비스 개발에 가능한 학습 데이터셋 품질오류 및 이슈 내용을 분석하여 보완조치 반영	AI모델 소스코드
			학습모델 파일
			모델 구축 도커 이미지
			AI모델 테스트 결과서
	2403. 품질검증결과 보완조치	- 최종데이터 제3자 품질검증결과가 미달성인 경우, 보완조치하여 결과 보고 ※ 제3자 품질검증 → 제3자 품질검증 세부 활동 정의 → 최종품질검증 프로세스 부분 내용 참고	품질검사 도구
			보완조치결과서

[표 II-24] 데이터 학습 단계 품질관리 활동 및 산출물

2.4.3 산출물 정의

※ 제출 여부 - M : 필수 제출 산출물, O : 조건 해당 시 필수 제출 산출물

산출물명	산출물 정의	제출 여부	유형
AI모델 설명서	- AI모델 구축/운영 및 테스트를 위한 환경 구축 내역 - AI모델 소스코드 활용을 위한 환경 구축 및 실행 매뉴얼 - 모델 관련 정보 및 라이선스 정보 - 라이브러리, 패키지 버전 및 구축환경 정보	M	문서
AI모델 소스코드	- 모델 학습 코드 - 모델 성능 테스트 코드 - 기타	M	Code
학습모델 파일	특정 유형의 패턴을 인식하도록 학습된 파일로 학습가중치, 아키텍처 정보, 기타 학습요소 등 포함	M	binary
모델 구축 도커 이미지	AI모델 구축환경정보가 내장된 도커 파일을 모델 산출물 파일과 같이 제출	M	tar
AI모델 테스트 결과서	제3자 품질검증 전 사업수행기관의 자체적인 모델 테스트를 수행하여 미흡한 경우 보완조치 필요	O	문서
품질검사 도구	학습용 데이터셋의 유효성 품질검사 도구	O	Application
보완조치결과서	- 제3자 최종 품질검증 미달성 기관만 해당 산출물 제출 - 최종 품질검증 결과서의 미흡 내용을 대상으로 공정별 개선 후 품질 검사 결과 작성	M	문서

[표 II-25] 데이터 학습 단계 산출물 정의

2.4.4 고려사항


항 목	고려사항
데이터 학습 유효성	‘학습 데이터셋’을 이용하여 사전에 정의된 인공지능 모델을 학습시키고, 학습된 AI모델의 성능을 향상시키거나 보정하는 검사를 수행 - 구축한 데이터셋을 인공지능 학습모델로 학습시킨 후 목표로 했던 수준으로 성능달성이 가능한지 확인 - 학습모델 평가를 위한 정확도, 정밀도, 재현율 등 성능지표 확인
AI모델 성능	인공지능 모델 성능 검사
품질오류 분석	학습모델, 활용 서비스 개발에 가능한 학습 데이터셋 품질오류 및 이슈 내용을 분석

[표 II-26] 데이터 학습 단계 시 고려사항

2.5 구축 단계 품질검사

2.5.1 품질검사 절차

- 구축 단계 품질검사는 품질검사 절차 중 품질통제를 제외한 모든 영역을 구축공정별로 적용
- 현 구축공정의 품질검사 결과가 앞서 수행한 구축공정에도 영향을 미칠 수 있음
- 예를 들어, 데이터 정제단계에서의 다양성 관련 지표의 품질오류가 발견되면 데이터 획득/수집 단계에서 적합성이 보장받지 못할 수 없고, 이 경우 데이터 획득/수집 단계부터 재수행하거나 보완이 필요하며, 각 공정의 품질검사 시 재작업을 최소화하기 위해 지속적이고 반복적인 품질검사 수행 필요



[그림 II-14] 공정별 구축 데이터 검사절차

① 검사대상 데이터 선정

구분	내용
검사절차명	● 검사대상 데이터 선정
검사이표명	● N/A
검사내용	● 각 공정의 품질기준(지표)에 따른 적절한 기준과 수량 선정 ● 구축대상 데이터의 분류체계(카테고리)가 모두 포함되게 선정 ● 초기데이터 구축 단계에서 부터 품질검사를 고려하여 각 분류체계의 데이터를 적절한 비율로 모두 획득/수집할 수 있도록 계획 수립
검사이시	● 약초의 식별 학습을 위해 인삼, 홍삼, 당귀, 참당귀, 느릅나무를 선정하여 데이터를 구축하는 경우 검사대상 데이터 선정 시 해당 데이터가 모두 포함

[표 II-27] 검사대상 데이터 선정 내용 및 예시

② 데이터 획득/수집 단계 검사

구분	내용
검사절차명	• 데이터 획득/수집 단계 검사
검사지표명	• 적합성(기준 적합성, 다양성)
검사내용	• 적합성(기준 적합성, 다양성)을 중점으로 검사 • 획득/수집 단계에서의 검사 결과에 따른 개선을 수행하기 위해서는 임무 정의, 학습모델에 따른 데이터 구축 요구사항을 재정리하여 구축계획을 수정하고 데이터 획득/수집 재 실시 • 검출한 오류사항은 그 특징과 사례를 정리하여 추후 검사 시 우선 체크하여 오류 최소화
검사예시	• 이미지 촬영 또는 오픈 이미지 사용에 따른 적합성 여부 확인(이미지 촬영, 다양성, 법적 문제 방안) • 품목 적합성 확인, 이미지 적합성 확인, 개인정보 침해 여부 확인

[표 II-28] 데이터 획득/수집 단계 검사 내용 및 예시

③ 데이터 정제/가공 단계 검사

구분	내용
검사절차명	• 데이터 정제/가공 단계 검사
검사지표명	• 정확성(의미 정확성, 구문 정확성)
검사내용	• 정확성(의미 정확성, 구문 정확성)을 중점으로 검사 • 인공지능 학습모델이 학습을 정확하게 수행하기 위한 필수적 요소이며, 구축공정의 특성상 작업자 간 품질 차이가 큼 • 품질관리담당의 정기 또는 수시 품질검사가 반복 수행되어야 함 • 본 단계의 검사에서 발생하는 오류는 현재 공정상의 오류일 수도 있으나, 이전 공정에서 발생한 오류가 현재 공정에 영향을 미치는 경우도 있음
검사예시	• 이전 공정에서의 영향을 분석하여 품질관리 또는 프로젝트 관리조직의 주관하에 공정 수행 계획 재수립 및 재실시를 통해 오류를 최소화할 수 있도록 해야 함

[표 II-29] 데이터 정제/가공 단계 검사 내용 및 예시

④ 모델 단계 검사


구분	내용
검사절차명	• 모델 단계 유효성 검사
검사지표명	• 유효성(전체 데이터를 사용하여 학습/검증/평가 데이터셋으로 분할하고 학습 완료 후 검증 데이터셋으로 성능 측정 또는 미세조정)
검사내용	• 데이터를 인공지능 모델로 학습시켰을 때 분류성능, 탐지성능, 인식성능, 질의응답, 기계번역, 문서요약, 이미지, 영상, 텍스트, 음성, 센서 등 영역별 품질검사 기준 확인
검사예시	• 학습용 데이터를 이용하여 학습한 AI모델이 목표했던 수준의 성능 달성하는지 검사 → 유효성 - 평균 IoU, AUC, 평균 정밀도, 평균 재현율, Fβ-점수, 픽셀 정확도, 평균 정확도, 일치도, 문장 유사도 등 - 분류·탐지·인식 성능은 정밀도, 재현율, Fβ-점수 및 기타 변형 지표로 측정 ※ IoU(Intersection Over Union), AUC(Area Under the Curve), Fβ-점수는 Precision(정밀도)과 Recall(재현율)의 가중치 조화 평균

[표 II-30] 모델 단계 검사 내용 및 예시

⑤ 전수검사

구분	내용
검사절차명	• 데이터 전수검사
검사지표명	• 데이터 정제 검수 기준을 준수하여 검수 진행
검사내용	• 부적합 판정 데이터 분포 확인 • 외부 검수자, 도메인 전문가, 데이터 요청자에 의한 검사 지표 및 기준 통일성 검사
검사예시	• 클라우드소싱 검사 공정 진행으로 데이터 정제 검사기준을 준수하여 검사 진행 • 정확성 시험 : 어노테이션 포맷 정확도 정합률 99% 이상 - 참값 정확도 ① 미태깅률 3% 이하, 가공 대상 객체에 대한 class 정보입력 및 바운딩/폴리곤 작업 누락 ② 오타깅률 1% 이하, 가공 대상 객체에 대한 class 정보입력 오류

[표 II-31] 전수검사 내용 및 예시



[그림 II-15] 공정단위 검사 과정

- (1차 교차검사) 공정별 데이터 구축조직 내 작업자 자가검사 및 교차검사 수행
 - ※ 교차검사 시 작업자 외 공정담당 또는 Validator의 검사 가능
- (2차 교차검사) 품질담당 조직에 의한 2차 검사 후 오류 식별 시 개선사항과 함께 재작업 지시
 - ※ 필요 시 개선사항을 반영한 공정별 가이드라인 현행화 및 작업자 교육 실시
- (품질 검증) 제3자 품질검증기관에 의한 최종 품질검증 수행
 - ※ 제3자 품질검증기관과의 협약에 따라 최종 품질검증 전 사전검증 등 수행

2.5.2 검사기준

- 데이터 구축사업의 특성에 따라 검사기준을 선택적으로 적용하거나 추가할 수 있으며, 아래 검사기준은 인공지능 학습용 데이터 구축사업에 필수적으로 적용해야 하는 기준임

구분	검사기준	내용
임무 정의, 구축계획 수립 및 데이터 획득 단계	법·제도 준수	• 원시데이터 획득 시 관련 법·제도적 규정 등 반드시 준수
	사실적 획득 환경 구성	• 원시데이터를 인위적인 환경과 조건하에 획득해야 하는 경우 사실적인 획득 환경 구성
	데이터 동기화	• 다중 속성 데이터 소스 간 정교한 동기화를 위한 절차 마련
	공평성 위배 방지	• 데이터 편향을 방지하기 위한 절차 마련
데이터 정제 단계	정제기준의 명확성	• 데이터 사용 목적에 적합한 정제기준 수립 여부 검수
	중복성 방지	• 데이터 정제 후 정보 비교 등을 통한 중복도 여부 검수
	정제 작업 매뉴얼	• 정제 작업을 위한 매뉴얼 작성 및 관리 여부 검수
	정제 도구	• 정제 작업에 사용될 소프트웨어(S/W) 도구를 확보 및 사용 방법 숙지
	정제 작업 방법	• 데이터 특성 및 활용 목적에 맞는 적절한 정제 방식 선정 여부 및 선정 기준 타당성 여부 검수
데이터 가공 단계	구축공정 가이드라인(가공)	• 목적에 맞게 작성된 구축공정 가이드라인(가공)에 대한 타당성 여부 검사 후 데이터 가공 작업자들에게 해당 내용의 가이드라인 전달
	어노테이션 항목	• 목적에 맞는 어노테이션 구성 여부 검수 후 확인된 내용을 포함하도록 작업자들에게 전달
	품질검사 도구	• 자동화 도구를 통해 검사 후 검사자가 육안으로 부적합 데이터 여부에 대해 2차 확인 및 조건 오류 전수 검사
전수검사	부적합 판정 데이터 분포 확인	• 부적합 데이터 확인을 위해 데이터의 오류율, 특성 분포 확인을 통한 데이터 획득, 정제, 가공 부문 최적화
	외부 검사자	• 제3자 품질검증기관 등 외부 검사자, 해당 분야 전문가, 데이터 요청자에 의한 검사를 위해 검사 지표 및 기준이 통일되게 전달되었고, 검사 방법의 동의를 이루어졌는지 확인

[표 II-32] 품질검사 검사기준 지표

3 운영·활용 단계(300)

3.1 데이터 운영·활용(310)

- 인공지능 학습용 데이터의 운영·활용 단계 품질관리는 데이터를 민간에 개방하기 위해 AI-Hub에 적재된 학습 데이터셋의 품질을 향상시키기 위한 제반 활동을 의미

3.1.1 데이터 운영·활용(310) 프로세스



[그림 II-16] 데이터 운영·활용 프로세스

3.1.2 데이터 운영·활용(310) 프로세스 품질관리 활동 및 산출물

프로세스	품질관리 활동	주요 검토 내용	산출물
310. 데이터 운영·활용	3101. 데이터 개방을 위한 품질점검 활동	• AI-Hub 등록 전 데이터에 대한 적정성 평가	없음
	3102. 데이터 하자 및 유지보수	• AI-Hub 공개 데이터에 대한 하자 및 유지보수	하자 및 유지보수계획서
	3103. 사용자 품질개선 의견 반영	• 사용자들의 개발 및 활용 지원을 위한 산출물 공개 • 데이터 품질에 대한 하자 및 유지보수 계획 • 사용자들의 품질 개선의견 반영 등 유지보수	활용 가이드라인 (데이터 설명서 포함) 데이터 활용 교육 영상

[표 II-33] 데이터 운영·활용 단계 품질관리 활동 및 산출물

3.1.3 산출물 정의

※ 제출 여부 - M : 필수 제출 산출물, O : 조건 해당 시 필수 제출 산출물

산출물명	산출물 정의	제출 여부	유형
활용 가이드라인 (데이터 설명서 포함)	• 이용자들의 데이터에 대한 이해도 제고를 통해 데이터의 원활한 활용이 가능하도록 하는 설명서(AI-Hub 개방)	M	문서
데이터 활용 교육 영상	• 데이터 1종당 1개의 데이터 활용 교육 영상을 제작하여 이용자의 데이터셋에 대한 이해도 제고(AI-Hub 개방)	M	동영상
하자 및 유지보수계획서	• 공개용 학습 데이터셋에 대한 하자 및 유지보수계획	M	문서

[표 II-34] 데이터 운영·활용 단계 산출물 정의

3.2 운영·활용 단계 품질검사

3.2.1 품질검사 절차

- 데이터 품질검사는 검사대상 선정(3), 품질검사 수행(2), 검사 결과 분석(2), 개선 수행(2), 품질 통제(3)의 5단계, 12개 상세 수행절차로 구성



[그림 II-17] 운영·활용 단계 품질검사 상세 수행절차

- ① 검사대상 선정

수행 절차	1.1 품질관리계획 검토 및 후보 데이터 선정				
주요 활동	- 품질관리 담당자는 구축사업의 품질관리계획과 관련된 자료를 수집하고 데이터 구축 및 인공지능 학습모델 담당자와 협의를 통해 변경된 요구사항, 업무절차 및 작업방법 등의 부가정보 획득 후보 데이터 선정 시 고려사항 - 데이터 가공 작업 그룹, 클라우드워크 플랫폼 등의 데이터 구축환경에서 접수되는 품질오류 및 개선의견 접수 내용 분석 - 학습모델, 활용 서비스 개발 그룹으로부터 접수되는 품질오류 및 개선의견 분석 - 데이터 구축사업 관련 전문가 검토에 따라 정비가 필요한 데이터 분석 - 데이터의 특성상 품질 이슈 발생 확률이 높은 데이터에 대한 개선 수요 분석				
수행 절차	1.2 품질검사 대상 데이터 선정				
주요 활동	- 품질관리 계획 검토 및 후보 데이터로 식별한 데이터 중에서 품질검사의 중요성, 시급성 관점으로 검사대상 데이터를 선정 데이터 선정 기준 <table border="1"> <tr> <td>중요성 측면</td><td> - 구축 공정별 데이터의 적합성, 정확성, 유효성이 확보되어야 하는 데이터 - 수집된 품질 이슈를 해결하기 위해 재작업 또는 추가 작업을 실시한 데이터 - 인공지능 학습모델이 동작하는데 핵심적인 기능을 담당하는 데이터 </td></tr> <tr> <td>시급성 측면</td><td> - 품질오류 이슈가 빈번하게 발생하는 데이터 - 시급히 해결해야 하는 품질 현안을 보유한 데이터 </td></tr> </table>	중요성 측면	- 구축 공정별 데이터의 적합성, 정확성, 유효성이 확보되어야 하는 데이터 - 수집된 품질 이슈를 해결하기 위해 재작업 또는 추가 작업을 실시한 데이터 - 인공지능 학습모델이 동작하는데 핵심적인 기능을 담당하는 데이터	시급성 측면	- 품질오류 이슈가 빈번하게 발생하는 데이터 - 시급히 해결해야 하는 품질 현안을 보유한 데이터
중요성 측면	- 구축 공정별 데이터의 적합성, 정확성, 유효성이 확보되어야 하는 데이터 - 수집된 품질 이슈를 해결하기 위해 재작업 또는 추가 작업을 실시한 데이터 - 인공지능 학습모델이 동작하는데 핵심적인 기능을 담당하는 데이터				
시급성 측면	- 품질오류 이슈가 빈번하게 발생하는 데이터 - 시급히 해결해야 하는 품질 현안을 보유한 데이터				

수행 절차	1.3 품질검사 계획 수립
주요 활동	- 품질검사 대상 데이터 선정이 완료되면 선정된 데이터를 대상으로 품질검사계획서를 작성하는 단계  품질검사계획서 품질검사계획서 작성 시 포함사항 · 품질검사 목적 · 검사 방법 및 절차 · 검사 일정 · 검사조직 (역할과 책임 포함) · 소요예산

[표 II-35] 검사대상 선정 활동

● ② 품질검사 수행

수행 절차	2.1 품질검사 준비 / 2.2 품질검사 실시										
주요 활동	품질검사 준비는 본격적인 품질검사 수행에 앞서 품질검사를 효율적으로 수행하기 위해 사업수행기관에서 사전에 준비해야 할 검사환경을 준비하는 단계 품질검사 환경 준비 <table> <tr> <td>품질검사 전담인력 지정</td><td>· 검사데이터 규모, 기간, 투입 인력 및 역할 등의 제반 여건에 적합한 전담인력을 구성</td></tr> <tr> <td>협조체계 구성</td><td>· 수행기관 및 참여기관에서 학습모델 개발 조직 및 담당자와 협조체계를 구성, 다양한 이해관계자 협조 필요</td></tr> <tr> <td>검사대상 데이터 준비</td><td>· 유관 부서의 사전 협조를 통해 검사대상 데이터가 누락되지 않도록 주의</td></tr> <tr> <td>검사 도구 준비</td><td>· 검사 수행에 필요한 품질관리 지표들을 식별하고 현행화 · 적용가능한 자동화 도구가 있다면 사전에 준비</td></tr> <tr> <td>수행 장소 마련</td><td>· 수행 조직의 규모 및 인원, 기간 등을 식별 · 검사 데이터의 접근성, 보안, 원활한 업무 협조 등 고려</td></tr> </table>	품질검사 전담인력 지정	· 검사데이터 규모, 기간, 투입 인력 및 역할 등의 제반 여건에 적합한 전담인력을 구성	협조체계 구성	· 수행기관 및 참여기관에서 학습모델 개발 조직 및 담당자와 협조체계를 구성, 다양한 이해관계자 협조 필요	검사대상 데이터 준비	· 유관 부서의 사전 협조를 통해 검사대상 데이터가 누락되지 않도록 주의	검사 도구 준비	· 검사 수행에 필요한 품질관리 지표들을 식별하고 현행화 · 적용가능한 자동화 도구가 있다면 사전에 준비	수행 장소 마련	· 수행 조직의 규모 및 인원, 기간 등을 식별 · 검사 데이터의 접근성, 보안, 원활한 업무 협조 등 고려
품질검사 전담인력 지정	· 검사데이터 규모, 기간, 투입 인력 및 역할 등의 제반 여건에 적합한 전담인력을 구성										
협조체계 구성	· 수행기관 및 참여기관에서 학습모델 개발 조직 및 담당자와 협조체계를 구성, 다양한 이해관계자 협조 필요										
검사대상 데이터 준비	· 유관 부서의 사전 협조를 통해 검사대상 데이터가 누락되지 않도록 주의										
검사 도구 준비	· 검사 수행에 필요한 품질관리 지표들을 식별하고 현행화 · 적용가능한 자동화 도구가 있다면 사전에 준비										
수행 장소 마련	· 수행 조직의 규모 및 인원, 기간 등을 식별 · 검사 데이터의 접근성, 보안, 원활한 업무 협조 등 고려										

[표 II-36] 품질검사 수행 활동

● ③ 제3자 결과 분석

수행 절차	3.1 오류 원인분석										
주요 활동	- 오류 원인을 추적하기 위해서는 선행적으로 품질검사 수행단계에서 조사된 추정 오류를 대상으로 실제 오류 여부를 확인하고, 실제 오류라고 할지라도 임무와 데이터 특성을 고려하여 분석 대상에 포함되는지 여부를 확인 ※ 오류 원인분석은 품질 수행체계 데이터 구조 모델학습 관점에서 추적하여 구체적인 근본 원인(Root Cause) 도출 <table> <tr> <th colspan="2">오류 원인분석 방향</th></tr> <tr> <th>구축 방법 측면의 오류원인</th><th>가이드라인 측면의 오류 원인</th></tr> <tr> <td> - 모델·데이터 대상 선정, 수집, 정제, 가공 등의 통제 미흡으로 인하여 구축 절차, 구조, 학습모델 측면의 다양한 오류 데이터 생성 </td><td> - 사업수행기관이 정의한 구축 가이드라인의 불완전성, 미준수로 인하여 작업자 간 서로 상이하게 작업을 수행하거나 데이터 간 일관성 위배 </td></tr> <tr> <th>데이터셋 측면의 오류원인</th><th>학습모델 측면의 오류 원인</th></tr> <tr> <td> - 데이터셋 설계의 부족, 구문정확성 위배, 데이터 구축 중복 등으로 인하여 사업수행 기관이 목표로 하는 품질목표 위배 </td><td> - 학습모델에 적합한 데이터 구축이 수행되지 않았거나, 잘못된 학습모델 선정으로 데이터 구축 방향이 잘못되어 품질목표를 맞출 수 없는 상황 </td></tr> </table>	오류 원인분석 방향		구축 방법 측면의 오류원인	가이드라인 측면의 오류 원인	모델·데이터 대상 선정, 수집, 정제, 가공 등의 통제 미흡으로 인하여 구축 절차, 구조, 학습모델 측면의 다양한 오류 데이터 생성	사업수행기관이 정의한 구축 가이드라인의 불완전성, 미준수로 인하여 작업자 간 서로 상이하게 작업을 수행하거나 데이터 간 일관성 위배	데이터셋 측면의 오류원인	학습모델 측면의 오류 원인	데이터셋 설계의 부족, 구문정확성 위배, 데이터 구축 중복 등으로 인하여 사업수행 기관이 목표로 하는 품질목표 위배	학습모델에 적합한 데이터 구축이 수행되지 않았거나, 잘못된 학습모델 선정으로 데이터 구축 방향이 잘못되어 품질목표를 맞출 수 없는 상황
오류 원인분석 방향											
구축 방법 측면의 오류원인	가이드라인 측면의 오류 원인										
모델·데이터 대상 선정, 수집, 정제, 가공 등의 통제 미흡으로 인하여 구축 절차, 구조, 학습모델 측면의 다양한 오류 데이터 생성	사업수행기관이 정의한 구축 가이드라인의 불완전성, 미준수로 인하여 작업자 간 서로 상이하게 작업을 수행하거나 데이터 간 일관성 위배										
데이터셋 측면의 오류원인	학습모델 측면의 오류 원인										
데이터셋 설계의 부족, 구문정확성 위배, 데이터 구축 중복 등으로 인하여 사업수행 기관이 목표로 하는 품질목표 위배	학습모델에 적합한 데이터 구축이 수행되지 않았거나, 잘못된 학습모델 선정으로 데이터 구축 방향이 잘못되어 품질목표를 맞출 수 없는 상황										
수행 절차	3.2 개선 기회 도출										
주요 활동	- 도출된 구체적인 개선 기회는 향후 “개선 수행(Implement)” 단계의 실제적인 활동 내용으로 연결되어야 함 <table> <tr> <th colspan="2">오류 원인분석 방향</th></tr> <tr> <th>구축 방법 측면</th><th>가이드라인 측면의 오류 원인</th></tr> <tr> <td> - 학습모델, 데이터 구조 및 구축 방법 변경·통제 프로세스 수립 </td><td> - 용어 개정 필요 - 수집 및 획득 방법 개선 - 도메인 추가 제정 및 도메인 중복제거 - 가공 수행 방법, 검사방법 개선 등 </td></tr> <tr> <th>데이터 구조 측면</th><th>학습모델 측면의 오류 원인</th></tr> <tr> <td> - 어노테이션 등 가공 데이터 정규화 필요 - 메타데이터 식별자 항목 조정 - 원시/원천데이터와 가공데이터간 1대 1 매핑 및 관리 구조 통합 등 </td><td> - 학습 알고리즘 변경 또는 학습프로세스 보완 - 학습모델의 원천데이터 및 가공데이터 간의 선·후행 활용 관계 프로세스 보완 등 </td></tr> </table>	오류 원인분석 방향		구축 방법 측면	가이드라인 측면의 오류 원인	학습모델, 데이터 구조 및 구축 방법 변경·통제 프로세스 수립	- 용어 개정 필요 - 수집 및 획득 방법 개선 - 도메인 추가 제정 및 도메인 중복제거 - 가공 수행 방법, 검사방법 개선 등	데이터 구조 측면	학습모델 측면의 오류 원인	- 어노테이션 등 가공 데이터 정규화 필요 - 메타데이터 식별자 항목 조정 - 원시/원천데이터와 가공데이터간 1대 1 매핑 및 관리 구조 통합 등	- 학습 알고리즘 변경 또는 학습프로세스 보완 - 학습모델의 원천데이터 및 가공데이터 간의 선·후행 활용 관계 프로세스 보완 등
오류 원인분석 방향											
구축 방법 측면	가이드라인 측면의 오류 원인										
학습모델, 데이터 구조 및 구축 방법 변경·통제 프로세스 수립	- 용어 개정 필요 - 수집 및 획득 방법 개선 - 도메인 추가 제정 및 도메인 중복제거 - 가공 수행 방법, 검사방법 개선 등										
데이터 구조 측면	학습모델 측면의 오류 원인										
- 어노테이션 등 가공 데이터 정규화 필요 - 메타데이터 식별자 항목 조정 - 원시/원천데이터와 가공데이터간 1대 1 매핑 및 관리 구조 통합 등	- 학습 알고리즘 변경 또는 학습프로세스 보완 - 학습모델의 원천데이터 및 가공데이터 간의 선·후행 활용 관계 프로세스 보완 등										

[표 II-37] 검사결과 분석 활동

● ④ 개선 수행

수행 절차	4.1 개선계획 수립						
주요 활동	• 검사 결과 분석 단계에서 도출된 개선 기회를 종합하여 개선 과제를 도출하고 과제별 상세 추진 계획 수립						
	품질개선 수립 내용						
	<table><tr><td>품질개선 목적 • 품질개선 필요성 기술 </td><td>주요 과업범위 • 개선유형과 수행 절차 기술 </td></tr><tr><td>일정계획 수립 • 품질개선 일정 계획 수립 </td><td>추진체계 • 수행 조직 및 이해관계자 역할과 책임 정의 </td></tr><tr><td>소요예산 • 투입인력, H/W S/W 규모 및 소요 비용 등 </td><td>기대효과 • 개선효과를 정량적, 정성적으로 평가 </td></tr></table>	품질개선 목적 • 품질개선 필요성 기술	주요 과업범위 • 개선유형과 수행 절차 기술	일정계획 수립 • 품질개선 일정 계획 수립	추진체계 • 수행 조직 및 이해관계자 역할과 책임 정의	소요예산 • 투입인력, H/W S/W 규모 및 소요 비용 등	기대효과 • 개선효과를 정량적, 정성적으로 평가
	품질개선 목적 • 품질개선 필요성 기술	주요 과업범위 • 개선유형과 수행 절차 기술					
	일정계획 수립 • 품질개선 일정 계획 수립	추진체계 • 수행 조직 및 이해관계자 역할과 책임 정의					
소요예산 • 투입인력, H/W S/W 규모 및 소요 비용 등	기대효과 • 개선효과를 정량적, 정성적으로 평가						
수행 절차	4.2 품질개선실시						
주요 활동	• 수립된 개선계획 중 단기 과제를 우선으로, 개선수행을 위한 환경을 준비하고, 실제 개선을 수행						
	품질개선 준비 및 실시						
	<pre>graph TD; A[협조체계 구성] --> B[개선 수행 도구 준비]; A --> C[전담 조직 및 장소 마련]; B --> B1[수집, 정제 및 라벨링 도구 식별 및 사전 준비]; B --> B2[수작업 수행 시 충분한 수행 인력 준비]; C --> C1[수행 조직의 규모 및 인원, 기간 등 식별]; C --> C2[데이터의 접근성, 보안, 원활한 업무 협조 등이 이루어지도록 적합한 수행 장소 준비];</pre>						

[표 II-38] 품질 개선계획 및 개선 활동

● ⑤ 품질통제

수행 절차	5.1 결과 평가
주요 활동	- 품질 관리체계 수립, 데이터 운영계획 수립, 데이터 보정으로 구분 - 구축공정 가이드라인 개정 영역과 실제 개선 영역을 종합적으로 표현, 실제 개선한 영역의 개선 효과를 정량적으로 평가
수행 절차	5.2 품질목표 관리
주요 활동	- 품질통제 대상에 대한 품질목표 설정 - 품질을 유지하거나 더 높은 품질 확보방안 수립
수행 절차	5.3 품질통제 실시
주요 활동	- 품질목표 관리 대상에 대해 수시로 모니터링 수행 - 사업수행기관 구성원들 교육, 홍보 활동으로 품질목표 관리 활동에 대한 공감대 형성 - 적극적인 참여 유도과 소통 필요

[표 II-39] 품질 통제 단계의 관리 활동

4 단계별 산출물

4.1 구축 및 품질 산출물

※ 제출 여부 - M : 필수 제출 산출물, O : 조건 해당 시 필수 제출 산출물

구분	산출물명	유형	필수 여부	AI-Hub 공개산출물
구축계획 수립	사업수행계획서 (※ 구축계획서, 품질관리계획서 포함)	문서	M	-
데이터 획득/수집, 정제, 가공	개인정보자율점검표	문서	M	-
	구축공정 가이드라인	문서	M	-
	저작도구/Viewer 사용설명서	문서	M	Y
	저작도구/Viewer	어플리케이션	M	Y
	원시데이터(획득/수집데이터)	데이터	O	-
	원천데이터(이미지, 영상, 오디오 등)	데이터	M	-
	가공데이터(JSON 등)	데이터	M	-
데이터 학습	AI모델 설명서	문서	M	Y
	AI모델 소스코드	Code	M	Y
	학습모델 파일	binary	M	Y
	모델 구축 도커 이미지	tar	M	Y
	AI모델 테스트 결과서	문서	O	-
데이터 품질	품질관리보고서	문서	M	-
	품질검증결과서	문서	M	-
	품질지표 기준서(사업수행계획서 내 포함)	문서	M	-
데이터 운영·활용	활용 가이드라인	문서	M	Y
	데이터 활용 교육 영상	동영상	M	Y
	하자 및 유지보수 계획서	문서	M	-

[표 II-40] 구축 및 품질 관련 산출물 목록

4.2 구축단계별 산출물

※ 범례 - * 필수 제출 산출물, ** 필수(공개) 제출 산출물

구분	구축계획 수립	데이터 획득/수집	데이터 정제	데이터 가공	데이터 학습	데이터 운영·활용
문서	사업수행계획서 (별첨포함)*					사업수행계획서 (별첨포함)*
	구축공정 가이드라인 (임무 정의)*	구축공정 가이드라인 (획득)*	구축공정 가이드라인 (정제)*	구축공정 가이드라인 (가공)*		
						활용 가이드라인**
		획득 저작도구 사용설명서	정제 저작도구 사용설명서**	가공 저작도구 사용설명서**		
		품질관리보고서*	품질관리보고서*	품질관리보고서*	품질관리보고서*	
		개인정보 자율점검표*				
					시모델 설명서**	
					시모델 테스트 결과서	
						하자 및 유지보수 계획서*
동영상						데이터 활용 교육 영상**
데이터		원시데이터 (획득/수집 데이터)	원천데이터 (이미지, 영상, 오디오 등)**	가공데이터 (JSON 등)**		
어플리 케이션		저작도구	저작도구**	저작도구**		
기타					시모델 소스코드**	
					학습모델 파일**	
					모델 구축 도커이미지**	

[표 II-41] 구축 단계별 산출물


제3장

품질 자가점검 및 품질검증

1


개요

- 사업수행기관의 품질관리 역량, 데이터 유형별 구축 난이도, 해당 분야 전문가 및 인공지능 전문가 확보 유무 등에 따라 품질 수준 편차 발생으로 품질 자가점검 필요성 증대



[그림 II-18] 구축단계별 자가점검 체크리스트 활용

- 1-Cycle 자가점검은 인공지능 학습용 구축 초기의 데이터를 이용하여 「획득/수집 → 정제 → 가공 → 학습」까지 전체 공정에 대한 1-Cycle 데이터 점검 실시 후, 수행 방법이 목표에 부합하지 않는다면 데이터의 획득/수집, 정제, 가공 절차를 빠르게 변경하여 재작업을 하기 위한 필수 절차



[그림 II-19] 1-Cycle 자가점검 검사내용 및 조직

II

품질 관리 체계

2

품질 자가점검

2.1 품질 자가점검

- 인공지능 학습용 데이터 구축사업 진행 시 구축공정별 품질 이슈를 최소화하기 위해 사업수행기관의 초기데이터 1-Cycle 자가점검, 중간데이터 1-Cycle 자가점검은 필수적으로 수행하고, 그 외 품질 자가점검은 사업 규모, 사업 범위, 일정 등에 따라 선택적으로 수행

2.1.1 품질 자가점검 프로세스



[그림 II-20] 품질 자가점검 프로세스

2.1.2 품질 자가점검 프로세스 주요 내용

사업일정	품질 자가점검 활동	주요 검토내용
사업 착수	샘플데이터 1-Cycle 자가점검	- 사업수행계획서 내 구축계획서, 품질관리계획서의 적정성 검토 - 샘플데이터 (클래스별 1건) 기준으로 데이터 획득/수집, 정제, 가공, 학습 관점의 설계 적정성 검토 - 품질지표기준(안) 수립을 위한 적정성 검토
구축 초기 시점	초기데이터 1-Cycle 자가점검	- 사전 품질검증 전 측정지표 적정성 및 정량목표 달성도 점검 - 데이터 오류 유형에 따른 보완조치방안 마련 및 반영 여부 확인 - 초기데이터(전체데이터의 10% 이내)
중간 시점	중간데이터 1-Cycle 자가점검	- 구축 초기 단계 품질점검 및 사전품질검증 결과에 따른 개선 여부 점검 - 중간데이터 기반 구축 목표 달성여부 점검 (다양성, 구문 정확성, 의미 정확성, 유효성) 및 대책 마련 - 전체 구축량의 30% 이상 데이터

사업일정	품질 자가점검 활동	주요 검토내용
중간시점	중간데이터 보완점검	- 중간데이터 1-Cycle 자가점검 결과서에서 확인된 오류사항에 대한 보완 완료 여부 재점검 (30% 데이터) - 중간데이터 1-Cycle 자가점검 이후 신규 구축한 데이터 기준(20% 이내) 개선 및 보완된 가공기준을 기반으로 데이터 품질점검 - 중간데이터 보완점검은 모델 학습 소요시간을 고려하여 유효성 점검은 제외, 중간데이터 1-Cycle 자가점검에서 발생한 오류 항목 대상으로 수행 - 원천데이터, 다양성, 구문정확성, 의미정확성 등
최종 시점	최종데이터 1-Cycle 자가점검	- 최종 품질검증 대비 구축 데이터 품질오류 최종 보완 확인 - 최종 품질관리 결과 점검 - 전체 데이터(100%) 및 산출물


[표 II-42] 품질 자가점검 활동의 주요 검토내용

품질 자가점검 활동	입력물	출력물	유형	품질검증
샘플데이터 1-Cycle 자가점검	사업수행계획서, 샘플데이터 (클래스별 1건)	샘플데이터 1-Cycle 자가점검 체크리스트	문서	-
초기데이터 1-Cycle 자가점검	학습용 데이터 (5~10% 이내)	- 초기데이터 1-Cycle 자가점검 결과보고서 - 초기데이터(5~10% 이내)	문서 데이터	- 대상
중간데이터 1-Cycle 자가점검	학습용 데이터 (30% 이상)	중간데이터 1-Cycle 자가점검 결과보고서	문서	-
중간데이터 보완점검	학습용 데이터 (50% 이내)	중간데이터 보완점검 결과보고서	문서	-
최종데이터 1-Cycle 자가점검	학습용 데이터 (100%)	- 최종데이터 1-Cycle 자가점검 체크리스트 - 사업수행결과보고서 - 전체 데이터(100%)	문서 문서 데이터	- - 대상

[표 II-43] 품질 자가점검 활동의 입력물 및 출력물

2.2 품질 자가점검 세부 활동 정의

2.2.1 샘플데이터 1-Cycle 자가점검 프로세스




[그림 II-21] 샘플데이터 1-Cycle 자가점검 프로세스

번호	활동	주체	주요 내용	산출물
1	샘플데이터 1-Cycle 자가점검 체크리스트 양식 배포	사업관리기관	사업수행계획서 내 구축계획서 및 품질계획서 자가점검 체크리스트 양식 배포	샘플데이터 1-Cycle 자가점검 체크리스트 양식
2	샘플데이터 1-Cycle 자가점검 체크리스트 작성	사업수행기관	- 사업수행기관이 자가점검 체크리스트 작성 - 구축계획 기반 각 클래스별 최소 1건씩 데이터 샘플을 생성하여, 샘플데이터 기준으로 점검 수행 - 점검 결과에 따른 품질목표 및 지표 설정	샘플데이터 1-Cycle 자가점검 체크리스트
3	미흡 항목 점검 및 보완	사업수행기관	- 자가점검 체크리스트 점검 항목 중 미흡 항목에 대해 점검 및 보완 - 점검결과에 따른 품질지표기준(계획), 데이터 구축계획 재점검 - 샘플데이터 1-Cycle 자가점검 결과에 따른 품질지표기준서 1.0 초안 작성 및 협의	샘플데이터 1-Cycle 자가점검 체크리스트 등의 산출물, 사업수행계획서
4	샘플데이터 1-Cycle 자가점검 체크리스트 제출	사업수행기관	최종 작성된 자가점검 체크리스트 결과서 제출	샘플데이터 1-Cycle 자가점검 체크리스트
5	품질점검 활동 결과물의 적정성 검토	사업관리기관	- 샘플데이터 1-Cycle 자가점검 결과에 따른 품질지표기준서 1.0 초안 작성 및 협의 - 사업담당자, 품질담당자 등 공유 - 품질점검 활동 결과 분석 및 적정성 검토	컨설팅 보고서

[표 II-44] 샘플데이터 1-Cycle 자가점검 품질관리 활동 및 산출물

2.2.2 초기데이터 1-Cycle 자가점검 프로세스




[그림 II-22] 초기데이터 1-Cycle 자가점검 프로세스

번호	활동	주체	주요 내용	산출물
1	초기데이터 1-Cycle 자가점검 양식 배포	사업관리기관	초기데이터 수량(5~ 10% 이내)으로 품질 정량목표에 부합하는지에 대한 자가점검 결과보고서 양식 배포	초기데이터 1-Cycle 자가점검 결과보고서 양식
2	초기데이터 1-Cycle 수행	사업수행기관	- 초기데이터 1-Cycle 수행 - 측정지표의 적정성 및 정량목표의 달성도 점검 - 자가점검 결과보고서 작성	초기데이터 1-Cycle 자가점검 결과보고서(초안)
3	미흡 결과 점검 및 보완	사업수행기관	- 초기데이터 1-Cycle 결과 반영 여부 점검 - 데이터 오류 유형에 따른 보완 방안 마련 - 단계별 구축공정 가이드라인에 반영	보완된 초기데이터 1-Cycle 자가점검 결과보고서
4	초기데이터 1-Cycle 자가점검 결과 제출	사업수행기관	최종 작성된 자가점검 결과보고서 제출	초기데이터 1-Cycle 자가점검 결과보고서
5	품질점검 활동 결과물의 적정성 검토	사업관리기관	- 사업담당자, 품질담당자 등 공유 - 품질점검 활동 결과 분석 및 적정성 검토	컨설팅보고서

[표 II-45] 초기데이터 1-Cycle 자가점검 품질관리 활동 및 산출물

2.2.3 중간데이터 1-Cycle 자가점검 프로세스




[그림 II-23] 중간데이터 1-Cycle 자가점검 프로세스

번호	활동	주체	주요 내용	산출물
1	중간데이터 1-Cycle 자가점검 결과보고서 양식 배포	사업관리 기관	중간 데이터(30% 이상)에 대한 자가점검을 위한 결과보고서 양식 배포	중간데이터 1-Cycle 자가점검 결과보고서 양식
2	중간데이터 1-Cycle 자가점검 수행	사업수행 기관	- 초기데이터 1-Cycle 결과의 보완 필요 사항, 조치 필요 사항에 대한 반영 여부 점검 - 대량 데이터(30% 이상) 기반의 정확성 및 유효성 점검(대량 데이터에서 다양성 기반 균등 샘플링 후 점검)	중간데이터 1-Cycle 자가점검 결과보고서(초안)
3	미흡 결과 점검 및 보완	사업수행 기관	- 중간데이터 1-Cycle 결과 반영여부 점검 - 데이터 오류 유형에 따른 보완 방안 마련 - 단계별 구축공정 가이드라인에 반영	보완된 중간데이터 1-Cycle 자가점검 결과보고서
4	중간데이터 1-Cycle 자가점검 결과 제출	사업수행 기관	최종 작성된 자가점검 결과보고서 제출	중간데이터 1-Cycle 자가점검 결과보고서
5	품질점검 활동 결과물의 적정성 검토	사업관리 기관	- 사업담당자, 유닛별 품질담당자 등 공유 - 품질점검 활동 결과 분석 및 적정성 검토	컨설팅보고서

[표 II-46] 중간데이터 1-Cycle 자가점검 품질관리 활동 및 산출물

2.2.4 중간데이터 보완점검 프로세스



[그림 II-24] 중간데이터 보완점검 프로세스

번호	활동	주체	주요 내용	산출물
1	중간데이터 보완점검 결과보고서 양식 배포	사업관리기관	중간 데이터(50% 이상)에 대한 보완점검을 위한 결과보고서 양식 배포	중간데이터 보완점검 결과보고서 양식
2	중간데이터 보완점검 수행	사업수행기관	- 중간데이터 1-Cycle 자가점검 (30% 이상) 결과에서 확인된 오류 항목 대상으로 자가점검 수행 - 중간데이터 1-Cycle 자가점검 결과의 보완 필요사항, 조치 필요사항에 대한 반영 여부 점검 - 중간데이터 1-Cycle 자가점검 이후 보완완료된 데이터 (30% 이상) - 중간데이터 1-Cycle 자가점검 이후 신규 구축한 데이터 (20% 이내 데이터) 품질점검 - 중간데이터 1-Cycle 자가점검에서 확인된 품질 오류 항목 점검 - 중간데이터 1-Cycle 자가점검 이후 추가 확인된 품질오류 내용 검토 ※ 유효성 점검은 학습기간을 고려하여 대상 제외	중간데이터 보완점검 결과보고서(초안)

번호	활동	주체	주요 내용	산출물
3	미흡 결과 점검 및 보완	사업수행 기관	- 중간데이터 1-Cycle 자가점검 결과와, 중간데이터 보완점검 수행 결과 분석하여 동일 오류 지속 발생시 보완계획 및 대책 재수립 - 중간데이터 1-Cycle 자가점검 이후 신규 발생한 오류 유형 분석 및 대책 수립 - 단계별 구축공정 가이드라인에 반영	보완된 중간데이터 보완점검 결과보고서
4	중간데이터 보완점검 결과 제출	사업수행 기관	최종 작성된 자가점검 결과보고서 제출	중간데이터 보완점검 결과보고서
5	품질점검 활동 결과물의 적정성 검토	사업관리 기관	- 사업담당자, 품질담당자 등 공유 - 품질점검 활동 결과 분석 및 적정성 검토	컨설팅보고서

[표 II-47] 중간데이터 보완점검 품질관리 활동 및 산출물

2.2.5 최종데이터 1-Cycle 자가점검 프로세스



[그림 II-25] 최종데이터 1-Cycle 자가점검 프로세스

번호	활동	주체	주요 내용	산출물
1	최종데이터 1-Cycle 자가점검 체크리스트 양식 배포	사업관리기관	• 전체데이터 (100%)에 대한 자가점검을 위한 체크리스트 양식 배포	최종데이터 1-Cycle 자가점검 체크리스트 양식
2	최종데이터 품질 자가점검 수행	사업수행기관	• 전체 데이터(100%) 구축 • 사업수행계획서, 품질지표 기준서 v2.0, 품질검사 도구 등 준비 • 구축 완료 데이터(100%)로 결과값이 품질기준에 부합하는지 최종 점검	전체 데이터, 최종 산출물, 최종데이터 1-Cycle 자가점검 체크리스트(초안)
3	미흡 결과 점검 및 보완	사업수행기관	• 최종 품질점검결과 보완조치 • 오류 원인 및 유형 분석 후 개선조치	데이터 및 산출물 보완
4	최종데이터 1-Cycle 자가점검 체크리스트 제출	사업수행기관	• 최종 작성된 1-Cycle 자가점검 체크리스트 제출	최종데이터 1-Cycle 자가점검 체크리스트
5	품질점검 활동 결과물의 적정성 검토	사업관리기관	• 사업담당자, 품질담당자 등 공유 • 품질점검 활동 결과 분석 및 적정성 검토	컨설팅보고서
6	최종데이터 제출	사업수행기관	• 최종데이터를 사업관리기관에 제출 • 제3자 품질검증을 위한 데이터 제출	학습용 데이터 100%

[표 II-48] 최종데이터 품질 자가점검 품질관리 활동 및 산출물


3

제3자 품질검증

3.1 제3자 품질검증

- 데이터 개별 특성에 따른 객관적 품질지표 기준을 마련하고, 지표 기준에 따라 제3자 품질검증을 수행하여 구축 데이터의 품질목표 달성 여부 측정
- ※ 제3자 품질검증 : 인공지능 학습용 데이터의 품질관리 기준, 절차 및 방법을 이해하고 있는 기관 또는 업체를 통해 사업수행기관이 구축한 인공지능 학습용 데이터 품질을 검증하는 활동

3.1.1 제3자 품질검증 프로세스



[그림 II-26] 제3자 품질검증 프로세스


3.1.2 제3자 품질검증 프로세스 주요 내용

활동	주요 내용	주요 산출물
품질지표 기준 수립	사업수행기관이 제출한 사업수행계획서를 토대로 사전 품질검증을 위한 품질지표 기준 수립	품질지표 기준서 v1.0
사전품질검증	- 구축 중인 학습용 데이터셋의 오류를 사전에 검출하여 수정하고 예방 - 검증 대상 : 다양성, 구문 정확성, 의미 정확성 등	사전 품질검증 결과서
품질지표 기준 확정	- 사전 품질검증 결과를 토대로 이슈 및 변경 사항 발생 시 협의하여 품질지표 기준서에 반영 - 최종품질검증을 위한 품질지표 기준 최종 확정	품질지표 기준서 v2.0
최종품질검증	- 최종 구축된 학습용 데이터셋을 대상으로 품질목표 달성 여부 측정 - 검증 대상 : 다양성, 구문 정확성, 의미 정확성, 유효성 등	품질검증 결과서

[표 II-49] 제3자 품질검증 프로세스 주요 내용

3.2 제3자 품질검증 세부 활동 정의

3.2.1 품질지표 기준 수립 프로세스



[그림 II-27] 품질지표 기준 수립 프로세스

번호	활동	주체	주요 내용	산출물
1	품질지표 기준서 작성 요청	품질검증기관	• 품질지표 기준서 양식 및 안내 자료 배포	• 품질지표 기준서 양식 • 품질지표 기준서 작성 안내자료
2	품질지표 기준서 초안 작성	사업수행기관	• 사업수행계획서를 토대로 품질지표 기준서 초안 작성 • 항목별 측정조건 작성 • 구문 정확성 검사규칙 작성 • 의미 정확성 검사기준서 작성	• 품질지표 기준서 (초안) • 항목별 측정조건 • 구문 정확성 검사규칙 • 의미 정확성 검사기준서
3	품질지표 기준 검토	품질검증기관	• 품질지표 기준 제반 문서 검토	-
4	품질지표 기준 보완	사업수행기관	• 검토내용을 토대로 품질지표 기준 수정 및 보완	• 품질지표 기준서 (수정) • 항목별 측정조건 • 구문 정확성 검사규칙 • 의미 정확성 검사기준서
5	품질지표 기준 수립 및 확인	사업수행기관 품질검증기관 사업관리기관	• 최종 보완된 품질지표 및 목표에 대한 합의 • 합의된 품질지표 기준 확인	• 품질지표 기준서 v1.0

[표 II-50] 품질지표 기준 수립 활동 및 산출물

3.2.2 사전품질검증 프로세스




[그림 II-28] 사전품질검증 프로세스

번호	활동	주체	주요 내용	산출물
1	사전품질검증 안내	품질검증기관	- 품질검증 안내자료 배포 - 품질검증 교육 제공	- 품질검증안내자료 - 품질검증 양식
		사업관리기관	초기데이터(10% 이내) 제출 안내	요청 공문
2	사전품질검증 준비	품질검증기관	품질지표 기준서 검토	초기데이터 1-Cycle 자가점검 결과서
		사업수행기관	- 데이터셋 제출(초기데이터 10% 이내) - 품질검증 참고자료 산출물 제출 - 검증 준비 현황 점검	
3	사전품질검증 의뢰	사업수행기관	온라인 검증의뢰	검사기준서
4	사전품질검증 수행	품질검증기관	사전품질검증 수행 및 검증 결과 작성	사전품질검증결과서
5	사전품질검증 결과 검토	사업수행기관 품질검증기관	검증 결과 상호검토 및 합의	-
6	사전품질검증 결과 공유	품질검증기관	사전품질검증 결과를 사업관리기관 및 사업수행기관에 공유	-
7	사전품질검증 결과 확인	사업수행기관 사업관리기관	- 사전품질검증 결과 확인 ※ 검증 결과 오류는 반드시 수정 · 반영	사업관리대장

[표 II-51] 사전품질검증 활동 및 산출물

3.2.3 품질지표 기준 확정 프로세스



[그림 II-29] 품질지표 기준 확정 프로세스

번호	활동	주체	주요 내용	산출물
1	사전품질검증 결과 반영	사업수행기관	- 사전품질검증 결과를 품질지표 기준서 v1.0에 반영 - 항목별 측정조건 변경 반영 - 구문 정확성 검사규칙 변경 반영 - 의미 정확성 검사기준서 변경 반영	- 품질지표 기준서 v1.0 (수정) - 항목별 측정조건 - 구문 정확성 검사규칙 - 의미정확성검사기준서
2	품질지표 기준 수정안 검토	품질검증기관	사업수행기관이 수정한 품질지표 기준 자료 검토	-
3	품질지표 기준 보완	사업수행기관	검토내용을 토대로 품질지표 기준 수정 및 보완	- 품질지표 기준서 v1.0 (수정) - 항목별 측정조건 - 구문 정확성 검사규칙 - 의미정확성검사기준서
4	품질지표 기준 확정	사업수행기관 품질검증기관 사업관리기관	- 최종 보완된 내용으로 품질지표 및 목표에 대한 합의 - 합의된 품질지표 기준 확인	품질지표 기준서 v2.0

[표 II-52] 품질지표 기준 확정 활동 및 산출물

3.2.4 최종품질검증 프로세스



[그림 II-30] 최종품질검증 프로세스

번호	활동	주체	주요 내용	산출물
1	품질검증안내	품질검증기관	• 품질검증 안내자료 배포	• 품질검증안내자료
		사업관리기관	• 최종데이터(100%) 제출 안내	• 요청 공문
2	품질검증 준비	품질검증기관	• 품질지표 기준서 검토	• 최종데이터 • 유효성 증빙자료
		사업수행기관	• 데이터셋 제출(최종데이터 100%) • 품질검증 참고자료 산출물 제출 • 검증 준비 현황 점검 • 유효성 증빙자료 제출	
3	품질검증 의뢰	사업수행기관	• 온라인 검증을뢰	-
4	품질검증 수행	품질검증기관	• 품질검증 수행 및 검증 결과 작성	• 품질지표별 검증 결과
5	검증결과 검토	품질검증기관, 사업수행기관	• 검증결과 상호검토 및 합의	-
6	품질검증결과서 발급	품질검증기관	• 사업관리기관 및 사업수행기관에 품질검증결과서 발급	• 품질검증결과서
7	품질검증결과 확인	사업수행기관, 사업관리기관	• 최종 품질검증결과 확인	• 사업관리대장


[표 II-53] 최종품질검증 활동 및 산출물

● 품질검증 항목

번호	품질특성	주요 내용	기준
1	다양성(요건)	• 관심객체, 카테고리, 수집 환경 등에 대해 구축결과물의 구성비와 수량이 구축목표에 충족되는지 통계적으로 검증	구축목표 대비 구축결과물 충족 여부 확인
2	다양성(통계)	• 관심객체, 카테고리, 수집 환경 등에 대해 구축결과물의 구성비를 통계적으로 확인	충분성, 균등성, 편향성 여부 확인
3	구문 정확성	• 가공데이터 포맷과 값이 정확하게 입력되어 있고 필수항목 누락 여부 검사	정확도 99.5% 이상 권고
4	의미 정확성	• 어노테이션 값이 의미적으로 정답(GT)인지 확인하는 항목으로 실제적인 정답 비율 확인 • 데이터 특성에 따라 가공 데이터의 '맥락적 적절성', '논리적 타당성' 확인	정확도 95% 이상 권고
5	유효성	• 구축한 데이터셋을 잘 알려진 인공지능 학습모델로 학습시킨 후 목표로 했던 수준의 성능 달성이 가능한지 확인	인공지능 학습모델별 적정 기준 설정

[표 II-52] 품질검증 항목 내용

3.2.5 품질 보완조치 프로세스



[그림 II-31] 품질 보완조치 프로세스

번호	활동	주체	주요 내용	산출물
1	품질검증 결과 검토	사업관리기관	• 최종품질검증 결과 달성 여부 검토 • 검증 결과에 따라 사업수행기관에 보완조치 시행 요구	• 사업관리대장
2	보완조치 수행	사업수행기관	• 보완 필요 항목 또는 미달성 항목에 대한 보완 수행 (데이터, AI모델 등) • 보완 완료 결과물 업로드	• 보완 완료한 데이터 혹은 AI모델
3	보완조치 확인	품질검증기관	• 사업관리기관에 보완조치 확인 결과통보	• 보완조치확인결과(공문)
4	보완조치 결과 확인 및 적정성 검토	사업관리기관	• 보완조치 결과 확인 • 필요 시 사업수행기관에 재보완 요구	• 사업관리대장

[표 II-54] 품질 보완조치 활동 및 산출물


- 품질특성에 따른 보완조치 항목

※ 품질특성별 보완 대상, 세부 절차 등 일부 변동 가능

품질특성	보완 대상	검사 주체	세부 절차
다양성	전체 데이터	품질 검사기관	[그림 II-33]
구문 정확성			
의미 정확성			
유효성	데이터, AI모델, 관련 서류	품질 검증기관	[그림 II-33]


[표 II-55] 품질 보완조치 대상 구분

- 품질 달성 데이터 보완조치 과정



[그림 II-32] 품질 달성 데이터 보완조치 과정

- 품질 달성 데이터 보완조치 절차



[그림 II-33] 품질 달성 데이터 보완조치 세부 절차

번호	활동	주체	주요 내용
1	보완조치 시행 요구	사업관리 기관 (NIA)	- NIA는 사업수행기관에 품질 보완조치 시행 요구 공문 발송 - 품질 보완조치 시행 요구 시, 아래 항목 포함 - 품질 보완조치 절차 - 관련 서류 제출 기한 등
2	보완조치 계획 수립	사업수행 기관	사업수행기관은 보완조치 일정·방안에 대한 세부계획 수립
3	보완조치 수행	사업수행 기관	- 사업수행기관은 전체 데이터를 대상으로 검증·확인된 오류 유형 및 *보완조치수행 * 품질검증 결과서 수령 후 협의한 기간 내 조치를 완료하여야 함
4	보완조치 완료	사업수행 기관	- 사업수행기관은 보완조치 수행 결과를 ‘품질검증 결과 오류사항 조치결과서*’에 작성 * 과제담당자와 협의한 기간 내 조치 완료 - 사업수행기관은 보완 완료 데이터 및 결과서를 S3 버킷에 업로드** ** 보완조치에서 제외했던 데이터 포함 전체 데이터를 제출 경로 폴더에 업로드
5	보완결과 확인요청	사업수행 기관	- 사업수행기관은 NIA에 ‘품질 보완조치 결과 확인요청’ 공문 발송 - 해당 공문에는 ‘품질검증 결과 오류사항 조치결과서’ 첨부
6	결과 확인	사업관리 기관 (NIA)	- NIA는 사업수행기관의 제출공문(품질검증 결과 오류사항 조치결과서 등)을 검토 - 보완결과 만족 시, 품질 보완조치 프로세스 종료 - 보완결과 불만족 시, 재보완조치 수행 요구

[표 II-56] 품질 달성 데이터 보완조치 세부 설명

● 품질 미달성 데이터 보완조치 과정




[그림 II-34] 품질 미달성 데이터 보완조치 과정

● 품질 미달성 데이터 보완조치 절차

번호	활 동	주 체	주요 내용	접수	제출
1	보완조치 시행요구	사업관리 기관 (NIA)	- 사업관리기관은 품질검증 결과에 따라 사업수행기관에 품질보완조치 시행 요구 공문 발송 - 품질보완조치 시행 요구 시, 아래 항목 포함 - 품질 보완조치 대상 - 데이터 보완 완료 기한 등	품질보완 조치시행 요구공문	-
2	보완조치 세부사항 안내	품질검증 기관	- 사업수행기관은 품질검증기관에 연락하여 품질보완 조치에 대한 세부 안내 확인 - 품질검증기관은 데이터 업로드 방법, 제출서류, 품질검사기관 리스트 등 안내 ※ 계약추진및보완조치검사일정협의등은사업수행 기관이직접진행	품질보완 조치 세부사항 안내	-
3	보완조치 계획수립	사업수행 기관	- 사업수행기관은 보완대상, 기간 등 보완조치 세부계획수립 후 ‘품질보완조치 계획서’를 작성하여 사업관리기관에 제출* * 품질 보완조치 시행 요구로부터 1주일 이내	-	품질보완 조치 계획서
4	보완조치 수행	사업수행 기관	- 사업수행기관은 전체 데이터에 대해 보완 수행* * 품질 보완조치 계획서에 명시 한 조치 기간 내 완료	-	-
5	보완조치 완료	사업수행 기관	- 사업수행기관은 보완조치 수행 결과를 ‘품질보완조치 결과서*’에 작성하여 사업관리기관으로 공문 제출 * 품질보완조치 계획서에 명시 한 조치 기간 내 조치 완료 후 결과서 제출 - 사업수행기관은 보완완료 데이터 및 문서를 S3 버킷에 업로드 ※ 보완조치에서 제외했던 데이터 포함 전체 데이터를 제출 경로 폴더에 업로드	-	품질보완 조치 결과서 보완결과 데이터
6	계약 체결	사업수행 기관, 품질검증 기관, 품질검사 기관	- 사업수행기관과 품질 검사기관은 검사기준, 검사대상* 및 기간 등 협의 후 계약 체결 * 다양성의 경우 보완 계획에 따라 품질지표별 검사수행 여부 결정	-	품질검사 기관 간 계약서
7	검사 수행	품질 검사기관	- 품질 검사기관은 보완조치 결과물에 대한 검사수행 후 사업수행기관 측으로 검사 결과서 발급 ※ 사업수행기관은 검증 일정을 사업관리기관, 품질검증 기관에 공유	보완결과 데이터 품질지표 기준서 검사 기준서	품질검사 결과서
8	검사 결과 확인	사업수행 기관	- Pass(달성) : 품질검증기관에 품질보완조치 확인요청 - 해당 공문에는 검사 결과서와 기준문서* 첨부	품질검사 결과서	품질보완 결과확인 요청공문

번호	활동	주체	주요 내용	접수	제출
			* 다양성, 구문 정확성 기준문서 : 구문 점검 규칙 파일 * 의미 정확성 기준문서 : 검사기준서 • Fail : 보완조치 수행 (활동 ④부터 재수행)		검사 기준서
9	보완조치 결과 확인	품질검증 기관	• 품질검증기관은 사업수행기관 제출공문 (품질검사기관의 검사 결과서 및 기준문서) 검토 - 품질 보완조치 확인 결과를 사업관리기관 및 사업수행기관에 공문으로 통보	품질보완 결과확인 요청공문 검사 기준서	품질보완 조치확인 결과공문
10	결과 확인	사업관리 기관 (NIA), 사업수행 기관	• NIA와 사업수행기관은 TTA의 '품질 보완조치 확인' 공문 수령 및 보완조치 결과 최종 확인 - 보완결과 불만족 시, NIA는 사업수행기관에 재보완 조치 수행 요구	품질보완 조치확인 결과공문	재보완 조치수행 요구 (불만족)

[표 II-57] 품질 미달성 데이터 보완조치 세부 설명



[그림 II-35] 품질 미달성 데이터 보완조치 세부 절차

AI 데이터 품질관리 가이드라인 v4.0

제1권 품질관리 프레임워크를 중심으로

AI 데이터 품질관리 가이드 v4.0

III

부록

부록 1 | 품질관리 기준

부록 2 | 품질지표 설정 가이드

부록 3 | 데이터 가공 가이드

부록 4 | 개인정보보호 가이드

부록1

품질관리 기준

1

품질관리 지표

1.1 품질관리 지표 정의

- 한국지능정보사회진흥원이 추진하는 ‘인공지능 학습용 데이터 구축사업’과 인공지능 통합 플랫폼 (AI-Hub)를 통해 서비스하는 학습데이터 전반의 품질관리를 위한 기준이 필요하며, 다양한 인공지능 학습용 데이터를 수집·가공·활용하는 특성을 반영하여 범용적이고 공통적인 지표로 인공지능 학습용 데이터에 대한 품질관리를 강화하고, 지속적인 품질관리가 가능할 수 있도록 기준 마련함
- 목적에 맞게 데이터가 구축되었는지 검사하기 위해, 검사대상과 방식을 결정하는 것이 중요하며, 구축 목표에 따라 요구사항을 정의하고 데이터 구축 생애주기에 따라 최적의 품질을 확보할 수 있도록 검사와 개선이 필요
- 이를 위해 데이터 품질관리 지표를 정의해야 하는데, 데이터 품질관리 지표는 추후 구축된 데이터를 활용할 수요자의 요구사항을 달성하는데 필요한 요소가 잘 갖추어졌는지 확인하기 위해 데이터 품질을 관리하는 기준임
- 따라서, 데이터 품질관리 지표는 “데이터의 품질 수준을 측정하기 위한 관점을 정의한 것으로 무엇을 측정할 것인가에 대한 기준”이라고 정의할 수 있음

1.2 품질관리 지표 구성

- 데이터 품질관리 지표는 검사기준에 따라 “품질특성, 검사 항목(Assessment Indicator), 측정지표(Evaluation Metric)”로 구성
- 품질관리 지표는 데이터 생애주기 분석, 데이터 구축 및 품질 관점에서의 일치성 분석, 데이터 품질 관리 기준 분석을 기반으로 구성되며, 구축 및 활용 관점을 반영하여 총 9개의 품질특성으로 구성
- 9개의 품질특성은 준비성, 완전성, 유용성, 기준 적합성, 다양성, 구문 정확성, 의미 정확성, 알고리즘 적정성, 유효성으로 정의
- 수립된 데이터 품질의 9개 품질특성은 데이터 생애주기인 계획, 구축, 운영·활용의 전 단계의 품질 관리에 활용하여 데이터 품질 수준을 확보하는 기준이 됨

구 분	품질특성	설 명
구축 공정 적정성	준비성	• 인공지능 학습용 데이터 품질관리를 위해 기본적으로 관리해야 하는 정책, 규정 (저작권, 초상권, 개인정보보호 및 정보보호 등에 대한 검토 결과를 포함), 조직, 절차 등을 마련하고, 최신의 내용으로 충실하게 관리되는지를 검사
	완전성	• 인공지능 학습용 데이터를 구축함에 있어 물리적인 구조를 갖추고, 정의한 데이터 형식 및 데이터값 범위에 맞게 데이터가 저장되도록 설계·구축되었는지를 검사
	유용성	• 발주기관(수요자)의 요구사항이 충분히 반영되었는지, 임무 정의에 적합한 인공지능 학습용 데이터의 범위와 상세화 정도를 충족시키는지 검사
데이터 적합성	기준 적합성	• 원시데이터가 학습 용도로써 적합한지 기준 충족 여부를 확인하기 위해, 분류 다양성, 신뢰성, 충분성, 균일성, 사실성, 공정성, 형식성을 측정하는 품질특성
	다양성	• 원천/가공데이터의 편향성을 방지하기 위해, 데이터별 분포, 데이터별 수, 토큰수 등을 측정하는 품질특성
가공 데이터 정확성	구문 정확성	• 어노테이션 데이터를 구성하는 속성값들과 원래 정의한 데이터 형식 및 데이터값 범위와의 일치성을 측정하는 품질특성
	의미 정확성	• 데이터의 참값(GT), 맥락, 논리적 타당성을 확인하기 위해, 정확도, 정밀도, 재현율, IoU, ROUGE, BLEU, F β -점수, EM 등을 측정하는 품질특성
학습모델 적합성	알고리즘 적정성	• 알고리즘을 Task 단위로 구분하여, 사업수행기관이 제시하는 학습모델의 Task가 적정한지 판단하는 품질특성
	유효성	• 학습용 데이터로 학습시키는데 적합한 인공지능 알고리즘의 유효성을 측정하는 품질특성

[표 III-1] 품질관리 지표

※ 생성형AI 데이터의 품질특성은 『제3권 생성형AI 데이터 품질관리 가이드』에 수록

1.3 품질검사 방법

- 데이터 품질검사 방법은 검사대상에 따라 정량적 검사와 정성적 검사를 수행하며, 세부 지표별 검사 대상과 검사 방법은 다음과 같음

구분	품질특성		검사 항목	검사대상			검사 시점(구축과정)						검사 방법	
				구축 절차	데이터	학습 모델	임무 정의	구축 계획 수립	데이터 획득/수집	데이터 정제	데이터 가공	데이터 학습	정량적 검사	정성적 검사
구축 공정 적정성	준비성	계획 수립성	절차준비	●			●	●	●	●	●			√
			조직준비	●			●	●	●	●	●			√
			도구준비	●				●	●	●	●			√
			위험관리	●			●	●	●	●	●			√
		체계 준수성	보안준수	●			●	●	●	●	●			√
			법·제도 준수	●			●	●	●	●	●			√
	완전성		수집 완전성	●					●					√
			정제 완전성	●						●				√
			가공 완전성	●							●			√
	유용성		사용 편의성	●			●					●		√
			유연성	●			●					●		√
데이터 적합성	기준 적합성		분류 다양성	●	●			●	●					√
			신뢰성	●	●			●	●					√
			충분성	●	●			●	●					√
			균일성	●	●			●	●					√
			사실성	●	●			●	●					√
			공평성	●	●			●	●					√
			형식성		●				●	●			√	
	다양성		데이터별 분포		●					●	●		√	
			데이터별 수		●					●	●		√	
			토근 수		●					●	●		√	
가공데이터 정확성	구문 정확성		구조 정확성		●						●		√	
			형식 정확성		●						●		√	
	의미 정확성		내용 전달성		●						●		√	
			질의 적정성		●						●		√	
			바운딩박스 정확성		●						●		√	
			3D 모델링 정확성		●						●		√	
			분류 정확성		●						●		√	
			※ 그 외 데이터 종류 및 목적에 따라 적합하게 선정		●						●		√	
학습모델 적합성	알고리즘 적정성		※ 데이터 종류별, 알고리즘 Task 분야에 맞게 선정			●						●	√	√
	유효성		※ 과업 목표에 따라 적합한 품질지표 선정 필요			●						●	√	√

[표 III-2] 품질특성별 검사대상 및 검사 방법

2 구축 공정 적정성 품질관리 지표

2.1 준비성

- 인공지능 학습용 데이터 품질관리를 위해 기본적으로 관리해야 하는 정책, 규정(저작권, 초상권, 개인정보보호 및 정보보호 등에 대한 검토 결과를 포함), 조직, 절차 등을 마련하고, 최신의 내용으로 충실하게 관리되는지를 검사
- '준비성'은 '계획 수립성'과 '체계 준수성'으로 구성되며, 검사 항목은 계획 수립성은 절차준비, 조직준비, 도구준비, 위험관리의 4개 항목으로 구성되고, 체계 준수성은 보안준수, 법·제도 준수의 2개 항목으로 구성

품질특성		검사 항목
준비성	계획 수립성	절차준비
		조직준비
		도구준비
		위험관리
	체계 준수성	보안준수
		법·제도 준수

[표 III-3] 준비성 검사 항목 구성

2.1.1 계획 수립성 - 절차준비

- 검사기준 및 방법

분 류		검사기준 및 방법
검사상세		● 인공지능 학습용 데이터 구축을 위한 절차를 체계적으로 수립하고 그에 대한 관리 및 데이터 구축을 수행하고 있는지 점검
검사대상	산출물	● 사업수행계획서(구축계획서, 품질관리계획서) 등
	공정	● 임무 정의, 구축계획수립, 데이터 획득/수집, 데이터 정제, 데이터 가공
검사방법		● 체크리스트

[표 III-4] 계획 수립성 내 절차준비 검사기준 및 방법

● 검사 내용

분 류	체크리스트
임무 정의	• 발주기관(수요자) 요구사항을 수집하였는가? • 발주기관(수요자) 요구사항을 분석하였는가? • 과제 관련 유사 또는 동일한 연구 등에 대한 사전조사를 하였는가? • 과제에 적합한 인공지능 학습모델선정 방안을 마련하였는가? • 과제에 적합한 인공지능 학습모델선정 결과를 제시하였는가? • 과제에 적합한 인공지능 학습모델선정 시 제약사항, 한계점 등에 대한 내용을 제시하였는가? • 인공지능 학습모델 성능지표와 목표를 제시하였는가? • 인공지능 학습모델에 성능을 보장하기 위한 지표와 목표를 제시하였는가? (지표 특징, 선행 연구결과 등에 대한 조사) • 인공지능 학습모델에 성능을 보장하기 위한 지표와 목표에 대한 객관성 확보를 위한 근거를 제시하였는가? (전문가 자문 등)
구축 계획수립	• 인공지능 학습용 데이터셋을 정의하였는가? • 인공지능 학습용 데이터셋(학습용, 검증용, 시험용) 구성 비율을 제시하였는가? (예, 8:1:1 또는 기타 비율) • 인공지능 학습용 데이터셋 중 시험용 데이터셋 미활용을 위한 관리방안을 제시하였는가? (관리 및 운영 규정, 환경, 접근 권한 등) • 원시, 원천, 가공, 학습모델 구축을 위한 환경 구성계획을 수립하였는가? • 인공지능 학습용 데이터 분류체계를 정의하였는가? • 인공지능 학습모델에 적합한지 초기데이터(데이터 규모 10% 이내)를 활용한 인공지능 학습모델 검토계획을 수립하였는가? • 정의된 분류체계별로 데이터 획득/수집, 정제, 가공 계획을 수립하였는가? • 인공지능 학습모델 검토를 위한 초기데이터(데이터 규모 10% 이내) 선정 방법 및 기준을 마련하였는가? • 인공지능 학습모델에 적합한지 초기데이터(데이터 규모 10% 이내)를 활용한 인공지능 학습모델 검토결과 반영을 위한 절차를 마련하였는가?
데이터 획득/수집	• 데이터 선정을 위한 개인정보, 초상권, 저작권, 명예훼손, 보안 등과 관련된 법·제도적인 검토 절차를 마련하였는가? • 데이터 선정 시 수집 기술 및 방법에 대한 검토절차를 마련하였는가? • 데이터 획득/수집을 위한 개인정보, 초상권, 저작권, 명예훼손, 보안 등과 관련된 법·제도적인 검토 절차를 마련하였는가? • 데이터 획득/수집 방법 및 기준을 마련하였는가? • 데이터 획득/수집 시 미확보 데이터 획득/수집을 위한 방안을 수립하였는가? • 데이터 획득/수집 기준변경에 대한 절차를 마련하였는가? • 데이터 획득/수집 방법에 대한 교육 및 훈련계획을 수립하였는가? • 데이터 획득/수집 결과에 대한 검수절차를 마련하였는가? • 데이터 획득/수집 결과에 대한 검수 교육 및 훈련계획을 수립하였는가? • 인공지능 학습모델에 적합한지 초기데이터(데이터 규모 7~10%)를 활용한 인공지능 학습모델 검토결과 반영을 위한 절차를 마련하였는가?
데이터 정제	• 데이터 정제 시 개인정보보호 등 비식별화를 위한 기준과 절차를 마련하였는가? • 데이터 정제 방법 및 기준을 마련하였는가? • 데이터 정제 기준변경에 대한 절차를 마련하였는가? • 데이터 정제 방법에 대한 교육 및 훈련계획을 수립하였는가? • 데이터 정제 결과에 대한 검수절차와 기준을 마련하였는가?

분 류	체크리스트
	• 데이터 정제 결과에 대한 검수 기준변경 절차를 마련하였는가? • 데이터 정제 결과에 대한 검수 교육 및 훈련계획을 수립하였는가?
데이터 가공	• 데이터 가공 방법 및 기준을 마련하였는가? • 데이터 가공 기준변경에 대한 절차를 마련하였는가? • 데이터 가공 방법에 대한 교육 및 훈련계획을 수립하였는가? • 데이터 가공 결과에 대한 검수절차를 마련하였는가? • 데이터 가공 결과에 대한 검수 기준변경 절차를 마련하였는가? • 데이터 가공 결과에 대한 검수 교육 및 훈련계획을 수립하였는가? • 인공지능 학습모델에 가공데이터가 적합한지 검사를 위한 데이터 샘플링 방안을 마련하였는가?

[표 III-5] 계획 수립성 내 절차준비 검사 내용

2.1.2 계획 수립성 - 조직준비

● 검사기준 및 방법

분류	검사기준 및 방법
검사상세	• 인공지능 학습용 데이터 구축을 위한 조직 구성, 역할 및 책임을 체계적으로 수립하여 관리 및 운영하고 있는지 확인
검사대상	산출물
	• 사업수행계획서(구축계획서, 품질관리계획서) 등
검사대상	공정
	• 구축계획수립, 데이터 획득/수집, 데이터 정제, 데이터 가공
검사방법	• 체크리스트

[표 III-6] 계획 수립성 내 조직준비 검사기준 및 방법

● 검사 내용

분 류	체크리스트
구축 계획수립	• 인공지능 학습모델에 적합한지 초기데이터(데이터 규모 10% 이내)를 활용한 인공지능 학습모델 검토를 위한 조직의 역할과 책임을 정의하였는가? • 인공지능 학습용 데이터셋 중 시험용 데이터셋 미활용을 위한 관리자를 지정하였는가?
데이터 획득/수집	• 데이터 획득/수집을 위한 관련 법·제도적인 검토를 위한 전담조직을 구성하였는가? • 데이터 획득/수집을 위한 조직을 구성하고 담당자를 명시하였는가? • 데이터 획득/수집을 위한 인력운영 계획을 수립하였는가? • 데이터 획득/수집을 위한 조직의 역할과 책임을 정의하였는가? • 데이터 획득/수집 방법에 대한 교육 및 훈련을 위한 조직을 구성하고 담당자를 명시하였는가? • 데이터 획득/수집 방법에 대한 교육 및 훈련을 위한 조직 역할과 책임을 정의하였는가? • 데이터 획득/수집 결과에 대한 검수를 위한 조직의 역할과 책임을 정의하였는가?
데이터 정제	• 데이터 정제 시 개인정보보호 등 비식별화를 위한 기준마련을 위한 전담조직을 구성하였는가? • 데이터 정제를 위한 조직을 구성하고 담당자를 명시하였는가? • 데이터 정제를 위한 인력운영 계획을 수립하였는가? • 데이터 정제를 위한 조직의 역할과 책임을 정의하였는가? • 데이터 정제 방법에 대한 교육 및 훈련을 위한 조직을 구성하고 담당자를 명시하였는가?

분 류	체크리스트
	- 데이터 정제 방법에 대한 교육 및 훈련을 위한 조직 역할과 책임을 정의하였는가? - 데이터 정제 결과에 대한 검수를 위한 조직의 역할과 책임을 정의하였는가?
데이터 가공	- 데이터 가공을 위한 조직을 구성하고 담당자를 명시하였는가? - 데이터 가공을 위한 인력운영 계획을 수립하였는가? - 데이터 가공을 위한 조직의 역할과 책임을 정의하였는가? - 데이터 가공 방법에 대한 교육 및 훈련을 위한 조직을 구성하고 담당자를 명시하였는가? - 데이터 가공 방법에 대한 교육 및 훈련을 위한 조직의 역할과 책임을 정의하였는가? - 데이터 가공 결과에 대한 검수를 위한 조직의 역할과 책임을 정의하였는가?

[표 III-7] 계획 수립성 내 조직준비 검사 내용

2.1.3 계획 수립성 - 도구준비

● 검사기준 및 방법

분 류	검사기준 및 방법
검사상세	인공지능 학습용 데이터 구축을 위한 도구와 환경 구성 계획을 수립하여 관리 및 운영하고 있는지 확인
검사대상	산출물 - 사업수행계획서(구축계획서, 품질관리계획서) 등 공정 - 구축계획수립, 데이터 획득/수집, 데이터 정제, 데이터 가공
검사방법	체크리스트

[표 III-8] 계획 수립성 내 도구준비 검사기준 및 방법

● 검사 내용

분 류	체크리스트
구축 계획수립	- 인공지능 학습모델 선정에 따른 인공지능 학습모델이 정의되어 있는가? - 요구사항 변화에 따른 후보 인공지능 학습모델을 제시하고 있는가?
데이터 획득/수집	- 데이터 획득/수집을 위한 작업 도구를 정의하였는가? - 데이터 획득/수집을 위한 작업 도구 활용을 위한 사용자/관리자 매뉴얼이 있는가? - 데이터 획득/수집을 위한 작업 도구에 대한 교육 및 훈련 계획을 수립하였는가? - 데이터 획득/수집을 위한 작업 도구에 대한 교육 및 훈련을 실시하였는가? - 데이터 획득/수집을 위한 작업 도구에 대한 법·제도적(저작권 등) 검토를 하였는가?
데이터 정제	- 데이터 정제를 위한 작업 도구를 정의하였는가? - 데이터 정제를 위한 작업 도구 활용을 위한 사용자/관리자 매뉴얼이 있는가? - 데이터 정제를 위한 작업 도구에 대한 교육 및 훈련 계획을 수립하였는가? - 데이터 정제를 위한 작업 도구에 대한 교육 및 훈련을 실시하였는가? - 데이터 정제를 위한 작업 도구에 대한 법·제도적(저작권 등) 검토를 하였는가?
데이터 가공	- 데이터 가공을 위한 작업 도구를 정의하였는가? - 데이터 가공을 위한 작업 도구 활용을 위한 사용자/관리자 매뉴얼이 있는가? - 데이터 가공을 위한 작업 도구에 대한 교육 및 훈련 계획을 수립하였는가? - 데이터 가공을 위한 작업 도구에 대한 교육 및 훈련을 실시하였는가? - 데이터 가공을 위한 작업 도구에 대한 법·제도적(저작권 등) 검토를 하였는가?

[표 III-9] 계획 수립성 내 도구준비 검사 내용

2.1.4 계획 수립성 - 위험관리

● 검사기준 및 방법

분 류		검사기준 및 방법
검사상세		• 인공지능 학습용 데이터 구축을 위한 위험관리체계를 수립하여 관리 및 수행하고 있는지 확인
검사대상	산출물	• 사업수행계획서(구축계획서, 품질관리계획서) 등
	공정	• 구축계획수립, 데이터 획득/수집, 데이터 정제, 데이터 가공
검사방법		• 체크리스트

[표 III-10] 계획수립성 내 위험관리 검사기준 및 방법

● 검사 내용

분 류	체크리스트
구축 계획수립	• 사업의 위험관리를 위한 계획을 수립하였는가? • 사업의 위험관리를 위한 위험요소를 식별하였는가? • 식별된 위험대응을 위한 활동을 수행하고 있는가?
데이터 획득/수집	• 데이터 획득/수집 시 위험관리를 위한 계획을 수립하였는가? • 데이터 획득/수집 시 위험관리를 위한 위험요소를 식별하였는가? • 식별된 위험대응을 위한 활동을 수행하고 있는가?
데이터 정제	• 데이터 정제 시 위험관리를 위한 계획을 수립하였는가? • 데이터 정제 시 위험관리를 위한 위험요소를 식별하였는가? • 식별된 위험대응을 위한 활동을 수행하고 있는가?
데이터 가공	• 데이터 가공작업 시 위험관리를 위한 계획을 수립하였는가? • 데이터 가공작업 시 위험관리를 위한 위험요소를 식별하였는가? • 식별된 위험대응을 위한 활동을 수행하고 있는가?

[표 III-11] 계획 수립성 내 위험관리 검사 내용

2.1.5 체계 준수성 - 보안준수

● 검사기준 및 방법

분 류		검사기준 및 방법
검사상세		• 개인정보보호, 비식별화 조치 등 민감정보 보호와 인공지능 학습용 데이터 보안 관리를 위한 절차와 규정을 수립하여 관리 및 수행하고 있는지 확인
검사대상	산출물	• 사업수행계획서(구축계획서, 품질관리계획서) 등
	공정	• 구축계획수립, 데이터 획득/수집, 데이터 정제, 데이터 가공
검사방법		• 체크리스트

[표 III-12] 체계 준수성 내 보안준수 검사기준 및 방법

- 검사 내용

분 류	체크리스트
구축 계획수립	• 인공지능 학습용 데이터셋(학습용, 검증용, 시험용)에 대한 보안 관리체계를 마련하였는가? (관리 및 운영 규정, 환경, 접근 권한 등) • 민감정보 보호를 위한 체계를 마련하였는가? (관리 및 운영 규정, 환경, 접근 권한 등) ※ 개인정보보호 및 보안을 위한 관계법령, 고시·권고사항 준수
데이터 획득/수집	• 데이터 획득/수집에 대한 보안관리를 수행하고 있는가? (담당자 지정, 운영 환경 구성, 접근 권한 관리 등) • 민감정보 보호를 위한 활동을 수행하고 있는가? (담당자 지정, 로그관리 등) ※ 개인정보보호 및 보안을 위한 관계법령, 고시·권고사항 준수
데이터 정제	• 데이터 정제 시 개인정보보호 등 비식별화를 수행하고 있는가? • 데이터 정제에 대한 보안관리를 수행하고 있는가? (담당자 지정, 운영 환경 구성, 접근 권한 관리 등) ※ 개인정보보호 및 보안을 위한 관계법령, 고시·권고사항 준수
데이터 가공	• 데이터 가공작업에 대한 보안 관리를 수행하고 있는가? (담당자 지정, 운영 환경 구성, 접근 권한 관리 등) ※ 개인정보보호 및 보안을 위한 관계법령, 고시·권고사항 준수

【표 III-13】 체계 준수성 내 보안준수 검사 내용

2.1.6 체계 준수성 - 법·제도 준수

- 검사기준 및 방법

분 류	검사기준 및 방법
검사상세	• 인공지능 학습용 데이터 구축 시 관련 법·제도(개인정보, 초상권, 저작권 등)에 대한 충분한 검토와 해결방안이 제시되었는지 검사
검사대상	산출물
	공정
검사방법	• 체크리스트

【표 III-14】 체계 준수성 내 법·제도 준수 검사기준 및 방법

- 검사 내용

분 류	체크리스트
구축 계획수립	• 인공지능 학습용 데이터 구축을 위한 관련 법·제도 검토 절차 및 해결방안을 제시하는가? • 인공지능 학습용 데이터 구축을 위한 개인정보활용 동의 절차를 마련하고 수행하고 있는가? • 인공지능 학습용 데이터 구축을 위한 초상권 활용 동의 절차를 마련하고 수행하고 있는가? • 인공지능 학습용 데이터 구축 시 명예훼손 가능성 여부 검토 절차를 마련하고 수행하고 있는가? ※ 개인정보보호 및 보안을 위한 관계법령, 저작권 및 초상권관련 관계법령준수

분 류	체크리스트
데이터 획득/수집	• 데이터 획득/수집을 위한 관련 법·제도적인 검토를 위한 절차 및 해결방안을 제시하는가? • 데이터 획득/수집 시 저작권 보호 대상인 경우 법에 저촉되지 않는 범위 내에서 수집할 수 있는 방안을 마련하였는가? • 데이터 획득/수집 시 저작권 보호 대상 저작물 활용에 따른 동의 절차를 마련하고 수행하는가? • 데이터 획득/수집 시 저작권 보호 대상 저작물 활용에 따른 계약절차를 마련하고 수행하는가? ※ 개인정보보호 및 보안을 위한 관계법령, 저작권 및 초상권관련 관계법령준수
데이터 정제	• 데이터 정제를 위한 관련 민감정보 비식별화 조치 등 법·제도적인 검토 절차 및 해결방안을 제시하는가? • 데이터 정제를 위한 비식별화 기법 적용하는 방안을 마련하였는가? ※ 개인정보보호 및 보안을 위한 관계법령, 저작권 및 초상권관련 관계법령준수
데이터 가공	• 데이터 가공을 위한 법·제도적인 검토 절차 및 해결방안을 제시하는가? ※ 개인정보보호 및 보안을 위한 관계법령, 저작권 및 초상권관련 관계법령준수

[표 III-15] 체계 준수성 내 법·제도 준수 검사 내용

2.2 완전성

- 인공지능 학습용 데이터를 구축함에 있어 각 단계별 품질기준에 맞게 설계·구축되었는지를 검사
- ‘완전성’에 대한 검사 항목은 ‘수집 완전성’, ‘정제 완전성’, ‘가공 완전성’으로 구성

품질지표	검사 항목
완전성	수집 완전성
	정제 완전성
	가공 완전성

[표 III-16] 완전성 검사 항목 구성

2.2.1 수집 완전성

- 검사기준 및 방법

분 류	검사기준 및 방법
검사상세	• 데이터의 편향성 방지 방안을 수립하여 관리 및 수행하고 있는지 확인 • 데이터 획득/수집 방법 및 기준, 교육, 검수에 대한 체계를 수립하여 관리 및 수행하고 있는지 확인 • 데이터 획득/수집 기준변경을 위한 체계를 수립하여 관리 및 수행하고 있는지 확인
검사대상	산출물
	공정
검사방법	체크리스트

[표 III-17] 수집 완전성 검사기준 및 방법

- 검사 내용

분 류	체크리스트
데이터 획득/수집	• 편향성 방지 방안을 마련하였는가? • 정의된 데이터 획득/수집 방법 및 기준을 적용하고 있는가? • 데이터 획득/수집 기준변경에 대한 절차를 마련하였는가? • 데이터 획득/수집 방법에 대한 교육 및 훈련을 실시하였는가? • 데이터 획득/수집 결과에 대한 검수 절차 및 기준에 따라 수행하고 있는가? • 데이터 획득/수집 결과에 대한 검수 기준변경 시 절차에 따라 수행하였는가? • 데이터 획득/수집 결과에 대한 검수 교육 및 훈련을 실시하였는가? • 인공지능 학습모델에 적합한지 초기데이터(데이터 규모 10% 이내)를 활용한 인공지능 학습모델 검토를 위한 데이터 선별 방안에 따라 선별하였는가?

[표 III-18] 수집 완전성 검사 내용

2.2.2 정제 완전성

- 검사기준 및 방법

분 류	검사기준 및 방법
검사상세	• 개인정보보호를 위한 비식별화 조치 등 민감정보 보호를 위한 절차와 규정을 수립하여 관리 및 수행하고 있는지 확인 • 데이터 정제방법 및 기준, 교육, 검수에 대한 체계를 수립하여 관리 및 수행하고 있는지 확인 • 데이터 정제 기준변경을 위한 체계를 수립하여 관리 및 수행하고 있는지 확인
검사대상	산출물
	구축계획서, 품질관리계획서, 구축 가이드라인 등
검사대상	공정
	데이터 정제
검사방법	체크리스트

[표 III-19] 정제 완전성 검사기준 및 방법

- 검사 내용

분 류	체크리스트
데이터 정제	• 데이터 정제 시 개인정보보호 등 비식별화를 실시하였는가? • 정의된 데이터 정제 방법 및 기준을 적용하고 있는가? • 데이터 정제 기준변경에 대한 절차를 마련하였는가? • 데이터 정제 방법에 대한 교육 및 훈련을 실시하였는가? • 데이터 정제 결과에 대한 검수 절차 및 기준에 따라 수행하고 있는가? • 데이터 정제 결과에 대한 검수 기준변경 시 절차에 따라 수행하였는가? • 데이터 정제 결과에 대한 검수 교육 및 훈련을 실시하였는가? • 인공지능 학습모델에 적합한지 초기데이터(데이터 규모 10% 이내)를 활용한 인공지능 학습모델 검토를 위한 데이터 선별 방안에 따라 선별하였는가?

[표 III-20] 정제 완전성 검사 내용

2.2.3 가공 완전성

● 검사기준 및 방법

분 류		검사기준 및 방법
검사상세		- 데이터 가공 방법 및 기준, 교육, 검수에 대한 체계를 수립하여 관리 및 수행하고 있는지 확인 - 데이터 가공 기준 변경을 위한 체계를 수립하여 관리 및 수행하고 있는지 확인
검사대상	산출물	구축계획서, 품질관리계획서, 구축 가이드라인 등
	공정	데이터 가공
검사방법		체크리스트

[표 III-21] 가공 완전성 검사기준 및 방법

● 검사 내용

분 류	체크리스트
데이터 가공	- 정의된 데이터 가공 방법 및 기준을 적용하고 있는가? - 데이터 가공 기준변경에 대한 절차를 마련하였는가? - 데이터 가공 방법에 대한 교육 및 훈련을 실시하였는가? - 데이터 가공 결과에 대한 검수 절차 및 기준에 따라 수행하고 있는가? - 데이터 가공 결과에 대한 검수 기준변경 시 절차에 따라 수행하였는가? - 데이터 가공 결과에 대한 검수 교육 및 훈련을 실시하였는가? - 인공지능 학습모델에 적합한지 초기데이터(데이터 규모 10% 이내)를 활용한 인공지능 학습모델 검토를 위한 데이터 선별 방안에 따라 선별하였는가?

[표 III-22] 가공 완전성 검사 내용

2.3 유용성

- 발주기관(수요자)의 요구사항이 충분히 반영되었는지, 임무 정의에 적합한 인공지능 학습용 데이터의 범위와 상세화 정도를 충족시키는지 검사
- ‘유용성’에 대한 검사 항목은 ‘사용 편의성’, ‘유연성’으로 구성

품질지표	검사 항목
유용성	사용 편의성
	유연성

[표 III-23] 유용성 검사 항목 구성

2.3.1 사용 편의성

● 검사기준 및 방법

분 류		검사기준 및 방법
검사상세		사용자의 요구사항을 만족시킬 수 있는 학습모델과 학습용 데이터셋이 제공되고 있는지 확인
검사대상	산출물	구축 가이드라인
	공정	데이터 학습
검사방법		체크리스트

[표 III-24] 사용 편의성 검사기준 및 방법

- 검사 내용

분 류	체크리스트
임무 정의	• 발주자(수요자)와 협의된 결과를 해결하는데 적합한 인공지능 학습모델에 적합한 데이터셋인가?
데이터학습	• 인공지능 학습모델이 성능지표를 만족하는가? • 인공지능 학습모델이 학습용 및 검증용 데이터셋을 활용한 결과 성능지표 및 목표를 만족하는가? • 인공지능 학습모델이 시험용 데이터셋을 활용한 결과 성능지표 및 목표를 만족하는가? (수행기관 제외) • 사용자가 인공지능 학습모델에 사용하기 위한 데이터셋을 검색 및 활용하기 위한 기본정보를 제공하는가? (학습형태 등)

[표 III-25] 사용 편의성 검사 내용

2.3.2 유연성

- 검사기준 및 방법

분 류		검사기준 및 방법
검사상세		• 사용자 요구사항을 수용할 수 있는 학습모델 선정 및 적용이 유연한지 확인
검사대상	산출물	• 구축 가이드라인
	공정	• 데이터 학습
검사방법		• 체크리스트

[표 III-26] 유연성 검사기준 및 방법

- 검사내용

분 류	체크리스트
임무 정의	• 인공지능 학습모델 성능지표를 만족하지 못하는 경우 대안을 제시하고 있는가?
데이터 학습	• 인공지능 학습용 데이터 변경사항 및 이력이 관리되고 있는가?

[표 III-27] 유연성 검사내용

3 데이터 적합성 품질관리 지표

3.1 기준 적합성

- 구축 데이터가 학습 용도로 적합한지에 대한 기준 충족 여부를 측정하는 품질특성
- '기준 적합성'에 대한 검사 항목은 '분류 다양성', '신뢰성', '충분성', '균일성', '사실성', '공평성', '형식성'으로 구성

품질특성	검사 항목
기준 적합성	분류 다양성
	신뢰성
	충분성
	균일성
	사실성
	공평성
	형식성

[표 III-28] 기준 적합성 검사 항목 구성

3.1.1 분류 다양성

- 검사기준 및 방법

분류		검사기준 및 방법
검사상세		• 공간, 시간 등 환경조건 및 대상 객체 종류와 속성의 변화 정도를 확인
검사대상	산출물	• 구축 공정 가이드라인, 원시데이터
	데이터 종류	• 텍스트, 이미지, 비디오, 오디오, 3D
검사방법		• 체크리스트, 전수검사

[표 III-29] 분류 다양성 검사기준 및 방법

- 검사 내용

분 류	체크리스트								
구축 계획수립	인공지능이 처리해야 하는 실제 세상의 데이터(사물, 사람, 장소, 시간, 환경, 언어 특성 등)와 유사한 특성(예시 참조)이 데이터에 반영되도록 계획을 수립하였는가? 〈예시〉 분야별 데이터 특성(포괄성) <table><tr><th>분야</th><th>설명</th></tr><tr><td>자율주행 데이터</td><td>· 위치정보(GPS), 촬영시간, 도로종류, 차량 속도 등 포함</td></tr><tr><td>어류행동 데이터</td><td>· 비디오 외에 생육단계, 수질정보 등 포함</td></tr><tr><td>음성 데이터</td><td>· 발화자의 연령, 성별, 지역정보 등 포함</td></tr></table> ※ 분야별 특성 정보는 지속적으로 추가 필요	분야	설명	자율주행 데이터	· 위치정보(GPS), 촬영시간, 도로종류, 차량 속도 등 포함	어류행동 데이터	· 비디오 외에 생육단계, 수질정보 등 포함	음성 데이터	· 발화자의 연령, 성별, 지역정보 등 포함
	분야	설명							
	자율주행 데이터	· 위치정보(GPS), 촬영시간, 도로종류, 차량 속도 등 포함							
	어류행동 데이터	· 비디오 외에 생육단계, 수질정보 등 포함							
	음성 데이터	· 발화자의 연령, 성별, 지역정보 등 포함							
	인공지능이 처리해야 하는 실제 세상의 데이터(사물, 사람, 장소, 시간, 환경, 언어 특성 등)와 유사한 변동성(예시 참조)을 데이터가 갖도록 계획을 수립하였는가? 〈예시〉 분야별 데이터 변동성 <table><tr><th>분야</th><th>설명</th></tr><tr><td>자율주행 데이터</td><td>· 넓은 범위의 지역을 대상으로 낮, 밤, 우천, 눈 등 조건하에서 도심도로, 고속도로, 외곽/시골도로를 중심으로 저속, 중속, 고속 주행 환경에서 촬영</td></tr></table> ※ 분야별 특성 정보는 지속적으로 추가 필요	분야	설명	자율주행 데이터	· 넓은 범위의 지역을 대상으로 낮, 밤, 우천, 눈 등 조건하에서 도심도로, 고속도로, 외곽/시골도로를 중심으로 저속, 중속, 고속 주행 환경에서 촬영				
분야	설명								
자율주행 데이터	· 넓은 범위의 지역을 대상으로 낮, 밤, 우천, 눈 등 조건하에서 도심도로, 고속도로, 외곽/시골도로를 중심으로 저속, 중속, 고속 주행 환경에서 촬영								
데이터 획득/수집	인공지능이 처리해야 하는 실제 세상의 데이터(사물, 사람, 장소, 시간, 환경, 언어 특성 등)와 유사한 특성(예시 참조)이 데이터에 반영되었는가? 〈예시〉 분야별 데이터 특성(포괄성) <table><tr><th>분야</th><th>설명</th></tr><tr><td>자율주행 데이터</td><td>· 위치정보(GPS), 촬영시간, 도로종류, 차량 속도 등 포함</td></tr><tr><td>어류행동 데이터</td><td>· 비디오 외에 생육단계, 수질정보 등 포함</td></tr><tr><td>음성 데이터</td><td>· 발화자의 연령, 성별, 지역정보 등 포함</td></tr></table> ※ 분야별 특성 정보는 지속적으로 추가 필요	분야	설명	자율주행 데이터	· 위치정보(GPS), 촬영시간, 도로종류, 차량 속도 등 포함	어류행동 데이터	· 비디오 외에 생육단계, 수질정보 등 포함	음성 데이터	· 발화자의 연령, 성별, 지역정보 등 포함
	분야	설명							
	자율주행 데이터	· 위치정보(GPS), 촬영시간, 도로종류, 차량 속도 등 포함							
	어류행동 데이터	· 비디오 외에 생육단계, 수질정보 등 포함							
	음성 데이터	· 발화자의 연령, 성별, 지역정보 등 포함							
	인공지능이 처리해야 하는 실제 세상의 데이터(사물, 사람, 장소, 시간, 환경, 언어 특성 등)와 유사한 변동성(예시 참조)을 데이터가 갖고 있는가? 〈예시〉 분야별 데이터 변동성 <table><tr><th>분야</th><th>설명</th></tr><tr><td>자율주행 데이터</td><td>· 넓은 범위의 지역을 대상으로 낮, 밤, 우천, 눈 등 조건하에서 도심도로, 고속도로, 외곽/시골도로를 중심으로 저속, 중속, 고속 주행 환경에서 촬영</td></tr></table> ※ 분야별 특성 정보는 지속적으로 추가 필요	분야	설명	자율주행 데이터	· 넓은 범위의 지역을 대상으로 낮, 밤, 우천, 눈 등 조건하에서 도심도로, 고속도로, 외곽/시골도로를 중심으로 저속, 중속, 고속 주행 환경에서 촬영				
분야	설명								
자율주행 데이터	· 넓은 범위의 지역을 대상으로 낮, 밤, 우천, 눈 등 조건하에서 도심도로, 고속도로, 외곽/시골도로를 중심으로 저속, 중속, 고속 주행 환경에서 촬영								

[표 III-30] 분류 다양성 검사 내용

3.1.2 신뢰성

● 검사기준 및 방법

분 류		검사기준 및 방법
검사상세		• 데이터가 신뢰할 수 있는 사람, 기관, 기업으로부터 수집되었는지를 확인
검사대상	산출물	• 구축 가이드라인, 원시데이터
	데이터 종류	• 텍스트, 이미지, 비디오, 오디오, 3D
검사방법		• 체크리스트

[표 III-31] 신뢰성 검사기준 및 방법

● 검사 내용

분 류	체크리스트
구축 계획수립	• 데이터 획득/수집 시 획득/수집 출처의 객관성 확보를 위한 계획을 수립하였는가? (출처예시, 사람, 기관, 기업 등)
데이터 획득/수집	• 데이터 획득/수집을 위한 획득/수집 출처에 대한 객관성 확보를 위한 근거를 제시하였는가?

[표 III-32] 신뢰성 검사 내용

3.1.3 충분성

● 검사기준 및 방법

분 류		검사기준 및 방법
검사상세		• 카테고리(분류체계) 및 인스턴스(분류체계별 특성을 갖고 있는 데이터) 등이 학습에 유용한 수량인지를 확인
검사대상	산출물	• 구축 가이드라인, 원시데이터
	데이터 종류	• 텍스트, 이미지, 비디오, 오디오, 3D
검사방법		• 체크리스트

[표 III-33] 충분성 검사기준 및 방법

● 검사 내용

분 류	체크리스트
구축 계획수립	• 인공지능 학습모델에 필요한 분류체계 및 분류체계별 데이터 획득/수집 최소 수량 결정을 위한 절차를 마련하였는가? • 인공지능 학습모델에 필요한 분류체계 및 분류체계별 데이터 획득/수집 최소 수량 결정에 대한 근거를 제시하였는가?
데이터 획득/수집	• 인공지능 학습모델에 필요한 분류체계 및 분류체계별 데이터 획득/수집 최소 수량을 확보하였는가? (예시, MS COCO 데이터셋은 객체당 5,000개 이상 인스턴스 수집)

[표 III-34] 충분성 검사 내용

3.1.4 균일성

● 검사기준 및 방법

분 류		검사기준 및 방법
검사상세		분류/탐지/인식/이해/예측 카테고리(분류체계)별 인스턴스(분류체계별 특성을 갖고 있는 데이터) 수량의 균일성 및 비율이 고려되었는지 확인
검사대상	산출물	구축 가이드라인, 원시데이터
	데이터 종류	텍스트, 이미지, 비디오, 오디오, 3D
검사방법		체크리스트

[표 III-35] 균일성 검사기준 및 방법

● 검사 내용

분 류	체크리스트
구축 계획수립	- 인공지능 학습모델에 필요한 분류체계별 데이터 획득/수집 수량에 대한 적합한 비율 결정을 위한 절차를 마련하였는가? - 인공지능 학습모델에 필요한 분류체계별 데이터 획득/수집 수량에 대한 적합한 비율 결정에 대한 근거를 제시하였는가?
데이터 획득/수집	인공지능 학습모델에 필요한 분류체계별 데이터 획득/수집 수량에 대한 적합한 비율에 맞게 수량을 확보하였는가?

[표 III-36] 균일성 검사 내용

3.1.5 사실성

● 검사기준 및 방법

분 류		검사기준 및 방법
검사상세		분류/탐지/인식/이해/예측 카테고리(분류체계)별 인스턴스(분류체계별 특성을 갖고 있는 데이터) 구축을 위한 실제 환경 및 특성을 반영하였는지 확인
검사대상	산출물	구축 가이드라인, 원시데이터
	데이터 종류	텍스트, 이미지, 비디오, 오디오, 3D
검사방법		체크리스트

[표 III-37] 사실성 검사기준 및 방법

● 검사 내용

분 류	체크리스트
구축 계획수립	- 인공지능 학습용 데이터 구축 시 데이터 획득/수집이 인위적인 환경인 경우 실제 환경 및 상황의 특성을 반영하기 위한 계획을 수립하였는가? - 인공지능 학습용 데이터 구축 시 데이터 획득/수집이 인위적인 환경인 경우 실세계 환경 및 조건이 일관성을 갖도록 계획을 수립하였는가?

분 류	체크리스트										
	데이터 획득/수집 시 다중 데이터 간에 동기화를 하도록 계획을 수립하였는가?										
데이터 획득/수집	- 데이터 획득/수집이 인위적인 환경인 경우 실제 환경 및 상황의 특성이 반영된 근거를 제시하였는가? - 데이터 획득/수집이 인위적인 환경인 경우 실제 환경 및 조건이 일관성이 확보된 근거를 제시하였는가? - 데이터 획득/수집 시 다중 데이터 간에 동기화된 근거를 제시하였는가? 〈예시〉 데이터 획득/수집 시 동기화 <table border="1"> <thead> <tr> <th>분야</th><th>설명</th></tr> </thead> <tbody> <tr> <td>자율주행</td><td>· 비디오의 멀티카메라 촬영 영상은 시간 동기화를 맞추어야 함</td></tr> <tr> <td>CCTV</td><td>· 비디오의 멀티카메라 촬영 영상은 시간 동기화를 맞추어야 함</td></tr> <tr> <td>영상, 음성, 자막 동시 수집</td><td> · 영상과 음성을 동기화 해야 됨 · 영상과 자막을 동기화 해야 됨 · 영상, 음성, 자막을 동기화 해야 됨 </td></tr> <tr> <td>컴퓨터 비전, 메타버스, 3D 프린팅 등</td><td> · 이미지와 3D 모델링 데이터의 선형적 특징(직사각형, 원형, 마름모)이 유사해야 함 · 3D 모델링 데이터에 실제 객체의 부속장치가 모두 표현되어야 함 · 노멀(Normal) 방향이 정확해야 함 · 좌표 중심축을 기준으로 3D 모델링 데이터의 3차원 자세가 정확해야 함 · 메쉬(Mesh)내 홀(Hole)이 존재하지 않아야 함 · 메쉬(Mesh)와 텍스처(Textures)가 존재해야 함 · 3D 모델링 특징점 간 규격이 실제 객체의 특징점 간 규격과 일치해야 함 </td></tr> </tbody> </table>	분야	설명	자율주행	· 비디오의 멀티카메라 촬영 영상은 시간 동기화를 맞추어야 함	CCTV	· 비디오의 멀티카메라 촬영 영상은 시간 동기화를 맞추어야 함	영상, 음성, 자막 동시 수집	· 영상과 음성을 동기화 해야 됨 · 영상과 자막을 동기화 해야 됨 · 영상, 음성, 자막을 동기화 해야 됨	컴퓨터 비전, 메타버스, 3D 프린팅 등	· 이미지와 3D 모델링 데이터의 선형적 특징(직사각형, 원형, 마름모)이 유사해야 함 · 3D 모델링 데이터에 실제 객체의 부속장치가 모두 표현되어야 함 · 노멀(Normal) 방향이 정확해야 함 · 좌표 중심축을 기준으로 3D 모델링 데이터의 3차원 자세가 정확해야 함 · 메쉬(Mesh)내 홀(Hole)이 존재하지 않아야 함 · 메쉬(Mesh)와 텍스처(Textures)가 존재해야 함 · 3D 모델링 특징점 간 규격이 실제 객체의 특징점 간 규격과 일치해야 함
분야	설명										
자율주행	· 비디오의 멀티카메라 촬영 영상은 시간 동기화를 맞추어야 함										
CCTV	· 비디오의 멀티카메라 촬영 영상은 시간 동기화를 맞추어야 함										
영상, 음성, 자막 동시 수집	· 영상과 음성을 동기화 해야 됨 · 영상과 자막을 동기화 해야 됨 · 영상, 음성, 자막을 동기화 해야 됨										
컴퓨터 비전, 메타버스, 3D 프린팅 등	· 이미지와 3D 모델링 데이터의 선형적 특징(직사각형, 원형, 마름모)이 유사해야 함 · 3D 모델링 데이터에 실제 객체의 부속장치가 모두 표현되어야 함 · 노멀(Normal) 방향이 정확해야 함 · 좌표 중심축을 기준으로 3D 모델링 데이터의 3차원 자세가 정확해야 함 · 메쉬(Mesh)내 홀(Hole)이 존재하지 않아야 함 · 메쉬(Mesh)와 텍스처(Textures)가 존재해야 함 · 3D 모델링 특징점 간 규격이 실제 객체의 특징점 간 규격과 일치해야 함										

[표 III-38] 사실성 검사 내용

III

부
록

3.1.6 공정성

● 검사기준 및 방법

분 류	검사기준 및 방법
검사상세	데이터 속에 포함될 수 있는 편향된 데이터를 제거하였는지 확인
검사대상	산출물
	데이터 종류
검사방법	체크리스트

[표 III-39] 공정성 검사기준 및 방법

● 검사 내용

분 류	체크리스트
구축 계획수립	인공지능 학습용 데이터 구축 시 지역적 편견, 사회적 편견, 인종적 편견 등을 방지하기 위한 계획을 수립하였는가?
데이터 획득/수집	인공지능 학습용 데이터 구축 시 지역적 편견, 사회적 편견, 인종적 편견 등의 방지 결과에 대한 근거를 제시하였는가?

[표 III-40] 공정성 검사 내용

3.1.7 형식성

- 원시데이터, 원천데이터의 파일 단위에서 학습 용도로 적합한지 판단하기 위해 측정하는 검사 항목
- ‘형식성’의 세부 검사 항목은 ‘파일 유효성’, ‘파일 포맷 적합성’, ‘파일 속성 적합성’ 등으로 구성

검사항목	세부 검사 항목
형식성	파일 유효성
	파일 포맷 적합성
	파일 속성 적합성

[표 III-41] 형식성 세부 검사 항목 구성

3.1.7.1 파일 유효성

- 검사기준 및 방법

분 류	검사항목	검사기준 및 방법
검사상세		• 파일이 손상되지 않고 정상적으로 활용 가능한지 확인
검사대상	산출물	• 원시데이터 • 원천데이터
	데이터 종류	• 텍스트, 이미지, 비디오, 오디오, 3D
	내용	• 값
검사방법		• 인공지능 학습용 데이터 구축 시 데이터의 파일 유효성을 전수검사를 통해 확인 ※ 데이터 확인방식은 전수조사를 기본으로 함
계산 방법		• 적합성(%) = 100 - 오류율(%) • 오류율(%) = $\frac{\text{오류 데이터 수(건)}}{\text{총 검사 데이터 수(건)}} \times 100(\%)$

[표 III-42] 파일 유효성 세부 검사 항목 구성

3.1.7.2 파일 포맷 적합성

- 검사기준 및 방법

분 류	검사항목	검사기준 및 방법
검사상세		• 대중적으로 널리 사용되는 대표적인 파일 포맷을 사용하였는지 확인
검사대상	산출물	• 원시데이터 • 원천데이터
	데이터 종류	• 텍스트, 이미지, 비디오, 오디오, 3D
	내용	• 값
검사방법		• 인공지능 학습용 데이터 구축 시 데이터의 파일 포맷이 정의된 기준에 적합한지 전수조사를 통해 확인 〈데이터 유형별 권장 파일 포맷〉

분 류	검사기준 및 방법		
	데이터 유형	파일 포맷	비고
	이미지	JPG, PNG, TIFF	· 의료 등 전문분야의 경우 해당 분야 표준 준수
	비디오	MP4, AVI	· 무압축 방식으로 프레임 이미지 시퀀스의 묶음 형태
	오디오	WAV, PCM	-
	텍스트	-	· UTF-8 인코딩 준수
	정량 수치	CSV	· 산업용 센서의 경우 해당 분야 표준 준수
	로그	JSON	· 표준 준수
계산 방법	- 적합성(%) = 100 - 오류율(%) - 오류율(%) = $\frac{\text{오류 데이터 수(건)}}{\text{총 검사 데이터 수(건)}} \times 100(\%)$		

[표 III-43] 파일 포맷 적합성 검사기준 및 방법

3.1.7.3 파일 속성 적합성

● 검사기준 및 방법

분 류	검사기준 및 방법	
검사상세	파일 유형별로 활용 목적 따라 파일 속성이 적합한지 확인	
검사대상	산출물	- 원시데이터 - 원천데이터
	데이터 종류	비디오, 이미지, 오디오, 텍스트
	내용	값
검사방법	인공지능 학습용 데이터 구축 시 정의된 파일 속성을 원천데이터에 적용하고 있는지 전수조사를 통해 확인	
	〈데이터 유형별 데이터 속성 예시〉	
	데이터 유형	데이터 속성 예시
	이미지	· 해상도, 컬러심도 등
	비디오	· 해상도, 컬러심도, 프레임레이트 등
	오디오	· 재생시간 등
	텍스트	· 인코딩 방식 등
	〈주요 속성별 측정 방법〉	

분 류	검사기준 및 방법		
	데이터 속성	데이터 유형	확인 방법
	해상도	비디오, 이미지	· 인공지능 학습용 데이터 구축 시 정의한 이미지, 비디오 데이터의 해상도(가로, 세로 픽셀 수)를 준수하고 있는지 전수조사를 통해 확인
	프레임 레이트	비디오	· 인공지능 학습용 데이터 구축 시 정의한 수집 비디오 데이터 프레임 레이트 (1초당 사용되는 이미지가 몇 장인지 초당 프레임 수)를 준수하고 있는지 전수조사를 통해 확인
	컬러심도	비디오, 이미지	· 인공지능 학습용 데이터 구축 시 정의한 수집 비디오 및 이미지 데이터에 대한 컬러심도(픽셀당 비트수)를 준수하고 있는지 전수조사를 통해 확인
	재생시간	오디오	· 인공지능 학습용 데이터 구축 시 정의한 수집 오디오 데이터에 대한 재생시간을 준수하고 있는지 전수조사를 통해 확인
	인코딩	텍스트	· 인공지능 학습용 데이터 구축 시 정의한 텍스트 데이터에 대한 인코딩 방식을 준수하고 있는지 전수조사를 통해 확인
계산 방법	※ 데이터 확인방식은 전수조사를 기본으로 함		
	적합성(%) = 100 - 오류율(%) $\text{오류율(\%)} = \frac{\text{오류 데이터 수(건)}}{\text{총 검사 데이터 수(건)}} \times 100(\%)$		

[표 III-44] 파일 속성 적합성 검사기준 및 방법

3.2 다양성

- 데이터의 충분성과 균일성 확보 및 편향성 방지를 위해 데이터의 수량, 구성비 등을 측정하는 품질특성
- ‘다양성’ 항목은 검사 유형에 따라 ‘다양성(요건)’, ‘다양성(통계)’로 구분

검사 유형	상세 내용
다양성(요건)	• 다양성(요건)은 인공지능 데이터 구축계획 수립 시 설정된 목표(기준 적합성 등)를 충족하는지 검증 • 데이터의 수량, 클래스 및 인스턴스별 수량, 클래스 및 인스턴스별 구성비, 연령별 구성비, 문장길이(어절 수, 음절 수), 어휘 빈도 수 등의 기준을 설정하고, 목표 대비 구축된 결과물의 충족 여부를 평가 • 목표대비 데이터 수량과 구성비가 적절한지 확인하며, 구축된 결과물이 설정된 기준을 만족하는지 검증 • 데이터 편향을 방지하고, 특정 클래스나 속성이 과소/과대 대표되는 현상을 막기 위해 구성비 중첩률을 활용하여 목표대비 달성도를 측정
다양성(통계)	• 다양성(통계)은 인공지능 데이터의 특성을 통계적으로 분석한 결과를 확인 • 데이터의 클래스 및 인스턴스별 구성비, 연령 별 구성비 등을 산출하여 실제 데이터의 분포를 확인 • 데이터를 직접 평가하는 것이 아니라, 객관적인 수치로 데이터의 구성과 분포를 통계적으로 분석하여 제공 • 다양한 통계적 방법을 활용하여 데이터의 균형성과 편향 여부를 확인할 수 있도록 정보를 제공

[표 III-45] 다양성 통계, 요건 상세 내용

3.2.1 다양성 검사 항목

- ‘다양성’에 대한 검사 항목은 데이터의 종류 및 목적에 따라 검사 항목을 적합하게 선정

품질특성	검사 항목
다양성	• 데이터별 분포 ※ 검사 항목은 데이터의 유형 및 활용 목적에 따라 주제분류/클래스/인스턴스 분포, 문장/어절 길이 분포 등으로 적절하게 선정하여 적용
	• 데이터 수 ※ 검사 항목은 데이터의 유형 및 활용 목적에 따라 원시데이터 수, 원천데이터 수, 주제분류별/클래스별/인스턴스별 데이터 수 등으로 적절하게 선정하여 적용
	• 토큰 수 ※ 검사 항목은 문장/어절 길이, 어휘 수 등으로 적절하게 선정하여 적용

[표 III-46] 다양성 검사 항목 구성 예시

3.2.1.1 데이터별 분포(주제분류/클래스 분포)

- 검사기준 및 방법

분 류		검사기준 및 방법
검사상세		• 학습에 유용한 분류체계(카테고리)별 클래스 유형 및 요건이 다양하게 분포되어 있는지 검사
검사대상	산출물	• 원천데이터, 가공데이터
	데이터 종류	• 텍스트, 이미지, 비디오, 오디오, 3D
	내용	• 값
검사방법		• 인공지능 학습용 데이터 구축 시 정의한 분류체계(카테고리)를 기준으로 어노테이션 데이터에 포함된 클래스 정보를 추출하여 통계값 산출 ※ 클래스 분포 최소 기준은 전문가 자문 또는 품질검증기관 협의를 통해 결정

[표 III-47] 클래스 분포 검사기준 및 방법

3.2.1.2 데이터 수(어휘 개수)

- 검사기준 및 방법

분 류		검사기준 및 방법
검사상세		• 텍스트 및 오디오 데이터의 어휘 개수가 학습에 유용한 수량과 수량의 균일성 및 비율이 고려되었는지 확인
검사대상	산출물	• 원천데이터, 가공데이터
	데이터 종류	• 텍스트, 이미지, 비디오, 오디오, 3D
	내용	• 값
검사방법		• 인공지능 학습용 데이터 구축 시 정의한 어휘 개수를 기준으로 어노테이션 데이터에 포함된 어휘 개수 정보를 추출하여 통계값 산출 ※ 학습에 유용한 수량, 비율 등의 최소 기준에 대한 전문가 자문 필요

[표 III-48] 어휘 개수 검사기준 및 방법

3.2.1.3 토큰 수 (문장 길이)

- 검사기준 및 방법

분 류		검사기준 및 방법
검사상세		• 텍스트 및 오디오 데이터의 문장 길이가 학습에 유용한 수량과 수량의 균일성 및 비율이 고려되었는지 확인
검사대상	산출물	• 원천데이터, 가공데이터
	데이터 종류	• 텍스트, 오디오
	내용	• 값
검사방법		• 인공지능 학습용 데이터 구축 시 정의한 문장 길이를 기준으로 어노테이션 데이터에 포함된 문장 길이 정보를 추출하여 통계값 산출

[표 III-49] 문장 길이 검사기준 및 방법

3.2.2 다양성 측정지표

- ‘다양성’에 대한 측정지표는 수량, 구성비, 구성비 중첩률 등으로 분류

품질특성		측정지표
다양성	다양성(요건)	수량
		구성비
		구성비 중첩률
	다양성(통계)	구성비

[표 III-50] 다양성 측정지표 구성

※ “수행계획서에 포함된 구성비”일 경우 반드시 ‘통계 항목’이 아닌 ‘요건 항목’에 기재

※ 구성비 중첩률은 다양성(요건)에만 해당됨

3.2.2.1 수량

- 검사기준 및 방법

분 류		검사기준 및 방법																
검사상세		• 데이터가 학습에 유용한 수량에 대한 기준을 고려했는지 확인																
검사대상	산출물	• 원천데이터, 가공데이터																
	데이터 종류	• 텍스트, 이미지, 비디오, 오디오, 3D																
	내용	• 값																
검사방법		• 인공지능 학습용 데이터에서 원천데이터 수량 또는 클래스/인스턴스/속성별 데이터 수량을 원천데이터, 어노테이션 값으로 검사함 ※ 학습에 유용한 수량의 최소 기준에 대한 전문가 자문 필요																
		• 예시																
		<table><tr><th>구분</th><th>항목</th><th>지표</th><th>목표</th><th>결과</th></tr><tr><td rowspan="2">다양성 (요건)</td><td>이미지 당 캡션 어절 수</td><td>최소 수량</td><td>30어절 이상</td><td>평균 35어절</td></tr><tr><td>원천데이터 문장 수</td><td>최소 수량</td><td>300만 문장 이상</td><td>총 3,500,000</td></tr></table>					구분	항목	지표	목표	결과	다양성 (요건)	이미지 당 캡션 어절 수	최소 수량	30어절 이상	평균 35어절	원천데이터 문장 수	최소 수량
구분	항목	지표	목표	결과														
다양성 (요건)	이미지 당 캡션 어절 수	최소 수량	30어절 이상	평균 35어절														
	원천데이터 문장 수	최소 수량	300만 문장 이상	총 3,500,000														
계산 방법		• 수량 = $\sum_{k=1}^K$ 데이터 개수 ※ K= 원천데이터, 클래스, 인스턴스, 속성 등으로 데이터의 특성에 따라 설정																

[표 III-51] 수량 검사기준 및 방법

3.2.2.2 구성비

- 검사기준 및 방법


분 류		검사기준 및 방법																																																							
검사상세		• 데이터 수량의 균일성 및 비율이 고려되었는지 확인																																																							
검사대상	산출물	• 원천데이터, 가공데이터																																																							
	데이터 종류	• 텍스트, 이미지, 비디오, 오디오, 3D																																																							
	내용	• 값																																																							
검사방법		• 인공지능 학습용 데이터의 전체 데이터에서 특정 범주(클래스, 인스턴스, 속성, 환경 등)가 차지하는 비율을 검사함 ※ 학습에 유용한 수량, 비율 등의 최소 기준에 대한 전문가 자문 필요 ※ 주제분류/클래스/인스턴스 분포 등 최소 기준은 전문가자문 또는 품질검증기관 협의를 통해 결정 ※ 계산 방법에 대한 전문가 자문 또는 품질검증기관 협의를 통해 결정 • 예시																																																							
		<table><tr><th>구분</th><th>항목</th><th>지표</th><th>목표</th><th colspan="2">결과</th></tr><tr><td rowspan="8">다양성 (통계)</td><td rowspan="4">분류 유형 분포</td><td rowspan="4">구성비</td><td rowspan="4">분포 확인</td><td>구분</td><td>비율</td></tr><tr><td>상당 주제</td><td>50%</td></tr><tr><td>상당 요건</td><td>50%</td></tr><tr><td>합계</td><td>100%</td></tr><tr><td rowspan="4">시각요소 설명문 길이 분포</td><td rowspan="4">구성비</td><td rowspan="4">분포 확인</td><td>구분</td><td>비율</td></tr><tr><td>5어절 이하</td><td>30%</td></tr><tr><td>6~10어절</td><td>40%</td></tr><tr><td>11어절 이상</td><td>30%</td></tr><tr><td rowspan="5">다양성 (요건)</td><td rowspan="5">레이아웃 안내문 비율 분포</td><td rowspan="5">구성비</td><td colspan="2">구분</td><td>비율</td></tr><tr><td>문서 페이지수</td><td>50%</td><td>문서 페이지수</td><td>45%</td></tr><tr><td>레이아웃 안내문수</td><td>50%</td><td>레이아웃 안내문수</td><td>65%</td></tr><tr><td colspan="2"></td><td></td><td></td></tr><tr><td colspan="2"></td><td></td><td></td></tr></table>					구분	항목	지표	목표	결과		다양성 (통계)	분류 유형 분포	구성비	분포 확인	구분	비율	상당 주제	50%	상당 요건	50%	합계	100%	시각요소 설명문 길이 분포	구성비	분포 확인	구분	비율	5어절 이하	30%	6~10어절	40%	11어절 이상	30%	다양성 (요건)	레이아웃 안내문 비율 분포	구성비	구분		비율	문서 페이지수	50%	문서 페이지수	45%	레이아웃 안내문수	50%	레이아웃 안내문수	65%								
		구분	항목	지표	목표	결과																																																			
		다양성 (통계)	분류 유형 분포	구성비	분포 확인	구분	비율																																																		
						상당 주제	50%																																																		
						상당 요건	50%																																																		
						합계	100%																																																		
			시각요소 설명문 길이 분포	구성비	분포 확인	구분	비율																																																		
						5어절 이하	30%																																																		
						6~10어절	40%																																																		
11어절 이상	30%																																																								
다양성 (요건)	레이아웃 안내문 비율 분포	구성비	구분		비율																																																				
			문서 페이지수	50%	문서 페이지수	45%																																																			
			레이아웃 안내문수	50%	레이아웃 안내문수	65%																																																			
계산 방법		• 특정 범주의 구성비 = $\frac{\text{특정 범주에 속하는 데이터 개수}}{\text{전체 데이터 개수}} \times 100$																																																							

[표 III-52] 구성비 검사기준 및 방법

3.2.2.3 구성비 중첩률

● 검사기준 및 방법

분 류		검사기준 및 방법														
검사상세		• 분류체계(카테고리)나 인스턴스(분류체계별 특성을 가지고 있는 데이터)수량이나 분포가 학습에 유용한 균일성 및 비율이 고려되었는지 확인														
검사대상	산출물	• 원천데이터, 가공데이터														
	데이터 종류	• 텍스트, 이미지, 비디오, 오디오, 3D														
	내용	• 값														
검사방법		• 지표에 대한 목표치를 설정하고 도출한 속성의 목표 구성비 막대그래프와 결과 구성비 막대그래프 간의 길이 중첩 비율을 계산 ※ 클래스/인스턴스 분포 최소 기준은 전문가 자문 또는 품질검증기관 협의를 통해 결정														
		• 예시														
		다양성	항목	지표	목표		결과									
		다양성 (요건)	영상 촬영 환경 분포	구성비 중첩률	구성비 중첩률	50% 이상	구성비 중첩률	86.57%								
					분야	비율	분야	결과비율								
					실내	40%	실내	46.5%								
					실외	30%	실외	22.8%								
					현장	30%	현장	30.7%								
			지시문 난이도 분포	구성비 중첩률	구성비 중첩률	50%	구성비 중첩률	99.60%								
					임무	비율	임무	결과비율								
상	33.5%				상	33.3%										
중	33.5%				중	33.6%										
하	33%				하	33.1%										
〈검사 예시〉 구성비 중첩률 : 50% 이상 목표대비 결과 비율 <table><tr><th>구분</th><th>목표</th><th>결과</th><th>구성비 중첩률</th></tr><tr><td>남성</td><td>40%</td><td>50%</td><td rowspan="2">81.8%</td></tr><tr><td>여성</td><td>60%</td><td>50%</td></tr></table> 구성비 중첩률(%) = (40 + 50) / (50 + 60) * 100 = 81.8 (목표대비 81.8%의 구성비를 달성)						구분	목표	결과	구성비 중첩률	남성	40%	50%	81.8%	여성	60%	50%
구분	목표	결과	구성비 중첩률													
남성	40%	50%	81.8%													
여성	60%	50%														

분 류	검사기준 및 방법												
	• 구성비 중첩률 표현 그래프 예시 <table><caption>구성비 중첩률 데이터</caption><thead><tr><th>학년</th><th>목표 구성비 (%)</th><th>결과 구성비 (%)</th></tr></thead><tbody><tr><td>3학년</td><td>15%</td><td>10.62%</td></tr><tr><td>2학년</td><td>10.67%</td><td>9.58%</td></tr><tr><td>1학년</td><td>5.33%</td><td>5.19%</td></tr></tbody></table> ※ ‘구성비 중첩률’이란 데이터의 실제 분포와 목표 분포를 막대그래프로 표현하였을 때 중첩되는 부분의 막대 길이를 측정하여 비율로 나타낸 것으로, 본 사업을 위해 도입된 지표	학년	목표 구성비 (%)	결과 구성비 (%)	3학년	15%	10.62%	2학년	10.67%	9.58%	1학년	5.33%	5.19%
학년	목표 구성비 (%)	결과 구성비 (%)											
3학년	15%	10.62%											
2학년	10.67%	9.58%											
1학년	5.33%	5.19%											
계산 방법	• $\text{구성비 중첩률}(\%) = \frac{\sum_{k=1}^n \text{중첩막대길이}_k}{\sum_{k=1}^n \text{최대막대길이}_k} \times 100$												

[표 III-53] 구성비 중첩률 검사기준 및 방법

4 가공데이터 정확성 품질관리 지표

4.1 구문 정확성

- 어노테이션 데이터의 구조와 속성 값들이 정의된 규칙에 부합하는지 구조 정확성과 형식 정확성 등을 측정하는 품질특성
- ‘구문 정확성0706’에 대한 검사 항목은 ‘구조 정확성’, ‘형식 정확성’으로 구성

품질특성	검사 항목
구문 정확성	구조 정확성 - 데이터 구조
	형식 정확성 - 데이터 형식, 데이터 값 범위

[표 III-54] 구문 정확성 검사 항목 구성

4.1.1 구조 정확성

- 검사기준 및 방법

분 류		검사기준 및 방법
검사상세		어노테이션 데이터 구조를 준수하는지 확인
검사대상	산출물	가공데이터
	데이터 종류	텍스트, 이미지, 비디오, 오디오, 3D
	내용	구조
검사방법		- 인공지능 학습용 데이터 구축 시 정의한 데이터 구조에 적합하지 않은 데이터가 있는지 확인 ※ 데이터 구조에 대한 표준화가 필요
계산 방법		$\text{정확도(\%)} = \frac{(\text{전체속성수} - \text{오류건수 구조})}{\text{전체 속성수}} \times 100$ ※ 속성: 요구되는 데이터 필드(컬럼, 속성 등)가 적절하게 포함되어 있는지, 각 필드가 미리 정의된 형식(숫자, 문자열, 날짜 등)을 정확히 따르는지, 그리고 필수 필드의 누락 없이 데이터 구조가 올바르게 구성되어 있는지를 평가하는 요소

[표 III-55] 구조 정확성 검사기준 및 방법

4.1.2 형식 정확성

- 검사기준 및 방법

분 류	검사기준 및 방법
검사상세	어노테이션 데이터를 구성하는 데이터가 형식 및 범위를 준수하는지 확인

분 류		검사기준 및 방법	
검사대상	산출물	• 가공데이터	
	데이터 종류	• 텍스트, 이미지, 비디오, 오디오, 3D	
	내용	• 값	
검사방법		• 인공지능 학습용 데이터 구축 시 정의한 데이터 형식에 적합하지 않은 데이터가 있는지 확인	
		• 세부 검사 내용	
		구분	내용
		데이터 형식	가공데이터의 데이터 값 구문이 정의된 형식 규칙에 부합하는지 확인
		데이터값 범위	가공데이터의 값이 정의된 범위에 부합하는지 확인
		※ 메타데이터에 대한 표준화가 필요	
		※ 텍스트, 오디오는 ETRI 전사 규칙을 준수	
계산 방법		$\text{정확도(\%)} = \frac{(\text{전체속성수}-\text{오류건수 형식})}{\text{전체 속성수}} \times 100$	
		※ 속성: 특정 데이터 필드 또는 요소가 요구된 형식(예: 날짜, 숫자, 텍스트 등) 및 데이터 값 범위를 정확히 준수하고 있는지를 평가하는 데이터 형식의 특성	

[표 III-56] 형식 정확성 검사기준 및 방법

※ ETRI 전사 규칙 : 한국전자통신연구원(ETRI)에서 음성 데이터를 텍스트로 변환하는 과정에서 일관성 있고 정확한 결과를 얻기 위해 마련한 규칙 (https://github.com/etri/kmsav/tree/main/trans_guide)

4.2 의미 정확성

- ‘의미 정확성’은 어노테이션 값이 의미적으로 정답(GT)의 일치성, 맥락 적절성, 논리적 타당성을 검사하는 항목으로 데이터 종류, 어노테이션 방식, 그리고 학습 Task에 따라 적절한 측정지표를 정의
- 의미 정확성의 검사 항목은 데이터 종류 및 목적에 따라 적절하게 선정하여 적용

4.2.1 검사 항목

- ‘의미 정확성’에 대한 검사 항목은 데이터의 종류 및 목적에 따라 검사 항목을 적합하게 선정

품질특성	검사 항목 예시
의미 정확성	내용 전달성
	질의 적정성
	바운딩 박스 정확성
	3D모델링 정확성
	분류 정확성
	※ 그 외 검사 항목은 데이터의 유형 및 활용 목적에 따라 적절하게 선정하여 적용

[표 III-57] 의미 정확성 검사 항목 구성

4.2.2.1 내용 전달성

● 검사기준 및 방법

항목명	• 내용 전달성
설명	• 일상적 사용 수준에 맞게 내용 전달 여부, 문법적 오류로 인한 전달성 오류 여부 검사
검사대상	• 가공데이터
검사방법	$\text{정확도} = \frac{\text{검사 대상 중 Pass 총합}}{\text{검사 총 개수}} \times 100$ • 전체 데이터 수: 문장/문단 총 수량 • 오류 데이터 수: 문장/문단 중 문법적 오류가 발견된 문장 또는 해당 언어의 일상적 사용 수준에서 어색한 문장 수량

[표 III-58] 내용 전달성 검사기준 및 방법

4.2.1.2 질의 적정성

● 검사기준 및 방법

항목명	• 질의 적정성
설명	• 주어진 질의 유형에 따라 질의 문장을 얼마나 정확하게 생성하였는지에 대한 검사 • 자연스러운 문장인지 검사 • 문장 중 질의에 대한 문법 오류가 발견되었는지 검사
검사대상	• 가공데이터
검사방법	$\text{정확도} = \frac{\text{평가척도별 평가점수 총합}}{\text{평가척도 수} \times n(\text{Likert 척도 최대 점수})}$ • 리커트(Likert) 척도 정의 예시 - 5점(매우 적합), 4점(적합), 3점(보통), 2점(부적합), 1점(매우 부적합) - 3점(협조적), 2점(중립적), 1점(비협조적) ※ 구축하는 데이터의 특성과 목적에 따라 리커트척도의 범위 구간을 정의하여야 함

[표 III-59] 질의 적정성 검사기준 및 방법

4.2.1.3 바운딩 박스 정확성

● 검사기준 및 방법

항목명	• 바운딩 박스 정확성
설명	• 바운딩 박스가 데이터의 텍스트 요소 및 시각 요소를 정확하게 포함하고 있는지 검사
검사대상	• 가공데이터
검사방법	$F1\text{-점수}(\%) = 2 \times \frac{\text{정밀도} \times \text{재현율}}{\text{정밀도} + \text{재현율}}$

	$\text{정밀도} = \frac{\text{전체 라벨 수} - \text{분류오류} - \text{영역오류} - \text{불필요객체}}{\text{전체 라벨 수}}$ $\text{재현율} = \frac{\text{전체 라벨수} - \text{분류오류} - \text{영역오류} - \text{불필요 객체}}{\text{전체 라벨 수} - \text{불필요 객체} + \text{객체누락}}$ • 데이터 가공한 요소에 대하여 얼마나 정확하게 바운딩 박스 처리를 했는지 검사 • 분류, 영역, 객체 누락, 불필요 객체 등 오류 유형 검사 ※ 측정지표의 경우, 데이터 유형에 따라 적절하게 선정
--	--

[표 III-60] 바운딩 박스 정확성 검사기준 및 방법

4.2.1.4 3D 모델링 정확성

• 검사기준 및 방법

항목명	• 3D 모델링 정확성
설명	• 3D 모델이 실제 물체나 환경을 얼마나 정확하게 재현하고 있는지를 평가하는 지표
검사대상	• 가공데이터
검사방법	$\text{정확도} = \frac{(\text{전체 데이터 수} - \text{오류 데이터 수})}{\text{전체 데이터 수}} \times 100$ • 3D 자세, 노멀 방향, 메쉬, 텍스처 등을 검사 • 오류 데이터 수 : 다음 중 한 요소라도 충족하지 않는 3D 모델링 데이터 수 - 3차원 자세가 정확해야 함 - 노멀 방향이 정확해야 함 - 메쉬 내 홀이 존재하지 않아야 함 - 메쉬와 텍스처가 존재해야 함 • 전체 데이터 수 : 3D 모델링 데이터 전체 수 ※ 측정지표의 경우, 데이터 유형에 따라 적절하게 선정

[표 III-61] 3D 모델링 정확성 검사기준 및 방법

4.2.1.5 분류 정확성

• 검사기준 및 방법

항목명	• 분류 정확성
설명	• 데이터(텍스트, 이미지, 영상 등)에 대해 클래스(Label)를 분류를 평가하는 지표
검사대상	• 가공데이터
검사방법	$\text{정확도(\%)} = 1 - \frac{\text{오류 데이터 수}}{\text{전체 데이터 수}} \times 100$ • 오류 데이터 수 : 분류가 잘못된 데이터 수 • 전체 데이터 수 : 전체 데이터 수 ※ 측정지표의 경우, 데이터 유형에 따라 적절하게 선정

[표 III-62] 분류정확성 검사기준 및 방법

4.2.2 측정지표

- ‘유효성’과 측정지표 명은 동일하지만, ‘의미 정확성’은 어노테이션 값과 참값(GT) 간의 차이를 측정하고, ‘유효성’은 학습모델의 예측값과 정답(GT) 간의 차이를 측정함
- 대표적인 측정지표는 아래와 같음

품질특성	측정지표	설명
의미 정확성	정확도 (Accuracy)	어노테이션과 참값 간의 중첩률을 확인
	정밀도 (Precision)	생성된 어노테이션 중 참값 어노테이션 비율을 확인
	재현율 (Recall)	모든 가능한 어노테이션 중 참값 어노테이션 비율을 확인
	$F\beta$ -점수 (F-beta Score)	어노테이션 값의 정밀도와 재현율 간 균형을 나타내는 비율
	EM (Exact Matching)	어노테이션 값이 참값(GT)과 완전히 일치하는 비율
	ROUGE-L (Recall-Oriented Understudy for Gisting Evaluation - Longest Common Subsequence)	어노테이션 값이 텍스트 요약에서 참값(GT)과 의미적으로 유사한 비율
	BLEU (Bilingual Evaluation Understudy)	어노테이션 값이 기계 번역에서 참값(GT)과 의미적으로 유사한 비율
	IoU (Intersection over Union)	어노테이션 값의 바운딩 박스가 참값(GT)과 겹치는 비율
	OKS (Object Keypoint Similarity)	어노테이션 값의 객체 키포인트가 참값(GT)과 유사한 비율
	MOTA (Multiple Object Tracking Accuracy)	여러 객체의 트래킹 어노테이션 값이 참값(GT)과 일치하는 비율
	PCK (Percentage of Correct Keypoints)	어노테이션 값의 객체 키포인트가 참값(GT)과 일정 거리 이내에 존재하는 비율
	DPC (Diversity-Preservation Coefficient)	어노테이션 값이 다양한 의미적 패턴을 포함하는 비율
	JSD (Jensen-Shannon Divergence)	어노테이션 값의 의미적 분포가 참값(GT)의 분포와 얼마나 유사한지 측정
	pMSE (probabilistic Mean Squared Error)	어노테이션 값의 확률적 오차가 참값(GT)과 얼마나 차이가 나는지 평가
	적합성 (Relevance)	어노테이션 값이 참값(GT)의 맥락과 의미적으로 적절한지 평가
	리커트 척도 (Likert Scale)	어노테이션 값에 대해 응답자의 주관적 평가를 점수화하여 측정

[표 III-63] 의미 정확성 대표적인 측정지표

- 정확도, 재현율, 정밀도를 제외한 나머지 지표는 ‘5.2 유효성’의 측정지표 참고

4.2.2.1 정확도

● 검사기준 및 방법

분 류		검사기준 및 방법	
검사상세		• 어노테이션과 참값 간의 중첩률을 확인	
검사대상	산출물	• 가공데이터	
	데이터 종류	데이터 종류	어노테이션 예시
		텍스트	내용 요약, 번역, 질의응답
		이미지/비디오	바운딩 박스, 키폰트, 세그멘테이션
		3D	세그멘테이션, 키폰트, 큐보이드, 태깅
		오디오	전사
내용	• 값		
검사방법		• 데이터 종류의 분류를 참조하여 데이터 종류별에 해당하는 어노테이션과 참값 간의 중첩률을 계산하여 의미 정확성의 정확도를 확인	

[표 III-64] 정확도 검사기준 및 방법

4.2.2.2 정밀도

● 검사기준 및 방법

분 류		검사기준 및 방법	
검사상세		• 생성된 어노테이션 중 참값 어노테이션 비율을 확인	
검사대상	산출물	• 가공데이터	
	데이터 종류	데이터 종류	어노테이션 예시
		텍스트	말뭉치 태깅
		이미지/비디오/센서	바운딩 박스, 키폰트, 세그멘테이션
		3D	큐보이드
	내용	• 값	
검사방법		• 데이터 종류의 분류를 참조하여 데이터 종류별로 생성된 어노테이션 중 참값 어노테이션 비율을 계산하여 의미 정확성의 정밀도를 확인	

[표 III-65] 정밀도 검사기준 및 방법

4.2.2.3 재현율

- 검사기준 및 방법

분 류		검사기준 및 방법	
검사상세		• 모든 가능한 어노테이션 중 참값 어노테이션 비율을 확인	
검사대상	산출물	• 가공데이터	
	데이터 종류	데이터 종류	어노테이션 예시
		텍스트	말뭉치 태깅
		이미지/비디오/센서	바운딩 박스, 키포인트, 세그멘테이션
		3D	큐보이드
	내용	• 값	
검사방법		• 데이터 종류의 분류를 참조하여 데이터 종류별로 모든 가능한 어노테이션 중 참값 어노테이션 비율을 계산하여 의미 정확성의 재현율을 확인	

[표 III-66] 재현율 검사기준 및 방법

5

학습모델 적합성 품질관리 지표

5.1 알고리즘 적정성

- ‘알고리즘 적정성’에 대한 검사 항목은 데이터 유형 별로 구성되며, 각각의 데이터 유형별 관련 알고리즘을 임무(Task)별로 구분하여 ‘알고리즘 적정성’을 평가
- 각 Task 측정지표는 ‘5.2 유효성’에서 설명하며, 본 장에서는 각각의 Task에 대한 개념을 제시하고, 제시되는 Task는 업무의 성격에 따라 ‘언어지능’ 및 ‘시각지능’으로 최상위층이 구분되며, 각각은 [이해/생성], [인지/생성]으로 좀 더 세분화될 수 있음
- 다만, 본 『제1권. AI 데이터 품질관리 가이드라인』에서 제시하는 Task는, 한국지능정보사회진흥원에서 공모하는 ‘인공지능 학습용 데이터 구축사업’의 구축사례들을 기반으로 널리 활용되는 Task 분야를 정리한 것으로 데이터 유형별 Task의 종류는 제시하는 것 외에도 매우 다양하므로, 데이터 구축 목적에 따라 별도의 Task를 정의해야 함

5.1.1 언어 이해

알고리즘 Task 분야		데이터 유형				
한글명	영문명	텍스트	이미지	비디오	오디오	3D
광학 문자 인식	Optical Character Recognition	●	●			
순차적 레이블링	Sequence Labeling	●				
텍스트 분류	Text Classification	●			○	
정보 추출	Information Extraction	●			○	
질의응답	Question Answering	●			○	
음성 인식	Speech Recognition	●			●	
오디오 분류	Audio Classification	●	●		●	
텍스트 추천	Text Extraction	●			○	
텍스트 예측	Text Prediction	●			○	
음성 분리	Speech Separation	●			●	
관계 추출	Relation Extraction	●			○	

※ 검은색 표기(●)는 학습모델에 직접적으로 적용되는 데이터 유형을 표시함

※ 하얀색 표기(○)는 원시데이터에서 정제 작업을 거친 후 학습모델에 적용되는 데이터 유형을 표시함

[표 III-67] 언어 이해 Task별 데이터 유형 구성

5.1.1.1 광학 문자 인식 (OCR, Optical Character Recognition)

구분	내 용
개념	사람이 쓰거나 기계로 인쇄한 문자의 영상을 이미지 스캐너로 획득하여 기계가 읽을 수 있는 문자로 변환하는 작업
세부 내용	기존의 정형화된 숫자나 텍스트 인식에서 벗어나, 인공지능 기술이 접목되어 필기체, 이미지, 비정형데이터까지 인식 범위를 넓히고 있음

[표 III-68] 광학 문자 인식의 개념 및 세부 내용

5.1.1.2 순차적 레이블링 (Sequence Labeling)

구분	내 용
개념	입력 시퀀스에 대하여 레이블 시퀀스를 각각 부여하는 작업으로, 태깅 작업이 대표적인 순차적 레이블링의 예시임
세부 내용	태깅을 해야 하는 단어 데이터를 X, 레이블에 해당되는 태깅 정보 데이터는 y라고 할 때, X와 y데이터의 쌍(pair)은 병렬 구조를 가지며, 각 데이터는 정수 인코딩 과정을 거친 후, 모든 데이터의 길이를 동일하게 맞춰주기 위한 패딩(Padding) 작업을 거쳐 학습용 데이터로 구축됨

[표 III-69] 순차적 레이블링의 개념 및 세부 내용

5.1.1.3 텍스트 분류 (Text Classification)

구분	내 용
개념	문장이나 문서를 적절한 범주로 지정하는 작업으로, 범주는 선택한 데이터셋에 따라 다르며 주제 범위가 다양할 수 있음
세부 내용	- 텍스트 분류 문제에는 감정 분류, 뉴스 분류, 인용 의도 분류 등이 있으며, 텍스트 분류 기능을 평가하기 위한 벤치마크 데이터셋에는 GLUE, AGNews 등이 있음 - 최근 몇 년 동안 XLNet 및 RoBERTa와 같은 딥러닝 기술은 텍스트 분류 문제에서 가장 큰 성능 향상을 달성함

[표 III-70] 텍스트 분류의 개념 및 세부 내용

5.1.1.4 정보 추출 (Information Extraction)

구분	내 용
개념	자연어에서 유용한 정보를 자동으로 수집하기 위해 비정형화된 텍스트 데이터 내에서 정형화된 데이터를 추출하는 작업
세부 내용	고유 명사 등을 판별하는 개체명 인식(Named Entity Recognition), 개체명 간의 관계를 판별하는 관계 추출(Relation Extraction), 중의성 해소(Word sense Disambiguation), 대표 단어/문장 추출 등이 가장 대표적인 정보 추출 문제이며, MRC(Machine Reading & Comprehension)의 기반이 되는 작업이라 할 수 있음

[표 III-71] 정보 추출의 개념 및 세부 내용

5.1.1.5 질의응답 (Question Answering)

구분	내 용
개념	질문(일반적으로 독해 질문)에 답변하는 작업으로서, 제공된 컨텍스트를 기반으로 답변할 수 없는 질문이 제시되면 기권함
세부 내용	- 질의응답은 커뮤니티 질문 답변 및 지식 기반 질문 답변과 같은 도메인별 작업으로 나눌 수 있음 - 평가 질문 응답 시스템을 위한 인기 있는 벤치마크 데이터셋에는 SQuAD, HotPotQA, bAbI, TriviaQA, WikiQA 등이 있으며, 질문 답변 모델은 일반적으로 EM 및 F1과 같은 성능지표로 평가함 - 최근 질의응답 분야 최고 성능 모델은 T5 및 XLNet 등이 있음

[표 III-72] 질의응답의 개념 및 세부 내용

5.1.1.6 음성 인식 (Speech Recognition)

구분	내 용
개념	사람이 말하는 음성 언어를 인공지능이 해석해 그 내용을 문자 데이터로 전환하는 작업
세부 내용	일반적으로 STT(Speech to Text)와 동일한 Task로 인식되며, Speaker Verification이나 Speaker Recognition과 같이 개별 사용자의 음성을 식별하는 데에 중점을 둔 Task도 존재함

[표 III-73] 음성 인식의 개념 및 세부 내용

5.1.1.7 오디오 분류 (Audio Classification)

구분	내 용
개념	오디오 정보를 특정 시간 단위로 분할(오디오 클립)하여, 신호의 특이점을 분석하고 특정 클래스로 분류하는 작업
세부 내용	- 소리는 음성과 음향으로 구분이 되며, 일반적으로 오디오 분류(Audio Classification)라고 정의할 때는 음향에 대한 분류를 의미함 - 오디오 분류 작업은 주석이 달린 오디오 데이터로 시작하며, 기계는 어떻게 듣고 무엇을 들어야 하는지 배우기 위해 이 데이터가 필요함 - 구글 오디오셋이 오디오 분류의 대표적인 데이터셋임

[표 III-74] 오디오 분류의 개념 및 세부 내용

5.1.1.8 텍스트 추천 (Text Extraction)

구분	내 용
개념	텍스트를 기반으로 어떤 조건에 적합한 대상을 추천하는 작업
세부 내용	- 텍스트 데이터를 분석하여 유사한 주제나 관심사를 추천하고, 감정 분석을 통해 사용자의 선호도나 취향을 파악하여 추천 - 텍스트 데이터에서 키워드나 태그를 추출하여 해당 키워드나 태그와 관련된 대상을 추천 기능으로 사용

[표 III-75] 텍스트 추천의 개념 및 세부 내용

5.1.1.9 텍스트 예측 (Text Prediction)

구분	내 용
개념	• 텍스트에 대한 미래에 특정한 내용을 예측하여 제공하는 작업
세부 내용	• 텍스트 자동 완성 기능은 사용자가 입력하는 동안 다음 단어를 예측하여 입력을 보완하고 자동 제공하는 기능으로 사용 • 기계 번역에서는 주어진 문장을 예측하여 다른 언어로 번역 수행

[표 III-76] 텍스트 예측의 개념 및 세부 내용

5.1.2 언어 생성

알고리즘 Task 분야		데이터 유형				
한글명	영문명	텍스트	이미지	비디오	오디오	3D
텍스트 요약	Text Summary	●			○	
텍스트 생성	Text Generation	●				
기계 번역	Machine Translation	●			○	
음성 합성	Speech Synthesis	●			●	
텍스트 교정	Text Reconstruction	●				

※ 검은색 표기(●)는 학습모델에 직접적으로 적용되는 데이터 유형을 표시함

※ 하얀색 표기(○)는 원시데이터에서 정제 작업을 거친 후 학습모델에 적용되는 데이터 유형을 표시함

[표 III-77] 언어 생성 Task별 데이터 유형 구성

5.1.2.1 텍스트 요약 (Text Summary)

구분	내 용
개념	• 상대적으로 큰 원문을 핵심 내용만 간추려서 상대적으로 작은 요약문으로 변환하는 작업
세부 내용	• 원문에서 중요한 핵심 문장 또는 단어구를 뽑아 이들로 구성하는 ‘추출적 요약(Extractive Summarization)’과 원문에 없던 문장이라도 핵심 문맥을 반영하여 새로운 문장을 생성해서 요약하는 ‘추상적 요약(Abstractive Summarization)’으로 구분됨

[표 III-78] 텍스트 요약의 개념 및 세부 내용

5.1.2.2 텍스트 생성 (Text Generation)

구분	내 용
개념	• 기계학습을 이용하여 문장을 생성하는 작업
세부 내용	• LSTM(Long Short Term Memory)/RNN(Recurrent Neural Network) 나 Softmax 알고리즘을 적용하여, 인간이 문장을 만드는 과정을 최대한 구현하는 방향으로 Language Modeling이 발전하고 있음

[표 III-79] 텍스트 생성의 개념 및 세부 내용

5.1.2.3 기계 번역 (Machine Translation)

구분	내 용
개념	인공지능을 이용해 인간이 사용하는 자연어를 다른 자연어로 번역하는 작업
세부 내용	- 자동 번역이라고도 부르며, 구글 번역, 네이버 파파고, SYSTRAN, 바벨피시, 빙 번역기 등 다양한 기계 번역기가 존재함 - 최근에는 기계 번역이 스스로 학습하여 자신의 정확도를 향상하는 역 번역(Back Translation)과 디노이징(Denoising) 같은 기술을 적용하여 발전하고 있음

[표 III-80] 기계 번역의 개념 및 세부 내용

5.1.2.4 음성 합성 (Speech Synthesis)

구분	내 용
개념	텍스트나 입술 움직임과 같이 다른 매체 정보로부터 음성을 생성하는 작업
세부 내용	- 음성 인식에 대응하는 음성 합성은 주로 텍스트 정보를 오디오 정보로 변환하는데 사용되며 음성 지원 서비스 및 모바일 응용 프로그램과 같은 응용 프로그램에서 사용됨 - 이 외에도 시각장애인이 텍스트 콘텐츠를 읽을 수 있도록 돕는 보조 기술에도 사용될 수 있음

[표 III-81] 음성 합성의 개념 및 세부 내용

5.1.2.5 텍스트 교정 (Text Reconstruction)

구분	내 용
개념	텍스트가 틀어지거나 잘못된 것을 교정하는 작업
세부 내용	- 문장이나 단어의 맞춤법, 문법, 구문 등을 검사하고 수정하여 텍스트의 품질을 향상시키고, 커뮤니케이션에서 오류를 줄여주는 기능으로 활용 - 사용자가 작성한 텍스트를 자동으로 검사하여 오류를 찾고 수정하여 제공

[표 III-82] 텍스트 교정의 개념 및 세부 내용

5.1.2.6 음성 분리 (Speech Separation)

구분	내 용
개념	다중 음성 신호에서 개별 발화자의 음성 분리
세부 내용	- 음성분리는 배경잡음, 다른 발화자의 목소리 등이 혼합된 환경에서 특정 발화자의 음성을 식별하고 분리 - 신호 처리 및 기계 학습 방법을 사용하여 복잡한 음향 환경에서 유용하며, 음성 인식, 보청기, 통신 시스템 등에 응용

[표 III-83] 음성 분리의 개념 및 세부 내용

5.1.2.7 관계 추출 (Relation Extraction)

구분	내 용
개념	텍스트에서 엔티티 간의 의미있는 관계를 식별하고 추출
세부 내용	- 주로 자연어 처리 분야에서 사용되며, 텍스트 내의 엔티티(예: 사람, 장소, 기관) 간의 관계를 파악 - 정보 검색, 지식 그래프 구축, 텍스트 마이닝 등에 활용되며, 데이터베이스에 구조화된 형태로 정보를 저장하는데 용이

[표 III-84] 관계 추출의 개념 및 세부 내용

5.1.3 시각 인지

알고리즘 Task 분야		데이터 유형				
한글명	영문명	텍스트	이미지	비디오	오디오	3D
이미지 분류	Image Classification		●	○		
3D 포인트 클라우드 분류	3D Point Cloud Detection					●
객체 인식	Object Detection		●	○		
3D 객체 인식	3D Object Detection		○	○		●
얼굴 인식	Face Recognition		●			
키포인트 검출	Keypoint Detection		●	○		
3D 키포인트 검출	3D Keypoint Detection					○
행동 인식	Action Recognition		●	○		
자세 추정	Pose Estimation		●	○		
3D 자세 추정	3D Pose Estimation					○
비디오 분류	Video Classification			●		
3D 객체 분류	3D Object Classification					○
비디오 인식	Video Recognition			●		
시멘틱 세그멘테이션	Semantic Segmentation		●	●		
인스턴스 세그멘테이션	Instance Segmentation		●	●		
3D 시멘틱 세그멘테이션	3D Semantic Segmentation			●		
이미지 캡셔닝	Image Captioning		●	●		
재인식	Re-Identification		●	○		

※ 검은색 표기(●)는 학습모델에 직접적으로 적용되는 데이터 유형을 표시함

※ 하얀색 표기(○)는 원시데이터에서 정제 작업을 거친 후 학습모델에 적용되는 데이터 유형을 표시함

[표 III-85] 시각 인지 Task별 데이터 유형 구성

5.1.3.1 이미지 분류 (Image Classification)

구분	내 용
개념	특정 이미지를 알고리즘에 입력했을 때, 그 이미지가 어떤 클래스에 속하는지 알려주는 작업
세부 내용	단순히 객체의 큰 범위만 분류하는 것이 아닌, 해당 속성이나 상세한 클래스까지 분류해내는 경우 이미지 인식 또는 객체 인식이라고 할 수 있음

[표 III-86] 이미지 분류의 개념 및 세부내용

5.1.3.2 3D 포인트 클라우드 분류 (3D Point Cloud Classification)

구분	내 용
개념	특정 포인트 클라우드를 알고리즘에 입력했을 때, 그 포인트 클라우드가 어떤 클래스에 속하는지 알려주는 작업
세부 내용	단순히 객체의 큰 범위만 분류하는 것이 아닌, 해당 속성이나 상세한 클래스까지 분류해내는 경우 3D 객체 인식이라고 할 수 있음

[표 III-87] 3D 포인트 클라우드 분류의 개념 및 세부내용

5.1.3.3 객체 인식 (Object Detection)

구분	내 용
개념	이미지 내에서 특정 클래스의 객체 인스턴스를 인식하는 작업
세부 내용	- 객체인식을 위한 방법은 1단계 방법과 2단계 방법의 두 가지 주요 유형으로 분류할 수 있음 1단계 방법은 추론 속도를 우선시하며, 대표적인 모델로는 YOLO, SSD, RetinaNet이 있음 2단계 방법은 탐지 정확도를 우선시하며, 대표적인 모델로는 Faster R-CNN, Mask R-CNN, Cascade R-CNN이 있음 - 객체 인식 작업과 관련된 가장 인기 있는 데이터셋은 MSCOCO이며, 모델은 일반적으로 평균 정밀도 평가모델에 따라 평가됨

[표 III-88] 객체 인식의 개념 및 세부내용

5.1.3.4 3D 객체 인식 (3D Object Detection)

구분	내 용
개념	3D 영상/이미지 내에서 특정 클래스의 객체 인스턴스를 감지하는 작업
세부 내용	3D 객체 인식은 일반적인 객체 인식과 유사하지만, 입력값으로 RGB 이미지와 함께 depth 값을 받아서 학습하고, 추론 시에는 RGB 이미지만을 입력으로 받아 depth 값을 추정하는 것이 중요한 차이라고 할 수 있음 - 객체 인식 분야를 3차원 객체 인식으로 범위를 확장하면, 물체의 크기, 위치, 방향 등을 알 수 있으므로 자율주행 및 이미지 검색, 증강 현실에서 다양한 분야에 응용 가능함

[표 III-89] 3D 객체 인식의 개념 및 세부내용

5.1.3.5 얼굴 인식 (Face Recognition)

구분	내 용
개념	얼굴을 사용하여 개인의 신원을 식별하거나 확인하는 작업
세부 내용	- 얼굴 인식 시스템은 사진, 비디오 또는 실시간으로 사람을 식별하는 데 사용할 수 있음 - 안면 인식은 생체 인식 보안의 범주로서, 다른 형태의 생체 인식 소프트웨어에는 음성 인식, 지문 인식, 눈 망막 또는 홍채 인식 등이 있음 - 얼굴인식Task는 Face Verification과 Face Identification과 같이 세부적인Task로 구체화됨

[표 III-90] 얼굴 인식의 개념 및 세부내용

5.1.3.6 키포인트 검출 (Keypoint Detection)

구분	내 용
개념	• 동작 인식을 위해 필요한 주요 키포인트를 검출하는 작업
세부 내용	• 키포인트는 관심 포인트라고도 하며, 이미지에서 흥미롭거나 눈에 띄는 것을 정의하는 공간적 위치 또는 이미지의 포인트를 지칭함 • 특징으로는, 이미지 회전, 축소, 변환, 왜곡 등에 대해 변하지 않음 • 얼굴을 대상으로 할 때는 Facial Landmark Detection, 신체를 대상으로 할 때는 Pose Estimation이라는 Task로 좀 더 구체화 됨

[표 III-91] 키포인트 검출의 개념 및 세부내용

5.1.3.7 3D 키포인트 검출 (3D Keypoint Detection)

구분	내 용
개념	• 3D 데이터에서 동작 인식을 위해 필요한 주요 키포인트를 검출하는 작업
세부 내용	• 키포인트는 관심 포인트라고도 하며, 3D 데이터에서 흥미롭거나 눈에 띄는 것을 정의하는 공간적 위치 포인트를 지칭함 • 특징으로는, 3D 데이터 회전, 축소, 변환, 왜곡 등에 대해 변하지 않음

[표 III-92] 3D 키포인트 검출의 개념 및 세부 내용

5.1.3.8 행동 인식 (Action Recognition)

구분	내 용
개념	• 비디오 데이터 스트림에서 객체 행동의 감지 및 인식을 하는 작업
세부 내용	• 실시간 CCTV 비디오 데이터 스트림에서 객체 행동의 감지 및 인식은, 잠재적으로 위험한 시나리오의 이상 감지를 위해 활용될 수 있음 • 최첨단 딥러닝 기술과 '경로 서명'을 결합하여 객체 행동을 해석하기 위한 일반화된 프레임워크를 개발하며, 문제를 효율적이고 효과적으로 해결하는 것을 목표로 함

[표 III-93] 행동 인식의 개념 및 세부 내용

5.1.3.9 자세 추정 (Pose Estimation)

구분	내 용
개념	• 객체와 객체의 주요 부분에 대한 위치, 방향을 식별하여 클래스를 분류하는 작업
세부 내용	• 기술적으로 키포인트 검출(Keypoint Detection)이나 행동 인식(Action Recognition) Task와 유사한 문제로 정의됨 • 게임, 의료, AR 및 스포츠를 포함한 광범위한 분야에서 응용 프로그램을 찾는 확장성으로 인해 많은 연구가 진행되고 있음

[표 III-94] 자세 추정의 개념 및 세부 내용

5.1.3.10 3D 자세 추정 (3D Pose Estimation)

구분	내 용
개념	3D 데이터에서 객체와 객체의 주요 부분에 대한 위치, 방향을 식별하여 클래스를 분류하는 작업
세부 내용	- 기술적으로 3D 키포인트 검출(3D Keypoint Detection) Task와 유사한 문제로 정의됨 - 게임, 의료, AR 및 스포츠를 포함한 광범위한 분야에서 응용 프로그램을 찾는 확장성으로 인해 많은 연구가 진행되고 있음

[표 III-95] 3D 자세 추정의 개념 및 세부 내용

5.1.3.11 비디오 분류 (Video Classification)

구분	내 용
개념	프레임이 주어진 비디오에서 특정 프레임 구간을 선택하고 클래스 레이블을 부여하는 작업
세부 내용	- 좋은 비디오 레벨 분류기는 정확한 프레임 레이블을 제공할 뿐만 아니라 비디오에 있는 다양한 프레임의 기능과 주석을 고려하여 전체 비디오를 설명할 수 있음 - 프레임과 비디오를 설명하는 데 필요한 레이블의 세분성은 작업에 따라 다르며, 일반적인 작업에는 비디오에 하나 이상의 전역 레이블을 할당하고 비디오 내부의 각 프레임에 하나 이상의 레이블을 할당하는 것이 포함됨

[표 III-96] 비디오 분류의 개념 및 세부 내용

5.1.3.12 3D 객체 분류 (3D Object Classification)

구분	내 용
개념	3D 이미지/영상 데이터를 알고리즘에 입력했을 때, 그 3D 이미지/영상이 어떤 클래스에 속하는지 알려주는 작업
세부 내용	단순히 객체의 큰 범위만 분류하는 것이 아닌, 해당 속성이나 상세한 클래스까지 분류해내는 경우 3D 객체 인식이라고 할 수 있음

[표 III-97] 3D 객체 분류의 개념 및 세부 내용

5.1.3.13 비디오 인식 (Video Recognition)

구분	내 용
개념	비디오를 활용하여 실시간 객체 식별 및 비디오 프레임을 분류하는 작업
세부 내용	- 컴퓨터는 수천 개의 비디오 스트림을 보고 프레임 단위로 수신하는 정보를 이해하는 과정을 거치며, Tracking 하는 업무로 정의될 수 있음 - 카메라를 사용하여 시간이 지남에 따라 움직이는 물체를 찾아 연속적인 비디오 프레임에서 대상 물체를 연결하는 것으로 구성됨

[표 III-98] 비디오 인식의 개념 및 세부 내용

5.1.3.14 시멘틱 세그멘테이션 (Semantic Segmentation)

구분	내 용
개념	동일한 객체 클래스에 속하는 이미지 부분을 함께 클러스터링하는 작업
세부 내용	- 이미지의 모든 픽셀에 클래스를 부여하는 가공 방법 - 물체, 배경 등을 의미적으로 분할하여 자율주행, 의료 영상 분석 기술 개발 등에 사용

[표 III-99] 시멘틱 세그멘테이션의 개념 및 세부 내용

5.1.3.15 인스턴스 세그멘테이션 (Instance Segmentation)

구분	내 용
개념	개체의 감지된 각 인스턴스에 대한 분할 맵을 생성하는 향상된 유형의 세그멘테이션 분할 작업
세부 내용	- 이미지의 모든 픽셀이 같은 클래스여도 다른 인스턴스를 부여하는 가공 방법 - 객체 인식 시 중첩된 경우 분할하는 기술개발 등에 사용

[표 III-100] 인스턴스 세그멘테이션의 개념 및 세부 내용

5.1.3.16 3D 시멘틱 세그멘테이션 (3D Semantic Segmentation)

구분	내 용
개념	실제 객체를 나타내는 포인트 클라우드의 입력을 받아 객체를 다른 부분으로 분할하는 작업
세부 내용	3차원 공간에서 객체를 식별하고 분할하는 작업 - 자율주행 자동차에서는 도로, 보행자, 차량 등의 객체를 식별하여 사용 - 의료 분야에서는 CT 스캔이나 MRI 영상에서 조직이나 종양 등을 식별하여 진단 등에 사용

[표 III-101] 3D 시멘틱 세그멘테이션의 개념 및 세부 내용

5.1.3.17 이미지 캡셔닝 (Image Captioning)

구분	내 용
개념	이미지를 캡처하여 이미지에 대한 의미나 특징을 식별하는 작업
세부 내용	- 이미지에서 객체의 경계를 식별하기 위해 시멘틱 세그멘테이션(Semantic Segmentation) 기술을 사용 - 이미지에 대한 자연어 처리 기술을 적용하여 이미지의 의미를 수행

[표 III-102] 이미지 캡셔닝의 개념 및 세부 내용

5.1.3.18 재인식 (Re-Identification)

구분	내 용
개념	이전에 관찰되었던 개체를 다른 시간이나 장소에서 다시 인식하는 과정
세부 내용	- 보안 및 감시 시스템에서 중요하며, 비디오 감시에서 특정 인물이나 물체를 여러 카메라 간에 추적하는 데 사용 - 얼굴 인식, 차량 번호판 인식, 인물 추적 등 다양한 형태로 응용되며, 고유한 특징을 기반으로 개체를 식별

[표 III-103] 재인식의 개념 및 세부 내용

5.1.4 시각 생성

알고리즘 Task 분야		데이터 유형				
한글명	영문명	텍스트	이미지	비디오	오디오	3D
이미지 생성	Image Generation		●			
이미지 합성	Image Synthesis		●			
3D 객체 복원	3D Object Reconstruction		○	○		○
2D 이미지를 통한 시점 합성	2D View Synthetic		○			○
해상도 개선	Super Resolution		●	○		

※ 검은색 표기(●)는 학습모델에 직접적으로 적용되는 데이터 유형을 표시함

※ 하얀색 표기(○)는 원시데이터에서 정제 작업을 거친 후 학습모델에 적용되는 데이터 유형을 표시함

[표 III-104] 시각 생성 Task별 데이터 유형 구성

5.1.4.1 이미지 생성 (Image Generation)

구분	내 용
개념	인공지능이 다양한 노이즈(Noise) 입력을 받아, 원하는 카테고리 내 새로운 이미지를 생성하는 작업
세부 내용	GAN 기술을 이용하여 이미지 정보들의 변환과 재구축으로 진짜처럼 보이는 가짜 이미지 형성이 가능함

[표 III-105] 이미지 생성의 개념 및 세부내용

5.1.4.2 이미지 합성 (Image Synthesis)

구분	내 용
개념	인공지능이 이미지나 비디오를 입력받아, 다른 형태나 정보를 지닌 이미지 또는 비디오로 변환하는 작업
세부 내용	GAN 기술을 이용하여 적은 양의 정보로 원본 이미지를 예측하거나, 사진을 특정한 방식의 이미지로 전환하는 것이 가능함

[표 III-106] 이미지 합성의 개념 및 세부내용

5.1.4.3 3D 객체 복원 (3D Object Reconstruction)

구분	내 용
개념	인공지능이 영상/이미지/포인트 클라우드로부터 객체(물체, 사람 등)의 3차원 구조를 복원(reconstruction)하는 작업
세부 내용	3D GAN 기술을 이용하여 영상/이미지/포인트 클라우드 정보들의 변환과 재구축으로, 실제 객체와 기하학적인 정확도뿐만 아니라 현실감이나 사실성 측면에서 매우 유사한 객체 형성이 가능함

[표 III-107] 3D 객체 복원의 개념 및 세부내용

5.1.4.4 2D 이미지를 통한 시점 합성(View Synthetic)

구분	내 용
개념	인공지능을 활용하여 이미지를 인공적으로 3D로 전환하는 작업
세부 내용	서로 다른 시점을 가진 여러 개의 카메라들을 이용하여 객체를 촬영한 뒤, 촬영된 영상들과 각 카메라들의 촬영 정보들을 이용하여 해당 객체에 대한 3차원 정보를 추정

[표 III-108] 2D 이미지 합성의 개념 및 세부내용

5.1.4.5 해상도 개선(Super Resolution)

구분	내 용
개념	저해상도 이미지 또는 동영상을 고해상도로 변환하는 기술
세부 내용	- 이미지 처리 및 컴퓨터 비전 분야에서 중요한 역할을 하며, 이미지의 세부 사항과 품질을 향상시키는 데 사용 - 저해상도의 입력 이미지에서 더 높은 픽셀 밀도를 갖는 이미지를 생성하여, 선명도와 디테일을 개선

[표 III-109] 해상도 개선의 개념 및 세부내용

5.2 유효성

- ‘유효성’의 검사 항목은 알고리즘 Task 별로 구성되며, 각 Task에 따른 유효성 측정지표를 사용함
- 본 장에서는 각 Task별 유효성 측정지표를 데이터 유형*에 따라 제시함
 - * ‘이미지 데이터’, ‘비디오 데이터’, ‘오디오 데이터’, ‘텍스트 데이터’, ‘3D 데이터’, ‘센서 데이터’
- 다만, 본 『제1권 AI 데이터 품질관리 가이드라인』에서 제시하는 유효성 측정지표는 한국지능정보사회진흥원에서 공모하는 ‘초거대AI 확산 생태계 조성사업’의 데이터 구축사례들을 기반으로 자주 활용되는 측정지표를 정리한 것으로, 제시하는 것 이외에도 매우 다양하므로 데이터 구축목적에 따라 적절한 측정지표 및 목표를 정의하는 것이 중요함


〈유효성 목표 설정 원칙〉

- 최신의 논문, 기고서, 공식 블로그 등에서 공식 보고된 값을 참고하여 유효성 목표치 기준 수립
 - 해당 구축사업과 가장 유사한 주제의 SoTA(State of The Art) 자료(논문, 기고서 등)에서 공식 보고되는 값을 기준으로 유효성 목표치를 설정하는 것이 원칙
 - 해당 구축사업의 이해관계자 간에 목표치에 대해 논의할 때, 반드시 상기 자료를 근거로 하고 출처를 명확히 제시
 - 다만, 선행연구 분야에 해당하는 임무이기 때문에 SoTA의 해당 자료를 참고하기 힘든 경우 이해관계자 및 해당 임무·도메인 관련 전문가 의견을 반영하여 설정

[표 III-110] 유효성 목표 설정 원칙

5.2.1 유효성 측정지표

5.2.1.1 Accuracy (정확도)

구분	내 용													
개념	알고리즘이 데이터 포인트를 올바르게 분류하는 빈도를 측정하는 평가지표													
세부 내용	- 기계 학습 분류 알고리즘의 정확도는 알고리즘이 데이터 포인트를 올바르게 분류하는 빈도를 측정하는 한 가지 방법으로, 정확도는 모든 데이터 포인트 중에서 올바르게 예측된 데이터 포인트의 수라고 할 수 있음 - 정확도는 다양한 비율의 참/거짓 양성/음성을 사용하는 다른 품질지표인 정밀도 및 재현율과 함께 사용되기도 함 													
계산식(방식)	<table><tr><th colspan="2" rowspan="2"></th><th colspan="2">Predicted Condition</th></tr><tr><th>Positive (PP)</th><th>Negative (PN)</th></tr><tr><th rowspan="2">Actual Condition</th><th>Positive (P)</th><td>True Positive (TP)</td><td>False Negative (FN)</td></tr><tr><th>Negative (N)</th><td>False Positive (FP)</td><td>True Negative (TN)</td></tr></table> Accuracy = $\frac{TP + TN}{TP + TN + FP + FN}$			Predicted Condition		Positive (PP)	Negative (PN)	Actual Condition	Positive (P)	True Positive (TP)	False Negative (FN)	Negative (N)	False Positive (FP)	True Negative (TN)
				Predicted Condition										
		Positive (PP)	Negative (PN)											
Actual Condition	Positive (P)	True Positive (TP)	False Negative (FN)											
	Negative (N)	False Positive (FP)	True Negative (TN)											
관련 출처	“Accuracy(error rate)”. DeepAI, https://deepai.org/machine-learning-glossary-and-terms/accuracy-error-rate , 2025년 11월 14일 접속													

[표 III-111] Accuracy의 개념 및 세부내용

5.2.1.2 OA (Overall Accuracy)

구분	내 용													
개념	• 각각의 객체에 대한 검출 정확도 총합으로서 표현되는 품질지표													
세부 내용	• Overall Accuracy(OA)는 기본적으로 모든 객체를 대상으로, 각각의 객체 검출이 올바르게 매핑 되었는지 총합으로 계산함 • 해당 품질지표는 계산 및 이해가 쉽고 전체적인 정확도를 표현하는데 유용하지만, 편향된 정확도에 대해서 편중(bias)이 발생할 수 있음													
계산식(방식)	<table><tr><th colspan="2" rowspan="2"></th><th colspan="2">Predicted Condition</th></tr><tr><th>Positive (PP)</th><th>Negative (PN)</th></tr><tr><th rowspan="2">Actual Condition</th><th>Positive (P)</th><td>True Positive (TP)</td><td>False Negative (FN)</td></tr><tr><th>Negative (N)</th><td>False Positive (FP)</td><td>True Negative (TN)</td></tr></table> $Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$			Predicted Condition		Positive (PP)	Negative (PN)	Actual Condition	Positive (P)	True Positive (TP)	False Negative (FN)	Negative (N)	False Positive (FP)	True Negative (TN)
				Predicted Condition										
		Positive (PP)	Negative (PN)											
Actual Condition	Positive (P)	True Positive (TP)	False Negative (FN)											
	Negative (N)	False Positive (FP)	True Negative (TN)											
관련 출처	• “Accuracy Metrics”. Humboldt State University https://gsp.humboldt.edu/olm/courses/GSP_216/lessons/accuracy/metrics.html , 2025년 11월 14일 접속													

[표 III-112] OA의 개념 및 세부내용

5.2.1.3 Recall (재현율)

구분	내 용													
개념	• 분류 모델에 일반적으로 사용하며, 올바르게 분류했는지 측정하는 평가지표													
세부 내용	• 분류 모델에 일반적으로 사용되는 성능 메트릭인 재현율(Recall)은 올바르게 분류된 양성의 비율로서, 재현율은 일반적으로 “진정한 긍정률”, “민감도” 및 “적중률”이라고도 함													
계산식(방식)	<table><tr><th colspan="2" rowspan="2"></th><th colspan="2">Predicted Condition</th></tr><tr><th>Positive(PP)</th><th>Negative (PN)</th></tr><tr><th rowspan="2">Actual Condition</th><th>Positive (P)</th><td>True Positive (TP)</td><td>False Negative (FN)</td></tr><tr><th>Negative (N)</th><td>False Positive (FP)</td><td>True Negative (TN)</td></tr></table> Recall = $\frac{TP}{TP + FN}$			Predicted Condition		Positive(PP)	Negative (PN)	Actual Condition	Positive (P)	True Positive (TP)	False Negative (FN)	Negative (N)	False Positive (FP)	True Negative (TN)
				Predicted Condition										
		Positive(PP)	Negative (PN)											
Actual Condition	Positive (P)	True Positive (TP)	False Negative (FN)											
	Negative (N)	False Positive (FP)	True Negative (TN)											
관련 출처	• “Recall”. C3.ai. https://c3.ai/glossary/data-science/recall/ , 2025년 11월 14일 접속													

[표 III-113] Recall의 개념 및 세부내용

5.2.1.4 Precision (정밀도)

구분	내 용													
개념	분류 모델에 일반적으로 사용되며, 정확하게 예측했는지 측정하는 평가지표													
세부 내용	분류 모델에 일반적으로 사용되는 성능지표인 정밀도는 정확하게 예측한 양성의 비율로서, 정밀도는 일반적으로 재현율과 반비례 관계임													
계산식(방식)	<table><tr><th colspan="2" rowspan="2"></th><th colspan="2">Predicted Condition</th></tr><tr><th>Positive(PP)</th><th>Negative (PN)</th></tr><tr><th rowspan="2">Actual Condition</th><th>Positive (P)</th><td>True Positive (TP)</td><td>False Negative (FN)</td></tr><tr><th>Negative (N)</th><td>False Positive (FP)</td><td>True Negative (TN)</td></tr></table> Precision = TP TP + FP = 1 1 + 1			Predicted Condition		Positive(PP)	Negative (PN)	Actual Condition	Positive (P)	True Positive (TP)	False Negative (FN)	Negative (N)	False Positive (FP)	True Negative (TN)
				Predicted Condition										
		Positive(PP)	Negative (PN)											
Actual Condition	Positive (P)	True Positive (TP)	False Negative (FN)											
	Negative (N)	False Positive (FP)	True Negative (TN)											
관련 출처	“What is Precision in Machine Learning?” C3.ai. https://c3.ai/glossary/machine-learning/precision/ ,2025년 11월 14일 접속													

[표 III-114] Precision의 개념 및 세부내용

5.2.1.5 $F\beta$ -점수

구분	내 용													
개념	정밀도와 재현율의 가중치 조화평균으로 정밀도 또는 재현율에 가중치를 주어 계산되는 평가 지표													
세부 내용	- 데이터 Label이 불균형 구조일 때, 모델의 성능을 정확하게 평가할 수 있으며, 성능을 하나의 숫자로 표현할 수 있음 - 매개변수인 베타(beta) 점수로 재현율의 가중치를 결정하며, 정밀도에 가중치를 부여하는 경우 $\beta < 1$, 재현율에 가중치를 부여하는 경우 $\beta > 1$을 적용													
계산식(방식)	<table><tr><th colspan="2" rowspan="2"></th><th colspan="2">Predicted Condition</th></tr><tr><th>Positive (PP)</th><th>Negative (PN)</th></tr><tr><th rowspan="2">Actual Condition</th><th>Positive (P)</th><td>True Positive (TP)</td><td>False Negative (FN)</td></tr><tr><th>Negative (N)</th><td>False Positive (FP)</td><td>True Negative (TN)</td></tr></table> ※ TP: 실제 True인 정답을 True라고 예측 ※ FP: 실제 False인 정답을 True라고 예측 ※ FN: 실제 True인 정답을 False라고 예측 ※ TN: 실제 False인 정답을 False라고 예측 $F\beta\text{-점수} = (1 + \beta^2) \times \frac{\text{precision} \times \text{recall}}{(\beta^2 \times \text{precision}) + \text{recall}}$ $\text{Precision} = \frac{TP}{TP + FP}$ $\text{Recall} = \frac{TP}{TP + FN}$			Predicted Condition		Positive (PP)	Negative (PN)	Actual Condition	Positive (P)	True Positive (TP)	False Negative (FN)	Negative (N)	False Positive (FP)	True Negative (TN)
				Predicted Condition										
		Positive (PP)	Negative (PN)											
Actual Condition	Positive (P)	True Positive (TP)	False Negative (FN)											
	Negative (N)	False Positive (FP)	True Negative (TN)											
관련 출처	“Metric: f1”. Hugging Face. 2025년 11월 14일 접속 https://huggingface.co/spaces/evaluate-metric/f1 “fbeta_score”. 2025년 11월 14일 접속 https://scikit-learn.org/stable/modules/generated/sklearn.metrics.fbeta_score.html - F-beta score. 2025년 11월 14일 접속 https://wiki.cloudfactory.com/docs/mp-wiki/metrics/f-beta-score													


[표 III-115] $F\beta$ -점수의 개념 및 세부내용

5.2.1.6 mAP (mean Average Precision)

구분	내 용
개념	각 쿼리에 대한 평균 정밀도 점수의 평균을 의미하는 평가지표로서, 클래스가 여러 개인 경우 각 클래스당 AP를 구한 뒤 그 합을 클래스의 개수로 나누어 계산함
세부 내용	- 쿼리 집합의 평균 정밀도(mAP, mean Average Precision)는 각 쿼리에 대한 평균 정밀도 점수의 평균으로서, 아래 수식에서 Q는 쿼리의 수를 의미함 - 수식이 의미하는 바는, 주어진 쿼리 q에 대해 해당 평균 정밀도(AP)를 계산한 다음, 이러한 모든 AP 점수의 평균을 mAP라는 단일 숫자로 제공하여 모델이 얼마나 좋은지를 수치화함
계산식(방식)	$mAP = \frac{\sum_{q=1}^Q AveP(q)}{Q}$
관련 출처	“Evaluation measures”, Wikipedia. https://en.wikipedia.org/wiki/Evaluation_measures_(information_retrieval)#Average_precision , 2025년 11월 14일 접속

[표 III-116] mAP의 개념 및 세부 내용

5.2.1.7 AUROC (Area Under Receiver Operating Characteristic)

구분	내 용
개념	이진 분류 문제에 대한 평가지표
세부 내용	- ROC(Receiver Operator Characteristic) 곡선은 이진 분류 문제에 대한 평가 지표로서, 다양한 임계값에서 FPR에 대한 TPR을 플롯하고 본질적으로 ‘신호’를 ‘잡음’에서 분리하는 확률 곡선을 의미함 - AUROC는 AUC(Area Under the Curve)와 같으며, 분류기가 클래스를 구별하는 능력의 척도이며 ROC 곡선의 요약으로 사용되는데, AUROC의 값이 최대값인 1에 가까울수록 Positive 클래스와 Negative 클래스를 구별하는 모델의 성능이 향상됨
계산식(방식)	
관련 출처	“AUC-ROC Curve – The Star Performer!”, Analytics Vidhya. https://www.analyticsvidhya.com/blog/2021/07/metrics-to-evaluate-your-classification-model-to-take-the-right-decisions/ , 2025년 11월 14일 접속

[표 III-117] AUROC의 개념 및 세부 내용

5.2.1.8 IDF1 (Identification F1-Score)

구분	내 용
개념	• 참값 정확도의 평균 개수를 계산하여 식별 정밀도를 표현하는 평가지표
세부 내용	• ID 정밀도(Identification Precision)와 ID 재현율(Identification Recall)은 trade-off 추적에 초점을 맞춘 평가지표인 반면, IDF1은 ID 정밀도와 ID 재현율 간의 조화 평균(harmonic mean)을 계산함
계산식(방식)	$IDF1 = \frac{2IDTP}{2IDTP + IDFP + IDFN}$
관련 출처	Identity F1 Score (IDF1). , https://github.com/shenh10/mot_evaluation?utm_source=chatgpt.com, https://ar5iv.labs.arxiv.org/html/2104.02631?utm_source=chatgpt.com - 2025년 11월 14일 접속

[표 III-118] IDF1의 개념 및 세부 내용


5.2.1.9 Kinship Verification 정확도

구분	내 용			
개념	• 주어진 얼굴 이미지 쌍 간의 친족 관계를 확인하는 평가지표			
세부 내용	• Kinship Verification 정확도(자동 친족 확인 시스템)는 주어진 얼굴 이미지 쌍 간의 친족 관계를 확인하도록 설계된 평가지표로서, 부모와 유전자 중복으로 자식에게서 비슷하게 나타나는 ‘외모’, ‘좋아하는 것과 싫어하는 것’, ‘행동’ 및 ‘목소리’ 등 많은 유사 특성을 검출하여 정확도를 측정함			
계산식(방식)			Predicted Condition	
			Positive(PP)	Negative (PN)
	Actual Condition	Positive (P)	True Positive (TP)	False Negative (FN)
		Negative (N)	False Positive (FP)	True Negative (TN)
$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$				
관련 출처	• Kinship verification using Compound LocalBinary Pattern and Local Feature DiscriminantAnalysis https://www.researchgate.net/publication/338359209_Kinship_verification_using_Compound_Local_Binary_Pattern_and_Local_Feature_Discriminant_Analysis - 2025년 11월 14일 접속			

※ Kinship Verification Accuracy란, Accuracy 품질지표를 유전성 분석 분야에 적용한 것으로 별도의 품질지표로 보기 어려울 수도 있으나, ‘인공지능 학습용 데이터 구축사업’ 내 다양한 품질지표를 소개하는 측면에서 해당 내용을 작성함


[표 III-119] Kinship Verification 정확도의 개념 및 세부내용

5.2.1.10 DICE-Coefficient

구분	내 용
개념	두 개의 데이터셋 간의 유사성을 측정하는 평가지표
세부 내용	- DICE-Coefficient는 두 데이터셋 간의 유사성을 측정하는 통계 도구이며, 2개의 중첩 영역을 두 이미지의 총 픽셀(pixel) 수로 나누어 계산함 - 인공지능으로 생성된 이미지 분할 알고리즘 검증에 특화되어있으며, 이미지 분할에서 가장 일반적으로 사용되는 품질지표임 - 참고로 DICE-coefficient는 F1-score의 값과 같음 따라서 F1-score를 이미지에 적용한 개념이라고 볼 수 있음 $*DICE-coefficient = F1 \text{ score} = \frac{2}{\frac{1}{Precision} + \frac{1}{Recall}}$
계산식(방식)	  Prediction  Ground Truth  FP (False Positive)  TP (True Positive)  FN (False Negative)  TN (True Negative) $Precision = \frac{TP}{TP + FP} = \frac{\text{정답영역}}{\text{정답영역} + \text{FP}}$ $Recall = \frac{TP}{TP + FN} = \frac{\text{정답영역}}{\text{정답영역} + \text{FN}}$ $IoU = \frac{\text{Area of Intersection}}{\text{Area of Union}} = \frac{TP}{TP + FP + FN} = \frac{\text{정답영역}}{\text{정답영역} + \text{FP} + \text{FN}}$
관련 출처	Daniel J Bell, "Dice similarity coefficient", Radiopaedia, https://radiopaedia.org/articles/dice-similarity-coefficient - 2025년 11월 14일 접속

[표 III-120] DICE-Coefficient의 개념 및 세부내용

5.2.1.11 mIoU (mean Intersection Over Union)

구분	내 용
개념	개체 범주 세분화 방법의 성능을 측정하는 데 사용하는 평가지표로서, IoU 값들에 대한 평균값을 의미함
세부 내용	IoU(intersection-over-union)는 Jaccard Index라고도 알려져 있으며, Segmentation과 Object Detection에서 많이 활용되는 품질지표임
계산식(방식)	$\text{IoU} = \frac{\text{Area of Overlap}}{\text{Area of Union}}$ 
관련 출처	“Optimizing Intersection-Over-Union in Deep Neural Networks for Image Segmentation”. ResearchGate. https://www.researchgate.net/publication/311531910_Optimizing_Intersection-Over-Union_in_Deep_Neural_Networks_for_Image_Segmentation - 2025년 11월 14일 접속

[표 III-121] mIOU의 개념 및 세부내용

5.2.1.12 Overall Pixel 정확도

구분	내 용
개념	올바르게 어노테이션이 수행되었는지 지정된 픽셀의 비율을 측정하는 평가지표
세부 내용	- 전체 픽셀 정확도(Overall Pixel Accuracy)는 올바르게 레이블이 지정된 픽셀의 비율을 측정하여, 검출에 대한 정확도를 판단함 - 다만, 불균형한 가공 산출물로 인한 결과의 편중(bias)이 발생할 수 있음
계산식(방식)	$\text{OP} = \frac{\sum_{i=1}^L C_{ii}}{\sum_{i=1}^L G_i}$ ※ 계산식 관련 세부 내용은 아래 출처 참조
관련 출처	Gabriela Csurka et al. Xerox Research Centre Europe, “What is a good evaluation measure for semantic segmentation?”, 2013 https://bmva-archive.org.uk/bmvc/2013/Papers/paper0032/abstract0032.pdf - 2025년 11월 14일 접속

[표 III-122] Overall Pixel 정확도의 개념 및 세부 내용

5.2.1.13 MOTA (Multiple Object Tracking Accuracy)

구분	내 용
개념	다수 객체를 추적하는 데 있어 정확도를 직관적으로 측정하는 평가지표
세부 내용	MOTA(Multiple Object Tracking Accuracy)는 다양한 목적 함수 평가 범위에서 각각 여러 성능 측정에 따라 확률 최적화 알고리즘을 조정하는 데 특화되어 있음
계산식	$MOTA = 1 - \frac{\sum_t (m_t + fp_t + mme_t)}{\sum_t g_t}$ 여기서 m_t는 t시간에 발생한 추적 실책 수, fp_t는 t시간에 발생한 거짓 양성 수, mme_t는 t시간에 발생한 부정합 추적결과 수를 의미함
관련 출처	- Keni Bernardin et al, "Multiple Object Tracking Performance Metrics and Evaluation in a Smart Room Environment", 2006. https://isl.iar.kit.edu/pdf/Bernardin2006b.pdf - 2025년 11월 14일 접속

[표 III-123] MOTA의 개념 및 세부내용

5.2.1.14 OKS (Object Keypoint Similarity)

구분	내 용
개념	관절의 추정 좌표와 참값 좌표의 유사성을 나타내는 평가지표
세부 내용	- OKS (Object Keypoint Similarity)는 관절의 추정 좌표와 참값 좌표의 유사성의 평균을 나타내는 평가지표이며, 인물의 추정 자세와 정답 자세가 완전히 일치하면 1이 됨 - Object Detection의 IoU(Intersection over Union)와 유사하며 Keypoint Detection에서 유사성 측정 방법으로 사용됨
계산식(방식)	$OKS = \frac{\sum_i [\exp(-\frac{d_i^2}{2s^2k_i^2})\delta(v_i > 0)]}{\sum_i \delta(v_i > 0)}$
관련 출처	Object Keypoint Similarity in Keypoint Detection, https://learnopencv.com/object-keypoint-similarity/ - 2025년 11월 14일 접속


[표 III-124] OKS의 개념 및 세부 내용

5.2.1.15 PCK (Percentage of Correct Keypoints)

구분	내 용
개념	키포인트의 추정 좌표와 참값 좌표의 거리가 임계값 기준을 만족하는지 측정하는 평가지표
세부 내용	PCK(Percentage of Correct Keypoints)는 키포인트 관절점의 추정 좌표와 참값 좌표의 거리가 임계값 기준을 만족하는지 측정하며, 임계값은 바운딩 박스의 사이즈를 통해 결정됨  ●: 키포인트 정답 좌표 ●: 키포인트 추정 좌표 □: 임계값 바운딩 박스 추정좌표 $\hat{x}$가 정답 좌표 x 중심의 임계값 바운딩 박스 안에 들어오는 검사 →PCK는 바운딩 박스 안에 들어오는 정답 확률
계산식(방식)	- PCKh@0.5 is when the threshold = 50% of the head bone link - PCK@0.2 = Distance between predicted and true joint $< 0.2 * \text{torso diameter}$
관련 출처	- Sergio Escalera Guerrero, ChaLearn, Computer Vision Center (UAB) and University of Barcelona, "Tutorial on Datasets, Annotations and Metrics in Computer Vision" 2015 https://sergioescalera.com/wp-content/uploads/2015/08/COST-ACTION-TRAINING-SCHOOL-DATASETS-CV-TUTORIAL.pdf https://velog.io/@pindum/Percentage-of-Correct-KeypointsPCK - 2025년 11월 14일 접속


[표 III-125] PCK의 개념 및 세부 내용

5.2.1.16 MPJPE (Mean Per Joint Position Error)

구분	내 용
개념	관절의 추정 좌표와 참값 좌표의 거리의 평균값을 측정하는 평가지표
세부 내용	- MPJPE (Mean Per Joint Position Error)는 모든 관절의 추정 좌표와 참값 좌표의 거리(단위: mm)를 평균하여 측정하는 평가지표이며, 값이 작을수록 정확도 우수로 판단 - Estimated and Ground-truth 3D Pose의 root 관절을 정렬한 후 계산함 
계산식(방식)	$MPJPE = \frac{1}{T} \frac{1}{N} \sum_{t=1}^T \sum_{i=1}^N \frac{\ (J_i^{(t)} - J_{root}^{(t)}) - (\hat{J}_i^{(t)} - \hat{J}_{root}^{(t)}) \ }{2}$
관련 출처	Mean Per Joint Position Error(MPJPE), https://oecd.ai/en/catalogue/metrics/mean-per-joint-position-error-mpjpe - 2025년 11월 14일 접속

[표 III-126] MPJPE의 개념 및 세부 내용

5.2.1.17 2D Reprojection Error

구분	내용
개념	투영된 점과 측정된 점 사이의 거리에 해당하는 기하학적 오차를 측정하는 평가 지표
세부 내용	3D 점의 추정치가 얼마나 근접하게 점의 실제 투영을 재생하는지를 정량화하기 위해 사용됨 - 재투영 오류(Reprojection Error)를 최소화하며, 두 이미지 사이의 점 대응에서 오류를 추정하는 데 사용됨
계산식(방식)	
관련 출처	“Augmented Lagrangian-based Algorithm for Projective Reconstruction from Multiple Views with Minimization of 2D Reprojection Error”. SEMANTIC SCHOLAR https://www.semanticscholar.org/paper/Augmented-Lagrangian-based-Algorithm-for-Projective-Mai-Hung/fb3b33345a25d36cdce5966abf8086d2d0f36 - 2025년 11월 08일 접속

[표 III-127] 2D Reprojection Error의 개념 및 세부내용

5.2.1.18 NME (Normalized Mean Errors)

구분	내 용
개념	작업자에 따라서 가공 결과가 일정하지 않아, 해당 데이터의 불확실성 특성을 판단하기 위한 평가지표
세부 내용	- NME(Normalized Mean Errors), 즉 정규화 오차는 Facial Landmark Detection 분야에서 많이 사용됨 - NME를 사용하는 이유는 Facial Landmark의 특성상 데이터 구축 과정에서 작업자에 따라 가공 결과의 위치가 일정하지 않으므로, 해당 데이터의 특성을 반영하기 위해서 사용함
계산식(방식)	$NME = \frac{1}{N} \sum_{i=1}^N \frac{\ p_i - g_i\ _2}{d}$ where d denotes the normalized term and N is the number of facial landmarks.
관련 출처	How to calculate NME(Normalized Mean Error) between ground-truth and predicted landmarks when some of gt has no corresponding in predicted?, https://stackoverflow.com/questions/69158002/how-to-calculate-nme-normalized-mean-error-between-ground-truth-and-predicted-l - 2025년 11월 08일 접속

[표 III-128] NME의 개념 및 세부내용

5.2.1.19 RMSE (Root Mean Squared Error)

구분	내 용
개념	예측 품질을 평가하기 위해, 실제 값에서 예측이 얼마나 떨어져 있는지 측정하는 평가지표
세부 내용	- 제공 평균 제공근 오차 또는 제공 평균 제공근 편차는 예측 품질을 평가하는 데 가장 일반적으로 사용되는 측정 방법 중 하나로서, 유클리드 거리를 사용하여 측정된 실제 값에서 예측이 얼마나 떨어져 있는지 측정함 - RMSE를 계산하려면 각 데이터 포인트에 대한 잔차(예측과 진실의 차이)를 계산하고, 각 데이터 포인트에 대한 잔차의 노름(norm)을 계산한 뒤, 잔차의 평균을 계산하고 그 평균의 제곱근을 취함 - RMSE는 각 예측 데이터 포인트에서 실제 측정값을 사용하고 필요로 하기 때문에 지도 학습 애플리케이션에서 일반적으로 사용될 수 있음
계산식	$RMSE = \sqrt{\frac{\sum_{i=1}^N \ y(i) - \hat{y}(i)\ ^2}{N}}$
관련 출처	“Root Mean Square Error”. C3.ai. https://c3.ai/glossary/data-science/root-mean-square-error-rmse/ - 2025년 11월 08일 접속

[표 III-129] RMSE의 개념 및 세부 내용

5.2.1.20 CER (Character Error Rate, 문자)

구분	내 용
개념	주어진 문장에 대해 공백을 포함한 총 문자 수(n)를 필요한 문자의 최소 삽입(i), 대체(s) 및 삭제(d) 수와 비교하여 글자 오류율을 측정하는 평가지표
세부 내용	CER(Character Error Rate)는 글자 오류율을 측정하는 지표로 주로 한글과 같이 조사를 사용하는 언어에 사용
계산식(방식)	$CER = \frac{S + D + I}{N}$
관련 출처	“Metric: cer”, Hugging Face, https://huggingface.co/spaces/evaluate-metric/cer - 2025년 11월 08일 접속

[표 III-130] CER의 개념 및 세부내용

5.2.1.21 WER (Word Error Rate, 글자)

구분	내 용
개념	주어진 문장에 대해 공백을 포함한 총 단어 수(n)를 필요한 단어의 최소 삽입(i), 대체(s) 및 삭제(d) 수와 비교하여 단어 오류율을 측정하는 평가지표
세부 내용	WER(Word Error Rate)는 단어 오류율을 측정하는 지표로 영어에 많이 사용
계산식(방식)	$WER = \frac{S_w + D_w + I_w}{N_w}$
관련 출처	“Metric: wer”, Hugging Face, https://huggingface.co/spaces/evaluate-metric/wer - 2025년 11월 08일 접속

[표 III-131] WER의 개념 및 세부 내용

5.2.1.22 BLEU (Bilingual Evaluation Understudy Score)

구분	내 용
개념	자연어를 기계 번역하여 다른 종류의 자연어로 생성된 문장을 평가하기 위한 평가지표
세부 내용	- BLEU는 생성된 문장을 참조 문장으로 평가하기 위한 평가지표로서, 완벽한 일치는 1.0의 점수가 나오는 반면 완벽한 불일치는 0.0의 점수가 나옴 - 측정 기준은 n-gram(n개의 연속적인 단어 나열)에 기반하며, n은 1~4 사이의 범위를 가짐. 여기서 n-gram precision(정밀도)란, n-gram 중 일치하는 개수를 전체 n-gram의 수로 나눈 값을 의미함
계산식(방식)	$BLEU = \min \left(1, \frac{\text{output-length}}{\text{reference-length}} \right) \left(\prod_{i=1}^4 \text{precision}_i \right)^{1/4}$
관련 출처	“Metric: BLEU”. Hugging Face, https://huggingface.co/metrics/bleu - 2025년 11월 08일 접속

[표 III-132] BLEU의 개념 및 세부내용

5.2.1.23 ROUGE-L (Recall-Oriented Understudy for Gisting Evaluation-Longest Common Subsequence)

구분	내 용
개념	가장 긴 일치하는 단어 시퀀스를 측정하는 평가지표
세부 내용	- ROUGE-L (Recall-Oriented Understudy for Gisting Evaluation-LCS)를 사용하여 가장 긴 일치하는 단어 시퀀스를 측정함 - LCS 개념을 적용한 평가지표 사용 시, 단어의 연속적 일치가 필요 없고 문장 수준의 어순을 반영한 순차적 일치를 측정하므로 유연하다는 장점이 있음
계산식(방식)	$\text{ROUGE-L}(\text{candidate}, \text{references}) = \max_k \{ \text{ROUGE-L}_{\text{single}}(\text{candidate}, \text{references}_k) \}$ $\text{ROUGE-L}_{\text{single}}(\text{candidate}, \text{reference}) = \frac{(1 + \beta^2) R_{\text{lcs}}(\text{candidate}, \text{reference}) P_{\text{lcs}}(\text{candidate}, \text{reference})}{R_{\text{lcs}}(\text{candidate}, \text{reference}) + \beta^2 P_{\text{lcs}}(\text{candidate}, \text{reference})}$ $R_{\text{lcs}}(\text{candidate}, \text{reference}) = \frac{\sum_{r_i \in \text{reference}} \text{LCS}_{\cup}(\text{candidate}, r_i) }{\text{numWords}(\text{reference})}$ $P_{\text{lcs}}(\text{candidate}, \text{reference}) = \frac{\sum_{r_i \in \text{reference}} \text{LCS}_{\cup}(\text{candidate}, r_i) }{\text{numWords}(\text{candidate})}$
관련 출처	“ROUGE”. ACL Anthology, https://aclanthology.org/W04-1013.pdf - 2025년 11월 08일 접속

[표 III-133] ROUGE-L의 개념 및 세부내용

5.2.1.24 TQA (Translation Quality Assessment)

구분	내 용																																																																																				
개념	원문의 의미를 포착하고, 적절한 단어가 있으며 오류가 없고 일관성 있게 번역되어 있는지 측정하는 평가지표																																																																																				
세부 내용	TQA(Translation Quality Assessment)는 4가지 파라미터로 정의되며, 각각 Meaning(의미), Wording/Expression(단어 및 표현), Errors(오류), Consistency(일관성)임																																																																																				
계산식(방식) (예시)	<table><tr><td>Words Checked:</td><td>265</td><td colspan="2"></td><td colspan="2"></td></tr><tr><td>QA Result:</td><td>Borderline Pass</td><td colspan="2">Quality Indicator:</td><td>92.5</td><td></td></tr><tr><td>Error points allowed:</td><td>1.325</td><td colspan="2">Error points calculated:</td><td>1</td><td></td></tr><tr><td>Error category</td><td>Critical</td><td>Medium</td><td>Minor</td><td>Repeat</td><td>Instruction</td></tr><tr><td>Accuracy</td><td>0</td><td>0</td><td>1</td><td>0</td><td>1</td></tr><tr><td>Terminology - Adherence</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td></tr><tr><td>Terminology - Consistency</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td></tr><tr><td>Appeal</td><td>0</td><td>0</td><td>0</td><td>5</td><td>2</td></tr><tr><td>Language - Tone & Voice</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td></tr><tr><td>Language - Grammar & Syntax</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td></tr><tr><td>Language - Punctuation & Spelling</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td></tr><tr><td>Compliance - Style Guide & Country Standards</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td></tr><tr><td>Compliance - Project Instructions&Format</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td></tr><tr><td>Total</td><td>0</td><td>0</td><td>1</td><td>5</td><td>3</td></tr></table>	Words Checked:	265					QA Result:	Borderline Pass	Quality Indicator:		92.5		Error points allowed:	1.325	Error points calculated:		1		Error category	Critical	Medium	Minor	Repeat	Instruction	Accuracy	0	0	1	0	1	Terminology - Adherence	0	0	0	0	0	Terminology - Consistency	0	0	0	0	0	Appeal	0	0	0	5	2	Language - Tone & Voice	0	0	0	0	0	Language - Grammar & Syntax	0	0	0	0	0	Language - Punctuation & Spelling	0	0	0	0	0	Compliance - Style Guide & Country Standards	0	0	0	0	0	Compliance - Project Instructions&Format	0	0	0	0	0	Total	0	0	1	5	3
Words Checked:	265																																																																																				
QA Result:	Borderline Pass	Quality Indicator:		92.5																																																																																	
Error points allowed:	1.325	Error points calculated:		1																																																																																	
Error category	Critical	Medium	Minor	Repeat	Instruction																																																																																
Accuracy	0	0	1	0	1																																																																																
Terminology - Adherence	0	0	0	0	0																																																																																
Terminology - Consistency	0	0	0	0	0																																																																																
Appeal	0	0	0	5	2																																																																																
Language - Tone & Voice	0	0	0	0	0																																																																																
Language - Grammar & Syntax	0	0	0	0	0																																																																																
Language - Punctuation & Spelling	0	0	0	0	0																																																																																
Compliance - Style Guide & Country Standards	0	0	0	0	0																																																																																
Compliance - Project Instructions&Format	0	0	0	0	0																																																																																
Total	0	0	1	5	3																																																																																
관련 출처	“The limitations of a quality assessment” vertaalt, https://www.vertaalt.nu/blog/the-limitations-of-a-quality-assessment/ 인공지능 데이터 구축·활용 가이드라인-전문분야 학습용 한영 번역 말뭉치 AI-Hub 2024년 9월 13일 접속 https://aihub.or.kr/aihubdata/data/view.do?currMenu=115&topMenu=100&dataSetSn=124, - 2025년 11월 08일 접속																																																																																				

[표 III-134] TQA의 개념 및 세부내용

5.2.1.25 Perplexity (복잡도)

구분	내 용
개념	• 확률 분포 또는 확률 모형이 표본을 얼마나 잘 예측하는지 나타내는 평가지표로서, Perplexity(복잡도)가 낮으면 확률 분포가 표본을 잘 예측한다는 것을 나타냄
세부 내용	• 기본적으로 외부 데이터를 이용하지 않고 언어모델 자체의 성능을 평가하겠다는 아이디어이기 때문에, 언어모델을 기반으로 한 다양한 Task의 간접적인 성능 지표로 사용할 수는 있지만 특정 Task가 정해진 경우에는 그 Task에 보다 적합한 품질지표를 사용하는 것이 일반적인 추세임 • 즉, 전통적인 n-gram 언어모델에서부터 사용하던 metric이지만 최근에는 그다지 많이 사용되지 않음
계산식(방식)	$PP(W) = \sqrt[x]{\frac{1}{P(w_1, w_2, \dots, w_n)}}$
관련 출처	• Unigram-Normalized Perplexity as a Language Model Performance Measure with Different Vocabulary Sizes, https://arxiv.org/abs/2011.13220 • https://facerain.github.io/nlp-ppl/?utm_source=chatgpt.com, - 2025년 11월 08일 접속

[표 III-135] Perplexity의 개념 및 세부내용

5.2.1.26 EM (Exact Matching)

구분	내 용
개념	• 실제 참값과 정확하게 일치하는 비율을 측정하는 평가지표
세부 내용	• 음성인식 분야 중, 특히 Machine Translation에서 정답과 예측값의 정확도를 측정하기 위한 지표
관련 출처	• “Exact Matching”. MatchIt, 2025년 11월 08일 접속 • https://kosukeimai.github.io/MatchIt/reference/method_exact.html

[표 III-136] EM의 개념 및 세부내용

5.2.1.27 MOS (Mean Opinion Score)

구분	내용
개념	• 음성 통화 성능평가에 주로 사용되는 통계에 의한 주관적 평가 지표
세부 내용	• MOS(Mean Opinion Score)는 지난 수십 년 동안 전반적인 음성 통화 품질을 측정하기 위해 가장 일반적으로 사용되었음 • 해당 품질지표는 ITU-T(International Telecommunications Union)에서 표준화되어 공개된 지표임
계산식(방식)	$MOS = \frac{\sum_{n=1}^N R_n}{N}$

구분	내용
관련 출처	“M.O.S. MEAN OPINION SCORE”, Arimas, 2025년 11월 08일 접속 https://arimas.com/2017/08/01/mos-mean-opinion-score/

[표 III-137] MOS의 개념 및 세부내용

5.2.1.28 SSA (Sensibleness and Specificity Average)

구분	내용
개념	챗봇이 사람과 같은 대화를 추구한다고 할 때(human-like), 이를 평가할 수 있는 척도
세부 내용	- 자연어 처리 분야에서 사용되는 평가 메트릭으로 답변이 합리성(sensible), 구체성(specific)을 사람이 측정한 점수를 계산 - 챗봇의 대화를 보고 sensibleness값과 specificity값을 평가하여 낸 평균 - Sensibleness는 common sense, logical coherence, consistency와 같은 요소들을 평가 - specificity는 response가 sensible한 경우에 specific한지 판단하여 평가함 - SSA와 PPL(Perplexity)*은 강한 상관관계를 가짐 * 5.2.8.25. Perplexity (복잡도) 참조
관련 출처	https://arxiv.org/abs/2001.09977, - 2025년 11월 08일 접속

[표 III-138] SSA의 개념 및 세부내용

5.2.1.29 FID (Fréchet Inception Distance)

구분	내용
개념	FID(Fréchet Inception Distance)는 생성된 이미지의 품질을 평가하는데 사용하는 평가 지표
세부 내용	- 생성된 이미지의 분포를 실제 이미지 집합의 분포와 비교 - 이미지를 픽셀 단위로 직접 비교하는 대신 Inception-v3에서 가장 깊은 레이어의 평균과 표준 편차를 비교
계산식(방식)	$FID = \ \mu_r - \mu_g\ + \text{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{\frac{1}{2}})$
관련 출처	“Evaluation measures”, Wikipedia. https://en.wikipedia.org/wiki/Fr%C3%A9chet_inception_distance - 2025년 11월 08일 접속

[표 III-139] FID의 개념 및 세부내용

5.2.1.30 PSNR (Peak Signal-to-noise ratio)

구분	내 용
개념	영상 화질 손실량을 평가하는 지표
세부 내용	- 이미지 저장, 전송, 압축, 영상 처리 등에서 영상 화질이 바뀌었을 때 사용 - 손실이 적을수록 (화질이 좋을수록) 높은 값, 무손실 영상의 경우, MSE가 0이 되기 때문에 PSNR을 정의할 수 없음 - MSE(Mean Square Error)는 원본 이미지와 비교 이미지 간의 각 Pixel 오차를 표시
계산식(방식)	$PSNR = 10 \log_{10} \left(\frac{R^2}{MSE} \right)$
관련 출처	“Point-NeRF: Point-based Neural Radiance Fields”, arxiv.org. https://arxiv.org/pdf/2201.08845 - 2025년 11월 08일 접속

[표 III-140] PSNR의 개념 및 세부내용

5.2.1.31 SSIM (Structural Similarity Index Measure)

구분	내 용
개념	SSIM (Structural Similarity Index Measure) 영상 화질 손실량을 평가하는 지표
세부 내용	- 이미지 저장, 전송, 압축, 영상 처리 등에서 영상 화질이 바뀌었을 때 사용 - 두 이미지(x, y) 간의 상관계수를 Luminance(휘도), Contrast(대비), Structure (구조) 총 3가지 측면에서 평가합니다. ($\alpha=\beta=\gamma=1$) - 휘도는 빛의 밝기, 대비는 밝기 차이, 구조는 상관관계를 표시
계산식(방식)	$SSIM(x,y) = [l(x,y)]^\alpha \cdot [c(x,y)]^\beta \cdot [s(x,y)]^\gamma$
관련 출처	“Image Quality Assessment: From Error Visibility to Structural Similarity” 2004, https://www.researchgate.net/publication/3327793_Image_Quality_Assessment_From_Error_Visibility_to_Structural_Similarity -2025년 11월 08일 접속

[표 III-141] SSIM의 개념 및 세부내용

5.2.2 유효성 지표 참고자료

5.2.2.1 텍스트 데이터

Task 분야	가공 유형	유효성 측정지표
텍스트 분류 (Text Classification)	Class Labeling	정확도
		정밀도
		AUC(AUROC)
		$F\beta$ -점수
		MAE
		MAPE
		MSE
		PCC
		QWK
	Text Summary	정확도
		$F\beta$ -점수
		TOP-K 정확도
		ROUGE-L
	Sequence Labeling	MAPE
	Tagging	정확도
		$F\beta$ -점수
		hits@1
		AVG BLEU
		AUC
		R2@1
		R10@1
언어 이해 (Language Understanding)	Machine Translation	$F\beta$ -점수
		BLEU
	Sequence Labeling	$F\beta$ -점수
		정밀도
질의응답 (Question Answering)	Class Labeling	정확도
		$F\beta$ -점수
	Sequence Labeling	정확도
		$F\beta$ -점수
		EM
	Tagging	정확도

Task 분야	가공 유형	유효성 측정지표
기계 번역 (Machine Translation)	Machine Translation	Unseen SR
		R10@1
		F β -점수
		BLEU
음성 인식 (Speech Recognition)	Machine Translation	ERR
		BLEU
음성 인식 (Speech Recognition)	Class Labeling	정확도
	Machine Translation	BLEU
텍스트 추천 (Text Extraction)	Tagging	Recall
텍스트 예측 (Text Prediction)	Class Labeling	정확도
		MAPE
	Sequence Labeling	F β -점수
		정확도
	Tagging	정밀도
		F β -점수
		C-index
		AUC
		RMSE
		Predicted R2
텍스트 교정 (Text Reconstruction)	Sequence Labeling	F β -점수
	Tagging	F β -점수
텍스트 생성 (Text Generation)	Sequence Labeling	Likert scale
		정확도
	Tagging	F β -점수
		hits@1
		BLEU
		ROUGE
		Coverage
		Perplexity
		CER

[표 III-142] 텍스트 데이터 유효성 품질지표 구성

※ 해당 내용은 한국지능정보사회진흥원에서 공모하는 ‘초거대AI 확산 생태계 조성사업’에 대한 데이터 품질검증결과를 기반으로 작성되었으며, 일반적으로 인공지능 분야에서 통용되는 품질기준과 상이할 수 있음

5.2.2.2 이미지 데이터

Task 분야	가공 유형	유효성 측정지표
객체 인식 (Object Detection)	Bounding Box	EOO
		FPS
		IoU
		mAP
		mlou
		Top-K 정확도
		재현율
		정확도
		F β -점수
	Keypoint	정확도
		AP
		ATE
		mAP
		PCK
		RMSE
	Polygon	AP
		AR
		BLEU
		FID
		mAP
		mlou
		Top-K 정확도
		정확도
		F β -점수
	Polyline	Correlation
		mAP
		AP
		F β -점수
키포인트 검출 (Keypoint Detection)	Keypoint	mAP
		정확도

Task 분야	가공 유형	유효성 측정지표
		OKS
		AP
		MPJPE
		PCK
얼굴 인식 (Face Recognition)	Bounding Box	Kinship Verification 정확도
		MAE
		정확도
	Keypoint	AP
		FID
		Rank-K 정확도
		정확도
	Polyline	Rank-K 정확도
	Tagging	Rank-K 정확도
이미지 분류 (Image Classification)	Bounding Box	AUROC
		Grid Cell 정확도
		mAP
		Top-K 정확도
		정확도
		$F\beta$ -점수
	Polygon	mAP
		mIoU
		Overall Pixel 정확도
		$F\beta$ -점수
	Class Labeling	정확도
		Overall Pixel 정확도
		$F\beta$ -점수
		AUROC
		DSC
		ERR
		mIoU

Task 분야	가공 유형	유효성 측정지표
		PQ
		MAE
		mAP
		MAPE
		mIoU
		Recall
		Sensitivity
		WAR
행동 인식 (Action Recognition)	Keypoint	정확도
이미지 추정 (Image Estimation)	Class Labeling	MAE
		Recall
	Segmentation	MAE
	Polyline	ADE
이미지 생성 (Image Generation)	Tagging	HR
	Class Labeling	정확도
		BLEU
		overall pixel 정확도
	Segmentation	MSE
		FID
	Sequence Labeling	BLEU
이미지 예측 (Image Prediction)	Class Labeling	AUC
		C-Index
		R2
		mIOU
		Spearman's Rho
	Segmentation	RecallVSD
		F β -점수
이미지 질의응답 (Image Question Answering)	Class Labeling	R10
	Tagging	BLEU
이미지 합성	Class Labeling	FID

Task 분야	가공 유형	유효성 측정지표
(Image Synthesis)		Mean point difference
인스턴스 세그멘테이션 (Instance Segmentation)	Segmentation	정확도
		mAP
		mIoU
		MAPE
		NMAE
		Pixel 정확도
		DICE
시멘틱 세그멘테이션 (Semantic Segmentation)	Segmentation	정확도
		mAP
		mIoU
		Pixel 정확도
광학 문자 인식 (Optical Character Recognition)	Segmentation	정확도
		F β -점수
		mAP
		CER
자세 추정 (Pose Estimation)	Class Labeling	AP
	Keypoint	AP
		mAP
음성 합성 (Speech Synthesis)	Segmentation	mIoU
음성 인식 (Speech Recognition)	Transcription	정확도
3D 객체 분류 (3D Object Classification)	Class Labeling	정확도
		AUROC
3D 객체 인식 (3D Object Detection)	Semantic Segmentation	mAP

[표 III-143] 이미지 데이터 유효성 품질지표 구성

※ 해당 내용은 한국지능정보사회진흥원에서 공모하는 ‘초거대AI 확산 생태계 조성사업’에 대한 데이터 품질검증결과를 기반으로 작성되었으며, 일반적으로 인공지능 분야에서 통용되는 품질기준과 상이할 수 있음

5.2.2.3 비디오 데이터

Task 분야	라벨 유형	유효성 측정지표
객체 인식 (Object Detection)	Bounding Box	AUROC
		mAP
		mIoU
		Sensitivity
		Specificity
		정확도
		$F\beta$ -점수
	Polygon	AUROC
		DSC
		MAE
		mAP
		mIoU
		NRMSE
		RE
		Sensitivity
		정확도
		$F\beta$ -점수
	Polyline	mAP
		RMSE
	Segmentation	PQ
	Sequence Labeling	정확도
	Text Summary	BLEU
이미지 분류 (Image Classification)	Bounding Box	AUROC
		IoU
		mAP
		RMSE
		Sensitivity
		Top-K 정확도
		정확도
		$F\beta$ -점수

Task 분야	라벨 유형	유효성 측정지표
	Keypoint	정확도
		MRE
		SMAPE
	Polygon	AUROC
		DSC
		IoU
		Top-K 정확도
		정확도
		$F\beta$ -점수
	Polyline	Correlation
		DSC
		Sensitivity
		$F\beta$ -점수
		MOTA
행동 인식 (Action Recognition)	Bounding Box	1DF1
		AP
		mAP
		MOTA
		Top-K 정확도
		$F\beta$ -점수
	Keypoint	BLEU
		mAP
		Mean Gaze Tracking Error
		Mean Position Error(pixel)
		PCK
		Top-K 정확도
		정확도
		$F\beta$ -점수
	Polygon	mIoU
		$F\beta$ -점수

Task 분야	라벨 유형	유효성 측정지표
	Polyline	mIoU
		MOTA
		$F\beta$ -점수
비디오 분류 (Video Classification)	Bounding Box	AUROC
		mA
		Sensitivity
		Specificity
		정확도
		$F\beta$ -점수
	Polyline	정밀도
	Tagging	micro F1
자세 추정 (Pose Estimation)	Bounding Box	$F\beta$ -점수
		정확도
		mASS
	Keypoint	$F\beta$ -점수
		정확도
		FID
		mASS
비디오 인식 (Video Recognition)	Polygon	PSNR
	Segmentation	PSNR
		$F\beta$ -점수
키포인트 검출 (Keypoint Detection)	Keypoint	mAP
	Segmentation	mAP
3D 객체 인식 (3D Object Detection)	Cuboid	NRMSE

[표 III-144] 비디오 데이터 유효성 품질지표 구성

※ 해당 내용은 한국지능정보사회진흥원에서 공모하는 ‘초거대AI 확산 생태계 조성사업’에 대한 데이터 품질검증결과를 기반으로 작성되었으며, 일반적으로 인공지능 분야에서 통용되는 품질기준과 상이할 수 있음

5.2.2.4 오디오 데이터

Task 분야	라벨 유형	유효성 측정지표
오디오 분류 (Audio Classification)	Class Labeling	정확도
		$F\beta$ -점수
		SDR
		PCC
		mAP
		WER
	Tagging	정확도
		CER
		WER
		Pearson Correlation
	Text Summary	정확도
		$F\beta$ -점수
		정밀도
		재현율
언어 이해 (Language Understanding)	Class Labeling	CER(문자)
		EER
		WER
	Sequence Labeling	CER
		EER
		$F\beta$ -점수
		WER
	Speech to Text	CER
		EER
		ESTOI
		WER
	Tagging	WER
음성 인식 (Speech Recognition)	Class Labeling	BLEU
		CER
		$F\beta$ -점수

Task 분야	라벨 유형	유효성 측정지표
	Machine Translation	AP
		BLEU
		정확도
		CER
		EER
		ESTOI
		F β -점수
		MOS
		PCC
		QWK
		ROUGE
		WER
		WCE
		WRR
	Sequence Labeling	BLEU
		WER
	Speech to Text	BLEU
		CER
		WER
	Text Summary	ROUGE
텍스트 분류 (Text Classification)	Class Labeling	CER(문자)
	Speech to Text	CER(문자)
음성 합성 (Speech Synthesis)	Class Labeling	MOS
		Recall
	Sequence Labeling	MOS
	Speech to Text	MOS
	Tagging	MOS

[표 III-145] 오디오 데이터 유효성 품질지표 구성

※ 해당 내용은 한국지능정보사회진흥원에서 공모하는 ‘초거대AI 확산 생태계 조성사업’에 대한 데이터 품질검증결과를 기반으로 작성되었으며, 일반적으로 인공지능 분야에서 통용되는 품질기준과 상이할 수 있음

5.2.2.5 3D 데이터

Task 분야	라벨 유형	유효성 측정지표
3D 객체 인식 (3D Object Detection)	Bounding Box	mAP
		mIoU
	Cuboid	정확도
		mAP
		mIoU
		PSNR
		SSIM
		AP
		IoU
		MOTA
		HOTA
	Polygon	정확도
		mAP
		mIoU
	Polyline	mAP
		mIoU
		Opt
	Keypoint	ATE
	Segmentation	AP
		mAP
		mIoU
3D 포인트 클라우드 분류 (3D Point Cloud Classification)	Cuboid	정확도
		mAcc
		mIoU
		OA
	Class Labeling	정확도
		F β -점수
		frame mAP

Task 분야	라벨 유형	유효성 측정지표
3D 자세 추정 (3D Pose Estimation)	Bounding Box	2D reprojection 정확도
		TOP-K 정확도
	Polygon	2D reprojection 정확도
	Cuboid	MPJPE
		PA-MPJPE
		frame mAP
		AP
3D 객체 복원 (3D Object Reconstruction)	Cuboid	mAP
2D 이미지를 통한 시점 합성 (2D View Synthetic)	Bounding Box	F β -점수
	Cuboid	mAP
	Polygon	F β -점수
3D 키포인트 검출 (3D Keypoint Detection)	Keypoint	AP
		mAP
	Cuboid	REMV

[표 III-146] 3D 데이터 유효성 품질지표 구성

※ 해당 내용은 한국지능정보사회진흥원에서 공모하는 ‘초거대AI 확산 생태계 조성사업’에 대한 데이터 품질검증결과를 기반으로 작성되었으며, 일반적으로 인공지능 분야에서 통용되는 품질기준과 상이할 수 있음

부록2

품질지표 설정 가이드

1

품질지표 설정 개요

1.1 품질특성

- 시모델(알고리즘)이 활용 가능한 형태의 데이터를 구축하기 위한 다양성(통계/요건), 구문 정확성, 의미 정확성, 유효성 확보 필요

	다양성 (통계/요건)	구문 정확성	의미 정확성	유효성
품질 특성	구축하는 데이터의 편향성을 방지하기 위해, 클래스 분포도, 인스턴스 분포도, 문장 길이, 어휘 개수 등을 측정하는 품질특성	어노테이션 데이터를 구성하는 속성값들과 원래 정의한 데이터 형식 및 입력값 범위와의 일치성을 측정하는 품질특성	데이터의 참값(Ground Truth)을 확인하기 위해, 정확도, 정밀도, 재현율, IoU, ROUGE, BLEU, F β -점수, EM 등을 측정하는 품질특성	학습용 데이터로 학습시키는데 적합한 인공지능 알고리즘의 유효성을 측정하는 품질특성

[그림 III-1] 인공지능 학습용 데이터 품질특성

- 본 가이드는 인공지능 학습데이터 구축사업 추진 시 구축 유형에 따른 품질지표 설정을 돕기 위해 다양성(통계/요건), 구문 정확성, 의미 정확성, 유효성별 지표 가이드를 제공



[그림 III-2] 데이터 품질지표 설정 가이드 구성

2

학습데이터 유형

2.1 데이터 유형별 학습 Task

- 인공지능 학습데이터 구축 시 ‘텍스트’, ‘이미지’, ‘비디오’, ‘오디오’, ‘3D’, ‘센서’ 데이터 종류별로 적합한 학습 Task를 선택함
- 이때, 학습 Task는 인공지능 학습데이터 구축목표 또는 임무에 적합하도록 선택함

학습 Task	개념	데이터 유형				
		텍스트	이미지	비디오	오디오	3D
텍스트 분류 (Text Classification)	문장이나 문서를 적절한 범주로 지정하는 작업으로, 범주는 선택한 데이터셋에 따라 다르며 주제 범위가 다양할 수 있음	●			○	
이미지 분류 (Image Classification)	특정 이미지를 알고리즘에 입력했을 때, 그 이미지가 어떤 클래스에 속하는지 알려주는 작업		●	○		
비디오 분류 (Video Classification)	프레임이 주어진 비디오에서 특정 프레임 구간을 선택하고 레이블을 부여하는 작업		●	○		
오디오 분류 (Audio Classification)	오디오 정보를 특정 시간 단위로 분할(오디오 클립)하여, 신호의 특이점을 분석하고 특정 클래스로 분류하는 작업	●	●		○	
3D 포인트 클라우드 분류 (3D Point Cloud Classification)	포인트 클라우드를 알고리즘에 입력했을 때, 어떤 클래스에 속하는지 알려주는 작업					○
객체 인식 (Object Detection)	이미지 내에서 특정 클래스의 객체 인스턴스를 인식하는 작업		●	○		
키폰트 검출 (Keypoint Detection)	동작 인식을 위해 필요한 주요 키폰트를 검출하는 작업		●	○		
3D 객체 인식 (3D Object Detection)	3D 영상/이미지 내에서 특정 클래스의 객체 인스턴스를 감지하는 작업		○	○		●
3D 키폰트 검출 (3D Keypoint Detection)	3D 영상/이미지 내에서 동작 인식을 위해 필요한 주요 키폰트를 검출하는 작업					○
자세 추정 (Pose Estimation)	객체와 객체의 주요 부분에 대한 위치, 방향을 식별하여 클래스를 분류하는 작업		●	○		
3D 자세 추정 (3D Pose Estimation)	3D 영상/이미지 내에서 객체와 객체의 주요 부분에 대한 위치, 방향을 식별하여 클래스를 분류하는 작업					○
순차적 레이블링 (Sequence Labeling)	입력 시퀀스에 대하여 레이블 시퀀스를 각각 부여하는 작업으로, 태깅 작업이 대표적인 순차적 레이블링의 예시임	●				

학습 Task	개념	데이터 유형				
		텍스트	이미지	비디오	오디오	3D
질의응답 (Question Answering)	• 질문(일반적으로 독해 질문)에 답변하는 작업으로서, 제공된 컨텍스트를 기반으로 답변할 수 없는 질문이 제시되면 기권함	●			○	
얼굴 인식 (Face Recognition)	• 얼굴을 사용하여 개인의 신원을 식별하거나 확인하는 작업		●			
행동 인식 (Action Recognition)	• 비디오 데이터 스트림에서 객체 행동의 감지 및 인식을 하는 작업		●	○		
비디오 인식 (Video Recognition)	• 비디오를 활용하여 실시간 객체 식별 및 비디오 프레임을 분류하는 작업			●		
음성 인식 (Speech Recognition)	• (전사)사람이 말하는 음성 언어를 인공지능이 해석해 그 내용을 문자 데이터로 전환하는 작업	●			○	
	• (자연어)사람이 말하는 음성 언어를 기계가 읽을 수 있는 형식으로 변환하는 작업	●			●	
3D 객체 복원 (3D Object Reconstruction)	• 영상/이미지/포인트 클라우드로부터 객체(물체, 사람 등)의 3차원 구조를 복원(reconstruction)하는 작업		○	○		○
텍스트 요약 (Text Summary)	• 상대적으로 큰 원문을 핵심 내용만 간추려서 상대적으로 작은 요약문으로 변환하는 작업	●			○	
음성 합성 (Speech Synthesis)	• 컴퓨터 또는 기타 장치를 사용하여 사람의 음성을 인공적으로 시뮬레이션하는 작업	●			●	
2D 이미지를 통한 시점 합성 (2D View Synthetic)	• 컴퓨터 또는 기타 장치를 사용하여 이미지를 인공적으로 3D로 전환하는 작업		○			○
기계 번역 (Machine Translation)	• 인공지능을 이용해 인간이 사용하는 자연어를 다른 자연어로 번역하는 작업	●			○	
인스턴스 세그멘테이션 (Instance Segmentation)	• 개체의 감지된 각 인스턴스에 대한 분할 맵을 생성하는 향상된 유형의 세그멘테이션 분할 작업		●			●
시멘틱 세그멘테이션 (Semantic Segmentation)	• 동일한 객체 클래스에 속하는 이미지 부분을 함께 클러스터링하는 작업		●	●		●
팬옵틱 세그멘테이션 (Panoptic Segmentation)	• Semantic Segmentation과 Instance Segmentation을 결합 방식으로 배경이 되는 부분까지 세그멘테이션 분할 작업		●			
광학 문자 인식 (Optical Character Recognition)	• 사람이 쓰거나 기계로 인쇄한 문자의 영상을 이미지 스캐너로 획득하여 기계가 읽을 수 있는 문자로 변환하는 작업	●	●			
이미지 캡셔닝 (Image Captioning)	• 이미지를 캡처하여 이미지에 대한 의미나 특징을 식별하는 작업		●			

〈범례〉 ○ : 원시데이터(획득/수집한 데이터 포맷), ● : 원천데이터(학습 시 활용하는 데이터 포맷)

[표 III-147] 데이터 유형별 학습 Task 종류

2.2 가공 방식

- 데이터 가공은 구축사업 목적 및 특성에 따라 다양한 가공 방식을 사용할 수 있으며, 대표적인 가공 방식은 다음과 같음


가공 유형	설명
세그멘테이션 (Segmentation)	• 이미지, 영상 데이터의 모든 객체를 구분하고 클래스 부여
바운딩 박스 (Bounding Box)	• 객체를 직사각형 박스안에 포함되도록 작업하여 클래스 부여
폴리라인 (Polyline)	• 여러 개의 점을 가진 선을 활용하여 인도, 차선, 경로 등 선형 객체를 구분하고 인식하기 위한 작업
폴리곤 (Polygon)	• 다각형 모양으로 객체의 테두리를 따라 점을 찍어 여백 없이 정확히 객체만을 구분하여 클래스 부여
키폰트 (Keypoint)	• 이미지나 비디오에서 안면, 신체 등 특정 물체의 키폰트(landmark)를 식별하는 작업
큐보이드 (Cuboid)	• 2D로 작업할 수 없는 3D 객체들을 정육면체로 생성
전사 (Transcription)	• 음성을 텍스트로 변환하는 작업
태깅 (Tagging)	• 원본 지문(텍스트)에서 질문에 대한 답 생성 • 데이터(객체)의 주제나 카테고리를 분류
분류 (Class Labeling)	• 데이터에 대한 레이블을 분류하는 작업
번역 (Machine Translation)	• 컴퓨터를 사용하여 서로 다른 언어를 번역하는 작업
질의/답변 (Sequence Labeling)	• 시퀀스에 따른 요소에 따라 순차적으로 라벨을 할당하는 것
요약 (Text Summary)	• 테스트 문서를 요약하는 작업
이미지 캡셔닝 (Image Captioning)	• 이미지를 입력하여 이미지에 대한 자연어 문장을 생성 및 제공하는 작업
3D 모델링 (3D Modelling)	• 3차원 디지털 모델을 만드는 작업
세그멘테이션 (Segmentation)	• 개체의 감지된 인스턴스에 대한 분할 맵 생성 및 이미지 부분을 클러스터링하고 분할 작업

[표 III-148] 대표적인 데이터 가공 유형

2.3 데이터, 학습 Task, 가공 유형 및 지표

2.3.1 텍스트 데이터


- 텍스트 데이터는 정보검색, 대화분석, 질의응답, 명령어 이해, 언어모델 학습 등의 자연어처리 AI 기술개발을 위해 구축되며, 주요 학습 Task 유형으로는 ‘텍스트 분류(Text Classification)’, ‘텍스트 요약(Text Summary)’, ‘기계 번역(Machine Translation)’, ‘순차적 레이블링 (Sequence Labeling)’, ‘질의응답(Question Answering)’, ‘음성인식(Speech Recognition)’ 등이 있음
※ 기타 학습 Task 유형으로 광학문자인식(Optical Character Recognition), 정보추출(Information Extraction), 텍스트 생성(Text Generation) 등이 있음
- 텍스트 데이터는 학습 Task 유형별로 적합한 가공을 선택하는 것이 필요하며, 선택된 가공 유형에 따라 적합한 지표를 적용



[그림 III-3] 텍스트 데이터 구축 유형

2.3.2 이미지 데이터

- 이미지 데이터는 시간의 흐름에 따라 지속적인 움직임을 담지 않고 피사체를 고정하여 촬영한 데이터를 의미하며, 주요 학습 Task 유형으로는 ‘객체 인식(Object Detection)’, ‘키포인트 검출(Keypoint Detection)’, ‘얼굴 인식(Face Recognition)’, ‘이미지 분류(Image Classification)’ 등이 있음
- 이미지 데이터는 학습 Task 유형별로 적합한 가공을 선택하는 것이 필요하며, 선택된 가공 유형에 따라 적합한 지표를 적용



[그림 III-4] 이미지 데이터 구축 유형

2.3.3 비디오 데이터

- 비디오 데이터는 연속적인 프레임을 연결하여 만든 스트리밍 이미지 데이터를 의미하며, 일정 시간 동안 연결을 가진 동영상을 뜻하기도 함
- 주요 학습 Task 유형으로는 ‘객체 인식(Object Detection)’, ‘이미지 분류(Image Classification)’, ‘행동 인식(Action Recognition)’, ‘비디오 분류(Video Classification)’, ‘자세 추정(Pose Estimation)’, ‘비디오 인식(Video Recognition)’, ‘키포인트 검출(Keypoint Detection)’ 등이 있음
- 비디오 데이터는 학습 Task 유형별로 적합한 가공을 선택하는 것이 필요하며, 선택된 가공 유형에 따라 적합한 지표를 적용



[그림 III-5] 비디오 데이터 구축 유형

2.3.4 오디오 데이터


- 오디오 데이터는 녹음이나 녹취 등을 통해 획득된 자연어/비자연어 소리 데이터를 의미하며, 주요 학습 Task 유형으로는 ‘오디오 분류(Audio Classification)’, ‘음성 인식(Speech Recognition)’, ‘텍스트 분류(Text Classification)’, ‘음성 합성(Speech Synthesis)’ 등이 있음
- 오디오 데이터는 학습 Task 유형별로 적합한 가공을 선택하는 것이 필요하며, 선택된 가공 유형에 따라 적합한 지표를 적용



[그림 III-6] 오디오 데이터 구축 유형

2.3.5 3D 데이터

- 3D 데이터는 이미지, 비디오, 센서(LiDAR 등) 등을 통해 획득된 3D 이미지, 포인트 클라우드 데이터를 의미하며, 주요 학습 Task 유형으로는 '3D 객체 인식(3D Object Detection)', '3D 포인트 클라우드 분류(3D Point Cloud Classification)', '3D 자세 추정(3D Pose Estimation)', '3D 객체 복원(3D Object Reconstruction)', '2D 이미지를 통한 시점 합성(2D View Synthetic)', '3D 키포인트 검출(3D Keypoint Detection)' 등이 있음
- 3D 데이터는 학습 Task 유형별로 적합한 가공을 선택하는 것이 필요하며, 선택된 가공 유형에 따라 적합한 품질지표를 적용



[그림 III-7] 3D 데이터 구축 유형

3 품질지표 설정 가이드

3.1 다양성

3.1.1 개요

- 데이터는 활용 목적을 달성할 수 있도록 지도 학습 계열 인공지능이 처리해야 하는 실제 세상의 데이터와 유사한 특성을 가진 데이터로 구성
- 이를 위해 학습에 유용한 모든 특성 정보를 포함하는 포괄성이 있어야 하며, 특성 정보가 학습에 유용한 범위에서 다양하게 변화하는 변동성이 있어야 하고, 학습에 지역적 편견, 사회적 편견, 인종적 편견 등의 의도가 없도록 편향성을 방지해야 함

〈참고 : 특성 정보〉

- 특성 정보란 데이터에 포함된 내용 중 학습에 활용되는 속성으로 다음과 같은 종류가 있음
 - 사물, 지역, 사람(성별, 연령대 등), 장소, 시간(오전, 오후, 야간 등), 환경(실외, 실내, 날씨 등), 언어특성(방언, 외국어 등)

[표 III-149] 다양성 항목 특성 정보

- 인공지능 학습용 데이터 구축에서 다양성 항목 정의 시 사업 목표(임무), 데이터 유형, 어노테이션 대상 등을 고려하여 다양성을 정의해야 함. 이때 메타데이터와 관련된 항목의 경우 사전 계획을 수립하기 비교적 용이하기 때문에 달성 가능한 명확한 목표 수치를 설정
- 단, 어노테이션과 관련된 항목의 경우 사업 목표(임무)를 정의 시 사전 정의가 어렵기 때문에 구축 결과에 대한 주요 통계 정보를 제공하는 목적을 가지고 정의

3.1.2 다양성 항목 정의 절차

- 다양성 항목을 정의하는 절차는 ① 학습에 유용한 모든 특성 정보를 포함하는 포괄성 항목을 정의하고, ② 포괄성 항목에 대한 범위 및 범주를 고려한 변동성을 검토한 후 ③ 편향성을 방지하기 위한 데이터 비율 구성 결정의 절차로 수행

〈다양성 항목 도출 절차〉



[그림 III-8] 다양성 항목 도출 절차

- ① 포괄성 항목 정의 시 학습에 유용한 모든 특성 정보를 고려하여 항목을 정의
 - 〈예〉 사물, 지역, 시간, 날씨, 화자, 도메인(임무에 따라 지역별 날씨 등과 같이 조합 항목도 가능)
- ② 변동성을 고려하기 위해 포괄성 항목을 범위 구분 후 범주화
 - 〈예〉 사물 세부 범주, 데이터 수집 지역(〈예〉 도심, 산간, 해변), 시간대 범위(〈예〉 오전, 오후, 야간, 새벽), 날씨 종류(〈예〉 맑음, 흐림, 눈, 비), 화자 연령대(〈예〉 유아(~13세), 청소년(14~19세), 청년(20~39세), 장년(40~59세), 노년(60세~)), 도메인(〈예〉 쇼핑, 날씨, 관광) 정의
- ③ 편향성 방지를 위해 단계 ②에서 도출한 범주별 적정 데이터 비율(%)을 고려하여 다양성 항목에 대한 구성비를 결정

3.1.3 다양성 항목 도출

- 다양성항목(속성) 도출시 ①사업목표(임무)별, ②어노테이션대상별, ③데이터유형별 항목을 참고해서 항목을 도출

① 사업 목표(임무)를 정의하고 사업 목표(임무)에 적합한 데이터 유형과 다양성 지표를 선택

임무	텍스트	이미지	비디오	오디오	3D	예시 항목	대상
객체/ 행위에 대한 분류/탐지	●	●	○	○	○	클래스별 인스턴스(객체/행위) 분포 또는 최소/평균 수	어노테이션
						이미지 별 최소/평균 클래스/인스턴스 수 ※ 이미지 내 여러 클래스/인스턴스를 분류/ 탐지하는 경우	
						인스턴스 크기(해상도) 범위별 분포 또는 최소/평균 수 ※ 인스턴스 크기가 중요한 임무이거나 크기 구간별로 분류/탐지 성능 측정하는 경우	
질환/위험의 수준 예측		●	○			수준별 인스턴스(객체/행위) 최소/평균 수	어노테이션
이상(질환/위험) 유무 예측		●	○			정상/이상 분포	어노테이션
자율주행	●	●	○		○	위치 정보(GPS 좌표 등), 시간(주/야간), 도로 종류(도심/고속도로, 국도 등), 차량 속도 (저/중/고속) 등	메타데이터
생물 성장(생육) 예측	●	●	○		○	환경 정보(공기 질/수질, 기온/수온 등)	메타데이터
비디오 요약			●			비디오별 범주 수(평균)	어노테이션
번역/ 기계독해	●			○		주제별, 언어별, 질의유형별 분포	어노테이션
음성인식/ 음성합성	●			●		화자 속성 분포, 도메인, 환경 관련 정보 분포	메타데이터
질의응답	●					질문유형, 답변유형, 질문/답변 쌍 데이터	어노테이션
클래스 분포 확인	●	●				클래스 분류, 결함 종류, 이미지 캡션 데이터	메타데이터

〈범례〉 ○ : 원시데이터(획득/수집한 데이터 포맷), ● : 원천데이터(학습 시 활용하는 데이터 포맷)

[표 III-150] 사업 목표(임무)별 다양성 항목 도출

- ② 데이터 유형별로 다양성 지표 결정 시 이미지의 경우는 데이터 수집 도구, 환경, 시점을 고려하고, 음성/텍스트 경우는 화자, 문장, 특성, 매체 등을 고려하여 적합한 다양성 지표를 선택하여 적용함

데이터 유형	예시 항목	대상
이미지	촬영 기기 종류(위성, 항공, 드론, CCTV, 블랙박스 등)	메타데이터
	촬영 환경(시간대, 날씨, 계절 등), 촬영 장소(행정/지리적 지역), (기타) 촬영 높이, 방향, 각도 등	
	촬영 시점(일인칭, 삼인칭)	
음성/텍스트	화자/저자 특성(연령대, 성별, 출신/거주지역 등) 분포	메타데이터
	문장길이, 핵심어 분포	
	주제, 도메인, NER(Named Entity Recognition),질의 유형, 감성 및 감정 종류	
	Device, 매체 종류	

[표 III-151] 데이터 유형별 다양성 항목 도출

- ③ 어노테이션 대상별로 다양성 지표 결정 시에는 데이터 유형을 고려하여 적합한 다양성 지표를 선택

대상	텍스트	이미지	비디오	오디오	3D	예시 항목	대상
사람 (이미지, 음성)	●	●	○	●	○	연령대, 성별, 출신 지역(인종) 분포 등	메타데이터
지형 (항공/드론 촬영)		●	○		○	촬영 고도[저고도 (Fine), 고고도 (Coarse)], 촬영기기 종류(위성, 항공, 드론) 분포 등	메타데이터

〈범례〉 ○ : 원시데이터(획득/수집한 데이터 포맷), ● : 원천데이터(학습 시 활용하는 데이터 포맷)

[표 III-152] 어노테이션 대상별 다양성 항목 도출

단, 다양성 항목 선정 시 다양성에 영향을 주지 않은 항목은 제외함

〈참고 : 다양성 항목 도출 시 제외 대상〉

- 값이 달라져도 데이터 다양성에 영향을 주지 않는 속성
〈예〉 촬영 각도(각도 값을 바꾸어도 객체의 특성에 별다른 차이가 없는 경우)
- 데이터 증식(augmentation) 기능의 파라미터에 해당하는 속성(속성의 변화에 따른 데이터를 자동으로 생성할 수 있으므로 데이터 수집 시 별도로 수집할 필요가 없음)
〈예〉 크기(해상도) 변경, 이동, 회전, 상하 반전, 명암 조절, 회색조(grayscale) 등

[표 III-153] 다양성 항목 도출 제외 대상

3.1.4 다양성 항목에 대한 요건/통계 항목 분류

- ‘다양성(요건)’ 항목은 인공지능 데이터의 카테고리, 인스턴스, 환경, 속성 등에 대해 수량 및 구성비의 설정된 목표(충분성 및 균등성 기준)가 존재하는 경우 설정
- ‘다양성(통계)’ 항목은 인공지능 데이터의 카테고리, 인스턴스, 환경, 속성 등에 대해 목표는 없지만, 통계적 분석결과의 확인이 필요한 경우 설정

3.1.5 다양성 항목 지표 기준 및 검사 방법

- 다양성 항목에 대한 지표는 단일 값 또는 분포도 중첩률을 기준으로 목표를 설정하고 구축 시 자체적으로 지표 달성에 대한 검사를 통해 다양성을 만족하는지 확인
- 다양성 항목이 단일값인 경우 지표 기준 및 검사 방법

〈지표가 단일값인 경우 지표 설정 및 검사 방법〉

- 예시 1) 이미지 당 평균 바운딩 박스 수
 - 지표 목표치 설정 기준 : MS COCO, Open Images 등 잘 알려진 데이터셋의 통계를 참고하여 임무에 적합하게 설정
 - 검사 방법 : 전체 바운딩 박스 수 / 전체 이미지 수
 - 목표 달성 기준 : 목표치 대비 결과치가 높을 경우
- 예시 2) XX 범주 최소 ~이상
 - 지표 목표치 설정 기준 : MS COCO, Open Images 등 잘 알려진 데이터셋의 통계를 참고하여 임무에 적합하게 설정
 - 검사 방법 : 최소 구축목표량(예, 경상도 출신 화자음성 최소 1만 건) 이상 구축하였는지 확인
 - 목표 달성 기준 : 목표치 대비 결과치가 높을 경우

[표 III-154] 단일값 지표 설정 및 검사 방법

- 다양성 항목이 분포도 중첩률인 경우 지표 기준 및 검사방법

- ※ 분포도 중첩률: 분포도 중첩률은 두 개 이상의 분포가 얼마나 겹쳐 있는지를 수치적으로 나타내는 지표로 구성비 중첩률로 검사하여 도출한 속성의 목표 구성비 막대그래프와 결과 구성비 막대 그래프간의 길이 중첩 비율을 계산
- ※ 구성비 중첩률: 데이터의 실제 분포와 목표 분포를 막대그래프로 표현하였을 때 중첩되는 부분의 막대길이를 측정하여 비율로 나타낸 것으로, 본 사업을 위해 도입된 지표

〈지표가 분포도 중첩률인 경우 지표 설정 및 검사 방법〉

- 지표 목표치 설정 기준
 - 지표 목표치 설정 기준 : 분포가 매우 균일할 필요는 없으며, 현실적인 수집 상황 등을 고려해서 설정
- 〈예〉 '21년도 반려동물 질병 진단을 위한 영상 데이터(근골격계)

: 질환 및 정상 이미지의 비율을 크게 차이 나게 설정해도 타당한 근거가 있다면 가능함

〈타당한 근거 사유 예시〉

해당 질환에 대해 당 사업 데이터 출처인 중대형 동물병원 내원 비율이 낮아지고 유전적 소인 차단 치료 증가 및 실내 생활 비율 증가에 따라 해당 질병 발생률 저하되고 있음
- 검사 방법 : 도출한 속성의 목표 구성비 막대그래프와 결과 구성비 막대그래프 간의 길이 중첩 비율을 계산

$$\text{구성비 중첩률(\%)} = \frac{\sum_{k=1}^n \text{중첩막대길이}_k}{\sum_{k=1}^n \text{최대막대길이}_k} \times 100$$

- 목표 달성 기준 : 목표치 대비 결과치가 높을 경우

〈지표가 분포도 중첩률인 경우 지표 설정 및 검사 방법〉


〈검사 예시〉

- 다양성 항목 : IoU 50% 이상
- 목표대비 결과 비율

구분	목표	결과	중첩률(IoU)
질환	40%	50%	81.8%
정상	60%	50%	

- 검사 결과 구성비 중첩률(%) = $(40 + 50) / (50 + 60) * 100 = 81.8$

- 구성비 중첩률 표현 그래프 예시



[표 III-155] 중첩률 지표 설정 및 검사 방법

3.2 구문 정확성

3.2.1 개요

- 인공지능 학습용 데이터 구축사업에서 구문 정확성의 대상은 가공데이터로, 가공데이터의 구조, 데이터값 범위 및 형식이 초기 설계 과정에서 정의한 데이터 속성에 따라 정확하게 입력되어 있어야 하며, 누락된 정보가 없도록 작성

예시 : 데이터 속성에 대한 가공데이터(JSON 형식)

데이터 속성						가공데이터
구분	항목명	타입	필수여부	설명	범위	비고
Raw_Data_Info.	Raw_Data_ID	string	Y	원시 파일명	D1_220401_IS01_E0001_IM	"Raw_Data_Info.": { "Raw_Data_ID": "D1_220401_IS01_E0001_IM",
	Copyright	string	Y	소유자	(주)○○○○	"Copyright": "(주)○○○○",
	Location	string	Y	촬영장소 ID	"IS01" ~ "OD01"	"Location": "IS01",
	Date	string	Y	촬영일자 (yyyy-mm-dd)	2022-04-01	"Date": "2022-04-01",
	Length	integer	Y	영상길이 초(sec)	10	"Length": 10,
	Resolution	string	Y	해상도	1920, 1080	"Resolution": "1920, 1080",
	FPS	integer	Y	FPS	60	"FPS": 60,
	F-Stop	string	Y	조리개 수치	F1.8~"F11"	"F-stop": "F/1.8",
	Exposure_Time	string	Y	노출 시간	1/1043~"1/40"	"Exposure_Time": "1/1043",
	Target_type	string	Y	폐색유형	"Static"(일정형), "Dynamic"(유동형)	"Target_type": "Static",
Source_Data_Info.	Angle	string	Y	촬영 각도	Low(로우앵글), "Eye"(아이앵글), "High"(하이앵글)	"Angle": "Eye", "File_Extension": "mp4"}, "Source_Data_Info.": { "Source_Data_ID": "D1_220401_IS01_E0001_IM_L03_0001",
	File_Extension	string	Y	원시 파일 확장자	mp4	"Time_start": "00:00:13:05"
	Source_Data_ID	string	Y	이미지 파일명	D1_220401_IS01_E0001_IM_L03_0001	"Time_end": "00:00:15:02"
	Time_start	string	N	시작시간	00:00:13:05	"Occlusion_level": "L01",
	Time_end	string	N	종료시간	00:00:15:02	"File_Extension": "jpg"}, "Learning_Data_Info.": { "Path": "//I-210501/",
Learning_Data_Info.	Occlusion_Level	string	N	폐색등급	"L01" ~ "L05"	"File_Extension": "JSON",
	File_Extension	string	Y	이미지 확장자	jpg	"Json_Data_ID": "D1_220401_IS01_E0001_IM_L03_0001",
	Path	string	Y	Json 폴더 경로	//I-210501/	"Annotations": [{ "Class_ID": "Human",
	File_Extension	string	Y	Json	JSON	"Object_type": "Target_object",
	Json_Data_ID	string	Y	Json 파일명	D1_220401_IS01_E0001_IM_L03_0001	"Object_num": "1",
	Annotations	array	Y		[]	"Type": "Bounding_Box",
	Class_ID	string	Y	객체 ID	Human	"Type_value": [1,0, 0,903, 574,634,
	Object_Type	string	Y	객체유형	"Target_object", "Occlusion_object"	576,0], "Class_size": 2345,
	Object_num	string	Y	Object 번호	"1"~"10"	"Occlusion_size": 1232,
	Type	string	Y	어노테이션 종류	"Segmentation", "Bounding_box"	"Occlusion_rate": "52%", }] } }
	Type_value	array	Y	[x,y, x,y, ...]	[1,0, 0,903, 574,634, 576,0, ...]	
	Class_size	integer	Y	객체크기(pixel)	2345	
	Occlusion_size	integer	Y	폐색크기(pixel)	1232	
	Occlusion_rate	string	Y	폐색비율(%)	"0%"~"95%"	

[표 III-156] 데이터 속성에 대한 가공데이터 예시

3.2.2 지표 설정 기준

- 구문 정확성은 가공데이터에 대한 무결성, 구조 정확성, 형식 정확성으로 구성되는데, 무결성은 가공데이터가 읽기 실행에 이상이 없어야 되는 것은 필수적인 사항이므로 기준치 설정에서는 제외되며, 구조 정확성과 형식 정확성에 대한 지표 설정 기준은 다음과 같음

※ 제시한 정량목표(예시)는 과제 특성에 따라 다르게 적용될 수 있으므로 참고용으로 활용

〈구문 정확성 지표 설정 기준〉

- 구문 정확성의 검사 항목은 구조 정확성과 형식 정확성

구분	기준치(예시)	검사 항목
구조 정확성	99.5%	구문 정확성 - 데이터 구조
형식 정확성	99.5%	구문 정확성 - 데이터값 범위, 데이터 형식

[표 III-157] 구문 정확성 지표 설정 기준


구문 정확성 오류 예시

- JSON 스키마 기준 구문 정확성 오류 항목 예시

타입	설명
array	· array를 구성하는 아이템의 최소 개수에 미달
	· array를 구성하는 아이템의 최대 개수를 넘음
string	· 문자열 최소 길이보다 짧음
	· 문자열 최대 길이보다 길음
	· 문자열 허용 포맷 외 포맷이 사용
	· format 항목: date(날짜), regExp(정규표현식), email(이메일), ipv4(ip주소), ipv6(ip주소), url(URL)
	· date(날짜), regExp(정규표현식)에 한하여 expression 미작성
object	· 허용 가능 문자열 외 문자가 존재
	· 허용 가능하지 않은 객체 내 속성
number	· 숫자 최소 허용 값에 미달
	· 숫자 최대 허용 값을 초과
	· 숫자 허용 배수를 위배
	· 허용 가능 숫자를 위배
기타	· 항목의 값 null 허용 가능하지 않은 값인데 null 표기

3.2.3 지표 검사 방법

- 구문 정확성에 대한 검사절차는 가공데이터에 대한 ① 무결성 확인, ② 구조 정확성 검사, ③ 형식 정확성 검사의 단계로 수행



[그림 III-9] 지표 검사절차

- ① 무결성 확인은 가공데이터가 읽기 실행 시 이상이 없는 경우만 구조/형식에 대한 정확성 검사를 수행하고, 이상이 있는 경우는 검사를 중지하고 문제점을 확인 및 조치
- ② 구조 정확성은 가공 파일 내 항목에 대한 구조적 문제를 점검하는 것으로 필수항목 누락 여부(구문 규칙(스키마)에 정의된 필수항목(객체, 속성)의 누락 여부)와 유효 항목 여부(구문 규칙(스키마)에 정의되지 않은 항목(객체, 속성)이 가공 파일에 있는지 확인)를 검사
- ③ 형식 정확성은 가공데이터의 항목별 형식을 점검하는 것으로 가공데이터 내 규칙위반 여부(Value 없음, Value Type 에러, 특정 항목의 상세 검증 조건위반 등)를 검사
- 구조 정확성과 형식 정확성은 “정확도 = 100 - [(오류건수 / 전체 항목 수) × 100]”로 계산하고, 그 결과값을 목표치와 비교하여 달성 여부 확인

3.3 의미 정확성

3.3.1 개요

- 의미 정확성이란 데이터 가공(정답 어노테이션)의 품질을 측정하기 위한 품질특성으로 예를 들어, 임무가 이미지 탐지인 경우 의미 정확성은 인스턴스를 둘러싸는 바운딩 박스의 위치 정보와 분류 태그 작업이 정답 수준에 맞게 잘 되어 있는지를 판별하여 통계를 내는 것임
- 이러한 의미 정확성 품질특성을 적용 시 사업 목표(임무), 데이터 종류와 데이터 가공(또는 데이터 어노테이션) 방법에 따라 적합한 지표와 목표를 설정
- 또한, 정답 어노테이션의 품질을 확인하는 의미 정확성 지표는 정답 어노테이션이 기재된 학습용 데이터로 임무에 적합한 시모델을 학습하고 평가해서 드러나는 성능을 확인하는 유효성 지표의 부분 집합이라고 볼 수 있음
- 단, 의미 정확성 지표 측정 시 기재한 분류 클래스 명(코드) 하나만 확인하면 되므로 임계치 변화에 기반하는 지표(AUC, AP 등)는 의미 정확성 지표로 선택하는 것은 지양
- 이러한 의미 정확성 지표 선택 시 『2.1 데이터 유형별 학습 Task』의 데이터 유형별 학습 Task를 참조하여 선택함

3.3.2 텍스트

- 인공지능 학습데이터 구축 목표 또는 임무 정의 시 적합한 데이터 종류가 텍스트인 경우 의미 정확성 지표를 선정하기 위해 구축 목표 또는 임무에 적합한 학습 Task를 결정

학습 Task	개 념
텍스트 분류 (Text Classification)	문장이나 문서를 적절한 범주로 지정하는 작업으로, 범주는 선택한 데이터셋에 따라 다르며 주제 범위가 다양할 수 있음
텍스트 요약 (Text Summary)	상대적으로 큰 원문을 핵심 내용만 간추려서 상대적으로 작은 요약문으로 변환하는 작업
기계 번역 (Machine Translation)	인공지능을 이용해 인간이 사용하는 자연어를 다른 자연어로 번역하는 작업
순차적 레이블링 (Sequence Labeling)	입력 시퀀스에 대하여 레이블 시퀀스를 각각 부여하는 작업으로, 태깅 작업이 대표적인 순차적 레이블링의 예시임
질의응답 (Question Answering)	질문(일반적으로 독해 질문)에 답변하는 작업으로서, 제공된 컨텍스트를 기반으로 답변할 수 없는 질문이 제시되면 기권함
음성 인식 (Speech Recognition)	사람이 말하는 음성 언어를 인공지능이 해석해 그 내용을 문자 데이터로 전환하는 작업

[표 III-158] 텍스트 학습 Task(의미 정확성)

- 학습 Task가 결정되면 적합한 가공 유형과 품질측정항목(예시)을 참고하여 품질과 관련된 품질지표 및 정량목표 범위(예시)를 선택하여 활용

※ 제시한 정량목표범주(예시)는 과제 특성에 따라 다르게 적용될 수 있으므로 참고용으로 활용

TASK 분야	가공 유형	측정지표	품질검사 항목(예시)	정량목표범주(예시)
기계 번역 (Machine Translation)	Machine Translation	정확도	번역 정확도	90 ~ 95
			번역 정확도_영어	90 ~ 95
			번역 정확도_중국어	90 ~ 95
			번역 정확도_일본어	90 ~ 95
			문장 단위 번역 정확도(교정 문장)	90 이상
			베트남어-영어 번역 적정성	95 이상
			베트남어-한국어 번역 적정성	95 이상
			한국어-베트남어 번역 적정성	90 이상
			한국어-인도네시아어 번역 적정성	90 이상
			한국어-캄보디아어 번역 적정성	90 이상
			한국어-태국어 번역 적정성	90 이상
기계 번역	Tagging	정확도	말뭉치 문장 품질	90 이상

TASK 분야	가공 유형	측정지표	품질검사 항목(예시)	정량목표범주(예시)
(Machine Translation)			NER 정확성	90 이상
			번역 가공 정확도(영어)	95 이상
			번역 가공 정확도(중국어-간체)	95 이상
			번역 가공 정확도(중국어-번체)	95 이상
			번역 가공 정확도(일본어)	95 이상
질의응답 (Question Answering)	Class Labeling	정확도	질의 난이도 분류 정확성	90 이상
			질의응답 멀티턴 문맥 유지 정확성	90 이상
			유해질의 분류 정확성	95 이상
			개체명 태깅 적정성	95 이상
			QA문맥 적정성	95 이상
	Sequence Labeling	정확도	지문-질의-응답 간 내용 일치성	95 이상
			질의 정확성	90 ~95
			응답 정확성	90 ~95
			기계 독해 질문의 정확성	90 이상
			기계 독해 정답의 정확성	90 이상
			말뭉치 문법 적정성	95 이상
			서술형 질의응답 정확도	90 이상
			객관식 질의응답 정확도	90 이상
	Tagging	정확도	대화 품질 적합성	95 이상
			질문자 발화 적합성	95 이상
			자연어 발화-SQL 질의문 의미 일치성	90 이상
			SQL 질의 문법 정확성	90 이상
			질의 문장 품질	95 이상
			질의 문장 정확성	90 이상
			질의 난이도 적합성	90 이상
			질의 답변 정확성	90 이상
			답변 태깅 정확성	90 이상
			동의 질문 정확성	90 이상
			사실근거 출처 정확성	90 이상
			여행객 및 소비 내역 로그 정확성	95 이상
			여행 장소 로그 정확성	95 이상

III

부록

TASK 분야	가공 유형	측정지표	품질검사 항목(예시)	정량목표범주(예시)
순차적 레이블 (Sequence Labeling)	Sequence Labeling	정확도	페르소나 반영 적정성	90 이상
			세션 간 시간 간격 반영 적정성	90 이상
			전문지식 대화 적정성	90 이상
	Tagging	재현율	Relation 정확성	95 이상
		정밀도	Entity 정확성	95 이상
		정확도	주제 연관성 유지 적정성	90 이상
			관계 Triple 정확도	95 이상
			수식 가공 정확성	90 이상
			사건(EVENT) 태깅 정확성	90 이상
			시간 관계(TLINK) 태깅 정확성	90 이상
음성 인식 (Speech Recognition)	Tagging	정확도	자연어 발화 정확성	90 이상
			NER 태깅 정확도	90 이상
	Transcription	정확도	전사 정확도	90 이상
텍스트 분류 (Text Classification)	Class Labeling	정확도	오류 유형 분류 정확도	95 이상
			제목-본문 패턴 유형 정확도	95 이상
			본문-도메인 패턴 유형 정확도	95 이상
			교통 유발 시설물 분류 정확도	95 이상
			교통수단판별 정확도	95 이상
			통행 궤적 정확도	95 이상
			질환명 분류 태그 정확성	99 이상
			앞, 가지 분류 정확성	95 이상
			종합정신건강위험도 분류 태그 정확성	95 이상
			주제 분류 정확도	90 이상
			주제 분류 태깅 정확성	95 이상
			상담 난이도 적정성	95 이상
	Sequence Labeling	정확도	오류 문장 교정 정확도	90 이상
			문장 형태 정확도	90 이상
	Tagging	정확도	페르소나의 대화 반영 적합성	95 이상

TASK 분야	가공 유형	측정지표	품질검사 항목(예시)	정량목표범주(예시)
			페르소나 프로필 적합성	95 이상
			전문가 발화 적합성	95 이상
			문서 정보 태깅 정확성	95 이상
			인터뷰 주제 분류 태그 정확성	95 이상
			주제 분류 정확성	95 이상
			정보 유형 분류 정확성	95 이상
			감정 가공 적합성	90 이상
			형태소 가공 정확도	95 이상
			개념 집합 가공 정확도	95 이상
			문장 생성 정확도	90 이상
			문형 정확도	90 이상
			민감정보 처리 정확도	99 이상
			척도 정확도	90 이상
			한국어 철자 및 맞춤법 오류 유형 태깅 정확성	90 이상
			한국어 철자 및 맞춤법 오류 교정문 정확도	90 이상
			STT 오류 유형 태깅 정확성	90 이상
			STT 오류 교정문 정확성	90 이상
			과교정 오류 유형 태깅 정확성	90 이상
			문서 단위 오류 심각도 태깅 정확도	90 이상
			문장 단위 DA Scoring 정확도	90 이상
			어절 단위 오류 태깅 정확도	90 이상
			오류 유형 태깅 정확도	90 이상
			특수라벨 태깅 정확도(일)	90 이상
			특수라벨 태깅 정확도(중)	90 이상
			특수라벨 태깅 정확도(영)	90 이상
			사망 사건 분류 태그 정확성	99 이상
			입원 사건 분류 태그 정확성	99 이상
			심혈관계 질환 사건 분류 태그 정확성	99 이상
			신장기능 악화 사건 분류 태그 정확성	99 이상
			사구체 여과율 분류 태그 정확성	99 이상
			단백뇨 검출 여부 분류 태그 정확성	99 이상

TASK 분야	가공 유형	측정지표	품질검사 항목(예시)	정량목표범주 (예시)
			당화혈색소 정상 여부 분류 태그 정확성	99 이상
			심장질환 분류 태그 정확성	95 이상
			호흡기질환 분류 태그 정확성	95 이상
			근골격계 분류 태그 정확성	95 이상
			건강인 분류 태그 정확성	95 이상
			스토리 장르 적정성	90 이상
			스토리 모티프 적정성	85 이상
			대본 형식 정확도	99 이상
			속성어휘 태깅 정확성	95 이상
			리뷰 문장 적합성	95 이상
			속성어휘에 대한 감정 태깅 정확성	90 이상
			표 기준 정확성	90 이상
			전문 용어 태깅 정확성	90 이상
			분야 분류 정확성	90 이상
			전문 용어(NE) 태깅 정확성	90 이상
			오류 유형 태깅 정확성	90 이상
			시간 표현 태깅 정확성	90 이상
			시간 표현 정규화 정확성	90 이상
			문장 유형 분류 정확도	95 이상
			확실성 태깅 정확도	95 이상
			시제 태깅 정확도	95 이상
			극성 태깅 정확도	95 이상
			용어 정의문 정확성	95 이상
			도메인별 BT(상의어) 태깅 정확도	95 이상
			도메인별 NT(하의어) 태깅 정확도	95 이상
			도메인별 RT(관련어) 태깅 정확도	95 이상
			용어 태깅 정확성	95 이상
			패시 분류 정확성	95 이상
			동형이의어 태깅 정확성	95 이상
			국가중점기술분류, 6T 분류 태깅 정확도	95 이상
			과학기술표준 분류 태깅 정확도	95 이상

TASK 분야	가공 유형	측정지표	품질검사 항목(예시)	정량목표범주(예시)
			화합물 생리활성 태깅 정확도	90 이상
			정답 여부 태그 정확성	95 이상
			이해 여부 태그 정확성	95 이상
			감정 여부 태그 정확성	95 이상
			우울 증상 및 불면 증상 분류 태그 정확성	95 이상
			직업군 추천 라벨 정확도	90 이상
			임무 수행 명령어 정확성	95 이상
			대화 주제 라벨 정확성	90 이상
			카테고리 분류 정확도	95 이상
			이상거래 태깅 정확성	95 이상
			물체 상태 라벨링 정확성	95 이상
			로봇팔 6자유도 파지 자세 라벨링 정확성	95 이상
			문제성 피부 태깅 정확성	95 이상
			대화의도 적정성	95 이상
텍스트 요약 (Text Summary)	Tagging	정확도	생성 요약문 정확성	90 이상
			키워드(핵심단어) 태깅 정확성	90 이상
			전체 수정요약문 정확성	90 이상
	Text Summary	정확도	세션 요약 정확도	90 이상
			스토리 요약 품질 적정성	95 이상
			요약문 데이터의 요약 적정성	95 이상
			요약문 정확도	90 이상
			주제어 적정성	95 이상
			오류 유형별 수정요약문 정확성	90 이상
추론 (Reasoning)	CoT (Chain-of-Reasoning)	정확도	추론 적절성	90 이상
			추론 일관성	90 이상

[표 III-159] 텍스트 학습 Task 분야별 품질측정항목(의미 정확성)

3.3.3 이미지

- 인공지능 학습데이터 구축 목표 또는 임무 정의 시 적합한 데이터 종류가 이미지인 경우 의미 정확성 지표를 선정하기 위해 구축 목표 또는 임무에 적합한 학습 Task를 결정

학습 Task	개 념
객체 인식 (Object Detection)	• 이미지 내에서 특정 클래스의 객체 인스턴스를 인식하는 작업
키폰트 검출 (Keypoint Detection)	• 동작 인식을 위해 필요한 주요 키폰트를 검출하는 작업
얼굴 인식 (Face Recognition)	• 얼굴을 사용하여 개인의 신원을 식별하거나 확인하는 작업
이미지 분류 (Image Classification)	• 특정 이미지를 알고리즘에 입력했을 때, 그 이미지가 어떤 클래스에 속하는지 알려주는 작업
자세 추정 (Pose Estimation)	• 객체의 주요 부분에 대한 위치, 방향을 식별하여 자세를 추정하는 작업
인스턴트 세그멘테이션 (Instance Segmentation)	• 개체의 감지된 각 인스턴스에 대한 분할 맵을 생성하는 향상된 유형의 세그멘테이션 분할 작업
시멘틱 세그멘테이션 (Semantic Segmentation)	• 동일한 객체 클래스에 속하는 이미지 부분을 함께 클러스터링하는 작업
팬옵틱 세그멘테이션 (Panoptic Segmentation)	• Semantic Segmentation과 Instance Segmentation을 결합 방식으로 배경이 되는 부분까지 세그멘테이션 분할 작업
광학 문자 인식 (Optical Character Recognition)	• 사람이 쓰거나 기계로 인쇄한 문자의 영상을 이미지 스캐너로 획득하여 기계가 읽을 수 있는 문자로 변환하는 작업
질의응답 (Question Answering)	• 이미지에 대한 질문(일반적으로 독해 질문)에 답변하는 작업으로서, 제공된 이미지를 기반으로 답변하는 작업
순차적 레이블링 (Sequence Labeling)	• 이미지 입력 시퀀스에 대하여 레이블 시퀀스를 각각 부여하는 작업으로, 태깅 작업이 대표적인 순차적 레이블링의 예시임
이미지 캡셔닝 (Image Captioning)	• 이미지를 캡처하여 필요한 작업을 식별하거나 구분하는 작업

[표 III-160] 이미지 학습 Task(의미 정확성)

- 학습 Task가 결정되면 적합한 가공 유형과 품질측정 항목(예시)을 참고하여 품질과 관련된 측정지표 및 목표치를 선택하여 활용

TASK 분야	가공 유형	측정지표	품질검사 항목(예시)	정량목표범주(예시)
얼굴 인식 (Face Recognition)	Bounding Box	$F\beta$ -점수	바운딩 박스 정확성	90 이상
	Keypoint	$F\beta$ -점수	키포인트 정확성	90 이상
	Tagging	정확도	표정 태그 정확성	95 이상
이미지 캡셔닝 (Image Captioning)	Image Captioning	정확도	이미지 캡셔닝 가공	90 이상
			이미지 캡션 정확성	95 이상
			시각요소와 설명문 일치성	95 이상
			시각요소와 참조텍스트 일치성	95 이상
			시각요소에 대한 캡션 일치성	95 이상
			판독문 일치성	90 이상
			논문-포스터 간 내용 일치성	90 이상
			이미지-캡션 내용 일치성	95 이상
			이미지캡션-로봇 행동 일치성	95 이상
			이미지캡션-로봇 행동 정렬성	95 이상
			로봇 상태 - 캡션 일치성	95 이상
			로봇 상태 - 캡션 정렬성	95 이상
	재현율		판독문 포괄성	90 이상
			판독문 문체 준수	90 이상
이미지 분류 (Image Classification)	Bounding Box	정확도	발아객체 번호 위치 정확성(종자 발아)	90 이상
			홍삼 품질 분류 정확성	90 이상
			품질 등급 분류 정확도	90 이상
			중결점 분류 정확도	95 이상
	Class Labeling	재현율	관계 태그 정확성	90 이상
		정밀도	관계 태그 정확성	90 이상
		정확도	블러 분류 정확성	90 이상
			대구치 관계 분류 태그 정확성	90 이상
			심전도 파형 분류 태그 정확성	90 이상
			인공호흡기 파형데이터 분류 태그 정확성	95 이상
			배아 등급 분류 태그 정확성	90 이상
			태아 상태 진단 분류 태그 정확성	95 이상
			질환명 분류 태그 정확성	99 이상

TASK 분야	가공 유형	측정지표	품질검사 항목(예시)	정량목표범주(예시)
			Chest X-ray 질환명 분류 태그 정확성	95 이상
			Mammography X-ray 질환명 분류 태그 정확성	95 이상
			PNS X-ray 질환명 분류 태그 정확성	95 이상
			Skull X-ray 질환명 분류 태그 정확성	95 이상
			Foot X-ray 질환명 분류 태그 정확성	95 이상
			복부 질환명 분류 태그 정확성	95 이상
			흉부 질환명 분류 태그 정확성	95 이상
			뇌종양 MRI 질환명 분류 태그 정확성	95 이상
			파지/조작 행동 분류 정확성	90 이상
			치계 분류 태깅 정확성	95 이상
			동작명 분류 라벨 정확성	90 이상
			분류 라벨 정확도	90 이상
			적지 이미지 유형 분류 정확성	90 이상
			건물/부재 분류 태깅 정확성	95 이상
			모래 품질 분류 태그 정확성	95 이상
			치아 번호 분류 태그 정확성	95 이상
			공간 분류 태그 정확성	90 이상
			질병 유발 환경 분류 정확성	95 이상
			피부질환 분류 정확성	95 이상
			논문-포스터 구조 적정성	90 이상
			이미지-정보 내용 매칭성	95 이상
	Segmentation	재현율	의류 세그멘테이션 정확성	90 이상
			액세서리 세그멘테이션 정확성	95 이상
		정밀도	의류 세그멘테이션 정확성	90 이상
			액세서리 세그멘테이션 정확성	95 이상
		정확도	수지량 단계 분류 정확성	95 이상
	Sequence Labeling	정확도	문제 구성 정확성	90 이상
	Tagging	정확도	의류 태그 정확성	95 이상
			초해상화 이미지 페어링 정확성	90 이상
			안구 움직임 분류 태그 정확성	90 이상
			눈감박임 분류 태그 정확성	90 이상

TASK 분야	가공 유형	측정지표	품질검사 항목(예시)	정량목표범주(예시)
			CDT 점수 분류 태그 정확성	90 이상
			신생아 카테터 객체 영역 분류 태그 정확성	90 이상
			상호작용 태그 정확성	95 이상
			물체 간 가림 관계 그래프 태그 정확성	95 이상
			질병 분류 정확성	90 이상
			수위 참값 태깅 정확성	95 이상
			생체신호 기반 관절염 라벨링 정확성	95 이상
인스턴스 세그멘테이션 (Instance Segmentation)	Polygon	재현율	자재 폴리곤 정확성	90 이상
		정밀도	자재 폴리곤 정확성	90 이상
		정확도	폴리곤 정확성(항공/드론 이미지)	90 이상
	Segmentation	F β -점수	세그멘테이션 정확성	90 ~ 99
			폴리곤 세그멘테이션 정확성	90 이상
			금융 세그멘테이션 정확성	95 이상
			물류 세그멘테이션 정확성	95 이상
			연어치어 세그멘테이션 정확성	95 이상
			명태치어 세그멘테이션 정확성	95 이상
			도로부속시설물 세그멘테이션 정확성	95 이상
			수중 생활폐기물 세그멘테이션 정확성	90 이상
			증상 세그멘테이션 정확성	80 이상
		재현율	세그멘테이션 정확성	90 ~ 95
			의류 세그멘테이션 정확성	90 이상
			의류 착용 세그멘테이션 정확성	90 이상
			객체, 전경 및 배경 인스턴스 세그멘테이션 정확성	90 이상
		정밀도	세그멘테이션 정확성	90 ~ 95
			의류 세그멘테이션 정확성	90 이상
			의류 착용 세그멘테이션 정확성	90 이상
			객체, 전경 및 배경 인스턴스 세그멘테이션 정확성	90 이상
		정확도	치아 경계 세그멘테이션 정확성	95 이상
			충치 세그멘테이션 정확성	90 이상
			입술경계 세그멘테이션 정확성	95 이상
			배아 구성요소 세그멘테이션 정확성	90 이상

III

부록

TASK 분야	가공 유형	측정지표	품질검사 항목(예시)	정량목표범주(예시)
			척추 위치 및 횡경막 경계 세그멘테이션 정확성	90 이상
			카테터 세그멘테이션 정확성	90 이상
			정상 및 폐 영역 세그멘테이션 정확성	90 이상
			복부 질환 세그멘테이션 정확성	90 이상
			물체 마스크 영역 가공 정확성	90 이상
			마디(화아분화) 세그멘테이션 정확성	95 이상
			마디(암/수꽃) 세그멘테이션 정확성	95 이상
			미수정암꽃(갈변) 세그멘테이션 정확성	95 이상
			치은염 세그멘테이션 정확성	95 이상
			충치 세그멘테이션 정확성	95 이상
			보철물 세그멘테이션 정확성	95 이상
			치석 세그멘테이션 정확성	95 이상
			치아 번호 세그멘테이션 정확성	95 이상
			뇌부위 세그멘테이션 정확성	95 이상
			공간 영역분할 정확성	90 이상
			2D 물체 영역분할 정확성	90 이상
키포인트 검출 (Keypoint Detection)	Keypoint	F β -점수	키포인트 정확성	90 ~ 95
			2D 키포인트 정확성	90 이상
		PCK	관절 키포인트 정확성	95 이상
			축구공 키포인트 정확성	95 이상
		재현율	의류 착용 키포인트 정확성	90 이상
			모델 키포인트 정확성	90 이상
			사람 키포인트 정확성	95 이상
			파지/조작 손 관절 키포인트 정확성	90 이상
			파지점 포인트 정확성	90 이상
			키포인트 정확성	90 ~ 95
		정밀도	의류 착용 키포인트 정확성	90 이상
			모델 키포인트 정확성	90 이상
			사람 키포인트 정확성	95 이상
			파지/조작 손 관절 키포인트 정확성	90 이상
			파지점 포인트 정확성	90 이상
			키포인트 정확성	90 ~ 95

TASK 분야	가공 유형	측정지표	품질검사 항목(예시)	정량목표범주(예시)
객체 인식 (Object Detection)		정확도	2D 키포인트 정확성	90 ~ 95
			청력역치 키포인트 정확성	95 이상
			SP/AP ratio 키포인트 정확성	95 이상
			주파수별 청력역치 키포인트 정확성	95 이상
			배드민턴 선수 객체 키포인트 정확성	90 이상
			키포인트 정확성	90 이상
			작업 자세 키포인트 정확성	90 이상
	Bounding Box	F β -점수	2D 바운딩 박스 정확성	95 이상
			바운딩 박스 정확성	90 ~ 95
			P&ID 심볼 바운딩 박스 라벨 정확성	95 이상
			바운딩 박스 라벨 정확성	95 이상
			배드민턴 선수 및 심판 객체 바운딩 박스 정확성	90 이상
			MONO 계란 데이터 바운딩 박스 정확성	95 이상
			COLOR 계란 데이터 바운딩 박스 정확성	95 이상
			보관 기간 계란 데이터 바운딩 박스 정확성	95 이상
			전신 바운딩 박스 정확도	95 이상
			부위별 바운딩 박스 정확도	95 이상
			작업 객체 바운딩 박스 정확성	95 이상
			2D RGB 이미지 바운딩 박스 정확성	95 이상
			2D NIR 이미지 바운딩 박스 정확성	95 이상
			이안류 바운딩 박스 정확성	90 이상
			목자판 바운딩 박스 정확성	95 이상
			수위 바운딩 박스 정확성	95 이상
			증상 바운딩 박스 정확성	90 이상
			개체 바운딩 박스 정확성	90 이상
			음식 바운딩 박스 정확성	90 이상
		IoU	얼굴 구성요소 바운딩 박스 정확성	80 이상
		MOTA	타겟 객체 추적 정확성	90 이상
			바운딩 박스 정확성	90 이상
			바운딩 박스 정확성(추적 대상)	90 이상
		재현율	바운딩 박스 정확성	90 ~ 95
			사람 및 객체 바운딩 박스 정확성	95 이상

TASK 분야	가공 유형	측정지표	품질검사 항목(예시)	정량목표범주(예시)
			유동형 폐색 영상 바운딩 박스 정확성	90 이상
			파지 가능지점 바운딩 박스 정확성	90 이상
			파지/조작 대상 객체에 대한 바운딩 박스	90 이상
			차량번호판	90 이상
			차종외관	90 이상
			바운딩 박스 정확성(추적 비대상)	95 이상
			입출고 데이터 바운딩 박스 정확성	90 이상
		정밀도	바운딩 박스 정확성	90 ~ 95
			사람 및 객체 바운딩 박스 정확성	95 이상
			유동형 폐색 영상 바운딩 박스 정확성	90 이상
			파지 가능지점 바운딩 박스 정확성	90 이상
			파지/조작 대상 객체에 대한 바운딩 박스	90 이상
			차량번호판	90 이상
			차종 외관	90 이상
			바운딩 박스 정확성(추적 비대상)	95 이상
			입출고 데이터 바운딩 박스 정확성	90 이상
			전통가옥 구성요소 바운딩 박스 정확성	90 이상
		정확도	바운딩 박스 정확성	90 ~ 95
			대상 장기 바운딩 박스 정확성	95 이상
			흉부X선-심장 영역 바운딩 박스 정확성	95 이상
			흉부X선-폐 영역 바운딩 박스 정확성	95 이상
			배아 바운딩 박스 정확성	95 이상
			이상시점 분류 태그 기반 바운딩 박스 정확성	90 이상
			Cup 바운딩 박스 정확성	95 이상
			Disc 바운딩 박스 정확성	95 이상
			화상 부위 바운딩 박스 정확도	95 이상
			차량 번호판	95 이상
			차종 외관	90 이상
			바운딩 박스 정확성(이미지 데이터)	90 이상
			바운딩 박스 정확성(SAR 이미지)	90 이상

TASK 분야	가공 유형	측정지표	품질검사 항목(예시)	정량목표범주(예시)
			출혈 바운딩 박스 정확성	95 이상
	Class Labeling	$F\beta$ -점수	정상/비정상 주행 분류 태깅 정확성	95 이상
		정확도	화상 단계 태그 정확도	99 이상
			OSA 위험 유무에 따른 분류 태그 정확도	99 이상
			폐질환 분류 태그 정확성	99 이상
			교통 분류 정확성	90 이상
			선박 도장 품질 분류 라벨 정확성	95 이상
			분류라벨 정확도(2D 이미지)	90 이상
			작업 자세 분류 태깅 정확성	80 이상
	Keypoint	재현율	키포인트 정확성	90 이상
		정밀도	키포인트 정확성	90 이상
	Polygon	$F\beta$ -점수	폴리곤 정확도	90 ~ 95
			선박 도장 품질 폴리곤 라벨 정확성	95 이상
			배드민턴 코트 및 네트 객체 폴리곤 정확성	90 이상
		재현율	폴리곤 정확성	90 ~ 95
		정밀도	폴리곤 정확성	90~ 95
		정확도	탄소량 정확성	95 이상
			이미지 2차원 폴리곤	95 이상
			신호최적화 데이터	95 이상
	Polyline	$F\beta$ -점수	폴리라인 정확성	90 이상
		재현율	폴리라인 정확성	90 이상
		정밀도	폴리라인 정확성	90 이상
		정확도	치촉 폴리라인 정확성	90 이상
			안모 중심선 폴리라인 정확성	90 이상
	Segmentation	정확도	세그멘테이션 정확성	95 이상
		재현율	영상 데이터	95 이상
		정확도	영상 데이터	95 이상
	Tagging	$F\beta$ -점수	속성 정확성	90 이상
		재현율	HOI 태그 정확성	95 이상
			OCR 라벨 정확도	95 이상
		정밀도	HOI 태그 정확성	95 이상
			OCR 라벨 정확도	95 이상

III

부록

TASK 분야	가공 유형	측정지표	품질검사 항목(예시)	정량목표범주(예시)
			상표 분류 비엔나 코드 가공 정확성	70 이상
			해외상표 가공 정확성	70 이상
			사용자 입력 상표 가공 정확성	70 이상
		정확도	객체 쌍 시각적 유사도	99 이상
			집단행동 구간 태그 정확성	95 이상
			수목화 화풍 태그 정확성	95 이상
			폐음 환자 정보 정확성	99 이상
			CMF 표현 분류 태그 정확성	95 이상
			철자 정확성	95 이상
광학 문자 인식 (Optical Character Recognition)	Text Summary	정확도	설명문 정확성(영문)	90 이상
			설명문 정확성(국문)	90 이상
	Machine Translation	리커트 척도	설명문 영-한 번역 정확성	90 이상
		정확도	메뉴명 지식정보 번역 정확성(영어)	90 이상
			메뉴명 지식정보 번역 정확성(일본어)	90 이상
			메뉴명 지식정보 번역 정확성(중국어-간체)	90 이상
			메뉴명 지식정보 번역 정확성(중국어-번체)	90 이상
팬옵틱 세그멘테이션 (Panoptic Segmentation)	Segmentation	F β -점수	Panoptic Segmentation 정확성	90 이상
		재현율	일정형 폐색 영상 세그멘테이션 정확성	90 이상
			팬옵틱 세그멘테이션 정확성	90 이상
		정밀도	일정형 폐색 영상 세그멘테이션 정확성	90 이상
			팬옵틱 세그멘테이션 정확성	90 이상
자세 추정 (Pose Estimation)	Segmentation	정확도	물체 6D 자세 정확성	90 이상
질의응답 (Question Answering)	Tagging	정확도	설문지 적합성	90 이상
			이미지에 대한 사실근거 정확성	90 이상
			질의 문장 정확성	90 이상
			질의 답변 정확성	90 이상
			QA 가공	85 이상
시멘틱 세그멘테이션 (Semantic Segmentation)	Segmentation	F β -점수	세그멘테이션 정확성	90 이상
			Polygon segmentation 정확성	95 이상
			Ellipse segmentation 정확성	95 이상

TASK 분야	가공 유형	측정지표	품질검사 항목(예시)	정량목표범주(예시)
			세그멘테이션 라벨 정확성	95 이상
			2D 객체 세그멘테이션 정확성	90 이상
			새조개 종자 객체 세그멘테이션 정확성	90 이상
			바지락 종자 객체 세그멘테이션 정확성	90 이상
			토지피복 클래스 세그멘테이션 정확성	95 이상
			고해상도 영상 토지피복 세그멘테이션 정확성	90 이상
			저해상도 영상 토지피복 세그멘테이션 정확성	88 이상
		재현율	세그멘테이션 정확성	90 ~ 95
			2D 세그멘테이션 정확성	85 ~ 90
		정밀도	세그멘테이션 정확성	85 ~ 95
			2D 세그멘테이션 정확성	85 ~ 90
		정확도	병변 세그멘테이션 정확성	90 이상
			폐암 병변 세그멘테이션 정확성	95 이상
			악성 림프종 병변 세그멘테이션 정확성	95 이상
			표피낭종 세그멘테이션 정확성	95 이상
			지루각화증 세그멘테이션 정확성	95 이상
			보웬병/편평상피암 세그멘테이션 정확성	95 이상
			기저세포암 세그멘테이션 정확성	95 이상
			멜라닌 세포 모반 세그멘테이션 정확성	95 이상
			흑색종 세그멘테이션 정확성	95 이상
			화상 부위 세그멘테이션 정확도	95 이상
			2D Sementic Segmentation 가공 정확성(실환경)	90 이상
			2D Sementic Segmentation 가공 정확성(가상환경)	90 이상
			감귤나무 세그멘테이션 정확성	95 이상
			장기 세그멘테이션 정확성	95 이상
			하천부지 점유형태 세그멘테이션 정확성	90 이상
			세그멘테이션 정확성	95 이상
순차적 레이블링 (Sequence Labeling)	Tagging	정확도	트리플 가공	85 이상

[표 III-161] 이미지 학습 Task 분야별 품질측정항목(의미 정확성)

※ 제시한 정량목표범주(예시)는 과제 특성에 따라 다르게 적용될 수 있으므로 참고용으로 활용

3.3.4 비디오

- 인공지능 학습데이터 구축 목표 또는 임무 정의 시 적합한 데이터 종류가 비디오인 경우 의미 정확성 지표를 선정하기 위해 구축 목표 또는 임무에 적합한 학습 Task를 결정

학습 Task	개 념
객체 인식 (Object Detection)	• 이미지 내에서 특정 클래스의 객체 인스턴스를 인식하는 작업
이미지 분류 (Image Classification)	• 특정 이미지를 알고리즘에 입력했을 때, 그 이미지가 어떤 클래스에 속하는지 알려주는 작업
행동 인식 (Action Recognition)	• 비디오 데이터 스트림에서 객체 행동의 감지 및 인식을 하는 작업
비디오 분류 (Video Classification)	• 프레임이 주어진 비디오에서 특정 프레임 구간을 선택하고 레이블을 부여하는 작업
자세 추정 (Pose Estimation)	• 객체와 객체의 주요 부분에 대한 위치, 방향을 식별하여 클래스를 분류하는 작업
비디오 인식 (Video Recognition)	• 비디오를 활용하여 실시간 객체 식별 및 비디오 프레임을 분류하는 작업
키폰트 검출 (Keypoint Detection)	• 동작 인식을 위해 필요한 주요 키폰트를 검출하는 작업
기계 번역 (Machine Translation)	• 인공지능을 이용해 인간이 사용하는 자연어를 다른 자연어로 번역하는 작업
질의응답 (Question Answering)	• 질문(일반적으로 독해 질문)에 답변하는 작업으로서
시멘틱 세그멘테이션 (Semantic Segmentation)	• 동일한 객체 클래스에 속하는 이미지 부분을 함께 클러스터링하는 작업
순차적 레이블링 (Sequence Labeling)	• 입력 시퀀스에 대하여 레이블 시퀀스를 각각 부여하는 작업으로, 태깅 작업이 대표적인 순차적 레이블링의 예시임
음성 인식 (Speech Recognition)	• 사람이 말하는 음성 언어를 인공지능이 해석해 그 내용을 문자 데이터로 전환하는 작업

[표 III-162] 비디오 학습 Task(의미 정확성)

- 학습Task가 결정되면 적합한 가공 유형과 품질 측정 항목(예시)을 참고하여 품질과 관련된 측정 지표 및 목표치를 선택하여 활용

※ 제시한 정량목표범주(예시)는 과제 특성에 따라 다르게 적용될 수 있으므로 참고용으로 활용

TASK 분야	가공 유형	측정지표	품질검사 항목 (예시)	정량목표범주 (예시)
3D 키포인트 인식 (3D Keypoint Detection)	Keypoint	정확도	3D 키포인트 정확성	90 이상
		PCK	모션 관절 3D 키포인트 정확성	95 이상
			캐릭터 관절 3D 키포인트 정확성	95 이상
행동 인식 (Action Recognition)	Tagging	정확도	2D 동작 태깅 정확성	95 이상
			논리 규칙 가공 정확성	90 이상
			동작 구간 태깅 정확성	95 이상
			고객 행동 의도 태깅 정확성	95 이상
			고객 발화 의도 태깅 정확성	95 이상
			로봇 행위 의도 태깅 정확성	95 이상
키포인트 검출 (Keypoint Detection)	Keypoint	정확도	2D 키포인트 정확성	90 이상
기계 번역 (Machine Translation)	Machine Translation	리커트 척도	영상 질의응답 한-영 번역 정확성	90 이상
객체 인식 (Object Detection)	Bounding Box	MOTA	바운딩 박스 정확성	95 이상
		재현율	바운딩 박스 정확성	95 이상
			사건 유발 객체 바운딩 박스 정확성	95 이상
		정밀도	바운딩 박스 정확성	95 이상
			사건 유발 객체 바운딩 박스 정확성	95 이상
	Keypoint	재현율	키포인트 정확도	95 이상
		정밀도	키포인트 정확도	95 이상

TASK 분야	가공 유형	측정지표	품질검사 항목 (예시)	정량목표범주 (예시)
질의응답 (Question Answering)	Sequence Labeling	정확도	영상에 대한 질의 정확성	90 이상
			영상 질의에 대한 답변 정확성	90 이상
			질의-응답 정확성	90 이상
시멘틱 세그멘테이션 (Semantic Segmentation)	Segmentation	재현율	세그멘테이션 정확성	90 이상
		정밀도	세그멘테이션 정확성	90 이상
순차적 레이블링 (Sequence Labeling)	Text Summary	정확도	사건 설명문 정확성	90 이상
			비디오 설명문 정확성	90 이상
음성 인식 (Speech Recognition)	Transcription	정확도	전사 정확성	90 이상
비디오 분류 (Video Classification)	Class Labeling	정확도	분류 라벨 정확도	95 이상
			전술 분류 정확성	95 이상
			스텝 분류 정확성(개인)	95 이상
			심판 판정 분류 정확성	95 이상
			수술종류 분류 태그 정확성	95 이상
비디오 인식 (Video Recognition)	Keypoint	PCK	축구공 좌표 정확성	95 이상
비디오 캡셔닝 (Video Captioning)	Video Captioning	정확도	영상-스크립트-문제 시간 정렬성	95 이상
			영상-스크립트-문제 내용 일치성	95 이상
			영상-이미지 시간 정렬성	95 이상
			영상-이미지 내용 일치성	95 이상
			프레임 추출 시간 정렬성	95 이상
			구간별 캡션 정렬성	95 이상
			구간별 캡션 적정성	95 이상
			실도로-시뮬레이션-캡션 내용 일치성	95 이상
			시뮬레이션-캡션 시간 정렬성	95 이상
			마스크 영상 정확성	95 이상
			클린본 영상 정확성	95 이상

[표 III-163] 비디오 학습 Task 분야별 품질측정항목(의미 정확성)

3.3.4 오디오

- 인공지능 학습데이터 구축목표 또는 임무 정의 시 적합한 데이터 종류가 오디오인 경우 의미 정확성 지표를 선정하기 위해 구축목표 또는 임무에 적합한 학습 Task를 결정

학습 Task	개 념
오디오 분류 (Audio Classification)	• 오디오 정보를 특정 시간 단위로 분할(오디오 클립)하여, 신호의 특이점을 분석하고 특정 클래스로 분류하는 작업
음성 인식 (Speech Recognition)	• 사람이 말하는 음성 언어를 인공지능이 해석해 그 내용을 문자 데이터로 전환하는 작업
텍스트 분류 (Text Classification)	• 문장이나 문서를 적절한 범주로 지정하는 작업으로, 범주는 선택한 데이터셋에 따라 다르며 주제 범위가 다양할 수 있음
음성 합성 (Speech Synthesis)	• 컴퓨터 또는 기타 장치를 사용하여 사람의 음성을 인공적으로 시뮬레이션하는 작업

[표 III-164] 오디오 학습 Task(의미 정확성)

- 학습 Task가 결정되면 적합한 가공 유형과 품질측정항목(예시)을 참고하여 품질과 관련된 측정지표 및 목표치를 선택하여 활용

※ 제시한 정량목표범주(예시)는 과제 특성에 따라 다르게 적용될 수 있으므로 참고용으로 활용

TASK 분야	가공 유형	측정지표	품질검사 항목 (예시)	정량목표범주 (예시)
오디오 분류 (Audio Classification)	Class Labeling	정확도	화자 규모 분류 정확도	90 ~ 95
			의도분류 정확도	90 이상
			심장음 분류 태그 정확성	90 이상
			호흡음 분류 태그 정확성	90 이상
			도메인 분류 정확도	90 이상
			감정 태깅 정확도	90 이상
			의도분류 정확도	90 이상
			감정 분류 정확도	90 이상
			소음 환경 분류 정확도	95 이상
			대화 주제 분류 정확도	95 이상
			문장 형태 분류 정확도	90 이상
			진료 프로세스 분류 태그 정확성	90 이상
			음향 분류 태그 정확성	90 이상
			음향 분류 태그 정확성(사운드 데이터)	90 이상
			소음 분류 태깅 정확성	95 이상
	Sequence Labeling	정확도	방언-표준어 매칭 정확도	95 이상

TASK 분야	가공 유형	측정지표	품질검사 항목 (예시)	정량목표범주 (예시)
	Tagging	정확도	음원 채보 정확도	95 이상
			평가 정확도	90 이상
			발음 오류 태그 정확도	90 이상
			발음 및 말하기 평가 정확도	95 이상
			음성 구간 분류 태그 정확성	95 이상
			요약 태깅 정확도	90 이상
			주소 표현형 매칭 정확도	95 이상
			음악 유사구간 정확도	95 이상
			음악 유사 계수 정확도	95 이상
			음향 카테고리 태그 정확성	95 이상
	Transcription	정확도	전사 정확도	95 이상
음성 인식 (Speech Recognition)	Tagging	정확도	발화 스타일별 감정 표현 정확도	90 이상
			말하기 평가 정확성	90 이상
	Transcription	정확도	번역 정확도	90 이상
			전사 정확도	90 이상
			발음 정확도	90 이상
			전사 텍스트 및 분류 태그 정확성	95 이상
			대본 발화 정확도	99 이상
음성 합성 (Speech Synthesis)	Tagging	정확도	명령어 상황 적정성	95 이상
	Transcription	정확도	요약 정확도	90 이상
텍스트 분류 (Text Classification)	Tagging	정확도	감정 표현의 강도 태깅 정확도	90 이상
			감정 종류/상태/정도/대상 태깅 정확도	90 이상
			감정 변화 태깅 정확도	90 이상
			카테고리 분류 정확성	95 이상
			주제어 분류 정확성	95 이상

[표 III-165] 오디오 학습 Task 분야별 품질측정항목(의미 정확성)

3.3.5 3D

- 인공지능 학습데이터 구축 목표 또는 임무 정의 시 적합한 데이터 종류가 3D인 경우 의미 정확성 지표를 선정하기 위해 구축 목표 또는 임무에 적합한 학습 Task를 결정

학습 Task	개 념
3D 객체 인식 (3D Object Detection)	• 3D 영상/이미지 내에서 특정 클래스의 객체 인스턴스를 감지하는 작업
3D 포인트 클라우드 분류 (3D Point Cloud Classification)	• 포인트 클라우드를 알고리즘에 입력했을 때, 어떤 클래스에 속하는지 알려주는 작업
3D 자세 추정 (3D Pose Estimation)	• 3D 영상/이미지 내에서 객체와 객체의 주요 부분에 대한 위치, 방향을 식별하여 클래스를 분류하는 작업
3D 객체 복원 (3D Object Reconstruction)	• 영상/이미지/포인트 클라우드로부터 객체(물체, 사람 등)의 3차원 구조를 복원(reconstruction)하는 작업
2D 이미지를 통한 시점 합성 모델 (View Synthetic)	• 컴퓨터 또는 기타 장치를 사용하여 이미지를 인공적으로 3D로 전환하는 작업으로서 다른 시점을 가진 여러개의 카메라들을 이용하여 객체를 촬영한 뒤, 촬영된 영상들과 각 카메라들의 촬영 정보들을 이용하여 해당 객체에 대한 3차원 정보를 추정
3D 키포인트 검출 (3D Keypoint Detection)	• 3D 영상/이미지 내에서 동작 인식을 위해 필요한 주요 키포인트를 검출하는 작업
인스턴트 세그멘테이션 (Instance Segmentation)	• 개체의 감지된 각 인스턴스에 대한 분할 맵을 생성하는 향상된 유형의 세그멘테이션 분할 작업
시멘틱 세그멘테이션 (Semantic Segmentation)	• 동일한 객체 클래스에 속하는 이미지 부분을 함께 클러스터링하는 작업

[표 III-166] 3D 학습 Task(의미 정확성)

- 학습 Task가 결정되면 적합한 가공 유형과 품질측정항목(예시)을 참고하여 품질과 관련된 측정지표 및 목표치를 선택하여 활용

※ 제시한 정량목표범주(예시)는 과제 특성에 따라 다르게 적용될 수 있으므로 참고용으로 활용

TASK 분야	가공 유형	측정지표	품질검사 항목 (예시)	정량목표범주 (예시)
3D 키포인트 검출 (3D Keypoint Detection)	Keypoint	$F\beta$ -점수	3D 키포인트 정확도	90 이상
		재현율	파지점 포인트 정확성	90 이상
		정밀도	파지점 포인트 정확성	90 이상
		정확도	3D 키포인트 정확성	85 ~ 95
			얼굴 랜드마크 가공 정확성	90 이상
			사람 손 3D 키포인트 정확성	90 이상
	Cuboid	정확도	파지 객체 3D 자세 큐보이드 정확성	90 이상
	Tagging	정확도	3D 동작 태깅 정확성	95 이상
3D 객체 인식 (3D Object Detection)	3D Modelling	정확도	3D 에셋 데이터 정확성	95 이상
	Bounding Box	$F\beta$ -점수	3D LiDAR 바운딩 박스 정확성	95 이상
		재현율	바운딩 박스 정확성	90 이상
			3D Bounding box 정확성	85 ~ 95
			파지 가능지점 바운딩 박스 정확성	90 이상
			파지 대상 객체에 대한 바운딩 박스 정확성	90 이상
		정밀도	바운딩 박스 정확성	90 이상
			3D Bounding box 정확성	90 이상
			파지 가능지점 바운딩 박스 정확성	90 이상
			파지 대상 객체에 대한 바운딩 박스 정확성	90 이상
	3D Segmentation	정확도	본 용접 구간 라벨링 정확성	95 이상
3D 객체 인식 확장 (3D Object Detection)	Bounding Box	정확도	바운딩 박스 정확성	95 이상
			3D Bounding box 정확성	95 이상
			라이다 3차원 바운딩 박스 정확성	95 이상
			이미지 3차원 바운딩 박스 정확성	95 이상
	Cuboid	$F\beta$ -점수	큐보이드 정확성	90 이상
			3D Cuboid 정확성	90 이상
			3D 바운딩 박스 정확성	95 이상
			3D 객체 큐보이드 정확성	90 이상

TASK 분야	가공 유형	측정지표	품질검사 항목 (예시)	정량목표범주 (예시)
		재현율	큐보이드 정확성	90 이상
			3D Bounding box 정확성	85 이상
			3D 큐보이드 정확성	85 ~ 90
		정밀도	큐보이드 정확성	90 이상
			3D Bounding box 정확성	90 이상
			3D 큐보이드 정확성	85 ~ 90
		정확도	3D Cuboid 가공 정확성 (실환경)	90 이상
			3D Cuboid 가공 정확성 (가상환경)	90 이상
	Polygon	정확도	폴리곤 정확도	95 이상
			다시점 이미지 정확성	95 이상
			스케치 이미지 정확성	95 이상
	Polyline	정확도	폴리라인 정확성	95 이상
	Segmentation	Fβ-점수	세그멘테이션 정확성	90 이상
			동적 객체 세그멘테이션 정확성	90 이상
		재현율	3D Semantic Segmentation	90 이상
			세그멘테이션 정확성	90 이상
		정밀도	세그멘테이션 정확성	90 이상
			3D 축산 기자재 객체 정확성	90 이상
		정확도	3D 객체 정확성	95 이상
	Tagging	정확도	화재 3D 객체 FDS 입력값 정확성	95 이상
			보행 환경 태깅 정확성	90 이상
			Gait Phase(보행단계) 태깅 정확성	90 이상
3D 객체 복원 (3D Object Reconstruction)	3D Modelling	정확도	화재 3D 객체 FDS 입력값 정확성	95 이상
			소방관 행동 모션(편집용) 3D 모델링 정확성	95 이상
			소방관 행동 모션(배포용) 3D 모델링 정확성	95 이상
			3D 소방시설/장비 객체 모델링 정확성	90 이상
			3D 공간 모델링 정확성	90 이상
			산림 수종 3D 객체 모델링 정확성	95 이상
			도로교통시설 3D 모델링 정확성	95 이상
			도로교통시설 3D 모델링(OBJ) 정확성	95 이상
			하천시설 3D 모델링(OBJ) 정확성	95 이상

III

부
록

TASK 분야	가공 유형	측정지표	품질검사 항목 (예시)	정량목표범주 (예시)
			하천시설 3D 모델링(CityGML) 정확성	95 이상
			3D 파지 객체 모델링 정확성	90 이상
			3D 모델링 데이터 정확성	90 이상
			가구·가전·사무기기 3D 객체 모델링 데이터 정확성	90 이상
			3D Map 데이터 정확성	90 이상
			3D 신체 모델링 데이터 정확성	99.9 이상
			3D 얼굴 모델링 데이터 정확성	99.9 이상
			3D 스캔 데이터 사실성	90 이상
			3D 객체 모델링 정확성	90 이상
			3D 객체 실사화 정확성	95 이상
			수목 3D 객체 모델링 정확성	90 이상
			3D 물체 모델링 정확성	90 이상
3D 포인트 클라우드 분류 (3D Point Cloud Classification)	Class Labeling	정확도	산림 수종 분류 정확성	95 이상
	Cuboid	정확도	큐보이드 정확성	95 이상
	Segmentation	재현율	3D Semantic Segmentation	90 이상
		정밀도	3D Semantic Segmentation	90 이상
		정확도	Lidar Instance segmentation 정확성	95 이상

[표 III-167] 3D 학습 Task 분야별 품질측정항목(의미 정확성)

3.4 유효성


3.4.1 개요

- 유효성은 임무에 적합한 AI모델을 구축한 데이터로 학습 및 평가해서 드러나는 성능을 확인하는 지표
 - 예를 들어, AI모델 예측한 바운딩 박스 위치 정보와 분류 태그를 정답과 비교해서 성능을 측정
- 따라서, AI모델은 분류 태그로 어느 한 클래스 명(코드)만 출력하지 않고 클래스별로 확률(또는 신뢰 수준)을 출력하므로 유효성 지표에는 신뢰수준 임계치(Threshold)를 변수로 두어 산정하는 지표(AUC, AP 등)가 존재할 수 있음

3.4.2 유효성 지표 선택 방법

- 데이터 구축 목표 또는 임무로 적합한 유효성 지표는 선정 알고리즘 및 측정 지표에 따라 상이하기에 선택이 어려우므로 ① 데이터 특성 등에 따라 지표를 선택하는 방법은 다음을 참고

〈데이터 특성에 따른 지표 선택 절차〉



Confusion Matrix

Prediction	Condition			
	Positive		Negative	
	Positive	Negative	Positive	Negative
	True Positive (TP)	False Negative (FN)	False Positive (FP)	True Negative (TN)

[그림 III-10] 데이터 특성에 따른 유효성 지표 선택

- ‘데이터 특성에 따른 지표 선택 절차’ 중 ② 판정표(Confusion Matrix) 작성이 가능한 경우에 선택할 수 있는 대표적인 유효성 지표는 다음과 같음

유효성 지표 선택 기준	유효성 지표	수식
• 클래스별 인스턴스 수의 비율이 균일한 데이터셋을 다룰 때	정확도 (Accuracy)	$\frac{TP + TN}{TP + FP + TN + FN}$
• FP가 매우 중요한 경우 선택 <예시> 스팸메일 여부 판단 모델: 악성 코드는 없는 단순한 스팸메일이라고 가정했을 때, FP는 정상 메일을 스팸으로 분류해서 업무 차질을 초래하므로 반드시 포함	정밀도 (Precision)	$\frac{TP}{TP + FP}$
• FN이 매우 중요한 경우 선택 <예시> 코로나여부 판단모델 진단키트가 아닌 순수 AI모델이 있다고 가정했을 때, FN은 코로나환자에게 코로나가 아니라고 분류해 방역 문제가 발생하므로 반드시 포함	재현율 (Recall),	$\frac{TP}{TP + FN}$
• FP와 TN이 매우 중요한 경우 선택	위양성율	$\frac{FP}{FP + TN}$
• 정밀도와 재현율 중 하나를 선택하기 어려운 경우(두 값의 가중치 조화평균으로, 단순 산술 평균과 달리 어느 하나가 낮은 값을 갖는 것을 비교적 잘 반영함)	Fβ-점수	$(1+\beta^{-2}) \times \frac{\text{정밀도} \times \text{재현율}}{(\beta^2 + 2 \times \text{정밀도}) + \text{재현율}}$
• 최적의 임계치를 선택하기 어렵고 균일한 데이터셋의 경우 F1-Score의 대안으로 선택(F1-Score는 특정 판단 기준이 되는 임계치를 설정해 두고 결과 판별) • 단, 양성과 음성 클래스의 비율이 균형을 이룰 경우 선택 - 탐지에서는 사용하지 않음 (탐지에서는 TN이 존재하지 않음)	AUC	ROC 커브 면적
• 최적의 임계치를 선택하기 어렵고 불균일한 데이터셋의 경우 AUC의 대안으로 선택 • 양성과 음성 클래스의 비율의 불균형이 클 경우 선택 <예시> 찾고자 하는 양성 클래스의 비율이 매우 작을 경우(예 : fraud detection 문제) AUC 대신 선택	AP	PR 커브 면적

[표 III-168] 판정표 작성이 가능한 경우 유효성 지표 선택 기준

- 또한, ③인공지능 학습데이터 구축 목표 또는 임무별 주요 유효성 지표를 참고하여 적합한 지표를 선택할 수 있음

임무	세부 임무	주요 성능 지표
분류	이미지/객체/감정 분류	정확도(Accuracy), 정밀도(Precision), 재현율(Recall), $F\beta$-점수, AUC
탐지, 인식	객체 탐지/추적/인식, 공간 탐지, 화자 탐지, 장소/얼굴/표정 인식	- IoU(Intersection over Union) ☞ 임무에 따라 최종 지표이거나 개별 데이터 참/거짓 판정의 수단 - 정밀도(Precision), 재현율(Recall), $F\beta$-점수 - AP(Average Precision) ☞ PR(Precision-Recall) Curve의 면적
(언어적) 이해	키워드 추출	- 정밀도(Precision), 재현율(Recall), $F\beta$-점수 - mAP(mean Average Precision), nDCG(normalized Discounted Cumulative Gain)
	이미지/비디오/음성/상황이해 등	$F\beta$-점수, AP
	기계 독해, QA	$F\beta$-점수, EM(Exact Matching), 정확도(Accuracy)
	번역	BLEU(Bilingual Evaluation Understudy)
	OCR, 음성인식	- WER(Word Error Rate) ☞ 단어 오류율 측정(라틴어 계열에 많이 사용) - CER(Character Error Rate) ☞ 글자 오류율 측정(한글과 같이 조사가 있는 언어에 주로 사용) $F\beta$-점수, AP
요약	텍스트 요약, 비디오 요약, 대화 요약 등	- 전문가 평가 - ROUGE(Recall Oriented Understudy of Gisting Evaluation)
합성(생성)	이미지/비디오/음성 합성(생성), 텍스트 합성(생성) 등	- 설문 조사 - Inception Score(IS) - Pitch Accuracy(PA) - Pitch Entropy(PE) - Fréchet Inception Distance(FID)
예측	이미지 예측, 상황 예측	$F\beta$-점수
행동/행위 분석	이미지, 비디오, 센서 추출/판단 등	- PCK(Percentage of Correct Keypoint) ☞ 최종 지표로 사용 가능 - OKS(Object Keypoint Similarity), PDJ(Percentage of Detected Joints), MPJPE(Mean Per Joint Position Error) ☞ 주로 개별 데이터 참/거짓 판정의 수단

[표 III-169] 임무별 유효성 지표 선택 기준

3.4.2.1 텍스트

- ① 데이터 특성, ② 판정표(Confusion Matrix) 작성이 가능한 경우, ③ 인공지능 학습데이터 구축 목표 또는 임무와 2.3 의미 정확성의 텍스트 데이터에 해당하는 학습 Task를 참조하여 적합한 유효성 측정지표를 선택할 수 있음

※ 제시한 정량목표범주(예시)는 과제 특성에 따라 다르게 적용될 수 있으므로 참고용으로 활용

Task 분야	측정지표	학습모델(알고리즘 예시)	정량목표범주(예시)
정보 추출 (Information Extraction)	$F\beta$ -점수	BERT	55 이상
	Recall@10	Cat Boost	25 이상
기계 번역 (Machine Translation)	BLEU	COMET22, COMET-KIWI	0.5 이상
		Fairseq	0.5 이상
		OpenNMT	70 이상
		OpenNMT-Transformer	70 이상
		Transformer	27.5 이상
	BLEU*100	Meta-Llama-3.1-8B-Instruct	8.19 이상
	ERR	Conformer	2 ~ 5
	$F\beta$ -점수	Electra	83 이상
		KoBERT-NER	70 이상
질의응답 (Question Answering)	EM	Longformer for QA	70 이상
		TAPEX-Large	50 이상
	$F\beta$ -점수	BART	80 이상
		ELECTRA	81 이상
		Longformer for QA	73 이상
		NumNet+	55 이상
	R10@1(Average)	Bi-Encoder using Roberta	82 이상
	SSA(MOS)	GPT-NeoX, Polyglot-5.8b-ko	60 이상
	Top1 ACC	TF-IDF(변형), RoBERTa	60 이상
	Unseen SR	MOCA	4.5 이상
	정확도	ELECTRA	81 이상
		KLUE-RoBERTa	27 이상
		Llama-3 70B	0.4 이상
		Transformers v4.56.1, Qwen2.5 7B	85 이상
		Qwen3-8B	75 이상
	Perplexity (WikiText-2)	LLaMA 3.1	6.0 이하
	BERTScore	LLaMA 3.1	0.90 이상
		Llama 3, mistral	0.85 이상

Task 분야	측정지표	학습모델(알고리즘 예시)	정량목표범주(예시)
음성 인식 (Speech Recognition)	BLEU	Transformer	15 ~ 40
텍스트 분류 (Text Classification)	AUC	1D CNN base model	80 이상
		1D CNN + LSTM	70 ~ 85
		Random Forest	80 이상
	AVG BLEU	KoGPT2	4 이상
	entity $F\beta$ -점수	Electra	83 이상
	$F\beta$ -점수	AAGCN	80 이상
		Artificial Neural Network	70 이상
		BERT	80 ~ 85
		CatBoostRegressor	80 이상
		Convolutional Neural Network	70 이상
		DNN	80 이상
		klue-BERT	80 이상
		KoBERT	40 ~ 80
		SincNet	75 이상
	hits@1	Klue RoBERTa	0.7 이상
	Macro $F\beta$ -점수	DenseNet	75 이상
	MAPE	TGNet	30 이상
		Tempor Fusion Transformer	5 이상
	R10@1	ScriptWriter-CPre	35 이상
	R2@1	ScriptWriter-CPre	70 이상
	정확도	BERT	55 이상
		COMET22, COMET-KIWI	0.5 이상
		HAND	60 이상
		koELECTRA	70 ~ 85
		KRBERT, SVM	80 이상
		SVM	65 ~ 80
		Transformer	0.5 이상
		xlm-roberta-base	50 이상
	F1-Score	Llama-3 70B	0.83 이상
	Recall@1	openchat-3.5-0106(mistral)	50 이상
		gemma-2-9b-it	50 이상
		Meta-Llama-3-8B-Instruct	50 이상

Task 분야	측정지표	학습모델(알고리즘 예시)	정량목표범주(예시)
텍스트 생성 (Text Generation)	AVG BLEU	Klue RoBERTa	4 이상
	CER	TPS+VGG+BiLSTM+Attn	20 이상
	Coverage	mBART	70 이상
	$F\beta$ -점수	KL-BERT	0.5 이상
		KM-BERT	0.5 이상
		KoLANG-T5	24 이상
	hits@1	KoGPT2	0.15 이상
	$KF\beta$ -점수	KoLANG-T5	24 이상
	Likert 5 Scale	T5	3.3 이상
	Perplexity	KL-BERT	10 이상
		KM-BERT	10 이상
		LLaMA-13B	학습 전후 10% 이상 감소
		LLaMa3.1 8B	학습 전후 10% 이상 감소
		LLaMa 7B	학습 전후 10% 이상 감소
	ROUGE-2	mBART	50 이상
	ROUGE-L	mBART	50 이상
		Bart	33 이상
		KoLLaVa 7B	0.6
	SSA	GPT-NeoX 3.8b, LLaMa	60 이상
	PPO 모델 자연어 추론	LLaMA-13B(PPO)	76.32 이상
	올바른 사용률	T5	17 이상
	적절한 답변 생성률	T5	60 이상
	정확도	BRIDGE	60 이상
		RYANSQL	58 이상
텍스트 예측 (Text Prediction)	AUC	DeepSurv	70 이상
	C-index	DeepSurv	70 이상
	$F\beta$ -점수	BERT	95 이상
		Cat Boost	70 이상
		EfficientNet D2	84 ~ 87
		Sequential	0.9 이상
	Kendall's Tau coefficient	COMET22, COMET-KIWI	0.05 이상

Task 분야	측정지표	학습모델(알고리즘 예시)	정량목표범주(예시)
	MAPE	DLinear	20 이상
		XGBoost	20 이상
	Micro $F\beta$ -점수	KLUE/RoBERTa-large	65 이상
	Precision	COMET22, COMET-KIWI	0.05 ~ 0.6
	Predicted R2	RandomForestRegressor	0.7 ~ 0.95
	RMSE	LSTM	20 이상
	Top-K 정확도 (ACC@10)	Lightmove	60 이상
	정확도	COMET22, COMET-KIWI	0.05 이상
텍스트 교정 (Text Reconstruction)	F0.5 Measure	Transformer	50 이상
	$F\beta$ -점수	kobart	40 이상
텍스트 자동완성 (Text Autocompletion)	Accuracy	Llama3.1	80 이상
	ROUGE-1	Llama3.1	0.5 이상

[표 III-170] 텍스트 Task 분야별 유효성 측정지표

3.4.2.2 이미지

- ① 데이터 특성, ② 판정표(Confusion Matrix) 작성이 가능한 경우, ③ 인공지능 학습데이터 구축 목표 또는 임무와 2.3 의미 정확성의 이미지 데이터에 해당하는 학습 Task를 참조하여 적합한 유효성 측정지표를 선택할 수 있음

※ 제시한 정량목표범주(예시)는 과제 특성에 따라 다르게 적용될 수 있으므로 참고용으로 활용

Task 분야	측정지표	학습모델(알고리즘 예시)	정량목표범주(예시)
행동 인식 (Action Recognition)	정확도	EfficientNet	70 이상
얼굴 인식 (Face Recognition)	Age 정확도	SAM	40 이상
	정확도	Retinaface	92 이상
이미지 분류 (Image Classification)	AUC	LightGBM	65 이상
		MobileNetV2	70 이상
		ResNet-50	65 ~ 85
		ResNeXt50	80 ~ 90
	AUC (F1-점수 0.3 이상)	CNN	50 이상
	AUC (F1-점수 0.5 이상)	CNN	80 이상
	AUROC	FingerPrint Module + MLP	70 이상
		BPE	60 이상
	DSC	EfficientNet + Unet	70 이상
		U-Net	63 ~ 75
	EER	CNN+LSTM	25 이상
	F β -점수	1D CNN + MLP	60 이상
		CRNN	90 이상
		EfficientNet B0	80 이상
		LSTM	80 이상
		RandomForest	80 이상
		ResNet+ EfficientNet	70 이상
		ResNet18	85 이상
		Restnet 기반 멀티모달 모델	85 이상
		SVM, Random Forest, Linear SVC, Logistic Regression, CNN	80 이상

Task 분야	측정지표	학습모델(알고리즘 예시)	정량목표범주 (예시)
		TransFG	90 이상
		VGG16	70 이상
		ViT	50 이상
		XGBoost	70 이상
		YOLOv5	60 ~ 90
		폐기능 : CNN, GRU 폐음 : CNN, GRU 임상정보 : ANN, TabNet	60 이상
	MAE	C3AE	5 이상
		RandomForest	10 이상
	mAP	EfficientNetV2 small	80 이상
		Mask-RCNN	40 ~ 85
		ResNet-50	74 이상
		YOLO v3	70 이상
		YOLO v5	50 ~ 85
		YOLO v7	85 ~ 90
		Dual ResNet50 + TabNet + MTAN + Mask R-CNN	45 이상
		Faster R-CNN	80 이상
	mAP@0.5	mask R-CNN	60 이상
		pspnet	85 이상
	MAPE	gradient boosting	20 이상
		YOLO v5	60 이상
	Micro F1-점수	1D CNN + MLP	60 이상
	mIoU	ConvPoint	68 이상
	Overall Pixel 정확도	UNet	88 이상
	Pixel 정확도	SegFormer	70 ~ 90
	PQ	EfficientPS	30 ~ 50
	Recall	RPN + MSDN	10 ~ 50
	Sensitivity	EfficientNet-B1	80 이상
	Top-1 정확도	DenseNet 121	75 ~ 80
		EfficientNet v2	78 이상

Task 분야	측정지표	학습모델(알고리즘 예시)	정량목표범주(예시)
		MViTv2	70 이상
		ResNet50	90 이상
		SwinTransformer	50 ~ 65
		LLaVA-NeXT(LMM)	97 이상
	Top-3 정확도	PoseC3D	80 ~ 85
	Top-5 정확도	ST-GCN	40 이상
		swintransformer	70 이상
	WAR	Former-DFER	70 이상
	정확도	CNN	90 이상
		DeepLab V3+	95 이상
		DenseNet121	5 이상
		EfficientNet	63 ~ 90
		EfficientNet-B0	80 이상
		GoogleNet	70 이상
		keras CNN	80 이상
		LightGBM	80 이상
		LSTM-FCN	95 이상
		MASK R-CNN	60 이상
		NS-VQA	0.65 이상
		Resnet	74 ~ 90
		ResNet, ShuffleNet, DenseNet	5 이상
		ResNet101	5 이상
		ResNet18	5 이상
		ResNet34	5 이상
		ResNet50	80 이상
		SE-ResNet	62 이상
		SVM	80 이상
이미지 추정(Image Estimation)	ADE	PECNet	20 이상
	MAE	IIM-Crowd Localization	65 이상
		L2CS-Net	10 이상
	AUC	ConvLSTM	80 이상
	F β -점수	Swin Transformer	70 이상

Task 분야	측정지표	학습모델(알고리즘 예시)	정량목표범주 (예시)
	RecallVSD	TemplatePose	30 이상
	교차로 지체 길이	LSTM	10 이상
	교차로 차량 통행 속도	LSTM	10 이상
이미지 생성 (Image Generation)	BLEU	CNN + Transformer	66 이상
	FID	Image-to-image Translation	30 이상
	HR	Pinsage	72 이상
	MSE	ConvLSTM	1.4 이상
	Overall Pixel 정확도	NeRF	70 이상
질의응답 (Question Answering)	BLEU	Transformer	50 이상
	R10@1(Min)	Bi-Encoder using Roberta	74 이상
	Recall@100	LLaMA 2	75 이상
	F1-Score	BERT(KoBERT, KcBERT), RoBERTa, ELECTRA	0.7
		GPT-2	0.73
		SeaLLMs3	85.6 이상
	CER	EEVE-Korean-Instruct-10.8B-v1.0	15% 이하
이미지 합성 (Image Synthesis)	FID	Score SDE	15 이상
		Deceive-D	14~18
		StyleGAN2-ADA	15 이상
		StyleGAN2-XL	15 이상
	Mean point difference	ResNet 50	0.4 이상
인스턴스 세그멘테이션 (Instance Segmentation)	AP	MASK R-CNN	80 이상
	mAP	MASK R-CNN	34 이상
		swin-t	54 이상
	mIoU	A-CE2P	55 이상
		Mask2Former	70 이상
	NMAE	Pycaret	5 이상
	픽셀 정확도	Mask R-CNN	80 이상
	DICE	Mask2Former	75 이상

Task 분야	측정지표	학습모델(알고리즘 예시)	정량목표범주 (예시)
키포인트 검출 (Keypoint Detection)	AP	Keypoint RCNN	90 이상
	MPJPE	HRNet	90 이상
	OKS	HRNet	70 이상
	PCK	HRNet	75 이상
객체 인식 (Object Detection)	AMT 점수	CycleGAN	20 이상
	AP	A-CE2P	59 이상
		Arcface	90 이상
		HOTR	50 이상
		ResNet-50, RetinaNet	80 이상
		Simple Baseline	78 이상
		Swin Transformer	70 이상
		YOLO v5	85 이상
	AP@OKS	HRNet	80 이상
	Dice 점수	Mask R-CNN	60 이상
		Mask2Former	75.0 이상
	F β -점수	EfficientNet + FPN	70 이상
		CLRNet	65 이상
		YOLO v4	90 이상
		YOLO v5	70 이상
	FID	GAN	70 이상
	IoU	Yolo v5	70 이상
	IS	DCGAN	2 이상
	MAE	RandomForest	10 이상
	mAP	convnext, swin, swinv2	35 ~ 50
		CSPDarknet53	40 이상
		Deeplabv3+	85 이상
		DetectoRS	80 이상
		Detectron2	80 이상
		DETR	45 이상
		EfficientNet	85 이상
		Faster RCNN	65 ~ 70
		HRNet	80 이상

Task 분야	측정지표	학습모델(알고리즘 예시)	정량목표범주 (예시)
		Mask R-CNN	40 ~ 70
		Modified Unet with WGAN	80 이상
		PointPillars	65 ~ 70
		PointRend	35 ~ 40
		PV-RCNN	65 이상
		Swin Transformer	50 ~ 55
		TridentNet	65 이상
		YOLACT	60 이상
		YOLO R	70 이상
		YOLO v4	65 ~ 90
		YOLO v5	50 ~ 80
		YOLO v7	60 ~ 85
		YOLO v8	60 이상
		YOLO X	65 이상
	mAP@0.5	EfficientDet	70 ~ 72
		HRNet	45 이상
		Mask R-CNN	40 ~ 75
		Swin Transformer V2	75 이상
		YOLO v3	75 이상
		YOLO v4	65 ~ 70
		YOLO v5	50 ~ 90
		YOLO v7	45 ~ 70
		YOLO X	30 이상
	mAP@0.75	Cascade Mask R-CNN	70 이상
		YOLO v5	80 이상
	mAPA	UOAIS-Net	30 이상
	mean F1-점수	AGRNet	70 이상
	mIoU	ConvNeXt	50 ~ 85
		DeepLabV3+	60 ~ 85
		EfficientNetV2 small	85 이상
		FPN	58 이상
		HarDNet	70 이상
		Mask R-CNN	80 이상

Task 분야	측정지표	학습모델(알고리즘 예시)	정량목표범주 (예시)
		PointRend	80 이상
		SegFormer	60 이상
		Swin Transformer	46 ~ 70
		Swin-L	60 ~ 70
		U-Net	75 ~ 80
		U-Net, EfficientnetB0	80 이상
		U-Net++	53 이상
	Overall Pixel 정확도	U-Net	60 이상
	PCK	YOLO	80 이상
	PSNR	Restormer	29 이상
		SwinIR	32 이상
		BrushNet	30.0 이상
	R2	LightGBM	0.65 이상
	Rank-1 정확도	Multiple Granuraliy Network	96 이상
	Rank-10 정확도	Joint Set-level Instance-Level Alignment Re-ID	72 이상
	RMSE	Automatic Self-Reconstruction Model	3 이상
		ConvLSTM	1.4 이상
	SSIM	Restormer	0.8 이상
		SwinIR	0.9 이상
	정확도	Automatic Self-Reconstruction Model	80 이상
		LaneNet	85 이상
		YOLO v5	80 이상
		YOLO v5, AttNet	0.4 이상
	CER	TrOCR	17 이하
	WER	TrOCR	18 이하
광학 문자 인식(Optical Character Recognition)	CER	YOLO v5	5 이상
	$F\beta$ -점수	CRAFT	80 이상
		FAST + ViTSTR	70 ~ 80
		HRCenterNet	70 ~ 82
		YOLO v5 + CNN	75 이상
	정확도	YOLO v4	90 이상

Task 분야	측정지표	학습모델(알고리즘 예시)	정량목표범주 (예시)
자세 추정 (Pose Estimation)	AP	KAPAO	62 이상
	AP@0.5	dite-HRNet	80 이상
	mAP	AlphaPose	80 이상
질의응답 (Question Answering)	overall 정확도	ZS-F-VQA	60 이상
시멘틱 세그멘테이션 (Semantic Segmentation)	$F\beta$ -점수	Informer	90 이상
	mAP	Mask R-CNN	55 이상
	mAP@0.5	YOLO v7	40 이상
	mIOU	Mask R-CNN	50 이상
	mIoU(Mean-13)	ERF-PSPNet	47 이상
	픽셀 정확도	Mask R-CNN	80 이상
음성 합성 (Speech Synthesis)	mIoU	YOLO v5	85 이상
3D 객체 분류 (3D Object Classification)	AUROC	EfficientNet-B0	90 이상
	mAP	PointPillars	46 이상
		Voxel R-CNN	70 ~ 90
	정확도	PointNet	71 이상
3D 객체 인식 (3D Object Detection)	mAP	PV-RCNN	50 ~ 70
		ResNet + YOLO v3	70 이상
		CenterFusion	40 이상
		CenterNet	20 이상
		CenterPoint	30 ~ 50
		CenterFusion	50 ~ 60
		CenterNet	40 이상
		CenterPoint	35 ~ 70
	mAP@0.5	EfficientDet	72 이상
		Mask R-CNN	54 이상
		YOLO v4, 2D + 3D fusion	70 이상
	LPIPS	StyleSplat	0.15 이하
	mIoU	StyleSplat	90 이상
3D 생성 (3D Generation)	CLIPScore	Hunyuan3D	0.2 이상

Task 분야	측정지표	학습모델(알고리즘 예시)	정량목표범주 (예시)
3D 포즈 생성 (3D Pose Generation)	Top-5 acc	EMAGE	50 이상
3D 객체 복원 (3D Object Reconstruction)	PSNR	neuralangelo	20 이상
3D 포인트 클라우드 분류 (3D Point Cloud Classification)	Top-1 정확도	DenseNet	75 이상

[표 III-171] 이미지 Task 분야별 유효성 측정지표

3.4.2.3 비디오

- ① 데이터 특성, ② 판정표(Confusion Matrix) 작성이 가능한 경우, ③ 인공지능 학습데이터 구축 목표 또는 임무와 2.3 의미 정확성의 비디오 데이터에 해당하는 학습 Task를 참조하여 적합한 유효성 측정지표를 선택할 수 있음

※ 제시한 정량목표범주(예시)는 과제 특성에 따라 다르게 적용될 수 있으므로 참고용으로 활용

Task 분야	측정지표	학습모델(알고리즘 예시)	정량목표범주(예시)
행동 인식 (Action Recognition)	$F\beta$ -점수	Bi_LSTM	75 이상
이미지 분류 (Image Classification)	$F\beta$ -점수	EfficientNet-B3, B7	70 이상
	MOTA	DeepSORT	50 이상
	정확도	LSTM, MIL Ranking	80 이상
		R3D	60 이상
		WGAN, Bi-LSTM	55 ~ 70
이미지 생성 (Image Generation)	BLEU	PDVC	0.75 이상
키포인트 검출 (Keypoint Detection)	PCKh	OpenPose, UniPose	90 이상
객체 인식 (Object Detection)	PQ	Mask2Former	50 이상
	BLEU-4	PDVC	65 ~ 75
	$F\beta$ -점수	Resnet101	70 이상
		YOLO v5	70 이상
	mAP	YOLO v4	65 이상
	정확도	HCRN	60 ~ 70
자세 추정 (Pose Estimation)	FID	Action2Motion	2.8 ~ 2.8
비디오 인식 (Video Recognition)	$F\beta$ -점수	Contrastive Learning Approach	75 이상
3D 객체 인식 (3D Object Detection)	NRMSE	Convolution Neural Networks	10 이상
영상 생성 (Video Generation)	VMAF	Real-ESRGAN	70 이상
	FVD	CogVideoX	20.0 이하
영상 검색 (Video Retrieval)	Recall@5	VAST	81.80
	NPS (Net Preference Score)	VAST	15% 이상 개선

[표 III-172] 비디오 Task 분야별 유효성 측정지표

3.4.2.4 오디오

- ① 데이터 특성, ② 판정표(Confusion Matrix) 작성이 가능한 경우, ③ 인공지능 학습데이터 구축 목표 또는 임무와 2.3 의미 정확성의 오디오 데이터에 해당하는 학습 Task를 참조하여 적합한 유효성 측정지표를 선택할 수 있음

※ 제시한 정량목표범주(예시)는 과제 특성에 따라 다르게 적용될 수 있으므로 참고용으로 활용

Task 분야	측정지표	학습모델(알고리즘 예시)	정량목표범주(예시)
오디오 분류 (Audio Classification)	1-CER	RNN-Transducer	85.5 ~ 86
	1-WER	RNN-Transducer	70 ~ 94
	AP	KoBERT	86 이상
	AUC	Resnet101v2	80 이상
	F β -점수	Pre-trained CNN	70 이상
		RESNET, ATTENTION	70 이상
	F1-점수@76dB	ESResNet	0.8 이상
	F1-점수@86dB	ESResNet	0.75 이상
	F1-점수@96dB	ESResNet	0.7 이상
	mAP	PaSST	50 이상
	PCC	Transformer	0.7 이상
	Pearson Correlation	Wav2vec2.0 & MLP	0.5 이상
	SDR	Parallel Stacked Hourglass Network	4 이상
		Spleeter	5 이상
	Top1-정확도	Inception V3	80 이상
		YAMNet	65 이상
	WER	HuBERT	25 이상
	정확도	BERT	65 이상
		ELECTRA	85 이상
		KoBERT	90 이상
		MFCC & CNN	70 ~ 80
		Multi-layer perceptron (MLP)	60 이상
		ResNet50	90 이상
		Sound feature extraction and fully connected network	70 이상
이미지 추정 (Image Estimation)	Recall@5	Inception V3, YAMNet, Contrastive Metric Learning	50 ~ 60
기계 번역 (Machine Translation)	BLEU	Transformer	15 ~ 40

Task 분야	측정지표	학습모델(알고리즘 예시)	정량목표범주 (예시)
음성 인식 (Speech Recognition)	AP	KoBERT	86 이상
	BLEU	mBART	60 이상
		Transformer	15 ~ 17
	CER	Conformer	15 ~ 20
		Conformer-CTC small	12 이상
		CTC Transformer	10 ~ 15
		ESPnet	8 ~ 10
		ESPNet2	30 이상
		HuBERT	20 이상
		Jasper	15 이상
		Transformer, Conformer	10 이상
		wav2vec	20 이상
		Whisper	30 이상
	EER	x-vector	8 이상
	ESTOI@76dB	TSCN	0.6 이상
	ESTOI@86dB	TSCN	0.5 이상
	ESTOI@96dB	TSCN	0.4 이상
	F β -점수	GroveToolBox	58 이상
		MelodyShape	58 이상
		Omnizart	60 이상
		Wav2vec2.0	70 이상
		YOLO X-AUDIO	85 이상
	F1-점수 error rate@76dB	ESPNet	0.15 이상
	F1-점수 error rate@86dB	ESPNet	0.1 이상
	F1-점수 error rate@96dB	ESPNet	0.05 이상
	MOS	VITS	3.4 이상
	PCC	Wav2vec2.0	0.6 이상
	QWK	LSTM	0.55 이상

Task 분야	측정지표	학습모델(알고리즘 예시)	정량목표범주 (예시)
	ROUGE-1	BART	40 이상
	ROUGE-1_{recall}	KoBART	50 이상
	ROUGE-2	BART	19 이상
	ROUGE-L	BART	38 이상
	sWER	Conformer	35 이상
	Weighted Classification Error	KcELECTRA	30 이상
	WER	Conformer	30 이상
		ESPnet	16 이상
		Wav2vec	12 ~ 15
	WRR	CTC (Connectionist Temporal Classification)	70 이상
음성 합성 (Speech Synthesis)	정확도	U-Net, based Omnizart	55 이상
		VGGNet	75 이상
	GLEU	BART	58 이상
	mIoU	YOLO v5	85 이상
	MOS	Transformer-GST	3.6 이상
		VITS	3.7 ~ 4.1

[표 III-173] 오디오 Task 분야별 유효성 측정지표

3.4.2.5 3D

- ① 데이터 특성, ② 판정표(Confusion Matrix) 작성이 가능한 경우, ③ 인공지능 학습데이터 구축 목표 또는 임무와 2.3 의미 정확성의 3D 데이터에 해당하는 학습 Task를 참조하여 적합한 유효성 측정지표를 선택할 수 있음

※ 제시한 정량목표범주(예시)는 과제 특성에 따라 다르게 적용될 수 있으므로 참고용으로 활용

Task 분야	측정지표	학습모델(알고리즘 예시)	정량목표범주(예시)
3D 키포인트 검출 (3D Keypoint Detection)	Reconstruction error median value	DECA	2.8 이상
3D 객체 인식 (3D Object Detection)	AP	PointRCNN	70 이상
		SpineNet	30 이상
		Swin Transformer	75 이상
	AP:R40	PointPillars	50 이상
	ATE	HDL SLAM, Cartographer	0.5 이상
	HOTA	DeepFusionMOT	50 이상
	IoU	ILN	0.18 이상
	mAP	Pointpillars	52 이상
		Swin Transfer	35 이상
		YOLO R	45 이상
		YOLO v5	64 이상
	mAP@0.5	EfficientDet	72 이상
		Mask R-CNN	54 이상
		YOLO v4, 2D + 3D fusion	70 이상
	mIoU	CMX	73 이상
		FKACnv	60 이상
		RandLa-Net	50 이상
		STDC, DeepLabV3+	65 ~ 73
		StyleSplat	90 이상
	mIoU(고해상도)	SPVConv	30 이상
	mIoU(노이즈)	SPVConv	30 이상
	mIoU(디노이즈, 객체)	SPVConv	18 이상
	mIoU(디노이즈, 날씨)	SPVConv	80 이상
	mIoU(저해상도)	SPVConv	18 이상
	MOTA	DeepFusionMOT	55 이상

Task 분야	측정지표	학습모델(알고리즘 예시)	정량목표범주(예시)
	Opt	Neural A*	80 이상
	PSNR	NeRF	18 이상
	LPIPS	StyleSplat	0.15 이하
3D 객체 복원 (3D Object Reconstruction)	meshAP	mesh R-CNN	25 이상
	PSNR	neuralangelo	20 이상
3D 포인트 클라우드 분류 (3D Point Cloud Classification)	$F\beta$ -점수	ResNet-152	90 이상
	frame mAP	YOWO	80 이상
	정확도	G3DNet18+RepSurf	90 이상
		PoseConv3D	70 이상
		ResNet-152	90 이상
		SE-PseudoGrid	85 이상
	Top-1 정확도	DenseNet	75 이상
3D 자세 추정 (3D Pose Estimation)	AP	DynamicHead	50 이상
이미지 분류 (Image Classification)	frame mAP	PoseConv3D	80 이상
	MPJPE	EvoSkeleton	53 이상
		Hybrik	95 이상
		SPIN	110 이상
		TCMR	73 이상
	PA-MPJPE	Hybrik	65 이상
	Top-1 정확도	MMNet	39 이상
객체 인식 (Object Detection)	정확도	DD-Net	70 이상
3D 객체 분류 (3D Object Classification)	AUROC	EfficientNet-B0	90 이상
	mAP	PointPillars	46 이상
		Voxel R-CNN	70 ~ 90
	정확도	PointNet	71 이상
3D 생성 (3D Generation)	CLIPScore	Hunyuan3D	0.2 이상
3D 포즈 생성 (3D Pose Generation)	Top-5 acc	EMAGE	50 이상

[표 III-174] 3D Task 분야별 유효성 측정지표

부록3

데이터 가공 가이드

1

텍스트, 음성 데이터 가공

구분	내용	
전사 정보의 저장	- 전사 정보는 json 형태의 파일로 저장 - json 파일의 형태는 필요에 따라 추가적인 항목을 가질 수 있으나 아래 항목은 필수적으로 가져야 함	
	Field	설명
	speaker_id	· 화자의 고유한 ID 정보
	start_time	· 문장의 시작 시간으로 소수점을 포함하는 초 단위 숫자로 기록
	end_time	· 문장의 끝 시간으로 소수점을 포함하는 초 단위의 숫자로 기록
	text	· 발성 내용 및 기타정보
화자정보의 전사	- 여러 화자가 함께 대화한 내용을 녹음하여 전사하는 경우, 분할된 개별 문장에 대하여 화자 정보를 기록 - 화자 ID가 정해져 있으면 해당 ID를 사용하고 화자 ID가 없는 경우 A, B, C 와 같이 영어 알파벳 대문자 1개로 표시 - 하나의 대화에서 같은 ID는 같은 화자를 가리켜야 하며 다른 대화에 대해서는 ID가 같더라도 화자가 다를 수 있음	
	시간정보는 문장 단위로 각 문장의 시작과 끝 지점을 파일의 맨 처음을 0으로 하여 초 단위로 기록	
	규칙	
	- 모든 발화에는 발화의 타임스탬프(시작시간, 끝시간)를 표시 - 시간 단위는 초를 사용하며 0.1초 이내의 정밀도를 가지도록 전사 - 발화 구간에 대해서만 시간정보를 기록하고 그 외의 잠음 및 무음 구간은 기록하지 않음 - 발화가 겹치는 구간(오버랩)은 각 발화자의 발화를 개별 발화로 간주하여 시작 시간 및 끝시간 상으로 겹치도록 전사하며 오버랩에 대한 별도 표기는 하지 않음	
시간정보의 전사		

III

부록

구분

내용

발성내용의 전사

- 발성 내용 전사는 실제 발성한 내용을 그대로 글자로 옮겨 적는 것을 원칙으로 하며 그 단위는 문장 단위로 설정

사실은 제가 사장님께 궁금한 게 참 많았는데요.

네.

우리 부산 시민들도 궁금한 점이 참 많더라구요.

- 각 문장별로 화자 정보를 문두에 표기하는 것도 가능

[A] 사실은 제가 사장님께 궁금한 게 참 많았는데요.

[B] 네.

[A] 우리 부산 시민들도 궁금한 점이 참 많더라구요.

- 이중전사는 하지 않고 표기전사로만 수행

잘못된 전사	바른 전사
(30km)/(삼십 킬로미터)	30 km

① 띄어쓰기

- 띄어쓰기는 표준어법에 맞추어 하되 표준어법으로 명확히 결정할 수 없는 경우에는 띄어 씀
- 전각 공백문자('Wu3000'), 탭 문자 등의 잘못된 문자로 표시되지 않도록 주의
- 숫자와 이어지는 단어는 붙여쓰는 것을 원칙으로 하되, 이어지는 단어가 수량을 나타내는 단위일 경우에는 한 칸을 띄움

발성 내용	바른 전사
삼십 킬로미터	30km
삼분의이가 지났다	2/3이 지났다
오월에는 다섯개	5월에는 5 개
삼 사십 대	3, 40대
이 삼 천원	2, 3천 원
오뉴월과 칠팔월	5, 6월과 7, 8월
사 오십 프로	4, 50%

② 문장부호

- 문장 부호에 대한 전사규칙은 마침표(.), 쉼표(,), 느낌표(!), 물음표(?) 네 가지 문장부호만을 규정하여 다른 문장부호는 삽입하지 않는 것을 원칙으로 함
- 한 문장이 끝나면 이 네 개의 문장 부호 중 하나를 반드시 붙여줌
- 문장이 종료되지 않고 발화가 종료된 경우에는 쉼표를 삽입
- 쉼표는 한 문장 중간에 필요한 경우에 삽입이 가능하며 문장부호 뒤에는 반드시 공백을 삽입

구분	내용										
발성내용의 전사	③ 그밖의 기호										
	- 온점은 마침표 이외에 소수점 및 낱자를 나타내거나 영어 약자를 나타내기 위해 사용되는 경우가 있음										
	- 이 경우 온점 뒤에 공백 없이 반드시 붙여서 온점 뒤에 공백이 있는 경우는 온점이 문장의 마침표인 경우 만 허용										
	<table><tr><th>발성 내용</th><th>전사</th></tr><tr><td>삼쩜일사일오구</td><td>3.14159</td></tr><tr><td>육이오 전쟁</td><td>6.25 전쟁</td></tr><tr><td>알오케이</td><td>R.O.K</td></tr><tr><td>씨오쩜 케이알</td><td>co.kr</td></tr></table>	발성 내용	전사	삼쩜일사일오구	3.14159	육이오 전쟁	6.25 전쟁	알오케이	R.O.K	씨오쩜 케이알	co.kr
	발성 내용	전사									
	삼쩜일사일오구	3.14159									
	육이오 전쟁	6.25 전쟁									
	알오케이	R.O.K									
	씨오쩜 케이알	co.kr									
	- 슬래시(/) 는 분수를 나타내거나 영어 약어를 나타내기 위해 사용될 수 있음										
	<table><tr><th>발성 내용</th><th>전사</th></tr><tr><td>오 분의 삼이 지났다</td><td>3/5이 지났다.</td></tr><tr><td>에이에스를 받으려고 해</td><td>A/S를 받으려고 해.</td></tr></table>	발성 내용	전사	오 분의 삼이 지났다	3/5이 지났다.	에이에스를 받으려고 해	A/S를 받으려고 해.				
	발성 내용	전사									
	오 분의 삼이 지났다	3/5이 지났다.									
	에이에스를 받으려고 해	A/S를 받으려고 해.									
	- +, -, @, & 등 일상적으로 사용되는 기호는 그대로 전사										
	<table><tr><th>발성 내용</th><th>전사</th></tr><tr><td>마이너스 5도 케이티앤지</td><td>-5도 KT&G</td></tr><tr><td>에비씨앳구글닷컴</td><td>abc@google.com</td></tr></table>	발성 내용	전사	마이너스 5도 케이티앤지	-5도 KT&G	에비씨앳구글닷컴	abc@google.com				
	발성 내용	전사									
	마이너스 5도 케이티앤지	-5도 KT&G									
	에비씨앳구글닷컴	abc@google.com									
	- 긴 발성을 표시하기 위한 표시(~), 말줄임표 표시(…)는 사용하지 않음										
- α , π 등의 그리스문자나 그밖의 특수기호는 한글로 전사											
<table><tr><th>발성 내용</th><th>전사</th></tr><tr><td>알파 곱하기 베타 더하기 감마</td><td>알파 곱하기 베타 + 감마</td></tr><tr><td>이 파이 나누기 삼</td><td>2 파이 나누기 3</td></tr></table>	발성 내용	전사	알파 곱하기 베타 더하기 감마	알파 곱하기 베타 + 감마	이 파이 나누기 삼	2 파이 나누기 3					
발성 내용	전사										
알파 곱하기 베타 더하기 감마	알파 곱하기 베타 + 감마										
이 파이 나누기 삼	2 파이 나누기 3										
④ 방언(사투리)											
- 방언은 표준어로 고쳐적는 것을 원칙으로 하되 그 특성을 살려야 하는 방언의 경우 그대로 표기											
- 표준어로 수정하는 전사 예시											
예) 했어요를 했어유(충청도 사투리)로 발음한 경우, 했어요로 전사											
예) 어머니를 어무이로 발음한 경우, 어머니로 전사											
- 방언의 특성을 살리는 전사 예시											
예) 어머니를 어멍(제주도 사투리)로 발음한 경우 어멍으로 전사											

구분	내용		
발성내용의 전사	⑤ 영어		
	- 영어의 경우에는 ‘외래어’라면 한국어로, ‘외국어’라면 영어로 표기		
	- 일상적으로 영어로 표기하는 것은 영어로 하고, 일상적으로 한글로 표기하는 것은 한글 표기로 함		
	잘못된 전사		바른 전사
	youtube		유튜브
	wikipedia		위키피디아
	white day		화이트데이
	wife		와이프
	wild win		와일드 푸드
	win win		윈윈
	won dollar		원 달러
	- 또한 영어로 긴 문장을 말하는 경우, 한글식 발음으로 발성했다면 한국어 음성인식을 위해서는 이는 한글로 전사되는 것이 바람직		
	- 만약 영어식 발음으로 발성했다면 이 발화는 한국어 음성 데이터로는 부적합하므로 전사 하지 않음		
	잘못된 전사		바른 전사
	widespread vaccination		와이드 스프레드 백신네이션
millions of good-paying jobs		밀리언스 오브 굿 페잉 잡스	
- 일상적으로 영어로 표기되는 것은 영어로 표기			
발성내용	바른 전사	잘못된 전사	
엠비씨	MBC	엠비씨	
에스엔에스	SNS	에스엔에쓰	
엘지전자	LG전자	엘지전자	
에스케이 하이닉스	SK하이닉스	에스케이 하이닉스 / SK Hynix	
- 영어로 읽은 숫자나 기호는 원래의 숫자나 기호로 표기			
발성내용	바른 전사	잘못된 전사	
플랜 투	플랜2	plan 2 / 플랜 투	
시즌 투	시즌2	season 2 / 시즌 투	
투 쓰리	2, 3	two, three / 투, 쓰리	
플러스 포	+4	plus 4 / 플러스 4 / 플러스 포	
플러스 마이너스 삼	+ -3	plus minus 3	

구분	내용																	
발성내용의 전사	⑥ 숫자 - 숫자 표기는 숫자는 살리되 조, 억과 같은 숫자의 단위는 한글로 살려서 표기 - 숫자 사이의 콤마는 적는 것이 자연스러운 경우에는 표기																	
	발성내용	바른 전사	잘못된 전사	백억	100억	100000000000	이천억 개	2,000억 개	2000000000000개	일조원	1조 원	1000000000000원	일경 달러	1경 달러	일경 dollar	이백 삼조 오천 사억원	203조 5,004억 원	203,500,400,000,000원
	발성내용	바른 전사	잘못된 전사															
	백억	100억	100000000000															
	이천억 개	2,000억 개	2000000000000개															
	일조원	1조 원	1000000000000원															
	일경 달러	1경 달러	일경 dollar															
	이백 삼조 오천 사억원	203조 5,004억 원	203,500,400,000,000원															
	- 천, 백, 십의 단위도 조, 억 등의 단위와 함께 사용되지 않고 단독으로 사용되는 경우에는 한글로 살려서 표기																	
	발성 내용	바른 전사	오천원	5 천원	이백개	2 백개	오천이백원	5,200 원										
	발성 내용	바른 전사																
	오천원	5 천원																
	이백개	2 백개																
	오천이백원	5,200 원																
	- 숫자와 이어지는 단어의 띄어쓰기는 ① 띄어쓰기를 참고 - 우리말 계열의 수는 한글로 표기하는 것을 원칙으로 함 - 단 의미하는 수가 10을 초과하는 경우 가독성을 위하여 숫자로 표기																	
	발성 내용	바른 전사	한 달 두 달 세달	한 달, 두 달, 세 달	술 석 잔	술 석 잔	열 한 마리와 열 명	11 마리와 열 명	마흔 아홉명의 사람들	49 명의 사람들								
	발성 내용	바른 전사																
	한 달 두 달 세달	한 달, 두 달, 세 달																
	술 석 잔	술 석 잔																
열 한 마리와 열 명	11 마리와 열 명																	
마흔 아홉명의 사람들	49 명의 사람들																	
- 시간을 나타내는 경우에는 우리말 계열의 숫자라 하더라도 숫자로 표기																		
발성 내용	바른 전사	두시 십구분	2시 19분	세시 반	3시 반													
발성 내용	바른 전사																	
두시 십구분	2시 19분																	
세시 반	3시 반																	
- 한자어 계열의 수는 숫자로 표기하는 것을 원칙으로 함 - 단 ‘아기돼지삼형제’와 같이 고유한 명칭이거나 관용적으로 한글로 쓰는 표현은 한글로 표기																		
발성 내용	바른 전사	일번문제 한번 풀어봐	1번 문제 한 번 풀어봐	독수리 오형제	독수리 오형제													
발성 내용	바른 전사																	
일번문제 한번 풀어봐	1번 문제 한 번 풀어봐																	
독수리 오형제	독수리 오형제																	

구분

내용

발성내용의 전사

불투명 수량사(서너 개, 사오십, 오뉴월, … 등)도 마찬가지로 10 이하의 우리말 숫자에 대해서는 한글로, 그렇지 않은 경우에는 숫자로 표기

발성내용

바른 전사

잘못된 전사

세 네 개

서너 개

3, 4개 / 3 4 개 / 3-4개

삼 사십 대

3, 40대

3 40대

이 삼 천원

2, 3천 원

2-3천원

오뉴월과 칠팔월

5, 6월과 7, 8월

5 6 월과 7 8 월

사 오십 프로

4, 50%

4 50 퍼센트

⑦ 단위

영문으로 표기 가능한 것은 영문으로 전사하고 숫자와 단위는 가급적 한 칸 띄어쓰

발성 내용

바른 전사

이리터는 이천미리리터이다

2 L는 2,000 mL 이다.

백미터 삼십 오 센티미터 백팔십센치미터

100 m, 35 cm

칠십오킬로그램

180 cm, 75 kg

단위가 생략된 경우 발화의 의도가 명백하면, 생략된 기호를 살려서 전사

단, 의도를 알 수 없는 경우에는 한글로 전사

발성 내용

바른 전사

오 키로나 빠졌어

5 kg이나 빠졌어

3 센치나 자랐어

3 cm나 자랐어

십이 킬로

12 킬로

특수기호가 들어가야 되는 단위는 한글로 전사

발성내용

바른 전사

잘못된 전사

삼 제곱미터

3 제곱미터

3 m²

사점삼세제곱미터

4.3 세제곱미터

4.3 m³

백팔십도

180 도

180°

삼십육점오도씨

36.5 도씨

35.6℃

⑧ 간투어

간투어(filler word)란 발성자가 다음 발성을 준비하기 위해서 소요되는 시간을 벌기 위해서 발성하는 것으로 의미가 없는 것을 의미

명확히 간투어로 확인되는 경우 간투어 앞에 f/를 붙여 표기

간투어는 표준어 규칙대로 띄어쓰며, f/와 간투어 사이는 띄어쓰지 않음

f/음 내가 그래서 있잖아.

간투어로는 아래와 같은 것이 있으며 이외에 다양한 것이 있을 수 있음

f/아, f/그, f/어, f/음, f/저기, f/저, f/에, f/음.


구분	내용
	- 간투어와 유사한 성격으로 발성한 단어라하더라도 길이가 길거나 강하게 발음한 경우 일반적인 단어로 취급하여 전사 그러니까 오늘 온다는 말이지? ⑨ 오발성 및 알아듣기 힘든 발음 - 오발성 및 알아듣기 힘든 발음은 사용자의 의도를 추정하여 표준어법이나 의도에 맞게 전사 어머니를 어머니로 오발성한 경우, 어머니로 전사 - 단, 음성이 명확하지 않은 경우 의도를 추정하기도 어렵다면 u/로 표시
추가 정보의 전사	• 앞서 설명한 내용은 발화자가 발성한 내용을 글로 표기하는 방법에 관한 것이었으나 발화자가 발성한 내용이 아닌 것도 일부 필요에 따라 전사에 포함할 수 있음 • 예를 들어 발화성 도중에 발생한 환경 잡음, 웃음소리, 상대방의 호응어 등을 포함 • 단, 상대방의 의미있는 발성은 추가 정보가 아니라 오버랩으로 처리 ① 잡음 - 발화 중 환경 또는 다른 사람의 목소리 등으로 인하여 잡음이 발생한 경우 잡음이 발생한 위치에 n/로 표기하여 잡음이 있음을 전사 - 잡음은 주변의 웃음소리, 잡음 등을 포함하며 뚜렷이 구분되는 것만을 표기하며 발성에 비해 크기가 작은 것은 무시해도 좋음 - 해당하는 잡음이 날 때마다, 잡음이 들린 곳에 단어 단위로 n/를 표기 - 발화 중 전체적인 잡음 환경인 경우 문장의 맨 앞에 n/를 표시 - 발화자 표시가 있는 경우 발화자 표시 앞에 전사 n/[A]열어보면은 어! 굉장히 질문이 많아 요 n/열어보면은 어! 굉장히 질문이 많아요 열어보면은 n/어! n/굉장히 n/질문이 많아요 - 발화자의 웃음소리 중 문장 중간에 있는 분명한 웃음소리는 잡음이 아니며 최대한 웃음소리와 일치하는 한글 발음으로 전사 - 해당 단어 앞에 l/를 붙여서 웃음소리임을 표시 - 발화자의 웃음소리 중 문장 사이에 있는 일반적인 작고 짧은 웃음소리는 전사하지 않으며 무시 어떻게 l/하하 오셨어요 오늘 할일은 내일의 l/크크크 내게 미룬다.

구분	내용																		
추가 정보의 전사	② 호응어 - 호응어란 백채널(back channel)에 관한 것으로 다른 발화자의 말에 덧붙이는 추임새를 의미 - 호응어는 두 가지 방법으로 표기할 수 있으며 두 가지 방법을 동시에 적용하는 것도 가능 - 단, 하나의 데이터셋에 대해서는 전체 데이터에 대하여 일관된 방법으로 적용해야 함 [호응어 화자의 발성내용을 독립 표기] - 호응어의 위치와 내용을 표기하는 방법으로 호응어 자체의 하나의 문장으로 간주하여 두 발화가 겹쳐서 발화된 것처럼 표기 - 호응어의 시작점과 끝점에 대한 시간 정보와 발화자 정보를 표기하고 호응어의 내용도 발성내용에 맞게 전사 - 단, 호응어임을 표기하기 위하여 문장의 맨앞에 b/를 붙임																		
	b/그렇죠 b/네 b/네네 b/아 b/음 b/저런																		
	[주 발화자의 발성내용에 병행 표기] - 호응어의 위치만을 표기하는 방법으로 주 발화자의 전사 내용 중 다른 화자가 발성한 호응어의 위치를 b/로 표기 - 단, 문장의 맨앞에 오는 b/는 이 발화 자체가 호응어임을 의미하므로 주의																		
	오늘 회사에 갔는데 b/ 쉬는 날 이었어 b/ b/어 b/저런																		
전사 규칙에 사용된 꼬리표	• 본 전사 규칙에는 영어 소문자 알파벳에 슬래시(/)를 붙여 꼬리표(tag)로 사용 • 사용된 꼬리표의 종류는 아래와 같음 <table><tr><th>꼬리표</th><th>의미</th><th>참고</th></tr><tr><td>b/</td><td>호응어로 단독으로 사용될 경우 해당 위치에 상대방의 호응어가 있거나 다른 단어의 앞에 붙어있는 경우 그 단어가 호응어임을 나타냄</td><td>② 호응어</td></tr><tr><td>f/</td><td>간투어로 이어지는 단어가 간투어임을 표시</td><td>⑧ 간투어</td></tr><tr><td>l/</td><td>웃음소리로 이어지는 단어가 웃음소리임</td><td>① 잡음</td></tr><tr><td>n/</td><td>잡음으로 단어 앞에 붙은 경우에는 해당 위치에서 환경 잡음이 발생했음을 의미하고 문장 가장 앞에 붙은 경우에는 발성 구간 전체에 걸쳐 잡음이 존재함을 의미</td><td>① 잡음</td></tr><tr><td>u/</td><td>오발성으로 알아듣기 힘들고 의도도 알 수 없는 발성</td><td>⑨ 오발성 및 알아듣기 힘든 발음</td></tr></table>	꼬리표	의미	참고	b/	호응어로 단독으로 사용될 경우 해당 위치에 상대방의 호응어가 있거나 다른 단어의 앞에 붙어있는 경우 그 단어가 호응어임을 나타냄	② 호응어	f/	간투어로 이어지는 단어가 간투어임을 표시	⑧ 간투어	l/	웃음소리로 이어지는 단어가 웃음소리임	① 잡음	n/	잡음으로 단어 앞에 붙은 경우에는 해당 위치에서 환경 잡음이 발생했음을 의미하고 문장 가장 앞에 붙은 경우에는 발성 구간 전체에 걸쳐 잡음이 존재함을 의미	① 잡음	u/	오발성으로 알아듣기 힘들고 의도도 알 수 없는 발성	⑨ 오발성 및 알아듣기 힘든 발음
꼬리표	의미	참고																	
b/	호응어로 단독으로 사용될 경우 해당 위치에 상대방의 호응어가 있거나 다른 단어의 앞에 붙어있는 경우 그 단어가 호응어임을 나타냄	② 호응어																	
f/	간투어로 이어지는 단어가 간투어임을 표시	⑧ 간투어																	
l/	웃음소리로 이어지는 단어가 웃음소리임	① 잡음																	
n/	잡음으로 단어 앞에 붙은 경우에는 해당 위치에서 환경 잡음이 발생했음을 의미하고 문장 가장 앞에 붙은 경우에는 발성 구간 전체에 걸쳐 잡음이 존재함을 의미	① 잡음																	
u/	오발성으로 알아듣기 힘들고 의도도 알 수 없는 발성	⑨ 오발성 및 알아듣기 힘든 발음																	


[표 III-175] 텍스트, 음성데이터 전사규칙


※ 'ETRI 전사작업 가이드라인 v1.0' (24.1.10)

2 이미지, 영상 데이터 가공

데이터 가공	설명
바운딩 박스 (Bounding Box)	• 이미지 혹은 영상 안 객체를 직사각형 모양의 박스 안에 포함되도록 그리는 가공 방법 • 데이터 가공 작업에서 가장 일반적으로 사용 • 객체 전체가 커버되도록 하며, 박스 안에 객체 이외의 여백을 최소화하도록 지정 〈바운딩 박스 예시〉 
키포인트 (Keypoint)	• 특정 지점(특징점)을 가공하는 방법 • 안면 인식을 통한 감정 분석과 같이 정밀하고 섬세한 작업을 요구하는 기술 • 객체의 중요 특징점을 지정하여 물체를 추적하고 인식할 수 있음 〈키포인트 예시〉 

데이터 가공	설명
폴리곤 (Polygon)	• 다각형 모양으로 객체의 가시 영역 외곽선을 따라 점을 찍어 그리는 가공 방법 • 객체 이외의 포함된 빈공간으로 인해 발생하는 오류에 대응할 수 있는 기능 • 사물의 테두리를 따라 그리는 것을 통해 여백 없이 정확히 물체만을 인식하기 위해 사용 〈폴리곤 예시〉
폴리라인 (Polyline)	• 여러개의 점을 가진 선을 활용하여 특정 영역을 가공하는 방법 • 인도와 차선, 경계 등의 선형 데이터들을 구분하고 인식시키기 위해서 사용 〈폴리라인 예시〉
시멘틱 세그멘테이션 (Semantic)	• 이미지의 모든 픽셀에 클래스를 부여하는 가공 방법 • 물체, 배경 등을 의미적으로 분할하여 자율주행, 의료 영상 분석 기술 개발 등에 사용

데이터 가공	설명
segmentation)	〈시멘틱 세그멘테이션 예시〉 
인스턴스 세그멘테이션 (Instance segmentation)	• 이미지의 모든 픽셀이 같은 클래스여도 다른 인스턴스를 부여하는 가공 방법 • 객체 인식 시 중첩된 경우 분할하는 기술 개발 등에 사용 〈인스턴스 세그멘테이션 예시〉  출처: MS COCO 데이터셋
팬옵틱 세그멘테이션 (panoptic segmentation)	• 시멘틱 세그멘테이션과 인스턴스 세그멘테이션을 결합한 방식으로 셀 수 있는 클래스 (예, 차, 사람 등)를 Thing 클래스라고 하며, 셀 수 없는 클래스(예, 하늘, 길 등)는 Stuff 클래스라고 하며, Thing 클래스에 대해서는 인스턴스 세그멘테이션, Stuff 클래스에 대해서는 시멘틱 세그멘테이션 작성을 수행

데이터 가공	설명
	〈펜옵틱 세그멘테이션 예시〉  원본 이미지  시멘틱 세그멘테이션  인스턴스 세그멘테이션  펜옵틱 세그멘테이션 출처: MS COCO 데이터셋

[표 III-176] 이미지, 영상 데이터 가공 방법

3

3D 데이터 가공

데이터 가공	설명
큐보이드 (Cuboid)	• 2D로 작업할 수 없는 자동차, 건물 등 입체적인 객체를 직육면체(3D Bounding Box)로 가공하는 방식 • 3D 객체 가공 작업에서 사용 • 객체 전체가 커버되도록 하며, 직육면체(3D Bounding Box) 안에 객체가 들어오도록 지정 출처 : 아이티데일리(http://www.itdaily.kr), 아주일보(https://www.ajunews.com) 〈큐보이드 예시〉  

[표 III-177] 3D 데이터 가공 방법

부록4

개인정보보호 가이드

1

인공지능 개인정보보호 개요

1.1 배경 및 목적

- 개인정보 보호법상 공개된 개인정보를 수집·이용할 수 있는 법 해석 기준 제시

구분	내용
배경	• 인공지능 기술이 적용된 새로운 서비스가 도입·확산됨에 따라 개인정보 침해 등 다양한 사회적 문제 발생 우려 • 광범위한 AI 도입 시, 데이터 및 알고리즘 편향으로 인한 잠재적 편견, 차별 및 기본 인권 침해에 대한 우려 제기 • 인공지능 학습용 데이터 구축 시 개인정보 처리의 안전성과 신뢰성 확보 필요 • 크고 작은 개인정보 유출 사고가 지속되어 개인정보보호 정책을 강화해야 한다는 사회적 요구 지속 • 다양한 데이터 활용을 필요로 하는 새로운 산업과 기술발전으로 개인정보 침해 위험도 증가 추세
목적	• 인공지능 학습용 데이터 구축 사업 생애주기(Life-Cycle) 과정에서 개인정보의 안전한 활용과 보호를 위한 관리체계 마련 • 인공지능 학습용 데이터 구축 사업의 개인정보보호 관련 지원 및 점검 확대 • 사업에 참여하는 사업수행기관(주관기관, 참여기관) 및 수요기관의 개인정보보호를 위한 역할과 책임 강화 • 개인정보의 적법·안전한 처리와 침해 예방 등을 위한 「개인정보 보호법」 준수 가이드

[표 III-178] 개인정보보호의 배경 및 목적

프라이버시 위험	인공지능이 위험에 영향을 주는 방식	설명
데이터 수집 위험	감시(Surveillance)	• 수집 개인정보의 규모와 편재성으로 감시 위험 악화
데이터 처리 위험	식별(Identification)	• 규모, 자연성, 견고성, 편재성 등으로 새로운 식별 위험 생성
	집적(Aggregation)	• 규모, 자연성, 편재성, 예측 역량 등에 따라 새로운 유형의 집적 위험 생성
	골상학/관상학 (Phrenology/Physiognomy)	• 임의의 입력과 출력 사이의 연계를 학습하여 골상/관상 관련 위험 생성
	목적 외 이용 (Secondary Use)	• 새로운 역량을 생성하여 목적 외 이용 위험 악화
	배제(Exclusion)	• 동의 없는 개인정보 대량 학습으로 배제 위험 악화
	불안전(Insecurity)	• 새로운 취약점을 형성하여 불안전 위험 악화
데이터 확산 위험	노출(Exposure)	• 삭제 정보를 재구성하는 생성 기술로, 새로운 유형의 노출 위험 생성
	왜곡(Distortion)	• 실제 같은 가상 이미지/오디오 생성으로 새로운 왜곡 위험 생성
	공개(Disclosure)	• 추론으로 새로운 유형의 공개 위험 생성 및 학습 데이터 공유로 악화
	증가한 접근성 (Increased Accessibility)	• 대규모 데이터 세트 공개로 인한 개인정보 접근성 위험 악화
침입 위험	침투(Intrusion)	• 중앙화/편재된 감시 인프라로 규모 및 편재성 측면의 침투 위험 악화

[표 III-179] 인공지능 프라이버시 위험 분류 체계(Taxonomy)

※ 출처: 2024 개인정보 이슈 심층 분석 보고서(VOL.1) - 인공지능(AI) 시대 안전한 개인정보 활용, KISA Hao-Ping Lee, et al.(2024), 저자 재구성

1.2 인공지능 관련 개인정보 처리 특성 및 기본방향

구분	인공지능 학습용 데이터 처리 특성	인공지능 학습용 데이터 처리 기본방향
대규모 데이터의 처리	- AI 학습데이터는 규모가 크고 다양한 개인정보와 민감한 사생활에 관한 정보가 포함될 가능성이 높음 - 또한 서비스 운영 중에도 이러한 데이터를 지속적으로 활용하려는 수요가 많음	정보주체의 동의, 가명처리 등 적법한 방법으로 개인정보를 수집하여 예측 가능하고 허용된 목적 범위에서 이용하고, 안전하게 관리하는 것이 중요
복잡성 불투명성	AI 학습데이터는 구축하는 과정에서 개인정보 처리방식은 매우 복잡하고 이용자는 자신의 개인정보가 어떻게 처리되는지 알기 어려워 정보주체의 권리행사가 제한될 우려	개인정보 처리내역 등을 투명하게 공개하여 정보주체가 자신의 개인정보 처리에 대한 권리를 행사할 수 있도록 이용자 참여에 대한 보장이 중요
자동화 불확실성	일반적으로 AI모델은 지식·확률기반의 추론 방식을 이용하여 데이터를 분석·처리함 이를 활용한 자동화된 서비스를 개발·운영하는 과정에서 데이터 처리 결과를 예측하기 어려워 사생활 침해, 사회적 차별·편향 등의 문제가 발생할 수 있음	프라이버시가 보호될 수 있도록 개인정보 처리 전반에 대한 책임 있는 관리가 중요하고, 이용자가 차별받지 않도록 개인정보의 처리 결과의 공정함을 고려할 필요

[표 III-180] 인공지능 학습용 데이터의 처리 특성 및 기본방향

※ 출처: 인공지능(AI) 개인정보보호 자율점검표(2021. 05, 개인정보보호위원회), 25년 11월 - 변동 사항 없음

1.3 인공지능 관련 개인정보보호 원칙 법 및 기준

- 인공지능 기술·서비스의 개인정보 처리 특성을 고려한 개인정보보호를 위해서는 현행 법령에 따른 개인정보보호 의무사항 준수뿐 아니라, 자율적 보호 활동 및 윤리적 이슈 대응이 중요

「개인정보 보호법」상 개인정보보호 원칙(§3)	개인정보보호 중심설계(PbD)	AI 윤리기준
① 필요 최소한의 정보 수집 및 처리 목적의 명확화 ② 목적 범위 내에서 적법하게 처리, 목적 외 활용금지 ③ 처리목적 내에서 정확성·완전성·최신성 보장 ④ 권리침해 가능성 등을 고려하여 안전하게 관리 ⑤ 개인정보 처리 내역의 공개 및 정보주체의 권리보장 ⑥ 사생활 침해를 최소화하는 방법으로 처리 ⑦ 익명 및 가명 처리의 원칙 ⑧ 개인정보처리자의 책임준수·신뢰 확보 노력	① 사후 조치가 아닌 사전 예방 ② 초기 설정부터 프라이버시 보호 조치 ③ 프라이버시 보호를 내재한 설계 ④ 프라이버시 보호와 사업기능의 균형 ⑤ 개인정보 생애주기 전체에 대한 보호 ⑥ 개인정보 처리 과정에 대한 투명성 유지 ⑦ 이용자 프라이버시 존중	① 인권보장 ⑥ 연대성 ② 프라이버시 보호 ⑦ 데이터 관리 ③ 다양성 존중 ⑧ 책임성 ④ 침해금지 ⑨ 안전성 ⑤ 공정성 ⑩ 투명성

[그림 III-11] 개인정보보호 원칙 법 및 기준

※ 출처: 인공지능(AI) 개인정보보호 자율점검표(2021. 05, 개인정보보호위원회), 25년11월 -변동 사항 없음

1.4 인공지능 관련 개인정보보호 6대 원칙




[그림 III-12] 개인정보보호 6대 원칙

※ 출처: 인공지능(AI) 개인정보보호 자율점검표(2021. 05, 개인정보보호위원회), 25년11월 -변동 사항 없음

2 생애주기별 개인정보보호 가이드라인

2.1 개요

- 인공지능 학습용 데이터의 생애주기별(계획, 구축, 운영·활용 단계) 개인정보보호에 대한 가이드라인



[그림 III-13] 인공지능 학습용 데이터 생애주기

● 가이드라인 구축

단계	내용
계획	- 사업수행계획서 포함 사항 - 데이터 구축에 개인정보 포함 여부 및 필수적인 개인정보의 구체적인 사항 - 개인정보를 활용하는 경우, 개인정보 보호법상의 의무·권고 사항에 대해 사전점검 및 법률 자문 실시* - 개인정보보호 및 관리를 위한 이행·점검 및 조치 방안** - 수행기관(주관기관, 참여기관) 담당자는 사업착수단계에서 사업관리기관에서 시행하는 개인정보보호 교육 이수 - 개인정보 보호법의 심각한 위반사항 발생 시 관련 법령 및 규정에 따라 협약 해지, 사업 참여 제한 등의 불이익을 받을 수 있음
구축	- 데이터 획득(수집) - 개인정보가 포함된 데이터를 수집하는 경우, 법률에 근거하거나 정보 주체의 동의 필수 - 만14세 미만 아동의 개인정보를 수집하는 경우 법정대리인 동의 필요 - 정보 주체 이외 개인정보 수집에 대한 수집 출처 및 처리목적 고지 - 데이터 정제/가공 - 데이터의 개인정보(얼굴, 번호판 등), 국가 보안 사항(공간정보, 위치정보 등) 등이 포함된 경우 개인정보·민감정보 비식별화 조치 - 음성 및 텍스트 데이터의 경우 비속어 및 개인정보, 민감정보 등의 비식별화 처리 - AI 모델/학습 - 모델 검토 후 필요시 AI 모델에 대한 미세조정·정렬 등 안전성 강화 장치 추가 - AI 시스템 접근권한 통제, 입출력 필터링 적용 - 개인정보보호 자율 점검 실시 및 보고
운영·활용	- 과제 수행 산출물(원시데이터 포함) - 과제 종료 후 5년간 보존 - AI 개발·운영종료 등으로 개인정보가 불필요하게 되었을 때에는 지체 없이 파기 - 사업 종료 이후 인공지능 사업 결과물(모델)에 개인정보 포함 여부 확인 - 모델 배포 전 테스트를 통한 프라이버시 리스크 점검·문서화 - 데이터 개방 이후에도 개인정보보호에 대한 주기적 검증 실시

* 인공지능 개인정보보호 자율점검표(2021. 05, 개인정보보호위원회)에 따른 자가점검을 실시하고 그 결과를 제출 및 과제조정위원회에서 검토

** 개인정보 비식별화를 시행하는 경우 '가명정보 처리 가이드라인(개인정보보호위원회)'을 준수

*** 합성데이터를 사용하는 경우 '합성데이터 생성 참조모델(개인정보보호위원회)'을 준수

[표 III-181] 생애주기별 개인정보보호 절차 및 가이드

2.2 계획단계 개인정보보호 가이드

● 계획단계 개인정보보호 검토사항

- 인공지능 학습용 데이터 구축 기획·설계 단계부터 PbD 원칙³⁾에 따라 개인정보 침해 위험을 분석·제거
- 「개인정보 보호법」 등 관련 법에 따른 준수사항, 사생활 보호 방안 등을 AI 학습용 데이터 구축 계획에 반영
- 사업수행계획서에 아래의 사항을 반드시 포함

3) Privacy by Design(PbD) : 제품·서비스 개발 시 기획 단계부터 개인정보 처리의 전체 생애주기에 걸쳐 이용자의 프라이버시를 고려한 기술·정책을 설계에 반영하는 것을 의미하며, 국제적으로 광범위하게 통용되는 개인정보보호 원칙

- 데이터 구축에 개인정보 포함 여부 및 필수적인 개인정보의 구체적인 사항
 - 개인정보를 활용하는 경우, 개인정보 보호법상의 의무·권고사항에 대해 사전점검 및 법률 자문 실시 방안
 - 개인정보보호 및 관리를 위한 이행·점검 및 조치 방안
- 계획단계 개인정보보호 참고사항
- PbD (Privacy by Design) 원칙 적용
 - 수집 이용하려는 전체 데이터 현황 파악
 - 개인정보 항목과 유형(식별자, 속성정보 등) 분석
 - 개인정보 항목별 수집 근거(동의 등)와 활용 방식(가명처리 등) 결정
 - 인공지능 학습용 데이터 구축에 개인정보 포함 여부 및 필수적인 개인정보의 구체적인 사항
 - 개인정보 처리 흐름도 작성을 사전에 수행하고, 개인정보 처리에 따른 위험성 침해요인 분석, 대안 마련 등을 순차적으로 수행하여, 인공지능 학습용 데이터 구축 전반의 개인정보보호 관련 사항을 검토
 - 사전 위험분석, 안전성 점검, 법령 해석 등을 위해 외부 전문가에게 자문을 받거나 전문기관에서 질의 가능
 - ※ 한국인터넷진흥원(개인정보침해신고센터, 국번없이 118) 등
 - 「자동처리되는 개인정보보호 가이드라인(Privacy by Design 적용사례를 중심으로, '20. 12), 2025년 변동 없음」 참고

2.3 구축 단계 개인정보보호 가이드

2.3.1 데이터 획득(수집) 단계 개인정보보호 가이드

- 개인정보 수집 동의
- 개인정보는 필수·선택 동의로 구분하여 목적에 필요한 최소한의 개인정보를 수집
 - 개인정보 처리에 대해 정보 주체의 동의를 받을 때에는 각각의 동의 사항을 구분하여 알리고 수집·이용 목적, 수집·이용하려는 항목, 기간 등에 관한 내용을 명확히 알려야 함
 - 개인정보 수집·이용 동의를 받았더라도 목적 외 이용인 경우에는 정보 주체의 추가적 동의 필요
 - 만 14세 미만 아동의 개인정보 수집 시 법정대리인의 동의
- 개인정보 수집 동의 참고사항
- ‘인공지능 학습용 데이터 구축’ 개인정보의 수집·이용 동의를 받는 경우 정보 주체가 충분히 이해·예측할 수 있도록 ‘인공지능 학습용 데이터’ 의미, 개인정보 이용 범위·목적 등을 구체적으로 알려야 함

단계	내용
개인정보 수집항목	• “OO SNS 대화 정보”와 같이 이용 항목을 구체적으로 작성
수집·이용 목적	• “OO 서비스의 챗봇 알고리즘 개발(학습용)”과 같이 구체적으로 작성
보유·이용 기간	• OO 알고리즘 개발을 위해 O 개월 보관·이용

※다만, 과학적 연구, 통계작성, 공익적 기록보존 등 목적으로 가명처리하여 필요 최소한의 기간동안 보관·이용 가능하며 동의를 거부할 권리가 있음을 알리고, 거부 시 불이익이 있는 경우 그 내용을 기재

[표 III-182] 인공지능 학습용 데이터 수집·이용 동의

- 민감정보와 고유식별정보

구분	내용
민감정보	- 민감정보(법 23조) - 개인정보처리자가 민감정보 공개로 인해 사생활 침해의 위험성이 있다고 판단하는 경우, 사전에 민감정보의 공개 가능성 및 비공개 선택 방법을 정보 주체에게 알기 쉽게 고지할 의무 규정
고유식별 정보	- 고유식별정보(법 24조, 시행령 제19조) : ① 여권번호, ② 운전면허번호, ③ 외국인등록번호 등 - 단, 주민등록번호는 법률·대통령령 또는 헌법기관 규칙에 구체적 근거가 없는 경우 처리가 불가능함(법 24조의2)

[표 III-183] 민감정보와 고유식별정보


※ 출처 : 개인정보 보호법 전면개정 2025.4, 개인정보보호위원회

2.3.2 데이터 정제/가공단계 개인정보보호 가이드

● 개인정보 비식별화

- 개인정보 비식별화 조치

- 개인정보에서 개인식별 요소를 제거하여 특정 개인을 알아볼 수 없는 형태로 만드는 조치
- 식별자 삭제 등 일련의 조치를 통한 식별방지와 프라이버시 모델 기반 추론 방지
- 정보에 포함되어 있는 개인정보의 일부 또는 전부를 삭제하거나 다른 정보로 대체함으로써 다른 정보와 결합하여도 특정 개인을 식별하기 어렵도록 하는 일련의 조치



[그림 III-14] 개인정보 비식별화 정의

※ 출처: 개인정보 비식별 조치 가이드라인 (비식별 조치 기준 및 지원·관리체계 안내), 2016. 06 관계부처 합동)

● 개인정보 비식별 조치 및 사후관리 절차

- **(사전검토)** 개인정보 해당 여부를 검토 후, 개인정보가 아닌 것이 명백한 경우 법적 규제 없이 자유롭게 활용
- **(비식별 조치)** 정보 집합물(데이터셋)에서 개인을 식별할 수 있는 요소를 전부 또는 일부 삭제하거나 대체하는 등의 방법을 활용, 개인을 알아볼 수 없도록 하는 조치
- **(적정성 평가)** 다른 정보와 쉽게 결합하여 개인을 식별할 수 있는지를 「비식별 조치 적정성 평가단」을 통해 평가
- **(사후관리)** 비식별 정보 안전조치, 재식별 가능성 모니터링 등 비식별 정보 활용 과정에서 재식별 방지를 위해 필요한 조치 수행

● 가명처리

- 인공지능 학습용 데이터의 가명처리⁴⁾ 유의사항
 - “가명처리”는 개인정보의 일부를 삭제하거나 일부 또는 전부를 대체하는 과정, “가명정보처리”는 가명처리를 통해 생성된 가명정보를 이용·제공 등 활용하는 행위를 말함
 - 인공지능 학습용 데이터를 정보 주체의 동의 없이 과학적 연구 등 목적으로 개인정보를 가명처리하여 활용하려는 경우, 가명처리의 적정성, 사생활 침해 가능성에 대한 검토 강화 필요
 - 가명처리 방법을 적용하여 학습데이터를 안전하게 가명처리하고, 적정성 검토 후 문제 발견 시 추가 가명 처리하여 정보 주체의 권리가 침해되지 않도록 해야함
 - (예시) SNS 대화 데이터의 경우 대화 발화자의 식별 정도⁵⁾ 외에도 대화 내용에 포함된 특정 개인의 식별 가능 정보 또는 사생활 침해 우려 정보도 가명처리 필요
 - 인공지능 학습용 데이터 가명처리·활용의 특수성 및 고려사항
 - (개인 식별성 판단의 어려움) 개인식별 가능 정보와 그렇지 않은 정보의 구분이 상대적이며, 처리 목적·환경 등에 따라 다르게 판단될 수 있음
 - (가명처리 기술의 불완전성) 비정형데이터 내 개인식별 위험성이 있는 모든 항목을 완벽하게 탐지·처리할 수 있는 기술이 부재
 - (재식별 공격 위험) AI 및 데이터 복원기술 발달로, 다른 정보와의 연계·결합 없이도 개인 재식별 공격 위험성 증가
- 인공지능 학습용 데이터의 가명정보의 공개제한
 - 가명정보를 불특정 다수에게 공개하는 경우에는 공개의 목적이 통계작성, 과학적 연구, 공익적 기록보존 등의 목적에 해당하는지가 불분명하고, 불특정 다수 중 누군가는 공개하는 정보와 결합하여 특정 개인을 알아볼 수 있는 정보를 가지고 있을 수 있어, 가명정보의 공개는 사실상 제한됨
 - 불특정 제3자(공개 등)에게 제공하는 경우 익명정보로 처리하는 것을 원칙으로 함
 - 가명정보를 특정 제3자에게 제공하는 경우 가명정보처리 목적의 합법성, 재식별 금지 등 책임은 제3자에게 있으며, 이에 대한 별도 계약을 체결할 수 있음
- 개인정보보호위원회에서 발간하는 ‘가명정보처리 가이드라인’ 준용 필수

III

부록

4) 개인정보의 일부를 삭제하거나 일부 또는 전부를 대체하는 등의 방법으로 추가 정보가 없이는 특정 개인을 알아볼 수 없도록 처리하는 것을 말함

5) 식별정보, 식별가능정보의 예시 등 자세한 사항은 「가명정보 처리 가이드라인」(P.17) 참고

개인정보



살아있는 개인에 관한 정보로
성명, 주민등록번호, 영상 등 개인을
알아볼 수 있는 정보

성명	홍길동
나이	32세
전화번호	010-1234-5678
주소	서울 종로구 한글길 12

가명정보



개인정보의 일부 또는 전부를
삭제·대체하는 등 가명처리를 통해
추가정보 없는 특정 개인을 알아볼 수
없는 정보

성명	홍 ○○
나이	30대 초반
전화번호	010-****-****
주소	서울특별시

익명정보



시간·비용·기술 등을 합리적으로 고려할 때
다른 정보를 사용하여도 더 이상 개인을
알아볼 수 없는 정보

성명	(삭제)
나이	30대
전화번호	(삭제)
주소	대한민국

[그림 III-15] 개인정보, 가명정보, 익명정보 예시

※ 출처 : 개인정보보호위원회 가명정보 처리 가이드라인

● 비식별처리와 합성데이터의 차이

- ‘비식별처리’는 일반적으로 데이터의 직접식별자, 간접식별자를 삭제하거나 일부 또는 전부를 대체하는 등의 방법으로 개인정보를 변형하는 것
- 비식별처리된 데이터는 개인과 관련된 실제 데이터이며, 비식별화 수준에 따라 여전히 개인정보로 취급되거나 규제 대상에 포함될 수 있음
- ‘합성데이터’는 실제 데이터의 특성만 참조하여 실제 개인과 직접적인 관련이 없는 완전히 새로운 데이터셋을 생성해내는 방식
- 합성데이터는 적절하게 생성된 경우, 실제 사람의 신원을 재식별해 낼 수 없고 개인에 대한 특정된 정보를 포함하지 않음
- 따라서 안전하게 생성된 합성데이터는 개인정보에 대해 요구되는 보호조치 등이 불필요하며, 분석과 연구 등에 광범위하게 활용 가능

구분	개인정보	가명정보	익명정보	합성데이터
프라이버시 위험	높음	중간	낮음	낮음
데이터 유용성	높음	중간	낮음	비교적 높음

[표 III-184] 비식별처리된 정보(가명·익명정보)와 합성데이터 비교

2.4 비정형데이터 가명처리 기준 (‘24.02, 개인정보보호위원회)

- 추진 배경
 - AI 기술발전과 컴퓨팅 자원 발달로 데이터 활용수요가 전통적 정형데이터(수치)에서 비정형데이터(이미지, 영상, 음성, 텍스트)로 변화
 - (전 세계 데이터 중 이미지, 영상, 음성, 텍스트 등 비정형데이터가 최대 90%를 차지 (IDC, '23))
 - 「가이드라인」은 정형데이터 기준으로 되어있어 비정형데이터 고유 특성과 AI 시대 기술발전 등을 반영하지 못하는 한계
 - AI 일상화 등 디지털 심화 시대에 맞는 비정형데이터 가명처리기준을 마련하여 기업·연구자의 불확실성 해소 및 기술혁신지원
 - 개인정보보호위원회에서 발간하는 ‘가명정보처리 가이드라인’ 준용 필수
- 비정형데이터 가명처리·활용의 특수성 및 고려사항

특성	고려사항
개인식별성 판단의 어려움	● 개인식별 가능 정보와 그렇지 않은 정보의 구분이 상대적이며, 처리 목적·환경 등에 따라 다르게 판단될 수 있음
가명처리 기술의 불완전성	● 비정형데이터 내 개인식별 위험성이 있는 모든 항목을 완벽하게 탐지·처리할 수 있는 기술이 부재
재식별 공격 위험	● AI 및 데이터 복원기술 발달로, 다른 정보와의 연계·결합 없이도 개인재식별 공격위험성 증가

[표 III-185] 비정형데이터 가명처리·활용의 특수성 및 고려사항

※ 출처: 비정형데이터 가명처리 기준 주요 내용, 개인정보보호위원회 24.02- 2025.11 변동없음


2.4.1 비정형데이터 가명처리 기본원칙

구분	내용
1	- 데이터 처리 목적·환경, 민감도 등을 종합적으로 고려하여 개인식별 위험성이 있는 정보를 판단하고, 합리적인 처리 방법·수준 설정 - 연구목적에 맞춰 데이터 자체 훼손을 최소화하면서 관리적·환경적 통제 등 다양한 안전성 확보방안 적용 가능 ▶ 연구목적 달성에 필수적인 정보 항목을 남기는 대신 그 외 정보 항목에 대한 가명처리 수준을 높이거나, 다른 정보 및 소프트웨어(SW) 반입 제한 등 충분한 안전조치를 보완하여 활용
2	- 가명처리 기술의 한계 등을 보완하기 위해 사전 준비단계(연구 및 기술개발 기획)부터 위험성을 충실히 검토하고 적절한 안전조치를 수행 - 가명처리 기술의 한계 보완을 위해 다음 조치를 이행할 것을 권고 ① 가명처리 기술의 적절성·신뢰성을 확인할 수 있는 근거 작성·보관 ② 가명처리 기술 적용 이후, 처리결과에 대해 자체적인 검수 수행 ③ 가명처리 적정성 검토 과정에서 ①, ②를 포함하여 점검 (외부전문가 과반 이상 참여 바람직) - 사전에 식별된 개인정보 침해 위험을 예방하기 위해서 가명 정보 활용에 참여하는 각 기관의 내부통제 강화 노력이 병행될 필요 - 가명 정보의 처리목적 달성이면 신속히 가명 정보를 파기하여 사후적 위험 최소화
3	- 데이터 복원기술 발달 등에 대응하여, 가명 처리된 비정형데이터 활용 시 관련 시스템·SW의 접근·사용 제한 등 통제방안 마련 (원본 복원에 활용될 수 있는 추가 정보 분리보관, 복원 SW에 대한 접근 권한 제한 등) - AI 개발·활용 과정에서 나타날 수 있는 다양한 위험을 사전에 완벽하게 제거하는 것은 불가능하므로, AI 서비스 제공 과정에서도 개인식별 위험 등 정보 주체 권익 침해 가능성을 지속 모니터링

[표 III-186] 비정형데이터 가명처리 기본원칙

※ 출처 : 비정형데이터 가명처리 기준 주요 내용, 개인정보보호위원회 24.02.02 - 2025.11 변동없음

2.4.2 비정형데이터 가명처리 단계별 고려사항



[그림 III-16] 개인정보의 가명처리 단계별 절차

※ 출처: 비정형데이터 가명처리 기준 주요 내용, 개인정보보호위원회 24.02.02 - 2025.11 변동없음

2.4.2.1 사전준비 단계

- 비정형데이터 내 개인식별 가능성이 있는 항목들을 도출하고, 목적 달성에 필요한 항목의 종류와 범위를 명확히 하여 가명처리 대상 선정

2.4.2.2 위험성 검토 단계

- 비정형데이터의 특성을 고려하여 ‘데이터 자체 식별 위험성’과 ‘처리 환경의 식별 위험성’을 종합적으로

검토하여 가명처리 방법·수준을 결정

구분	내용
(1) 데이터의 식별 위험성 검토	- 개인식별 가능성이 높은 정보 (①식별정보, ②식별가능정보), ③특이정보, ④데이터 특성만으로 재식별 시 영향도가 높은 항목이 있는지 검토 (식별성) 비정형데이터는 정형데이터와 달리 식별정보*와 식별가능정보**의 절대적인 구분이 어렵기때문에, 처리목적·방법 등 데이터 처리 맥락(context)을 고려하여 항목별 개인식별 가능성을 상대적으로 판단하여야 함 * (식별정보) 특정 개인과 직접적으로 연결되어 다른 사람과 구분되는 정보 ** (식별가능정보) 단일 항목으로는 식별 가능성이 없으나, 가명처리 대상이 되는 다른 항목과 결합하는 경우 식별 가능성이 높아지는 정보 (특이정보) 개인의 특이한 신체적·외형적·행태적 특징 또는 개인과 연관된 객체·사물 등의 특이성으로 인한 식별 위험성에 대해 검토 (재식별 시 영향도) 가명 처리된 비정형데이터가 재식별될 경우 특정 정보 주체에게 사회적 파장 등 영향도가 높은 항목이 있는지 검토 〈데이터 자체 개인식별 위험성 요소〉
(2) 처리 환경의 식별 위험성 검토	① 가명 정보 활용 형태, ②가명 정보 처리 장소, ③가명 정보 처리 방법 등 가명 정보 처리 환경에 따라 발생할 수 있는 식별 위험성을 검토해야 함 (활용 형태) 처리자(또는 취급자)가 보유하고 있는 정보 또는 접근·입수 가능한 정보와 이용 범위·유형을 고려하여 식별가능한 항목이 있는지 검토 (처리 장소) 가명 정보가 해당 가명 정보 외에 다른 정보의 접근·입수, 재식별 기술의 접근이 제한된 환경·장소에서 처리되는지 검토 (처리 방법) 가명 정보가 다른 정보와 연계·결합되거나 반복 제공 등이 예정된 경우, 식별 가능성이 높아지는 항목이 있는지 검토 〈처리 환경에 따른 개인식별 위험성 요소〉

[표 III-187] 위험성 검토 단계

2.4.2.3 가명처리 단계

- 가명처리가 필수적이지 않은 항목과 가명처리가 필요한 항목을 구분하고, 가명처리가 필요한 항목은 합리적인 가명처리 방법과 수준을 결정
- 비정형데이터가명처리기술 적용 시, 해당 기술의 적절성·신뢰성을 평가하고 관련 근거를 작성하여 보관할 것을 권고
- 비정형데이터 가명처리의 기술적 한계를 보완하고 잔존 위험(Residual Risk)을 낮추기 위해, 처리 결과에 대한 자체적인 추가검수 등이 필요
- 검수 과정에서 발견된 위험을 낮추기 위한 조치사항을 기록·보관하고 이에 대한 적정성 검토를 받을 것을 권고

2.4.2.4 적정성 검토 단계

- 비정형데이터의 특성과 처리 목적·환경 등을 고려하여 합리적인 방법 수준으로 가명처리를 수행하였는지 검토
- 비정형데이터 가명처리에 활용한 기술의 적절성·신뢰성을 검토하고, 해당 기술의 한계 등으로 인한 잔존 위험(Residual Risk)을 충분히 낮추기 위한 추가검수를 하였는지 검토
- 비정형데이터는 가명처리 시 데이터의 특성과 관련 기술발전 수준, 재식별 위험 등을 종합 고려하여야 하고, 이를 위한 전문성이 필요하므로, 적정성 검토 시 외부전문가를 과반수 이상으로 구성하여 객관성·전문성 있는 검증을 받을 것을 권고

2.4.2.5 안전한 관리 단계

- 가명 정보 특례를 활용하여 AI 학습·연구개발을 하고자 하는 자는 AI 기술·서비스의 특성을 고려하여 사전·사후적으로 발생할 수 있는 다양한 위험을 낮추기 위한 충분한 조치를 취해야 함
- AI 맥락에서 나타날 수 있는 다양한 위험을 사전에 완벽히 제거하는 것은 현재 기술상 불가능하므로, 잔존 위험을 최소화시키기 위한 노력 정도에 따라 사후관리의 이행 수준을 판단하여야 함
- AI 서비스 운영 과정에서도 개인식별 위험성 및 프라이버시 침해 가능성이 높아지지 않는지 지속적으로 모니터링하여야 하고, 개인식별 위험 증가 및 프라이버시 침해 등 관련 문제 발견 즉시, 해당 가명정보처리를 중단하고 관련 위험을 제거하여야 함

※ 출처 : 비정형데이터 가명처리 기준 주요 내용, 개인정보보호위원회 24.02

2.4.3 비정형데이터 개인식별 위험성 검토 체크리스트(‘24.02, 개인정보보호위원회)

※ 해당 체크리스트는 가명처리 계획을 세우기 전에 개인식별 위험성을 검토하기 위한 것으로, 검토 결과가 “예”에 해당하더라도, 해당 위험을 낮추기 위한 적절한 가명처리 방안 적용 후 활용 가능

구분		검토항목	검토결과
데이터	식별성	(개인식별이 가능한 항목 여부) ① 그 자체로 특정 개인을 식별할 가능성이 높은 정보가 있는가 ② 두 개 이상의 정보를 조합하여 식별 가능성이 높아지는 정보가 있는가	☐ 예 ☐ 아니오
	특이정보	(개인의 특이한 특징으로 인하여 식별 가능성이 있는 이용 항목 여부) ③ 개인의 특이한 신체적·외형적 특징으로 인해 특정 개인을 식별할 가능성이 있는가 ④ 개인의 특이한 행태적 특징으로 인해 특정 개인을 식별할 가능성이 있는가 ⑤ 개인과 연관된 객체사물 등의 특이성으로 인하여 식별 가능성이 있는 이용 항목 여부	☐ 예 ☐ 아니오
	재식별 시 영향도	(재식별 시 정보 주체에게 심각한 피해 또는 불이익을 초래할 수 있는 이용 항목 여부) ⑥ 사회 통념상 차별 등으로 인해 정보 주체가 피해 또는 불이익을 받을 수 있는 정보가 있는가 ⑦ 재식별로 인하여 받는 피해 또는 불이익의 정도와 규모가 상당히 클 수 있는 정보 주체에 관한 정보가 있는가	☐ 예 ☐ 아니오
처리환경	이용 및 제공	(가명정보 활용 형태 및 이용 기관의 개인정보 보호 수준 등을 고려하여 식별 가능성이 있는 항목 여부 검토 항목) ⑧ 처리 주체가 보유하고 있는 정보 또는 접근·입수 가능한 정보와 이용	☐ 예 ☐ 아니오

구분	검토항목	검토결과
	범위 및 유형을 고려하여 식별 가능한 항목이 있는가 ⑨ 추가정보를 삭제하지 않고 보관하는가 ⑩ 가명정보 제공 시 제공받는 자의 개인정보보호 수준 및 신뢰할 수 있는 인증을 받았는가 (ISMS, ISMS-P, ISO 27001 등)	
처리장소	(가명정보가 관리적·기술적·물리적으로 안전한 장소에서 처리되는지 여부) ⑪ 가명정보 처리 시 다른 정보를 접근·입수할 수 있는 장소인가	☐ 예 ☐ 아니오
다른 정보와 결합	(가명정보를 다른 정보와의 결합하여 활용 시 식별 가능성이 있는 항목 여부) ⑫ 다른 정보와의 연계 분석이 예정되어 있는가 ⑬ 처리 주체가 보유하거나 접근·입수 가능한 정보 등 다른 정보와 연계 또는 결합하여 식별 가능한 항목이 있는가	☐ 예 ☐ 아니오

[표 III-188] 개인식별 위험성 검토사항

※ 출처 : 비정형데이터 가명처리 기준 주요 내용, 개인정보보호위원회 24.02

2.4.4 비정형데이터 가명처리 기술 및 예시(24.02, 개인정보보호위원회)

2.4.4.1 영상 정보

● 이미지 필터링 기술

- 필터링 기술(① 블러링, ② 픽셀화, ③ 마스킹)로 처리된 영상 이미지


* 얼굴 이외에도 사람 형상, 신체, 옷차림 등, 사람과 관련된 사물/동물 등도 필터링 대상이 될 수 있음



[그림 III-17] 이미지 필터링

● 이미지 암호화

- 원본 이미지의 일부를 암호화하여 데이터 주체를 알아볼 수 없도록 하는 기법
- 이미지 암호화로 처리된 영상 이미지



[그림 III-18] 이미지 암호화


※ 출처: Lihua Gong 외[32], Image compression-encryption algorithms by combining hyper-chatic system with discrete fractional random transform (Optics and Laser Technology)

- 이미지 합성

- ‘합성데이터’는 실제 데이터의 특성만 참조하여 실제 개인과 직접적인 관련이 없는 완전히 새로운 데이터셋을 생성해내는 방식
- 실제 데이터(Real Data)와 통계적 특성이 유사하여, 실제 데이터 분석결과와 유사한 결과를 얻을 수 있도록 새롭게 생성해낸 가상의 데이터
- 개인정보보호 등의 사유로 실제 데이터의 활용이 어렵거나, 활용할 수 있는 데이터의 양이 부족한 경우에 주로 활용되며, 실제 데이터와 유사할수록 활용 가치가 높음
- 합성데이터는 적절하게 생성된 경우, 실제 사람의 신원을 재식별해 낼 수 없고 개인에 대한 특정된 정보를 포함하지 않기 때문에 안전하게 생성된 합성데이터는 개인정보에 대해 요구되는 보호조치 등이 불필요하며, 분석과 연구 등에 광범위하게 활용 가능

- 인페인팅 (Inpainting)

- 영상 내 개인식별 영역을 제거한 후 다른 물체 또는 배경으로 대체하여 신원을 보호하는 기술



[그림 Ⅲ-20] 인페인팅 기법으로 처리된 영상 이미지

※ 출처: <https://www.aitimes.kr/news/articleView.html?idxno=17686>

- AnonymousNet 프레임워크

- 얼굴 보존형 가명·익명처리 기술의 프레임과 비슷해 보이지만 다음의 4단계 절차를 통하여 아이덴티티가 완전히 다른 이미지를 생성



[그림 Ⅲ-21] AnonymousNet 프레임워크

※ 출처: Tao Li 외 1인, AnonymousNet: Natural Face De-Identification with Measurable Privacy

- AI 딥러닝 기반의 알고리즘을 활용
 - 얼굴 및 차량 번호판 등을 추출한 후 각종 SW 라이브러리를 활용하여 블러링 처리
 - ※ 미검출이나 오검출 얼굴 등에 대해서는 수작업을 통하여 추가 보정
- AI 적대적 생성 신경망 기반 모델(GAN, Generative Adversarial Networks)
 - 이미지에서 보존해야 할 영역을 수치화하여 연속형 데이터로 처리한 후 해당 개별 데이터에 노이즈를 추가하거나 재현 처리

2.4.4.2 음성 정보

- 원천데이터에 포함된 개인정보는 가공 대상에서 제외하거나, 익명처리 등 비식별화를 통해 개인정보 비식별화 처리
- 개인정보 활용 및 3자 제공 동의를 받은 경우엔 동의 범위 내에서 개인정보를 가공데이터로 활용할 수 있음

개인정보에 대한 라벨링 익명처리 예시

• 대화자들의 신분 보장을 위해 이름, 주민등록번호, 카드 번호, 전화 번호 등 개인 정보와 관련된 사항은 그대로 전사하지 않고 아래와 같이 영문 기호로 적는다. • 사람 이름은 '&name&'로 전사한다. 정치인, 연예인 등 유명인 이름은 그대로 전사한다. (발화) 저는 김철수입니다. (전사) 저는 &name&입니다.	• 여러 이름이 나올 때는 '&name1&', '&name2&' 등 name 뒤에 숫자를 붙여 구별한다. (발화) 그때 철수랑 민수랑 너랑 나랑 갔잖아. 철수도 알고 있지? (전사) 그때 &name1&이랑 &name2&이랑 너랑 나랑 갔잖아. &name1&도 알고 있지? • 집 주소 등 개인정보에 해당되는 주소는 동 단위 까지만 전사하고, 그 이하 구체 적인 주소는 영문 기호로 적는다. (발화) 홍제동 한양아파트 205동 304호로 배달해주세요. (전사) 홍제동 &address&로 배달해주세요.
---	---

[그림 III-22] 음성 데이터 개인정보 익명처리 예시

※ 출처: 인공지능 학습용 데이터셋 구축 안내서(2021. 02, 한국지능정보사회진흥원)

- 음성 정보 자체에 대한 가명처리
 - 대부분 텍스트로 변환하여 처리하고 있으며 그 외 발화자의 개인정보(비속어, 성적, 정치적 발언 등 포함)에 대한 규칙을 정하여 해당 구간을 단순히 삭제하거나 혹은 음성 변형의 원리에 기반하여 음조를 변형하여 처리
 - 규칙기반 개인정보 단순 삭제
 - 음성 데이터상에서 규칙*을 정하여 개인식별 가능 정보를 단순히 삭제
 - * (예) 인명, 지명 등 개인식별 가능 정보가 포함된 카드번호, 주민등록번호, 전화번호 등을 삭제하고, 비속어, 성적 및 정치적 발언의 경우도 삭제하거나 다른 언어로 대체하는 등
 - ※ 이 방법은 완전 자동으로 수행이 어려운 측면이 있으므로 추가적인 검수가 필요할 수 있음
 - 음성 변형의 원리에 기반하여 음성 데이터 내용에 영향을 주지 않으면서 주어진 발화의 비언어적 특징들을 수정
- 음성을 텍스트로 변환(STT, Speech To Text) 후 가명처리
 - 개인식별정보가 포함된 음성을 텍스트로 변환 후 변환한 텍스트에서 개인식별정보를 가명처리하고 다시 음성으로 변환하는 방식

2.4.4.3 텍스트 정보

- 규칙기반 개인정보 단순 삭제 혹은 마스킹
 - 사전에 텍스트 내 개인식별(가능)정보들을 정의하고 정의된 형태(포맷)에 기반하여 해당 정보를 삭제하거나 마스킹, 대체 처리 등의 방법으로 제거
 - 스크러빙(Scrubbing)
 - 원 텍스트의 내용과 구조를 보존하면서 즉시 파싱을 통하여 혹은 파싱 이후 개인식별(가능)정보만을 제거(마스킹 혹은 대체) 하는 것으로 이 경우 다수의 정보 주체와 해당 속성들 사이의 명확한 연관성이 없어질 수도 있음
 - 즉, 특정 정보 주체가 어느 속성을 지칭하는지 알 수가 없게 될 수도 있음
 - 단순 삭제 혹은 마스킹 방법과 유사하며 수작업이 아닌 자동화 SW를 이용한다는 점이 다름
 - 정규 표현식(Regular Expression)
 - 문자나 혹은 문자열의 일정한 패턴을 표현하는 일종의 형식 언어
- ※ 사용 시 오타나 혹은 문자 숫자 혼합 등에 따라 누락되는 경우가 존재하므로 추가검수가 필요할 수 있음

범주	항목	텍스트 예시	정규 표현식
1	전화번호	010-1111-2222	<code>^d{3}\-d{4}\-d{4}\$</code>
2	이메일 주소	abc@abc.net	<code>^[0-9a-zA-Z]([-_.]?[0-9a-zA-Z])*@[0-9a-zA-Z]([-_.]?[0-9a-zA-Z])*.[a-zA-Z]{2,3}\$/i;</code>

[표 III-189] 정규 표현식(Regular Expression) 예시

- 주석 달기(Annotation)
 - 주어진 텍스트를 논리적으로 분할한 후 분할된 단어(들)에 주석을 첨가하는 기법
- AI 기반 텍스트 정보 가명처리
 - 규칙, 정규 표현식 등을 통한 개인정보 검출 및 마스킹은 정확도 측면에서 한계가 있을 수 있으며, 이를 보완하기 위해 딥러닝 기술 등을 적용한 자연어 처리 언어모델을 통해 사전에 정의되지 않은 패턴의 개인정보를 검출하고 마스킹할 수 있음
 - 학습 방법에 따라 다양한 형태의 인공지능 기반 개인정보 검출 기법 존재 (HMM, MEM, CRFs, structural SVM, Deep-Learning)
 - 규칙기반의 유연성 부족을 해결하기 위해 패턴이나 규칙을 수동이나 반자동으로 작성하고 인공지능을 통해 사전(dictionary)을 확장하여 규칙에 적용되는 개인식별 가능정보를 새롭게 검출할 수 있음
- 텍스트를 테이블 형식으로 변환
 - 주어진 텍스트를 구문 문법의 규칙에 따라 파싱(parsing, 정해진 규칙에 따라 문장의 구문을 분할)한 다음 분할된 각 세그먼트들을 열과 행이 있는 테이블 형태로 정렬한 후 나머지 데이터들은 삭제
 - 변환된 테이블은 기존 정형데이터에 대한 가명처리를 적용
 - 실제로는 텍스트 자체의 복잡성으로 인하여 구조화된 테이블로의 변환이 불가능할 수도 있음

※ 출처: 비정형데이터 가명처리 기준 주요 내용, 개인정보보호위원회 24.02


2.5 운영·활용 단계 개인정보보호 가이드

- AI 서비스 운영 과정에서도 개인식별 위험성 및 프라이버시 침해 가능성이 높아지지 않는지 지속적으로 모니터링하여야 함
- 또한, 개인식별 위험 증가 및 프라이버시 침해 등 관련 문제 발견 즉시, 해당 가명정보 처리를 중단하고 관련 위험을 제거해야 함
- 원시데이터를 포함한 과제 수행 산출물은 과제 종료 후 5년간 보존
- 인공지능 개발 및 운영종료 등으로 개인정보가 불필요하게 되었을 때에는 지체없이 파기
- 데이터 운영·활용 단계 개인정보보호 가이드
 - AI모델 개발이 완료되면 반복적인 테스트를 통해 사회적 차별·편향 등 이슈 발생 가능성 등을 검토하고, 발견된 문제점은 서비스를 출시하기 이전에 개선해야 함
 - 사업 종료 이후 인공지능 학습용 데이터 구축사업 결과물에 개인정보가 포함되어 있는지 등을 확인
 - 데이터를 개방하는 경우에는 개방 이후에도 개인정보탐지 SW 등을 활용한 주기적 검증 등 실시
- 기타 보안관리 강화
 - (물리적 보안) 개인정보를 무단으로 반출하지 못하도록 입·출입통제, 작업 승인, 개발 PC 분리, 작업 PC 반출 불가, USB 봉인 등
 - (기술적 보안) 권한, 접근제어, 암호화, 네트워크, 콘텐츠 보안 등 기술적 보안
 - (관리적 보안) 실증랩 이용 이력 관리, 개인정보 취급자 지정 및 교육, 정기적 보안 취약 점검 등

● 개인정보보호 관련 법령

구분	법	시행령	시행규칙 등
개인정보 보호 관계법령	개인정보 보호법	개인정보 보호법 시행령	표준 개인정보 보호지침
			개인정보 처리 방법에 관한 고시
			개인정보의 기술적 관리적 보호조치 기준
정보보호 관계법령	정보통신망 이용촉진 및 정보보호 등에 관한 법	정보통신망 이용촉진 및 정보보호 등에 관한 법률 시행령	정보통신망 이용촉진 및 정보보호 등에 관한 법률 시행규칙
	정보통신기반 보호법	정보통신기반 보호법 시행령	정보통신기반 보호법 시행규칙
	지능정보화 기본법	지능정보화 기본법 시행령	지능정보화 기본법 시행규칙
	전자정부법	전자정부법 시행령	-
	위치정보의 보호 및 이용 등에 관한 법률	위치정보의 보호 및 이용 등에 관한 법률 시행령	위치정보의 보호 및 이용 등에 관한 법률 시행규칙
	신용정보의 이용 및 보호에 관련 법률	신용정보의 이용 및 보호에 관련 법률 시행령	신용정보의 이용 및 보호에 관련 법률 시행규칙
	전자상거래 등에서의 소비자보호에 관한 법률	전자상거래 등에서의 소비자보호에 관한 법률 시행령	전자상거래 등에서의 소비자보호에 관한 법률 시행규칙
인공지능 참고법령	데이터 산업진흥 및 이용촉진에 관한 기본법	데이터 산업진흥 및 이용촉진에 관한 기본법 시행령	데이터 산업진흥 및 이용촉진에 관한 기본법 시행규칙
	산업 디지털 전환 촉진법	산업 디지털 전환 촉진법 시행령	산업 디지털 전환 촉진법 시행규칙
	전자문서 및 전자거래 기본법	전자문서 및 전자거래 기본법 시행령	전자문서 및 전자거래 기본법 시행규칙
	전자서명법	전자서명법 시행령	전자서명법 시행규칙
	통신비밀보호법	통신비밀보호법 시행령	통신제한조치 등 허가 규칙

【표 III-190】 개인정보보호 관련 법령



[그림 III-23] 개인정보 처리 흐름도

AI 데이터 품질관리 가이드라인 v4.0

제1권 품질관리 프레임워크를 중심으로

AI 데이터 품질관리 가이드 v4.0

IV

참고자료

제1장 | 용어 정의

제2장 | 참고 문헌

제1장

용어 정의

7

- 가명처리
 - 개인정보의 일부를 삭제하거나 일부 또는 전부를 대체하는 등의 방법으로 추가 정보가 없이는 특정 개인을 알아볼 수 없도록 처리하는 것을 말함
- 가공유형(Labelling Type)
 - 데이터를 AI 학습용으로 변환하기 위해 객체나 메타정보를 주석 등의 형태로 적용하는 처리방식의 유형
- 강화 학습 (Reinforcement Learning)
 - 행동에 대한 보상을 통해 스스로 학습하는 인공지능 학습 방식. 주로 자율주행, 게임 AI 등에 사용
- 개방데이터
 - AI 통합 플랫폼인 AI-Hub(<https://aihub.or.kr/>)에 공개되는 인공지능 학습용 데이터
- 개인정보
 - 살아있는 개인에 관한 정보로서 성명, 주민등록번호 및 영상 등을 통하여 개인을 알아볼 수 있는 정보이거나 해당 정보만으로는 특정 개인을 알아볼 수 없더라도 다른 정보와 쉽게 결합하여 알아볼 수 있는 정보
- 개인정보보호 중심 설계(PbD) 원칙
 - 제품·서비스 개발 시 기획 단계부터 개인정보 처리의 전체 생애주기에 걸쳐 이용자의 프라이버시를 고려한 기술·정책을 설계에 반영하는 것을 의미하며, 국제적으로 광범위하게 통용되는 개인정보보호 원칙임
- 개인정보 영향평가
 - 개인정보파일의 운용으로 인하여 정보 주체의 개인정보 침해가 우려되는 경우에 그 위험요인의 분석과 개선사항 도출을 위한 평가
- 개인정보자기결정권
 - 자신에 관한 정보가 언제 누구에게 어느 범위까지 알려지고 이용되도록 할 것인지를 그 정보 주체가 스스로 결정할 수 있는 권리. 즉, 정보 주체가 개인정보의 공개와 이용에 관하여 스스로 통제·결정할 수 있는 권리를 말함
- 객체
 - 실체가 있는 대상(사물) 자체를 지칭 ▶ 예) 자동차, 자전거, 사람, 표지판, 건물, 도로, 하늘, 바다
- 객체 인식 (Object Detection)
 - 이미지나 비디오에서 특정 개체를 식별하고 위치를 파악하는 기술

- **검사항목 (Assessment Indicator)**
 - AI 데이터의 품질 특성(다양성, 정확성 등)을 측정·평가하기 위해 정의된 세부 평가항목으로 각 항목은 하나 이상의 측정지표로 수치화 됨
- **검증 데이터셋 (Validation Data Set)**
 - 전체 학습 데이터셋 중에서 일정한 비율을 정하여 인공지능의 기계학습에 따른 성능을 보정하거나 향상하는 용도로 사용하는 데이터셋
 - 학습이 끝난 모델에 적용시켜 테스트 데이터셋을 이용한 모델의 평가로 넘어가기 이전에 최종적으로 모델을 미세조정(Fine Tuning)하는데에 사용
- **고유식별정보**
 - ① 여권번호, ② 운전면허번호, ③ 외국인등록번호 등 단, 주민등록번호는 법률·대통령령 또는 헌법기관 규칙에 구체적 근거가 없는 경우 처리가 불가능함 ※ 출처 : 개인정보보호법 제24조
- **과제조정위원회**
 - 사업관리기관에서 사업수행기관이 제안한 사업수행계획서의 적정성을 검토하는 과정으로, 공모 절차에 의해 선정된 과제 대상으로 협약 이전에 진행
- **기반 모델 (Foundation Model)**
 - 대규모 데이터셋으로 사전 학습된 인공지능으로 목적에 맞게 미세조정하여 사용할 수 있는 범용적인 AI모델
- **기계학습 (Machine Learning)**
 - 인간이 자연적으로 수행하는 학습 능력과 같은 기능을 컴퓨터에서 실현하려는 기술이나 방법

L

- **노이즈 (Noise)**
 - 원본 데이터에 포함된 정확하지 않거나 무의미한 정보로 모델 학습을 어렵게 만드는 데이터로, 데이터 수집 과정에서 발생한 환경 소음, 센서의 오류 또는 무작위한 변동 등이 이에 해당함

C

- **단어 임베딩**
 - 사람이 사용하는 자연어를 컴퓨터가 이해하고 처리할 수 있도록 단어를 숫자 벡터로 변환하는 기술
 - 해당 벡터에는 단어의 의미와 문맥 정보를 담고 있어 모델이 텍스트를 더 잘 이해하고 분석할 수 있게 함
- **데이터 구축 공정**
 - 인공지능 학습을 위하여 데이터 구축 계획 수립 및 데이터 획득/수집부터 정제, 가공작업을 통해 인공지능 모델의 성능을 향상시킬 수 있는 의미있는 수준의 데이터를 구축하는 과정

IV

- 데이터 구축 절차
 - 인공지능 학습용 데이터 구축 공정 내부의 세부 실행 단계에 대한 절차를 의미하며, 구체적이고 세부적인 업무를 수행하고 순차적 단계에 따라 책임자와 산출물이 도출되는 과정
- 데이터 품질관리 프레임워크
 - 고품질의 인공지능 학습용 데이터 확보 및 지속적인 품질향상을 위하여 품질관리 대상·기준·조직·절차적 원칙을 제시하고 인공지능 학습용 데이터 구축 공정 5단계와 데이터를 활용하는 단계를 포함한 총 6단계에 대하여 각 단계별 품질관리 활동과 품질관리를 위한 도구 및 인프라 등을 정의한 품질관리 체계
- 데이터 획득/수집 (Data Acquisition/Collect)
 - 인공지능의 기계학습에 필요한 데이터를 현실 세계에서 직접 수집 또는 생성하거나, 이미 보유하고 있는 조직이나 시스템 등으로부터 법률적 제약이 없도록 ‘원시데이터’를 확보하는 활동
- 데이터 정제 (Data Refinement)
 - 획득한 원시데이터를 기계학습에 필요한 형식으로 맞추거나 불필요한 중복을 제거하며, 개인정보를 비식별화하여 처리하는 등 일련의 전처리 과정을 통해 ‘원천데이터’를 확보하는 활동
- 데이터 가공 (Data Labeling)
 - 인공지능이 기계학습에 활용할 수 있도록 기능이나 목적에 부합하는 정보를 원천데이터에 부착하는 활동
- 데이터 심의 위원회 (Data Review Board)
 - 법률 전문가, 기술 전문가, 데이터 활용 분야 전문가 등으로 이루어진 조직으로 민감한 데이터나 민감한 상황에서 데이터를 수집·사용·저장하거나 공개하는 경우, 그 과정이 윤리적이고 법적으로 적합한지를 심의하는 조직
- 데이터 전처리 (Data Preprocessing)
 - 초기데이터를 분석이나 모델링에 활용 가능한 형태로 가공하는 작업으로 모델의 성능을 향상하고 결과의 정확성과 신뢰성을 높이는 데 기여하는 작업
- 데이터 학습 (Data Machine Learning)
 - 학습 데이터셋, 검증 데이터셋을 이용하여 선정된 인공지능 알고리즘을 학습시키고, 학습된 AI모델의 성능을 향상시키거나 보정하는 활동
- 딥 페이크 (Deepfake)
 - 실제로는 존재하지 않는 가상의 영상, 음성 혹은 사진을 생성하는 기술
 - 최근 얼굴 합성 기술을 이용하여 특정 인물의 얼굴을 다른 영상에 합성하는 방식의 범죄가 발생, 이에 대한 대응으로 최근 딥페이크 탐지 기술의 개발이 진행

2

- 라벨 (Label)
 - 지도학습을 위하여 데이터에 부여된 타깃 값
- 라벨링 (Labelling)
 - 데이터에 라벨을 부착하는 프로세스
- 리소스 집약적 모델 학습 (Resource-intensive Model Training)
 - 대량의 데이터셋을 사용하여 고성능 AI모델을 만드는 프로세스로 막대한 데이터와 복잡한 알고리즘을 사용하며 주로 자연어처리, 음성 인식, 이미지 생성 등의 초거대 AI모델에서 사용

□

- 멀티모달(Multimodal) 데이터
 - 인공지능 모델이 복합적인 대상 및 상황을 정확하게 분석하고 이해할 수 있도록, 모델 학습에 필요한 텍스트, 오디오, 이미지, 동영상 등 서로 다른 2가지 양식 이상의 데이터
- 모달리티(Modality)
 - 멀티모달 인공지능 분야에서 모달(Modal)이라고도 하며, 사람의 시각, 청각 등의 오감을 이용하여 사물에 대한 정보를 파악하고 받아들이는 방식을 모방하여 인공지능이 수행하는 역할이 가능하도록 컴퓨터의 여러 인터페이스를 통해 수집된 서로 다른 감각의 정보 유형
- 모델 유효성 검증
 - 정제 가공 작업이 완료된 데이터를 통해, 실제 인공지능 모델 학습 및 검증에 유효한지를 확인하는 작업으로, 순수하게 데이터의 품질이 모델 학습의 성능에 미치는 영향을 파악하기 위한 작업
- 말뭉치 데이터 (Corpus Data)
 - 자연어처리를 위해 수집된 방대한 텍스트 데이터로 AI가 언어의 규칙, 패턴, 의미를 학습하기 위해 사용
- 메타데이터 (Metadata)
 - 데이터에 대한 데이터로 데이터를 설명하고, 정의하고, 찾고, 관리하고, 사용하는 데 도움이 되는 정보를 가지고 있는 데이터
- 민감도 (Sensitivity)
 - 재현율의 다른 용어로 AI모델이 양성 값 중 실제로 맞춘 양성의 수로 정확하게 식별하는 능력이 좋다는 것을 의미
- 민감정보
 - ① 사상·신념, ② 노동조합·정당의 가입·탈퇴, ③ 정치적 견해, ④ 건강, ⑤ 성생활 등에 관한 정보, ⑥ 유전정보, ⑦ 범죄경력자료에 해당하는 정보, ⑧ 바이오정보(특징정보), ⑨ 인종이나 민족에 관한 정보 등 정보주체의 사생활을 현저히 침해할 우려가 있는 개인정보

※ 출처 : 개인정보보호법 제23조

IV

참고 자료

B

- 반정형데이터(Semi Structured Data)
 - 데이터의 형식과 구조가 변경될 수 있는 데이터로 데이터의 구조 정보를 데이터와 함께 제공하는 파일 형식의 데이터
- 비정형데이터(Unstructured Data)
 - 테이블 데이터와 다르게 정형화되지 않은 데이터를 뜻하며 이미지, 동영상, 오디오 등이 해당됨
- 범주
 - 개념적인 대상의 분류체계 예) 주제, 분야, 인종
- 불확실성 (Uncertainty)
 - AI 시스템이 예측이나 결정을 내릴 때, 그 결과에 대한 확신 정도를 나타내는 것
 - 모델 자체의 한계나 데이터의 부족, 데이터 자체의 오류 등으로 발생함
- 비식별화 (de-identification)
 - 특정 개인을 식별할 수 없도록 개인정보의 일부 또는 전부를 변환하는 일련의 과정 또는 방법
- 비정형데이터 (Unstructured Data)
 - 일정한규격이나형태를 지닌숫자데이터와달리 이미지, 영상, 음성, 보고서나 문서처럼 구조화되지 않은 데이터
- 비지도 학습
 - 레이블이 지정되어 있지 않은 상태로 자체적으로 데이터의 패턴, 구조, 특징을 스스로 학습하는 머신러닝의 유형
 - 다만, 정답 레이블이 없어서 학습 결과를 정량적으로 평가하기 어려움

A

- 생성형 멀티모달 모델
 - 텍스트, 이미지, 오디오, 비디오 등 두가지 이상의 다양한 유형의 데이터를 함께 인공지능 모델에 학습하여 같은 공간 안에 임베딩 시킴으로써 서로의 관계성을 학습 및 처리하는 모델
- 생성형 인공지능(Generative AI)
 - 사용자의 명령에 대응하여 텍스트, 이미지, 동영상, 기타 미디어를 생성할 수 있는 인공지능
- 사업관리기관
 - 소관 부처가 사업에 대한 관리 등의 업무를 대행하기 위하여 설립하거나 지정한 전문기관
- 사업수행기관
 - 전담기관의 장과 별도의 협약 등을 통하여 사업을 수행하는 기관(기업)을 통칭(주관기관, 참여기관)

- 사전학습용 데이터 (Pretrained Data)
 - 거대 언어 모델(LLM)이나 거대 멀티모달 모델(LMM)을 미리 학습시키는 데 사용되는 방대한 데이터셋으로, 모델이 일반적인 지식과 패턴을 습득하도록 하여 성능을 향상시키는 데 사용됨
 - 사전 학습된 모델을 사용하여 시간을 절약할 수 있고, 일반적인 지식을 갖추고 있어 특정 작업에 대한 성능이 향상됨
- 시험 데이터(셋) (Test Data Set)
 - 전체 학습 데이터셋 중에서 일정한 비율을 정하여 인공지능의 기계학습 성능 시험을 목적으로 사용하는 데이터셋
- 설명 가능성(Explainability)
 - AI 모델의 의사결정 과정을 사람이 이해할 수 있는 방식으로 설명할 수 있는 능력

○

- 오디오 데이터
 - 사람의 발화, 자연음 및 인공음 등 아날로그 신호를 디지털 신호로 변환한 데이터
- 음성 데이터
 - 음성을 추출하여 녹음한 데이터이며, 음성 녹음파일과 전사 텍스트파일을 포함함
- 음성 인식
 - 음성으로부터 언어적 의미 내용을 자동으로 식별하여 인공지능이 발화 내용을 인식하는 서비스를 수행하는 임무
- 이미지 데이터
 - 시각정보를 나타낸 데이터로, 2차원(2Dimension, 2D) 정보를 표현하는 2D 이미지와 3차원(3Dimension, 3D) 정보를 표현하는 3D 이미지로 구분함
 - 2D 이미지와 3D 이미지는 동일한 시각적 데이터이나 각 표현방식이 다르며, 2D 이미지는 xy좌표로 표현되는 2차원 평면 정보를 나타내고, 3D 이미지는 xyz좌표로 표현되는 3차원 공간 정보를 의미
- 어노테이션 (Annotation)
 - 데이터 가공 공정에서 인간이 부여한 식별 기준을 기계가 인식할 수 있도록 선정된 데이터에 추가적인 정보를 기입하여 알고리즘이 이해할 수 있도록 만드는 과정
- 온디바이스 AI (OnDevice AI)
 - 클라우드나 외부 서버를 거치지 않고 휴대용 기기 자체에서 로컬로 작동되는 인공지능 모델
 - 데이터가 인터넷을 통해 이동되지 않아 네트워크 의존성이 적고, 즉각적으로 대응될 수 있음
- 원시데이터 (Raw Data)
 - 기계학습을 목적으로 획득 단계에서 수집 또는 생성한 음성, 이미지, 영상, 텍스트 등의 데이터

- 원천데이터 (Source Data, Unlabeled Data)
 - 원시데이터를 가공 공정에 투입하기 위해 필요한 전처리 등 정제 작업을 수행한 데이터로 가공데이터가 부여되지 않은 상태의 데이터
- 이미지 분류 (Image Classification)
 - 인공지능이 이미지를 분석하여 미리 정의된 카테고리 중 하나에 할당하는 작업
 - 객체 인식, 이미지 분석, 결함 감지 등에 사용됨
- 이미지 캡셔닝 (Image Captioning)
 - 인공지능이 이미지를 이해하고 그 내용을 자연어로 서술하는 기술로 이미지를 분석(Convolutional Neural Networks, CNN)하고 그 내용을 바탕으로 자연스러운 문장을 생성(Recurrent Neural Networks, RNN)함
- 인간 중심 디자인 (human-centered design approach)
 - 제품, 서비스, 시스템 등을 디자인할 때 사람들의 요구와 필요를 중심에 두는 접근 방식
 - 사용자 만족도 및 사용성 향상, 비용 절감 등의 효과가 있음
- 인공지능 (Artificial Intelligence)
 - 자연 언어의 이해, 음성 번역, 문제 해결, 학습과 지식 획득, 인지 과학 등에 응용하기 위해 인간의 지능이 갖는 학습, 추리, 적응, 논증 등의 기능을 갖춘 컴퓨터 시스템
- 인공지능 학습용 공개 데이터셋 (AI Open Dataset)
 - AI-Hub에 등록하여 사용자가 활용할 수 있도록 공개된 학습 데이터셋
- 인공지능 학습용 데이터 구축
 - 임무 정의, 데이터 획득/수집, 데이터 정제, 데이터 가공(가공), 데이터 학습 등 인공지능 학습용 데이터를 구축하는 일련의 활동
- 인공지능 학습용 데이터 품질 (AI Data Quality)
 - 기계학습에 필요한 데이터의 적합성, 정확성, 유효성 등을 확보하여 사용자에게 유용한 가치를 줄 수 있는 수준
- 인공지능 학습용 데이터 품질관리 (AI Data Quality Management)
 - 인공지능 학습용 데이터 품질확보에 필요한 조직, 절차, 기준, 제반 활동 등을 정의하여 점검하고 조치하는 일련의 활동
- 인스턴스 (Instance)
 - 클래스에 해당하는 개별 개체를 의미
 - 범주/클래스에 속하는 실제 데이터(example)로 어노테이션 대상을 의미
 - 예) ‘인공지능 구축과제’를 추진하는 경우 개품종의 클래스인 ‘푸들’, ‘비글’, ‘퍼그’ 등의 각 클래스에 해당하는 데이터 건수

- 임무 (Task)

인공지능 시스템이 제공하는 서비스의 목적에 따라 학습데이터가 갖추어야 하는 라벨링 작업

- 임무 정의 (Task Define)

- 인공지능 기계학습을 통해 해결하고자 하는 문제를 명확하게 정의하고, 문제 해결에 필요한 학습용 데이터의 요구사항을 구체적으로 정의하고 설계하는 활동

- 인공지능 임무(AI Task)

- AI 학습모델이 데이터 학습을 통해 해결하거나 달성하도록 설계된 구체적인 문제 또는 목표
- ‘시각지능’, ‘언어·청각지능’, ‘음성지능’, ‘융합지능’ 등 지능별 기술에 따라 다양하게 분류

ㅈ

- 전사

- 언어의 음성을 일정한 규칙에 근거해 문자로 표기한 것

- 정형데이터 (Structured Data)

- 관계형 데이터베이스 시스템의 테이블과 같이 고정된 컬럼에 저장되는 데이터와 파일, 그리고 지정된 행과 열에 의해 데이터의 속성이 구별되는 스프레드시트 형태의 데이터

- 지도 학습 (Self Supervised Learning)

- 기존 지도 학습 방식에서 데이터 자체에서 규칙이나 패턴을 찾아내 스스로 학습하는 방법
- 데이터 속에서 유의미한 구조 및 특징을 파악하여 학습

- 지능형 질의응답 시스템

- 질의응답 시스템에 인공지능 기술을 활용하여 성능을 개선한 시스템

- 작업자

- 본 가이드라인에서 작업자란 인공지능 학습용 데이터 구축 과정에서 생성되는 원시데이터, 원천데이터, 가공 데이터 등의 구축 활동을 수행하는 인력을 의미하며, 크라우드워커(Crowd worker)라고 표현하기도 함
- 작업자는 역할에 따라 ‘수집 작업자’, ‘정제 작업자’, ‘가공 작업자’로 구분 가능하며, 각 구축 과정 내 ‘검수자’ 또한 작업자의 범위에 속함
- 다만, 전문적인 지식을 기반으로 데이터를 구축하는 과업의 경우, 크라우드소싱 기반으로 작업자를 무작위 선정하지 않고 별도의 채용 과정을 통해 선정할 수 있음

- 적응 학습(Adaptation Learning)

- 사전에 훈련된 AI모델을 새로운 작업이나 데이터에 맞추어 추가적으로 조정하는 학습
- 특정 도메인의 데이터나 특수한 작업 요구사항에 맞게 모델을 미세 조정하는 것을 포함

- 적응 학습 데이터(Adaptation Learning Data)
 - AI모델이 사전학습 과정을 거친 후 특정 도메인이나 작업에 맞게 적응(추가 훈련)할 때 사용하는 데이터
 - 이 데이터를 사용하여 특정 작업에 필요한 언어 패턴, 지식, 용어 등을 학습하고 이를 통해 AI모델이 해당 작업에 더 잘 적응할 수 있도록 최적화
- 제3자 품질검증
 - 인공지능 학습용 데이터 구축 사업에 직접 참여하는 당사자인 수행기관 및 참여기관 등 이외의 자를 제3자 라고 하며, 제3자가 데이터의 다양성, 정확성, 유효성 등을 검증하는 과정
- 주관 사업수행기관
 - 사업수행기관이 다수인 경우, 사업비 신청·관리 및 실적보고와 정산 등 해당 협약사업에 대한 책임이 있는 사업수행기관 또는 사업비 지분이 가장 많은 사업수행기관, 약칭 주관기관
- 지도 미세조정 (SFT, Supervised Fine Tuning)
 - 사전 훈련된 모델을 가져와 목적에 맞춰 추가적인 학습을 통해 미세 조정하는 작업을 의미함
 - 사전 훈련된 모델만으론 특정 전문 분야(의료, 법률 등)에서 제대로 된 성능을 낼 수 없기에 주로 사용함
 - 작업 데이터에 대한 입력-출력 쌍으로 구성된 데이터(예로 원문-번역문 데이터 쌍)를 사용함
- 지시 미세조정 (Instruction Tuning)
 - 사전 훈련된 모델에 특정 작업을 수행하는 방법을 설명하는 지시문과 함께 미세 조정하는 작업을 의미함
 - 데이터가 적더라도 작업에 대해 지시를 통하여 동작할 수 있도록 훈련시킬 수 있어 효율적으로 학습시킬 수 있음
 - 작업 데이터에 대해 지시문-출력 쌍으로 구성된 데이터(예로 번역, 질의응답 데이터)를 사용

㉔

- 참값 (Ground Truth)
 - 인공지능의 기계학습 목적에 따라 원천데이터에 가공된 정확한 값이나 사실의 의미적 표현
- 참여 사업수행기관
 - 수행기관과 공동으로 해당 과제에 참여하여 과제를 수행하는 기관, 약칭 참여기관
- 측정지표 (Evaluation Metric)
 - AI 데이터 품질 또는 AI 학습모델 성능을 검사항목 기준으로 수치화하여 평가하기 위해 사용하는 정량적 지표

ㄱ

- 크라우드소싱 (Crowdsourcing)
 - 대중(crowd)과 아웃소싱(outsourcing)의 합성어로 기업 활동의 일부 과정에서 일반대중(크라우드 워커)을 참여시키는 것을 의미
- 크롤링 (Crawling)
 - 인터넷 상의 존재하는 웹 페이지들을 방문하여 데이터를 수집하는 것을 의미
 - 웹상의 방대한 정보를 수집하고 활용하는 데 유용한 기술이지만, 웹사이트의 정책과 저작권을 준수하여 사용해야 함
- 크라우드워커 (Crowd worker)
 - 일반인이 기업의 업무 용역을 대행 수행하고, 일정 대가를 받는 경우를 의미하며, 집이나 재택근무 등의 형태로도 업무 수행이 가능하고, 자유롭게 할당된 과제물을 수행하는 일자리
 예) A 참여기관이 '음식데이터 AI구축과제'를 추진하는 경우 '크라우드워커'를 고용하여 일반인으로부터의 음식 사진 데이터를 대량 수집
- 클라우드 컴퓨팅 서비스 보안 인증 제도 (Cloud Security Assurance Program)
 - 중앙부처·지자체·공공기관에게 안전성 및 신뢰성이 검증된 민간 클라우드 서비스를 공급하고 이용자에게 안전한 클라우드 서비스를 제공하기 위한 제도
 - 서비스 제공 범위에 따라 'IaaS', 'PaaS', 'SaaS'로 세분화됨
- 클래스 (Class)
 - 분류/탐지하고자 하는 대상을 카테고리화 한 것으로 실체가 있는 대상(사물)의 분류체계 명칭
 예) 자동차, 자전거, 사람, 표지판, 건물, 도로, 하늘, 바다
 예) A 참여기관이 '메일의 스팸 여부를 감지하는 인공지능 구축과제'를 추진하는 경우 스팸에 대한 클래스는 '스팸', '스팸 아님'이며, B 참여기관이 '개 품종을 판별하는 인공지능 구축과제'를 추진하는 경우 개 품종의 클래스는 '푸들', '비글', '퍼그' 등등
- 클래스 불균형 (Class Imbalance)
 - 데이터 집합에서 각 클래스의 샘플 수가 불균형하게 분포되어 있는 상태로 양이 많은 클래스에는 민감하게 학습되고 양이 적은 클래스는 무시하기도 함
 - 의료나 건설 관련 인공지능을 만들 때 중요시 되는 문제로 희귀병이나 사고 징후같이 일반적인 상황보다 데이터 수가 매우 적기 때문에 데이터 리샘플링 등의 방법을 사용해야 함

ㄷ

- 텍스트 분류 (Text Classification)
 - 주어진 텍스트를 분석하고 미리 정의된 범주 또는 클래스로 분류하는 자연어 처리(NLP) 기법
 - 텍스트 데이터를 수집하고 분석에 적합하도록 정제하거나 의미 있는 특징을 추출함

IV

- 텍스트 생성 (Text Generation)
 - LLM에서 단어들의 순서, 문법 규칙, 문맥 등을 파악하여 해당 정보를 바탕으로 새로운 텍스트를 생성하는 방식으로 사람이 작성한 것처럼 자연스러운 텍스트를 생성하는 것이 목적
- 텍스트 요약 (Text Summary)
 - AI모델이 긴 글을 읽고 중요한 내용만 간결하게 요약해주는 기술로, 주로 중요한 문장을 그대로 추출해 오는 ‘추출 요약’과 원본 텍스트 내용을 이해한 뒤 새로운 문장으로 요약하는 ‘추상 요약’으로 나눌 수 있음
- 텍스트 데이터
 - 언어형태로 기록된 문자를 문장 또는 문단 단위로 구분하여 가공한 데이터
- 테스트 데이터셋 (Test DataSet)
 - 학습이 완료된 AI 모델의 성능을 평가하기 위한 데이터셋으로 학습데이터와 동일한 분포를 가지도록 구성하거나, 학습데이터에 없는 데이터로 구성하는 등 실사용 성능을 예측하기 위한 역할

II

- 품질관리 지표
 - 데이터의 품질 수준을 측정하기 위한 관점을 정의한 것으로 무엇을 측정할 것인가에 대한 기준
- 품질 자가점검
 - 데이터 품질 이슈 조기발견 및 조치를 위한 사업수행기관 자체적인 전 구축과정(획득/수집 → 정제 → 가공 → 학습)에 대한 품질점검 활동
- 편향 데이터 (Biased Data)
 - 특정 경향이나 속성을 지나치게 반영하거나, 반대로 충분히 반영하지 못하여 전체 데이터를 제대로 대표하지 못하고 왜곡된 정보를 담아낸 데이터
- 피드백 루프 (Feedback Loop)
 - 어떤 시스템이나 프로세스에서 출력물이나 결과가 다시 입력 단계로 돌아가서 입력을 조절하거나 수정함으로써 시스템이나 프로세스의 성능을 개선하는 반복 과정으로 주로 시스템이나 모델의 성능을 평가하고 개선하기 위해 사용

III

- 학습 데이터(셋) (AI Data Set)
 - 인공지능의 기계학습에 사용하는 원천데이터와 가공데이터의 묶음을 말하며, 사용하는 목적에 따라 ‘학습 데이터셋’, ‘검증 데이터셋’, ‘시험 데이터셋’으로 구분

- 학습모델 임무 (Learning Model TASK)
 - 학습모델 알고리즘의 목적을 구분하기 위한 단위로서, 지능별 기술*에 따라 ‘시각지능’, ‘언어·청각지능’, ‘음성지능’, ‘융합지능’ 등 지능별 기술에 따라 다양하게 분류할 수 있음
- ※ 출처 : NIA, AI INSIGHT REPORT('19.12.)
- 합성데이터 (Synthetic Data)
 - 실제 데이터를 기반으로 인공적으로 생성한 데이터로 실제 데이터와 유사한 통계적 특징을 가지지만 개인정보나 민감정보를 포함하지 않음
 - 환각 현상 (Hallucination)
 - 인공지능이 실제로는 존재하지 않거나 사실이 아닌 정보를 마치 사실인 것처럼 생성하는 현상
 - 훈련 데이터셋 (Training Data Set)
 - 전체 학습 데이터셋 중에서 일정한 비율을 정하여 인공지능의 기계학습에 직접 사용하는 데이터셋
 - 전이 모델의 학습만을 위해서 사용. 훈련 데이터셋(Training Data set)을 통해 모델을 학습시키고, 파라미터나 특징 등을 수정해서 모델의 성능을 높이는 작업을 거칠 때 사용

A

- AI 신뢰성 (Trustworthy AI)
 - 윤리적으로 안전하고 책임감 있게 사용될 수 있는 인공지능이란 뜻으로 기술적인 측면과 아울러 사회적, 윤리적 측면까지 고려하여 개발, 운영되는 AI 시스템
 - 편향된 발언, 개인정보 침해, 오작동 등의 사회적으로 문제가 제기되는 AI 문제를 예방하기 위한 중요한 역할을 함

B

- BLEU (Bilingual Evaluation Understudy Score)
 - 기계 번역의 품질을 평가하는 데 사용되는 지표로 0부터 1 사이의 값을 가지며, 1에 가까울수록 번역 품질이 높다는 것을 의미
 - 단어의 일치도만 고려하기 때문에 문장의 의미, 문맥을 제대로 반영하지 못하거나 문법적인 오류를 판별하지 못하는 문제점이 있음

G

- General Data Protection Regulation (EU GDPR)
 - 유럽연합의 개인정보보호법

IV

L

- LLM (Large Language Model)
 - 대규모 텍스트 데이터를 학습하여 훈련된 인공지능 모델로, 인간의 언어를 이해하고 생성하는데 특화된 AI모델
 - 주로 텍스트 생성, 번역, 요약, 질의응답에 대한 작업을 수행함
- LMM (Large Multimodal Model)
 - 텍스트, 이미지, 오디오, 비디오 등 여러 유형의 데이터를 이해하고 처리할 수 있는 AI모델
 - 주로 텍스트-데이터(이미지, 비디오, 오디오 등) 생성 등에 사용됨

P

- Perplexity (PPL)
 - 언어모델에서 사용하는 지표로 모델이 다음 단어를 얼마나 잘 예측하는지 나타내는 척도

R

- RLHF (Reinforcement Learning from Human Feedback)
 - 인간 피드백을 통한 강화 학습으로 사람이 수집한 의견을 사용하여 모델을 조정하는 방법
 - 모델 출력이 복잡하고 설명하기 어려운 경우 사용됨
- ROUGE (Recall-Oriented Understudy for Gisting Evaluation)
 - 자동 텍스트 요약 및 기계 번역의 품질을 평가하는 데 사용되는 지표로 0부터 1 사이의 값을 가지며, 1에 가까울수록 요약이나 번역의 품질이 높다는 것을 의미
 - 사람이 작성한 요약은 다양한 표현을 사용할 수 있지만, ROUGE는 하나의 정답만을 기준으로 평가하기 때문에 다양성을 반영하기 어려움

1

- 1-Cycle 자가점검
 - 인공지능 학습용 구축 초기의 데이터를 이용하여 「획득/수집 → 정제 → 가공 → 학습」까지 전체 공정에 대한 1-Cycle 데이터(적합성, 정확성, 유효성)를 검사하여, 품질 이슈 조기발견 및 신속한 개선조치를 위한 활동

제2장

참고 문헌

- [NIA] 2021 인공지능 학습용 데이터셋 구축 안내서 v1.0
- [NIA] 2022 인공지능 학습용 데이터 가이드라인 v2.0
- [NIA] 2023 인공지능 학습용 데이터 품질관리 가이드라인 및 구축 안내서 v3.0
- [NIA] 2024 AI 데이터 품질관리 가이드라인 v3.5
- [NIA] 2023.04.27. [IT & Future Strategy 2023-3] 대규모 언어모델 기반의 공공분야 초거대AI 도입 방향
<https://www.nia.or.kr/site/nia_kor/ex/bbs/View.do?sessionId=E79567BECFE20ABB7745F8D098569D8F.154564d7171006361120?cbldx=25932&bcldx=25490&parentSeq=25490&pageIndex=2&mode=&searchKey=&orderByDiv=date>
- [관계부처 합동] 2016.06.30 개인정보 비식별 조치 가이드라인
<https://www.mois.go.kr/frt/bbs/type010/commonSelectBoardArticle.do?bbsId=BBSMSTR_000000000008&nttId=55 287>
- [개인정보보호위원회] 2020.12 자동처리되는 개인정보 보호 가이드라인
<<https://www.pipco.go.kr/np/cop/bbs/selectBoardArticle.do?bbsId=BS217&mCode=D010030000&nttId=7043>>
- [개인정보보호위원회] 2021.05.31 인공지능(AI) 개인정보보호 자율점검표
<[kisia.or.kr/bucket/uploads/2021/06/01/ai_개인정보보호_자율점검표\(개발자.운영자용\)\(2021.5.31\).pdf](https://kisia.or.kr/bucket/uploads/2021/06/01/ai_개인정보보호_자율점검표(개발자.운영자용)(2021.5.31).pdf)>
- [개인정보보호위원회] 2023.03 개인정보 보호법 전면 개정
<<https://www.pipco.go.kr/np/cop/bbs/selectBoardArticle.do?bbsId=BS074&mCode=C020010000&nttId=9145>>
- [개인정보보호위원회] 2024.02.04 가명정보 처리 가이드라인
<https://www.privacy.go.kr/front/bbs/bbsView.do?bbsNo=BBSMSTR_000000000049&bbscttNo=20658>
- [행정안전부] 행정안전부훈령 제 173호(공간정보 보안관리규정, 개정 2020. 12. 29)
<https://www.mois.go.kr/frt/bbs/type001/commonSelectBoardArticle.do?bbsId=BBSMSTR_000000000016&nttId=81999>
- [국토교통부] 공간정보 품질기준(국가공간정보센터 운영세부규정, 시행 2018. 1. 1)
<<https://www.law.go.kr/LSW/admRulLsInfoP.do?admRulSeq=2100000100190>>
- [NIPA 싱가포르 IT지원센터] 2020.01.03 2019 글로벌 ICT 이슈리포트-싱가포르 정부의 인공지능(AI) 정책
<https://www.nia.or.kr/site/nia_kor/ex/bbs/View.do?cbldx=82618&bcldx=21689&parentSeq=21689>
- [NIA] 2022 인공지능 학습용 데이터 가공 전문교육 - 데이터 라벨러 과정 - 품질관리 심화과정 교재
<<https://aihub.or.kr/aihubnews/notice/view.do?currMenu=131&topMenu=103&nttSn=10121>>
- [NIA] 2022 인공지능 학습용 데이터 가공 전문 교육 - 데이터 라벨러 과정 - 입문, 이미지/영상
<<https://aihub.or.kr/aihubnews/notice/view.do?currMenu=131&topMenu=103&nttSn=10121>>
- [NIA] 2022 인공지능 학습용 데이터 가공 전문 교육 - 데이터 라벨러 과정 - 입문, 음성/텍스트
<<https://aihub.or.kr/aihubnews/notice/view.do?currMenu=131&topMenu=103&nttSn=10121>>
- AI-Hub, 전문분야 학습용 한영 번역 말뭉치
<<https://aihub.or.kr/aihubdata/data/view.do?currMenu=115&topMenu=100&aihubDataSe=realm&dataSetSn=111>>
- [NIA] 거대 멀티모달 모델(LMM) 동향 조사
<https://nia.or.kr/site/nia_kor/ex/bbs/View.do?cbldx=39485&bcldx=27270&parentSeq=27270>
- [개인정보보호위원회] 2024.05 합성데이터 생성 참조 모델
<<https://www.pipco.go.kr/np/cop/bbs/selectBoardArticle.do?bbsId=BS217&mCode=G010030000&nttId=10201>>
- [KISA] 2024 개인정보 이슈 심층 분석 보고서(VOL.1) - 인공지능(AI) 시대 안전한 개인정보 활용,
Hao-Ping Lee, et al.(2024), 저자 재구성 인공지능 프라이버시 위험 분류 체계
<<https://www.kisa.or.kr/20202/form?postSeq=313&page=1>>
- 지각의 새로운 지평을 연 멀티모달 AI <<https://www.tta.or.kr/tta/publicationHosuView.do?key=80&rep=1&searchKindNum=1&searchHosu=214>>
- [NIA] 2024.09 버티컬AI로의 변화 및 과제
<https://www.nia.or.kr/site/nia_kor/ex/bbs/View.do?cbldx=39485&bcldx=27241&parentSeq=27241>
- [ETRI] 전사규칙 <https://github.com/etri/kmsav/tree/main/trans_guide>
- 글로벌 초거대AI 모델 현황 분석 <https://spri.kr/posts/view/23767?code=data_all>
- 초거대AI의 기반모델(Foundation Model) 개념 및 표준화 동향
<<https://www.kics.or.kr/html/?pmode=Bpublication&page=1&smode=view&seq=3965&search>>

- Value=&searchTitle=strTitle>
26. 초거대AI와 생성형 인공지능 <http://weekly.tta.or.kr/weekly/files/20232901012950_weekly.pdf>
 27. 초거대 인공지능 등장으로 인한 인공지능 시스템 개발 패러다임 변화 및 향후 전망
<https://www.tta.or.kr/tta/preportNewsNDownload.do?sfn=20230317032055297_bicQ.pdf>
 28. 거대 언어 모델(LLM) <<https://www.databricks.com/kr/glossary/large-language-models-llm>>
 29. 초거대AI 한눈에 보기
<<https://nsp.nanet.go.kr/plan/subject/detail.do?newReportChk=list&nationalPlanControlNo=PLAN0000041962>>
 30. [국가정보원] 2023.06 챗GPT 등 생성형 AI 활용 보안 가이드라인
<https://www.ncsc.go.kr:4018/main/cop/bbs/selectBoardArticle.do?bbsId=InstructionGuide_main&nttlId=54340&pageIndex=1>
 31. 큐보이드(Cuboid) 예시 - 아이티데일리<<http://www.itdaily.kr>>. 아주일보<<https://www.ajunews.com>>
 32. Data quality for analytics and machine learning — Part 4: Data quality process framework(ISO/IEC WD 5259-4:2020(E))
 33. Moumita Mukherjee et al. Electronics and Telecommunication Engineering, National Institute of Technology, “Kinship verification using Compound Local Binary Pattern and Local Feature Discriminant Analysis” (2019)
 34. Gabriela Csurka et al. Xerox Research Centre Europe, “What is a good evaluation measure for semantic segmentation?” (2013)
 35. Keni Bernardin et al, “Multiple Object Tracking Performance Metrics and Evaluation in a Smart Room Environment” (2006) <<https://isl.iar.kit.edu/pdf/Bernardin2006b.pdf>>
 36. Sergio Escalera Guerrero, ChaLearn, Computer Vision Center (UAB) and University of Barcelona, “Tutorial on Datasets, Annotations and Metrics in Computer Vision” (2015)
<<https://sergioescalera.com/wp-content/uploads/2015/08/COST-ACTION-TRAINING-SCHOOL-DATASETS-CV-TUTORIAL.pdf>>
 37. Ergys Ristani et al. “Performance Measures and a Data Set for Multi-Target, Multi-Camera Tracking” (2016)
 38. Jinbao Wang et al. “Deep 3D human pose estimation: A review” (2020)
 39. Shenqi Lai et al, “Enhanced Normalized Mean Error loss for Robust Facial Landmark detection” (2019)
 40. Google Machine Learning <<https://developers.google.com/machine-learning/crash-course?hl=ko>>
 41. “Optimizing Intersection-Over-Union in Deep Neural Networks for Image Segmentation”. ResearchGate.
<https://www.researchgate.net/publication/311531910_Optimizing_Intersection-Over-Union_in_Deep_Neural_Networks_for_Image_Segmentation>
 42. “Augmented Lagrangian-based Algorithm for Projective Reconstruction from Multiple Views with Minimization of 2D Reprojection Error”. SEMANTIC SCHOLAR.
<<https://www.semanticscholar.org/paper/Augmented-Lagrangian-based-Algorithm-for-Projective-Mai-Hung/fb3b33345a25d36cdcece5966abf8086d2d0f36>>
 43. Paper with code <<https://paperswithcode.com/>>
 44. “Metric: F1”, Hugging Face <<https://huggingface.co/metrics/f1>>
 45. “Accuracy(error rate)”, DeepAI <<https://deepai.org/machine-learning-glossary-and-terms/accuracy1-error-rate>>
 46. “Metric: BLEU”, Hugging Face <<https://huggingface.co/metrics/bleu>>
 47. “Exact Matching”, MatchIt <https://kosukeimai.github.io/MatchIt/reference/method_exact.html>
 48. “ROUGE”, ACL Anthology. <<https://aclanthology.org/W04-1013.pdf/>>
 49. Daniel J Bell, “Dice similarity coefficient”, Radiopaedia, <<https://radiopaedia.org/articles/dice-similarity-coefficient>>
 50. “Recall”. C3.ai. <<https://c3.ai/glossary/data-science/recall/>>
 51. “Precision”. C3.ai <<https://c3.ai/glossary/machine-learning/precision>>
 52. “Accuracy Metrics”. Humboldt State University – GSP216 Introduction to remote sensing
<http://gsp.humboldt.edu/olm_2019/courses/GSP_216_Online/lesson6-22/metrics.html>
 53. “Root Mean Square Error”. C3.ai. <<https://c3.ai/glossary/data-science/root-mean-square-error-rmse/>>
 54. “Evaluate: Keypoints”, COCO Common Objects in Context <<https://cocodataset.org/#keypoints-eval>>
 55. “Metric: cer”, Hugging Face <<https://huggingface.co/metrics/cer>>
 56. “Metric: wer”, Hugging Face <<https://huggingface.co/metrics/wer>>
 57. “Perplexity in Language Models”, towards data science
<<https://towardsdatascience.com/perplexity-in-language-models-87a196019a94>>
 58. “M.O.S. MEAN OPINION SCORE”, Arimas <<https://arimas.com/2017/08/01/mos-mean-opinion-score/>>
 59. “fbeta_score”. <https://scikit-learn.org/stable/modules/generated/sklearn.metrics.fbeta3_score.html>

60. F-beta score. <<https://hasty.ai/docs/mp-wiki/metrics/f-beta-score>>, <<https://wiki.cloudfactory.com/docs/mp-wiki/metrics/f-beta-score>>
61. "Evaluation measures"
<[https://en.wikipedia.org/wiki/Evaluation_measures_\(information_retrieval\)#Average_precision](https://en.wikipedia.org/wiki/Evaluation_measures_(information_retrieval)#Average_precision)>
62. "AUC-ROC Curve – The Star Performer!", Analytics Vidhya.
<<https://www.analyticsvidhya.com/blog/2021/07/metrics-to-evaluate-your-classification-model-to-take-the-right-decisions/>>
63. "Identity F1 Score (IDF1)"
<https://github.com/shenh10/mot_evaluation?utm_source=chatgpt.com>
<https://ar5iv.labs.arxiv.org/html/2104.02631?utm_source=chatgpt.com>
64. Gabriela Csurka et al. Xerox Research Centre Europe, "What is a good evaluation measure for semantic segmentation?", 2013 <<https://bmva-archive.org.uk/bmvc/2013/Papers/paper0032/abstract0032.pdf>>
65. Object Keypoint Similarity in Keypoint Detection, <<https://learnopencv.com/object-keypoint-similarity/>>
66. Mean Per Joint Position Error(MPJPE)
<<https://oecd.ai/en/catalogue/metrics/mean-per-joint-position-error-mpjpe>>
67. How to calculate NME(Normalized Mean Error) between ground-truth and predicted landmarks when some of gt has no corresponding in predicted?
<<https://stackoverflow.com/questions/69158002/how-to-calculate-nmenormalized-mean-error-between-ground-truth-and-predicted-l>>
68. "The limitations of a quality assessment" vertaalt,
<<https://www.vertaalt.nu/blog/the-limitations-of-a-quality-assessment/>>
69. Perplexity Unigram – Normalized Perplexity as a Language Model Performance Measure with Different Vocabulary Sizes
<<https://arxiv.org/abs/2011.13220>>, <https://facerrain.github.io/nlp-ppl/?utm_source=chatgpt.com>
70. FID – "Evaluation measures", Wikipedia <https://en.wikipedia.org/wiki/Fr%C3%A9chet_inception_distance>
71. [국가법령정보센터] <<https://www.law.go.kr/>>
72. Image_Quality_Assessment_From_Error_Visibility_to_Structural_Si
<https://www.researchgate.net/publication/3327793_Image_Quality_Assessment_From_Error_Visibility_to_Structural_Similarity>
73. Deep 3D human pose estimation A review
<https://pure.uva.nl/ws/files/67521019/1_s2.0_S1077314221000692_main.pdf>
74. Kinship verification using Compound Local Binary Pattern and Local Feature Discriminant Analysis
<https://www.researchgate.net/publication/338359209_Kinship_verification_using_Compound_Local_Binary_Pattern_and_Local_Feature_Discriminant_Analysis>
75. Point-NeRF: Point-based Neural Radiance Fields <<https://arxiv.org/abs/2201.08845>>
76. ROUGE: A Package for Automatic Evaluation of summaries <https://www.researchgate.net/publication/224890821_ROUGE_A_Package_for_Automatic_Evaluation_of_summaries>
77. The unreasonable effectiveness of deep features as a perceptual metric <<https://arxiv.org/abs/1801.03924>>
78. SSA – Towards a Human-like Open-Domain Chatbot <<https://arxiv.org/abs/2001.09977>>
79. What is a good evaluation measure for semantic segmentation
<https://www.researchgate.net/publication/258642225_What_is_a_good_evaluation_measure_for_semantic_segmentation>
80. On LLMs-Driven Synthetic Data Generation, Curation, and Evaluation: A Survey
<<https://arxiv.org/abs/2406.15126>>
81. An Introduction to Diffusion Models and Stable Diffusion
<<https://blog.marvik.ai/2023/11/28/an-introduction-to-diffusion-models-and-stable-diffusion>>
82. Stable diffusion using Hugging Face
<<https://towardsdatascience.com/stable-diffusion-using-hugging-face-501d8dbdd8>>
83. Unsupervised Learning <<https://c3.ai/introduction-what-is-machine-learning/unsupervised-learning/>>
84. DPO: Scaling Direct Preference Optimization with 2-Dimensional <<https://arxiv.org/html/2410.19720v1>>
85. Microsoft, Microsoft Responsible AI Impact Assessment Guide
<<https://query.prod.cms.rt.microsoft.com/cms/api/am/binary/RE4ZzOI>>
86. IBM, What is generative AI? <<https://research.ibm.com/blog/what-is-generative-ai>>
87. Anantrasirichai, N., Bull, D., "Artificial intelligence in the creative industries: a review," Artificial intelligence review, vol.55, pp. 589–656, 2022. <<https://link.springer.com/article/10.1007/s10462-021-10039-7>>
88. Accelerate your genAI success with the LLM training leader <<https://www.turing.com/services/generative-ai>>
89. Michael Chui, Eric Hazan, Roger Roberts, Alex Singla, Kate Smaje, Alex Sukharevsky, Lareina Yee, and

- Rodney Zimmel, The economic potential of generative AI: The next productivity frontier,
 <<https://www.mckinsey.com/capabilities/mckinsey-digital/our-insights/the-economic-potential-of-generative-ai-the-next-productivity-frontier#introduction>>
90. Díaz-Rodríguez, N., et.al, "Connecting the dots in trustworthy Artificial Intelligence: From AI principles, ethics, and key requirements to responsible AI systems and regulation
 91. Dwivedi, Yogesh K., Nir Kshetri, Laurie Hughes, Emma Louise Slade, Anand Jeyaraj, Arpan Kumar Kar, Abdullah M. Baabdullah et al. "So what if ChatGPT wrote it?" Multidisciplinary perspectives on opportunities, challenges and implications of generative conversational AI for research, practice and policy
 92. Li, Bo, Peng Qi, Bo Liu, Shuai Di, Jingen Liu, Jiquan Pei, Jinfeng Yi, and Bowen Z., "Trustworthy AI: From principles to practices," ACM Computing Surveys, vol. 55 no. 9, pp. 1-46, 2023.
 93. UNESCO, Guidance for generative AI in education and research
 <<https://unesdoc.unesco.org/ark:/48223/pf0000386693>>
 94. Kathy Baxter and Yoav Schlesinger, Managing the Risks of Generative AI
 <<https://hbr.org/2023/06/managing-the-risks-of-generative-ai>>
 95. Daan Kolkman, "F**k the algorithm?": What the world can learn from the UK's A-level grading fiasco
 <<https://blogs.lse.ac.uk/impactofsocialsciences/2020/08/26/fk-the-algorithm-what-the-world-can-learn-from-the-uks-a-level-grading-fiasco/>>
 96. Dylan Walsh, The legal issues presented by generative AI
 <<https://mitsloan.mit.edu/ideas-made-to-matter/legal-issues-presented-generative-ai>>
 97. Christopher J. Valente, Michael J. Stortz, Amy Wong, Peter E. Soskin, Michael W. Meredith, Recent Trends In Generative Artificial Intelligence Litigation In The United States
 <<https://www.klgates.com/Recent-Trends-in-Generative-Artificial-Intelligence-Litigation-in-the-United-States-9-5-2023>>
 98. Kyle Wiggers, The current legal cases against generative AI are just the beginning
 <<https://techcrunch.com/2023/01/27/the-current-legal-cases-against-generative-ai-are-just-the-beginning/>>
 99. Rabihah Butler, Generative AI and the courts: Balancing efficiency and legal obligations,
 <<https://www.thomsonreuters.com/en-us/posts/government/generative-ai-courts/>>
 100. 과학기술정보통신부, 제4차 인공지능 최고위 전략대회 개최
 <<https://www.msit.go.kr/bbs/view.do?sCode=user&mPid=113&mPid=238&pageIndex=&bbsSeqNo=94&nttSeqNo=3183597&searchOpt=ALL&searchTxt=>>
 101. Marcus Ng, et. al, The Economic Impact of Generative AI: The Future of Work in South Korea,
 <<https://accesspartnership.com/gen-ai-future-of-work-south-korea/>>
 102. Kim Yoo-chul, How can Korea expand AI ecosystem?
 <https://www.koreatimes.co.kr/www/tech/2023/10/129_354043.html>
 103. Kim Yoo-chul, Korea advised to avoid heavy-handed AI regulations
 <https://www.koreatimes.co.kr/www/tech/2023/10/129_354833.html>
 104. University of Florida, AI Tools and Resources – Evaluating the Reliability and Authority of AI Generated text and media <<https://guides.lib.usf.edu/c.php?g=1315087&p=9678779>>
 105. Anuj Saxena, Exploring the Reliability Dilemma: Generative AI Vs. Human Insights,[Online], Available:
 <<https://www.knowledgeridge.com/Blog/Exploring-the-Reliability-Dilemma-Generative-AI-Vs-Human-Insights>>
 106. Luis Serrano, Emerging Trends in Generative AI Research: Top Research Papers August 2023
 <<https://txt.cohere.com/top-nlp-papers-august-2023/>>
 107. Dwivedi, Yogesh K., Anuj Sharma, Nripendra P. Rana, Mihalis Giannakis, Pooja Goel, and Vincent Dutot," Evolution of artificial intelligence research in Technological Forecasting and Social Change: Research topics, trends, and future directions," Technological Forecasting and Social Change, vol. 192, 2023.122579.
 108. Michael Chui, Roger Roberts, Tanya Rodchenko, Alex Singla, Alex Sukharevsky, Lareina Yee, and Delphine Zurkiya, What every CEO should know about generative
 <<https://www.mckinsey.com/capabilities/mckinsey-digital/our-insights/what-every-ceo-should-know-about-generative-ai>>
 109. 의안정보시스템, 알고리즘 및 인공지능에 관한 법률안(윤영찬의원 등 12인)
 <https://likms.assembly.go.kr/bill/billDetail.do?billId=PRC_A2J1R1B1R1J0S1V6W3K9B0K6N6Q0Z9>
 110. WEF, World Economic Forum Launches AI Governance Alliance Focused on Responsible Generative AI
 <<https://www.weforum.org/press/2023/06/world-economic-forum-launches-ai-governance-alliance-focused-on-responsible-generative-ai>>

111. United Nation, International Community Must Urgently Confront New Reality of Generative, Artificial Intelligence, Speakers Stress as Security Council Debates Risks, Rewards
[〈https://press.un.org/en/2023/sc15359.doc.htm〉](https://press.un.org/en/2023/sc15359.doc.htm)
112. [개인정보보호위원회] 신뢰 기반 인공지능 데이터 규범, 첫발 떼다
[〈https://www.pipc.go.kr/np/cop/bbs/selectBoardArticle.do?bbsId=BS074&mCode=C020010000&nttId=9083〉](https://www.pipc.go.kr/np/cop/bbs/selectBoardArticle.do?bbsId=BS074&mCode=C020010000&nttId=9083)
113. Digital Policy Alert, Republic of Korea: Adopted Artificial Intelligence(AI) Personal Information Protection Self-Checklist
[〈https://digitalpolicyalert.org/event/1059-adopted-artificial-intelligence-ai-personal-information-protection-self-checklist〉](https://digitalpolicyalert.org/event/1059-adopted-artificial-intelligence-ai-personal-information-protection-self-checklist)
114. Bommasani, R., et al. "On the opportunities and risks of foundation models."
[〈https://arxiv.org/abs/2108.07258〉](https://arxiv.org/abs/2108.07258)
115. Liam A., Divyansh K., How Do OpenAI's Efforts to Make GPT-4 "Safer" Stack Up Against the NIST AI Risk Management Framework?
[〈https://fas.org/publication/how-do-openais-efforts-to-make-gpt-4-safer-stack-up-against-the-nist-ai-risk-management-framework/〉](https://fas.org/publication/how-do-openais-efforts-to-make-gpt-4-safer-stack-up-against-the-nist-ai-risk-management-framework/)
116. Holistic AI, The Need for Risk Management in AI Systems
[〈https://www.holisticai.com/blog/need-for-risk-management-in-ai〉](https://www.holisticai.com/blog/need-for-risk-management-in-ai)
117. [NIST] NIST Risk Management Framework Aims to Improve Trustworthiness of Artificial Intelligence
[〈https://www.nist.gov/news-events/news/2023/01/nist-risk-management-framework-aims-improve-trustworthiness-artificial〉](https://www.nist.gov/news-events/news/2023/01/nist-risk-management-framework-aims-improve-trustworthiness-artificial)
118. [NIST] Artificial Intelligence Risk Management Framework(AIRMF1.0), ISTAI100-1
[〈https://doi.org/10.6028/NIST.AI.100-1〉](https://doi.org/10.6028/NIST.AI.100-1)
119. White Paper Artificial Intelligence Technology, Use Cases and Applications, Trustworthiness and Technical Standardization V. 1.1
<https://portal-qualite.public.lu/dam-assets/publications/normalisation/2021/ilnas-white-paper-artificial-intelligence.pdf>
120. Sarah Ladipo, The Risks of GPT-3: What Could Possibly Go Wrong?
[〈https://www.datarobot.com/blog/the-risks-of-gpt-3-what-could-possibly-go-wrong/〉](https://www.datarobot.com/blog/the-risks-of-gpt-3-what-could-possibly-go-wrong/)
121. What are the risks of artificial intelligence(AI)? [〈https://www.tableau.com/data-insights/ai/risks〉](https://www.tableau.com/data-insights/ai/risks)
122. John Willis, What DevOps Needs to Know About ChatGPT [〈https://devops.com/what-devops-needs-to-know-about-chatgpt/〉](https://devops.com/what-devops-needs-to-know-about-chatgpt/)
123. Hayden Field, John Grisham, George R.R. Martin and other prominent authors sue OpenAI
<https://www.cnn.com/2023/09/20/john-grisham-george-rr-martin-other-prominent-authors-sue-openai.html>
124. Is AI a Risk to Intellectual Property?
[〈https://www.innovationinbusiness.com/is-ai-a-risk-to-intellectual-property/〉](https://www.innovationinbusiness.com/is-ai-a-risk-to-intellectual-property/)
125. Somepalli, G., Vasu S., Micah G., Jonas G., and Tom G., "Diffusion art or digital forgery? investigating data replication in diffusion models," In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 6048-6058, 2023.
126. ISO, Crosswalk AI RMF(1.0) and ISO/IEC FDIS 23894 Information technology – Artificial intelligence Guidance on risk management [〈https://www.nist.gov/system/files/documents/2023/01/26/crosswalk_AI_RMF_1_0_ISO_IEC_23894.pdf〉](https://www.nist.gov/system/files/documents/2023/01/26/crosswalk_AI_RMF_1_0_ISO_IEC_23894.pdf)
127. Kimberly Steele, Risk Management Framework: What is RMF? [〈https://bigid.com/blog/risk-management-framework-what-is-rmf/〉](https://bigid.com/blog/risk-management-framework-what-is-rmf/)
128. [NIST] AI RMF Playbook [〈https://airc.nist.gov/AI_RMF_Knowledge_Base/Playbook〉](https://airc.nist.gov/AI_RMF_Knowledge_Base/Playbook)
129. Benjamin A., 5 biggest risks of Generative AI according to an expert [〈https://generativeai.pub/5-biggest-risks-of-generative-ai-according-to-an-expert-599fcb4e6bb〉](https://generativeai.pub/5-biggest-risks-of-generative-ai-according-to-an-expert-599fcb4e6bb)
130. George L., AI transparency: What is it and why do we need it? [〈https://www.techtarget.com/searchcio/tip/AI-transparency-What-is-it-and-why-do-we-need-it〉](https://www.techtarget.com/searchcio/tip/AI-transparency-What-is-it-and-why-do-we-need-it)
131. François C., Theodoros E. and David M., AI Can Be Both Accurate and Transparent
[〈https://hbr.org/2023/05/ai-can-be-both-accurate-and-transparent〉](https://hbr.org/2023/05/ai-can-be-both-accurate-and-transparent)
132. Melissa Heikkilä, Google DeepMind has launched a watermarking tool for AI-generated images [〈https://www.technologyreview.com/2023/08/29/1078620/google-deepmind-has-launched-a-watermarking-tool-for-ai-generated-images/〉](https://www.technologyreview.com/2023/08/29/1078620/google-deepmind-has-launched-a-watermarking-tool-for-ai-generated-images/)
133. Cheng Lim, Lauren Bourke, Kendra Fouracre, Luke Pallaras and Antonio Barbaro, Why your company needs a ChatGPT use policy and an AI governance framework? [〈https://www.kwm.com/global/en/insights/latest-thinking/why-your-company-needs-a-chatgpt-use-policy-and-an-ai-governance-framework.html〉](https://www.kwm.com/global/en/insights/latest-thinking/why-your-company-needs-a-chatgpt-use-policy-and-an-ai-governance-framework.html)
134. 생성형AI 개념도 [〈https://news.skynix.co.kr/post/all-around-ai-1〉](https://news.skynix.co.kr/post/all-around-ai-1)
134. 초거대 AI 운영비용에 관한 컨설팅 기업 세미애널리시스(SemiAnalysis)의 보고서
135. 버티컬AI 특성 [〈https://news.mt.co.kr/mtview.php?no=2024102317220470605〉](https://news.mt.co.kr/mtview.php?no=2024102317220470605)

- 136.K-Means Clustering <<https://datapilots.tistory.com/103>>
- 137.DBSCAN <<https://github.com/kloud80/urban-data-mining/blob/master/09%20Clustering/014%20ED%81%B4%EB%9F%AC%EC%8A%A4%ED%84%B0%EB%A7%81.pdf>>
- 138.Hierarchical 알고리즘 <<https://velog.io/@i-zro/ml-clustering>>
- 139.Principal Component Analysis <<https://jinger.tistory.com/entry/%EA%B8%B0%EA%B3%84-%ED%95%99%EC%8A%B5-9-Unsupervised-Learning-Techniques>>
- 140.연관 규칙 학습 세부 분류 <<https://www.ibm.com/kr-ko/topics/unsupervised-learning>>, <<https://charmingham.tistory.com/144>>, <<https://wendys.tistory.com/169>>
- 141.이상 감지와 분류의 차이<https://datanetworkanalysis.github.io/2020/02/05/understanding_outlier1>
- 142.잠재 변수 모델 <<https://www.appier.com/ko-kr/blog/a-simple-guide-to-unsupervised-learning>>
- 143.SH-GAN 모델 <<https://github.com/SHI-Labs/SH-GAN>>
- 144.공공누리 라이선스 유형 <<http://whhttp://www.kogl.or.kr/info/license.do>>
- 145.Instruction Tuning <[https://www.ibm.com/topics/instruction-tuning\(2024\)](https://www.ibm.com/topics/instruction-tuning(2024))>
- 146.Self-Instruct - Yizhong Wang, Yeganeh Kordi, et al. "SELF-INSTRUCT: Aligning Language Models with Self-Generated Instructions." arXiv preprint (2023)
- 147.DPO - 2D-DPO:Scaling Direct Preference Optimization with 2-Dimensional Supervision(2024)
<<https://www.aitimes.com/news/articleView.html?idxno=155284>>, "Direct preference optimization: Your language model is secretly a reward model."arXiv preprint (2023)
- 148.Open LLMs <<https://github.com/eugeneyan/open-llms>>
- 149.객체 레벨 캡셔닝 <<https://vision.cs.uiuc.edu/pascal-sentences/>>
- 150.AI허브 시각정보 기반 질의응답 데이터
<<https://www.aihub.or.kr/aihubdata/data/view.do?currMenu=&topMenu=&aihubDataSe=data&data SetSn=104>>
- 151.스토리텔링 캡셔닝 <<https://arxiv.org/pdf/1604.03968>>
- 152.Dense Captioning <<https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2019.01321/full>>
- 153.Dense Captioning 모델 구조 -Potential of Incorporating Motion Estimation for Image Captioning
- 154.Sparse Captioning <<https://cocodataset.org/#explore>>
- 155.Sparse Captioning 선호도 기반 캡셔닝 <<https://arxiv.org/abs/2309.14525>>
- 156.AIHub Image Caption <<https://www.youtube.com/watch?v=mvHxI4oRuN0&t=517s>>
- 157.RNN 원리 구조 - Quality Improvement of Image Captions for Cinematic Video Using Character Tags
- 158.LSTM 원리 구조 <<https://medium.com/dowie/deep-learning-long-short-term-memory-model-lstm-d4ee2f005973>>
- 159.동영상 캡셔닝 동작 <github.com/eodud0582/Video_Caption_Generation_Using_Deep_Learning>
- 160.RECAP DataComp-1B - What If We Recaption Billions of Web Images with LLaMA-3
<[https://arxiv.org/pdf/2406.08478/\(2024\)](https://arxiv.org/pdf/2406.08478/(2024))>
- 161.RECAP DALL·E3 구조 <<https://jehyunlee.github.io/2024/03/20/General-46-dalle3styles3/>>,
<<https://arxiv.org/pdf/2204.06125>>
- 162.DALL·E 캡션 기반 이미지 <<https://openai.com/index/dall-e-3/>>
- 163.GPT-4V로 캡션 업샘플링 DALL·E 3 이미지 생성 <<https://cdn.openai.com/papers/dall-e-3>>
- 164.Contrastive Learning <<https://proceedings.mlr.press/v139/radford21a/radford21a.pdf>>
- 165.CLIP 구조 <<https://proceedings.mlr.press/v139/radford21a/radford21a.pdf>>
- 166.PLIP 구조 <<https://www.biorxiv.org/content/10.1101/2023.03.29.534834v1.full.pdf>>
- 167.BLIP 구조 <<https://proceedings.mlr.press/v162/li22n/li22n.pdf>>
- 168.BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models
<<https://arxiv.org/abs/2301.12597>>
- 169.InstructBLIP <<https://arxiv.org/pdf/2305.06500>>
- 170.LLaVA 아키텍처 <<https://arxiv.org/abs/2304.08485>>
- 171.Show and Tell (Google) 구조 <<https://research.google/pubs/show-and-tell-a-neural-image-caption-generator/>>
- 172.NIC (Neural Image Caption) 구조 <<https://openai.com/index/clip/>>
- 173.Bottom-Up Top-Down(BUTD) 구조 <https://www.tensorflow.org/tutorials/text/image_captioning>
- 174.Transformer-based Model 구조 <<https://github.com/laxmimerit/NLP-Tutorials-with-HuggingFace>>
- 175.Image-Captioning-ResNet-Attention(Microsoft) 구조 <<https://www.researchsquare.com/article/rs-2265972/v1>>
- 176.이미지 캡션을 만드는 요소 What Makes for Good Image Captions? 2024 <<https://arxiv.org/html/2405.00485v2#bib>>
- 177.정보 추출 비율 - Scene Graph Generation by Iterative Message Passing(2017)

178. 정보 표현 적절성, 일치성 - Hallucination of Multimodal Large Language Models_ A Survey(2024)
179. 정보 표현 풍부성 - CoMat_ Aligning Text-to-Image Diffusion Model
180. 정보추출 비율 반영 캡션 <<https://unsplash.com/>>, <<https://www.istockphoto.com/>>, <<https://unsplash.com/>>, <<https://www.istockphoto.com/>>
181. 정보 표현 적절성 반영 캡션- 문자가 포함된 그림(사진) 기반 문장 생성
<<https://kli.korean.go.kr/benchmark/taskOrdtm/taskList.do?taskOrdtmId=58>>,
<https://github.com/eodud0582/Video_Caption_Generation_Using_Deep_Learning>, <https://github.com/eodud0582/Video_Caption_Generation_Using_Deep_Learning>
182. 정보 표현 풍부성 반영 캡션 - 한국컴퓨터종합학술대회 논문집
Multi-Modal Complex Emotion Recognition Based on Image Captioning, <<https://unsplash.com/>>
<<https://www.istockphoto.com/>>
183. 정보 내용 일치성 반영 캡션 <<https://unsplash.com/>>, <<https://www.istockphoto.com/>>
언어정보 나눔터 <<https://kli.korean.go.kr/benchmark/taskOrdtm/taskList.do?taskOrdtmId=58>>
그림(사진) 기반 문장 생성
184. METEOR <<https://en.wikipedia.org/wiki/METEOR>>
185. CIDEr: Consensus-based Image Description Evaluation <<https://arxiv.org/pdf/1411.5726>>
186. SPICE: Semantic Propositional Image Caption Evaluation <<https://arxiv.org/pdf/1607.08822>>
187. CLIP Score <https://lightning.ai/docs/torchmetrics/stable/multimodal/clip_score.html>
188. Molmo - Univ. of Toronto, Kaustav Kundu | Datasets and Metrics for Image Captioning Generation, MINT-1T-
<<https://arxiv.org/pdf/2406.11271>>, Measuring Massive Multitask Language Understanding
<<https://arxiv.org/pdf/2009.03300>>
189. LLaMA3 구조 <<https://ai.meta.com/blog/meta-llama-3>>
190. LLaMA2 구조 <<https://www.llama.com/llama2/>>
191. Solor 10.7B 아키텍처 - 디지털경제뉴스<<http://www.denews.co.kr>>, <<https://ostin.tistory.com/350>>
192. Mistral-7B의 Attention 아키텍처 <<https://arxiv.org/pdf/2310.06825v1>>
193. BLOOM 아키텍처 <<https://arxiv.org/abs/2211.05100>>, <<https://www.aitimes.com/news/articleView.html?idxno=145494>> Montreal AI Ethics Institute, <https://www.researchgate.net/figure/The-BLOOM-architecture-example-sourced-from-9_fig5_372341712>
194. GPT-NeoX 아키텍처 - Black, Sid, et al. "Gpt-neox-20b: An open-source autoregressive language model." arXiv preprint arXiv:2204.06745(2022)
195. KoBERT 아키텍처 <<https://jkie.org/xml/32836/32836.pdf>>, <https://jkie.org/_common/do.php?a=full&b=12&bidx=3140&aid x=34983>
196. Stable Diffusion 구조 - Rombach, R., Blattmann, A., Lorenz, D., Esser, P., & Ommer, B. (2022)
High-resolution image synthesis with latent diffusion models - In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition (CVPR) (pp. 10684-10695)
<<https://arxiv.org/abs/2112.10752>>
197. GAN 구조 <https://developers.google.com/machine-learning/gan/gan_structure?hl=ko>
198. VAE 구조 <https://www.researchgate.net/figure/The-basic-architecture-of-variational-autoencoder-VAE_fig3_359471754>
199. ViT 아키텍처 <<https://arxiv.org/abs/2010.11929>>
200. SegFormer 아키텍처 <https://huggingface.co/docs/transformers/model_doc/segformer>
201. InceptionV3 구조 <https://www.researchgate.net/figure/The-architecture-of-Inception-V3-model_fig5_349717475>
202. GPT-4V 시뮬레이션 <<https://meetcody.ai/ko/>> <<https://textcortex.com/ko/post/what-is-gpt-4v-ision#2c>>
203. ExpansionNet v2 구조 - Hu. Cheng. Jia. et al. "Exploiting Multiple Sequence Lengths in Fast End to End Training for Image Captioning." (arXiv preprint arXiv:2208.06551)
204. Faster R-CNN 구조 - Towards Real-Time Object Detection with Region Proposal Networks
<<https://arxiv.org/pdf/1506.01497v3>>, <<https://hugrypiggykim.com/2019/04/19/light-head-r-cnn/>>
205. nn-UNet 구조 <<https://keemsir.github.io/posts/nnUNet-tutorial/>>
206. TransUNet 구조 <<https://arxiv.org/pdf/2102.04306>>, <<https://medium.com/@maknimariem11/transunet-transformers-make-strong-encoders-for-medical-image-segmentation-2646419be4bb>>
207. Touvron, H., Lavril, T., Izacard, G., Martinet, X., Lachaux, M. A., Lacroix, T., ... & Lample, G. (2023). Llama: Open and efficient foundation language models. arXiv preprint arXiv:2302.13971
208. SSIM <<https://medium.com/srm-mic/all-about-structural-similarity-index-ssim-theory-code-in-pytorch-6551b455541e>>
209. LPIPS <<https://arxiv.org/pdf/1801.03924>>
210. Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., ... & Amodei, D. (2020). Language

- models are few-shot learners. Advances in neural information processing systems, 33
211. Radford, Alec, et al. "Improving language understanding by generative pre-training." (2018)
212. R. Socher, A. Perelygin, J. Wu, J. Chuang, C. D. Manning, A. Ng, and C. Potts. Recursive deep models for semantic compositionality over a sentiment treebank. In Proceedings of the 2013 conference on empirical methods in natural language processing, pages 1631–1642, 2013
213. W. B. Dolan and C. Brockett. Automatically constructing a corpus of sentential paraphrases. In Proceedings of the Third International Workshop on Paraphrasing (IWP2005), 2005
214. S. R. Bowman, G. Angeli, C. Potts, and C. D. Manning. A large annotated corpus for learning natural language inference. EMNLP, 2015
215. [개인정보보호위원회] 합성데이터 생성·활용 안내서
216. ETRI 전사가이드라인 v1.0

AI 데이터 품질관리 가이드라인 v4.0

제1권 AI 데이터 품질관리 가이드 v4.0

2026년 02월 발행

발행처: 한국지능정보사회진흥원

작성 참여진

한국지능정보사회진흥원 신신애 본부장

한국지능정보사회진흥원 유호진 팀장

한국지능정보사회진흥원 이창민 수석

한국지능정보사회진흥원 윤주미 선임

(주)티지 허다영 책임

자문 위원

세종대학교 구영현 교수

인하대학교 김승환 교수

건양대학교 김종엽 교수

연세대학교 김현중 교수

경희대학교 홍아름 교수

한양대학교 강하예진 박사

(주)셀렉트스타 김세엽 대표이사

(주)드위치 이태석 대표이사

- 본 『제1권 AI 데이터 품질관리 가이드 v4.0』 내용의 무단전재 및 재배포를 금하며, 가공·인용 시에는 반드시 과학기술정보통신부, 한국지능정보사회진흥원의 「AI 데이터 품질관리 가이드라인 v4.0 - 제1권 AI 데이터 품질관리 가이드 v4.0」임을 밝혀주시기 바랍니다.
- 본 『제1권 AI 데이터 품질관리 가이드 v4.0』는 ‘2025년 초거대AI 확산 생태계 조성사업’ 중 ‘초거대AI 확산 생태계 조성 사업관리 전문지원’ 용역 사업의 결과 산출물입니다.
 - 한국지능정보사회진흥원 인공지능데이터본부 AI데이터사업팀 품질유닛 : aidq@nia.or.kr