

제4권 추론형 AI 데이터를 중심으로

신기술 AI 데이터 품질관리 가이드 v1.0

제4권

신기술 AI 데이터 품질관리 가이드 발행에 부쳐

생성형 AI 분야에서 대두되는 신기술들, 혹은 별도로 분류되는 신기술들을 '데이터'의 수집, 처리, 활용 방식이라는 관점에서 설명하기 위해 품질관리 가이드라인을 별도로 제작하고자 합니다. 가이드라인의 설명을 통해 AI 모델의 학습 및 추론에 사용되는 데이터의 양, 다양성, 품질, 효율성 개선을 목표로 합니다.

3권 생성형 AI 데이터의 품질관리 가이드에서 생성형 AI 데이터 중에서 이미지를 중심으로 하는 멀티모달 데이터 즉, 이미지 생성 기술에 대해 주로 설명하면서 텍스트 데이터셋, 이미지 데이터셋 등 멀티모달 데이터셋을 동일한 임베딩 공간으로 통합하여 하나의 거대한 융합 데이터셋으로 활용하는 부분을 주로 다루었습니다.

4권에서는 고품질의 구조화된 추론데이터의 품질관리를 중점으로 서술하려 합니다. 모델이 추론 과정을 거쳐 생성하는 데이터, 즉 결과물의 논리적 구조를 개선하는 데 사용되는 학습용 데이터의 품질관리에 초점을 맞추고 단계별 사고과정이 명시적으로 포함된 고품질의 프롬프트-응답 쌍데이터에 대해 설명하도록 하겠습니다.

AI가 향후 어떻게 발전하고 어느 방향으로 확대될지를 지금 이 순간 예측하는 것은 우리의 인지적 사고의 한계 밖의 이야기인 듯 싶습니다.

다만 우리는 사후적으로 발전되는 기술과 그에 조응하는 데이터 구축의 품질관리에 대해서는 지속적으로 품질관리 가이드라인에 담아내고자 합니다.

그러한 시도의 일환으로 4권 신기술 AI 데이터의 구축 및 품질관리에 대한 내용을 담아내어 데이터 구축의 신뢰성, 투명성, 복잡한 문제 해결 능력을 획기적으로 개선되기를 바랄 뿐입니다.

추론형 AI 데이터를 구축하고자 하는 분들에게 도움이 되셨으면 하는 바람을 담아 작성하였으며 추론형 AI 데이터 이외 이후에 발생하는 수많은 생성형 AI 트렌드와 최신기술들도 수요자에 제공하도록 할 예정입니다.

I | 개요

제1장 추진 배경 및 목적

- | | |
|---------|---|
| 1. 추진배경 | 1 |
| 2. 목적 | 6 |

제2장 가이드라인 구성 및 범위

- | | |
|----------------|---|
| 1. 가이드라인 구성 개요 | 7 |
| 2. 가이드라인의 적용범위 | 9 |

제3장 추론형 AI 데이터 이해

- | | |
|----------------------------|----|
| 1. 추론형 AI 정의 | 10 |
| 2. 추론형 AI 특징 | 13 |
| 3. 주요 추론형 AI 데이터셋 동향 | 17 |
| 4. 추론형 AI 데이터 생성 및 품질관리 기술 | 23 |

제4장 추론형 AI 데이터 품질관리의 이해

- | | |
|------------------------------|----|
| 1. 추론형 AI 데이터 품질관리 필요성 | 26 |
| 2. 추론형 AI 데이터 품질관리 개념 및 정의 | 28 |
| 3. 추론형 AI 데이터 품질관리 목적 및 기대효과 | 29 |
| 4. 추론형 AI 데이터 품질관리 활동 | 30 |

II | 추론형 AI 데이터 품질관리 체계

제1장 품질특성 및 고려사항

- | | |
|------------------------|----|
| 1. 추론형 AI 데이터의 특성 | 31 |
| 2. 추론형 AI 데이터 특성별 고려사항 | 34 |
| 3. 추론형 AI 데이터 품질특성 | 35 |

제2장 추론형 AI 데이터 품질관리

- | | |
|--------------------|----|
| 1. 품질관리 프레임워크 구성 | 66 |
| 2. 품질관리 활동 | 70 |
| 3. 품질관리 프로세스 및 산출물 | 73 |
| 4. 가공단계 품질관리 활동 | 74 |

III | 추론형 AI 주요기술

제1장 추론형 AI 기법

1. 개요	91
2. 추론형 AI 기본 구조	93
3. 추론형 AI 강화 기법	118
4. 도메인/표현 확장 적용기법	129

제2장 추론형 AI 주요 모델

1. 개요	137
2. LLM 데이터 추론모델	140
3. LMM 데이터 추론모델	150
4. 합성데이터 추론모델	155
5. 액션중심 데이터 추론모델	159
6. 추론형 AI 데이터의 주요 벤치마크 데이터셋	163

IV | 부록

부록1. 품질관리 지표 기준

1. 품질관리 지표	165
2. 구축 공정 적정성 품질관리 지표	171
3. 데이터 적합성 품질관리 지표	172
4. 가공데이터 정확성 품질관리 지표	176
5. 학습모델 적합성 품질관리 지표	191

부록2. 품질지표 설정 가이드

1. 의미정확성 품질지표 설정 가이드	218
2. 유효성 품질지표 설정 가이드	224

부록3. 근거문헌

1. 근거문헌 세부내용	226
--------------	-----

AI 데이터 품질관리 가이드라인 v4.0

제4권

추론형 AI 데이터를 중심으로

신기술 AI 데이터 품질관리 가이드 v1.0

I

개요

제1장 | 추진 배경 및 목적

제2장 | 가이드라인 구성 및 범위

제3장 | 추론형 AI 데이터 이해

제4장 | 추론형 AI 데이터 품질관리의 이해

제1장

추진 배경 및 목적

1

추진배경

1.1 추론형 AI 데이터의 정의

- 추론형 AI(Reasoning AI)는 단순한 패턴 인식이나 예측을 넘어 논리적 단계를 거쳐 복잡한 문제 해결이나 의사결정을 수행하는 인공지능(AI) 시스템을 의미
- 이 과정에서 사용되는 '추론형 AI 데이터'는 일반 데이터와 달리 논리적 연결성, 인과 관계, 다단계 추론 패턴을 포함하는 데이터를 말함
- 추론형 AI 데이터는 인공지능(AI)의 '생각 과정'을 강화하기 위한 특화된 데이터로 정의

1.2 등장 배경과 필요성

- LLM은 생성 능력은 뛰어나지만 환각(hallucination)과 논리적 비약이 잦아 단순히 데이터 및 파라미터 규모를 키우는 것만으로는 '정확한 이해·추론' 성능을 안정적으로 확보하기 어렵다는 한계 발생
- 이에 따라 정답만 제공하는 데이터가 아니라 문제를 단계적으로 분해하고 근거를 점검하는 중간 추론 과정(Chain-of-Thought 등)까지 포함한 '추론형 데이터'의 필요성이 제기됨
- 학습 이후 실제 추론 단계에서 샘플링·탐색과 같은 추가 계산을 투입해 성능을 끌어올리는 추론 강화 기법 등이 확산되며 모델이 인간처럼 단계적 사고를 수행하도록 뒷받침하는 데이터의 중요성이 부각

1.2.1 등장배경

- AI 발전의 맥락
 - 1990년대부터 인공지능(AI)은 지식 기반 시스템에서 딥러닝 기반 패턴 인식모델로 전환되었으나, 2020년대 들어 의료진단, 법률분석, 자율주행 등 복잡한 실세계 문제 해결에 있어 단순 예측을 넘어선 '추론' 능력이 필수로 인식
 - 저품질 데이터가 AI의 인지 성능을 저하시킨다고 지적하며 고품질 추론 데이터의 수요가 급증
- 데이터 부족 문제
 - 기존 데이터셋은 양은 방대함에도 불구하고 논리적 사고나 인과관계를 학습하기 어려운 비구조적 텍스트가 대부분이었기 때문에 추론에 적합한 구조화된 논리 패턴이 부족
 - 이에 추론형 데이터가 독립적인 별도의 카테고리 구분되기 시작

- 산업 수요
 - 기업들은 점차 AI를 비즈니스 의사결정의 핵심 도구로 활용하면서 단순 결과 예측이 아닌 “왜(Why)”와 “어떻게(How)”를 설명할 수 있는 추론 기반 모델을 요구
 - 예를 들어, M&A 성공 가능성 분석, 자율주행 차량의 상황판단, 복잡한 법률 문서 해석 등 투명하고 검증 가능한 추론 과정이 핵심 경쟁력으로 작용

시대	AI 기술 발전 트렌드	데이터 요구사항
1990년대 (지식기반)	• 지식기반 전문가시스템 • Symbolic AI	• 도메인 지식 중심의 구조화된 규칙 데이터 (규칙/온톨로지 중심) • 사람이 수작업으로 구성한 지식베이스
2000년 ~ 2010년 (통계학습)	• 통계학습과 머신러닝 모델 • SVM, Random Forest 등장	• Feature기반정형데이터(구조화된수치데이터) • 품질보다는 양 중심의 데이터 활용
2010년 ~ 2020년 (딥러닝)	• 딥러닝 기반 패턴 인식 • 이미지/음성 인식 능력강화 • Transformer 구조 확산	• 대규모 비구조적 데이터(웹 크롤링 • Common Crawl 중심의 대량 텍스트 • “정확한 추론”보다는 “패턴 학습” 중심
2020년 ~ 현재 (추론형 AI)	• 거대언어모델(LLM) • CoT, ToT 등 • 복잡 문제 해결 능력 요구 • 비즈니스, 의료, 법률 등에서 투명한 추론 과정 필요	• 고품질 추론 데이터 필요 • 인과관계와 논리과정이 포함된 구조적 데이터 부족 문제 • 합성 추론데이터 생성 기술 급부상 • 설명가능한 데이터의 중요성 증가 • 데이터 품질 저하 우려 확대

[표 1-1] 추론형 데이터의 필요성

1.2.2 필요성

- 성능 향상
 - 추론형 데이터는 단순 패턴 인식에 머무르던 기존 딥러닝 모델의 한계를 극복하기 위한 핵심 요소
 - 복합적 사고 과정을 학습시켜 다중 단계 질문 응답(Multi-step QA),수학적 추론(Math reasoning)등 복잡한 과업의 성능 향상을 이끌어내며, AI의 실생활 적용 신뢰도를 높이고 있음
- 편향 및 오류 감소
 - 저품질 웹 데이터의 편향(bias)이 사회적으로 문제가 되는 가운데, 추론형 데이터는 ‘논리적 일관성’과 ‘공정성’을 확보할 수 있는 대안으로 주목받고 있음
- AI 에이전트화
 - AI가 점차 ‘에이전트형 시스템(Agentic AI)’으로 진화함에 따라, 자율적 계획·실행을 지원하는 논리적 추론 데이터는 필수 인프라로 자리 잡고 있으며, 장기적으로 범용 인공지능(AGI)으로의 이행을 촉진하는 동력으로 작용
- 경제적 효율
 - 고품질 추론 데이터는 모델 학습 효율과 에너지 사용을 최적화함으로써 경제적 비용 절감에도 기여

구분	내용	기대효과
성능 향상	추론형 데이터는 AI의 논리적 사고를 강화하여 복잡한 작업(수학 증명, 다중 QA 등)에서 성능 향상을 유도	- 고난도 문제 해결력 제고 - 실생활 응용 시 신뢰성 향상
편향 및 오류 감소	- 저품질 데이터 기반 편향(bias) 문제가 사회적 이슈로 대두 - 추론형 데이터는 논리성과 공정성을 강화하여 사회적 신뢰 제고	- 데이터 편향 완화 - 합리적 의사결정 구조 확보
AI의 에이전트화	- 차세대 AI는 자율 계획 및 실행(Agentic AI)을 수행하는 시스템으로 진화 - 체계적 추론 데이터 학습이 필수	- 자기계획(Self-planning) 및 의사결정 능력 향상 - 범용 인공지능(AGI) 발전촉진
경제적 효율	- 고품질 추론 데이터는 학습 효율을 높여 훈련 비용 및 에너지 소비 절감에 기여 2025년 AI 데이터 시장 규모 1,000억 달러 초과 전망	- 지속가능한 AI 학습 환경 구축 - 데이터 중심 AI 산업 확장

[표 1-2] 추론형 데이터의 필요성

1.3 추론형 AI 데이터 품질의 중요성

- 추론형 AI에서 데이터 품질은 “Garbage In, Garbage Out(GIGO)” 원칙의 핵심으로, 모델의 전체 성능과 신뢰도를 결정짓는 핵심 요인
- 저품질 데이터는 학습 및 추론 과정에서 오류를 증폭시켜 결과의 일관성을 무너뜨리고, 궁극적으로 인공지능(AI)의 신뢰성을 저하시키므로 고품질 추론 데이터의 확보와 관리는 인공지능(AI)의 지능화 및 실질적 활용을 위한 전제 조건
- 정확성과 신뢰성
 - 불완전하거나 편향된 데이터는 인공지능(AI)의 추론 과정에서 논리적 왜곡을 초래함
 - 예를 들어, 의료 AI 모델이 부정확한 임상 데이터로 학습한 경우 진단오류나 치명적 오진을 유발할 가능성이 높아지는 것처럼 결정적 오류로 이어지므로 데이터 품질은 인공지능(AI)의 신뢰성과 안전성을 직접적으로 좌우함
- 편향 방지와 윤리성 제고
 - 추론형 데이터의 다양성과 공정성이 부족하면 인공지능(AI)은 특정 그룹에 불리한 결정을 내릴 수 있으며 이는 사회적 편향을 재생산하고, 윤리적 신뢰를 저하시킴
 - 따라서 데이터 수집·가공·검증 전 과정에서 공정성 확보를 위한 품질관리 체계가 필수적이며 이를 통해 윤리적이고 설명가능한 AI를 실현해야 함
- 효율성 및 성능 향상
 - 데이터 품질의 주요 차원인 완전성(Completeness), 적시성(Timeliness), 일관성(Consistency) 이 높을수록 학습 효율과 추론 안정성이 향상됨
- 비즈니스 및 운영 효율성
 - AI기반 테스트나 모델링 단계에서 데이터 품질이 낮으면 소프트웨어 오류 증가, 운영비용 상승, 프로젝트 지연 등 실질적 손실이 발생함
 - 반면, 고품질 데이터 관리는 모델 개발 및 운영 비용을 절감하고, ROI를 향상시키며, 프로덕션 단계의 안정성을 확보하는 핵심 요소로 작용
- 도전과 극복 방향
 - AI 데이터 품질 관리는 단순한 정제를 넘어 프라이버시 보호(GDPR 등 법규 준수), 데이터 스케일링 및 거버넌스 문제 해결, 품질 모니터링 자동화 등 복합적인 과제를 포함
 - 이러한 과제들을 지속적으로 해결하는 과정은 AI 준비성(AI Readiness)을 높이고, 장기적으로 지속가능한 AI 생태계를 구축하는 데 기여함
 - 추론형 AI 데이터는 단순한 학습 자원이 아니라 AI의 사고 체계(Cognitive System)를 형성하는 근본적 요소로 데이터 품질에 대한 체계적 관리와 지속적 모니터링, 그리고 국제 표준 기반의 검증된 실무 방법론(Best Practice) 수립이 필수적임

구분	핵심내용	영향/의미
정확성과 신뢰성	- 저품질 데이터는 논리적 왜곡·오류 증폭 - 의료·법률 등에서는 치명적 오판 가능	모델 신뢰성·안전성 직결
편향 방지 및 윤리성	- 양성·공정성 부족 시 사회적 편향 재생 - 윤리적 신뢰도 하락	설명가능한(Responsible) AI 실현을 위한 필수 요건
효율성 및 성능 향상	- 완전성·적시성·일관성이 높을수록 학습 효율이 향상하고 추론 안정성이 높아짐 - 저품질 데이터 증가는 곧 추론 정확도 하락	일관성(Consistency), Hallucination 감소촉진
비즈니스 및 운영 효율성	- 데이터 품질이 낮으면 비용 증가·오류 증가·프로젝트 지연 발생 - 고품질 데이터는 ROI 향상·운영 안정성 강화	데이터 품질이 즉 비즈니스로 경쟁력 기반 인프라에 영향
도전과 극복방향	개인정보 보호·스케일링·데이터 거버넌스·자동 모니터링 등 복합 과제 존재	지속가능한 AI 생태계 구축 및 AI 준비성(AI Readiness) 강화

[표 1 -3] 추론형 AI 데이터 품질의 중요성

2

목적

I

개요

- 본 가이드는 고품질 추론 데이터를 효율적이고 일관된 방식으로 수집·가공·검증할 수 있도록 품질관리 방안을 제시하는 것을 목적으로 함

2.1 체계적 구축 방법 제시

- 본 가이드는 데이터의 전주기적 관리 단계에 따라 데이터 수집과 정제 이후 가공단계에서 추론데이터를 생성, 검증, 평가, 재구축 등의 핵심 프로세스를 제시
- 이러한 체계적 접근은 데이터 부족 문제를 완화하고, 모델 학습 기반 강화 및 추론 일관성 확보에 기여할 것으로 전망함

2.2 품질 기준 설정 및 지속적 평가

- 추론형 데이터의 품질은 정확성(Accuracy), 완전성(Completeness), 일관성(Consistency), 적시성(Timeliness), 관련성(Relevance)등 다차원적 특성으로 정의
- 본 가이드는 이러한 품질 차원을 구체화하고, 정량적 지표 기반 평가 체계를 제시

2.3 품질관리 방법론 및 운영 거버넌스 제시

- 본 가이드는 이론 중심의 권고를 넘어, 실무 적용성을 높이기 위한 검증된 실무 방법론(Best Practice)을 제시하고 이를 통해 기업과 기관은 윤리적·법적 리스크를 예방하고, AI 개발 및 운영의 지속가능성(Sustainability)을 확보

2.4 AI 성능 극대화와 산업 적용 촉진

- 추론형 AI 데이터 관리 가이드는 AI 모델의 정확도, 신뢰성, 효율성을 극대화하여, 개방을 통해 다양한 분야에서의 안정적 활용을 지원하며 특히 데이터 품질의 개선은 모델의 해석 가능성 및 추론 투명성을 강화하여, AI 신뢰 생태계 조성에 기여
- 이 가이드는 AI 기술의 성숙도(Maturity Level)와 산업별 특성에 따라 지속적으로 업데이트되어야 하는 동적 체계이며 이를 통해 수행기관은 AI 임무 수립(AI Task) 단계에서 데이터 품질 관리 역량을 내재화하고, AI 신뢰성 확보와 위험 최소화라는 장기적 목표 실현 가능

제2장

가이드라인 구성 및 범위

1

가이드라인 구성 개요

목차	제목	소제목
I 개요	제1장 추진 배경 및 목적	1. 추진배경 2. 목적
	제2장 가이드라인 구성 및 범위	1. 가이드라인 구성 개요 2. 가이드라인의 적용범위
	제3장 추론형 AI 데이터 이해	1. 추론형 AI 정의 2. 추론형 AI 특징 3. 주요 추론형 AI 데이터셋 동향 4. 추론형 AI 데이터 생성 및 품질관리 기술
	제4장 추론형 AI 데이터 품질관리의 이해	1. 추론형 AI 데이터 품질관리 필요성 2. 추론형 AI 데이터 품질관리 개념 및 정의 3. 추론형 AI 데이터 품질관리 목적 및 기대효과 4. 추론형 AI 데이터 품질관리 활동
	제1장 품질특성 및 고려사항	1. 추론형 AI 데이터의 특성 2. 추론형 AI 데이터 특성별 고려사항 3. 추론형 AI 데이터 품질특성
	제2장 추론형 AI 데이터 품질관리	1. 품질관리 프레임워크 구성 2. 품질관리 활동 3. 품질관리 프로세스 및 산출물 4. 가공단계 품질관리 활동
	제1장 추론형 AI 기법	1. 개요 2. 추론형 AI 기본 구조 3. 추론형 AI 강화 기법 4. 도메인/표현 확장 적용기법
	제2장 추론형 AI 주요 모델	1. 개요 2. LLM 데이터 추론모델 3. LMM 데이터 추론모델 4. 합성데이터 추론모델 5. 액션중심 데이터 추론모델 6. 추론형 AI 데이터의 주요 벤치마크 데이터셋

IV 부록	부록 1. 품질관리 지표 기준	1. 품질관리 지표
		2. 구축 공정 적정성 품질관리 지표
		3. 데이터 적합성 품질관리 지표
		4. 가공데이터 정확성 품질관리 지표
		5. 학습모델 적합성 품질관리 지표
	부록 2. 품질지표 설정 가이드	1. 의미정확성 품질지표 설정 가이드
		2. 유효성 품질지표 설정 가이드
	부록 3. 근거문헌	1. 근거문헌 세부내용

[표 I -4] 신기술 AI 품질관리 가이드라인 구성


2

가이드라인의 적용범위

- 본 가이드라인은 추론형 AI 데이터 생애주기를 기반으로 품질관리 활동을 안내

2.1 추론형 AI 데이터 생애주기

- 추론형 AI 데이터의 생애주기는 준비·계획, 구축, 학습, 운영·활용 영역으로 구분되며 인공지능 학습용 데이터 생애주기를 기준으로 진행
 - 추론형 AI 데이터 생애주기 특징
 - 데이터 유형 및 학습 절차에 따라 문제-정답(또는 기준 답)에 더해 추론 경로와 단계 단위 신호 등을 추가로 생성·구성하여 이를 지도학습, 강화학습 등 목적에 맞게 데이터를 사용하는 것이 특징
 - 활용 목적에 따라 Zero-shot CoT 등과 같은 프롬프팅/디코딩 기반으로 추론을 유도·선택하거나 추론 경로를 포함한 지도 미세조정(SFT), 검증·보상모델(PRM), 강화학습(RL)과 결합하는 등 다양한 방식을 사용
 - 데이터 유형에 따라 원천데이터에 이미 추론 경로(사고과정/풀이)가 포함된 경우 지도미세조정(SFT)을 위해 가공 단계를 거치지 않고 학습 가능 (예: 수학문제 풀이과정이 포함된 원천데이터)
- ※ 여기서 의미하는 원천데이터는 모델 학습절차에 따라 '사전 학습용 데이터', '강화 학습용 데이터' 등의 역할을 하는 데이터를 포괄하여 표현



※ 추론형 AI 데이터 생애주기는 기존 인공지능 학습용 데이터 생애주기의 과정과 동일하게 진행

[그림 1-12] 추론형 AI 데이터 생애주기

제3장

추론형 AI 데이터 이해

I

개요

1

추론형 AI 정의

1.1 추론형 AI 데이터 정의

- 추론형 AI 데이터란, 인공지능 모델이 문제 해결이나 의사결정 과정에서 명시적 또는 암묵적인 논리적 추론을 수행할 수 있도록 지원하는 구조화된 데이터로서, 입력-추론 과정-출력의 3요소를 포함하거나 이에 준하는 형태로 구성된 데이터를 말함

1.2 추론형 유형

- 추론형 AI의 유형은 추론을 수행하는 방식과 사용되는 논리적 원리에 따라 다양하게 분류

1.2.1 기반 기술에 따른 분류

구분	내용
기호적 추론 (Symbolic Reasoning)	• 인간이 읽고 이해할 수 있는 기호(Symbol)와 논리적 규칙을 사용하여 결론을 도출하는 전통적인 AI 방식으로 명확하고 엄격한 규칙 기반 분석에 사용 • 수학적 논리에 기반하며 주로 *연역적 추론을 사용 * 연역적 추론: 일반적인 원칙(전제)에서 출발하여 특정 사례에 대한 필연적인 결론을 도출 (예: "모든 새는 난다. 참새는 새다. 그러므로 참새는 난다.") • 증명, 법률AI, 전문가 시스템 등 추론과정이 투명하고 설명가능하며 정확성이 요구되는 분야에 적합
통계적 추론 (Statistical Reasoning)	• 대규모 데이터에서 패턴, 상관관계, 확률 등을 학습하고 이를 기반으로 결론이나 예측을 도출 • 주로 *귀납적 추론 및 **가추적 추론을 사용하여 불확실성을 다루는데 뛰어나며 예측, 분류 등 복잡하고 모호한 데이터 처리 분야에 활용 * 귀납적 추론: 특정 관찰(사례)에서 출발하여 일반적인 규칙을 도출 ** 가추적 추론: 최선의 설명일 가능성이 있는 가설 도출 (예:환자의 증상들을 보고 가장 가능성 높은 질병을 추론)
뉴로-심볼릭 추론 (Neuro-Symbolic Reasoning)	• 기호적 추론의 투명한 논리적 구조와 통계적 추론(신경망)의 유연한 패턴 인식 능력을 결합한 하이브리드 방식 • 논리적 일관성과 데이터 기반의 유연성을 모두 확보하여, 복잡한 문제 해결 능력과 설명 가능성을 동시에 높이는 차세대 접근 방식

[표 1-11] 기반 기술에 따른 추론형 데이터 분류

1.2.2 논리적 원리에 따른 분류

구분	내용
논리적 추론 (Logical Reasoning)	형식 논리(삼단논법 등)를 사용하여 전제가 참일 때 결론의 참을 보장 (예시: 정리 증명, 컴퓨터 프로그램 검증)
수리적 추론 (Mathematical Reasoning)	수학적 원리, 공식, 연산을 통해 문제를 해결하고 답을 도출 (예시: 복잡한 수학 문제 풀이 (CoT 기법 사용), 코딩 문제 해결)
비단조 추론 (Nonmonotonic Reasoning)	새로운 정보가 들어오면 기존의 결론이 번복될 수 있는 유연한 추론 (예시: 상식적 추론, 계획 및 스케줄링 (환경 변화에 따라 계획을 수정))
퍼지 추론 (Fuzzy Reasoning)	참/거짓 대신 '소속도'나 '정도'를 사용하여 모호하거나 불완전한 정보를 다룸 (예시: 에어컨 등의 비선형 제어 시스템. 매우 뜨겁다"와 같은 모호한 개념 처리)
상식 추론 (Common Sense Reasoning)	일상생활에서 당연하게 여겨지는 방대한 비공식적 지식에 기반하여 추론 (예시: 자연어 이해 및 대화 시스템에서 문맥 파악)

[표 1-12] 논리적 원리에 따른 분류

1.3 주요 추론 아키텍처

구분	내용
CoT (Chain-of-Thought)	- 모델이 최종 답을 내기까지 거치는 '중간 추론 과정'을 자연어 또는 구조화된 형태로 명시한 것으로 정답(output)만이 아닌 '왜 그 결론에 도달했는지'의 단계적 사고 흐름을 함께 포함 - CoT 는 단일 사고과정-단일 답변형태를 도출하는 구조
CoT-SC (Self-Consistency with Chain-of-Thought)	- 하나의 문제에 대해 여러번의 독립적인 추론과정(CoT)을 생성하고, 그 중 가장 많이 도출된 답(최빈값)을 최종 결과로 선택하는 기법 - CoT-SC는 다중 사고과정-통계적으로 일관된 최종 답변을 도출 - 일반적으로 "다양한 사고 경로 → 집단적 일관성 검증 → 최종 선택"의 세 단계를 거쳐 추론과정 진행
ToT (Tree-of-Thought)	- 문제를 해결하는 과정에서 여러 가능한 추론 경로를 탐색하고 평가하여 가장 유망한 경로를 선택하도록 하는 트리(Tree) 구조의 아키텍처 - 문제를 작은 단계로 분해한 후, 각 단계마다 여러 개의 '사고' 상태를 생성 '사고' 상태를 탐색트리로 구성하고 너비/깊이우선과 같은 탐색알고리즘을 사용하여 가장 좋은 결론에 도달함 - 창의적 사고, 계획, 전략적 의사결정이 필요한 문제에 더 나은 성능을 보임

GoT (Graph-of-Thought)	- 추론 과정을 그래프 구조로 표현하여 각 추론 단계를 노드(node)로 단계 간의 논리적 관계를 엣지(edge)로 연결 - 모델은 문제 해결 시 여러 추론 경로를 병렬적으로 확장(branching)하며 각 경로에서 도출된 중간 결과들을 상호 참조하거나 병합(fusion) - 복잡한 문제에 대한 논리적 일관성과 창의적 해결 능력을 향상시키고 단일 추론(CoT) 보다 오류 복원력과 추론다양성이 높지만 그래프 탐색의 계산 복잡도와 관리 비용이 커서 대규모 모델 적용 시 효율성 저하가 발생할 수 있음
---------------------------	---

[표 1-13] 주요 추론 아키텍처

1.3.5 추론형 AI 모델의 진화

- Transformer 기반 → CoT 확장 → Multi-step Reasoning → Tool-augmented Reasoning
- 추론형 AI 모델은 단순한 언어 예측을 넘어 점진적으로 ‘고도화된 사고 능력’을 갖추는 방향으로 진화
- 초기의 Transformer 기반 모델은 대규모 언어 패턴 학습을 통해 문맥 이해와 문장 생성 능력을 확보했으나, 명시적 사고 과정을 거치지 않아 복잡한 논리적 문제 해결에는 한계 발생
- 이를 보완하기 위해 등장한 CoT는 모델이 중간 사고 단계를 명시적으로 서술하도록 하여, 추론 과정의 투명성과 정답률을 크게 향상
- 이후 단일 사고 경로의 한계를 넘어 다단계 추론(Multi-step Reasoning)으로 발전하였으며, ToT·GoT와 같은 구조적 사고 확장 모델들이 등장하여 복합적인 논리 전개를 가능하게 함
- 최근, 이러한 추론 구조에 도구 사용 능력(Tool-augmented Reasoning)이 결합 되면서 외부 지식 검색·계산·시뮬레이션을 수행하는 지능적 추론체계로 확장되고 있음

2

추론형 AI 특징

2.1 추론형 AI 데이터의 개념 및 역할

2.1.1 추론형 AI 데이터의 개념

- 추론형 AI 데이터는 AI 모델의 논리적 사고 과정을 강화하기 위해 설계된 데이터로, 질의-추론-답변 구조를 기반으로 구성하여 중간 추론 단계를 명시적으로 포함함으로써 모델의 문제 해결 능력을 향상시키고 복잡한 TASK에서 모델의 투명성과 정확성을 높이는 데 핵심적으로 사용

2.1.2 추론형 AI 데이터의 역할

- 추론형 AI는 크게 학습 데이터와 입력 데이터라는 두 가지 맥락에서 데이터를 활용

구분	내용
학습 단계의 데이터 (훈련 데이터)	• 모델이 단순히 패턴을 인식하는 것을 넘어, 단계별 사고 과정과 논리적 관계를 학습하게 함 • 추론형 AI 데이터는 사고과정이 명시된 데이터로서 문제와 정답 뿐 만 아니라 문제 해결의 중간 단계가 명시적으로 어노테이션(Annotation) 처리된 데이터셋이 중요 • 구조화된 지식(Knowledge Base)으로 지식 그래프(Knowledge Graphs) • 온톨로지(Ontologies), 시맨틱 네트워크(Semantic Networks) 등과 같이 개념, 사실, 관계, 규칙 등이 명확하게 정의된 구조화된 데이터도 추론 능력을 강화하는 데 활용가능 • 추론형 AI 데이터는 다중 추론 체인 데이터로서, 여러 단계의 논리적 연결을 요구하는 복잡한 질의응답 쌍이나 문제 해결 사례를 포함
추론 단계의 데이터 (입력 데이터)	• 훈련된 모델이 실제로 결론을 도출하는 데 사용되는 새로운 정보로 학습된 논리 및 패턴을 새로운 실시간 데이터에 적용하여 예측, 결정 또는 통찰 생성

[표 1-14] 추론형 AI 데이터 역할

2.2 기존 학습데이터와의 차별성

분류	기존 학습데이터	추론형 AI 학습데이터
주요목표	• 패턴 인식, 분류, 예측, 지식 암기 및 재생성	• 논리적 사고, 단계별 문제 해결, 인과관계 파악
데이터 구성	• 입력-출력 쌍 (Input-Output Pairs)으로 구성된 대량의 데이터셋	• 입력-추론경로-출력쌍 (Input-Reasoning Path-Output)으로 구성된 데이터셋
핵심요소	• 정답(레이블)과 특징(Feature)의 통계적 연결	• 추론과정(Chain-of-Thought)에 대한 명시적인 주석(Annotation)
데이터 예시	• 고양이 이미지(입력) → '고양이'(출력/레이블)	• 수학 문제(입력) → 단계별 풀이 과정 → 최종 정답(출력)

[표 1-15] 기존 학습데이터와 추론형 AI 학습데이터의 차별성

※출처: <https://arxiv.org/pdf/2201.11903>

2.2.1 추론형 AI 학습데이터 학습데이터의 특징

- 인간처럼 사고하는 방식을 모방하도록 훈련하는 데 사용
- 데이터에 결과를 도출하는 중간 단계(Reasoning Path)가 명시적으로 포함되므로 이는 사고 사슬(CoT) 데이터의 형태를 띠며, 문제 해결의 논리적 흐름과 단계적 절차를 알려주는 사고과정이 명시되어 있음
- 모델은 단지 'A 다음에 B가 온다'는 사실을 학습하는 것이 아니라, 'A이기 때문에 B가 성립된다'는 인과 관계와 논리적 규칙을 학습
- 데이터셋은 종종 수리적, 과학적, 법률적 문제와 같이 복잡한 논리적 연결을 요구하는 내용으로 구성되며, 지식 그래프(Knowledge Graphs)와 같은 구조화된 지식도 추론 능력을 강화하는 데 사용
- 지식형 데이터는 "무엇(What)"을 아는지에 중점을 둔다면, 추론형 데이터는 "왜(Why)" 그리고 "어떻게(How)" 그 답에 도달하는지에 대한 절차적 지식을 AI에게 가르치는 데 핵심적인 차별성을 가짐

2.2.2 상호보완성

- 생성형 AI와 추론형 AI는 서로 다른 역할을 수행하지만 다양한 분야에서 상호보완적으로 사용됨 예를 들어 생성형 AI는 창의적인 콘텐츠를 만들고, 추론형 AI는 이를 분석하고 평가하는데 활용
- 이 두 기술은 각각 장점과 한계를 가지고 있으며 함께 사용될때 보다 정교하고 효율적인 시스템을 구축할 수 있으며, 더 큰 잠재력의 발휘 가능

2.3 추론형 AI 데이터 구조

- 추론형 AI 데이터의 기본 구조는 질의(Query, Q) - 추론(Reasoning, R) - 답변(Answer, A) 형식으로 구성되며, 모델이 복잡한 문제를 단계적으로 해결하도록 유도함

구성요소	내용
질의 (Query, Q)	• 사용자의 질문이나 문제제기를 나타내는 입력 부분으로 모델이 처리해야 할 핵심 쿼리를 포함 • 텍스트 기반의 간단한 질문부터 복잡한 다중 선택 문제, 수학 문제, 의학적 진단 등 활용하고자 하는 분야에 따라 다양한 형태를 가질 수 있음 • 문제를 명확하게 인식하고 해결할 수 있도록 구체적인 질의로 작성해야 함
추론 (Reasoning, R)	• 질의에 대한 단계적 논리과정으로, 모델이 최종 답변에 도달하기 위한 중간 생각 과정을 명시적으로 기록하여 단순한 입력-출력 매핑이 아닌 인간의 사고과정을 모방하여 논리적 연결을 학습하도록 도움 • 단계별로 세분화하여 문제 분석, 가정 검토, 계산 또는 논증, 잠재적 오류 고려 등을 수행하며 간단한 문제는 2-3단계, 복잡한 문제(예: 수학 GSM8K)는 5-10 단계 이상으로 구성
답변 (Answer, A)	• 추론 과정을 바탕으로 도출된 최종 결론으로 모델의 출력 결과를 나타냄 • 이는 추론의 요약 형태로 종종 '그러므로 정답은 X'처럼 명확하게 추출 • 추출방식은 프롬프트 기반으로 자동화되며, 평가기준으로는 정답 여부 뿐만 아니라 추론과의 일관성을 고려해야 함

[표 1-16] 추론형 AI 데이터 구조

2.4 추론 데이터 구성요소

- 추론 데이터 구성요소는 AI 모델이 신뢰할 수 있는 결론에 도달하도록 돕는 필수 특성
- 다양성은 모델이 실제 문제의 복잡성을 처리하도록 여러 관점과 예외 상황을 포함
- 일관성은 데이터 내의 사실과 규칙이 상호 모순되지 않고 논리적 통일성을 유지
- 해석 가능성은 추론 과정이 명확하여, 사람이 모델의 결론 도출 과정을 이해하고 검증할 수 있어야 함
- 논리적 정합성은 데이터 내의 추론 단계들이 엄격한 논리 법칙을 따라 오류 없이 다음 단계로 이어지는지를 보장하는 가장 기본적인 요건

구성요소	의미	주요특징	기대효과
다양성	다양한 도메인·문제 유형·난이도·언어·문화적 배경을 포함하는 폭넓은 분포	- 수학·과학·상식 도메인 포함 - 쉬운 문제부터 어려운 문제까지 균형 확보 - 편향 완화를 위한 다각적 샘플링	- 일반화 성능 향상 - 편향(bias) 감소 - 다양한 실제 상황 대응
일관성	데이터 형식·품질·추론 구조가 전체적으로 통일	- 사고과정, 추론 서술에 대한 스타일/방식 통일 - 중간 단계 서술 규칙 통일 - 데이터 구조와 모델 구조의 정합성 확보	- 안정적 학습 - 예측 가능성 증가 - 혼란·노이즈감소
해석 가능성	추론 과정이 사람이 이해·검증 가능하도록 투명하게 구성	- 단계별 reasoning 명시 - 중간 과정 설명 - 시각화·근거 제시 가능	- 신뢰성 향상 - 고위험분야(의료·법률 등) 설명 책임 확보
논리적 정합성	모든 추론단계가 논리적으로 연결되고 모순 없이 최종 답변에 도달	- 형식 논리 기반 흐름 - 단계 간 인과성 유지 - 오류없는 사고과정 체계	- 정확한 결론 도출 - 비합리적 결과 방지 - 고품질 추론 확보

[표 1-17] 추론 데이터 구성 요소

3 주요 추론형 AI 데이터셋 동향

3.1 텍스트 기반 데이터셋

- 텍스트 기반 추론형 AI 데이터셋은 LLM의 논리적 사고와 문제 해결 능력을 강화하기 위해 설계된 것으로 질문-추론-답변 구조를 통해 복잡한 태스크를 다룸
- 대표적으로 GSM8K(수학 문제), CommonsenseQA(상식 추론), GLUE(다양한 자연어 이해 작업) MATH, StrategyQA, HotpotQA 등이 있으며, 모델의 일반화와 정확성을 높이는 데 핵심
- LLM의 논리적·수학적·상식적 추론 능력을 평가하고 강화하기 위해 점차 고난도화되고 있으며, 기존 벤치마크의 포화로 인해 메타-추론이나 전문가 수준 문제(예: FrontierMath, HMMT25)를 포함한 새로운 확장 버전이 등장하는 추세
- 특히, 2024-2025년에는 데이터셋의 다각화와 OOD(Out-of-Distribution, 학습분포 외 모델이 학습한 데이터 분포 외에서 들어오는 입력), 견고성 평가가 강조되면서 기존 데이터셋의 변형(예: MR-GSM8K, GLUE-X)이 활발히 연구되고 있음

구분	내용
GSM8K(수학 문제)	• 8,500개 이상 고품질 초등학교 수준 수학 단어 문제를 포함한 데이터셋 • LLM의 기본 수학 추론 능력을 평가하는 표준 벤치마크로 자리 잡음 • 언어적 다양성을 강조하며 단계별 풀이를 통해 모델의 논리적 사고 과정을 테스트 • 메타-추론을 도입한 MR-GSM8K 변형이 등장으로 모델이 자신의 추론 과정을 검토하도록 유도하며 LLM 오류 감소와 고급수학 적용성 강화하는 방향으로 진화
CommonsenseQA	• 상식 추론을 위한 다중 선택 질문 데이터셋으로 AI가 인간 수준의 일상 지식을 바탕으로 답변을 도출하는 능력을 평가 • ConceptNet 같은 지식 그래프 기반, 모델의 암시적 추론을 테스트 • CommonsenseQA 2.0 버전을 통해 더 어려운 예시를 추가하여 다중 연구 수행 (예: RAINBOW)와 통합되어 상식 모델의 일반화 연구를 촉진하는 추세
MATH	• MATH는 12,500개 경쟁 수준의 고난도 수학 문제를 포함한 데이터셋 • AI의 고급 수학 문제 해결 능력 측정, LaTeX와 자연어 기반 단계별 풀이를 제공하고, 기본 산술부터 고등 수학까지 다루며, 모델의 추론 부족 진단에 활용 • 훈련 데이터셋(예: APTO) 확장으로 계산 단계 강화가 강조되며 벤치마크 포화 분석(2022-2024 성능 추적)이 활발
Strategy QA	• StrategyQA는 암시적 다중 홉 추론을 요구하는 'yes/no' 질문으로 구성된 QA 벤치마크 데이터셋 • 질문에 대한 추론 단계 분해와 증거 주석을 제공하여 AI의 전략적 사고 능력 평가 • Crowd sourcing을 통해 창의적이고 다양한 질문을 수집하며, open-domain QA에서 모델의 논리적 추론을 테스트하는 데 활용 • 2024년 데이터셋 내 다수 오류 지적과 CoT기법과 통합이 두드러지며, 모델의 일반화 정확도 향상을 위한 distillation 연구가 활발

[표 1-18] 텍스트 기반 데이터셋

3.2 멀티모달 추론 데이터셋

- 멀티모달 추론 데이터셋은 AI 모델이 텍스트, 이미지, 비디오 등 여러 양식의 정보를 동시에 이해하고 종합하여 복잡한 결론을 도출하도록 돕는 특수 데이터를 말함
 - VideoCoT은 비디오를 분석하여 단계적 추론을 생성하는 능력
 - VideoEspresso는 비디오 속의 미묘한 상황적 인과관계를 파악하는 능력
 - MathVista와 같은 데이터셋은 시각 정보를 수학적 논리와 결합하는 능력
- 단순한 패턴 인식을 넘어, AI가 실세계의 복잡한 정보를 통합하고 인간과 유사한 인지 능력을 갖추 수 있도록 훈련하는 데 필수적으로 AI의 추론 능력과 설명 가능성 향상에 핵심적인 역할 수행

구분	내용
VideoCoT	• 비디오 기반 전략적 사고를 위한 핵심 자료로 모델이 비디오를 이해하고 질문에 답하는 과정에서 단계별 추론 (CoT)을 명시적으로 생성하도록 유도 • 정답 도달을 위한 상세한 중간 단계 설명이 주석으로 포함되어 비디오에서 시각적 단서를 추출, 텍스트 정보와 통합하여 논리적인 사고 과정을 전개 • 단순한 행동 인식이나 장면 분류를 넘어, 사건의 인과관계, 시간적 순서에 대한 깊은 이해로 비디오 내용에 대해 ‘왜 그런 결론을 내렸는지’ 설명할 수 있는 해석 가능성을 가짐 • 192,000개의 세밀한 시공간 질문-답변 쌍과 23,000개의 고품질 CoT 어노테이션 샘플을 제공, 비디오 키프레임 처리와 시각-언어 모델을 통해 복잡한 비디오 이해 가능 • TopicQA와 TopicCoT 같은 관련 데이터셋과 함께 비디오 QA의 공백을 메우는 역할을 수행하며 비디오 인필링 및 예측 작업을 통해 모델의 오류를 줄일 수 있음
Video Espresso	• 세밀한 비디오 추론을 위한 대규모 CoT 데이터셋으로 핵심 프레임 선택을 통해 공간적 세부와 시간적 일관성을 유지하는 VideoQA쌍이 특징 • 1,219개의 수동 큐레이션 비디오를 기반으로 14개의 주요 카테고리, 171개의 하위 카테고리, 638개의 세부 카테고리를 커버하며 데이터 구축 파이프라인은 원시 비디오 수집, 중복 제거, 그리고 필터링 및 재작성 단계 포함 • 기존 비디오 QA데이터셋의 한계를 보완하여 모델의 시공간 추론을 향상시키는 데 사용되며 필터링된 샘플을 통해 고품질 비디오 이해를 촉진함으로써 AI의 세밀한 비디오 기반 전략적 사고를 발전시키는 핵심자료로 평가
MathVista	• 시각적 맥락에서 수학적 추론 능력 평가 멀티모달 벤치마크 데이터셋 • LLM과 비전-언어 모델의 성능을 테스트. 총 6,141개의 예시로 구성되며, 28개의 기존 멀티모달 데이터셋과 3개의 신규 데이터셋(IQTest*, FunctionQA**, PaperQA***)에서 유래 *IQTest(지능 테스트 스타일의 시각적 수학 문제), ** FunctionQA(함수 해석과 그래프 이해 중점), ** PaperQA(학술 논문 기반의 복잡한 수학 질문으로, 실생활 적용성을 강조) • 산술, 기하학, 통계 등 다양한 수학 영역을 다루며, 모델의 단계적 추론을 평가하고, 다중 선택, 질문 답변, 시각적 질문 답변 등의 태스크를 지원

[표 I -19] 멀티모달 추론 데이터셋

3.3 대규모 CoT(Chain-of-Thought) 데이터 구축 사례

3.3.1 OpenAI

- OpenAI는 최근 모델들이 복잡한 추론 과제를 해결하는 데 있어 “사고 과정”을 언어로 표현하도록 유도해온 연구 프레임워크의 일부로 CoT 데이터 및 CoT 기반 학습을 활용
- OpenAI는 CoT 기반 추론 데이터를 중심으로 모델 학습 및 평가 구조를 설계해 왔으며, 이는 모델이 단순히 답변을 출력하는 것에서 나아가 중간 사고 과정을 표현하고 활용하도록 유도


구분	내용
사고과정 생성	• 모델이 문제에 답하기 전에 중간 사고 과정을 자연어로 생성하게 하여 투명성과 추론 능력을 향상하는 방식 • 이러한 방식은 수학 문제, 논리적 질문, 다단계 질의응답 등에 적용되어 모델이 단순히 정답만 출력하는 것이 아니라, “어떻게 그 답에 도달했는가”를 표현하도록 설계
사고과정 활용	• OpenAI는 데이터나 추론경로 자체를 사용자에게 직접 노출시키는 대신, 내부적으로 사고 흐름을 모니터링하고 안전성·정렬(alignment) 문제 해결을 위한 수단으로 활용한다는 입장을 밝힘 • 이러한 접근은 단순한 “답변 생성”에서 나아가 “사고 생성 → 사고 검토/정렬 → 최종 결론”의 흐름을 모델 훈련 또는 평가 과정에 포함시키려는 맥락으로 평가됨

[표 1-20] OpenAI 데이터 구축의 원칙

3.3.2 Google DeepMind

- DeepMind는 LLM의 복잡한 추론능력을 강화하기 위해 사고 경로, 추론 모듈 구성, 그리고 구조적 사고 설계(self-discovering reasoning modules) 등에 관한 연구를 활발히 수행
- 최근 발표된 논문 중 하나인 ‘Large Language Models Self-Discover Reasoning Structures’에서 모델이 스스로 사고 모듈을 발견하고 조합할 수 있는 프레임워크인 SELF-DISCOVER를 소개
- 위 프레임워크에서는 모델 내부에 잠재되어 있던 비가시적(implicit) 추론 과정을 단계·노드·관계가 드러나는 구조화된 형태로 외부화·표현하는 방법으로 암묵적 사고과정을 명시적 추론 구조로 변환하는 방식을 제안함
- 영상과 텍스트를 함께 활용하는 로보틱스 비주얼 질의응답 데이터셋인 RoboVQA은 실제 로봇 및 인간양자(dual-embodiment)를 이용한 수집 프로세스를 통해 만들어졌으며, 이를 영상과 텍스트 기반 사고학습을 가능하게 하는 데이터 인프라로 활용하는 멀티모달 장기 추론을 수행

DeepMind 데이터 수집 절차



[그림 1-3] Deep Mind 데이터 수집 절차

- 장기(long-horizon) 요청이 주어지면, 작업자가 로봇을 원격 조종하여 해당 작업을 수행
- 이후 중기(media-horizon) 작업은 클라우드소싱을 통해 사후(hindsight) 라벨링되며, 각 구간(segment)에 대해 시간적 분할(temporal segmentation) 과 작업 지시(task instruction)가 부여
- 마지막으로, 라벨링된 구간들의 연속(sequence)으로부터 10가지 유형의 질문/답변(QA) 쌍을 자동 생성


※출처: <https://deepmind.google/research/publications/63605>

※출처: RoboVQA: Multimodal Long-Horizon Reasoning for Robotics

3.3.3 Meta

- Meta는 단순히 언어모델을 학습시키는 것을 넘어, 모델이 중간 사고 과정을 표현하고 활용하는 방식에 관한 연구를 활발히 진행해 왔으며 특히 “사고의 사슬(CoT)”을 넘어 메타 수준의 사고 구조를 탐색하며, 이와 관련된 데이터 생성·구축 방식에 주목
- Meta는 “Towards System 2 Reasoning in LLMs: Learning How to Think With Meta Chain-of-Thought”라는 연구에서, 전통적 CoT를 확장하여 탐색(search), 검증(verification), 반복(iteration) 과정을 포함한 메타적 추론 구조를 제시
- 모델이 내부적으로 여러 후보 사고 경로를 탐색하고, 이 중 유망한 경로를 선택하여 최종 결론을 낼 수 있도록 설계되어 있으며, 이를 위한 데이터 생성 방식을 제시

Meta 행동정제(Behavior Curation)



[그림 1-4] Meta 행동정제 예시

- Behavior Curation, 모델이 수행하거나 생성한 다양한 행동·추론·전략들 중에서 목적에 부합하고 학습 가치가 높은 행동만을 선별·구조화·관리하여 이후 추론이나 학습에 재사용 가능하게 만드는 과정
 - LLM A는 문제 해결 과정에서 ‘무엇을 어떻게 생각할지’를 스스로 점검·선택·조정하는 상위 수준의 의사결정 주체를 의미
 - 행동 기반 추론(우측): 행동(behaviors)이 LLM 추론과정에서 활용되는 다양한 방식으로 behavior-conditioned inference (행동 조건부 추론) 및 behavior-guided self-improvement(행동 기반 자기개선)에서 행동 핸드북에서 검색된 행동들이 추론시 학생모델(LLM C)에 in-context(모델의 파라미터를 업데이트하지 않고, 입력 프롬프트(컨텍스트) 안에 직접 제공되어 추론에 활용되는 방식)으로 제공
 - 행동 조건부 SFT(behavior-conditioned SFT)의 경우, 교사 모델(LLM B)이 행동 조건부 추론을 통해 학습용 (질문, 응답) 쌍을 생성하며, 이후 학생 모델이 이 데이터로 학습하고 학습이 완료된 후 실제 추론 단계에서는 학생 LLM이 행동 없이 주어진 질문만으로 응답을 생성

※출처: <https://arxiv.org/pdf/2509.13237>

※출처: Aniket Didolkar, et al. - "Metacognitive Reuse: Turning Recurring LLM Reasoning Into Concise Behaviors"

3.3.4 Deep Seek

- Deep Seek는 중국 기반 AI 기업으로 DeepSeek-R1 등을 통해 추론력 강화를 위해 문제 해결 시 중간 사고 단계를 언어화하는 사고 사슬 구조 활용
- DeepSeek 측 기술 설명에 따르면, 모델 학습용 코퍼스는 약 14.8조 토큰 규모라고 알려져 있으며, 수학·프로그래밍 등 추론 중심 데이터가 강조되어 있음
- Hugging Face에 “WSDM 2024 DeepSeek Chain-of-Thought Dataset”이라는 이름으로 CoT설명이 포함된 데이터셋이 등록되어 있으며, prompt-응답-이유(rationale) 형태로 구성
- DeepSeek의 CoT데이터 전략은 고품질 라벨링 CoT → 모델 자동 생산 CoT → 대규모 CoT 데이터의 단계적 파이프라인을 갖추며 CoT 데이터 구축은 단순히 답을 맞추는 것이 아니라 모델이 “어떻게 생각했는가”를 텍스트로 표현하게 하는 방식

3.4 오픈소스 및 공개 데이터 동향

- 최근 LLM의 추론 능력 강화가 중요해지면서, 특히 CoT 및 그 확장된 형태(예: 멀티스텝 reasoning, 멀티도메인 CoT) 데이터를 공개하고 공유하려는 움직임이 활발해짐
- “OpenThoughts-114k”는 약 114,000개의 문제에 대해 중간 사고과정(intermediate reasoning)을 포함한 데이터를 제공하고 있으며, 수학·과학·프로그래밍 등 다양한 분야를 망라
- “OpenMathReasoning”은 수학 문제 중심으로 약 3.2백만(CoT솔루션 포함)의 대형 reasoning 코퍼스를 구축한 사례이며 또한 최근에 저자원이 언어(Low-resource language, 예: 티벳어)를 위한 “TIBSTC-CoT” 같은 다언어·다도메인 CoT 데이터 구축도 이루어지고 있음

3.4.1 국내 한국어권 오픈소스 추론형 데이터셋 동향

- 한국어 AI 생태계에서는 언어모델의 이해 및 추론 능력을 평가할 수 있는 한국어 특화 벤치마크 및 데이터셋 구축이 최근 활발히 진행
- KLUE(Korean Language Understanding Evaluation)은 2021년에 국내 여러 기관(업스테이지·KAIST·NYU 등)이 협업하여 한국어 자연어이해(NLU) 8개 과제를 위한 공개 데이터셋을 구축
- 정부 차원에서도 한국지능정보사회진흥원(NIA)과 과학기술정보통신부(과기정통부)가 “국내 독자 AI 파운데이션 모델 개발을 위한 평가 데이터셋 구축” 사업 추진 등을 진행

구분	내용
국어 추론 특화 및 다단계 논리 데이터 증가	• 한국어로 된 추론형 데이터셋 구축 최근 증가하는 추세. Ko-PIQA는 한국어 물리상식 추론 데이터셋으로, 문화적 맥락을 담아 한국어권의 독특한 상황을 반영한 11,553문제(441쌍 고품질 QA) 규모로 발표됨 • Ko-MuSR이라는 한국어 장문 내 다단계 소프트 추론(Multi-step Soft Reasoning) 벤치마크 공개. 완전히 한국어 서사와 추론과정을 포함하는 데이터 구조로 설계
산업계의 데이터셋 공개 및 기능 평가 확대	• 산업계 한국어 AI 모델을 위한 평가용/추론 지원용 데이터셋등을 공개 • 플리토는 ‘오픈 Ko-LLM리더보드’에 감성평가(Ko-EQBench) 및 지시준수(Ko-Instruction Following) 등의 데이터셋을 제공하여 한국어 LLM의 지시이행능력·추론능력 평가를 강화 • 카카오에서는 한국어 기반 함수호출(Function Call) 성능 평가를 위한 ‘평선헤-벤치(FunctionChat-Bench)’ 데이터셋을 구축·공개

[표 1-21] 한국어권 오픈소스 데이터셋 구축 동향

4

추론형 AI 데이터 생성 및 품질관리 기술

- 추론형 AI 모델의 성능은 단순히 데이터의 양이 아니라 데이터의 논리적 구조와 추론 품질에 의해 결정되며 특히 추론형 데이터는 모델이 사고의 과정을 학습하는 데 필수적이지만, 그 생성 과정은 일반 언어 데이터보다 훨씬 복잡하고 정밀한 품질관리를 요구
- 추론형 AI 데이터의 경우 사람이 생성하는 ‘인적 어노테이션(human annotation)’과 모델을 활용한 ‘자동 생성(automated generation)’으로 구분되며 본 가이드에서 각 장단점과 품질관리 방안 제시
- 생성된 추론데이터의 품질확보를 위한 품질확보를 위한 품질지표·목표 설정 및 데이터 검증 방안을 제시하여 고품질 추론형 데이터 구축을 위한 기준을 제시함

※ 2025년 초거대 AI 생태계 확산 조성사업에서 구축한 CoT 데이터를 중심으로 품질관리 기술을 서술

4.1 추론형 데이터의 생성 방식

- 추론형 데이터 구축은 크게 인간 전문가 기반의 ‘휴먼 어노테이션(human annotation)’과 AI 모델을 활용한 ‘자동 생성(automated generation)’으로 구분되며 두 접근 방식은 데이터 품질, 비용, 확장성, 신뢰도 등 여러 측면에서 상호보완적인 관계를 가짐

4.1.1 인적 어노테이션 (human annotation)


구분	내용
개념	● 휴먼 어노테이션은 도메인 전문가나 숙련된 작업자가 직접 문제를 분석하고 정답까지의 사고과정을 단계적으로 기술하는 방식 ● 수학 문제나 법률·의료 추론 데이터의 경우 전문가가 “문제 이해 → 가설 설정 → 논리적 연결 → 결론 도출”의 과정을 명시적으로 작성
장점	● 휴먼 어노테이션은 문제 맥락과 근거의 적합성을 검증할 수 있어, 모델이 헛갈리기 쉬운 *spurious reasoning을 방지 방지할 수 있으므로 논리적 일관성과 사실성이 높은 편 *spurious reasoning: 결론은 우연히 맞지만 그에 이르는 추론 과정이 실제 문제의 인과-논리 구조와 무관하거나 잘못된 추론을 따르는 현상 ● 복합적 판단이 필요한 영역(법률, 과학적 추론 등)에서는 인간의 도메인 지식이 여전히 필수적이며 인간이 작성한 추론데이터는 AI 모델이 생성한 데이터의 품질 평가 및 참조 데이터셋으로 활용 가능
단점 (한계 및 비용구조)	● 비용과 시간의 부담 - Google의 Minerva (Lewkowycz et al., ‘Solving Quantitative Reasoning Problems with Language Models, arxiv 2206.14858) 프로젝트에서 수학 CoT 데이터셋 구축 시 전문가 가공작업에 상당한 비용이 발생했다고 보고 ● 일관성(Consistency) 유지의 어려움 - 가공작업자 스타일 차이로 인해 사고단계의 표현 방식이 달라질 수 있음 ● 확장성의 한계 - 모델 학습에는 수천~수백만 건의 데이터를 필요로 하므로 인간만으로 감당하기 어려움

[표 1-22] 인적 어노테이션(human annotation)

4.1.2 자동화된 생성 (AI 모델 기반 자동 생성)

구분	내용
개념	• LLM의 자기추론 능력을 활용하여 자동으로 추론데이터를 생성하는 방식 • CoT prompting - “Let’s think step by step” 등 명시적 사고 유도 프롬프트를 활용하여 모델이 추론 경로를 자연스럽게 출력하게 하는 방식 (Wei et al., CChain-of-Thought Prompting Elicits Reasoning in Large Language Models, arxiv 2201.11903) • Self-instruct 방식 - LLM이 자체적으로 문제를 생성하고, 그에 대한 추론과 답변을 동시에 생성하는 자동 데이터 생성 구조
장점	• 대규모 확장성(Scalability) - 수십만~수백만 건의 데이터를 단기간에 생성 가능 • 비용 효율성 - 인적 어노테이션 대비 1/100이하 비용으로 데이터셋 구축이 가능 • 모델이 다양한 논리 경로를 생성하여 인간이 놓칠 수 있는 추론패턴을 보완 가능
단점 (한계 및 품질문제)	• 논리적오류(Logical Fallacy), 환각, 비일관적 추론(Inconsistent Reasoning)이 잦은 발생 • Self-instruct 방식은 “모델이 스스로 만든 문제를 다시 푸는 구조”이므로, 자기확증(Self-confirming bias) 위험 존재 • 자동 생성 CoT는 후처리(Filtering, Verification)가 필수적으로 DeepSeek, VideoEspresso 등은 LLM이 생성한 CoT를 다시 다른 모델 또는 휴먼 라벨러가 검증하는 이중 filtering 구조를 채택하고 있음

[표 1-23] 자동화된 CoT 생성(LLM 기반 자동 생성)



[그림 1-5] Self-Instruct의 개요

※출처: <https://arxiv.org/pdf/2212.10560>

4.1.3 하이브리드 접근 방식 (human-in-the-loop)

구분	내용
예시 및 근거사례	- Grok과 DeepSeek CoT 데이터 구축 과정에서는 LLM이 1차 CoT를 생성한 뒤, 인간 검수자가 추론단계 정렬성과 추론 충실성 검증을 수행 - OpenAI의 Critic-Referee프레임워크는 모델이 생성한 추론을 다른 모델이 평가하고, 인간이 최종 판단하는 3단계 검증을 제안
장점 및 효과	- 자동 생성의 확장성과 인간 검증의 신뢰성을 결합하여 품질과 비용의 균형을 달성 - 사람은 CoT 전부를 생성하지 않고, 검수·수정·평가 역할에 집중하여 효율성을 제고 - 대규모 데이터 파이프라인 내에서 품질지표(Logical Consistency, Faithfulness 등) 기반의 지속적 개선이 가능함

[표 1-24] 하이브리드 접근 방식 (human-in-the-loop)

4.1.4 종합 비교 요약

구분	인적 어노테이션	LLM 자동 생성	하이브리드
품질	매우 높음 (논리적, 사실적)	품질 불균일	높음 (검수 반영)
비용/시간	높음	매우 낮음	중간
확장성	제한적	매우 높음	높음
일관성관리	어노테이션별 편차	모델출력 편차	검수로 보완 가능
대표활용예시	Minerva GSM8K(expert labeling)	Self-Instruct, DeepSeekCoT(auto)	Grok, VideoEspresso

[표 1-25] 비교 요약

- 인적 어노테이션은 여전히 고품질 CoT의 기준 역할을 수행하고 있으며, 자동화된 CoT 생성은 규모의 경제와 신속한 데이터 구축을 가능하게 하지만, 필연적으로 품질 검증 체계가 필요
- 향후 추론형 AI 데이터 구축의 핵심 방향은, LLM 자동 생성, 인간 검수, Self-consistency 기반 검증이 결합된 하이브리드 파이프라인으로 이에 대한 품질관리 필요

제4장

추론형 AI 데이터 품질관리의 이해

“추론형 AI 데이터의 품질관리”는 단순히 데이터의 정확성이나 노이즈 제거수준이 아니라, 추론 과정의 논리적 일관성, 단계별 정합성, 설명 가능성 등을 포함해 관리해야 한다는 점에서 매우 특수한 영역

1

추론형 AI 데이터 품질관리 필요성

- 추론형 AI는 입력 데이터의 미세한 오류나 불일치가 전체 추론 과정에 연쇄적으로 영향을 미쳐, 모델의 안정성과 신뢰성을 크게 저하시킬 수 있음
- 예측 모델과 같은 기존 인공지능 모델은 데이터 품질을 주로 정확도에 초점을 맞췄지만, 추론형 AI에서는 논리적 일관성, 맥락적 연계성, 오류 전파 방지가 핵심이므로 데이터 품질 관리는 모델의 성능 최적화뿐만 아니라 윤리적·법적 위험 관리 측면에서도 중요함

1.1 추론형 데이터(Reasoning Data)의 특성과 중요성

- 추론형 데이터는 AI 모델이 논리적 추론을 수행하기 위해 활용하는 데이터
- 단순한 입력-출력 쌍이 아닌 단계적 사고 과정을 포함한 구조화된 데이터로 이는 추론형 데이터셋이나 논리적 연쇄를 기록한 데이터로, 모델이 문제 해결 과정을 학습할 수 있게 함
- 데이터의 품질 저하는 AI의 전체 추론 능력을 약화시킬 수 있으므로, 관리 체계가 반드시 필요
- 기존의 LLM 데이터셋과는 달리, 단계적 사고 과정과 논리적 연계를 강조하며 이러한 특성은 AI가 인간처럼 복잡한 문제를 해결할 수 있게 하며, 모델의 신뢰성과 적응성을 높이는 데 핵심적 역할을 수행

1.2 검증 가능한 정답구조(Verifiable Answer Structure)

- 추론형 AI 데이터가 최종 답변의 정확성을 외부적으로 검증할 수 있는 형태를 갖추는 특성으로 답변이 논리적 구조를 가지며, 각 요소가 독립적으로 확인 가능하도록 설계되어야 함
- 답변을 "주장 → 증거 → 결론"으로 구조화하여 사용자가 각 부분을 검증할 수 있게 해야 함
- 검증 가능한 정답 구조를 구축하기 위해 근거기반성(evidence-grounded)을 확보해야 함
 - 근거기반성은 추론형 AI 데이터가 모든 추론과 결론을 검증가능한 외부 증거나 사실에 기반하며 AI가 임의의 추측을 피하고, 데이터나 지식 베이스를 참조하여 논리를 구축
 - 준수 요구사항을 충족하여 AI의 정확도를 향상하여 뉴스검증이나 과학 연구에서 유용하게 사용할 수 있도록 투명성을 제공

1.3 기존 데이터 품질관리 접근과의 구조적 차이

- 기존 데이터 품질 관리(Traditional Data Quality Management)는 LLM형 데이터셋 (텍스트 기반 입력-출력 쌍)이나 멀티모달형 데이터셋(이미지, 텍스트, 오디오 결합)의 정확성, 완전성, 일관성을 중시하여 규칙 기반 접근을 사용하는 반면, 추론형 AI에서의 데이터 품질 관리는 추론 데이터의 동적·논리적 특성을 고려한 AI 중심 접근으로 전환

구분	기존 데이터 품질 관리	추론형 AI 데이터 품질 관리
대상 데이터 유형	비구조화된 텍스트나 멀티모달 데이터	비구조화된 순차적 데이터
주요 품질관리 영역	정확도, 다양성, bias 감지, 중복 제거	논리적 일관성, 오류 전파 방지, 맥락 연계성
방법론	수동 규칙 정의	AI 자동화
시스템 운용	대규모 데이터셋 중심 인간 annotator 의존	동적 학습, ML 기반 자동화
목적	모델 학습 안정화, 환각 감소	모델 추론 안정화, logical instability 방지

[표 1-26] 데이터 품질관리 접근의 구조적 차이

1.4 품질 문제 발생 시 모델에 미치는 영향

- 데이터 품질 문제가 발생하면 추론형 AI 모델은 단순 오류를 넘어 체계적 실패를 초래하며 특히 논리 불안정성(logical instability)과 오류 전파(error propagation)가 주요 문제

구분	내용
논리 불안정성	- 불완전하거나 부정확한 데이터는 모델의 기본 논리 추론을 왜곡 - 예를 들어, 기본 로직에서 미세 오류가 발생하면 복잡한 문제에서 성능이 급락하며, 모델이 겉보기에는 복잡한 문제를 잘 수행하면서도, 매우 기초적인 논리 규칙이나 단순한 추론 단계에서 빈번히 실패하는 모순적 오류 현상이 나타남 - 이는 *overfitting이나 **data leakage를 유발해 모델의 일반화 능력을 저하 *모델이 학습 데이터의 패턴과 노이즈까지 지나치게 잘 맞춰 일반화 성능이 오히려 저하되는 현상 **학습 또는 추론 과정에서 모델이 실제로는 알 수 없어야 할 정보가 직접적 또는 간접적으로 유입되어 성능이 과대평가되는 현상
오류 전파	- 한 단계의 오류가 후속 추론에 연쇄적으로 적용되어 전체 출력이 왜곡되는 현상이 발생 - 예를 들어, 의료 AI에서 잘못된 데이터가 진단 오류를 초래하고 이 결과 치료 계획 전체에 영향을 미치는 경우 등이 있음 - 이 외에도 모델 성능 저하, 편향 증폭, 경제적 손실 등이 나타남

[표 1-27] 품질 문제 발생시 모델에 미치는 영향

2

추론형 AI 데이터 품질관리 개념 및 정의

- 추론형 AI 데이터 품질 관리는 기존 AI 데이터 관리에서 한 걸음 더 나아가 모델이 논리적 추론을 위한 필수적인 데이터의 논리적 일관성, 맥락적 정확성, 그리고 오류 전파 방식을 중점으로 하는 체계
- 단순한 데이터 정확도 중심이 아닌 추론 과정 전체의 신뢰성을 확보하기 위한 접근으로 AI 모델의 고도화에 따라 등장한 새로운 패러다임

2.1 “추론형 데이터 품질”의 정의

- AI 모델이 논리적 추론을 수행하기 위한 데이터가 갖추어야 할 특성으로 데이터의 정확성, 완전성, 일관성, 적합성(fitness for purpose) 등을 포함
- 추론형 AI에서 데이터가 모델의 논리적 안정성과 정확도를 직접적으로 영향을 미치기 때문에 정확도, 완전성, 일관성과 같은 일반 데이터 품질 정의를 확장한 개념으로 볼 수 있음
- 구체적으로, 추론형 데이터 품질관리는 데이터가 오류 없이 논리적 연쇄를 형성할 수 있도록 보장하며 편향(bias)이나 불완전함이 추론 과정에 미치는 영향을 최소화함
- 최근 AI 발전에 따라 데이터 품질은 모델의 성능뿐만 아니라 윤리적·법적 안정성을 좌우하는 요소로 인식되고 있으며 이는 인간 검증과 AI 자동화를 결합하여 고품질 훈련 데이터를 가속화함

2.2 품질관리 범위

- 품질관리의 범위는 기존 생성형 AI 데이터 품질관리 범위와 동일하며 구축 데이터에 대한 품질관리 방안은 추론형 AI 데이터의 특성을 고려하여 품질관리 세부 활동을 정의

※ II. 추론형 AI 품질관리 체계에 해당 내용 상세 서술

단 계	품질관리 영역	수행 내용
준비·계획 단계 /구축 단계	구축 프로세스	● 구축사업에 참여하는 사업수행기관이 자체적으로 품질관리 수행 ● 구축 중인 데이터셋에 대한 품질 개선의견이 제기된 경우, 사업수행기관이 품질개선 활동 직접 수행
	구축 데이터	
운영·활용 단계	개방데이터	● AI-Hub를 통해 개방된 데이터의 개선사항을 도출하여 고품질의 데이터를 지속적으로 유지 및 운영하기 위해 구축사업에 참여한 사업수행기관과 사업관리기관이 함께 품질관리 활동 수행 ● 사업관리기관은 사용자로부터의 데이터 품질에 대한 개선의견을 검토하고, 해당 데이터를 구축한 사업수행기관에 품질개선을 요청하며, 사업수행기관은 이를 반영하여 품질개선 수행

[표 I -28] 품질관리 영역별 수행 내용

3

추론형 AI 데이터 품질관리 목적 및 기대효과

- 추론형 AI 데이터 품질 관리는 모델의 논리적 안정성을 강화, 오류 최소화, 전체 시스템의 신뢰성 향상을 목적으로 하며 이는 AI의 실세계 적용성을 확대하여 경제적·운영적 효율성을 가져옴

3.1 모델의 추론 안정성(Logical Stability) 확보

- 품질관리는 데이터의 논리적 일관성을 통해 모델의 추론 안정성을 확보함
- 불완전한 데이터는 모델의 기본 로직을 왜곡하지만, 고품질 관리는 이를 방지하여 인간-like reasoning을 지원하고 이는 고위험 응용(예: 의료)에서 신뢰성을 제고

3.2 오류·환각(Hallucination) 감소

- 환각은 AI가 논리적으로 일관되지만 사실적으로 잘못된 출력을 생성하는 현상으로, 데이터 품질 저하가 주원인
- 품질관리는 데이터 정제와 검증으로 이를 감소시킴

3.3 일관성·재현성·정당성 강화


- 품질관리는 데이터의 일관성을 통해 모델의 재현성과 정당성을 강화
- AI 모델 간 변동성 감소와 결과가 모델의 프로토콜과 일치하도록 하여 편향 증폭을 방지

3.4 정답 중심을 넘어 “추론 과정 중심 품질관리”의 필요성

- 과적합을 유발하는 정답 중심 관리와 달리 과정 중심 관리는 추론을 통해 논리적 안정성을 강화하며 이는 AI의 의사결정 정확도를 높이고 효율성을 개선함

4 추론형 AI 데이터 품질관리 활동

- 사업수행기관(주관기관 및 참여기관)의 품질관리 담당자는 구축공정별 품질관리를 위해 아래와 같은 절차에 따라 품질검사 및 개선절차를 수행함
 - 추론형 AI 데이터 품질관리 활동은 인공지능 학습용 데이터 품질관리 활동과 동일하게 적용하며 아래의 품질검사 절차를 가짐



[그림 1-6] 생성형AI 데이터 품질검사 절차

- 품질관리 담당자는 아래의 세부 수행 내용을 참고하여 생성형AI 데이터의 품질을 확보할 수 있도록 관리

번호	품질검사 수행 절차	수행 내용
1	품질검사 준비	원시데이터, 원천데이터, 가공데이터 등의 검사대상을 선정하고 데이터 품질 수준에 대해 부합하는 상태인지를 판단하기 위한 품질검사 계획 수립
2	품질검사실시	정의된 검사대상에 대해 정확성, 논리적 일관성, 추론 완전성, 추론 경로의 명효성, 일관성, 신뢰성, 검증가능성 등 품질관리 지표에 대해 체크리스트와 같은 검사기법을 적용하여 품질검사실시
3	검사 결과 분석	품질검사 결과를 바탕으로 주요 품질문제를 식별하고 문제의 근본적 원인을 파악하여 품질문제를 해결하기 위한 개선 기회를 도출하는 단계
4	품질개선수행	품질문제 해결을 위해 개선계획 및 방안을 정의하고 우선순위를 결정하며, 결정된 우선순위에 따라 데이터 보정, 추가 작업 등 개선 영역별 품질개선 활동 수행
5	품질통제	개선 수행 결과의 확인 및 점검을 통해 품질문제 재발 방지 및 고품질 데이터를 유지하기 위한 품질관리 활동 수행 단계

[표 1-29] 품질검사 수행절차별 수행 내용

- 추론형 데이터의 경우 특히 추론형 사고과정, 사고구조를 생성하는 가공단계에서 모델 출력 또는 인간이 생성한 데이터를 기반으로 품질검사를 순환적으로 수행함
- 인식(perception), 추론(reasoning), 행동(action), 피드백을 반복하여 메타인식을 가능하게 하며 품질저하를 방지하여 데이터 품질 문제를 최소화함

AI 데이터 품질관리 가이드라인 v4.0

제4권

추론형 AI 데이터를 중심으로

신기술 AI 데이터 품질관리 가이드 v1.0

II

추론형 AI 데이터 품질관리 체계

제1장 | 품질특성 및 고려사항

제2장 | 추론형 AI 데이터 품질관리

제1장

품질특성 및 고려사항

1

추론형 AI 데이터의 특성

- 추론형 AI 데이터는 A 모델이 단순한 패턴 인식이나 생성을 넘어 논리적 추론을 수행할 수 있도록 설계된 데이터로 단계적 사고 과정과 논리적 연계를 강조
- 이러한 특성은 AI가 인간처럼 복잡한 문제를 해결할 수 있어 모델의 신뢰성과 적용성을 높이는 데 핵심적인 역할을 수행함

1.1 사고과정

- 사고과정은 추론형 AI 데이터의 핵심 특성으로, 인공지능(AI)이 문제를 해결하는 동안 중간 단계의 논리적 사고를 명시적으로 기록하고 활용하는 것을 의미
- 즉, AI가 단순히 최종 답변을 도출하는 것이 아니라 인간의 인지 과정을 모방하여 단계별로 문제를 분해하고 분석하는 구조를 포함한다는 의미
- 예를 들어, 수학 문제에서 "문제 이해 → 관련 공식 적용 → 중간 결과 계산 → 결론 도출"과 같은 순차적 단계를 데이터에 포함해 AI 모델의 추론 능력을 강화하며, 복잡한 작업에서 오류를 줄이고 성능을 향상시킴
- 사고 과정은 단계적 분해와 생성 과정으로 구분

구분	내용
단계적 분해	● 복잡한 문제를 작은 하위 문제로 나누어 처리 ● AI가 즉각적인 결론으로 도약하는 대신 논리적 연쇄를 형성함으로써 정확도를 향상
자발적 생성	● 데이터는 AI 모델이 자발적으로 사고단계를 생성할 수 있도록 훈련하여 ToT와 같은 확장 기법으로 발전 가능 ● AI 모델에게 "생각하는" 능력을 부여하나 훈련 데이터에 포함된 사고 과정이 다양하고 정확해야 효과적

[표 II-1] 추론형 데이터 사고과정의 구분

1.2 설명 가능성

- 설명가능성(Explainability)은 추론형 AI 데이터가 모델의 결정 과정을 투명하게 드러낼 수 있도록 하는 특성으로 *AI의 블랙박스 문제*를 해결하여 사용자가 AI의 출력이 어떻게 도출되었는지 이해할 수 있도록 함
* 내부 작동 과정이 불투명하여 사용자가 입력 데이터와 출력 결과만 알 수 있고, 그 사이의 결정 메커니즘이 설명되지 않는 현상
- 주로 입력-출력 쌍에 초점 맞춤 기존 데이터와 달리 추론형 데이터는 중간 추론단계와 그 이유를 명시적으로 포함하여 설명성을 강조
- 설명가능성은 크게 ‘내장된 투명성’과 ‘사용자 상호작용’ 측면으로 구분

구분	내용
내장된 투명성	• 데이터에는 추론형 매커니즘을 통해 설명성을 내장하며 AI가 각 단계별 근거를 제공 • 예를 들어 의료 진단 AI에서 “증상 분석 → 가능한 질병 나열 → 증거 기반 선택” 과정을 설명하며 이는 모델의 신뢰성을 제고
사용자 상호작용	• AI와 인간의 상호작용을 촉진하며 사용자가 AI의 사고를 검토하고 수정할 수 있도록 하여 결정 과정의 감사 가능성을 보장 • AI 편향을 식별하고 수정하는 데 도움을 주나 과도한 복잡성은 데이터 처리 비용을 증가시킴 • 설명가능한 모델은 고위험 분야(예: 금융, 의료)에서 법적 준수를 용이하게 함

[표 II-2] 설명가능성의 주요 측면

1.3 검증 가능한 정답구조

- 검증 가능한 정답구조(Verifiable Answer Structure)는 추론형 AI 데이터가 최종 답변의 정확성을 외부적으로 검증할 수 있는 형태를 갖추는 특성으로 답변이 논리적 구조를 가지며 각 요소가 독립적으로 확인가능하도록 설계
- 주로 답변을 "주장→증거→결론"으로 구조화하여 사용자가 각 부분을 검증할 수 있게 설계
- 데이터는 답변을 트리나 그래프 형태로 구성하여 각 노드가 검증 가능한 단위를 형성하는 ‘구조화된 형식’을 가져 이를 통해 인공지능(AI)이 환각을 줄이고 신뢰할 수 있는 출력을 생성
- 답변 구조는 사실 데이터베이스나 외부 소스와 연계되어 사용자가 실시간으로 확인할 수 있는 외부 검증 메커니즘이 적용 가능해야 함(예: 법률 AI에서 판례를 인용한 구조는 법적 검증 용이)
- AI 모델의 신뢰성을 높여 코드생성, 데이터 분석과 같은 산업 적용을 확대하는 한편 전체적으로 AI의 실용성을 강화하므로 이는 추론형 데이터 품질 관리의 핵심

II

1.4 근거 기반성(evidence-grounded)

- 근거 기반성은 추론형 AI 데이터가 모든 추론과 결론을 검증가능한 외부 증거나 사실에 기반하는 특성
- AI가 임의의 추측을 피하고, 데이터나 지식 베이스를 참조하여 논리를 구축(예를 들어, 주장마다 출처를 명시하여 환각 위험을 축소)
- 증거를 추론 과정에 통합하여 AI모델이 사실 기반 결론을 도출하게 하여 오류를 최소화하고 준수해야 할 요구사항을 충족하여 AI의 정확도를 향상
- 뉴스 검증이나 과학 연구에서 유용하게 사용할 수 있도록 투명성을 제공

2

추론형 AI 데이터 특성별 고려사항

2.1 추론이 가능한 데이터 구조 설계

- 추론이 가능한 데이터 구조 설계는 데이터를 논리적 추론에 적합한 형태로 구성하는 것을 의미
- 기존의 텍스트 쌍과 같은 평면적 데이터셋과 달리, 그래프나 트리 구조를 활용하여 단계적 연계 지원
- 데이터 구조는 데이터셋, 모델, 소프트웨어 간의 논리적 일치를 유지하며, 관계적(relational) 또는 기호적(symbolic) 구조를 우선함으로써 논리적 일관성을 유지해야 함
- 대규모 데이터에서 효율성을 위해 계층적 구조를 설계하며, AI가 동적 탐색을 할 수 있게 함 (예시: 시각 추론데이터에서 temporal이나 causal 그래프를 사용하면 AI의 추론 깊이가 증가)
- 특히 AI의 효율성을 제고하기 위해 추론이 가능한 데이터 구조를 설계해야 함

2.2 추론이 가능한 질문유형 설계

- 추론이 가능한 질문유형 설계는 AI가 논리적 사고를 유발하는 질문을 생성하는 데 초점을 맞춤으로써 단순 사실 질문이 아닌, 다단계 추론을 요구하는 유형(예: relational, causal)이 되도록 설계해야 함
- deductive, inductive, commonsense 등 다양한 추론 유형을 포함하며, 테이블 기반 질문처럼 데이터 중심 질문을 설계하며, 초보자용 간단 질문부터 전문가용 복잡 질문까지 복잡도 조절을 수행
- 이를 통해 AI의 일반화 능력을 강화하고 훈련 데이터의 효과성을 제고하여 적용 범위를 확대

2.3 추론 내용의 사실근거 확보

- 추론내용의 사실근거 확보는 모든 추론이 검증 가능한 한 사실에 기반하도록 하는 고려 사항으로써 이는 사실에 근거한 접근을 통해 환각을 방지
- 데이터에 외부 지식 베이스를 연계하여 증거 소스를 통합하면서 각 추론 단계에 근거를 명시하고, 사실 검증을 통해 안정성을 유지하여 AI의 신뢰성을 보장

2.4 추론과정에 대한 논리 일관성 확보

- 추론 과정에 대한 논리 일관성 확보는 AI의 사고 과정이 논리적으로 일관되도록 설계함으로써 오류 전파를 방지하는 것을 의미
- 형식 논리학(명제(propositions), 진술(statements), 또는 연역적 논증(deductive arguments)의 추상적 연구로써 논증의 내용(진실성)이 아닌 형식(구조)에 초점을 기반으로 함

II

3 추론형 AI 데이터 품질특성

- 추론형 AI 특성을 고려하여 수행해야 할 품질관리 항목의 전체적인 내용은 다음과 같음

※ 기존 인공지능 및 생성형 AI 데이터에서 정의된 동일·유사한 지표도 추론형 AI의 품질특성에 맞춰 그 내용을 재정의

특성	정의	품질관리 세부내용
정확성 (Accuracy)	추론 결과 또는 단계별 중간 산출물이 객관적·논리적으로 올바른 정도	정답 데이터의 신뢰성, 추론경로의 타당성, 지식기반 일관성, 결과 일관성
논리적 일관성 (Logical Consistency)	추론의 전제-과정-결론이 상호 모순 없이 논리적으로 연결되는 정도를 의미	- 사고과정 단계 간 연결성 유지 - 동일 맥락 내 동일 문제에 대해 상반된 결론이 없을 것
정합성 (Faithfulness/ Coherence)	추론 경로가 모델이 실제 사용하는 정보 및 근거에 충실한 정도	- 설명-결과 정합성 - 근거 문장 추론 근거 유효성
추론 완전성 (Reasoning Completeness)	추론 경로가 주어진 문제를 해결하는데 필요한 모든 논리적 단계와 근거를 충분히 포함하고 있는 정도	- 중간 단계 생략 없이 단계별 사고과정 명시 - 불충분한 추론방지
추론 경로의 명료성 (Reasoning Transparency/ Explainability)	추론 경로가 사람이 이해 가능한 형태로 명확히 표현되는 정도	- 중간 단계가 자연어 또는 수식으로 명확히 서술 - 불필요한 모호 표현 최소화
일관성 (Consistency across Instances)	동일한 입력 또는 유사한 맥락(Context)에서 반복적으로 수행될 때, 동일하거나 논리적으로 호환되는 결과를 생성하는 정도	- 프롬프트 재생성 시 결과의 안정성 - Multi-turn QA에서 맥락 유지
다양성 (Reasoning Diversity)	다양한 추론 유형과 난이도를 포함하여 일반화 가능성이 확보된 정도	- 논리·수리·상식·인과 등 복합형 추론 포함여부 확인 - 문제 유형, 도메인, 사고 패턴의 분포 다양성
신뢰성 (Reliability/ Robustness)	데이터가 재활용·재학습 시에도 일관된 성능을 보장하는 정도	- 노이즈, 오류 가공, 비논리적 추론 최소화 - 사고과정, 사고패턴의 재현 가능성 확보
검증가능성 (Verifiability)	추론 내용이 근거 데이터를 통해 검증될 수 있는 정도	- 추론 경로의 각 단계가 데이터 내 근거 문장과 대응 - 검증 절차의 반복 가능성
윤리·투명성 (Ethical Transparency)	데이터 구축·가공 과정이 편향이나 비윤리적 추론을 유발하지 않는 정도	- 편향된 추론 패턴, 인종·성별 고정관념의 배제 - 데이터 출처 및 생성 기록의 투명성 확보

[표 II-3] 추론형 AI 품질특성

3.1. 정확성 (Accuracy)

- 추론 결과 또는 단계별 중간 산출물이 객관적·논리적으로 올바른 정도
- “추론형 AI 데이터에서의 정확성”은 일반적인 분류 문제에서의 정답 비율과는 조금 다른 개념으로 추론형 AI는 단순히 “정답을 맞히는 것”보다 “논리적으로 타당한 과정을 통해 올바른 결론에 도달하는 것”을 중시
- 정확성은 “데이터가 모델이 수행해야 할 논리적 추론과 실제 정답 간의 일치 정도를 나타내는 품질 특성”으로 모델이 추론 데이터를 학습했을 때 논리적 근거를 통해 도출한 결론이 실제 정답이나 합리적 정답 범위와 얼마나 일치 하는가를 평가
- 즉 “정답의 맞고 틀림”을 넘어 “모델이 올바른 논리 과정을 통해 사실적·논리적으로 타당한 결론을 도출할 수 있도록 하는 데이터의 품질 수준”을 의미

구분	일반 AI 데이터	추론형 AI 데이터
정확성의 기준	• 정답과의 일치여부	• 논리적 과정과 결론의 일치 및 타당성
평가대상	• 출력값	• 추론사슬(CoT)과 출력값
오류유형	• 오탐/미탐 등 단순오분류	• 논리 비약, 잘못된 전제, 계산 오류, 추론 불일치 등
지표 예시	• Accuracy, Precision, Recall	• Faithfulness, Logical Consistency, Step-wise Accuracy 등

[표 II-4] 정확성에 대한 일반 AI데이터와 추론형 AI 데이터의 차이

3.1.1 정확성의 품질관리 항목

항목	설명
정답 데이터의 신뢰성	• 가공된 추론 결과가 참조 정답과 일치하는가
추론 경로의 타당성	• 단계별 논리 전개가 오류 없이 연결되는가
지식기반 일관성	• 외부 지식이나 사실 데이터와 모순되지 않는가
결과 일관성	• 같은 입력에 대해 유사한 논리경로로 동일한 결론을 도출하는가

[표 II-5] 추론형 AI 데이터에서 정확성에 대한 품질관리항목

3.1.2 추론형 AI 데이터의 정확성 관리 지표

3.1.2.1 Step-wise Accuracy (단계별 정확성)

구분	내용
개념	입력에 대해 모델(또는 가공작업자)이 제시한 사고과정의 각 단계가 기대되는 중간 정답 또는 근거와 일치하는 비율
수식	- 데이터셋 i의 단계 수 N_i 중 올바른 단계 수: k_i $Step-wise Accuracy_i = \frac{k_i}{N_i}$ - 데이터셋 평균 $Avg Step-wise Accuracy = \frac{1}{M} \sum_{i=1}^M \frac{k_i}{N_i}$
가공 가이드라인	가공 항목 : Correct (1) / Partially correct (0.5) / Incorrect (0) 권장
장단점	- 장점: 문제 발생 단계 식별 가능 → 데이터 보강 지점 명확 - 단점: 가공 비용·시간 소요가 크고 단계 분할 기준에 민감

[표 II-6] Step-wise Accuracy (단계별 정확성) 관리 지표

3.1.2.2 Reasoning Faithfulness (추론 충실도)

구분	내용
개념	생성된 추론 경로(설명)가 실제로 해당 결론을 도출하는 데 기여했는지 (모델의 내부적 원인경로와 일치하는지) 측정. 즉, 추론과정이 단순한 사후 합리화(post-hoc)인지 여부를 판별
정량화 (근사지표)	$Faithfulness\ score = \frac{\text{결론이 변한 평가데이터 수}}{\text{총 평가데이터 수}}$
가공 가이드라인	- 평가자에게 ‘이 단계가 없었다면 결론이 동일했을까?’를 Yes/No로 판단 - 다수 평가자(최소 3인)로 합의 도출
장단점	- 장점: 설명의 진정성(신뢰성) 검증에 직접 유용 - 단점: 비용·복잡도가 높아 대규모 자동화에 부담

[표 II-7] Reasoning Faithfulness (추론 충실도) 관리 지표

3.1.2.3 Final Answer Accuracy (최종 답변 정확도)

구분	내용
개념	- 모델의 최종 결론(답변) 이 정답 또는 심사자 허용범위와 일치하는 비율 - 전통적 'accuracy'에 가장 근접한 지표
수식	$\text{Final Answer Accuracy} = \frac{\text{정답으로 판정된 샘플 수}}{\text{총 샘플 수}}$
가공 가이드라인	- 객관식: 자동 비교(정확한 값/정규화된 텍스트) - 주관식: 다중 평가자 합의(majority vote) 또는 등급(Exact/Acceptable/Wrong)
장단점	- 장점: 직관적 KPI로 배포·A/B 테스트 지표로 사용 - 단점: 과정(Why/How)에 대한 정보 부족하여 우연히 정답을 맞춘 경우 등을 확인 불가
목표 예시	Final Answer Accuracy $\geq$ 0.9(도메인별로 조정)

[표 II-8] Final Answer Accuracy (최종 답변 정확도) 관리 지표

3.1.2.4 Hallucination Rate/Factual Integrity (환각율/사실 무결성)

구분	내용
개념	모델이 검증 가능한 사실 영역에서 근거 없이 잘못된 정보(환각)를 제공한 빈도. 사실성(factuality) 기반의 정확성 지표
분류	Unsupported(출처로 확인 불가), Contradicted(명백히 사실과 반대), Supported(출처와 일치)
수식	- 데이터셋 기준(데이터셋에 환각이 하나라도 있으면 환각 데이터셋으로 간주) $\text{Hallucination Rate} = \frac{\text{환각 데이터셋 수}}{\text{총 데이터셋 수}}$ - 정밀도 향상을 위해 문장 단위 집계도 가능
가공 가이드라인	- 작업자에게 검증 가능한 근거(출처 목록) 제공 요청 - Supported / Unsupported / Contradicted로 가공
장단점	- 장점: 사용자 신뢰·안전성 확보에 중요 - 단점: 전수 검증 비용 크고 자동화의 최신성 문제가 있음
목표 예시	Hallucination Rate $\leq$ 3~10% (도메인 위험도에 따라 엄격화)

[표 II-9] Hallucination Rate/Factual Integrity (환각율/사실 무결성) 관리 지표

3.2 논리적 일관성 (Logical Consistency)

- ‘추론의 전제-과정-결론이 상호 모순 없이 논리적으로 연결되는 정도’를 의미
- 추론형 AI 모델이 주어진 문제를 단계적으로 사고할 때, 각 단계에서의 논리적 전개가 앞선 근거와 충돌하지 않으며 일관된 논리 흐름을 유지하는지를 평가하는 핵심적인 품질관리 지표 영역
- 논리적 일관성이 확보되지 않으면 모델은 부분적으로 타당한 추론을 하더라도 최종 결론에서 오류를 낳거나 동일 문제에 대해 상반된 답변을 내놓는 행동을 보임
- 단순한 정답 정확도(Accuracy)와 달리 추론 과정의 내적 안정성, 사고 경로의 일관성, 결론의 논리적 타당성을 동시에 검증하는 것이 핵심
- 따라서 논리적 일관성은 추론 데이터의 내적 신뢰도와 모델의 사고 안정성을 판단하는 척도로 활용

3.2.2 품질관리의 세부 내용

구분	내용
추론 단계별 연결성 유지 (CoT)	● 추론형 AI는 문제해결을 위해 복수의 추론단계를 거치며 사고를 전개 ● 각 단계는 이전 단계의 결과를 기반으로 다음 결론을 도출해야 하며 이 과정에서 단계 간 논리의 비약이나 모순이 없어야 함 ● 예를 들어, 수학적 문제에서 ‘A > B’라는 전제에서 시작했다면 이후 단계에서 ‘B > A’라는 결론으로 전환되는 것은 논리적 비일관성으로 간주 ● 데이터 품질관리 측면에서는 각 추론형 데이터 내 문장 간 논리적 연쇄성(logical linkage)을 검증하여 추론의 선형성과 타당성을 확보해야 함
맥락과 문제에 대한 결론 일치	● 논리적 일관성은 단일 추론 흐름 내의 연결성 뿐 아니라, 동일맥락(Context) 내에서 모델이 동일 문제에 대해 일관된 결론을 내리는지 여부를 포함 ● 예를 들어 동일한 입력 질문에 대해 한번은 “참(True)”이라 답하고 다른 경우 “거짓(False)”라 답하는 경우 이는 논리적 불안정성을 나타냄 ● 데이터 구축 단계에서 동일 문제, 유사 맥락에 대한 응답 간 일관성을 점검함으로써 모델이 상황적 혼동 없이 안정적으로 추론할 수 있도록 해야 함

[표 II-10] 품질관리의 세부 내용

3.2.3 예시 지표

3.2.3.1 Logical Coherence Score (논리적 응집도 점수)

구분	내용
정의	- 추론데이터 내 인접 단계 간 논리적 연결성을 수치화한 지표 - 각 단계의 서술이 앞 단계에서 제시된 근거·가정·전제와 얼마나 논리적으로 호응하는지 평가
측정 방식	- 데이터의 각 문장을 쌍(pair)으로 구성하여 이전 단계의 진술이 다음 단계의 진술을 논리적으로 함의(entail)하는지를 자연어 추론(NLI, Natural Language Inference) 기반 검증 - 문장 간 논리적 일치, 모순, 중립 관계를 판별하고 전체 단계 대비 “논리 일치”로 분류된 비율을 계산 (공식 예시) $\text{Logical Coherence Score} = \frac{\text{Entailed Step Pairs}}{\text{Total Step Pairs}}$ $\text{논리적 응집도 점수} = \frac{\text{논리적으로 함의 관계에 있는 단계쌍의 수}}{\text{전체 단계쌍의 수}}$
의미 해석	1에 가까울수록 각 단계가 논리적으로 매끄럽게 연결됨을 의미하며, 0에 가까울수록 추론 과정 내 논리적 비약, 근거 누락, 또는 모순적 흐름이 존재함을 뜻함 - 값이 높을수록 추론의 단계 간 연결성이 우수하고 논리적 일관성이 잘 유지됨을 의미

[표 II-11] Logical Coherence Score (논리적 응집도 점수) 관리 지표

3.2.3.2 Self-consistency Ratio (자기일관성 비율)

구분	내용
정의	- 동일 입력 문제에 대해 모델이 여러 번 추론했을 때, 최종 결론이 얼마나 일관되게 유지되는지를 평가하는 지표 - 이는 추론형 AI의 “사고 경로 변동성”과 “내적 논리 안정성”을 함께 반영
측정 방식	- 동일한 입력(문제)에 대해 모델을 다중 샘플링(예: 20회) 수행하여 각각의 추론 결과를 수집하고 결과 중 가장 빈도가 높은 결론과의 일치율을 계산 (공식 예시) $\text{Self-consistency Ratio} = \frac{\text{Outputs matching the mode conclusion}}{\text{Total of sampled outputs}}$ $\text{자기 일관성 비율} = \frac{\text{최빈 결론과 일치하는 출력의 개수}}{\text{전체 샘플링된 출력의 개수}}$
의미 해석	1에 가까울수록 각 단계가 논리적으로 매끄럽게 연결됨을 의미하며, 0에 가까울수록 추론 과정 내 논리적 비약, 근거 누락, 또는 모순적 흐름이 존재함을 뜻함 - 값이 높을수록 추론의 단계 간 연결성이 우수하고 논리적 일관성이 잘 유지됨을 의미

[표 II-12] Self-consistency Ratio (자기일관성 비율) 관리 지표

3.1.3.3 Contradiction Rate (모순 발생률)

구분	내용
정의	동일 맥락 내에서 모델의 추론이 스스로 모순되는 빈도를 측정하는 지표로, 논리적 일관성을 반대로 표현한 개념
측정 방식	- 추론 단계 간 또는 동일 문제에 대한 다중 응답 간의 논리적 모순 관계를 탐지 - NLI 기반으로 “contradiction”으로 분류된 비율을 전체 문장 쌍 대비 계산 (공식 예시) $\text{Contradiction Rate} = \frac{\text{Contradictory Pairs}}{\text{Total Step Pairs}}$ $\text{모순 발생률} = \frac{\text{모순 관계로 판정된 단계쌍의 수}}{\text{전체 단계쌍의 수}}$
의미 해석	낮은 비율은 논리적으로 안정된 추론을 의미하며 높은 비율은 데이터 내 논리적 오류, 비일관된 문장 구조, 또는 전제-결론 불일치 가능성을 시사함
활용 목적	- 모순 발생률은 주로 데이터 정합성 검증 및 모델 튜닝 단계의 품질 진단 지표로 사용되며 논리적 응집도점수(Logical Coherence Score)와 상호보완적으로 해석될 수 있음 - 추론 데이터의 논리적 안정성과 내적 정합성을 평가하는 핵심 지표

[표 II-13] Contradiction Rate (모순 발생률) 관리 지표

3.1.3.4 Reasoning Path Stability Score (추론경로 안정도 점수)

구분	내용
정의	모델이 동일한 문제를 여러 번 추론할 때, 각 추론 경로간의 논리적 구조가 얼마나 일관되게 유지되는가를 평가하는 지표
측정 방식	- 동일한 입력에 대해 다중 추론을 수행하고, 각 추론 경로를 문장 임베딩 기반으로 비교하며, 단계 순서는 내용 유사도를 종합하여 경로 간 평균 유사도를 계산 (공식 예시) $\text{Reasoning Path Stability} = \text{Mean cosine similarity between sampled CoT embeddings}$ (추론경로 안정도 = 샘플링된 CoT 임베딩 간 평균 코사인 유사도)
의미 해석	높은 값은 모델이 논리적으로 일관된 사고 구조를 유지하며, 낮은 값은 모델의 추론 경로가 매번 상이하여 사고 불안정성이 있음을 의미
활용 목적	이 지표는 단순 결론의 일관성보다 추론 과정의 구조적 안정성을 중점 평가에 사용하며, 특히 복합 단계 추론이 포함된 데이터셋 검증에 효과적

[표 II-14] Reasoning Path Stability Score (추론경로 안정도 점수) 관리 지표

3.2.4 논리적 일관성 지표 예시 종합

지표명	평가대상	주요 측정방법	지표 해석	활용 목적
논리적 응집도 점수 (Logical Coherence Score)	사고과정 내 단계간 논리적 연결성	NLI 기반 entailment 비율	높을수록 논리적 연계성 우수	추론과정의 논리검증
자기 일관성 비율 (Self-consistency Ratio)	동일 입력의 결론 일관성	다중 샘플링 결과 일치율	높을수록 추론 안정성 우수	모델의 내적 신뢰성 평가
모순 발생율 (Contradiction Rate)	문장·결론간 모순 발생 빈도	NLI 기반 contradiction 비율	높을수록 논리적 신뢰성 우수	품질점검/데이터 정합성 검증
추론경로 안정도 점수 (Reasoning Path Stability Score)	추론 경로의 구조적 유사성	CoT 임베딩간 평균 유사도	높을수록 논리적 구조 우수	복합추론 데이터 품질관리

[표 II-15] 논리적 일관성 지표 예시 종합요약

3.3 정합성 (Faithfulness / Coherence)

- 정합성(Faithfulness / Coherence)은 모델이 생성한 추론(Reasoning Path)이 실제로 사용된 입력 정보, 근거 데이터, 또는 문제의 맥락에 얼마나 충실하게 기반하고 있는지를 평가
- 모델이 단순히 설득력 있는 답변을 생성하는 수준을 넘어 실제 데이터 내 근거 또는 입력 정보에 의존하여 결과를 도출했는지를 검증하는 것으로 ‘왜 그렇게 도출되었는가’에 대한 논리·근거 일관성을 검증
- 정합성이 높은 데이터는 모델의 설명이 결과와 논리적으로 일치하며 추론의 근거가 입력 정보와 객관적으로 대응되는 상태로 ‘자기 일관적이지만 틀린’ 상황을 방지하기 위한 추론형 AI 모델이 ‘그럴듯한 허위 추론’을 생성하지 않도록 관리하기 위한 데이터 품질 관리의 필수 요소

구분	내용
설명-결과 정합성 (explanation- result coherence)	• 모델의 추론과정에서 생성된 설명은 최종 결론을 논리적으로 뒷받침해야 하며, 결과와 모순되거나 독립적으로 존재 불가 • 예를 들어 수학문제에서 “A > B”라는 결론을 냈다면 그 과정에서 제시된 설명은 해당 비교를 합리적으로 지지하는 계산이나 논리 단계를 포함해야 함
근거 문장에 대한 추론 근거 활용	• 모델이 사용하는 근거 문장이 실제로 문제 해결에 필요한 정보를 제공하는지 평가 • 즉, 데이터 내 특정 문장이나 단서가 단순히 언급만 된 것이 아니라 실제 추론 경로 내에서는 논리적으로 활용되고 있는지를 검증 • 근거 문장이 추론과정과 무관하거나 결론에 기여하지 않는 경우는 비정합 상태로 간주하여 이를 통해 데이터 구축단계에서 입력 정보와 추론 경로 간의 논리적 대응 관계를 명확히 확보

[표 II-16] 정합성 항목의 세부 내용 및 특징

3.3.1 예시 지표

3.3.1.1 Faithfulness Score (정합성 점수)

구분	내용
정의	모델의 추론 경로 또는 설명이 실제 입력 정보나 근거 문장에 얼마나 충실히 기반하고 있는가를 수치화한 지표
측정 방식	- 입력 문장(또는 근거 문장)과 모델의 사고과정 설명 간 내용적 대응 정도를 의미론적 유사도 또는 *이론/문제 정의 기반으로 측정 *textual entailment, 하나의 텍스트(전제, premise)가 주어졌을 때, 그 텍스트의 의미로부터 다른 텍스트(가설, hypothesis)가 논리적으로 참이라고 판단될 수 있는 관계 - 이론/문제 정의는 주로 자연어 추론 기반의 'Entailment(함의)' 검증을 사용하며, 설명 내 문장이 입력 근거로부터 논리적으로 도출될 수 있는 경우 'Faithful'로 판단 - 입력에서 직접적으로 지원되지 않는 내용이 추론 과정에 포함될 경우 점수가 낮게 산정 $\text{Faithfulness Score} = \frac{\text{입력 근거와 논리적으로 일치하는 문장 수}}{\text{전체 설명 문장 수}}$
의미 해석	높은 점수는 추론 과정이 입력 근거에 충실함을 의미하며, 낮은 점수는 입력에 존재하지 않는 정보나 왜곡된 근거를 바탕으로 추론하고 있을 가능성을 나타냄

[표 II-17] Faithfulness Score (정합성 점수) 관리 지표

3.3.1.2 Explanation-Answer Alignment (설명-결과 정합도)

구분	내용
정의	모델이 제시한 설명과 최종 결과가 논리적으로 얼마나 일치하는지를 평가하는 지표
측정 방식	- 설명 문장과 결과 문장을 비교하여 전제가 결론을 논리적으로 지지(entail)하는 정도를 계산 - NLI 모델 또는 인과적 관계 탐지 기반의 정합성 평가 모델 활용 가능 $\text{Explanation-Answer Alignment} = \frac{\text{결론을 직접 지지하는 설명 단계 수}}{\text{전체 설명 단계 수}}$
의미 해석	- 설명이 결과와 논리적으로 연결되어 있으면 정합도가 높게 나타나고, 반대로 설명의 내용이 결과와 모순되거나 불필요한 정보로 구성될 경우 정합도가 낮아짐 - 즉 높은 정합도는 모델의 추론 경로가 결론과 논리적으로 잘 맞물려 있음을 의미하고 낮은 정합도는 결과가 설명과 분리되어 있거나 설명이 결론을 지지하지 못하는 경우를 나타냄
활용	정합성(Faithfulness/Coherence)은 '모델이 실제 사용한 근거에 충실하게 추론했는가'를 평가하는 품질 항목으로, 결과의 타당성분 아니라 추론 과정의 근거 충실성(evidence-grounded reasoning)을 확보하는 데 목적이 있음

[표 II-18] Explanation-Answer Alignment (설명-결과 정합도) 관리 지표

3.3.1.3 Evidence Grounding Rate (근거 기반 비율)

구분	내용
정의	- 모델의 추론단계 중 명시적으로 입력 데이터 내 근거 문장에 연결될 수 있는 단계의 비율 - 각 추론 스텝이 외부 지식이나 임의의 추측이 아니라 실제 데이터 내 특정 근거 문장으로부터의 도출 여부를 평가
측정 방식	정보검색(Retrieval) 또는 문장 매핑 기법을 활용하여 각 추론 단계가 참조하는 근거 문장을 식별한 뒤, 유효한 근거를 가진 단계의 비율로 계산 $\text{Evidence Grounding Rate} = \frac{\text{유효한 근거가 확인된 추론 단계 수}}{\text{전체 추론 단계 수}}$
의미 해석	값이 높을수록 모델이 실제 데이터 근거에 충실하게 추론했음을 의미하며 낮은 경우 환각 발생 가능성이 높아 데이터의 신뢰성을 저하시킴

[표 II-19] Evidence Grounding Rate (근거 기반 비율) 관리 지표

3.3.1.4 Attribution Consistency (근거 귀속 일관성)

구분	내용
정의	동일한 입력 또는 문제에 대해 여러 번 추론을 수행했을 때, 모델이 같은 근거 요소를 일관되게 인용하는가를 측정하는 지표
측정 방식	다중 시도된 추론에서 언급된 근거 문장들의 일치도를 계산하며, 보통 코사인 유사도 또는 교집합 비율로 표현 $\text{Attribution Consistency} = \frac{\text{반복 추론 간 동일 근거 인용 비율}}{\text{전체 인용 근거 수}}$
의미 해석	높은 값은 모델이 일관된 판단 기준과 근거를 활용하고 있음을 의미하며, 낮은 값은 추론이 상황마다 달라지는 불안정한 패턴을 나타내어 정합성 품질이 낮음을 시사

[표 II-20] Attribution Consistency (근거 귀속 일관성) 관리 지표

3.3.2 정합성 지표 예시 종합

지표명	핵심 평가내용	대표 측정식	주요 의미
정합성 점수	설명이 입력근거에 충실한 정도	근거기반 설명문장 수/ 전체 설명문장 수	모델의 추론이 사실기반인가?
설명결과 정합도	설명과 결과의 논리적 일치도	결론지지 설명 단계 수/ 전체설명 단계 수	설명이 결론을 타당하게 뒷받침하는가?
근거기반 비율	실제 데이터 근거와 연결된 추론단계 비율	유효근거 단계 수/ 전체 단계 수	환각 방지 및 데이터 신뢰성 검증
근거귀속 일관성	반복 추론간 근거 일관성	동일근거 인용비율 수	추론과정의 안정성과 신뢰성

[표 II-21] 정합성 지표 예시 종합요약

3.4 추론 완전성 (Reasoning Completeness)

- 문제 해결에 필요한 모든 논리 단계를 포함하고 있는 정도로 모델의 추론 경로가 주어진 문제를 해결하는 데 필요한 모든 논리적 단계와 근거를 충분히 포함하고 있는 정도를 의미
- 최종 결론에 도달하기 위한 사고 과정이 중간 단계의 생략 없이 충분하게 전개하는지, 논리 전개 흐름이 누락 없이 완결적인지를 평가
- 추론형 AI 데이터의 ‘사고 과정적 충실도(process-level fidelity)’를 측정하는 기준으로 논리적 일관성이 ‘모순 없이 이어지는가’를 본다면, 추론 완전성은 ‘완전하게 모두 포함되었는가’를 평가
- 추론 완전성은 단순히 답의 정확성을 평가하는 것을 넘어 모델이 문제를 해결하는 과정에서 얼마나 체계적이고 포괄적인 사고를 수행했는지를 판단하기 위한 품질 기준으로 활용

구분	내용
중간단계 생략 없이 단계별 사고과정 명시	● 추론형 데이터의 품질은 최종결과 뿐만 아니라 ‘그 결과에 도달하기 까지의 사고과정이 얼마나 명시적으로 표현되었는가’에 의해 크게 좌우 ● 완전한 추론 데이터는 문제의 전제에서 결론에 이르는 모든 중간 단계를 순차적·연속적으로 서술해야 하며 단계간 연결이 자연스럽게 이어져야 함 ● 단순한 ‘정답 생성’이 아닌, ‘사고과정의 구조적 기록’임을 전제로 함
불충분한 추론 방지	● 모델이 결론에 도달하는 가정에서 핵심 논리 단계를 생략하거나 불충분하기 서술하는 경우 추론의 신뢰성과 검증 가능성이 저하 ● 특히 복합문제나 다단계 수리·논리적 문제에서 빈번히 발생하며 모델의 ‘겉보기 일관성’은 유지되더라도 실제 사고 과정의 내재적 결함을 유발

[표 II-22] 추론 완전성 세부내용 및 특징

3.4.1 예시 지표

3.4.1.1 Step Coverage Ratio (단계 포괄 비율)

구분	내용
정의	문제 해결에 필요한 전체 추론단계 중 데이터에 실제로 명시된 단계의 비율을 측정하는 지표
측정 방식	정보검색(Retrieval) 또는 문장 매핑 기법을 활용하여 각 추론 단계가 참조하는 근거 문장을 식별한 뒤, 유효한 근거를 가진 단계의 비율로 계산 $\text{Step Coverage Ratio} = \frac{\text{데이터에 명시된 추론 단계 수}}{\text{문제 해결에 필요한 전체 추론 단계 수}}$
의미 해석	- 높은 값은 추론 과정이 누락 없이 완전하게 기술되었음을 의미하며 낮은 값은 핵심 단계의 생략, 논리적 점프, 혹은 설명 불충분 등의 문제가 있음을 시사 - 특히 수학, 과학, 법리 추론 등 복합적 사고 구조를 요구하는 문제 유형에서 데이터의 논리적 충실도를 검증할 때 유용
활용 예시	모델이 “A → B → C → D”로 추론하는 문제에서 “A → D”만 언급했다면, Step Coverage Ratio는 0.5 이하로 낮게 측정되어 under-reasoning 문제로 분류됨

[표 II-23] Step Coverage Ratio 단계 포괄 비율 관리 지표

3.4.1.2 Reasoning Depth Index (추론 깊이 지수)

구분	내용
정의	- 모델이 추론 과정에서 얼마나 다층적이고 세분화된 사고 구조를 형성했는가를 측정하는 지표 - 단순한 직선형 추론이 아닌 논리 트리(Logical Tree) 형태의 계층적 사고의 구현 정도
측정 방식	Reasoning Depth Index = 평균 추론 트리 깊이 (Average Reasoning Tree Depth)
의미 해석	- 값이 높을수록 세밀하고 단계적인 사고 과정이 잘 전개되었음을 의미 - 낮은 값은 단순 연결이나 피상적 추론 경향을 나타내며, 이는 복합 문제에 대한 사고 과정이 충분히 표현되지 않았음을 시사
활용 예시	- 문제 해결 시 근거 설명이 “결론 → 단일 원인” 수준에서 멈추면 얕은 추론으로 간주 “결론 → 원인1 → 근거A → 사실X”로 이어질 경우 더 깊은 reasoning depth를 가짐

[표 II-24] Reasoning Depth Index (추론 깊이 지수) 관리 지표

3.4.1.3 Inference Sufficiency Score (추론 충족도 점수)

구분	내용
정의	- 모델이 도출한 추론 경로가 최종 결론을 정당화하기에 충분한 근거와 단계를 포함하고 있는가를 평가하는 지표 - 추론의 각 단계가 결론 도출에 필요한 논리적 근거를 충분히 제공했는지를 정량화
측정 방식	$\text{Inference Sufficiency Score} = \frac{\text{결론을 정당화하는 필수 단계 수}}{\text{전체 추론 단계 수}}$
의미 해석	- 높은 점수는 모든 주요 전제와 중간 근거가 명확히 기술되어 있음을 의미하며, 낮은 점수는 불충분한 단계나 비약적 결론을 나타냄 - 설명형 QA 데이터나 CoT 학습 데이터 검증 시, 각 단계가 최종 결론을 직접 지지하는지 점검하는 데 활용됨
활용 예시	예를 들어 “문제 원인 → 증거 제시 → 결론 도출”의 3단 구조 중 “증거 제시” 단계가 누락된 경우 Inference Sufficiency Score는 0.67로 감소

[표 II-25] Inference Sufficiency Score (추론 충족도 점수) 관리 지표

3.4.1.4 Missing Step Rate (추론 누락 비율)

구분	내용
정의	- Missing Step Rate은 문제 해결을 위해 필요한 논리 단계 중 데이터 내에서 누락된 단계의 비율을 평가하는 보완 지표이며 Step Coverage Ratio의 역개념 - 추론의 불완전성(under-reasoning)을 직접적으로 탐지하는 데 사용
측정 방식	$\text{Missing Step Rate} = \frac{\text{누락된 추론 단계 수}}{\text{전체 필요 추론 단계 수}}$
의미 해석	- 값이 높을수록 추론 과정이 단순화되거나 중간단계가 생략된 것으로 판단 - Step Coverage Ratio와 병행 사용하여 “추론 누락 위험도”를 정량적으로 모니터링
활용 예시	필요한 단계가 6개인데 그 중 2개가 생략되었다면, Missing Step Rate = $2 / 6 = 0.33$으로, 불완전한 reasoning으로 평가됨

[표 II-26] Missing Step Rate (추론 누락 비율) 관리 지표

3.4.2 추론완전성 지표 예시 종합

지표명	핵심 평가내용	대표 측정식	주요 의미
Step Coverage Ratio (단계 포괄 비율)	필요한 추론 단계가 얼마나 포괄적으로 표현 되었는가	명시된 단계 수/ 필요 단계 수	추론 누락 여부 평가
Reasoning Depth Index (추론 깊이 지수)	추론구조의 계층적 깊이	평균추론 트리 깊이	사고과정의 세분화 수준 평가
Inference Sufficiency Score (추론 충족도 점수)	결론을 정당화하기 위한 충분한 단계 포함	필수 단계 수/ 전체 단계 수	논리적 정당성의 완전성 평가
Missing Step Rate (추론 누락 비율)	누락된 추론 단계비율	동일근거 인용비율 수	under-reasoning 탐지

[표 II-27] 추론완전성 지표 예시 종합요약

3.5 추론 경로의 명료성 (Reasoning Transparency / Explainability)

- 추론 경로가 사람이 이해가능한 형태로 명확히 표현되는 정도로 모델이 생성한 추론 과정이 사람이 이해가능한 형태로 명확하게 표현되는 정도를 의미
- 단순히 올바른 답을 도출했는지에 그치지 않고 중간 사고 과정과 근거가 독자 또는 검증자가 쉽게 이해할 수 있도록 표현되었는가를 평가하는 품질 기준
- 명료성이 높은 추론 데이터는 모델의 사고 구조를 투명하게 분석, 검증, 재사용할 수 있으며 모델의 신뢰성과 책임성을 확보하는 핵심 요소로 작용

3.5.1 예시 지표

3.5.1.1 Explanation Clarity Score (설명 명료도 점수)

구분	내용
정의	추론 과정의 각 단계가 얼마나 명확하고 이해 가능한 형태로 서술되었는가를 평가하는 지표
측정 방식	- 각 단계가 독립적으로 이해 가능한지, 불필요한 모호성이 있는지를 평가 - 단계별 명료도를 0~1 범위로 평가한 후 평균하여 전체 점수 산출 $\text{Explanation Clarity Score} = \frac{\text{명료한 단계 수}}{\text{전체 단계 수}}$
의미 해석	높은 점수는 추론 과정이 직관적이고 단계별 논리 흐름이 분명함을 의미하고, 낮은 점수는 모호하거나 불분명한 단계가 포함되어 검증·재현이 어려움을 의미

[표 II-28] Explanation Clarity Score (설명 명료도 점수) 관리 지표

3.5.1.2 Readability Index (가독성 지수)

구분	내용
정의	추론 과정이 읽기 쉽고 이해하기 쉬운 문장 구조로 작성되었는가를 평가하는 지표
측정 방식	- Flesch Reading Ease, Gunning Fog, SMOG 등 기존 텍스트 가독성 지표를 활용 - 문장 길이, 전문 용어 비율, 복합문 사용 등을 기반으로 계산
의미 해석	높은 점수는 문장이 간결하고 명료하여 독자가 쉽게 이해 가능함을 의미하고 낮은 점수는 문장이 복잡하거나 길어 이해에 어려움을 의미

[표 II-29] Readability Index (가독성 지수) 관리 지표

3.5.1.3 Step Interpretability (단계 해석 용이성)

구분	내용
정의	각 추론 단계가 외부 검증자나 사용자에게 얼마나 직관적으로 이해되는가를 정량화한 지표
측정 방식	단계별로 “직관적 이해 가능/불가능” 여부를 평가하여 비율 계산 $\text{Step Interpretability} = \frac{\text{직관적으로 이해 가능한 단계 수}}{\text{전체 단계 수}}$
의미 해석	높은 값은 각 단계가 논리적으로 명확히 설명되어 사용자가 쉽게 검증·이해 가능함을 의미하고 낮은 값은 단계가 난해하거나 추론 논리와 연결되지 않아 이해가 어려움을 의미
활용 예시	수학 문제에서 각 연산, 논리 단계를 단계별로 명시하면 Step Interpretability가 높음

[표 II-30] Step Interpretability (단계 해석 용이성) 관리 지표

3.5.1.4 Explanation Conciseness (설명 간결성)

구분	내용
정의	• 추론 과정에서 불필요하게 장황하거나 반복적인 문장 없이 핵심만 표현되었는가를 평가하는 지표
측정 방식	총 문장 수 대비 핵심 단계·근거 문장 비율로 계산 $\text{Explanation Conciseness} = \frac{\text{핵심 단계 문장 수}}{\text{전체 단계 수}}$
의미 해석	• 높은 값은 추론 설명이 간결하며 핵심만 포함, 이해 용이성 증가함을 의미하며 낮은 값은 불필요한 반복, 장황한 설명 포함, 독자의 이해 부담 증가함을 의미
활용 예시	• CoT 설명에서 불필요한 배경 서술을 제거하면 Conciseness 점수가 상승

[표 II-31] Explanation Conciseness (설명 간결성) 관리 지표

3.5.2 추론 경로의 명료성 지표 예시 종합

- 추론 경로의 명료성은 모델이 생성한 사고 과정이 인간이 이해할 수 있도록 투명하고 체계적으로 표현되었는가를 평가하는 품질관리 항목으로 단순한 정답 도출을 넘어 설명 가능성, 재현 가능성, 검증 용이성을 확보하며 AI 신뢰성 강화와 직결되는 핵심 지표로 활용

지표명	핵심 평가내용	대표 측정식	주요 의미
Explanation Clarity Score (설명 명료도 점수)	단계별 설명 명료성	명료한 단계수/ 전체단계수	추론단계가 직관적 이해 가능한 정도
Readability Index (가독성 지수)	문장구조 및 이해 용이성	Flesch, Gunning Fog 등	설명 텍스트의 읽기 편의성
Step Interpretability (단계 해석 용이성)	각 단계의 직관적 이해 가능성	직관적 단계수/ 전체단계 수	단계별 논리이해의 용이성 평가
Explanation Conciseness (설명 간결성)	불필요한 반복/ 장황성 최소화	핵심단계 문장 수/ 전체 문장 수	간결하고 핵심적인 추론 설명 평가

[표 II-32] 추론 경로의 명료성 지표 예시 종합요약

3.6 일관성 (Consistency across Instances)

- 동일한 입력 혹은 유사한 맥락에서 일관된 추론 결과를 생성하는 정도
- 일관성은 추론형 AI 모델이 동일한 입력 또는 유사한 맥락(Context)에서 반복적으로 수행될 때, 동일하거나 논리적으로 호환되는 결과를 생성하는 정도를 의미
- 단순히 한 번의 정답 정확도(accuracy)만을 평가하는 것이 아니라, 모델의 출력 안정성과 맥락 이해 능력을 포함한 내적 신뢰도를 검증하는 핵심 품질 항목
- 모델이 동일 질문을 여러 번 받거나 약간 변형된 유사 질문을 받더라도 결과가 일관되게 유지된다면, 해당 모델은 논리적 일관성과 맥락 유지 능력이 높다고 평가
- 반대로 결과가 입력과 맥락이 유사함에도 불구하고 변동이 크거나 상반되는 결론을 도출한다면 이는 모델의 사고 경로 불안정성과 추론 신뢰도 저하를 나타냄
- 일관성은 단순 정답 정확도를 넘어, 반복적·맥락적 환경에서 모델의 추론 안정성, 논리적 일관성, 맥락 유지 능력을 종합적으로 평가하는 추론형 AI 데이터 품질관리의 핵심 항목으로 이 지표는 모델 신뢰성, 재현 가능성, 사용자 경험, 다중 턴 상호작용 품질과 직결되므로 품질관리에서 반드시 점검해야 함

구분	내용
프롬프트 재생성시 결과의 안정성	- 동일한 질문, 입력 프롬프트를 여러 번 모델에 제공했을 때 모델의 답변이 일관되게 유지되는 정도를 평가 - 모델의 샘플링 설정에 따라 답변이 달라질 수 있으므로 반복 추론 반복성을 통해 자기일관성을 추적 - 안정적인 출력은 모델이 특정 입력에 대해 명확한 추론 경로를 갖고 있음을 의미하며 불안정한 출력은 내부 출력이 확정적이지 않거나 노이즈가 존재함을 시사
질의응답의 맥락유지	- 추론형 데이터를 멀티턴 질문응답 환경으로 구축할 경우 모델이 이전 대화의 내용을 정확히 기억하고 반영하여 후속 답변이 초기 맥락과 모순되지 않도록 유지하는 것을 의미 - 예를 들어, “A 사건의 원인은 무엇인가?”라는 질문 이후 “그렇다면 결과는?”이라는 후속 질문에 대해 모델이 이전 답변과 일치하는 논리적 결론을 제시해야 함 - 맥락 유지 실패는 맥락적 불일관성으로 이어져 대화형 모델의 신뢰성과 사용자 경험을 저해

[표 II-33] 일관성 세부 내용 및 특징

3.6.1 예시 지표

3.6.1.1 Self-consistency Accuracy (자기일관성 정확도)

구분	내용
정의	동일한 입력 문제에 대해 모델이 여러 번 추론했을 때 가장 빈번히 나타난 결론과의 일치율을 나타내는 지표로 모델이 입력에 대해 일관된 결론을 내리는가를 평가
측정 방식	$\text{Self-consistency Accuracy} = \frac{\text{mode output과 일치하는 샘플 수}}{\text{전체 샘플 수}}$
의미 해석	높은 값은 모델이 반복 추론에서도 안정적으로 동일 결론을 도출함을 의미하며, 낮은 값은 모델의 추론 불안정성과 변동성을 의미
활용 예시	동일 문제에 대해 N번(예: 20회) 샘플링한 뒤, 최빈 결론을 계산하고, 각 답변이 이 결론과 일치하는 비율을 산출

[표 II-34] 일관성 세부 내용 및 특징 관리 지표

3.6.1.2 Contextual Stability (맥락적 안정성)

구분	내용
정의	- 유사한 맥락 또는 멀티턴 질의응답 상황에서 모델이 이전 맥락 및 정보와 일관된 추론 결과를 유지하는 정도 - 특히 대화형·연속형 상황에서 맥락 인식 및 유지능력 평가에 중요하며 일관성 측정에서 “입력 변형 시에도 안정된 응답”을 보는 지표
측정 방식	- 멀티턴 QA 또는 유사 입력 시 답변이 이전 맥락과 논리적으로 얼마나 일관되는가 측정 - 동일 또는 유사 입력을 기반으로 생성된 답변 쌍 간 논리적 모순 여부(NLI 기반) 또는 텍스트 의미 유사도(semantic similarity)를 계산
의미 해석	높은 Contextual Stability는 모델이 대화나 연속적 추론 상황에서 맥락을 정확히 이해하고 유지함을 의미하며, 낮은 값은 문맥 반영 실패로 인한 상반된 결론 발생 가능성을 시사

[표 II-35] Contextual Stability (맥락적 안정성) 관리 지표

3.6.1.3 Answer Consensus Rate (응답 일치율)

구분	내용
정의	- 동일 또는 유사한 입력 문제 집합(예: 동의어 질문, 재구성된 질문)에서 모델이 일관되게 동일한 답변을 산출하는 비율 - 즉, 입력이 변경되어도 의미상 동일한 문제일 경우 모델이 동일 답을 내는 정도를 측정
측정 방식	의미상 동등한 M개의 입력을 모델에 제시하여 각 출력이 얼마나 같은지(모드 output) 계산 $\text{Answer Consensus Rate} = \frac{\text{모드(output)과 일치한 출력 수}}{M}$
의미 해석	높은 값은 모델이 입력 재구성에 대해서도 안정적인 대응을 한다는 것을 의미하며 낮은 값은 입력 표현 변화에 취약하거나 이해가 일관되지 않다는 신호
활용 예시	동일 의미의 질문을 여러 버전(gen paraphrases)으로 만들고 모델의 응답 일치 비율을 측정하여 이 지표를 활용

[표 II-36] Answer Consensus Rate (응답 일치율) 관리 지표

3.6.1.4 Inference Path Agreement Rate (추론 경로 일치율)

구분	내용
정의	동일 입력 또는 유사 입력에 대해 모델이 여러 번 추론 경로를 생성했을 때 결론뿐 아니라 중간 추론 경로 수준에서 얼마나 유사한 경로/단계를 따르는가를 평가하는 지표
측정 방식	여러 샘플링된 추론 경로에서 각 경로의 단계 시퀀스를 비교 (예: 임베딩 유사도, 단계 매핑) 하고, 동일하거나 유사한 경로를 따른 출력의 비율로 산출 $\text{Inference Path Agreement Rate} = \frac{\text{경로 간 유사 또는 동일한 추론 단계를 따른 출력 수}}{\text{샘플링된 출력 수}}$
의미 해석	- 값이 높을수록 모델이 동일 입력에 대해 추론 과정(사고 경로)을 일관되게 유지 - 값이 낮으면 결론은 같더라도 서로 다른 사고 구조를 사용하거나 불안정한 추론을 수행하고 있을 가능성이 높음
활용 예시	동일 입력에 대해 N개의 사고과정을 생성한 뒤, 각 사고과정의 단계 또는 문장 시퀀스를 임베딩하여 유사도를 계산하거나, 단계별 태깅(mapping)을 통해 얼마나 동일한 경로를 따랐는지 정량화할 수 있음

[표 II-37] Inference Path Agreement Rate (추론 경로 일치율) 관리 지표

3.6.2 일관성 지표 예시 종합

지표명	핵심 평가내용	대표 측정식	주요 의미
Self-consistency Accuracy (자기일관성 정확도)	동일 입력 반복 시 결론 일치 비율	결론과 일치한 출력수/모든 출력수	- 높은 값: 동일 입력에 대해 안정적으로 동일한 결론 도출 - 낮은 값: 추론 경로 변동성/논리 불안정성
Contextual Stability (맥락적 안정성)	유사 맥락/ 다중 턴에서 맥락 일관성유지 정도	의미 유사도 또는 NLI 기반 모순 판정 후 일치율 계산	- 높은 값: 대화형 또는 연속 문제에서 맥락 유지 우수, - 낮은 값: 맥락 혼동 발생
Answer Consensus Rate (응답 일치율+)	의미상 동일 입력군에 대한 응답 일관성	동일답변 출력 수 / 전체 입력 수	- 높은 값: 입력 표현 변화에도 일관된 답변 - 낮은 값: 표현 민감, 이해 불안정
Inference Path Agreement Rate (추론 경로 일치율)	동일 입력에 대한 추론 경로 수준의 일관성	동일 유사경로출력 수/ 샘플링 데이터 수	- 높은 값: 추론 경로까지 일관적 - 낮은 값: 결론은 같더라도 사고 구조 불안정

[표 II-38] 일관성 지표 예시 종합 요약

3.7. 다양성 (Reasoning Diversity)

- 추론 유형과 난이도를 포함하여 일반화 가능성이 확보된 정도
- 모델이 학습하거나 사용되는 추론형 AI 데이터가 다양한 추론 유형과 난이도를 포함하여 모델이 특정 유형에 편중되지 않고 넓은 범위의 문제·사고 패턴임을 의미
- 즉, 단일 유형의 논리 문제만 반복하지 않고 수리·상식·인과·추론·비유·그 외 복합적 사고 유형을 골고루 커버할 때 해당 데이터의 추론 다양성이 높다고 평가함

구분	내용
논리·수리·상식· 인과 등 복합형 추론	- 데이터셋이 단순히 한 종류의 사고(예: 단일 수리문제, 단일 논리유형)만 포함하는 대신 여러 유형의 추론을 포함 - 논리적 추론, 수리계산, 상식유추, 인과관계 해석, 비유적 사고 등이 모두 포함되면 다양성이 확보
문제 유형, 도메인, 사고 패턴의 분포 다양성	- 문제 유형, 도메인, 사고 패턴의 분포가 고르게 분포되어야 함 - 예를 들어, 수학문제만 90% 이고 상식유추·인과질문이 10% 인 경우는 다양성이 낮다고 판단함 - 또한 동일 도메인 내에서도 사고 패턴이 반복되지 않고 새롭고 다양한 패턴이 포함되어야 일반화 가능성이 상승

[표 II-39] 다양성 세부 내용 및 특징

3.7.1 예시 지표

3.7.1.1 Reasoning Type Coverage (추론 유형 포괄성)

구분	내용
정의	데이터셋이 포함하고 있는 각기 다른 추론 유형의 수 또는 비율을 측정하는 지표
측정 방식	$\text{Reasoning Type Coverage} = \frac{\text{포함된 추론유형 수}}{\text{전체 계획된 유형 수}}$
의미 해석	값이 높으면 다양한 사고 유형을 폭넓게 반영한다는 의미이며, 낮으면 특정 유형에 편중되었다는 것을 의미

[표 II-40] Reasoning Type Coverage (추론 유형 포괄성) 관리 지표

3.7.1.2 Complexity Distribution (복잡도 분포)

구분	내용
정의	- 데이터셋 내 문제 난이도의 분포가 어느 정도 ‘안만하게 골고루 분포되어 있는가’를 측정하는 지표 - 즉, 쉬운 문제부터 매우 어려운 문제까지 다양하게 포함되었는가를 나타냄
측정 방식	$\text{Complexity Distribution} = \frac{\text{표준편차}}{\text{분포지표 또는 레벨별 문제수 비율}}$ (예: 난이도 수준별 문제 수의 분포 → 균형지표)
의미 해석	난이도 분포가 치우치지 않고 균형적일수록 모델이 특정 난이도에만 특화되지 않고 일반화가능성이 높아짐

[표 II-41] Complexity Distribution (복잡도 분포) 관리 지표

3.7.1.3 Domain Coverage Rate (도메인 커버리지 비율)

구분	내용
정의	- 데이터셋이 포함하고 있는 다양한 도메인의 수 혹은 비율 - 도메인은 수학, 과학, 역사, 사회, 법률, 일상 상식 등의 활용 분야
측정 방식	$\text{Domain Coverage Rate} = \frac{\text{포함된 도메인 수}}{\text{계획된 도메인 수}}$ 또는 도메인별 데이터 비율이 최소 임계값(threshold, 예: 5% 이상)을 넘는 도메인의 비율 측정 가능
의미 해석	높은 값은 모델이 단일 도메인에 치우치지 않고 다양한 분야의 추론 문제를 다루었다는 것을 의미하며, 이는 도메인 일반화(domain generalization) 가능성을 높임

[표 II-42] Domain Coverage Rate (도메인 커버리지 비율) 관리 지표

3.7.1.4 Reasoning Pattern Diversity Index (추론 패턴 다양성 지수)

구분	내용
정의	- 데이터셋 내 추론 문제에서 사용된 사고 패턴의 다양성을 나타내는 지표 ‘비유적 추론’, ‘유비 비교’, ‘인과 추론’, ‘전제-결론 추론’, ‘조건적 사고’ 등 다양한 사고 패턴이 존재할 경우 다양성이 높다고 판단
측정 방식	$\text{Reasoning Pattern Diversity Index} = \frac{\text{사용된 사고패턴 수}}{\text{전체 계획된 패턴 수}}$ 또는 사고패턴별 등장 빈도를 기반으로 Shannon entropy(엔트로피) 지수처럼 다양성 지수를 산출할 수도 있음
의미 해석	값이 높으면 데이터셋이 사고패턴 측면에서 다양함을 의미하며, 이는 모델이 여러 사고방식을 학습했다는 신호로 단일 패턴에 특화되지 않은 유연한 추론능력을 시사

[표 II-43] Reasoning Pattern Diversity Index (추론 패턴 다양성 지수) 관리 지표

3.7.2 다양성 지표 예시 종합

지표명	핵심 평가내용	대표 측정식	주요 의미
Reasoning Type Coverage (추론 유형 포함 범위)	데이터셋이 포함하고 있는 다양한 추론 유형을 (논리, 수리, 상식, 인과 등) 얼마나 반영하는지 평가	전체 계획된 추론 유형 수 대비 실제 포함된 유형 수 비율 = 포함된 유형 수 / 전체 유형 수	값이 높을수록 다양한 사고 유형을 학습할 수 있어 모델 일반화 가능성 향상
Complexity Distribution (난이도 분포)	문제 난이도 (쉬움/중간/어려움 등) 분포의 폭과 균형	난이도별 문제 수 비율, 또는 난이도 수준별 평균·표준편차 측정	난이도가 골고루 분포되어 있으면 특정 난이도 편향 없이 일반화 가능성이 높음
Domain Coverage Rate (도메인 커버리지 비율)	데이터셋이 포함하고 있는 도메인 (수학, 과학, 역사 등) 다양성	전체 계획된 도메인 수 대비 실제 포함 도메인 수 비율 = 포함된 도메인 수 / 전체 계획 도메인 수	높은 값은 다양한 분야의 문제를 다루어 도메인 일반화 능력 향상
Reasoning Pattern Diversity Index (추론 패턴 다양성 지수)	데이터셋 내 다양한 사고/추론 패턴 사용 여부	사용된 사고 패턴 수 대비 계획된 패턴 수 비율 또는 사고패턴별 등장 빈도 기반 엔트로피 계산	값이 높을수록 다양한 사고패턴 학습, 단일 패턴 특화 방지 및 복합 추론 능력 강화

[표 II-44] 다양성 지표 예시 종합요약

3.8. 신뢰성 (Reliability / Robustness)

- 신뢰성(Reliability / Robustness)은 AI 모델이 다양한 환경과 조건에서도 일관되고 안정적인 성능을 유지하도록 데이터를 관리하는 핵심적인 요소로 데이터의 재활용 및 재학습 시에도 모델의 성능 저하를 방지하고 예측의 안정성을 보장하는 데 중점 둠
- 데이터가 재활용·재학습 시에도 일관된 성능을 보장하는 정도를 나타냄
- AI 모델이 학습 데이터셋을 벗어난 변화나 교란 요소(perturbations)가 있는 입력에 대해서도 예측 성능을 유지하는 능력으로 이는 단순히 모델의 정확도(Accuracy)뿐만 아니라, 데이터의 품질이 모델의 장기적인 안정성에 미치는 영향을 측정하는 척도
- 추론형 AI 데이터와 그로 학습된 모델이 데이터 재사용·재학습·배포 환경에서 일관된 성능을 유지하고, 소소한 입력 변형·라벨 노이즈·프롬프트 재생성 등에 의해 성능이 급격히 변하지 않는 정도를 말함
- 동일한 데이터로 재학습(또는 검증)을 반복하거나, 동일한 모델에 대해 약간 다른 운영환경에서 실행하더라도 성능·추론 품질이 안정적으로 유지되는가가 신뢰성의 핵심

구분	내용
노이즈, 오류, 비논리적 추론 최소화	• 데이터 자체에 내재된 오염(Contamination) 요소들을 최소화 • 입력 데이터의 무작위적인 변형(노이즈)이나, 부정확하거나 모호하게 부여된 정답은 모델이 잘못된 패턴을 학습하게 하여 성능의 일관성을 해치므로 이러한 오류를 최소화 • 신뢰성 관점에서는 가공데이터 품질 검증, 근거 매핑, 사고과정 단계의 품질 검토를 통해 노이즈를 최소화하고 오류를 제거하는 것이 필수적
사고과정 패턴의 재현가능성 확보	• 동일한 데이터(또는 유사한 노이즈가 포함된 데이터)와 프롬프트를 사용하여 모델을 재학습시키거나 새로운 데이터를 추론할 때 일관성 있는 논리적 중간 과정을 출력 • 모델의 추론 과정이 우연에 의존하지 않고 데이터와 모델의 학습 능력에 의해 안정적으로 유도됨을 의미

[표 II-45] 신뢰성 세부 내용 및 특징

3.8.1 예시 지표

3.8.1.1 Error Rate (오류율)

구분	내용
정의	데이터셋 또는 모델이 생성한 추론에서 사실 오류, 라벨 오류, 논리 오류, 계산 오류, 근거 불일치 등이 발생하는 비율
측정 방식	- 신뢰성 관점에서는 단순히 최종 모델의 오류율뿐만 아니라, 데이터셋이 변경되거나 노이즈가 추가되었을 때 오류율의 변화 폭을 관찰하여 신뢰성을 평가 - 분류(Classification) 문제에서 모델이 전체 데이터 중 정답을 맞히지 못한 비율을 측정 $\text{Error Rate} = \frac{\text{검증에서 오류로 판정된 데이터셋 수}}{\text{검증된 전체 데이터셋 수}}$
의미 해석	- 높은 Error Rate는 데이터 품질 문제(라벨 노이즈·잘못된 근거) 또는 모델의 사실성 문제를 시사 - 데이터 정제·가공 재검토·가공 프로세스 개선 우선순위 판단에 사용
활용 예시	샘플링 데이터셋 기반 검사 (예: 랜덤·리스크 기반 표본)로 주기적으로 Error Rate를 측정하고, 도메인·태스크별 허용치(예: $\leq 1\sim 5\%$ or 도메인 위험도별 규정)를 설정

[표 II-46] Error Rate (오류율) 관리 지표

3.8.1.2 Stability Score (안정성 점수)

구분	내용
정의	- 데이터셋의 미세한 변화(예: 노이즈 추가, 라벨링 오류 수정, 데이터 분포 변화) 또는 학습 환경의 변화에도 불구하고 모델의 성능(예: Error Rate, Accuracy)이 얼마나 적게 변하는지를 정량적으로 측정하는 지표 - 동일 입력에 대해 반복 실행(Temperature, sampling, paraphrase된 prompt) 시 출력(결론)과 추론 경로가 얼마나 일관되게 유지되는지를 나타내는 지표 - 동일 입력(또는 유사 입력/프롬프트 변형)에 대해 여러 번 수행했을 때 출력(결론) 및/또는 추론 경로의 변동성을 종합적으로 측정한 점수 - Stability Score는 단일 수치로 모델의 출력 안정성을 감시하는 데 사용
측정 방식	여러 번 샘플링(예: N회) 후 출력 일치율 및 경로 유사도를 결합하여 산술평균 또는 가중평균으로 계산할 수 있음 $\text{Output Consistency(최빈값 답변과 동일한 출력 비율)} = \frac{\text{모든 응답과 일치하는 출력 수}}{N}$ $\text{Stability Score} = w1 \cdot \text{Output Consistency} + w2 \cdot \text{CoT Path Similarity}$ $\text{CoT Path Similarity} = \text{샘플 간 CoT 임베딩 코사인 평균}$
의미 해석	점수가 높을수록 책정된 환경(프롬프트·파라미터 등)에서 모델이 안정적으로 같은 사고·결론을 재현함을 의미. 낮으면 운영 중 예측 불가능성·버그·노이즈 민감성을 의심해야 함
활용 예시	- Stability Score는 프롬프트 변경, temperature 변동, 파라미터 튜닝 시 모니터링 지표로 사용 - 반응 불안정 구간 식별 시 추가 조사(라벨 오류·데이터 편향·모델 캘리브레이션 등)를 수행

[표 II-47] Stability Score (안정성 점수) 관리 지표

3.8.1.3 Output Sensitivity Index (출력 민감도 지수)

구분	내용
정의	입력(Prompt)의 경미한 변형(Paraphrasing, Synonym Replacement, Formatting Variation)에 대해 모델 출력이 얼마나 변하지 않고 안정적으로 유지되는지를 측정하는 지표로, 신뢰성/견고성 평가에서 최근 가장 많이 사용되는 지표
측정 방식	- 입력 변형 집합 $P_1, P_2, \dots, P_n$ 을 만들어 각 변형별 출력의 유사도를 비교 $\text{Output Sensitivity Index} = 1 - \frac{1}{n} \sum_{i=1}^n \text{Sim}(O_0, O_i)$ - Sim은 BLEU, ROUGE, BERTScore, 또는 embedding cosine similarity 사용 - 값이 낮을수록 민감도가 낮고 더 안정적(신뢰성 높음)
의미 해석	모델이 작은 표현·문장 구조 변경에도 흔들리는지 확인하며, 추론을 사용하는 모델의 Prompt Fragility를 정량화하는 핵심 지표

[표 II-48] Output Sensitivity Index (출력 민감도 지수) 관리 지표

3.8.1.4 Noise Robustness Score (노이즈 견고성 점수)

구분	내용
정의	입력 텍스트에 타이포, 비문(grammar noise), 구두점 변경, 스페이싱 오류, OCR 노이즈 등을 의도적으로 주입했을 때, 모델 출력이 얼마나 일관되게 유지되는지를 측정하는 지표
측정 방식	노이즈 레벨을 달리 주입해 원본 출력과 비교 $\text{Noise Robustness Score} = \frac{1}{k} \sum_{i=1}^k \text{Sim}(O_{\text{clean}}, O_{\text{noise}_i})$ k = 노이즈 수준(level) 또는 유형 수 Sim = 출력 의미 유사도(BERTScore, cosine similarity 등)
의미 해석	데이터 실제환경 적용(고객 질의, 음성 STT 오류, OCR 등)에 매우 중요하며 Noise Robustness가 높으면 모델이 소규모 입력 오류에 무너지지 않음 → 신뢰성 확보

[표 II-49] Noise Robustness Score (노이즈 견고성 점수) 관리 지표

3.8.2 신뢰성 지표 예시 종합

지표명	핵심 평가내용	대표 측정식	주요 의미
Error Rate (오류율)	라벨오류, 사실 오류 등 데이터·출력 오류 비율	오류 샘플 / 전체 샘플	데이터 품질·추론 안정성의 기본 지표
Stability Score (안정성 점수)	반복 실행 시 출력· 사고 경로의 일관성	Output Consistency + CoT Similarity	모델의 재현성, 운영 안정성을 평가
Output Sensitivity Index (출력 민감도 지수)	입력의 경미한 변형에 따른 출력 변화 정도	1 - 평균 출력유사도	프롬프트 민감도, 비일관성 탐지
Noise Robustness Score (노이즈 견고성 점수)	텍스트 노이즈(타이포·OCR 등) 조건에서 출력 유지 정도	평균 Sim (clean, noise)	실제 환경에서의 견고성 평가

[표 II-50] 신뢰성 지표 예시 종합요약

3.9 검증가능성 (Verifiability)

- 추론 내용이 근거 데이터를 통해 검증될 수 있는 정도로 검증가능성(Verifiability)은 추론형 AI 데이터 또는 그에 의해 학습된 모델의 출력이 제공된 근거 데이터 또는 입력 맥락에 기반하여 외부 검증자나 시스템이 독립적으로 검증할 수 있는 정도를 의미
- 단순히 모델이 답을 제시하는 것이 아닌 그 추론 과정이나 결과가 근거 데이터와 대응하여 ‘이 근거가 이 결론을 도출했다’는 매핑이 명확하게 존재해야 함

구분	내용
추론 경로의 각 단계와 데이터 내 근거 문장의 대응	- 추론형 AI 데이터가 단일 정답만 나열하는 것이 아니라 각 단계마다 ‘어떤 근거 문장 또는 입력 정보가 그 단계를 가능하게 했는가’를 명시하고 있어야 함 - 이 과정이 명확해야 외부 검증자나 시스템이 ‘이 단계는 해당 근거로부터 도출되었는가?’를 검증할 수 있음
검증 절차의 반복가능성	- 검증가능성은 단발성 검사만이 아니라 반복적으로 검증이 가능해야 함 - 동일 데이터에 대해 동일 검증자 또는 자동화 시스템이 여러번 검토했을 때 동일한 판단이 나와야 하며 검증 프로세스 자체가 표준화되고 재현가능해야 함

[표 II-51] 검증가능성 세부 내용 및 특징

3.9.1 예시 지표

3.9.1.1 Evidence Alignment Score (근거 정렬 점수)

구분	내용
정의	추론 경로의 각 단계가 입력 또는 근거 문장과 얼마나 잘 정렬(alignment)되어 있는지를 수치화한 지표
측정 방식	- 신뢰성 관점에서는 단순히 최종 모델의 오류율뿐만 아니라, 데이터셋이 변경되거나 노이즈가 추가되었을 때 오류율의 변화 폭을 관찰하여 신뢰성을 평가 - 분류(Classification) 문제에서 모델이 전체 데이터 중 정답을 맞히지 못한 비율을 측정 $\text{Evidence Alignment Score} = \frac{\text{근거 문장과 논리적 대응이 확인된 단계 수}}{\text{전체 단계 수}}$
의미 해석	값이 높을수록 각 단계가 근거 데이터와 명확히 연결되어 있어 검증 가능성이 높다는 것을 의미

[표 II-52] Evidence Alignment Score (근거 정렬 점수) 관리 지표

3.9.1.2 Verifiability Ratio 검증 가능 비율

구분	내용
정의	데이터셋 또는 모델 출력 중 검증 가능하다고 판단된 항목의 비율을 나타내는 지표
측정 방식	$\text{Verifiability Ratio} = \frac{\text{검증 가능한 샘플 수}}{\text{전체 샘플 수}}$ ‘검증 가능한 샘플’은 각 단계에 대해 근거 매핑이 존재하고, 검증자가 재현가능한 절차로 확인한 샘플을 의미
의미 해석	높은 비율은 데이터 전체가 외부 검증에 적합하게 구성되어 있다는 의미이며, 낮은 비율은 많은 샘플이 근거 미기재 단계 누락 등으로 인해 검증 불가능 상태임을 의미

[표 II-53] Verifiability Ratio (검증 가능 비율) 관리 지표

3.9.1.3 Evidence Traceability Index (근거 추적성 지수)

구분	내용
정의	- 각 추론 단계가 외부 근거까지 얼마나 잘 추적될 수 있는가를 평가하는 지표. - 즉, 근거 문장이 명시되어 있으며 해당 문장을 외부 자료 (논문, 데이터베이스, 웹 페이지 등)로 참조할 수 있는 정도
측정 방식	$\text{Evidence Traceability Index} = \frac{\text{추적 가능한 근거가 있는 단계 수}}{\text{전체 단계 수}}$ ‘추적 가능한 근거’는 문장 내에서 출처가 명시되었거나 참조 가능한 형식 (예: 논문 ID, 웹 URL, 데이터세트 ID)을 갖춘 근거를 의미
의미 해석	- 지수가 높을수록 각 추론 단계가 외부 검증자가 근거 문장을 찾아서 확인할 수 있는 구조로 되어 있다는 의미 - 설명 및 추론의 신뢰성/투명성을 향상시키는 중요한 요인

[표 II-54] Evidence Traceability Index (근거 추적성 지수) 관리 지표

3.9.1.4 Step Verifiability Consistency (단계 검증 일관성)

구분	내용
정의	동일 입력 또는 유사 입력에 대해 모델이 생성한 여러 추론 경로(혹은 동일 데이터에 대해 검증자가 여러 번 검토한 결과) 중에서 각 단계의 검증 가능성 상태가 얼마나 일관되게 유지되는가를 평가하는 지표
측정 방식	$\text{Step Verifiability Consistency} = \frac{\text{모든 시도 중 검증 가능 상태가 동일한 단계 수}}{\text{전체 단계 수}} \times \text{시도수}$ 또는 여러 검증자 혹은 반복 시도 결과 간에 단계별 근거 대응 상태가 변화하지 않는 비율로 계산할 수도 있음
의미 해석	값이 높을수록 검증 구조가 안정적이고 반복 가능한 검증 절차가 존재함을 의미하고, 반대로 낮으면 검증 프로세스의 신뢰성이 떨어짐을 의미

[표 II-55] Step Verifiability Consistency (단계 검증 일관성) 관리 지표

3.9.2 검증가능성 지표 예시 종합

지표명	핵심 평가내용	대표 측정식	주요 의미
Evidence Alignment Score (근거 정렬 점수)	추론 단계 ↔ 근거 문장 정렬 여부	정렬된 단계 수 / 전체 단계 수	각 단계가 근거에 충실하면 검증 가능성이 높음
Verifiability Ratio (검증 가능 비율)	전체 샘플 중 검증 가능한 항목 비율	검증 가능한 샘플 수 / 전체 샘플 수	데이터 전체가 구조화되어 검증 가능하면 신뢰성 확보됨
Evidence Traceability Index (근거 추적성 지수)	각 단계의 근거가 외부 자료로 추적 가능한 수준	추적 가능한 단계 수 / 전체 단계 수	외부 자료 대응 가능성이 높으면 설명·추론의 투명성 증가
Step Verifiability Consistency (단계 검증 일관성)	반복 검증/다중 시도 시 단계별 검증 가능 상태의 일관성	동일 검증 상태 유지 단계 수 / (전체 단계 수 × 시도 수)	검증 절차가 반복 가능하고 안정적이면 검증체계 신뢰성 높음

[표 II-56] 검증가능성 예시 지표 종합 요약

3.10 윤리·투명성 (Ethical Transparency)

- 데이터 구축·가공 과정이 편향이나 비윤리적 추론을 유발하지 않는 정도
- 윤리·투명성은 데이터의 수집·정제·라벨링·가공·배포 전 과정이 편향·차별·비윤리적 추론을 유발하지 않고, 동시에 데이터 출처·처리 이력·라벨링 규칙 등이 충분히 공개되어 외부 검증이 가능한 수준을 의미
- 단순한 기술적 성능뿐 아니라 데이터 파이프라인의 투명성(누가, 언제, 어떤 근거로 데이터를 만들었는가)과 윤리적 위험관리가 함께 충족되어야 윤리·투명성이 확보된다고 볼 수 있음

구분	내용
편향된 추론패턴, 인종·성별 등 고정관점의 배제	- 데이터셋에 특정 집단(예: 인종·성별·국적 등)에 대한 편향적 표본 분포나 편향적 가공 규칙이 포함되면 모델은 그 편향을 학습하여 편향된 추론·행동을 재현하거나 증폭 - 데이터 설계 단계부터 대표성, 민감 속성 분포 점검, 편향측정, 편향 완화를 도입해야 함
데이터 출처 및 생성 기록의 투명성 확보	데이터의 출처, 라이선스·저작권 정보, 수집일시·수집 방법, 전처리 및 가공 이력(누가·언제·어떤 기준으로 가공했는지) 등의 메타데이터를 체계적으로 기록, 공개(또는 내부 감사가 가능하도록 보관)해야 함

[표 II-57] 윤리·투명성 내용 및 특징

3.10.1 예시 지표

3.10.1.1 Bias Index (편향 지수)

구분	내용
정의	- 특정 민감 속성(예: 성별·인종·연령 등)에 대해 편향적 분포 또는 차별적 가공 패턴을 가지고 있는 정도를 측정하는 지표 - AI 모델이 학습 시 사회적 편향을 그대로 강화하거나 증폭할 위험을 평가함
측정 방식	[여러 지표를 사용해 편향을 다각도로 측정] - Statistical Parity Difference - 통계적 동등성 차이, 보호집단(protected group)과 비보호집단 간에 긍정적 예측 결과가 나올 확률의 차이 - Demographic Parity Ratio - 인구통계학적 동등성 비율, 두 집단 간 긍정적 예측 비율의 비율을 측정 - Equal Opportunity Difference - 기회 균등 차이, 실제 정답이 긍정인 경우(True Positive)에 대해 집단 간 정답 예측률 차이를 측정 - Disparate Impact - 차별적 영향, 특정 집단이 다른 집단에 비해 불리한 결과를 체계적으로 받는지를 비율로 측정 - KL-divergence - 쿨백-라이블러 발산, 두 확률분포 P와 Q가 얼마나 다른지를 측정하는 정보 이론적 거리 등 - Statistical Parity Difference = $P(\hat{Y}=1 \mid \text{group}=A) - P(\hat{Y}=1 \mid \text{group}=B)$ - Disparate Impact = $P(\hat{Y}=1 \mid \text{group}=A) / P(\hat{Y}=1 \mid \text{group}=B)$
의미 해석	값이 클수록(또는 임계값을 초과하면) 해당 속성에 대해 편향 가능성이 높아 차별적 추론 경향을 가지고 있다는 것을 의미하므로 데이터를 재샘플링하거나 가공 규칙의 수정 필요

[표 II-58] Bias Index (편향 지수) 관리 지표

3.10.1.2 Provenance Completeness (출처·생성기록 완전성)

구분	내용
정의	데이터셋(또는 개별 샘플)에 대해 필수 메타데이터(출처, 수집일시, 저작권/라이선스, 가공자·가공 기준, 전처리 이력 등 데이터가 어디서 왔는지, 어떻게 생성·가공되었는지를 추적할 수 있는지)가 얼마나 완전하게 기록·보관·제공되어 있는지를 나타내는 비율·점수
측정 방식	Provenance Completeness Ratio = $\frac{\text{샘플 또는 데이터 항목 중에서 필수 메타데이터가 모두 기재된 항목 수}}{\text{전체 항목 수}}$ 또는 메타데이터 항목별 완성도(각 항목의 채워진 비율)를 가중평균한 점수로 산출
의미 해석	높은 값은 데이터의 출처·처리 이력이 투명하게 관리되어 법적·윤리적 문제 발생 시 추적·시정이 용이함을 의미하며, 낮으면 데이터 신뢰성·책임성 확보에 취약함을 의미

[표 II-59] Provenance Completeness (출처·생성기록 완전성) 관리 지표

3.10.1.3 Valid Consent Rate (정당한 동의 확보율)

구분	내용
정의	- 데이터에 포함된 개인 정보·개인 발화·사용자 생성 데이터 등이 적절한 동의(consent) 또는 합법적 수집 절차에 따라 확보되었는지를 평가하는 지표 - 특히 대규모 웹 크롤링 데이터, 스크래핑 데이터, 사용자 로그 기반 데이터에서 중요한 윤리 지표
측정 방식	Valid Consent Rat = $\frac{\text{합법적·명시적 동의를 확인 가능한 데이터 수}}{\text{전체 개인 관련 데이터 수}}$
의미 해석	- 높은 값은 개인 정보 남용 위험 낮음, 법적 안정성 확보를 의미 - 낮은 값은 개인정보보호법·GDPR·CCPA 등 규제 리스크 증가를 의미

[표 II-60] Valid Consent Rate (정당한 동의 확보율) 관리 지표

3.10.1.4 Sensitive Attribute Leakage Score (민감속성 유출 지수)

구분	내용
정의	- 데이터 또는 추론 과정 속에 민감 정보(성별·인종·정치성향·질병·위치 등) 이 암묵적으로 노출되거나 유추 가능한 형태로 남아 있는 정도를 측정하는 지표 - 데이터에 '직접 포함되지 않아도' 문맥이나 힌트로 복원 가능한 경우도 포함
측정 방식	- Leakage Detection Model 활용 : 텍스트에서 민감 속성을 자동 추정 - Leakage Score : 모델이 민감속성(A,B,C...)을 $\geq$ 일정 확률로 예측할 수 있는 샘플 비율 - 민감정보 탐지 규칙 기반 필터링(PII detection)
의미 해석	- 높을 경우 개인 정체성 노출·편향 학습 위험 증가를 의미 - 낮을 경우 안전한 데이터, 편향 재생산 가능성 감소를 의미

[표 II-61] Sensitive Attribute Leakage Score (민감속성 유출 지수) 관리 지표

3.10.2 윤리투명성 지표 예시 종합

지표명	핵심 평가내용	대표 측정식	주요 의미
Bias Index (편향 지수)	특정 집단에 대한 차별적 패턴 여부	SPD, DI Ratio, EOpp Diff 등	편향 감지 및 완화 필요성 판단
Provenance Completeness (출처·생성기록 완전성)	데이터 출처·라벨링 처리 이력의 투명성	메타데이터 완전성 비율	법적·윤리적 책임 추적 가능
Valid Consent Rate (정당한 동의 확보율)	수집된 개인 데이터가 합법적으로 확보되었는가	명시적 동의 확보 비율	개인정보보호 규제 준수 여부

[표 II-62] 윤리투명성 지표 예시 종합 요약

제2장

추론형 AI 데이터 품질관리

1 품질관리 프레임워크 구성


- 추론형 AI 데이터의 품질확보를 위한 프레임워크는 ‘준비·계획, 구축, 운영·활용’의 3단계로 구분
- 추론형 AI 데이터의 구성 요소는 아래와 같음
 - 추론형 AI 데이터의 품질관리 프레임워크는 인공지능 학습용 데이터 품질관리 프레임워크를 기반으로 구성

조 직	구 분	내 용
-	단계	• 준비·계획, 구축, 운영·활용 3단계 사업 단계
사업수행기관	프로세스	• 데이터 준비·계획, 획득/수집, 정제, 가공, 학습, 운영·활용 단계까지 사업의 모든 단계와 관련된 프로세스
	산출물	• 사업수행 프로세스별 활동을 통해 생산되는 데이터 및 문서 등 산출물
	품질관리 활동	• 사업수행 단계별 품질관리 활동에 대한 정의 • 사업수행 일정별로 수행하는 자가점검 활동 • 제3자 품질검증 활동 정의

[표 II-63] 추론형 AI 데이터 품질관리 프레임워크 구성 항목

II

1.1 품질관리 프레임워크 프로세스 정의



※ 추론형 AI 데이터 품질관리 프레임워크는 인공지능 학습용 데이터 품질관리 프레임워크를 기반으로 진행

[그림 II-1] 품질관리 프로세스 개요

단 계	프로세스	프로세스 정의
100. 준비·계획	110. 구축계획 수립	- 구축 목적의 일치성과 일관성 확보를 위한 구체적 계획 수립 - 사업수행기관의 컨소시엄 간 업무와 역할 정의 - 품질지표 및 목표, 품질점검 기준 수립단계
200. 구축	210. 데이터 획득/수집	- 데이터 획득/수집에 대한 프로세스 및 원시데이터에 대한 품질관리 - 생성형AI 데이터를 획득/수집하는 단계로 원시데이터를 생성
	220. 데이터 정제	- 데이터 정제에 대한 프로세스 및 원천데이터 품질관리 - 데이터 획득/수집 프로세스에서 생성된 원시데이터 중복제거, 비식별화 등의 정제 작업을 진행하는 단계로 정제 작업을 수행한 원천데이터 생성 - 데이터 유형에 따라 특정 원천데이터는 데이터 가공단계를 거치지 않고 사전학습/미세조정 학습에 사용
	230. 데이터 가공	- 데이터 가공에 대한 프로세스 및 데이터 품질관리 - 구축목적과 사전에 정의된 가공 프로세스에 따라 데이터를 학습할 수 있는 형태로 가공하는 단계 - 데이터 가공은 정제 데이터에 기반하되, 필요에 따라 별도로 획득/수집, 정제 프로세스를 반복 수행
	240. 데이터 학습	- 데이터 학습에 대한 프로세스 및 학습용 데이터 품질관리 - 학습 데이터셋을 이용하여 학습시키고 학습된 AI모델의 성능을 보정 - 생성형AI 데이터는 필요에 따라 데이터 학습을 반복
300. 운영·활용	310. 데이터 운영·활용	- 데이터 개방을 위해 개방 전 점검 활동 수행 - AI-Hub에 적재되어 개방되는 학습용 데이터에 대한 품질관리 - 개방용 데이터 운영 및 활용지원을 위한 하자 및 유지보수 단계

[표 II-67] 추론형 AI 데이터 품질관리 프레임워크 프로세스 정의

1.2 품질관리 대상 데이터 유형(예시)

- 추론형 AI 데이터는 단계별 사고, 문제해결형 등 다양한 데이터 유형으로 구성되며 대표적인 데이터 유형을 아래와 같이 정의

유형	내용
논리 추론형 QA 데이터	- 질문과 답변 간 논리적 연결과 추론 과정을 포함한 QA데이터 - 모델이 논리적 사고와 근거 기반 사고과정을 학습하도록 지원
단계별 사고과정 데이터	- 문제 해결 과정을 단계(step)별로 서술한 데이터 - 모델이 추론의 중간 단계와 논리 흐름을 학습할 수 있게 함
멀티턴 추론 데이터	- 여러 발화(turn)에 걸친 대화 속에서 추론적 사고와 문맥 유지를 포함한 데이터 - 모델의 장기적 추론 능력 학습에 활용
논리적 판단·분류 추론 데이터	- 사실, 조건, 규칙 등을 기반으로 판단·분류·결정 과정을 포함한 데이터 - 모델이 논리적 의사결정 능력을 학습
문제해결형 데이터	- 수식 계산, 실험 논리, 코드 작성 등 문제 해결 중심의 사고과정을 포함한 데이터 - 모델이 단계별 해결 전략과 근거 기반 추론을 학습
지식기반 추론 데이터	- 외부 지식이나 도메인 정보를 근거로 정확하고 신뢰성 있는 결론을 도출하는 데이터 - 모델의 사실적 사고과정과 정보 활용 능력을 향상

[표 II-64] 품질관리 대상 데이터 유형(예시)

1.3 품질관리의 원칙

구분	내용
정확성	데이터가 사실과 근거에 기반하여 정확하게 구성되고, 잘못된 정보나 허위 추론을 배제
논리성	- 추론 과정 전체에서 논리적 모순이나 비약이 없어야 함 - 문제-근거-결론이 구조적으로 타당하게 연결되어야 함
일관성	- 사고과정의 단계 구조, 문장 표현 방식, 포맷 규칙이 데이터 전체에서 일관되게 준수되어야 하며 이를 통해 모델이 안정적인 패턴을 학습하도록 지원 - 사고과정의 단계는 데이터 특성별 상이하며 1단계 ~ n 단계 등 다양하게 설정
재현성	동일한 조건에서 동일한 입력을 사용할 경우 동일한 품질의 데이터 결과가 재현되어야 하며 이는 품질관리 프로세스의 신뢰성과 공정성을 보장
추적성	데이터의 생성, 보완, 평가 과정에서 모든 메타정보와 변경 이력이 기록 관리되어 오류 원인 분석과 책임성을 확보
안정성	- 데이터셋이 편향, 오류, 노이즈의 영향을 최소화 하도록 설계·검증 되어야 함 - 안전성 높은 데이터는 모델의 일반화 성능과 신뢰성을 강화

[표 II-65] 품질관리의 원칙

1.4 품질관리 목적과 기대효과

- 추론형 AI 데이터 품질 관리는 모델의 논리적 안정성을 강화, 오류를 최소화, 전체 시스템의 신뢰성 향상을 목적으로 하며 이는 AI의 실세계 적용성을 확대하며, 경제적·운영적 효율성을 가져옴

기대효과	내용
모델의 추론 안정성 (Logical Stability) 확보	• 품질관리는 데이터의 논리적 일관성을 통해 모델의 추론 안정성을 확보 • 불완전한 데이터는 모델의 기본 로직을 왜곡하지만 고품질 관리는 이를 방지하여 인간-like reasoning을 지원하고 이는 고위험 응용 (예: 의료)에서 신뢰성을 제고
오류·환각 (Hallucination) 감소	• 환각은 AI가 ‘논리적으로 일관되지만 사실적으로 잘못된 출력을 생성하는 현상’으로 데이터 품질 저하가 주 원인 • 품질관리는 데이터 정제와 검증으로 이를 감소시킴
일관성·재현성·정당성 강화	• 품질관리는 데이터의 일관성을 통해 모델의 재현성과 정당성을 강화 • LLM 간 변동성을 줄이고, 결정이 모델의 프로토콜과 일치하도록 함


[표 II-67] 품질관리 기대효과

1.5 정답 중심을 넘어 “추론 과정 중심 품질관리”의 필요성

- 정답(결과) 중심 품질관리는 최종 데이터의 적합 여부에 검증이 집중되어 과적합이나 데이터 편향에 의한 취약성이 검증 과정에서 충분히 드러나지 않을 수 있음
- 반면, 추론 과정 중심 품질관리는 근거-중간 단계-결론의 연결 구조를 단계별로 점검하여 논리적 비약, 단계간 불일치, 근거 부재·환각 등을 체계적으로 통제함으로써 ‘추론의 안정성’을 강화

2 품질관리 활동

- 추론형 AI 데이터 품질관리는 인공지능 학습용 데이터 품질관리 가이드라인에서 제시하는 생애주기 기반 품질관리 체계 및 구축공정을 준용하여 수행
- 다만, 추론형 데이터는 추론경로 및 사고과정이 학습 성능에 영향을 주는 핵심 정보이며 해당 내용이 표면적으로는 타당해 보이더라도 모델의 실제 판단 근거를 충실히 반영하지 않을 수도 있으므로 추론형 AI 품질 특성을 고려한 품질관리가 필요함
- 따라서 데이터 가공 단계의 ‘가공데이터 품질검사’ 세부 활동을 2단계 품질검사 형태로 세분화하여 수행



[그림 II-2] 추론형 AI 데이터 품질관리 활동

단계	프로세스	품질관리 활동
100. 준비·계획	110. 구축계획 수립	1101. 사업수행 및 구축계획 수립 1102. 데이터 구축 절차, 조직 구성 1103. 임무 정의에 대한 적절성 검토 1104. 품질목표 및 점검기준 수립
200. 구축	210. 데이터 획득/수집	2101. 획득/수집 방법 및 기준 현행화 2102. 데이터 법적 근거 검토 2103. 획득/수집 도구 및 저장환경 검토 2104. 원시데이터 품질검사

II

	220. 데이터 정제	2201. 정제 방법 및 기준 현행화 2202. 개인정보/민감정보 비식별화 등 법적 준거 확보 2203. 정제 도구 및 저장환경 검토 2204. 원천데이터 품질검사
	230. 데이터 가공	2301. 가공 방법 및 기준 현행화 2302. 가공 도구 및 저장환경 검토 2303. 가공 데이터 품질검사 2303-1. 추론데이터 품질검사(1차) 2303-2. 추론 데이터 정제 2303-3. 추론데이터 품질검사(2차)
	240. 데이터 학습	2401. 구축목적-AI모델 합치성 확인 2402. 학습결과 확인 및 최적화 2403. 품질검증결과 보완조치
300. 운영·활용	310. 데이터 운영·활용	3101. 데이터 개방을 위해 개방 전 점검 활동 3102. 개방용 데이터 하자 및 유지보수 3103. 사용자 품질개선의견 반영

[표 II-68] 추론형 AI 데이터의 품질관리 활동

- 추론형 AI 데이터 구축사업 수행 일정별로 자가점검을 위한 활동에 대한 정의와 제3자 품질검증 활동은 다음과 같음



[그림 II-3] 품질 자가점검 및 품질검증 활동



[그림 II-4] 추론형 AI 데이터 품질관리 프레임워크 프로세스 및 데이터 산출물

3


품질관리 프로세스 및 산출물

- 기존 생성형 AI 데이터와 품질관리 활동이 동일한 내용은 본 가이드라인에서 서술하지 않으며 추론형 AI 데이터의 가공단계의 품질관리 세부 활동에 대해서 제시

※ 그 외 데이터 준비/계획 단계, 데이터 구축단계의 획득/수집, 정제, 학습 단계와 운영·활용 단계와 동일한 사항은 ‘[제3권] 생성형 AI 데이터 품질관리 가이드의 II. 생성형 AI 데이터 품질관리 체계’ 참고

3.1 데이터 가공(230) 프로세스

200.구축



[그림 II-5] 추론형 AI 데이터 가공 프로세스

3.2 데이터 가공(230) 프로세스 품질관리 활동 및 산출물

- 추론형 AI 데이터 가공 프로세스 품질관리 활동 및 산출물

프로세스	품질관리 활동	주요 검토 내용	구축 및 품질 산출물
230. 데이터 가공	2301. 데이터 가공 방법 및 기준 현행화	- 가공데이터 구축 방법 및 기준 정의 - 데이터 가공에 필요한 데이터 구축 - 데이터 형식 및 입력값 범위 기준 마련 - 데이터 가공 방법 및 기준, 교육, 검사체계 수립 - 데이터 가공 기준변경 관리	구축공정 가이드라인 (가공)
	2302. 데이터 가공 도구 및 저장환경 검토	- 가공에 사용될 저작도구 확보 및 사용 방법 검토 - 데이터 가공 기준 변경 관리 - 가공데이터 저장환경 구축	저작도구(가공) 사용설명서
	2303. 가공데이터 품질검사	- 추론사고과정, 경로 및 추론 구조를 중점으로 검사 - 생성된 사고과정·경로의 논리·일관성 검사(1차) - 검사 결과에 따른 추론 내용 및 사고과정의 논리적 잡음, 불안전 추론 단계 정제 - 정제가 완료된 추론 데이터의 품질을 정량적으로 점수화하여 재평가 (2차) - 가공데이터 품질검사를 위한 검사 도구 및 검사 결과 - 품질검사 결과에 따른 보완조치	가공데이터
			품질관리보고서 품질검사 도구

[표 II-69] 추론형 AI 데이터 가공 단계 품질관리 활동 및 산출물

4 가공단계 품질관리 활동

4.1 가공 방법 및 기준 현행화

4.1.1 품질관리 활동

- 가공할 추론데이터의 구축 방법과 기준을 정의하여 데이터를 구축하는 단계로 데이터 가공 방법 및 기준, 교육, 검사체계를 수립하고 관리
- 데이터 구축과정 및 검사단계에서 보완 및 변경되는 가공 기준에 대해서는 지속적으로 현행화 작업을 수행하고 휴먼 가공인 경우 작업자 교육을 병행
- 추론형 AI 데이터가 구조적 오류, 논리적 결함 없이 일관된 형식과 기준을 갖추도록 보장하고 이를 통해 모델이 문제를 잘못 이해하거나 비약적·모순된 추론을 생성하는 것을 사전에 차단함으로써 생성자(AI모델·사람)마다 발생할 수 있는 품질 편차를 최소화하는 것이 목적

4.2 가공 도구 및 저장환경 검토

4.2.1 품질관리 활동

- 가공에 사용될 저작도구를 확보하고 사용 방법을 검토하여 가공가이드라인에 반영
- 특히 가공작업자(사람)를 통해 직접 데이터를 가공하는 경우 정의한 사고과정 및 데이터 구조를 고려하여 저작도구 확보 및 관리 필요

고려사항	내용
추론 데이터 구조	● 정의된 추론 데이터 구조 (필수 요소 등)에 맞게 입력 요소가 반영되어있는지 확인/점검 가능하도록 구성 ● 추론(사고과정)이 다단계로 구성된 경우 각 단계별 요소가 포함되어있는지, 단계별 사고과정 및 서술내용이 적합한지 점검할 수 있도록 단계별 사고과정을 분리하여 서술 가능하도록 구성
작성 완결성	● 추론(사고과정)이 다단계로 구성된 경우 중간 단계 누락, 빈값 등이 발생하지 않도록 저작도구 내에서 저장 및 제출 전 자동점검이 가능하도록 구성
추론에 대한 사실성 및 근거 확보	● 추론(사고과정)에 대한 사실성 및 근거 확보를 위해 수집한 원천데이터 또는 용어 사전/정의집 등을 도구 내에서 조회/검색/참조할 수 있도록 구성

[표 II-70] 추론형 AI 데이터 저작도구 고려사항

4.3 가공 데이터 품질검사

4.3.1 추론데이터 품질검사(1차)

4.3.1.1 목적

- 생성된 데이터가 논리적 일관성, 사실성, 구조적 정확성 등 핵심 품질 기준을 충족하는지 확인
- 모델이 잘못 학습할 위험이 있는 오류·비약·모순·편향 요소를 조기에 식별하여 학습 데이터의 안전성과 신뢰도를 보장하기 위한 검사
- 데이터 생성자의 편차나 무작위적 변동을 제거하고, 데이터의 균질성과 재현성을 향상
- 검증되지 않은 저품질 데이터가 이후 단계에 유입되는 것을 방지하여 전체 파이프라인의 오류 전파를 차단함으로써 궁극적으로는 모델이 학습 시 안정적으로 추론 능력을 습득할 수 있도록 정확하고 검증된 고품질 데이터만을 선별하는 것이 목적

4.3.1.2 품질관리 활동

- 생성된 데이터가 구조적 형식(템플릿, 단계 수, 문장 규칙)을 정확히 준수하는지 자동 형식검사를 수행
- 사고과정의 각 단계, 서술방식이 논리적으로 연결되는지, 비약이나 모순이 없는지 등을 점검하는 논리 일관성 검사를 진행하며 사실 기반 과제의 경우 외부 지식베이스 또는 정답셋과 비교하여 사실성·정답성 검사 (Factuality/Accuracy Check)를 수행
- Embedding 기반 유사도 점검을 통해 중복된 사고과정, 불필요한 변형본, 의미 반복 데이터를 제거하며 데이터 중복·변질 검출을 병행하며 금지 표현, 위험 문장, 개인정보 등 안전 기준 위반 여부를 판단하는 Safety·Risk 검사를 수행
- 문제 유형별로 기대되는 추론 패턴과 비교하여 비정상적 추론 패턴(불필요한 서술, 단계 누락 등)을 탐지하고 검사 결과에 따라 오류 유형을 자동 분류하여 수정 및 폐기 데이터를 품질 기준 기반으로 선별
- 품질 불량 데이터는 규칙 기반 재검증 또는 재생성 트리거로 정제 및 2차검사/보완과정에 전달되며 검증 로그와 오류 패턴은 지속적으로 수집되어 검증 기준과 모델 프롬프트 개선의 피드백 루프로 활용 가능
- 이러한 품질관리 활동을 통해 전체 데이터셋이 논리적·사실적·구조적 기준을 충족하는 고품질 추론 데이터로 유지할 수 있음

4.3.1.3 품질관리 방법

- 품질검사 및 관리를 위한 주요 기술을 제시

구분	내용
LLM 평가모델 활용	• 생성된 추론형 AI 데이터를 평가시 LLM을 평가자로 활용하여 데이터의 논리성, 사실성, 형식 준수 여부를 판단하는 품질관리 기술 • 사람이 일일이 검증하기 어려운 대규모 데이터셋에서 논리적 오류, 비약, 사실 오류, 형식 위반을 자동으로 식별하여 데이터 검증 효율과 일관성을 높이는 것이 목적 • 실행 방법 ① 평가기준(논리성, 사실성, 형식, 안전성 등)을 명확히 정의 ② LLM에 평가 프롬프트를 제공하여 각 데이터 샘플을 평가하도록 지시 ③ LLM이 제시한 점수·평가 결과를 수집하고 기준값과 비교하여 통과 여부를 결정 (필요시 평가 결과를 기반으로 재검증 또는 재생성 트리거를 실행)
사실검증 모듈 활용	• 생성된 추론형 AI 데이터에서 제시된 정보, 주장, 숫자, 근거 등이 사실적으로 정확한지 자동으로 검증하는 기술 • 모델이 생성한 데이터의 허위 정보, 잘못된 수치, 오류 가능성을 조기에 식별하여 데이터셋의 신뢰성과 학습 안전성을 확보하는 것이 목적 • 실행 방법 ① 검증 대상 데이터 샘플을 통한 검증 범위 설정 ② 외부 지식베이스, API, 신뢰 가능한 데이터 소스와 연동하여 사실성 검증 수행 ③ 검증 결과를 기준값과 비교하여 참/거짓 또는 신뢰도 점수를 산출 ④ 오류가 발견된 경우 수정, 재생성 또는 폐기 여부 결정의 순으로 진행 • 품질관리를 위해서는 자동비교·검증 알고리즘, 검증 점수 산출 및 기준값 판단 로직, 오류 로그 및 재검증 트리거, 결과 기록 및 추적 시스템 등의 요소를 준비해야 함
일관성 점수 부여	• 생성된 추론형 데이터에 모델이 생성한 사고과정과 결론에 대한 논리적 사실성, 일관성을 정량적으로 평가하는 지표를 활용 • 데이터 검증 단계에서 사고과정의 논리적 비약, 모순, 사실 오류 등을 식별하고 고품질 추론데이터만 선별하는 것이 목적 • 실행방법 ① 동일 프롬프트로 여러 사고과정 생성 ② 단계·근거·결론 단위로 상호 비교 ③ 논리 충돌·누락·모순을 탐지 ④ 일관성 점수 계산 ⑤ 기준치 미달 시 재생성·보정
스키마/형식 검증기 활용	• 추론 데이터가 사전에 정의된 구조(스키마), 형식, 규칙을 정확히 준수하는지 자동으로 검증하는 품질관리 기술 • 추론데이터의 질문-사고과정-답변에 대한 구조적 오류를 사전에 제거하여 안정적으로 학습·추론할 수 있는 기반을 확보하는 것이 목적 • 품질관리 수행을 위해 구조 정의, 형식 제약조건, 규칙검사 등의 요소를 정의하여 수행

의미정합성 (Semantic Alignment) 검증	• 데이터의 내용이 논리·의미적으로 일관되고 문제-해결-정답 또는 입력-출력 간 의미적 대응이 정확한지를 평가하는 기술 • 데이터의 표현은 맞지만 의미적 오류가 존재하는 ‘의미 부조화(Semantic Drift)’를 방지해 모델이 잘못된 추론 패턴 학습을 차단하는 것이 목적 • 의미적 유사도 측정모델(LLM·임베딩 기반), 논리연결성 규칙, 응답 정합성 기준 등을 필요로 함 • 실행방법 ① 의미 구조 정의 ② 입력-출력, 문제-답변 간 의미적 관계 분석 ③ 의미 불일치 지점 검출 ④ 불일치 유형 분류 및 보고 ⑤ 보완 및 재검증 순으로 진행
자연어 추론 기반 모순 탐지 (NLI Contradiction Detection)	• 자연어 추론(NLI, Natural Language Inference) 모델을 활용하여 데이터 내 문장들 간 의미적 모순이 존재하는 지 자동으로 식별하는 품질관리 기술 • 사고과정, 답변, 설명문 등에서 발생하는 자기모순, 전제-결론 불일치, 사실적 충돌을 제거하여 데이터의 논리적 안전성을 확보하는 것이 목적 • NLI모델 (Entailment·Neutral·Contradiction 분류), 모순 판단 기준, 문장쌍 생성 규칙, 모순 리포트 체계로 구성됨 • 실행방법 ① 문장 단위 또는 단계 단위 쌍 생성 ② NLI 모델로 모순 여부 판별 (레이블/확률 산출) ③ 종합 점수 계산 및 기준치 비교 ④ 모순 유형 분류 ⑤ 수정·재평가 순으로 진행

[표 II-71] 품질검사(1차) 주요 품질관리 기술

4.3.1.4 품질검사(1차) 품질관리 체크리스트

구분	체크리스트
프롬프트 입력 관리	- 프롬프트 템플릿이 표준화 규격(문장 구조, 지시문, 변수 슬롯)을 준수했는가? - 문제 유형별 필수 지시(예: 단계별 사고과정 요구)가 포함되었는가? - 금지 표현/금지 패턴(예: “정답만 말해”, “설명 생략”)이 입력에 포함되지 않았는가? - 난이도·문제 조건·도메인 지식 요구사항 등 메타정보가 정확하게 설정되었는가?
형식·스키마 검증	- 출력이 정의된 스키마(예: {question, answer, reasoning})를 정확히 준수하는가? - 필수 필드 누락(Null Missing)이 없는가? - JSON/문단/단계(step) 구조가 템플릿 규칙과 일치하는가? - 단계 번호, 구문 패턴 등 형식 규칙 위반이 없는가?
추론 구조·단계 품질 검증	- 사고과정 및 추론 단계가 템플릿에서 요구하는 단계 수를 충족하는가? (예: 1-step, 3-step, 5-step 등 사전에 정의한 단계 수) - 추론 단계가 논리적으로 구분되어 있으며 중복·순서 오류가 없는가? - 단계 간 논리적 비약, 누락된 근거가 없는가? - 결론이 추론 단계에서 제시된 근거와 일치하는가?
의미 정합성 검증	- 질문-근거-결론 간 의미적 정렬이 잘 이루어졌는가? - 문제의 조건을 잘못 해석하거나 거짓 가정을 사용하지 않았는가? - 사고과정 전체가 하나의 일관된 관점과 논리로 유지되는가? - 필요 시 Semantic Alignment Check 점수 기준을 통과했는가?
모순 오류 검출	- NLI 기반 모순 탐지에서 Contradiction이 발생하지 않았는가? - 단계 간 사실적 충돌(예: 숫자·지식·조건 불일치)이 없는가? - 자기모순(Self-contradiction)이 탐지되지 않았는가? - 정답과 사고과정이 서로 상충하지 않는가?
사실성·정확성 검증	- Fact-checking Module에서 주요 사실·지식이 검증되었는가? - 외부 지식 필요 시 잘못된 정보·환각(Hallucination)이 없는가? - 수식, 계산, 논리 결과가 정확한가? - 날짜·수치 기반 정보가 오류 없이 계산되었는가?
Self-Consistency 및 대안적 추론 검증	- 동일 입력으로 생성한 여러 데이터 간 답변이 일관성을 유지하는가? - 정답은 다르지 않으나 논리 흐름이 자연스러운 분산 범위 내에 있는가? - Self-consistency 점수가 기준치 이상인가? - 비정상적으로 다른 reasoning 패턴이 있는 경우 검출되었는가?
오류·노이즈 검출 및 데이터 수정 필요성 평가	- 중복·불필요한 문장, 무의미한 텍스트가 포함되어 있지 않은가? - 감정적 표현, 가치 판단적 표현 등 금지 표현이 없는가? - 안전·윤리 기준에 위배되는 표현이 없는가? - 수정이 필요한 항목이 명확히 식별되고 재검증 절차가 지정되었는가?
최종 품질 판정	- 형식·구조·의미·사실 검증에서 모두 통과했는가? - 품질 기준 점수(예: 85점 이상)를 충족하는가? - Reviewer / Validator의 승인 여부가 기록되었는가? - 검증 결과와 로그가 품질관리 시스템에 저장되었는가?

[표 II-72] 품질검사(1차) 품질관리 체크리스트

4.3.2 추론데이터 정제

4.3.2.1 목적

- 학습에 악영향을 미치는 오류·잡음·중복 데이터를 제거하여 모델 학습 효율과 성능을 극대화하는 단계
- 불완전하거나 모순된 사고과정, 사실과 다른 진술, 형식 오류 등 저품질 요소를 제거하여 학습모델이 잘못된 추론 패턴을 학습하는 위험을 축소하고 중복과 의미적 유사 데이터를 정제하여 다양성과 유효표본 수를 보존하여 과적합을 방지
- 표기·문체·포맷을 일관화해 검증·평가의 안정성을 높이고 자동화 처리를 용이하게 하여 궁극적으로는 정제된 데이터가 모델의 일반화 능력과 설명 가능성을 향상 시키도록 하는 것이 목적
- 기존의 구축공정 프로세스 상의 (수집 → 정제 → 가공 → 학습) ‘정제’ 단계와 별도의 단계로 추론 데이터 정제 단계는 추론형 데이터의 사고과정 자체를 대상으로 점검하여 보완하는 단계

4.3.2.2 품질관리 활동

구분	내용
중복 제거 (Deduplication)	- 정확 일치 및 근사 일치를 먼저 적용한 뒤 임베딩 기반 클러스터링(cosine similarity, MinHash 등)을 사용해 의미적 중복을 탐지 - 거의 동일한 의미의 변형본을 식별하고, 난이도·문체·예시 차이를 고려해 적정 데이터만 남기도록 규칙을 적용
저품질 사고과정의 단계 축약·정제	- 동일 추론을 장황하게 반복하는 단계는 축약 규칙(중복 단계 병합, 불필요 설명 제거)을 적용해 핵심 추론 흐름만 보존 - 단계 누락이나 불명확한 단계는 태깅하여 재검토
문장 노이즈 수정	- 맞춤법·문법 교정, 비표준 약어 정규화, 숫자·단위 표기 통일 등을 처리 - 기계가 읽기 쉬운 표준 텍스트로 변환
이상치(Anomaly) 및 저품질 탐지	구조적 이상치(비정상적 길이, 비정형 토큰 비율)와 의미적 이상치(논리 단절, 무관한 내용)를 규칙·모델 기반으로 탐지하여 자동격리 또는 검수 대상으로 태그
할루시네이션 필터링	사실성 검증 모듈과 연계해 근거가 없는 주장·오류 수치를 제거하거나 ‘근거 없음’으로 라벨링하고 필요 시 Fact-checking으로 재생성 트리거를 표시
스타일·형식 표준화	- 추론 단계 명명법, 문장 시작·종결 패턴, 인용·수식 표기 등 스타일 가이드를 적용 - 전체 데이터의 일관성을 확보
메타데이터 보강 및 정합성 검사	샘플의 생성 프롬프트, 모델 버전, 샘플링 파라미터를 보완·정리하여 추적성(traceability) 및 필터링(예: 특정 모델 버전만 학습)에 활용
Human-in-the- Loop(HITL)	고난도·애매 항목은 전문가 검수 큐에 올려 최종 품질을 확보
지표화 및 피드백	정제 전후의 품질 지표(중복률, 할루시네이션 비율, 평균 사고과정에 대한 길이 등)를 기록하여 정제 규칙을 지속 개선하고, 생성·검증 단계로 피드백을 반환

[표 II-73] 추론형 데이터 정제 품질관리 활동

4.3.2.3 품질관리 기술

구분	내용
사고과정에 대한 의미적 중복 제거	• 사고과정 문장 또는 전체를 임베딩 벡터로 변환한 뒤 의미적 유사도를 계산하여 사실상 동일하거나 매우 유사한 데이터를 자동으로 탐지·제거 • 표현만 다르고 의미가 거의 동일한 데이터의 과잉 축적을 방지하고 학습데이터의 다양성과 효율성을 확보하는 것이 목적 • 핵심 구성요소로는 텍스트 임베딩 모델, 유사도 측정 방식(cosine similarity 등), 임계값 기준, 클러스터링/근접 탐색 알고리즘(HNSW 등)으로 이루어짐 • 실행방법 ① 대상 데이터의 임베딩 생성(샘플링 등 기준에 맞춰 수행) ② 벡터 간 유사도 계산 ③ 임계값 이상 그룹을 중복 후보로 분류 ④ 대표 샘플 선택 또는 병합 ⑤ 중복 제거 결과 확인 및 검토
사고과정의 이상치 탐지	• 정상적인 추론 패턴에서 벗어난 비정상 데이터 (구조적 오류, 극단적 길이, 비논리적 내용, 무관한 텍스트 등)를 자동으로 식별하는 방법 • 데이터 품질을 저해하는 비정형·노이즈 데이터, 모델이 잘못 학습할 위험이 있는 오류를 사전에 제거하여 학습 안정성과 신뢰성을 높이는 것이 목적 • 핵심 구성요소로는 통계 기반 특징(길이, 토큰 분포), 임베딩 기반 군집 밀도, 규칙 기반 탐지 기준, 비지도 학습 모델(LOF, Isolation Forest 등)으로 구성 • 실행방법 ① 데이터(샘플)의 구조·길이·임베딩 특징 추출 ② 정상 분포 대비 이상 패턴 계산 ③ 임계값 초과 데이터(샘플)을 이상치로 태깅 ④ 이상치 검수 또는 자동 제거 ⑤ 제거 로드 점검 및 재평가
환각 및 허위정보 필터링	• 모델이 생성한 추론데이터의 사고과정이나 답변 속에서 사실 기반이 없거나 근거가 부정확한 내용을 자동으로 탐지·제거하는 방법 • 잘못된 지식, 왜곡된 근거, 비사실적 추론이 학습데이터에 유입되는 것을 차단하고 모델의 사실성·신뢰성을 유지하는 것이 목적 • 핵심 구성요소는 사실 검증 모듈(Fact-checker), 지식베이스 매칭, 근거 일치성 판단 알고리즘, 신뢰도 점수 스케일링 등이 있음 • 실행방법 ① 주요 사실 단위 추출 ② 외부 지식·Fact-checking 으로 사실 여부 판단 ③ 낮은 신뢰도 또는 근거 불일치 내용 태깅 ④ 오류 부분 수정 또는 해당 데이터 제거 ⑤ 최종검토 순으로 진행

노이즈 수정	- 추론형 데이터에서 발생하는 문법 오류, 비표준 표기, 불필요 반복, 의미 불명확 표현 등 다양한 텍스트 노이즈를 체계적으로 탐지하고 자동으로 정정하는 방법 - 데이터 품질을 향상하고 학습과정에서 모델이 불필요한 오류 패턴을 학습하지 않도록 안정적인 학습 환경을 제공하는 것이 목적 - 핵심 구성요소는 문법·맞춤법 교정기, 표준화 규칙 세트, 임베딩 기반 의미 정합성 검사, 오류 로그 및 자동 수정 모듈로 구성 - 실행방법 ① 데이터 입력 ② 문법 및 표기 오류 탐지 ③ 규칙·모델 기반 자동 수정 ④ 의미적 오류 및 중복 표현 검증 ⑤ 수정 완료된 데이터 검수 및 기록
추론 단계 축약 점검	- 추론 데이터에서 반복되거나 불필요하게 중복된 추론 단계(step)을 식별하고 축약하여 핵심 논리 흐름으로 데이터를 구성할 수 있도록 점검하는 방법 - 과도하게 반복된 단계, 표현을 제거하여 사고과정의 간결성을 확보하고 학습데이터의 효율성과 모델 학습 속도 향상이 목적 - 핵심 구성요소는 중복 탐지 알고리즘(문장 유사도, 임베딩 기반 클러스터링), 단계 병합 규칙, 불필요 단계 식별 기준, 검수 및 로그 기록 모듈로 이루어짐 - 실행방법 ① 추론데이터의 각 단계별 임베딩 생성 ② 유사도 계산으로 중복 단계 점검 /휴먼검수를 통한 단계 중복 탐지 ③ 병합 또는 제거 대상 결정 ④ 불필요한 추론 단계(step) 축약 및 재배치 ⑤ 최종 추론데이터 검수
사고과정의 스타일 표준화	- 추론데이터의 사고과정 및 답변 데이터상에서 문체, 문장 구조, 수식 및 단위 표기법, 단계 표기형식 등 표현 방식을 일관된 규칙에 맞추어 표준화하는 방법 - 데이터셋 전반의 표현 일관성을 확보하여 모델 학습 시 불필요한 변형 학습을 방지하고 검증·평가 자동화와 재현성을 제고하는 것이 목적 - 핵심 구성요소는 표현 스타일, 단계 및 문장 작성 규칙 등으로 구성 - 실행방법 ① 사고과정에 대한 스타일, 작성 규칙 수립 ② 추론 단계, 문장구조 분석 ③ 문체·표기·단계 표준화 적용 ④ 수정 사항 검수 및 로그 기록 ⑤ 표준화 수행 재점검

[표 II-74] 추론형 데이터 정제 품질관리 기술

4.3.2.4 품질관리 체크리스트

구분	체크리스트
중복 (Deduplication)	- 동일 또는 의미상 유사한 데이터가 제거되었는가? - 임베딩 기반 유사도 측정으로 의미적 중복까지 확인했는가? - 중복 제거 후 데이터 대표 데이터가 특성이 유지되었는가?
저품질 사고과정 정제	- 불필요하게 길거나 반복된 추론 단계가 축약되었는가? - 논리 비약이나 모호한 단계가 식별되어 수정되었는가? - 핵심 추론 흐름이 유지되면서 중복/불필요 단계가 제거되었는가?
문장노이즈 수정	- 맞춤법, 문법, 단위·숫자 표기 오류가 교정되었는가? - 비표준 약어, 특수문자 등 노이즈가 제거되었는가? - 의미 불명확한 표현이나 불필요 반복이 수정되었는가?
의미적 중복 및 유사 패턴 제거	- 의미상 거의 동일한 변형본이 탐지되고 제거되었는가? - 난이도·문체·예시 차이를 고려하여 적절한 데이터만 남겼는가?
이상치(Anomaly) 탐지	- 구조적 이상치(길이, 토큰 분포 등)가 식별되었는가? - 의미적 이상치(논리 단절, 무관 내용)가 제거되었는가?
환각 필터링	- 사실 기반이 없는 내용, 왜곡된 근거가 제거되었는가? - Fact-checking 모듈과 연계하여 근거 없는 정보가 검증되었는가?
스타일 표준화 (Style Normalization)	- 사고과정에 대한 단계 표현형식, 문장 구조, 문체, 표기법 등 이 통일되었는가? - 표준화 규칙 적용 후 데이터셋 전반의 일관성이 확보되었는가?
최종 품질 판정	- 정제 전/후 품질 지표(중복률, 노이즈 비율, 사고 과정 서술 길이 등)를 기록했는가? - Human-in-the-Loop 검수 후 승인 절차를 완료했는가? - 수정 내역과 로그가 품질관리 시스템에 저장되었는가?

[표 II-75] 추론형 데이터 정제 품질관리 체크리스트

II

4.3.3 추론데이터 품질검사(2차)

4.3.3.1 목적

- 품질검사(1차) 및 추론 데이터 정제 단계를 거친 데이터셋 전체의 품질 수준을 객관적·정량적으로 평가
- 이를 통해 데이터셋이 학습 목적에 부합하는지, 모델 성능 향상에 기여할 수 있는지를 판단하고 평가 결과는 저품질 데이터의 재구축 여부와 추가 정제 필요성을 결정하는 기준으로 활용
- 품질검사(2차) 단계는 데이터셋의 논리적 일관성, 사실성, 다양성, 분포 균형 등을 종합적으로 분석하고 품질을 종합 점수로 환산하며 궁극적으로 데이터 평가를 통해 추론형 AI 모델 학습에 최적화된 고품질 데이터셋을 확보하는 것이 목적
- 품질검사(1차)→ 추론데이터 정제 → 품질검사(2차) 2단계의 품질검사 단계로 품질관리 활동을 수행하여 사고과정(추론경로 등)의 오류, 사고과정의 논리/근거/일관성을 확보

4.3.3.2 품질관리 활동

- 논리적 일관성, 근거의 정확성, 데이터셋 분포·다양성, 저품질 샘플 식별 등 다양한 측면을 정량·정성적으로 점검하며, 그 결과를 기반으로 재정제·재구축 여부를 판단
- 추론 단계별 논리적 일관성과 결론의 적합성을 확인하여 추론 품질을 평가하며 각 단계에서 제시된 근거가 충분하고 사실에 부합하는지 검증하여 근거 기반 점수를 산출
- 문제 유형, 정답 유형, 사고과정 길이 등 데이터 분포와 다양성을 분석해 학습 편향을 확인하며 데이터셋 내 주제, 난이도, 문체 등 표본 대표성을 평가하여 균형성을 점검 후 평가 점수가 기준치 이하인 저품질 샘플은 자동으로 태깅하여 후속 조치 대상으로 분류

4.3.3.3 품질관리 기술 및 지표

- 품질검사 및 관리를 위한 기술 및 지표 활용 방안

구분	내용
추론 품질 점수(RQS) 활용	• 추론 데이터에서 사고과정 즉 추론 단계가 존재하는 경우 각 단계별 논리적 일관성, 근거 제시 적합성, 결론 도출 정확성을 종합적으로 평가하여 수치화 • 데이터셋의 추론 품질을 정량화하고 저품질 샘플을 식별하여 보완 여부를 결정하는 기준을 제공하는 것이 목적 • 핵심 구성요소는 논리 일관성 평가 모듈, 근거 적합성 평가 모듈, 단계별 결론 도출 적합성 점수, 종합 점수 산출 알고리즘으로 이루어짐 • 실행방법 ① 추론 단계 분석 ② 각 단계의 논리적 연결성 평가 ③ 근거 및 결론 적합성 점수 산출 ④ 데이터의 RQS 계산 ⑤ 기준값과 비교하여 저품질 샘플 태깅
일관성 점수 활용	• 추론데이터에서 단계간 논리적 연결성과 흐름의 일관성을 평가하여 수치화한 지표로 추론 데이터의 논리적 연속성과 추론 흐름의 명료성을 정량적으로 측정하고 저품질 또는 불일치 데이터를 식별하는 것이 목적 • 핵심 구성요소는 단계 간 논리적 연결성 평가 모듈, 문장 및 단계 구조 분석, 유사도·연관성 점수 산출 알고리즘 등으로 이루어짐 • 실행방법 ① 각 사고과정의 단계 추출 ② 단계 간 논리적 연결 및 연관성 분석 ③ 연결 불일치 여부 점검 ④ 일관성 점수 계산 ⑤ 기준값과 비교하여 저일관성 샘플 태깅
편향 지수 활용	• 데이터셋 내 특정 주제, 그룹, 정답 유형 등이 과도하게 편중되어 있는 정도를 정량화하는 지표로 데이터셋에서 발생할 수 있는 편향을 사전에 식별하고 모델이 특정 방향으로 치우친 추론을 학습하는 위험을 줄이는 것이 목적 • 핵심 구성요소는 데이터 범주별 샘플 비율, 그룹·속성 분포 분석, 편향 계산 알고리즘, 정규화 지표 등으로 구성 • 실행방법 ① 데이터셋 내 범주 및 속성 분포 수집 ② 편향 지수 계산 ③ 기준값과 비교 ④ 기준치 초과 시 데이터 보강 또는 재샘플링 ⑤ 편향 수정 결과 검증

출처·생성기록에 대한 완전성 점수 활용	• 데이터의 생성된 출처, 생성 과정, 검증 기록 등 관련 메타데이터가 얼마나 완전하게 기록되어있는지를 정량화한 점수로 데이터 출처와 생성 과정의 투명성을 확보하고 추후 검증, 재구축 시 신뢰할 수 있는 근거 자료를 제공하는 것이 목적 • 핵심 구성요소는 데이터식별 정보, 데이터 생성 일자·방법, 검증 및 정제 기록, 출처 신뢰도 지표, 점수 계산 알고리즘으로 이루어짐 • 실행방법 ① 각 샘플의 메타데이터 (데이터의 출처, 생성과정 등이 기록된) 수집 ② 필수 항목 누락 여부 확인 ③ 완전성 점수 산출 ④ 기준치 미달 샘플 태깅 ⑤ 누락 정보 보강 또는 재검증
근거 기반 점수 활용	• 사고과정 또는 답변 데이터가 제시한 결론과 추론이 실제 근거, 사실, 규칙에 얼마나 기반하고 있는지를 정량화한 점수 • 데이터셋의 추론 및 답변이 신뢰할 수 있는 근거를 바탕으로 생성되었는지를 평가하고 근거 부족으로 인한 오류 학습을 방지하는 것이 목적 • 핵심 구성요소는 사실 검증 모듈, 근거-결론 매칭 알고리즘, 근거 신뢰도 점수 산출 등으로 구성 • 실행방법 ① 사고과정 단계별 근거 추출 ② 외부 지식베이스 및 참조 자료와 근거 일치 여부 확인 ③ 근거 적합성 점수 산출 ④ 기준치 미달 샘플 태깅 ⑤ 필요 시 수정 또는 재검증
포괄성 및 다양성 지표 활용	• 데이터셋이 다루는 문제 유형, 주제영역, 난이도, 정답 유형 등이 얼마나 포괄적이고 다양하게 포함되어 있는지를 정량화한 지표 • 데이터셋의 학습 범위와 대표성을 평가하고 특정 유형이나 영역에 편중되지 않도록 하여 모델 일반화 능력 향상이 목적 • 핵심 구성요소는 문제 유형 분포, 정답 유형 분포, 난이도 분포, 문체/표현 다양성 분석 모듈, 지표 산출 알고리즘으로 이루어짐 • 실행방법 ① 데이터셋 내 속성 및 범주 분석 ② 각 속성별 분포 계산 ③ 포괄성 및 다양성 점수 산출 ④ 기준치 미달 영역 확인 ⑤ 필요 시 데이터 보강 및 재검증 • 특정 문제 유형 과다 또는 과소, 반복 패턴, 난이도 편중 등을 식별하여 모델이 균형잡힌 추론과 일반화를 학습하도록 지원

[표 II-76] 품질검사(2차) 주요 품질관리 기술

4.3.3.4 품질검사(2차) 품질관리 체크리스트

구분	체크리스트
추론 품질 점수 (Reasoning Quality Score, RQS)	- 사고과정의 단계별 논리적 연결성과 결론 도출 적합성을 평가했는가? - 단계 간 비약, 모순, 근거 부족 등 문제를 점수화했는가? - 기준점 이하 데이터를 태깅하고 재검증 대상으로 분류했는가?
일관성 (Coherence Score)	- 사고과정 내 추론 단계 간 흐름과 연결성이 유지되는가? - 일관성 점수를 산출하고 기준치 미달 샘플을 식별했는가? - 단계 누락, 논리 비약 등 문제를 재정제 또는 재구축 대상으로 지정했는가?
편향 지수 (Bias Index)	- 데이터셋 내 특정 문제 유형, 그룹, 속성 편중 여부를 점검했는가? - 계산된 편향지수를 기준치와 비교하고 필요한 보강 조치를 결정했는가?
출처·생성 기록 (Provenance Completeness Score)	- 각 데이터의 출처, 생성 과정, 검증 기록이 완전하게 존재하는가? - 누락된 메타데이터를 보강하거나 재검증을 수행했는가?
근거 기반 평가 (Groundedness Score)	- 사고과정과 답변이 사실과 규칙에 기반하고 있는지 검증했는가? - 근거 부족, 오류, 비논리적 추론 샘플을 식별했는가?
포괄성 및 다양성 (Coverage & Diversity Metrics)	- 문제 유형, 난이도, 주제, 정답 유형 분포가 균형 있게 구성되었는가? - 특정영역 과대/과소 대표 문제를 식별하고 데이터 보강 계획을 수립했는가?
종합 점수 및 재구축 판단	- 각 지표별 점수를 종합하여 데이터셋 품질 상태를 평가했는가? - 저품질, 편향, 근거 부족 데이터에 대해 재정제·재구축 여부를 결정했는가? - 평가 결과를 기록하고 품질관리 시스템에 로그를 저장했는가?

[표 II-77] 품질검사(2차) 품질관리 체크리스트

4.3.3.5 데이터 보완 방법 및 고려사항

- 추론 데이터 검사(1차) → 추론데이터 정제 → 추론 데이터 검사(2차) 이후 검사 결과 기준 데이터 보완 수행
- 점수가 낮거나 근거 부족으로 식별된 데이터셋들을 수정하거나 재생성하는 보강작업을 수행
- 추론 단계별 추론 흐름과 결론 도출이 일관되도록 재작성하거나 단계 추가·조정을 통해 논리적 일관성을 재검증하여 근거기반 점수가 낮은 데이터에 대해 신뢰할 수 있는 근거 추가 및 보완 수행
- 편향 분석 결과 특정 그룹·유형의 과대/과소 대표를 개선하기 위해 데이터를 추가하거나 재샘플링하는 것을 통해 편향을 보정하고, 다양성 기준을 충족하도록 문제 유형, 난이도, 문제, 정답 유형을 보강하여 포괄성 및 다양성 확보
- Provenance Completeness Score를 기준으로 생성기록, 출처, 검증 로그를 추가하여 (출처·메타데이터 보강) 추적 가능성을 확보하고 LLM이나 자동화 도구를 활용하여 저품질 또는 누락 데이터를 체계적으로 재생성
- 재구축 데이터셋을 HITL 검수 또는 자동 검증 모듈로 최종 점검하여 재검증하고 최종 승인하고 재구축 데이터셋을 기존 데이터셋에 통합하고, 변경 내역과 품질 지표를 기록

구분	내용
LLM 활용 데이터 재구성	• 저품질, 불완전, 일관되지 않은 데이터를 LLM을 활용하여 자동으로 재생성·보강 • 평가 및 정제 단계에서 식별된 문제점을 신속하게 개선하고 데이터셋의 논리적 일관성, 근거 신뢰성, 추론 품질을 향상시키는 것이 목적 • 핵심 구성요소는 저품질 데이터 식별 모듈, LLM 기반 자동 재생성 엔진, 근거 보강 알고리즘, 품질점수 재산출 모듈로 이루어짐 • 실행방법 ① 평가·정제 단계에서의 이슈데이터 추출 ② LLM에 자동 재생성 프롬프트 적용 ③ 사고과정 재구성 및 근거 보강 ④ 추론형 구조 및 논리 일관성 검증 ⑤ 품질점수 재평가 후 검토

적대적/반사실적 데이터 보완	• 기존 데이터를 기반으로 의도적으로 난이도를 높이거나 반사실적 조건을 적용하여 새로운 학습데이터를 생성하는 방법 • 모델의 추론 강건성(시스템이나 모델이 외부 환경 변화, 잡음, 예외 상황, 입력 변동 등 예상치 못한 조건에서도 성능을 유지하거나 안정적으로 동작하는 능력)과 일반화 능력을 향상하고 데이터셋 내 편향, 취약성, 논리적 결함을 보완하는 것이 목적 • 핵심 구성요소는 기존 샘플 분석 모듈, 반사실적 변형 생성 알고리즘, 논리·근거 일관성 검증 모듈, 재평가 점수 산출 엔진으로 구성 • 실행방법 ① 기존 데이터 선택(샘플데이터 선별 등) ② 반사실적 조건 또는 적대적 변형 적용 ③ 추론데이터에 대한 구조, 근거 검증 ④ Quality, Coherence, Groundedness 등 점수 산출 ⑤ 기준치 충족 시 데이터셋 통합 • 논리적 오류, 근거 부족, 추론 비약 문제를 사전에 방지하여 모델 학습 시 발생할 수 있는 다양한 상황에 대한 대응력을 강화할 수 있음
난이도 균형 조정	• 데이터셋 내 문제 샘플의 난이도를 분석하고 학습 데이터 분포를 균형 있게 조정 • 모델이 특정 난이도에 과도하게 편향되지 않고 쉬운 문제부터 어려운 문제까지 고르게 학습하도록 하여 일반화 능력과 추론 강건성 향상이 목적 • 핵심 구성요소는 난이도 평가 모듈, 난이도 기준 및 구간 설정, 데이터 재배포 또는 재생성 엔진, 품질 점수 재산출 모듈로 구성 • 실행방법 ① 데이터셋 샘플별 난이도 평가 ② 난이도 분포 분석 ③ 특정 난이도 과대/과소 데이터 식별 ④ 난이도 균형을 위한 데이터 보완, 재생성 등 수행 ⑤ 보완 데이터 반영 후 검토
Self-evolution (자기진화) 파이프라인	• 기존 데이터와 모델의 결과값을 기반으로 자동 피드백, 개선, 재생성을 반복하여 데이터셋을 점진적으로 향상시키는 방법 • 저품질, 불완전하고 편향된 데이터를 지속적으로 개선하고 데이터셋 품질과 모델 학습효과 점진적 향상이 목적 • 핵심 구성요소는 자동 평가 모듈, 개선 전략 엔진, LLM 기반 재작성/보강 모듈, 품질 점수 재산출 모듈, 피드백 순환 시스템으로 구성 • 실행방법 ① 기존 데이터 품질 평가 ② 문제 샘플 식별 ③ 재생성 및 근거/논리 개선 ④ 품질점수 재산출 ⑤ 개선 결과 반영, 이후 반복적 피드백 수행 ⑥ 기준 충족시 데이터셋 통합

능동 학습 기반 데이터 재생성	• 모델이 학습 중 불확실성을 보이는 샘플을 식별하고 이를 중심으로 데이터셋을 재생성 및 보강하여 학습 효율을 높이는 방법 • 저품질 또는 학습효과가 낮은 데이터를 선별적으로 개선하여 모델의 일반화 능력과 추론 강건성을 향상이 목적 • 핵심 구성요소는 모델 불확실성 측정 모듈, 저품질 샘플 선정 엔진, LLM 기반 재작성/보강 모듈, 품질 점수 재산출 시스템, 재통합 및 검증 모듈로 구성 • 실행방법 ① 학습 모델 실행 후 불확실성이 높은 데이터 식별 ② 해당 데이터 재작성 또는 보강 ③ 사고과정, 구성된 단계 등에 대한 구조 및 근거 검증 ④ 품질 점수 재산출 ⑤ 기준치 충족 시 데이터셋 통합 ⑥ 반복 학습 및 검증
휴먼 검수자 활용 (HILR)	• 자동화된 데이터 재구축 과정에서 인간 검수자(Human) 피드백을 결합하여 모델과 데이터 품질을 지속 향상하는 방법 • 데이터 재생성이나 보완 과정에서 발생할 수 있는 오류, 논리 비약, 근거 부족 등을 검수자(전문가)의 판단으로 보완하고 데이터셋과 모델 학습 품질을 안정적으로 개선 • 핵심 구성요소는 자동 재구축 모듈, 인간 검수 인터페이스, 피드백 통합 시스템, 품질 점수 재산출 모듈, 반복 학습 및 개선 루프로 구성 • 실행방법 ① 저품질 데이터 식별 ② 해당 데이터 재작성 또는 보강 ③ 휴먼 검수자(전문가) 피드백 수집 ④ 피드백 기반 데이터 보완 ⑤ 품질점수 재산출 및 개선된 데이터셋 통합 ※ 위 과정을 반복적으로 수행

[표 II-78] 데이터 보완 방법 및 고려사항

4.3.3.6 보완데이터 품질관리 체크리스트

- 추론 데이터 검사(1차) → 추론데이터 정제 → 추론 데이터 검사(2차) 결과를 바탕으로 보완이 완료된 데이터를 기준으로 보완의 완전성 확인/확보 위한 품질점검 체크리스트 수행
- 가공프로세스 중 품질관리 활동의 최종 단계로 즉, ‘검수까지 완료된 최종 가공데이터’라 할 수 있으며, 완료된 데이터는 AI 모델에 학습

구분	체크리스트
저품질 데이터 보완	• 평가·정제 단계에서 저품질 데이터를 식별했는가? • 해당 데이터를 재작성, 근거 보강, 단계 재구성 등의 방식으로 개선했는가?
AI 모델 기반 재생성	• AI 모델을 활용하여 논리 비약, 근거 부족, 문장 노이즈를 보강했는가? • 재작성 후 사고과정의 구조, 근거 및 논리 일관성을 검증했는가?
적대적/반사실 보완	• 반사실적/적대적 변형을 통해 데이터셋 다양성과 강건성을 강화했는가? • 생성된 데이터의 논리적 일관성과 근거를 검증했는가?
난이도 균형 조정 (Difficulty Rebalancing)	• 데이터셋 내 난이도 분포를 분석하고, 편중된 난이도 데이터를 보강했는가? • 난이도 균형 재조정 후 학습 데이터셋의 일반화 가능성을 평가했는가?
자기진화 파이프라인 (Self-evolution Pipeline)	• 피드백 기반 반복 개선을 통해 데이터 품질을 지속적으로 향상했는가? • 재구축 후 품질 점수와 메타데이터를 기록했는가?
능동 학습 기반 데이터 재생성 (Active Learning Data Regeneration)	• 학습 모델의 불확실성 높은 데이터를 선별하여 재생성했는가? • 재생성된 데이터에 대해 사고과정의 구조와 근거 검증을 수행했는가?
인간 개입 강화 (Human-in-the-Loop Reinforcement)	• 자동 재구축 과정에 인간 검수자의 피드백을 반영했는가? • 피드백 기반 수정과 품질 점수 재평가를 통해 최종 데이터를 데이터셋에 통합했는가?
종합 점검	• 모든 재구축 데이터가 논리적 일관성, 근거 신뢰성, 난이도 균형, 다양성 기준을 충족하는가? • 재구축 과정과 결과를 품질관리 로그에 기록하고, 재반복 계획을 수립했는가? (재반복 계획은 구축 데이터에 따라 필요한 경우 진행)

[표 II-79] 보완데이터 품질관리 체크리스트

AI 데이터 품질관리 가이드라인 v4.0

제4권

추론형 AI 데이터를 중심으로

신기술 AI 데이터 품질관리 가이드 v1.0

III

추론형 AI 주요기술

제1장 | 추론형 AI 기법

제2장 | 추론형 AI 주요 모델

제1장

추론형 AI 기법

1

개요

- 추론의 유형 및 추론형 AI 데이터 구축방식은 생성 방식, 구조 기반, 데이터 품질표현 방식, 학습 목적, 구조 수치기반 등 데이터 구축 방식에 따라 다양한 형태로 분류됨
- 이러한 분류방식은 현재에도 기술의 발전에 따라 꾸준히 하위 기술이 새로 개발되고 있어 데이터 구축 방식과 분류 구분이 1:1로 매칭되지 않으므로 다양한 형태의 분류 방식이 존재함

분류기준	종류	내용
생성방식	Standard CoT	● 모델이 자동으로 생성하는 단계적 추론
	Self-Consistency CoT	● 여러 CoT를 생성하여 가장 일관성이 높은 답변을 선택하는 방식
	Few-shot CoT	● 예시의 CoT를 제공하여 모델이 비슷한 형식으로 추론을 유도하는 방식
	Zero-shot CoT	● “Let's think step-by-step”과 같은 프롬프트만으로 CoT를 유도
	Program-aided CoT	● 추론과정 일부를 코드·프로그램으로 계산하며 논리를 구성
구조 기반	Linear CoT	● 가장 기본적인 단계별 직선형 추론 구조 방식
	Tree-of-Thought (ToT)	● 가지치기 가능한 추론 경로를 트리 형태로 탐색하는 방식
	Graph-of-Thought (GoT)	● 추론 단계를 그래프 구조로 연결하여 병렬 추론, 여러 경로의 결합 및 재조합을 통해 다양한 추론 경로 생성 및 탐색
	Flow-of-Thought(FoT)	● 외부 도구 호출, 증거 검색, 사고과정, 상태를 반복적으로 반영하는 흐름 기반 추론
	Embedding CoT	● 추론 단계를 임베딩으로 구조화하여 일관성 검증, 패턴 분석, 품질측정에 활용하는 방식
데이터 품질 및 표현방식	Structured CoT	● SON·template 기반으로 추론 단계를 구조적으로 기재
	Explain-then-Solve CoT	● 설명(근거)를 먼저 생성한 후 이후 답을 도출하는 방식
	Visual CoT	● 이미지·비디오 사고과정에서 시각적 근거를 포함한 방식
	Knowledge-grounded CoT	● 특정 지식(위키, 문헌 등)을 기반으로 하고, 출처를 명시하는 방식
	Embedied CoT	● 로봇/에이전트의 관측과 상태 기반 추론과정 생성 및 행동 결정 방식
학습목적	Error-minimizing CoT	● 오답 경로를 학습해 해결 전략을 최적화하는 방식
	Robust CoT	● 잡음, 모호한 입력에도 안정적인 사고과정을 도출하는 방식
	Sparse CoT	● 불필요한 단계를 줄이고 최소 단계로 문제를 해결하는 방식

[표 III-1] 분류 기준에 따른 다양한 추론형 AI 기법

- 본 가이드에서는 추론형 AI 구조, 구조 기반 파생 기법, 도메인/표현 확장 기법을 중심으로 기술 개념, 적용 사례를 안내

※ 2025년 초거대 AI 확산 생태계 조성 사업에서 구축한 데이터인 CoT 기법을 중심으로 안내

1.1 추론형 AI 기본 구조

구분	의미	내용	
추론형 AI 기본 구조	추론을 수행·구성 하는 기본 설계(구조/흐름)	CoT	• 중간 추론을 전개하여 답변 도출을 유도하는 기법
		CoT-SC	• 여러 추론 경로를 샘플링하여 일치한 답을 선정하는 기법
		ToT	• 생각을 트리로 분기해 탐색하여 답변을 선택하는 기법
		GoT	• 생각 단위를 그래프로 연결해 추론을 조합하는 기법

[표 III-2] 추론형 AI 기본 구조

1.2 추론형 AI 기본 구조 파생 및 강화 기법

구분	의미	내용	
파생·강화 기법	기본 추론 구조를 기반으로 성능/유용성을 확장한 주요 기법	ReAct	• 추론과 행동을 교차해 도구로 정보를 보강하는 기법
		Reflexion/ Self-Reflection	• 자기 출력을 평가·수정해 다음 시도를 개선하는 루프 기법
		Multi-Agent Reasoning(MAR)	• 여러 에이전트가 역할을 분담해 합의로 추론하는 기법
		Tool-Augmented /Retrieval- Augmented Reasoning	• 도구 검색 결과를 통합해 추론 근거를 확장하는 기법

[표 III-3] 파생 및 강화 추론 기법

1.3 도메인/표현 확장 추론 기법

구분	의미	내용	
도메인/ 표현 확장 기법	특정 환경 또는 특정 표현 공간에 맞춰 추론 방식을 변경·적용	Embedding CoT	• 추론결과를 임베딩으로 압축해 재사용하는 기법
		Embodied CoT	• 물리환경과 상호작용을 기반으로 추론을 수행하는 기법

[표 III-3] 도메인/표현 확장 기법


2

추론형 AI 기본 구조

2.1 CoT

- LLM의 비약적 발전과 함께 복잡한 추론형 질문 처리 필요성 증대로 기존 LLM은 정답 생성은 우수하지만, 중간 사고 과정의 불투명성으로 인해 일관성·신뢰성 문제가 발생하여 이를 해결하기 위한 방법론으로 CoT를 제안
- CoT는 모델이 단순히 답변을 생성하는 것이 아니라, 문제 해결의 단계별 사고 과정을 자연어 형태로 명시적으로 생성하도록 유도하는 기법으로 인간의 “사고 흐름(thought process)”을 모방하는 형태의 추론 중심 프롬프팅 기법
- 입력과 중간 추론 단계, 출력으로 구성
- LLM 내부의 확률적 언어 모델링을 활용하여 중간 사고 경로를 확률적으로 탐색하고 “문제 → 사고 흐름 생성 → 결과 도출” 과정의 내적 경로를 언어적으로 단계별 표현

CoT 구조 및 작동원리



[그림 III-1] CoT 구조 및 작동원리

※ 출처: <https://arxiv.org/pdf/2210.03493>

2.1.1 CoT의 주요 적용 사례

- 수리적 추론 (Mathematical Reasoning)
 - CoT를 수학 문제 적용시 복잡한 수리 문제를 여러 추론 단계로 분해하여 모델이 체계적으로 문제를 해결 할 수 있게 도움을 주고 계산 오류, 단순 누락된 단계, 논리 비약을 축소
 - 설명 가능한 사고 과정을 제공해 모델의 추론이 어떻게 진행되었는지를 사람이 이해하고 검증할 수 있도록하여 특히 계산 + 심볼릭 + 언어 기반 수학 문제에서 성능 향상
 - 모델의 추론 투명성과 신뢰성을 동시에 높이는 효과가 있으며 실제로 GSM8K, MATH, AQUA-RAT 등의 데이터셋에서 CoT 적용 시 정확도가 상승함을 보여줌

수리추론 사례 문제

함수 $f(x)=x^3-3x+1$ 이 있다.

- (1) 함수의 증가·감소 구간을 구하라.
- (2) 극값을 구하고 그래프의 형태를 설명하라.
- (3) $f(x)=0$ 의 실근의 개수를 증가·감소 분석을 이용하여 판단하라.

CoT 풀이 예시

Step 1 — 도함수 계산

증가·감소 분석을 위해 $f'(x)$ 을 구함 $f'(x) = 3x^2 - 3 = 3(x^2 - 1)$

Step 2 — 임계점 찾기. $f'(x) = 0 \Rightarrow x^2 - 1 = 0 \Rightarrow x = -1, 1$

Step 3 — 구간별 부호 분석.

$x < -1 : x^2 - 1 > 0$, 증가

$-1 < x < 1 : x^2 - 1 < 0$, 감소

$x > 1$: 증가

따라서 증가-감소-증가 형태

Step 4 — 극값 계산

$f(-1) = -1 + 3 + 1 = 3 \Rightarrow$ 극대, $\rightarrow f(1) = 1 - 3 + 1 = -1 \Rightarrow$ 극소

Step 5 — 실근 판단

함수는 증가-감소-증가 형태이므로 반드시 실근이 1개 이상 존재

또한 $f(-2) = -8 + 6 + 1 = -1 < 0$

$f(0) = 1 > 0$ 이므로 하나의 실근

또 $f(1) = -1 < 0$, $f(2) = 8 - 6 + 1 = 3 > 0$ 이므로 또 하나의 실근

최종적으로 실근은 3개

● 상식추론 및 다단계 QA

- CoT는 질문에 포함된 단서를 여러 단계로 연결하여, 상식 기반 추론이나 다중 문장·다중 증거를 요구하는 복합적 질의에 대해 더 정확한 답을 생성하도록 지원
- 특히 상식추론에서 숨겨진 전제(implicit commonsense)를 언어적으로 풀어 쓰는 데 효과적이며, 다단계 QA에서는 문맥 간 관계 연결(multi-hop linking)을 강화하여 기존방식보다 정답률이 높아지고, 오류 분석과 모델 신뢰성 평가 용이
- 이는 복잡 질문 응답 시스템, 검색 기반 QA, 대규모 지식 추론 작업에서 CoT의 핵심적인 활용 가능
- StrategyQA*, HotpotQA** 등에서 단계적 근거 탐색을 강화하고 Zero-shot CoT prompting을 통해 fine-tuning 없이도 추론 성능 향상

* 단일 문장으로 답변 가능한 간단한 사실 기반 질문이 아니라, 정답을 도출하기 위해 여러 개의 숨겨진 중간 추론 단계(implicit reasoning steps)가 필요한 질의응답(QA) 벤치마크

** 명시적인 Multi-hop 추론을 요구하는 대규모 질의응답 벤치마크로, 정답을 얻기 위해 여러 문서(또는 문단)를 넘나드는 근거 결합(evidence chaining)이 필수적인 데이터셋

상식추론 사례

Q.

한 실험실에서 온도 센서를 교체한 뒤부터, 동일한 환경에서도 온도 데이터의 분산이 크게 증가하기 시작했다. 연구원들은 냉각장치의 성능 저하를 의심했지만, 냉각장치 점검 결과 이상이 없었다. 이 상황에서 가장 가능성이 높은 원인은 무엇일까?

설명(CoT)

냉각장치는 정상 → 외부 환경은 동일

분산 증가 → 평균값이 아니라 측정의 일관성 문제

새 센서 이후 발생 → 원인은 센서 자체 특성

즉, 새로운 센서가 기존보다 노이즈가 크거나 정밀도가 낮은 모델일 가능성이 가장 높음

A.

센서 자체의 정밀도(precision)가 기존보다 떨어지는 모델로 교체되었기 때문

● 복합 의사결정 및 플래닝 (Complex Decision-Making & Planning)

- 복합 의사결정 및 플래닝은 여러 단계의 선택, 제약 조건, 목표를 포함하는 문제에서 최적의 행동 순서를 도출하는 과정으로 CoT는 문제 해결 과정을 단계별 자연어로 분해하여 모델이 장기적 결과를 예측하고 올바른 계획을 구성하도록 지원
- 모델은 단순 결과 예측을 넘어서 전략 수립, 자원 배분, 경로 탐색, 일정 계획 등 고차원 의사결정 가능
- CoT 기반 플래닝은 특히 환경 시뮬레이션, 작업 스케줄링, 로봇 경로 계획, 게임 전략 생성 등에서 효과가 검증되었으며 이러한 방식은 모델의 논리적 오류를 줄이고, 다단계 플랜의 정합성을 높여 복잡한 목표 달성의 성공률 향상으로 증명

공정 라인 최적화 플래닝 문제 사례

Q.공장에서 제품 생산을 위해 다음 공정을 순서대로 수행해야 한다:

- 금속 절단 (Machine X: 3시간 / Machine Y: 2시간)
- 연마 (Machine Z: 4시간)
- 도장 (Machine W: 3시간)

머신 X와 Y 중 하나를 선택해 1단계를 진행할 수 있으며, Z는 항상 2단계에서 사용됨
 도장은 동시에 최대 2개 제품까지 처리 가능하지만 1단계와 2단계는 동시에 1개 제품만 처리 가능함
 총 3개 제품을 가장 빨리 완성하기 위한 최소 총 소요 시간을 구하시오.

CoT 추론 핵심

- 병목 지점(bottleneck) 탐색
- 병렬 공정 스케줄링
- 자원 분배 최적화
- 기계 선택에 따른 전체 일정 변화 계산

CoT 추론 상세화

(문제정리)

- 제품 수: 3개
- 공정 및 소요 시간:
 - 금속 절단: X = 3시간, Y = 2시간 (1개 제품당, 선택 가능)
 - 연마: Z = 4시간 (1개 제품당, 항상 사용)
 - 도장: W = 3시간 (1개당 처리 가능 최대 2개 동시)
- 제약 조건:
 - 1단계와 2단계는 동시에 1개 제품만 처리 가능
 - 도장은 최대 2개 제품 동시 처리 가능
 - 목표: 3개 제품 가장 빨리 완성

(1단계(금속 절단) 기계 선택)

- X: 3시간/제품 → 총 3제품 = $3 \times 3 = 9$ 시간 (직렬 처리)
- Y: 2시간/제품 → 총 3제품 = $2 \times 3 = 6$ 시간 (직렬 처리)
- 최적 선택: Y (2시간/제품) → 전체 소요 시간 최소화

(2단계: 연마(연속 단계))

- 연마 Z는 1개 제품씩 순차 처리 → 4시간/제품
- 병목: 1단계와 2단계는 모두 1개씩 처리
- 연마 단계 총 14시간까지 완료

(3단계: 도장)

- W는 최대 2개 제품 동시 처리 가능
- 각 제품 3시간 소요
- 1,2,3 제품 준비 완료 시간: 6, 10, 14시간
- 도장은 준비된 제품부터 순차적/병렬 처리
- (도장배치) 1,2 제품: 10시간 시점에 W 2개 사용 → 10-13시간, 3번째 제품: 14시간에 도장 시작 → 14-17시간

(4단계: 전체 최소 소요 시간)

- 마지막 제품 완성 시점 = 17시간

A.


정답: 17시간

III

● 비디오/멀티모달 추론

- 모델이 영상의 시간적 흐름과 공간적 관계를 단계적으로 추론할 수 있게 되므로 단순 패턴 인식이 아니라 영상에서 핵심 프레임을 추출하고, 그 사이의 인과관계를 설명
- 복잡한 비디오 QA를 여러 논리적 단계로 분할하고 모델이 더 긴 문맥을 효과적으로 이해하도록 지원하여 응답의 정확성과 투명성이 증가

비디오/멀티모달 추론 예시



[그림 III-2] Deep Mind 데이터 수집 절차

※ 출처: <https://arxiv.org/pdf/2411.14794>

2.1.2 CoT 학습 및 데이터 구축 방법

- CoT 데이터셋의 구성요소는 ①문제(질문)-입력, ②단계별 reasoning 문장, ③ 정답(결론)-출력, ④ 검증 태그(pass/fail, consistency score 등)으로 구성


구분	내용
Human-written CoT	• 사람이 직접 문제를 단계별로 추론하여 CoT를 작성하는 방식 • 이를 통해 모델이 학습할 수 있는 고품질의 휴먼 추론 데이터 확보 가능 • 주로 복잡한 논리적 추론이나 세밀한 판단이 필요한 작업에 적합
Model-generated CoT	• 모델이 자체적으로 CoT를 생성한 후 검증 모델을 통해 정확성과 논리성을 검토 • 인간 개입을 최소화하여 대규모 데이터를 효율적으로 수집하며 검증 과정이 없을 경우 오류나 편향이 포함될 수 있음
Hybrid	• 인간이 작성한 샘플데이터를 기반으로 모델이 CoT를 생성하고 이를 반복적으로 개선(self-improve)하는 방식 • 인간의 직관과 모델의 생성 능력을 결합해 데이터 규모와 품질을 동시에 확보 가능하며 이러한 접근은 점진적 학습과 성능 향상에 유리

[표 III-3] CoT 데이터 구축 방법

2.2 CoT-SC (Chain-of-Thought + Self-Consistency)

- 최근 LLM의 추론 능력 강화가 중요한 과제로 CoT 기법이 “단계별 사고 과정”을 유도함으로써 복잡한 문제 해결에 도움을 주나 CoT 방식에서도 단일 추론경로 → 탐욕적 디코딩(greedy decoding*) 방식으로 인해 오류가 누적되거나 국지 최적(local optimum)**에 머무르는 문제가 존재
 - * 언어 모델(LLM)이 다음 토큰을 선택할 때 매 순간 가장 확률이 높은 토큰을 무조건 선택하는 방식 즉, 항상 최적(최고 확률)의 선택만 하면서 탐욕스럽게(greedy) 진행한다는 의미
 - ** 전체에서 가장 좋은 해(global optimum)가 아니라 국지적 영역에서만 보면 더 이상 개선할 여지가 없는 해
- 이 문제를 해결하고자 등장한 것이 Self-Consistency (SC) 디코딩 전략으로 동일 문제에 대해 다양한 추론 경로를 샘플링하고, 그 중 일관된(혹은 다수) 결론을 선택하는 방식
- CoT-SC는 “CoT + Self-Consistency” 결합 전략으로 볼 수 있으며 보다 견고하고 신뢰도 높은 추론 결과를 확보하는 데 목적이 있음
- CoT-SC는 LLM이 문제에 대한 ‘사고과정’을 생성하도록 유도한 뒤 여러 개의 서로 다른 사고 경로를 샘플링 하여 그 결과로 나온 답변 중에서 가장 일관성 있는 답을 선택하는 디코딩 전략

CoT-SC 흐름



Flow chart SC-CoT

[그림 III-3] CoT-SC 흐름

※ 출처: <https://arxiv.org/pdf/2203.11171>

2.2.1 구성 요소

구분	내용
프롬프트 설계	• CoT-SC의 프롬프트 설계는 기존 CoT의 핵심을 유지하면서 모델의 단계적 추론을 유도 • 구체적으로, "Let's think step by step"과 같은 지시어를 포함하여 모델이 문제를 단순히 답하는 대신 중간 추론 과정을 명시적으로 생성하도록 유도 • 모델의 내재된 지식을 활용해 자연스러운 추론을 형성하며 복잡한 문제에서 효과적 • 프롬프트에 예시나 문제 설명을 추가하여 맥락을 강화함으로써, 모델이 일관된 사고 흐름을 따르도록 하여 단일 출력이 아닌 다중 샘플링의 기반을 마련
샘플링 단계	• 샘플링 단계에서 동일한 프롬프트를 사용해 모델에게 질문을 여러 번 반복적으로 입력 • 이 과정에서 랜덤샘플링 기법을 적용, 매번 다른 추론을 생성 • 일반적으로 10~40개의 샘플을 추출하며, 이는 모델의 비결정적 출력을 활용해 다양한 사고 경로를 탐색하여 단일 경로의 한계를 넘어 문제 해결의 잠재적 다양성 포착
집계(Aggregation) 단계	• 집계 단계는 생성된 다중 CoT 출력에서 최종 답변을 도출하기 위해 여러 번 샘플링하여 나온 수많은 답변 중에서 가장 많이 나온 답변을 그대로 최종 정답으로 선택하거나 과반수 투표(majority vote) 방식을 적용 • 여러 추론의 결론 중 가장 빈번하게 등장하는 답을 선택하며 선택적 추론일관성 점수(consistency score)를 통해 신뢰성을 평가 • 복잡한 문제에서 다수의 다른 사고 경로가 동일 결론으로 수렴할 가능성이 높음에 기반 • 예를 들어, 수학 문제에서 20개 샘플 중 15개가 '42'를 도출하면 이를 정답으로 채택 • 이 과정은 모델의 불확실성을 완화하고, 단일 출력의 오류를 줄이는 데 효과적

[표 III-4] CoT-SC 구성요소

2.2.2 디코딩 방식 비교

- 기존 CoT는 가장 높은 확률 토큰을 선택하여 단일 추론단계만 생성하는 반면, CoT-SC는 다중 샘플링을 통해 여러 경로를 병렬 생성한 후 집계로 최종 답을 결정
- CoT-SC는 CoT 단독 디코딩 대비 샘플링 및 집계 비용이 증가하지만, 추가 학습이나 파인튜닝 없이 디코딩 전략만 변경해도 성능이 크게 향상됨
- CoT-SC의 핵심은 단일 '생각의 사슬'이 아닌 '여러 생각의 사슬'을 생성하고 그중 일관성 있는 결론을 선택하는 것으로 복잡한 작업에서 오류가 더 감소됨

2.2.3 CoT-SC의 주요 장점 및 특성

장점	내용
성능 향상	• 최근 연구사례에서는 CoT-SC를 적용했을 때, 기존 CoT(단일 greedy decoding) 대비 대부분의 산술·상식 추론 벤치마크에서 정확도 향상을 보고 • 특히 GSM8K와 SVAMP, AQuA에서 큰 폭의 성능 상승을 보였고 StrategyQA와 ARC-Challenge 같은 상식 추론 데이터셋에서도 각각 향상되어 CoT-SC가 산술 추론뿐만 아니라 일반적인 복잡 추론 작업에서도 효과적임을 입증 • 이는 동일한 모델과 동일한 프롬프트 조건에서 디코딩 전략 변경으로 달성된 결과이므로 추가 학습 없이 즉시 적용가능한 강력한 방법론으로 평가됨 ※ Wang et al., Self-Consistency Improves Chain of Thought Reasoning in Language Models, 2022
강건성 (Robustness) 증가	• CoT-SC는 단일 탐욕적 디코딩에서 흔히 발생하는 초기 단계의 작은 실수나 계산 오류가 전체 추론 과정을 망치는 문제를 효과적으로 완화 • 하나의 사고과정은 잘못된 중간 단계를 밟으면 끝까지 오답으로 수렴하지만, CoT-SC는 수십 개의 서로 다른 경로를 동시에 탐색하기 때문에 동일한 오류가 모든 경로에서 반복될 확률이 극히 낮음 • 특히 산술 문제에서 자리수 계산 실수, 부호 오류, 잘못된 공식 적용 등 결정적 오류가 발생해도 다른 경로들은 올바른 길을 찾아 정답으로 수렴됨 • 결과적으로 CoT-SC는 추론 과정에 내재된 불확실성을 강점으로 전환하여 훨씬 더 강건한(reasoning-robust) 성능을 제공함
논리적 신뢰도 향상	• CoT-SC는 서로 다른 여러 추론 경로가 동일한 최종 답변으로 수렴할 때, 그 답변의 논리적 신뢰도가 극적으로 높아진다는 점을 핵심 장점으로 제시 • 하나의 경로만 존재할 경우 그 경로가 우연히 맞았는지, 진짜 논리적으로 타당한지는 판단하기 어렵지만 40개 중 35개가 서로 다른 계산·추론 과정을 거쳐도 같은 답을 도출하는 경우 단순한 우연이 아니라 모델의 내재된 지식에 기반한 정답일 가능성이 높음 • 일부 연구 사례에서는 GSM8K 문제 중 greedy CoT가 틀린 사례라도 CoT-SC에서는 80~90% 이상의 경로가 정답으로 수렴하여 최종 선택된 답변의 신뢰도가 사실상 인간 수준에 근접했다고 평가

[표 III-5] CoT-SC 장점 및 특성

III

2.2.4 CoT-SC 적용사례 및 실험결과

- Wang et al. (2022) Self-Consistency Improves Chain of Thought Reasoning in Language Models 논문에서 언급된 벤치마크 사례 안내

벤치마크	내용
GSM8K	+17.9 %p 개선
SVAMP	- CSVAMP (Single-Variable Arithmetic Math Problems, 단일 변수 산술 수학 문제 데이터셋) - 겉보기엔 쉬운 초등 산술 문제이나 문장 구조를 교묘하게 변경하여 LLM의 언어 이해 능력과 간단한 추론 능력을 동시에 테스트하는 벤치마크 +11.0 %p 개선
AQuA	- AQuA (Algebra Question Answer Dataset, 대수 문제 정답 데이터셋) - 고등학교 대수 문제를 객관식으로 만든, LLM의 수학적 추론 능력과 언어 이해를 동시에 테스트하는 대표적인 고난도 벤치마크 +12.2 %p 개선
StrategyQA	- StrategyQA (Strategy Question Answering, 전략적 추론이 필요한 암시적 Yes/No 질문 데이터셋) - 직접적인 사실이 아니라, 여러 상식 사실을 연결해 전략적으로 판단해야 하는 암시적 Yes/No 질문 데이터로 LLM의 진짜 상식 추론 능력을 가장 잘 드러내는 벤치마크 +6.4 %p 개선
ARC-Challenge	- ARC-Challenge (Abstraction and Reasoning Corpus - Challenge, 추상적·추론적 패턴 인식 데이터셋의 고난도 버전) - 그리드 패턴으로 표현된 추상적 추론 퍼즐로 AI의 진짜 일반화·추론 능력을 테스트하는 '최종 보스' 수준 벤치마크 +3.9 %p 개선

[표 III-6] 적용 사례 및 실험 결과

- 프롬프트/샘플링 방식
 - CoT-SC의 실제 적용 시, 동일한 질문에 대해 “Let’s think step by step”과 같은 CoT 프롬프트를 포함한 입력을 모델에 반복적(평균10~40회)으로 실행
 - 각 실행마다 측정지표를 동일한 비율로 높게 혹은 낮게 설정하고 랜덤시드(random seed)를 달리 하여 모델의 출력이 비결정적으로 되게 함으로써 매번 서로 다른 추론 chain을 생성
 - 생성된 각 chain은 독립적인 중간 추론 과정을 거치며 최종 답안을 도출하는데, 일부 chain은 계산 실수나 잘못된 가정을 포함할 수 있지만 나머지는 올바른 경로를 따르게 됨
 - 모든 실행이 끝난 후, 각 chain의 최종 답안만 추출하여 가장 빈번하게 등장한 답안을 다수결 또는 답변 다수성 방식으로 최종 답으로 선택
 - 이 과정은 추가적인 학습 없이 순수 디코딩 단계에서만 이루어지며, 실험에서 PaLM 540B 모델에 40회 샘플링을 적용했을 때 최적의 성능을 보임

- 실무 응용 예시

- ※ Medium 의 “Self-Consistency with Chain of Thought (CoT-SC)”에서 파이썬 구현 예시
- 동일한 프롬프트에 "think step-by-step"을 추가해 모델(gpt-3.5-turbo)을 여러 번 호출 (iterations=5)하여 다중추론 chain을 생성하고, 응답을 수집해 다수결로 최종 답을 결정

적용 프롬프트

```
# Chain of Thought with Self-Consistency with majority vote demo
# Code written by OpenAI Code Interpreter
# 2023-08-07
import openai
from dotenv import find_dotenv, load_dotenv
import os

# Initialize OpenAI API with your key
load_dotenv(find_dotenv(), override=True)
api_key = os.environ.get('OPENAI_API_KEY')
openai.api_key = api_key
engine = "gpt-3.5-turbo"
def chain_of_thought_prompting(initial_prompt, iterations=5):
    current_prompt = initial_prompt + ", think step-by-step"
    messages = [
        {"role": "system", "content": "you answer like a scientist in a brief and precise manner"},
        {"role": "user", "content": current_prompt}
    ]

    response = openai.ChatCompletion.create(
        model=engine,
        messages=messages,
        max_tokens=150,
        n=iterations,
    )

    responses = [choice['message']['content'] for choice in response['choices']
                  if choice['message']['role'] == 'assistant']
    responses_string = "first answer: " + ', next answer: ' + ' '.join(responses)
```

III


2.2.5 CoT-SC 구축 시 고려사항

고려사항	내용
리소스 및 비용	• CoT-SC를 구축할 때 가장 큰 고려사항은 다중 샘플링(보통 10~40회)로 인해 토큰 소비, API 호출 횟수, 응답 지연 시간이 기존 CoT 대비 10~40배 증가하는 비용 부담 • 이를 효율화하기 위해 난이도 기반 자기일관성처럼 문제 난이도를 사전 평가하여 쉬운 문제(일관된 답변 빠름)에는 1~5회, 어려운 문제에는 20회 이상 샘플링을 동적으로 배분하는 전략을 적용하는 방법 등을 사용 등을 권고 • DSC 실험에서 GPT-4 기준으로 비용을 절감하면서도 성능 저하 없이 ASC/ESC 기준 초과 • 실무 구현 시 클라우드 비용 모니터링 도구나 배치처리를 병행하여 리소스 최적화
도구화 및 프레임워크화	• CoT-SC를 실무에 적용할 때는 파이썬 스크립트로 모듈화하여 프롬프트 입력 → 다중 샘플링(OpenAI API n=iterations) → 집계(majority vote) → 출력 반환의 파이프라인을 구축하는 것이 표준 • API 키를 관리하면서, gpt-3.5-turbo 모델에 'think step-by-step' 프롬프트를 5회 반복 호출해 진화론 설명을 생성한 후 LLM이 '가장 공통적인 주제'를 추출하는 코드를 활용하여 구현 • 프레임워크로는 LangChain의 Chain 모듈이나 Hugging Face Transformers의 확률적 디코딩 기법을 적용해 출력을 생성하는 방식을 내부 파이프라인에 삽입하며, 병렬 처리로 응답 시간을 50% 단축
모델 크기/ 응용 분야 고려	• CoT-SC는 모델 크기가 클수록(예: PaLM 540B 이상) 더 큰 효과를 발휘하는데, 대형 모델의 내재된 추론 능력이 샘플링된 다양한 경로에서 더 일관된 정답 수렴을 유발 • 논문실험에서 소형 모델(LaMDA 13B)에서는 CoT-SC가 5~10% 향상으로 그치지만, 대형 모델에서는 15~20%까지 상승하며 규모에 따른 추론 폭발을 증폭 • 응용 분야로는 수리(GSM8K), 상식(StrategyQA, ARC-Challenge)에 최적화되어 있지만, 창의 개방형(예: 에세이 작성)에서는 USC 같은 확장 전략 필요 • 따라서 구축 시 모델 스케일(70B+ 추천)과 도메인(closed-ended 우선)을 평가해 적용 범위를 제한해야 하며, 소형 모델에는 hybrid(부분 SC) 접근시 자원낭비를 방지하고, 분야별 벤치마크로 사전 테스트를 통해 ROI를 최대화하는 것을 고려

[표 III-7] CoT-SC 구축 고려사항

2.3 ToT (Tree-of-Thought)

- CoT와 CoT-SC가 단일 사고 사슬의 다양성을 확보했지만 여전히 "병렬적 탐색"이나 "분기형 사고(branching reasoning)"는 불가능함
- ToT는 이러한 한계를 극복하기 위해 사고 과정을 트리(Tree) 형태로 확장하여, 가능한 여러 사고 경로를 동시 탐색·평가·선택하는 프레임워크를 제안
- ToT는 “탐색 기반 사고(search-based reasoning)”를 통해 모델이 인간처럼 여러 생각 경로를 탐색하고 되돌아가며 수정할 수 있도록 하여 AI 모델이 단일 사고 사슬이 아닌 “트리 구조의 다중 사고 경로(thoughts)”를 생성·탐색·평가하는 추론 프레임워크



[그림 III-4] ToT 개념

※ 출처: <https://www.ibm.com/think/topics/tree-of-thoughts>

항목	CoT	ToT
구조 형태	단일 선형 사슬 (Linear Chain)	트리 구조
시각적 비유	한 줄로 쭉 내려가는 강물	뿌리에서 수많은 가지가 뻗어나가는 나무
고려하는 경로수	항상 1개(최종 1개 선택)	동시에 수십~수백 개의 경로를 유지·탐색
분기발생	없음	매 단계 의도적으로 3~5개 분기 생성
백트래킹	불가능 (이미 생성된 문장 되돌릴 수 없음)	가능 (잘못된 가지를 버리고 다른 가지로 되돌아감)
탐색공간	1차원 (길이만 있음)	2차원 (폭 × 깊이)
실패시 회복	거의 없음 (한 번 실수하면 끝)	매우 강함(다른가지에서 정답 탐색)

[표 III-8] CoT VS ToT 비교

2.3.1 핵심 구성요소

핵심구성요소	내용
상태(State)	- 문제 풀이의 중간 단계 표현으로 현재까지 도달한 문제 해결의 중간 표현 예: 수학 문제라면 “방정식 $x + 2y = 10$까지 세웠다” 또는 “현재 24를 3으로 나누면 8이 도출되는 단계” - CoT의 중간 문장과 동일하나 ToT에서는 여러 개의 상태가 동시에 존재하며 각각이 트리 노드임
사고(Thought)	- 상태에서 다음 상태로 이동하기 위한 부분 추론 단위 - 하나의 State에서 다음 State로 이동하는 작은 추론 단위로 보통 1~3문장으로 제한 - ToT는 한 번에 3~5개의 사고 후보를 생성해 분기
Transition Function	- Transition Function은 현재 상태에서 다음 사고 후보 생성 - 현재 상태를 입력으로 받아 다음 가능한 사고 후보군을 생성하는 모듈 - 실제 구현에서는 LLM에게 “다음에 가능한 3가지 생각을 제안해줘”라는 프롬프트를 주고 파라미터를 설정하여 샘플링하고 이 함수가 ToT의 탐색 폭(breadth)를 결정
Evaluation Function	- Evaluation Function은 후보 사고의 품질·타당성을 평가 - 생성된 사고 후보 또는 도달한 상태의 품질·유망성을 점수화하는 핵심 모듈 - Majority Vote는 동일 상태에 대해 5~10회 독립 샘플링 후 가장 일관된 결론을 채택 - 평가 함수가 ToT의 탐색 깊이(depth)와 정확도를 좌우
탐색전략(Search Strategy)	- ADFS/BFS/Beam Search 등을 이용하여 사고Tree를 탐색하며 최적 추론경로를 선택 - 사고트리를 어떻게 탐색할지 결정하는 알고리즘 - DFS (Depth-First Search) — 깊이 우선 탐색 : 경로를 끝까지(깊게) 탐색한 뒤, 막히면 되돌아(backtracking)와서 다른 경로를 탐색 - BFS(Breadth-First Search)+Evaluation — 상위 k개 유지하여 너비 우선 탐색 : 모든 경로를 “같은 깊이에서 하나씩” 넓게 탐색하는 방식 - Beam Search — 가장 높은 평가 점수 k개만 계속 확장 : 상위 k개만 선택하는 실용적 탐색으로 실무에서 가장 많이 사용 - DFS + Backtracking — 깊이 우선 탐색 후 실패하면 되돌아옴 : 실험 결과, 깊이 5~8, 폭 3~5일 때 최고 성능을 보이며 창의적 문제에 유리

[표 III-9] ToT 핵심 구성요소

구분	DFS	BFS	Beam Search
탐색방향	한 경로 끝까지	넓게, 깊이의 순서	DFS+ 상위 K
비용	낮음	높음	중간 / 효율적
장점	창의, 깊이 탐색 강함	최적해 탐색 강함	성능-비용 균형 최고
단점	잘못된 경로로 가면 성능이 낮아짐	계산 메모리 비용 큼	K선택에 따라 결과 영향
ToT에서의 용도	창의적 문제 백트래킹 기반	실험/연구용 (대규모 탐색)	가장 널리 쓰임

[표 III-10] ToT 알고리즘 비교

2.3.2 ToT 작동 원리

- 문제 분해(Problem Decomposition)

- ToT는 처음에 복잡한 문제를 하나의 거대한 목표가 아니라 여러 개의 작고 명확한 하위 목표(subgoals)로 분할

예시

예를 들어 “4, 8, 8, 13으로 24 만들기”를

- ① 24를 만들 수 있는 중간 숫자 3개를 먼저 brainstorm
- ② 각 중간 숫자를 만들 수 있는 식을 찾기
- ③ 조합하기의 3단계로 분할

- 이 과정은 LLM에게 “이 문제를 해결하기 위해 필요한 중간 단계를 3~5개로 나눠줘”라는 프롬프트로 수행되며 분해된 하위 목표들은 트리의 최상위 레벨(level 1) 노드가 됨으로써 모델이 한 번에 모든 것을 해결하려고 애쓰지 않고, 작은 문제 단위로 체계적으로 해결

- 사고 트리 확장 (Thought Expansion)

예시

- ① 각 상태(노드)에 도달하면, ToT는 한 번에 3~5개의 서로 다른 사고 후보를 의도적으로 생성
프롬프트 예시: “현재 상태에서 다음 단계로 나아갈 수 있는 서로 다른 3가지 생각을 제안해줘.”
- ② 이렇게 생성된 후보들은 바로 트리의 자식 노드가 됨
예: “ $8 \times 3 = 24$ 니까 3을 만들자”, “ $6 \times 4 = 24$ 니까 6과 4를 만들자”, “ $12 \times 2 = 24$ 니까 12와 2를 만들자” 등
이 확장 단계는 파라미터를 조정, 의도적인 다양성을 확보함으로써 결과적으로 한 단계만 지나도 1→3~5개의 가지가 생성됨

- 평가 및 선택 (Evaluation & Pruning)

- 생성된 모든 사고후보에 대해 품질 평가를 수행하며 평가 방법은 LLM 활용 또는 다수결 투표

- 탐색 알고리즘 적용 (Search Strategy)

- ToT는 단순 무작위 탐색이 아니라 고전적인 검색 알고리즘인 BFS, DFS, Beam Search, DFS + backtracking 등을 적용


- 최종 해 도출 (Solution Selection)

- 탐색이 종료되면 목표 상태(정답 도달 또는 최대 깊이 도달)에 도달한 모든 경로 중 평가 점수가 가장 높은 경로 하나를 최종 답으로 선택
- 때로는 여러 경로가 정답에 도달했을 경우, 가장 짧거나 가장 자연스러운 경로를 선택하기도 함
- 최종 출력은 선택된 경로의 모든 사고를 연결해 하나의 완전한 CoT로 제시
- “다음과 같은 과정을 거쳐 정답에 도달 → (가지① → 가지③ → 가지②의 최종 조합)” 식으로 정리

2.4 GoT (Graph-of-Thought)

- ToT의 트리 구조는 “고정된 계층 구조”로 인해 모든 문제를 “계층 구조”로 표현해야 한다는 제약 때문에 브랜치 간 메모리가 공유되지 않고 진행 단계 중간 아이디어 통합이 어려워 새로운 통찰이 생겨도 상위 노드 구조를 변경하기 어렵기 때문에 유기적, 점진적 추론이 제한됨
- 인간 사고는 트리보다 그래프 형태의 연결적 사고에 가깝다는 인지과학적 통찰에서 출발하여 순환과 교차검증, 요소간 연결성이 강화된 그래프기반 추론을 수행하는 것이 GoT의 목적
- 기존 ToT의 고정된 계층 구조에서 벗어나, 사고 과정을 노드와 엣지로 구성된 비선형·비계층적 추론 그래프로 모델링하는 최초의 프레임워크
- GoT는 문제 해결을 그래프 탐색 형태로 확장한 추론 프레임워크로 각 노드는 하나의 사고 상태, 각 엣지는 사고 간의 논리적 전이 관계(transition)를 나타냄

GoT 기본 구조



- 사용자는 새로운 프롬프트 방식으로 손쉽게 설계를 확장할 수 있으며, 새로운 사고 변환을 실험하거나 서로 다른 LLM들을 연결해 사용할 수도 있음
- 그림에서 파란색 영역은 전체 아키텍처 개요를, 초록색 영역은 API 목록을, 빨간색 영역은 예시 프롬프트와 함께 GRS 및 관련 연산들을 담고 있음

[그림 Ⅲ-5] GoT 기본 구조

※ 출처: <https://arxiv.org/pdf/2308.09687>

구분	ToT	GoT
구조	• 트리 (계층형)	• 그래프 (비계층형, 상호연결형)
탐색	• DFS/BFS 기반	• Graph search (backtracking, merging 가능)
사고 경로	• 단방향(루트→리프)	• 다방향 (노드 간 연결 및 재활용 가능)
중간 상태 재활용	• 불가능	• 가능
병렬추론	• 제한적	• 지원
대표 적용	• 수리·계획형 문제	• 다중 hop reasoning, symbolic, 지식그래프 기반 문제

[표 Ⅲ-11] ToT 대비 GoT의 차별점

2.4.1 핵심 구성요소

핵심구성요소	내용
사고단위 (Node)	- 추론 단계 또는 서브 목적(sub goal) - GoT 프레임워크에서 하나의 '사고 단위'를 의미하며 문제 해결 과정에서 LLM이 생성한 부분적 추론 결과(중간 결론, 관찰, 규칙, 가정, 제약 조건 등)를 저장하는 단계 - 또는 특정 해결 단계에 해당하는 subgoal(부분 목표)로 기능하며 Node는 서로 독립적일 수도 있고, 다른 node의 검증 근거·조건으로 사용될 수도 있음
관계 (Edge)	- 사고 간의 연관성, 인과, 의존성으로 두 노드 간의 '논리적 관계'를 표현 - 근거관계, 인과 관계, 의존 관계, 반박 관계, 조건/제약 관계를 포함 - 단순 분기가 아니라 상호 연결된 추론 네트워크를 구성하는데 핵심 역할을 수행하며 방향성을 가지는 경우, 추론의 흐름을 나타냄
그래프 생성 함수 (Graph construction function)	- 새로운 노드를 생성할 때 기존 노드들과의 관계를 결정해 관계(Edge)를 구성하는 기능 - 수행내용 ① 새로운 노드 생성: LLM 등 규칙에 의한 새로운 추론단계 제안 ② 관계 설정: 기존 노드들과의 인과·의존·근거 연결 판단 ③ 그래프 업데이트: 노드·엣지를 그래프에 삽입하고 필요하면 구조를 재구성 - GoT가 비선형 추론 그래프를 동적으로 구축할 수 있게 만들며 일부 GoT 구현에서는 주의(attention) 기반 연결, 유사성 기반 연결, 규칙기반 연결을 혼합해 사용
평가 기능 (Evaluation function)	- 사고단위(Node), 관계(Edge)의 유효성과 신뢰성 평가 - 생성된 사고단위 또는 관계가 유효한지, 논리적으로 타당한지, 문제 해결에 도움이 되는가를 평가하는 방법 - 평가기준 ① 논리적 일관성, ② 사실성과 정확성, ③ 문제 목표와의 연관성, ④ 중복 여부, ⑤ 모순 여부, ⑥ 전체 그래프에서의 기여도
탐색 및 현행화	- 문제해결을 위해 그래프를 어떻게 확장하고 유지·수정할지 규정하는 정책 - 주요기능 ① 그래프 확장: 어떤 사고과정(Node)를 더 펼칠지 선택 ② 그래프 병합: 의미적으로 동일하거나 유사한 노드를 통합 ③ 경로 선택 또는 pruning: 가치 없는 경로 제거 ④ 되돌리기: 잘못된 부분 경로를 폐기하고 이전 상태로 복귀 ⑤ 전략적 탐색(search strategy): top-down, bottom-up, hybrid 방식 등 선택 ⑥ 추론 종료 조건 결정: 목표 상태 도달 또는 탐색 비용한계 등

[표 III-12] GoT 핵심 구성요소

III

2.4.2 GoT 주요 특징

- GoT는 사고 단계를 트리가 아닌 일반 그래프 구조로 모델링하여 기존 CoT·ToT의 한계를 극복하고 병렬 추론, 재사용 가능한 노드, 장기 의존성 표현 등을 지원
- 그래프 구조는 오류 노드 감지를 통한 대체 경로 생성, 불완전 추론 보완, 신뢰 점수 낮은 노드의 가지치기(pruning) 등 자기 검증과 정제가 용이하여 추론 복원력이 증가
- 노드 재사용, 병렬 탐색으로 ToT 대비 전체 토큰 수를 절감할 수 있으며 외부 모듈, 지식베이스 검색, 시뮬레이터, 논리검증기 등을 그래프 노드로 삽입 가능
- 구조적 특징

특징	내용
비선형 추론구조	● ToT는 분기(branch)만 가능하지만 GoT은 임의의 연결(Edges)을 허용하는 일반 그래프(DAG 또는 부분 순환 그래프) ● 동일 노드가 여러 경로에서 재사용이 가능하고, 다중 접근 경로를 허용하며, 문제 해결 전략들이 서로 교차·합류가 가능하므로 복잡한 문제 구조를 더 사실적으로 표현이 가능
메모리 재사용/ 부분 추론 재활용	● GoT에서는 특정 부분 추론을 하나의 노드로 저장하고, 여러 추론경로에서 동일 노드를 참조 가능하여 중복계산이 감소되므로 일관성 있는 추론을 제공
병렬 추론	● 그래프 구조 덕분에 서로 독립된 부분 문제를 동시에 생성/평가 가능 ● 여러 가설을 병렬로 확장하거나 퀄리티 기반 탐색과 결합이 용이하고 LLM의 배치 처리가 최적화되어 효율이 높아지고 추론 시간이 단축

[표 III-13] GoT 구조적 특징

- 기능적 특징

특징	내용
장기 의존성 처리능력 강화	● 트리 구조는 깊어질수록 의존성이 약해지지만, 그래프는 멀리 떨어진 노드도 직접 연결할 수 있으므로 수학 증명, 기호 추론, 계획 문제에서 효과적
다중 전략 결합	● GoT는 다양한 추론전략을 그래프 상 subgraph로 결합, 복합형 추론에서 유리
정확도 기반 최적경로 선택	● 그래프 전체 탐색 후, 평가 모델/ 가점 함수 / 투표 / 합의 알고리즘 등을 통해 최적 추론 경로를 선택할 수 있음. 이로 인해 최종 답변의 신뢰도가 향상됨

[표 III-14] GoT 구조적 특징

2.4.3 GoT 데이터 구축 방법

- 아래에서 GoT의 핵심 모듈(Prompter, Parser, Scoring 등)을 기반으로 각 항목을 세부적으로 설명

1.4.3.1 문제 입력

구분	내용
의미 및 내용	- GoT 프로세스의 시작점으로 사용자가 해결하고자 하는 복잡한 문제를 입력 - 입력은 LLM이 이해할 수 있도록 명확하게 정의되어야 하며, 초기 프롬프트로 변환
역할	- 문제 복잡도를 분석하여 그래프 구조를 설계 - 입력 후 Prompter 모듈이 LLM 호출을 위한 메시지를 준비
중요성	- 입력이 모호하면 그래프가 비효율적으로 확장될 수 있으므로, 명확한 문제 정의가 핵심 - GoT 프레임워크에서 이 단계는 LLM API 키 설정 등 환경 초기화가 이루어짐

[표 III-15] 문제 입력 단계

2.4.3.2 초기 노드 생성 (Root thought)

구분	내용
의미 및 내용	- 입력을 바탕으로 그래프의 루트 노드를 생성 - 이 노드는 초기 '사고', 문제의 기본 아이디어나 중간 상태를 나타냄 - LLM을 호출하여 하나의 초기 응답을 생성하며, 이는 그래프의 출발점으로 작용 - 표준 GoT에서 루트는 단일 노드지만, 병렬 생성 시 여러 루트가 가능
역할	- Parser 모듈이 LLM 출력에서 정보를 추출하여 노드로 저장 - 노드는 텍스트 문자열이나 벡터 임베딩으로 표현될 수 있음 (예시: 입력 "[5, 3, 8, 1] 정렬" → 루트 노드: "초기 목록: [5, 3, 8, 1]. 정렬 전략 고려 중") - 이 노드는 후속 확장을 위한 기반으로 작용
중요성	루트가 잘 정의되지 않으면 전체 그래프가 왜곡될 수 있으므로, LLM 프롬프트에 "초기 아이디어 생성" 지시를 포함

[표 III-16] 초기 노드 생성 단계

2.4.3.3 후보 사고 확장을 통한 새 사고과정(Node) 생성

구분	내용
의미 및 내용	- 기존 노드(루트부터 시작)에서 후보 생각을 생성하여 새로운 노드를 추가 - LLM을 호출하여 "생성" 변환을 적용, 하나의 노드에서 여러 하위 생각을 병렬적으로 생성 - 이는 그래프의 폭(width)을 확장하고 각 후보는 문제의 부분 해결 아이디어로서 작용하여 최대 생성 수(k)를 제한하여 효율성을 유지
역할	- 확장된 후보를 그래프에 노드로 삽입 - GoT의 비선형성 덕분에 순차적이지 않고, 여러 브랜치가 동시에 생성될 수 있음
중요성	- 다양성을 확보하여 최적 경로를 찾기 쉽게 함 - ToT와 유사하지만, GoT는 후속 집계를 위해 설계

[표 III-17] 사고과정(Node) 생성 단계

2.4.3.4 노드 간 관계 추론을 통한 관계(Edge) 연결

구분	내용
의미 및 내용	- 생성된 노드들 사이의 관계를 추론하여 연결 (예: "Improve" - 기존 생각 개선, "Aggregate" - 여러 생각 통합) - LLM이 관계를 제안 혹은 자동 매핑. 그래프는 DAG 형태로 유지되어 순환을 피함
역할	- 관계 정의로 그래프의 깊이(depth)를 형성 "이 생각들을 어떻게 연결할까?" 프롬프트를 사용
중요성	GoT의 비선형 연결로 복잡 문제 해결

[표 III-18] 관계(Egde) 연결 단계

2.4.3.5 평가함수로 각 노드/엣지 품질 측정

구분	내용
의미 및 내용	- 각 노드와 에지의 품질을 평가 함수로 측정 - 노드는 유용성·정확성으로, 에지는 변환 효과로 평가하고 임계값을 넘어가는 항목만 유지
역할	- 불필요한 브랜치를 가지치기(pruning)하여 효율성 향상 - Dynamic GoT 변형에서 실시간으로 적용됨
중요성	평가가 없으면 그래프가 폭발적으로 커져 비용이 증가하며 Validator 모듈이 이 역할을 수행

[표 III-19] 사고과정(Node) 및 관계(Egde) 품질 측정

2.4.3.6 최우선(best-first) 또는 빔 기반(beam-based) 탐색으로 그래프 확장

구분	내용
의미 및 내용	- 평가된 그래프를 탐색 알고리즘으로 확장함 - Best-First Search는 최고 점수 노드부터 우선 확장(탐욕적)을 말하고 Beam Search는 상위 k개 경로만 유지하며 확장(빔 폭 제한)하는 것 - GoT에서 그래프 전체를 탐색하며 반복적으로 3~5단계를 호출하며 그래프를 성장
역할	자원 최적화 및 최적 경로 탐색, 깊이 우선(DFS)이나 너비 우선(BFS) 변형도 가능
중요성	무작위 탐색 대비 효율적이며 GoT의 분해(decomposition)와 연계

[표 III-20] 그래프 확장 단계

2.4.3.7 목표 상태 도달 시 최종 경로 선택

구분	내용
의미 및 내용	- 그래프가 목표 상태(예: 문제 해결 완료)에 도달하면 최종 경로를 선택 - 최고 점수 경로(노드-에지 시퀀스)를 추출하여 최종 출력 생성 - 목표 도달 기준은 평가 점수 임계값 초과 또는 최대 반복 도달
역할	전체 프로세스 마무리, 여러 경로 중 투표(voting) 나 평균으로 최종 답변 결정
중요성	- 이 단계에서 GoT의 장점(다중 경로 통합)이 드러남 - 실패 시 그래프 재탐색 - 다단계 추론 문제에 적합함

[표 III-21] 최종 경로 선택

2.4.4 GoT 데이터 응용 도메인 및 사례

2.4.4.1 Multi-hop QA (HotpotQA, StrategyQA)

- “한 번에 답을 알 수 없고, 여러 단계(2~5hop)를 거쳐 정보를 모아야 비로소 정답을 찾을 수 있는 질문” 즉 “퍼즐 조각 여러 개를 맞춰야 답이 나오는 질문”을 의미
- Multi-hop QA(HotpotQA, StrategyQA 등)에서 GoT는 현재 가장 강력한 성능을 내는 프레임워크 중 하나이며, 특히 검색 증강 + GoT 조합이 SOTA를 연이어 갱신

2.4.4.2 지식추론 / Graph QA

- 지식 추론과 Graph QA(그래프 질의 응답)는 지식 그래프(KG) 기반, 복잡한 질문을 여러 단계로 분해·추론하는 작업으로 GoT는 이 분야에서 KG를 추론 그래프의 백본으로 활용하여 LLM의 환각을 줄이고, 구조화된 비선형 추론을 강화
- 현재는 GoT 응용은 KG를 동적으로 구축하는 형태로 진화했으며, GraphRAG나 KG-IRAG 같은 프레임워크와 결합되어 SOTA를 달성

2.4.4.3 Code 추론 (GoT-Code, 2025)

- GoT-Code은 LLM을 활용한 코드 생성, 디버깅, 설명, 검증 등의 작업을 의미하며 복잡한 프로그래밍 문제를 논리적으로 풀어내는 과정을 포함
- GoT는 이러한 분야에서 코드 관련 사고를 그래프 구조로 조직화, LLM의 선형적 추론 한계를 극복
- 노드(node)는 코드 스니펫, 중간 로직, 또는 검증 아이디어를 에지(edge)는 변환을 나타내어 비선형적·의존성 기반 코딩을 가능하게 함

2.4.4.4 창의적 기획(Creative planning)/스토리 그래프 생성(story graph generation)

- 창의적 기획(소설·영화·게임 스토리, 광고 캠페인, 제품 디자인 브레인스토밍 등) 분야에서 GoT는 “가장 강력하고 실용적인 창작 도구”로 급부상
- 2024년 말부터 2025년까지 발표된 시스템들은 모두 CoT → ToT → GoT 순으로 발전하여 이제는 GoT 없이는 SOTA급 창작물을 만들기 어렵다는 중론이 다수
- 기존 작가들은 “아이디어 브레인스토밍 + 초고 생성”은 GoT에게 맡기고 본인은 감정 묘사·대사 톤 조정 같은 고차원 작업에만 집중하는 워크플로우로 전환하는 추세

예시

Root

```


├── Act 1: 현재 - 보스 딸 납치 (3개 버전)
│   ├── 버전A: 딸이 살해당함 → 복수극
│   ├── 버전B: 딸이 살아있음 → 구출극
│   └── 버전C: 딸이 배신자임 → 반전극 → (점수 최고)
├── Act 2: 시간여행 기술 발견 (5개 방법 브랜치)
│   ├── 과학자 협박
│   ├── 고대 유물
│   ├── 꿈 속 세계 ← (Aggregate with 버전C)
│   └── ...
└── Act 3: 과거에서 딸을 구하려다 자신이 납치범이 됨 (파라독스 루프)
    → 4개 해결책 → 최고 점수 경로 자동 선택 → 최종 시나리오 출력
  
```

2.4.5 GoT 변형 및 확장형 연구 사례

2.4.5.1 Adaptive Graph of Thoughts (AGoT)

Adaptive Graph of Thoughts (AGoT) 주요 내용

- LLM의 추론 능력을 추론 시점에서 동적으로 강화하는 그래프 기반 프레임워크
- 2025년 2월 arXiv에 발표된 논문 "Adaptive Graph of Thoughts: Test-Time Adaptive Reasoning Unifying Chain, Tree, and Graph Structures에서 Pandey 등에 의해 제안
- CoT, ToT, GoT를 통합하여 복잡한 쿼리를 재귀적으로 분해하고, 동적 Directed Acyclic Graph (DAG)를 구성
- AGoT의 핵심은 "적응성(adaptivity)"으로, 고정된 구조 대신 쿼리의 복잡도에 따라 그래프를 실시간으로 확장·축소
- 이는 LLM의 선형적·비선형적 추론 한계를 극복하며, 특히 과학적·탐색적 문제 해결에서 강점을 보임



[그림 III-6] Adaptive Graph of Thoughts (AGoT)


- CoT구조에서 보다 복잡한 추론 패턴으로 진화한 구조적 변화를 보여줌
- CoT는 순차적 추론을 사용하고, ToT는 분기형 경로로 GoT는 임의의 연결과 정제가 가능한 구조를 제공하며, 준-선형(quasi-linear)구조를 구현
- AGoT 프레임워크는 재귀적 그래프 구조(주황색 원은 중첩 계산을 의미)를 통해 이러한 접근법을 통합하면서도, 방향 비순환 그래프(DAG) 형태의 연결성을 유지

※출처: <https://arxiv.org/pdf/2502.05078>

2.4.5.2 Hierarchical GoT (HGoT)

Hierarchical GoT (HGoT) 주요 내용

- HGoT는 LLM의 사실성을 향상시키기 위해 설계된 계층적 그래프 기반 프레임워크
- 2024년 2월 arXiv에 발표된 논문 "HGoT: Hierarchical Graph of Thoughts for Retrieval-Augmented In-Context Learning in Factuality Evaluation"에서 Fang 등에 의해 제안
- 검색 증강 검색(RAG)과 인-컨텍스트 학습을 결합하고 LLM의 환각 문제를 해결하기 위해 쿼리를 계층적으로 분해
- 다층 그래프를 통해 의존성을 관리하여 사고의 품질을 평가하여 가중 투표를 수행




[그림 III-7] Hierarchical GoT (HGoT)

※출처: <https://arxiv.org/pdf/2402.09390>

2.4.5.3 GoT + RL (Reinforcement-Learning based)

GoT + RL 주요 내용

- GoT와 강화학습의 결합은 LLM의 구조화된 추론 능력을 RL의 보상 설계와 최적화 과정에 통합하는 접근으로, 복잡한 작업에서 인간 전문가 의존성을 줄이고 자동화된 보상 함수 생성을 가능
- 가장 대표적인 방법은 2025년 9월 arXiv에 발표된 Reward Evolution with Graph-of-Thoughts (RE-GoT)로, GoT의 그래프 기반 작업 분해를 RL의 보상 진화(reward evolution)에 적용한 바이-레벨(bi-level) 프레임워크
- LLM과 VLM(Visual Language Model)을 결합하여 RL 에이전트의 성능을 향상
- 기존 LLM 기반 보상 설계의 환각과 다단계 작업 처리 한계를 극복
- 특히 로봇틱스와 조작 작업에서 성공률 향상을 보임



[그림 III-8] GoT + RL

상위 레벨은 VLM을 사용해 롤아웃(rollout) 영상들을 평가하여 시각적 피드백을 제공하고, 하위 레벨은 그래프 기반 추론 방식을 활용하는 LLM을 통해 보상 함수를 정제함


- 환경 추상화(environment abstraction)를 사용, LLM에게 프롬프트 제공, 로봇시스템과 연결
- LLM은 작업을 텍스트 속성을 가진 그래프(text-attributed graph) 형태로 분해
- 그래프 구조와 시각적 피드백이 주어진다면, LLM은 보상 함수를 정제
- VLM은 롤아웃 영상을 분석하여 학습된 RL 에이전트에 대한 구조화된 피드백을 제공

※출처: <https://arxiv.org/pdf/2509.16136>

2.4.5.4 GoT + Tool-use (도구 사용)

GoT + Tool-use 주요 내용

- GoT와 Tool-use의 결합은 LLM의 그래프 기반 추론을 외부 도구(예: API 호출, 함수 실행)와 통합하여 복잡한 그래프 추론 작업을 강화하는 프레임워크
- 가장 대표적인 예는 2024년 12월 arXiv에 발표된 GraphTool-Instruction으로, GoT의 작업 분해 원리를 활용해 그래프 추론을 세부 서브태스크로 쪼개고, 도구 호출(tool calling)을 통해 구조화된 실행 가능
- 이 접근은 LLM의 그래프 구조 인식 부족과 도구 호출 오류를 해결하며, 특히 그래프 분석과 매개변수 쿼리에서 SOTA(State-of-the-Art) 성능을 달성함
- 이 결합의 핵심은 GoT의 비선형 그래프 구조(노드: 생각, 에지: 의존성)를 도구 호출의 순차적 실행과 매핑하여, LLM의 환각과 비효율성을 최소화함. 로보틱스나 지식 그래프 탐색 등에 확장 가능



[그림 III-9] GoT + Tool-use

- Basic Graph Analysis Task는 추가적인 도구 파라미터를 요구하지 않지만 Parametric Graph Query Task는 추론을 위해 특정 입력 파라미터가 필요
- WL-Graph는 작업 길이가 4096 토큰 이내인 경우를 의미하고, EL-Graph는 그 반대의 경우를 나타냄
- 위 그림에서 붉은색 화살표는 BGA-Task의 추론 과정을 보여주며 파란색 화살표는 PGQ-Task의 과정을 나타내는데, 파라미터 추출의 정확도를 높이기 위해 Parameter-Instruction이 추가로 도입

※출처: <https://arxiv.org/pdf/2412.12152v1>

3

추론형 AI 강화 기법

3.1 ReAct (Reason+Act)

- ReAct는 2022년 NeurIPS 2022에 발표한 논문 “ReAct: Synergizing Reasoning and Acting in Language Models”에서 처음 제안된 추론(Reason) + 행동(Act)을 반복하는 최소주의 에이전트 프레임워크로 현재 ReAct는 거의 모든 최신 시스템(LangChain, LlamaIndex, AutoGPT, BabyAGI, MetaGPT, Agentic RAG 등)의 핵심 ReAct 루프로 사용되고 있음
- ReAct의 핵심 아이디어는 “LLM이 생각(Reason) → 외부 도구 호출(Act) → 관찰 결과 확인(Observation) → 다시 생각(Reason)…”을 반복하면서 문제를 해결하는 것

3.1.1 핵심 개념

구분	내용
추론	• 현재 상태를 해석하고 다음 행동 계획을 세우는 단계 • 단순히 떠오르는 생각을 나열하는 것이 아니라 명시적으로 다음 행동을 정당화하는 논리적 근거를 제시 • 현재 상태를 해석하고 구체적인 다음 단계를 결정 (예: “이 질문은 두 명의 인물이 연결된 다중 문제로 먼저 A라는 인물의 출생지를 알아야 B와 연결할 수 있다”)
행동	• 사고 단계에서 세운 계획을 실제로 실행하는 단계 • AI 모델은 사용할 수 있는 외부 도구 중 하나를 선택하고, 그 도구에 넘겨줄 정확한 입력값을 작성 • 도구는 위키피디아 검색, 구글 검색, 파이썬 코드 실행기, 계산기, 데이터베이스 쿼리, 웹 브라우저 조작 등 무엇이든 될 수 있음 • 중요한 점은 LLM이 “검색을 해야겠다”라고만 말하지 않고, “Search[2022년 FIFA 월드컵 우승국]”처럼 도구 이름과 입력을 정확한 형식으로 출력
결과 확인	• 조치 및 실행(Action) 직후, 외부 도구가 반환한 결과를 받아들이는 단계 • AI모델은 이 새로운 정보를 맹목적으로 믿는 것이 아닌 다음 추론단계에서 이를 비판적으로 검토하고 기존 지식과 통합 • 실행결과가 기대와 상이하다면 바로 다음 사고에서 “잘못된 키워드로 검색함”을 깨닫고 다른 조치를 취할 수 있음 • 이러한 단계는 끝없이 반복되어 한 번의 조치(실행)으로 문제가 해결되지 않으면 실행결과를 바탕으로 새로운 사고를 생성하고 또 다른 조치를 취함 • 최종적으로 AI모델이 “이제 모든 정보가 모여 더 이상 조치가 필요없다”로 판단하면 Final Answer를 출력하며 루프를 종료

[표 III-22] ReAct의 핵심개념

III

ReAct의 실제 구현 예시

• Q.

“2024년 파리 올림픽에서 한국이 금메달을 가장 많이 딴 종목은 뭐고, 그 종목에서 몇 개 땀어?”

• ReAct 전체 흐름

Thought 1: 질문은 최신 스포츠 결과이므로, 내 지식(2023년 9월까지)으로는 답할 수 없다. 실시간 검색이 필요하다.

Action 1: google_search

Action Input 1: 2024 파리 올림픽 대한민국 종목별 금메달 순위

Observation 1:

2024 파리 올림픽 대한민국 메달 집계 (2024.08.11 기준)

- 양궁: 금 4, 은 1, 동 1

- 태권도: 금 3, 은 0, 동 2

- 펜싱: 금 2, 은 3, 동 1

- 사격: 금 2, 은 2, 동 0

...

Thought 2: 검색 결과 양궁이 금메달 4개로 1위다. 태권도는 3개이므로 양궁이 가장 많다.

하지만 올림픽이 아직 진행 중일 수도 있으니 최종인지 확인해야 한다.

Action 2: google_search

Action Input 2: 2024 파리올림픽 폐회일

Observation 2: 2024 파리올림픽은 2024년 8월 11일 폐회식으로 공식 종료되었습니다.

Thought 3: 8월 11일에 이미 폐회했으므로 검색 결과는 최종 집계다.

양궁이 금메달 4개로 대한민국 최다 금메달 종목이다.

Action 3: N/A (더 이상 도구 필요 없음)

• Final Answer

2024 파리 올림픽에서 한국이 금메달을 가장 많이 딴 종목은 양궁이며, 총 4개의 금메달을 획득했습니다.

2.1.2 구조 및 작동 매커니즘

- Question → Thought → Action → Observation → Thought → ... → Final Answer 구조

단계	설명
Thought (Reason)	문제를 분석하고 다음 행동을 결정
Action	검색, 계산, 톨 호출 등 외부 행위 수행
Observation	행동 결과를 받아 Reason 단계에 반영
Loop	위 과정을 반복하며 점진적으로 정답 근접
Final Answer	종합적 reasoning 후 최종 결론 도출

[표 III-23] 단계별 메커니즘

3.2 Reflexion/Self-Reflection

- ReAct 이후 등장한 ‘자기 피드백(Self-feedback)’ 기반 LLM 추론 강화 모델
- Reflexion은 LLM이 자신의 실행 이력을 바탕으로 언어적 성찰(reflection)을 생성하고 이를 경험 기반 메모리에 저장하여 후속 시도에서 의사결정을 개선하는 방법론
- 이 방법은 모델 파라미터를 직접 업데이트하지 않고도 성찰 기반의 피드백을 반복적으로 재활용함으로써 성능을 향상시킬 수 있음

3.2.1 핵심 개념

- 문제 해결 후 성찰(Reflection) 단계를 추가하여 모델이 자신의 추론·행동 이력을 평가하고 실패 원인, 비효율적 선택, 개선 방향을 자연어 피드백으로 명시하도록 하는 구조
- 이후 재추론 시에는 이전에 생성·축적된 피드백을 컨텍스트(프롬프트/메모리)에 포함하여 수행하며 이 과정은 모델 파라미터를 직접 업데이트하지 않고도 입력 컨텍스트가 변화함으로써 의사결정(행동 선택) 품질이 개선되는 효과를 유도함
- 강화학습의 보상 신호와 유사하나 수치 보상 대신 자연어 피드백을 사용한다는 점이 특징으로 그 결과 별도의 재학습 없이도 언어 기반 피드백을 통한 자기 개선이 가능

구분	ReAct (Reason + Act)	Reflexion(ReAct+ Self-Feedback)
핵심목적	• 추론(Reasoning)과 행동(Action) 결합으로 문제를 단계적으로 해결	• LLM이 결과 평가(Self-evaluation) 후, 피드백을 통해 성능을 개선
작동방식	• 사고→ 실행 →결과 루프 반복	• ReAct 루프 + Reflection 생성 → Memory 저장 → 다음 시도에서 활용
오류처리방식	• 오류가 발생해도 동일한 방식 반복하여 오류 반복 가능	• 오류 원인을 언어로 분석 후 교훈 저장 • 다음 시도에서 전략을 실제로 변경
학습필요여부	• 모델 재학습 없이 단순 추론 방식으로 작동	• 재학습 없음 + 언어 기반 자체 개선 (Language-level improvement)
상태기억여부	• 개별 시도 간 기억 없음 (stateless)	• Reflection Memory 유지하여 이전 실패를 학습
출력구조	• Thought / Action 중심	• Thought / Action + Reflection / Lesson / Rule 추가
문제해결능력	• 단일 시도에 의존하여 난도 높은 문제는 실패 가능성이 높음	• 여러 번 시도할수록 성능 증가하여 적응형 문제 해결(Adaptive reasoning) 가능
필요요소	• ReAct 프롬프트 + 도구	• ReAct + Evaluator(채점기) + Self-Reflection Module + Memory
적합도메인	• 도구 기반 탐색, 검색, 환경 상호작용	• 장기적 문제 해결, 코드 디버깅, 강화학습형 환경, 자동 연구 에이전트

[표 III-24] ReAct vs Reflexion 비교

3.2.2 구조 및 작동 매커니즘

- 작업입력 → 추론 및 행동 → 결과 평가 → 자기 성찰 → 성찰 기반 재추론 및 재시도 → 최종 개선 답변


단계	내용
작업입력 (Task Input)	• 사용자가 주는 최종 목표 예시: “알프월드 환경에서 ‘냉장고에 사과를 넣고, 책상을 청소한 뒤, 침대에 누워라’라는 3단계 작업을 완수하라.”
초기 추론 및 행동 (Initial Reasoning & Action)	• 기본 ReAct 에이전트가 실행 • Thought → Action → Observation을 반복하며 목표 달성 시도 • 결과는 성공하거나 (대부분) 중간에 실패하거나 불완전 상태에서 종료
결과 평가 (Outcome Evaluation)	• 별도의 Evaluator (간단한 규칙 또는 작은 LLM)가 “성공 또는 실패”를 판단하거나 0~1 사이의 점수로 평가
자기 성찰 (Self-Reflection)	• 실패한 궤적 전체(Thought+Action+Observation 히스토리)와 평가 결과를 LLM에게 주고 성찰결과를 생성 • 출력 예시 (실제 생성되는 성찰결과) “나는 책상을 청소하기 전에 냉장고 문을 닫지 않아 사과가 바닥에 떨어졌다. 또한 침대에 눕는 명령을 너무 일찍 시도해 청소 도구를 놓쳤다. 다음에는 모든 물건을 제자리에 넣은 후에만 다음 단계를 진행해야 한다.” • 이 결과는 “언어적 강화 시도”로 작용하며, 장기 메모리에 영구 저장
성찰기반재추론 및재시도 (Revised Reasoning / Next Attempt)	• 새로운 시도 시작 시, 이전 시도에서 생성된 성찰결과 중 최근/핵심 항목 3~5개를 선별하여 프롬프트(컨텍스트) 선행 구간에 포함 • 이를 통해 모델이 동일한 오류를 반복하지 않도록 주의점·제약·전략 지침을 제공 (예) 당신은 과거에 2번 실패했습니다. 성찰 피드백 : ① [성찰결과 1], ② [성찰결과 2] 이 피드백을 따르며 새로 시도 • 에이전트는 위 피드백을 통해 훨씬 더 나은 계획과 행동을 수행
최종 개선 답변 (Improved Final Answer)	• 반복 시도 결과 중 성공한 해 또는 사전 정의한 평가 기준(예: 점수/정확도/제약 충족도)에서 최고 성과를 기록한 산출물을 최종 답변으로 채택 • 최종 답변과 함께 필요 시 오류원인과 같은 성찰 피드백을 요약하여 제공함으로써 실패 사례에도 “원인과 한계를 명시한 결과”를 제시

[표 III-25] Reflexion의 기본구조

- Reflexion의 구성요소와 역할은 아래와 같음

단계	내용
추론 모듈 (Module)	- 문제 해결 및 사고 수행 - LLM 본체가 담당하며, 현재 상황을 분석하고 다음에 어떤 행동을 취할지 계획하는 사고과정을 생성하여 ReAct의 기본 추론 엔진으로 작동
행동 모듈 (Acting Module)	- 외부 환경/도구를 상호작용 하는 단계로 ReAct 기반 수행 - ReAct 루프를 그대로 사용해 추론 모듈이 결정한 Action(검색, 코드 실행 등)을 실제로 수행하고 Observation을 받아오는 외부 환경과 유일한 연결 통
성찰 모듈 (Reflection Module)	시도가 끝난 뒤 결과를 입력 받아 “왜 실패했는지, 다음엔 어떻게 해야 하는지”를 자연어로 작성하는 별도 LLM(또는 동일 LLM)으로 출력이 바로 언어적 강화 신호
메모리 버퍼 (Memory Buffer)	- 과거 모든 Reflection Module 출력(언어적 반성문)을 저장하는 메모리 - 새로운 시도 시작 시 최근 3~5개의 반성문을 컨텍스트 앞부분에 삽입해 에이전트가 과거 실수를 반복하지 않게 함

[표 III-26] Reflexion의 구성요소 및 역할



[그림 III-10] Reflexion 작동과정

※ 의사결정(Section 4.1), 추론(Section 4.2), 프로그래밍(Section 4.3) 과제를 대상으로 적용

※ 출처: <https://arxiv.org/pdf/2303.11366>

3.3 MAR (Multi-Agent Reasoning)

- 여러 독립적 LLM 에이전트가 상호작용하여 협력적 추론을 수행하는 프레임워크
- 각 에이전트는 독립된 추론 수행(논증), 투표, 검증 등의 상호작용을 통해 최종 답안을 산출하는 “사회적 추론(Social Reasoning)” 또는 “집단 사고” 기반 인공지능
- MAR은 단순히 “복수의 에이전트를 동시 실행”하는 수준이 아니라, 각 에이전트가 독립적인 추론·행동·반성 루프(ReAct + Reflexion)를 돌리면서 동시에 서로에게 피드백을 주고받는 완전한 협업 시스템을 의미


3.3.1 핵심 개념

구분	내용
다양성	• MAR은 각 에이전트를 서로 다른 프롬프트·역할·모델 (GPT-4o, Claude-3.5, Llama-3.1 등)로 설정, 사고의 다양성을 극대화 • 예를 들어 한 에이전트는 낙관적 탐색, 다른 에이전트는 비관적 검증을 담당해 단일 모델이 놓치는 맹점을 보완
상호작용	• 에이전트들은 자연어 기반 메시지 교환을 통해 토론·피드백·이견 제기를 수행하며 특정 에이전트의 오류를 다른 에이전트가 검출·지적하고 즉시 보정하도록 유도 • 예를 들어 Critic 에이전트가 추론 또는 증명 과정의 특정 단계(예: 3번째 단계)의 오류를 지적하면 해당 에이전트는 Self-Reflection(Reflexion) 절차를 통해 근거와 추론 경로를 재점검하고 수정 • 이를 통해 단일 에이전트 대비 오류의 누적·전파 가능성을 낮출 수 있음
합의	• 최종 답변은 다수결 투표, 점수 가중 평균 또는 Manager 에이전트의 합의 조정을 통해 결정함 • 예를 들어, 7개 에이전트 중 5개가 동일 답변을 내면 자동 채택되며, 의견 분열 시 추가 토론 라운드를 진행
창발 지능 (Emergent Intelligence)	• 단일 에이전트의 성능이 제한적이더라도, 다중 에이전트를 역할 기반으로 분해(계획/추론/검증 등) 하고 결과를 상호검증한 뒤 통합(합의/평가기반 선택)함으로써 시스템수준에서 더 높은 문제 해결 성능이 나타나는 현상을 의미 • 이 현상은 에이전트 간 상호작용을 통해 오류 및 환각이 교차 검출, 보정되고 서로 다른 가설·풀이 경로가 병렬로 제시되어 탐색 범위가 확장되며 최종 단계의 합의/선택 절차를 통해 산출물이 정제되면서 발생 • 결과적으로 개별 에이전트의 한계를 구조적 협업으로 보완하여 정확도, 강건성, 재현성 등 시스템 성능 지표의 개선을 유도할 수 있음

[표 III-27] MAR 핵심 개념

3.3.2 MAR 구조와 구성요소

MAR의 구조



[그림 III-11] MAR

[구성요소]

- Supervisor : 회의 사회자 역할, 누가 말할지 결정
- 5개 전문 에이전트 : 각자 ReAct+Reflexion 돌림
- 메시지 토론 : 서로 자연어로 질문·반박·보완
- 공유 메모리 : 모두가 읽고 쓰는 공용 노트
- 합의 단계 : 70% 이상 동의하거나 Critic 승인 시 종료

[주요 유형별 MAR 프레임워크]

- Debate-based MAR 에이전트 간 찬반 토론을 통해 오류 수정 및 설득
- Collaborative MAR 각 에이전트가 부분 문제를 해결 후 병합
- Referee-based MAR 제3의 심사자(Referee)가 중간 평가 수행
- Hierarchical MAR 상위/하위 레벨로 분할된 의사결정 구조
- Self-Reflective MAR 각 Agent가 자체 Reflexion 후 상호 피드백

※출처:<https://arxiv.org/pdf/2501.06322>

3.4 TAR(Tool-Augmented Reasoning)/RAR(Retrieval-Augmented Reasoning)

- TAR은 LLM이 외부 도구(검색엔진, 파이썬 REPL, 계산기, API 등)를 필요 시 호출하고 도구 실행 결과를 근거로 다음 추론·생성 단계를 갱신함으로써 정확도와 신뢰성을 높이는 추론 아키텍처
- RAT은 TAR 중에서도 특히 외부 지식 검색을 핵심 보조수단으로 삼아 모델의 파라미터 기반 내부지식 한계를 보완하고 근거 문서에 추론/응답을 유도하는 접근
- LLM은 학습 시점에 내재화된 지식에 크게 의존하므로 최신 정보·도메인 변경·문서 업데이트가 있는 환경에서 단독 추론만으로는 사실성/재현성 확보가 어려우나 RAR은 검색을 통해 외부 지식을 비(非)파라미터 메모리로 결합함으로써 위 문제를 완화
- 또한 산술·통계·코드 실행·데이터 처리/시각화처럼 정확한 계산/실행이 필요한 작업에서 LLM이 자연어로만 “모사”하면 오류가 누락 될 위험을 해결하기 위해 TAR은 계산·실행을 외부 런타임에 위임해 오류를 줄이는 방향으로 수행

3.4.1 핵심 목표

단계	내용
최신 지식 확보	● LLM의 고정된 파라미터 지식 대신 실시간으로 외부 벡터 DB·검색엔진·기업 내부 DB에서 최신 문서를 검색해 컨텍스트로 주입 - 예: “2025년 11월 한국 AI 규제법 최신안”을 물으면 내부 지식이 아닌 국회·법제처 최신 PDF를 검색해 정확한 조항을 인용
정확도 향상	● 긴 산술 계산, 코드 실행, 파일 입출력, API 호출 등 LLM이 내부적으로 틀리기 쉬운 작업을 외부 도구에 위임해 100% 가까운 정확도를 보장 - 예: “123456 × 789123 계산해줘” → Python REPL 도구 호출 → 정확한 결과 반환
복합 추론 수행	● 단순 질문-답변이 아니라, “계획 수립 → 정보 검색 → 계산 → 검증 → 보고서 작성”까지 여러 단계를 순차·병렬로 수행하는 복합 문제를 해결 - 예: “우리 회사 2025년 매출 데이터를 분석해서 2026년 전략 보고서 작성해줘” ① Planner: 단계 분해 ② Researcher: 최신 데이터 검색 ③ Coder: pandas로 분석 ④ Critic: 오류 검증 ⑤ Writer: 보고서 작성

[표 III-28] TAR 및 RAR의 핵심 목표

3.4.2 TAR(Tool-Augmented Reasoning) 개념 및 구조

구분	내용
개념	- TAR은 LLM이 외부 도구(API, 계산기, 코드 실행기, 검색기 등)를 자율적으로 호출하여 복잡한 추론을 수행하는 프레임워크 - LLM이 문제 해결 과정에서 “어떤 도구를 언제, 어떻게 사용할지”를 스스로 결정하고 각 Tool의 출력을 추론맥락에 통합하여 최종 응답 생성
주요 구성요소	- Tool Interface API, 계산기, 데이터베이스, 코드 실행기 등 - Planner 도구 호출 시점과 종류 결정 - Executor Tool(실행툴) 호출 실행 및 결과 반환 - Integrator 도구(통합) 출력을 LLM 문맥으로 통합
작동단계	① 문제인식, ② 도구선택, ③ 도구실행, ④ 결과통합, ⑤ 추론지속

[표 III-29] TAR 개념 및 구조

3.4.3 RAR(Re-trival-Augmented Reasoning) 개념 및 구조


- RAR은 LLM이 외부 지식베이스(문서, DB, 웹 등)에서 관련 정보를 검색·결합하여 지식 기반 추론을 수행하는 구조
- RAG의 확장 개념으로, 단순 생성이 아닌 “검색 결과를 바탕으로 하는 단계적 추론(CoT)”을 결합

3.4.3.1 작동단계

단계	내용
1 질문생성	사용자의 원래 질문을 그대로 또는 LLM이 자동으로 검색에 최적화된 쿼리로 재작성 - 예: 2025년 한국 AI 규제법 최신 내용 → 2025년 인공지능산업진흥법 개정안 전문
2 외부검색	검색기(Retriever)가 벡터 DB·웹·기업 DB에서 쿼리와 가장 유사한 문서 후보군 (보통 5~50개)을 빠르게 반환
3 관련문서 획득	Re-ranker/LLM 평가를 통해 후보 문서의 관련성을 재평가하고 상위 K개(3~10개)를 선정
4 문맥 통합	선정된 문서들을 [문서1][문서2]... 형태의 참조 블록으로 포함하거나 모델이 요약·압축하여 컨텍스트 윈도우 한도 내에 수용되도록 구성
5 추론 및 답변 생성	통합된 외부 문맥(참조문서)과 사용자 질의를 입력으로 하여 LLM이 추론을 수행하고 참조 근거(문서 인용)를 명시한 최종 답변을 생성

[표 III-30] RAR 작동 단계

3.4.3.2 핵심모듈



[그림 III-12] RAR 접근방법 개요

구분	내용
검색 질의 생성, 유사문서 추출	- 사용자 질문 또는 LLM이 생성한 최적화된 쿼리를 받아 외부 벡터 DB·웹·기업 지식베이스에서 의미적으로 유사한 문서 후보군을 추출 2025년 표준은 BGE, ColBERTv2, Voyage 등 Dense Retriever*이며 Hybrid 방식(키워드+벡터)은 정확도가 추가 상승 * 문장·문서 전체의 의미를 고차원 실수 벡터(dense vector, 보통 768~1024차원)로 압축해 표현하고, 코사인 유사도 또는 내적으로 가장 비슷한 문서를 찾아내는 검색 방식
관련도 기반 정렬	검색기가 뽑은 후보 중 실제 관련도·최신성·신뢰도를 재평가해 Top 3~10 문서로 압축
독해/생성기 (Reader/Generator)	- 선정된 문서를 프롬프트 컨텍스트에 참조 블록으로 포함하거나 요약·압축 - 컨텍스트 윈도우 제약 내에서 통합한 후 질의에 대한 최종 추론을 수행하고 답변 생성 - 필요 시 근거 문서 식별자(예: [문서1], [문서2])를 인용하여 근거를 명시 - 검색 결과가 없거나 관련성이 기준치에 미달하는 경우에는 외부 근거 없이 내부 지식만으로 답변을 생성하도록 처리할 수 있음
메모리 모듈	- 과거 검색 쿼리·검색된 문서·최종 답변·사용자 피드백을 저장해 재사용하거나 캐싱 - 장기 메모리는 벡터 DB, 단기 메모리는 LangGraph State 또는 Redis에 저장 - 동일 질문 시 재검색 없이 즉시 응답해 속도·비용을 70% 이상 절감

[표 III-31] RAR 핵심모듈

3.4.4 TAR & RAR의 공통점과 차이점

구분	TAR	RAR	공통점
목적	계산·실행·외부 기능 정확도 100% 보장	최신·정확한 사실 지식 제공 (환각 제거)	LLM의 내재 한계 보완
주요 외부의존	Python REPL, 검색 API, 계산기, 파일시스템, DB API 등	벡터 DB, 웹 검색, 기업 지식베이스	외부시스템 필수
환각감소 효과	수학·코드·사실 확인 영역에서 극대화	사실·최신 정보 영역에서 극대화	환각 감소
실시간성	도구 호출마다 0.5~3초 지연	검색·재순위화(Re-ranking) 0.3~1.5초 지연	처리과정 특성상 응답 지연이 증가할 수 있음
비용구조	API·코드 실행 비용	벡터 DB 조회 및 재순위화(Re-ranking) 추가비용 발생	토큰 외 추가 비용 발생

[표 III-32] TAR & RAR의 공통점과 차이점


4

도메인/표현 확장 적용기법

4.1 Embedding CoT

- 추론 단계(Chain-of-Thought)를 자연어 문장으로 직접 제시하는 대신, 추론 과정에서 나타나는 단계적 구조·패턴을 임베딩(벡터) 표현으로 변환·압축하여 활용하는 접근 방식
- 텍스트 기반 CoT가 ‘서술형 중간 단계’를 통해 논리 전개를 명시화하는 방식이라면, Embedding CoT는 추론 단계 간 관계(순서, 구조, 유사성 등)를 벡터 공간에서 표현하고, 이를 기반으로 추론 경로의 일관성·유사성·정합성 평가 또는 학습 신호(특징/보상/라벨 등)로 활용할 수 있음
- 텍스트 기반 CoT 프롬프팅은 중간 추론을 포함해 성능 향상을 도모할 수 있으나, 단계가 길어질수록 토큰이 증가해 컨텍스트 윈도우 소모 및 응답 지연·비용이 늘 수 있음
- Embedding CoT는 이러한 제약을 완화하기 위해 임베딩 기반 표현을 프롬프트 입력 또는 모델 내부 처리에 결합해 토큰 효율을 높이면서 추론 구조 정보를 유지하는 것을 목표로 함

4.1.1 개념 및 구조



[그림 III-13] Embedding CoT의 전체 구조

※출처: <https://arxiv.org/pdf/2410.13640>

- Embedding CoT는 복잡한 추론 과정을 담고 있는 원본 CoT 텍스트를 임베딩 벡터로 변환하고 이 압축된 벡터 표현을 LLM의 입력 시퀀스에 통합하여 추론을 유도
- Embedding CoT의 구조는 크게 세 가지 요소로 구성

구분	내용
원본 CoT (Source CoT)	● 문제와 해답 사이 논리적 단계를 상세히 보여주는 일반적인 텍스트 기반의 추론 과정
임베딩 모듈 (Embedding Module)	● 원본 CoT 텍스트를 고정된 길이의 벡터(예: BERT, RoBERTa 등)로 변환하는 역할
LLM 모델	● 변환된 임베딩 벡터를 입력 프롬프트의 특정 위치에 ‘주입(Injection)’받아 추론을 수행하는 주체 ● 이 벡터는 모델의 내부 상태에 영향을 미쳐 원하는 추론 경로를 활성화

[표 III-33] Embedding CoT 구조

4.1.2 작동원리 및 주요 장단점

- Embedding CoT는 다음과 같은 단계를 통해 작동

구분	내용
CoT 임베딩 생성	대상 문제에 대한 이상적인 추론 경로가 포함된 예시를 수집하고 수집된 CoT 텍스트는 범용 임베딩 모델을 사용하여 하나의 고차원 벡터로 변환
임베딩 주입 위치 결정	생성된 임베딩 벡터는 LLM의 입력 토큰 시퀀스 중 특정 위치에 삽입
LLM 어텐션 매커니즘 활성화	- LLM은 삽입된 임베딩 벡터를 일반적인 토큰 임베딩처럼 처리 - 이 벡터는 LLM의 어텐션 메커니즘(Attention Mechanism)을 통해 모델의 다른 부분(질문 및 출력)에 영향을 미침
압축된 추론경로 유도	임베딩 벡터는 긴 텍스트 추론의 의미 요약물 담고 있으므로, LLM은 이 벡터를 참고하여 명시적인 중간 단계 출력 없이 원하는 추론 단계를 따라 답변을 생성

[표 III-34] Embedding CoT 구조

- 효율성, 추론능력, 유연성 측면의 주요 장단점이 존재하여 특성을 고려하여 적용

구분	장점	단점
효율성	프롬프트 길이(토큰) 감소 CoT 텍스트 벡터압축으로 Latency와 API 비용 절감	임베딩 모델 의존성 CoT 텍스트의 벡터 변환 임베딩 모델의 성능에 최종추론 결과가 크게 의존
추론능력	추론 성능 유지 토큰을 줄임에도 불구하고 CoT의 추론 강화효과는 대부분 유지	임베딩 품질과 손실 텍스트 기반 CoT가 벡터로 압축될 때 일부 미세한 정보가 손실될 수 있음
유연성	다양한 위치에 삽입 가능 임베딩 벡터를 프롬프트의 여러 위치에 유연하게 삽입하여 추론 제어가 용이	가시성 부족 LLM의 내부에서 추론이 진행되므로, 중간 추론 과정의 투명성이 낮아 디버깅이 어려움

[표 III-35] Embedding CoT의 장단점

4.1.3 적용사례


- Embedding CoT는 주로 추론 능력과 효율성이 동시에 요구되는 사례에 적용

구분	내용
실시간 질의응답 시스템 환경	• 짧은 지연 시간으로 복잡한 질문에 대해 추론 기반 답변을 제공해야 하는 챗봇이나 검색 엔진에 유용
리소스 제약환경에 적용	• 모바일 기기나 엣지 컴퓨팅 환경 등에서 토큰 비용과 컨텍스트 창 크기가 제한적일 때 추론과정 압축에 활용
다단계 복합추론	• 여러 단계를 거쳐야 하는 복잡한 수학 문제나 논리 퍼즐을 해결할 때, 각 단계의 추론을 임베딩 형태로 미리 주입하여 전체 프로세스를 가이드
전문 도메인 및 지식 주입이 필요한 경우	• 특정 전문 도메인의 복잡한 지식 구조나 규칙을 임베딩하여 모델이 해당 도메인의 논리를 따르도록 유도할 때 사용

[표 III-36] Embedding CoT 적용사례

4.1.4 구현단계 및 절차

- Embedding CoT를 구현하는 일반적인 단계는 다음과 같음



[그림 III-14] CoT 경로를 임베딩으로 압축하는 구조 다이어그램

※출처: <https://arxiv.org/pdf/2310.19750>


구분	내용
CoT 데이터셋 구축	• 해결하고자 하는 문제 유형에 맞춰 질문-추론 과정-정답으로 구성된 예시 데이터셋을 준비
임베딩 모델 선택 및 훈련	• CoT 텍스트를 벡터로 변환할 임베딩 모델(e.g., Sentence Transformers, BGE)을 선택하고, 필요한 경우 CoT 데이터에 맞춰 파인튜닝을 수행하여 품질을 제고
CoT 임베딩 생성	• 구축된 CoT 텍스트를 선택된 임베딩 모델을 사용하여 벡터로 변환하고 저장
AI모델 통합 및 주입	• 사용자가 입력하면, LLM의 입력 시퀀스를 구성하고 사전에 생성된 CoT 임베딩 벡터를 LLM의 입력 임베딩 레이어에 직접 주입
추론 및 텍스트 생성	• 주입된 임베딩 벡터를 바탕으로 LLM이 답변을 생성하도록 하고, CoT 결과와 비교하여 추론 정확도와 효율성을 평가하고 조정

[표 III-37] Embedding CoT 구현 단계 및 절차

4.2 Embodied CoT

- 로봇/에이전트 영역에서는 사전학습된 비전-언어 모델과 로봇 시연/궤적 데이터를 결합해 관측으로부터 행동을 생성하는 VLA(vision-language-action) 계열이 활발히 연구되고 있으며 물리 환경의 장기 과업에서는 행동 시퀀스의 계획·실행이 중요한 요구로 제시됨
- 일부 연구에서는 기존 VLA가 주로 직접 입력-출력 매핑에 치우쳐 복잡 조작에 필요한 추론 단계 및 시각적 계획 능력이 부족하다고 지적
- 또한 로봇 정책은 센서 관측과 로봇 상태에 근거한 판단이 필요하므로 서브태스크(sub-tasks)를 순수 의미적으로만 서술하는 형태의 CoT가 불충분할 수 있다는 문제의식 제시
- 이러한 문제의식 하에서 행동을 예측하기 전에 계획(plan)/중간목표 등 명시적 추론 단계를 생성·활용하도록 구성하는 접근이 제안되었으며 단계의 구체적 형태는 연구에 따라 계획·모션·시각적 근거 요소를 포함하는 방식 등 다양하게 정의되고 있음

4.2.1 개념 및 구조



[그림 III-15] Embodied CoT의 전체 구조

※출처: <https://arxiv.org/pdf/2407.08693>

- Embodied CoT는 과업에서 시각 관측과 자연어 지시, 필요시 로봇 상태/센서 정보를 입력으로 받아 행동 출력 이전에 계획·중간목표 등 명시적 중간 추론 단계를 생성 및 활용하도록 설계된 접근
- 즉, Embodied CoT는 관측 및 지시 → 단계적 추론 → 최종행동(action) 또는 답변 형태이며 추론 단계의 형태는 연구에 따라 다양하게 적용
 - (1) 계획(plan)·서브태스크(sub-tasks)·모션(motion) 등 텍스트 기반 단계
 - (2) 행동생성 전에 모델이 예측/생성한 목표 관측 이미지로, 이후 행동이 해당 목표 상태를 달성하도록 중간추론 단계에 시각적 목표(visual goals)를 활용
 - (3) 계획을 활용한 특징 선택 및 질의기반 제어 연결
- 이들 접근은 공통적으로 중간 단계 산출물을 조건(conditioning)으로 삼아 행동을 생성하고 조작·내비게이션 등 Embodied 과업 수행에 활용

4.2.2 핵심 요소

핵심 요소	세부 요소	설명
멀티모달 입력 처리 (Multimodal Input)	인지(perception) 및 정합화(grounding)	• 지시를 입력 받아 '무엇을 말하고자 하는지 연결'하는 단계 • 인지(perception)는 모델이 시각 관측과 자연어 지시를 함께 입력으로 받아 과업 수행이 필요한 정보를 모델이 처리 가능한 표현으로 통합하는 단계 • 정합화(grounding)는 지시(언어)에서 언급된 대상·속성·관계가 관측/상태의 표현과 대응되도록 연결하여 중간 추론이 실제 관측 근거에 기반하도록 만드는 것을 의미 • 정합화는 단순 객체 검출을 넘어 객체 위치, 바운딩박스, 로봇좌표 위치처럼 관측에 직접 대응되는 단서가 중간추론 단계와 결합되어 이후 행동 결정에 활용되도록 하는 것을 포함
추론 단계	공간 추론 및 정합화(grounding)	• 최종행동을 결정할 수 있도록 대상 객체의 위치, 상대관계, 접근 가능성 등 '공간단서를 추론 단계에 결합'하여 공간적으로 구체화 • 추론 과정이 실제 장면에서 실행 가능하도록 관측 및 로봇 상태에 근거해 대상 객체의 위치, 상대관계 등 공간 단서를 추론 단계에 결합 • 일부 연구에서는 이를 위해 객체 바운딩 박스나, 로봇좌표 위치와 같이 공간적으로 근거를 확인할 수 있는 요소를 추론 단계에 포함

[표 III-38] Embodied CoT 핵심요소

III

4.2.3 Embodied CoT의 특징

항목	텍스트 기반 CoT	Embodied CoT	차이의 원인
입력형태 (input)	텍스트 (프롬프트) 중심 입력	시각 관측(이미지/비디오) + 자연어 지시, 필요시 로봇/환경의 상태 (센서/상태추정치 등)	시각·공간·상태 정보가 추론의 핵심 근거로 텍스트만으로 필요 정보를 충분히 제공하기 어려움
추론대상	문제-정답 중심 (논리·지식·계산 등)	물체·공간·상태를 바탕으로 실행 가능한 행동의 선택	물리환경은 제약(충돌, 안정성 등)이 존재하여 추론이 '가능한 행동/상태' 범위 내에서 수행되어야 함
추론 구조	서술형 단계 (텍스트 CoT) 중심	[관측·지시] → [추론] → [추론을 통한 행동 생성]	물리 환경에서는 미래 결과 예측과 계획 검증이 중요
출력 형태 (Output)	최종 답변(텍스트) 및 설명	행동(제어/궤적/행동 시퀀스) 또는 행동계, 필요시 설명 추가	로보틱스/VLA계열은 관측·지시를 바탕으로 실행가능한 행동 출력을 생성
검증·평가 기준	정답 정확도, 논리 일관성 등 텍스트 중심 지표	과제 성공률, 충돌/제약 위반 여부, 안전성, 실행 가능성 등 결과 기반 지표	물리과제는 '맞는 말'보다 '실행결과와 제약준수'가 핵심으로 평가 기준이 결과·안전 중심으로 확장
데이터/ 라벨 구성	문제, (선택)추론단계, 정답의 텍스트 라벨 중심	센서 관측 + 상태/행동+ 작업 성공/실패 라벨 (또는 시뮬레이션 결과)	- 행동 학습에는 관측-행동과 환경상호작용 데이터가 필요 - 데이터 수집 비용이 높아 시물/합성데이터 활용 다수
데이터 확장/전이	주로 텍스트 변형으로 증강	시뮬레이션 합성데이터, 도메인 랜덤화, sim-to-real 전이 등	현실 데이터 수집이 고비용이므로 합성데이터 등으로 분포를 확장하고 현실 전이를 지원하는 방법이 다수

[표 III-39] Embodied CoT와 텍스트 기반 CoT의 차이

4.2.4 Embodied CoT 적용 사례

구분	내용
NVIDIA Cosmos Reason	• 비디오·텍스트 입력을 기반으로 단계적 추론을 수행하여 로봇 및 자율주행 등 의사결정/설명 생성과 합성데이터의 비평·큐레이션을 지원하는 추론 모델 • NVIDIA의 GROOT-Dreams 등 합성 궤적/시나리오 생성 워크플로에서는 생성된 후보 시나리오의 품질·성공 가능성을 평가해 ‘부적절한 결과’를 걸러내는 용도로 활용

[표 III-40] Embodied CoT 적용사례

4.2.5 Embodied CoT 필요성

구분	내용
로봇 조작의 안정성 평가	• 실행 전 후보 행동에 대해 물체 낙하, 미끄러짐, 충돌 가능성 등 물리적 결과를 단계적으로 예측·점검하도록 구성할 수 있음 • End-to-end 방식은 실패 원인 해석이 제한될 수 있으나 단계적 추론을 통해 실패의 원인(지지 안정성, 경로 제약 위반 등)을 구조적으로 드러내어 개발·검증 단계에서 취약점 진단 및 보완에 활용할 수 있음
비디오 물리 추론 정확성 향상	• 일반 비디오 예측은 사건의 발생 여부(예:낙하) 중심으로 학습되는 경우가 있으나 Embodied CoT는 원인(예:지지 조건 변화)과 과정(속도·가속도·접촉 변화 등)을 단계적으로 추론하도록 설계할 수 있음 • 이를 통해 물리적 인과관계 및 시간적 변화에 대한 설명력과 예측 정합성을 개선
오류 전파 방지	• 물리 환경에서는 초기 상태추정의 미세 오차가 장시간 수행 과정에서 경로 편차 또는 충돌 위험으로 누적될 수 있음 • 단계별로 제약(충돌, 도달가능성, 안정성 등)을 점검하고 필요시 재계획·보정을 수행하도록 구성하여 오류의 누적·전파 가능성을 완화하는데 활용할 수 있음
시뮬레이션-현실 전이 안정화	• 시뮬레이션 학습 모델은 현실 환경의 마찰, 조명, 센서 노이즈 등 분포 차이로 성능 저하가 발생할 수 있음 (sim-to-real gap) • Embodied CoT는 환경 파라미터 차이(예: 관측 노이즈)를 가정·추정하고 그 영향과 보정 전략을 추론하도록 설계함으로써 전이 안정성을 높일 수 있음
안전 중시 작업 (Safety-critical)	• 자율주행, 의료·물류 로봇 등 안전이 중요시되는 작업에서는 단일 오류가 안전사고로 이어질 수 있어 실행 전 위험 평가와 제약 준수가 필수적 • Embodied CoT는 행동 후보에 대해 위험요인(충돌, 인체 근접, 속도위반 등)을 단계적으로 평가하고 사전에 정의된 안전 기준(예: 위험점수 임계치 등)에 따라 실행·보류·재계획을 결정하도록 구성 가능 • 이를 통해 의사결정 근거를 구조적으로 제시하는 ‘설명 가능한 안전성’ 확보에 기여

[표 III-41] Embodied CoT 필요성

III

제2장

추론형 AI 주요 모델

자연어, 멀티모달, 합성데이터, Action(행동) 중심 데이터 유형별 주요 AI 모델을 안내

1

개요

1.1 LLM 데이터 추론모델

- 순수 텍스트(프롬프트, 논리 체인)로 추론 과정을 학습하며 주로 LLM에서 CoT 같은 단계적 텍스트 생성을 통해 논리/수학 추론 강화

아키텍처	모델	설명
CoT	OpenAI o1 (Reasoning Model)	- CoT를 내장한 RLHF 훈련 모델로, 텍스트 프롬프트를 단계별로 분해해 수학/논리 문제를 해결 - 학습 데이터: GSM8K 같은 텍스트 수학 데이터셋
	SIM-CoT	수학 독해 지식, 단계별 사고를 문자로 전개하여 문제 해결
Embedding CoT	CoT-T5-11B (CoT Collection 기반 T5 Fine-Tuned 모델)	- CoT rationale을 대규모(1.84M)로 추출해 파인튜닝된 T5 모델 - zero/few-shot 학습에서 CoT를 임베딩 공간에 내재화 - 임베딩이 reasoning chain을 캡처해 일반화 향상
ToT	DeepSeek-R1 트리	- 탐색으로 다중 경로를 생성하는 텍스트 기반 모델 - 긴 CoT 트레이닝, 데이터 합성 논리 체인, 계획 문제 (예: 퍼즐)에서 브랜치 탐색으로 오류 감소
	ToT_GPT	BFS/DFS 탐색 기반 다중 사고 경로 확장
	MCTS-ToT	MCTS 기반 탐색으로 고보상 추론 경로를 우선 선택
GoT	QwQ (QwQ-Reasoner)	- 근거/지식을 그래프(노드-관계) 형태로 구성해 추론을 지원 - MCTS와 결합해 후보 추론 경로를 탐색·선택 - 데이터: 텍스트 그래프(근거-관계) 구조 데이터셋 - 적용: 다중 가설 검증(예: 법률 논리)
	GoT-Huang	사고 단위를 그래프로 표현해 병렬 reasoning
SC-CoT	PaLM 540B	CoT-SC의 원래 평가 모델 중 하나로 대규모 few-shot 학습에 적합
	LaMDA	- CoT-SC 평가 모델로 ARC-challenge에서 +3.9% 향상 - 다중 추론 경로를 샘플링하고, 답을 일관성 기준으로 집계하여 정합성 강화 - 대화(Dialog)응용에 특화된 언어모델로 개방형 대화응답 생성 용이
ReAct	ReAct-GPT, Llama-ReAct	Reasoning과 Tool-call을 혼합
TAR	Toolformer, Gorilla	API/코드/DB 조회 등 외부 도구 활용
Reflexion	RCI	자신의 답변을 수정·개선하며 reasoning 최적화

[표 III-42] 자연어 데이터의 추론 AI 모델

1.2 LMM 데이터 추론 모델

- 텍스트+이미지/비디오/오디오를 통합해 시각적/언어적 추론 학습
- VLM(Visual Language Model)에서 CoT를 확장해 공간/시각 추론. 데이터는 이미지-텍스트 쌍(예: VQA 데이터셋)으로 주요 아키텍처로는 Multimodal CoT (시각-텍스트 체인), M-ICL (멀티모달 인컨텍스트 학습), Multimodal ToT (트리 기반 멀티모달 탐색) 등

아키텍처	모델	설명
Multimodal CoT (시각-텍스트 체인)	LLaVA-1.5 (LMM)	• 이미지+텍스트 입력으로 CoT 생성, RLHF로 정렬 - 데이터: LAION 같은 멀티모달 코퍼스 - 적용: VQA(Visual QA)에서 시각적 단계 추론 (예: "이미지에서 객체 위치 분석")
	VideoGPT-CoT, Video-Bench	• (Video CoT 계열) 질의 관련 프레임/구간을 선별해 입력 컨텍스트를 구성한 뒤, "단계적(CoT) 시간 추론(Temporal Reasoning)"으로 사건 순서·인과·상태 변화를 추론 • (Video-Bench) 비디오 생성 결과를 MLLM 기반으로 다차원 평가하기 위한 벤치마크로 평가 절차(구조화된 프롬프트/스코어링 등)를 제시
M-ICL (멀티모달 인컨텍스트 학습)	GPT-4o (Multimodal)	• 멀티모달 입력을 포함한 few-shot 프롬프팅으로(in-context) 추론을 유도·보조 • 프론티어급 LMM으로 멀티모달 추론 과제에서 오답 유형·실패 양상(근거 정합화, 시각 인식 오류 등) 분석에 활용 - 데이터: MMMU(Massive Multimodal Multitask)
Multimodal ToT	Gemini 1.5	• 수백만 토큰 수준의 장문 컨텍스트에서 텍스트, 이미지, 비디오, 오디오를 통합 처리하는 멀티모달 모델 • 장시간 비디오 QA 등 비디오 이해 과제에서 프레임 기반 정보에 자막/오디오 등 추가 단서를 결합해 추론 성능 강화 - 데이터: YouTube-8M 등 대규모 비디오 라벨 데이터셋 - 적용: 동적 장면 예측(예: 영화 QA 등)
Multimodal SC-CoT	BLIP-2	• 동결된 이미지 인코더와 대규모 언어모델을 Q-Former로 연결하여 적은 학습 파라미터로 비전-언어 과제(캡셔닝·VQA)를 수행 - 데이터: OCO/Visual Genome/CC3M/CC12M/SBU 및 LAION400M 일부 등 대규모 이미지-텍스트 쌍 기반 사전학습 - 적용: 이미지 캡셔닝, 시각 질의응답(VQA), 이미지-텍스트 검색(검색·정합화)

[표 III-43] 멀티모달 데이터의 추론 AI 모델

1.3 합성데이터 중심의 추론모델

- 시뮬레이션/생성 모델로 합성된 데이터(예: 물리 엔진 시뮬)로 추론 학습. 데이터 부족 보완, 특히 Physical AI에서 Sim2Real 전이. 아키텍처: SWiRL(단계적 RL), AutoReason(자동 CoT 생성)

아키텍처	모델	설명
Synthetic CoT (합성체인 생성)	SWiRL (Step-Wise RL)	- 합성 다단계 트래젝트리로 RL 학습, CoT 분해 - 데이터: 합성 QA/수학(GSM8K 합성 버전) - 적용: 도구 사용/수학에서 21% 상대 정확도 향상, HotPotQA에서 일반화
AutoReason	Auto-CoT Variant	- 자동 합성 CoT 체인 생성, 클러스터링으로 다양성 - 데이터: FLUX.1 같은 텍스트-이미지 합성. - 적용: LMM fine-tuning에서 오류 수정, 553k 예시 생성
UniFilter 합성품질필터링	MLLM-CTQ (Multimodal Classifier)	- 합성 데이터 품질 분류, "hard negative" 생성 - 데이터: UniFilter 큐레이션(10B 토큰) - 적용: MLLM pre-training에서 zero-shot reasoning 15% 향상
Synthetic ToT	Cosmos Predict (NVIDIA WFM)	- 합성 비디오 상태 예측으로 ToT. ViT+텍스트 임베딩 - 데이터: Omniverse 시뮬레이션 - 적용: 물리 예측(예: 객체 낙하)에서 Sim2Real 갭 60% 축소

[표 III-44] 합성데이터의 추론 AI 모델

1.4 액션 데이터 중심 추론모델

- 로봇/에이전트 행동 로그(상태-액션-보상)로 embodied 추론 학습

아키텍처	모델	설명
MAR	PaLM-E (Embodied VLM)	- 멀티모달 알고리즘 추론으로 액션 계획 - 데이터: RoboTurk(로봇 행동) - 적용: 로봇조작(예: 물건 집기)에서 공간 추론 통합
ReAct	Voyager (Embodied Agent)	- 추론-액션 루프, LLM+RL - 데이터: Minecraft 시뮬 행동 로그 - 적용: 오픈-엔드 탐험에서 3D 액션 시퀀스 생성
VLA (Action CoT)	Cosmos-Reason1 (NVIDIA)	- 물리 CoT로 embodied 결정. SFT+RL - 데이터: Omniverse 합성 액션 - 적용: 로봇/자율주행에서 next-step액션(예: 충돌피함)예측
RAR/TAR	GEN-0 (Generalist)	- Harmonic Reasoning으로 연속 액션 스트림 - 데이터: 물리 상호작용 로그 - 적용: humanoid 제어에서 실시간 reflex+추론(예: 청소작업)
Physical	PhysBench	물리 시뮬레이션과 reasoning 결합

[표 III-45] 액션 데이터의 추론 AI 모델

2


LLM 데이터 추론모델

2.1 OpenAI o1(Reasoning Model)

- OpenAI o1은 강화 학습(RL)을 통해 복잡한 추론 작업을 수행하도록 훈련된 LLM 시리즈로, 이전 모델(GPT-4o)보다 수학, 코딩, 과학 등에서 우수한 성능을 발휘
- 이 모델은 응답 전에 내부적으로 긴 '생각 체인'을 생성하여 문제를 단계적으로 분석하고 해결하며 o1-preview와 o1-mini 버전이 있으며, o1-mini는 속도와 비용 효율성을 강조한 경량 버전

2.1.2 주로 적용되는 도메인 분야

- 수학 및 과학분야에서 AIME(미국 수학 올림피아드)나 GPQA(PhD 수준 과학 벤치마크)에서 뛰어난 성능을 보였으며, 코딩 및 프로그래밍, 데이터 분석 및 의료/물리학 등 복잡한 연구작업에 적합




[그림 III-15] 대화턴에서 모델이 내부적으로 'reasoning' 단계를 거쳐 출력하는 과정

※출처: <https://cobusgreyling.medium.com/openai-o1-reasoning-models-49ccff5b3a20>

2.2 PaLM 2 – CoT

- PaLM 2 – CoT는 Google의 PaLM 2(Pathways Language Model 2) 모델에 CoT 프롬프팅 기법을 적용한 접근으로, 복잡한 문제를 단계적 추론 과정으로 분해하여 LLM의 reasoning 능력을 강화, PaLM 2의 다국어·코드 처리 능력을 활용해 수학·공상·논리 작업에서 성능을 크게 향상
- 효용성
 - PaLM 2-CoT의 주요 효용성은 모델 크기 확대 없이 프롬프팅만으로 multi-step reasoning을 향상시키는 데 있으며, 이는 데이터 효율적이고 비용이 효과적
 - 특히, 오류 수정과 대안 탐색을 자동화하여 복잡한 작업의 신뢰성을 높이며, 도메인 fine-tuning과 결합 시 전문가 수준의 성능을 발휘
- 주로 적용되는 도메인 분야
 - 수학 및 과학, 의료, 코드생성 및 사이버 보안, 다국어 번역 등에 주로 적용




[그림 III-16] PaLM 2 – CoT

※출처: <https://feel2certainty.tistory.com/32> 구글 PaLM 2 정리

2.3 SIM-CoT

- SIM-CoT (Supervised Implicit Chain-of-Thought)는 LLM의 암시적 CoT추론을 강화하는 플러그 앤 플레이 훈련 모듈로 명시적 텍스트 대신 잠재 토큰(latent tokens)을 통해 효율적인 단계적 추론을 실현
- 효율성
 - 명시적 CoT 대비 2.3배 토큰 효율성을 유지하면서도 성능을 초과하는 데 있으며, 훈련 후 디코더 제거로 추론 비용이 없어 실시간 응용에 적합. 이는 LLM의 추론 안정성과 확장성을 크게 강화해, 데이터의 효율적인 파인 튜닝을 가능하게 함
- 주로 적용되는 도메인 분야
 - 수학및논리추론, 공상및상식추론: CommonsenseQA·StrategyQA에서 안정적 다중 단계 reasoning 적용
 - 코드 생성 및 디버깅, 멀티태스크 학습(과학, 법률)등에서 적용




[그림 III-17] SIM_CoT-LLaMA3-CODI-3B

※출처: https://huggingface.co/internlm/SIM_CoT-LLaMA3-CODI-3B

※출처: SIM_CoT-LLaMA3-CODI-3B

2.4 임베딩 CoT에서 CoT-T5-11B (CoT Collection 기반 T5 Fine-Tuned 모델)

- CoT-T5-11B는 Flan-T5-11B를 기반으로 한 언어 모델로, CoT Collection의 1.84백만 rationale과 1,060개 작업을 통해 CoT 파인튜닝을 적용하여 zero-shot 및 few-shot 학습을 강화
- 모델 크기 확대 없이 CoT 파인튜닝만으로 작업 정확도를 높이는 데 있으며, 이는 데이터 효율적이고 비용 효과적으로 few-shot 학습에서 우수한 결과를 보여 일반화 능력을 강화
- 오픈소스 특성으로 커스터마이징이 용이하며 Hugging Face에서 공개 11B 파라미터 규모로 복잡한 추론 작업에 적합
- 수학 및 논리 추론, 공상 및 상식 추론, 코드 생성 및 프로그래밍, 도메인 특화 작업(의료·과학)이나 다국어 번역에서 few-shot 학습 강화




[그림 III-18] CoT-T5-11B 구조 다이어그램 또는 개념도

※ 출처: <https://aiml.com/t5-architecture-explained-encoder-decoder-model-comparison/> T5 Architecture Explained & Encoder-Decoder Model Comparison

2.5 (ToT) DeepSeek-R1트리

- DeepSeek-R1은 DeepSeek AI의 오픈소스 추론 모델로, 대규모 강화 학습(RL)을 통해 CoT 추론을 자율적으로 탐색하며 복잡한 문제를 해결
- DeepSeek-R1의 주요 효용성은 RL 기반 CoT로 모델 크기(671B 파라미터) 대비 비용을 절감하면서도 벤치마크에서 o1 수준 성능을 내는 데 있으며, 자율적 오류 수정과 반성(reflection)을 통해 추론의 투명성과 일반화 능력을 강화
- 수학 및 논리 추론, 공상 및 상식 추론, 코드 생성 및 프로그래밍, 도메인 특화 작업(의료·과학, Medical CoT 데이터셋 fine-tuning으로 진단·연구 작업 강화에 적합)




[그림 III-19] DeepSeek-R1 전체 아키텍처 개요도

※출처 : <https://deepseeksr1.com/r1>


2.6 (ToT) MCTS-ToT

- Monte Carlo Tree Search(MCTS)를 ToT에 결합한 고급 추론 프레임워크.
LLM(GPT-4/GPT-4o 등)이 각 노드에서 여러 후보 생각을 생성하고 시뮬레이션(rollout) → 평가 → 백업 과정을 반복하여 최적의 경로를 찾아냄
- 동일한 LLM을 사용하더라도 최적 경로를 체계적으로 찾아내어 성공률을 극대화하고, 실패 시에도 “왜 이 경로가 잘못되었는지”를 트리 구조로 명확히 확인 가능하여 디버깅과 해석이 훨씬 용이
- 특히 탐색 비용을 효율적으로 관리해 “한 번에 맞춰야 하는 고위험 작업”에서 주로 사용
- 고난도 수학·퍼즐, 전략적 게임·플래닝, 창의적 문제 해결(창작 글쓰기(소설 플롯 생성), 제품 디자인 브레인스토밍), 코드 생성·디버깅에 적합



[그림 III-20] MCTS의 기본 구조:선택 (Selection), 확장 (Expansion), 시뮬레이션 (Simulation), 역전파 (Backpropagation) 단계

※출처: <https://www.mlinterview.org/questions/how-does-monte-carlo-tree-search-work>




[그림 III-21] “MCTS 기반 언어모델 추론” 구조: MCTS 탐색트리+LLM결합 추론 framework

※출처: <https://llm-mcts.github.io> Large Language Models as Commonsense Knowledge for Large-Scale Task Planning NeurIPS 2023

2.7 (GoT)QwQ (QwQ-Reasoner)

- QwQ (Qwen with Questions)는 Alibaba Cloud의 Qwen 팀이 개발한 오픈소스 reasoning 모델 시리즈로 Graph of Thoughts(GoT)와 유사한 그래프 기반 다중 경로 추론을 통해 복잡한 문제를 탐색하며, 자가 반성과 질문(self-questioning)을 통해 깊은 사고 과정을 시뮬레이션
- 이 모델은 프롬프트에 대해 긴 reasoning chain을 출력하며, Hugging Face에서 공개되어 커스터마이징이 용이
- QwQ의 주요 효용성은 inference-time scaling을 통해 추가 컴퓨팅으로 reasoning 품질을 동적으로 향상시키는 데 있으며, 특히, 자가 반성 루프(self-dialogue)를 통해 오류를 자동 수정하고, 다중 경로 탐색으로 dead-end를 피해 성공률을 높이며, 출력의 투명성(전체 thinking trace 공개)으로 해석 가능성을 강화함
- 수학 및 논리 추론, 코드 생성 및 프로그래밍, 과학 및 공상 추론, 시각·멀티모달 reasoning에 적합




[그림 III-22] “Qwen” 제품 라인 (product line)

※출처: <https://skywork.ai/blog/qwen-llm-alibaba-cloud/>

※출처: What Is Qwen? A Plain-English Guide to Alibaba Cloud’s LLM Family

2.8 GoT-Huang

- Huang et al. (2023)이 제안한 GoT 프레임워크로 LLM의 추론을 임의 그래프로 모델링하여 CoT나 ToT의 한계를 넘어 복잡한 문제 해결을 가능하게 함
- 여기서 LLM의 "생각" 단위가 노드(정점)로, 의존성 관계가 에지로 표현되어 시너지적 결과 생성, 네트워크 증류, 피드백 루프를 지원
- GoT-Huang의 주요 효용성은 그래프 구조를 통해 LLM의 생각을 비선형적으로 연결·평가함으로써 비용을 줄이면서도 문제 해결 성공률을 높이는 데 있으며, 피드백 루프와 병합 연산으로 오류를 최소화하고 해석 가능성을 강화함
- 수학 및 논리 추론, 창의적 문제 해결, 계획 및 최적화, 코드 및 알고리즘 분야에 적합




[그림 III-23] Graph-of-Thought framework overview

※출처: <https://aclanthology.org/2024.findings-naacl.183.pdf>

※출처: GoT: Effective Graph-of-Thought Reasoning in Language Models

2.9 PaLM 540B

- PaLM 540B가 CoT-SC 추론형 데이터의 유효성을 확인하는 데 가장 적합한 AI 모델
- PaLM 540B는 대규모 few-shot 학습 능력으로 CoT-SC 데이터셋의 일반화와 오류 감소 효과를 정량적으로 평가하기에 이상적이며, BBH(Big-Bench Hard) 같은 복잡 reasoning 태스크에서 자가 일관성의 유효성을 입증




[그림 III-24] Pathways 시스템 개요

※출처: <https://arxiv.org/pdf/2204.02311>

2.10 Llama-ReAct

- Llama-ReAct는 Meta의 오픈소스 Llama 시리즈(특히 Llama-3 8B/70B)에 ReAct 프레임워크를 적용한 에이전트형 모델로, “생각(Reason) → 행동(Act) → 관찰(Observe)”을 반복하면서 외부 도구(검색, 계산기, 코드 실행기, API 등)를 자유롭게 호출
- 단순한 CoT가 “말로만 생각”하는 반면, ReAct는 생각 중간에 실제 행동을 삽입해 실시간 정보를 가져오고, 그 결과를 다시 생각에 반영하는 실행 가능한 추론 루프를 생성
- 외부 지식 실시간 보완하고, 장기·복잡 작업 해결하며, 완전 오픈소스로 로컬 실행 가능



[그림 III-25] LLM core + tool 호출 + scratch-pad reasoning 흐름

※출처: <https://www.gettingstarted.ai/llamaindex-ai-agent/>

2.11 (TAR) Toolformer, Gorilla

- Toolformer는 2023년 Meta AI가 공개한 6.7B 파라미터 규모의 언어 모델로, 훈련 단계부터 스스로 API 호출을 학습한 최초의 모델
- 인간이 쓴 CoT처럼 “생각”하는 게 아니라, 텍스트 중간에 [Search(“파리 날씨”)] → 21°C 같은 특수 토큰 형태로 도구 호출을 삽입하도록 fine-tuning해서, 모델이 스스로 언제·어떤 도구를 활용해야 할지 결정
- 추가 프롬프트 엔지니어링 없이 검색, 계산기, 번역기, 위키피디아, 달력 등 도구를 자유롭게 사용




[그림 III-26] Toolformer의동적 실행, 통합 흐름 예시

※출처: <https://arxiv.org/pdf/2302.04761#page=3>

2.12 Reflexion RCI

- RCI는 2024년에 나온 Reflexion의 최신·가장 강력한 버전으로, 단순히 “틀렸나요? → 반성 → 다시 시도”를 넘어 내부적으로 완전한 Chain-of-Thought를 여러 번 생성·비교·반성하면서 점진적으로 정답에 수렴하는 자가 개선 에이전트 모델
- 초기 추론과 과거 실패 사례와 현재 CoT를 비교해 0~10점으로 자기 평가하고 점수가 낮으면 오류 부분을 구체적으로 지적하고, 새로운 CoT를 다시 생성하는 반복루프를 가짐



[그림 III-28] Reflexion/RCI가 가진 핵심 개념


※출처: <https://medium.com/%40faulknerproject/reflexion-actor-evaluator-and-reflector-agents-12dc26979de6>

3 LMM 데이터 추론모델

- 텍스트+이미지/비디오/오디오를 통합해 시각적·언어적 추론 학습
- VLM(Visual Language Model)에서 CoT를 확장해 공간/시각 추론
- 데이터는 이미지-텍스트 쌍(예: VQA 데이터셋)으로 주요 아키텍처로는 Multimodal CoT (시각-텍스트 체인), M-ICL (멀티모달 인컨텍스트 학습), Multimodal ToT (트리 기반 멀티모달 탐색) 등 수행

3.1 LLaVA-1.5 (LMM)

- LLaVA-1.5는 이미지와 텍스트를 동시에 입력받는 LMM으로, 시각 정보를 보고 “단계적으로 생각하자”는 CoT를 자연스럽게 생성
- 예를 들어, 사진 속 물체 위치·개수·관계를 먼저 분석한 뒤, 그 다음에 질문에 답하는 식으로 시각적 단계추론을 수행
- 훈련은 LAION, CC3M, Visual Genome 등 대규모 이미지-캡션 데이터로 학습한 뒤, 고품질 GPT-4 생성 VQA/CoT 데이터를 통해 RLHF로 정렬
- 대표적인 적용 사례는 VQA, 이미지 캡셔닝, 시각적 수학/과학 문제 해결이며, 2024년 기준 오픈소스 LMM 중 실용성 1위로 평가




[그림 III-29] LLaVA-1.5의 특징(예: 비전-언어 융합, instruction-tuning, 이미지-텍스트 쿼리 처리 등)을 요약한 인포그래픽 스타일 다이어그램

※ 출처: <https://www.labellerr.com/blog/llava-and-llava-1-5-evolution-in-language-and-vision-fusion/>
Unlocking Multimodal AI: LLaVA and LLaVA-1.5's Evolution in Language and Vision Fusion

3.2 Video-Bench

- Video-Bench는 2023년 베이징대학교(PKU) Yuan Group에서 개발한 종합 벤치마크 및 Tool
- Video-based Large Language Models (Video-LLMs)의 성능을 체계적으로 평가하기 위해 설계
- 이 벤치마크는 세 가지 수준의 능력 평가(비디오 전용 이해, 사전 지식 통합, 비디오 기반 복잡 추론)를 통해 모델의 인식·이해·의사결정 능력을 측정
- GitHub에서 공개된 데이터와 평가 코드, 리더보드를 통해 연구자들이 모델을 제출하고 비교할 수 있으며, 비디오 이해의 미래 방향을 제시하는 데 초점을 맞춤




[그림 III-30] “Video-Bench 개요/프레임워크”

※출처: <https://arxiv.org/pdf/2504.04907v1>

3.3 GPT-4o(Multimodal)

- GPT-4o는 OpenAI의 네이티브 멀티모달 모델로, 텍스트·이미지·오디오·비디오를 단일 아키텍처에서 통합 처리하며, M-ICL을 통해 few-shot 데모(이미지+텍스트 쌍)를 프롬프트에 포함해 새로운 시각-언어 태스크를 즉시 적응
- 이는 전통적 fine-tuning 없이, 데모 시퀀스를 입력으로 주어 모델이 시각적 맥락(예: 객체 위치 분석)을 학습하도록 유도하며, zero/few-shot에서 인간 수준 성능을 발휘




[그림 III-31] 일반적인 멀티모달 아키텍처

※출처: <https://pmc.ncbi.nlm.nih.gov/articles/PMC11645129/>

3.4 (Multimodal ToT) Gemini 1.5

- Gemini 1.5는 Google DeepMind의 네이티브 멀티모달 모델 시리즈(Pro/Flash 버전)로, Multimodal ToT 아키텍처를 통해 이미지·비디오·오디오·텍스트 입력을 트리 구조의 다중 추론 경로로 탐색하며, 수백만 토큰의 장기 컨텍스트에서 추론을 수행
- ToT는 선형 CoT를 넘어 분기·백트래킹을 지원해 복잡한 시각적 문제(예: 비디오 QA나 다중 이미지 분석)에서 오류를 최소화하며, Gemini 1.5는 이를 위해 MoE(Mixture of Experts) 기반 스파스 아키텍처와 RLHF로 파인튜닝되어 최고성능을 달성
- 이 모델은 1M 토큰 컨텍스트로 1시간 이상의 장시간 비디오 이해를 가능하게 하며, ToT의 탐색적 추론으로 agentic 작업(예: 멀티스텝 계획)에 특화됨




[그림 III-32] Gemini 1.5 아키텍처 스플리터

※출처: <https://medium.com/@vanya203/google-gemini-1-5-test-ef3120a424b7>

3.5 (Multimodal CoT-SC) BLIP-2(Bootstrapping Language-Image Pre-training 2)


- BLIP-2는 Salesforce Research에서 개발한 효율적 멀티모달 모델로, Multimodal CoT-SC 아키텍처를 통해 이미지·텍스트 입력에 대해 다중 추론 경로를 생성하고, 다수결 투표를 적용해 일관된 CoT추론을 강화
- 이는 frozen ViT 이미지 인코더 + Q-Former (쿼리 트랜스포머) + LLM (FlanT5/OPT) 구조로, CoT-SC를 통해 VQA나 캡셔닝에서 오류를 줄이며, zero-shot 성능을 향상



[그림 III-33] BLIP-2의 프로세스

※출처: <https://arxiv.org/pdf/2301.12597>

- (왼쪽) Q-Former의 모델 아키텍처와 BLIP-2의 1단계 비전-언어 표현 학습 목표로 세 가지 목표를 동시에 최적화하여, 학습 가능한 임베딩들로 구성된 쿼리(query)들이 텍스트와 가장 관련성 높은 시각 표현을 추출하도록 유도
- (오른쪽) 각 목표에 사용되는 self-attention 마스킹 전략으로 쿼리와 텍스트 간 상호작용을 제어하기 위해 각 목표마다 서로 다른 마스킹 패턴을 적용



[그림 III-34] BLIP-2의 2단계 비전-투-언어 생성형 사전 훈련

※출처: BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models

- 동결된 LLM을 그대로 활용하여 부트스트래핑(bootstrapping) 방식으로 진행

4


합성데이터 추론모델

- 데이터 부족을 보완하기 위해 시뮬레이션/생성 모델로 합성된 데이터(예: 물리 엔진 시뮬)로 추론 학습

4.1 (합성 CoT 생성) SWiRL (Step-Wise RL)


- SWiRL (Step-Wise Reinforcement Learning)은 2025년 Google DeepMind와 Stanford University 연구자들이 제안한 합성데이터 생성 및 멀티스텝 RL프레임워크
- 단일 단계 RL의 한계를 넘어 복잡한 추론과 도구 사용을 위한 다단계 CoT데이터를 합성으로 생성하고 최적화
- 2단계 구조 (Stage1: LLM 기반 합성데이터 생성 및 프로세스 필터링, Stage 2: step-wise RL로 서부 추론단계 최적화)를 통해 도구 호출·추론 체인을 분해·학습하며, Gemma-2-27B 같은 중형 LLM을 기반으로 훈련되어 성능을 발휘

Stage 1 : Synthetic 데이터 생성



- 다단계 합성데이터 생성/필터링
 - CoT를 생성하거나, 검색 엔진·계산기 같은 도구를 호출하거나, 질문에 대한 답변을 생성

Stage 2 : Step-Wise RL Optimization



- Stage 1에서 생성된 합성데이터 대상으로 단계별 강화학습(step-wise RL)을 수행

[그림 III-35] 합성데이터 생성 및 Step-Wise RL Optimization


※ 출처: <https://arxiv.org/pdf/2504.04736#page=3>

※ 출처: Synthetic Data Generation & Multi-Step RL for Reasoning & Tool Use


4.2 (AutoReason) Auto-CoT Variant

- Auto-CoT의 자동 CoT 생성 아이디어를 유지하면서, 쿼리 재작성·분업·후처리 등을 추가해 성능을 더 끌어올린 개선 버전으로 Auto-CoT의 변형(variant)으로 작동하며, zero-shot 프롬프트를 쿼리별로 자동 분해하여 few-shot CoT 추론근거를 생성해 LLM의 다단계 추론을 강화
- 이 모델은 GPT-4 같은 강력한 LLM을 사용해 암시적 쿼리를 명시적 질문 시퀀스로 변환하고, GPT-3.5-turbo 같은 약한 모델이 이를 활용해 최종 답변을 도출
- 쿼리 재포매팅 → 추론근거 생성 → 후처리 단계로 구성되어 수동 예시 의존성을 제거하며, 오픈소스 구현 가능
- 2025년 현재 “Auto-CoT Variant”라고 하면 통상적으로 100% Auto Reason을 가리킴

AutoReason 전체 아키텍처 다이어그램



생성 및 후처리 상세 흐름 (Auto-CoT variant 통합)




[그림 III-36] AutoReason 전체 아키텍처 다이어그램 및 생성 및 후처리 상세 흐름

※ 출처: <https://arxiv.org/pdf/2412.06975#page=3>

※ 출처: 'AUTOREASON: AUTOMATIC FEW-SHOT REASONING DECOMPOSITION,

4.3 (UniFilter합성품질 필터링) MLLM-CTQ(Multimodal Classifier)


- MLLM-CTQ (Multimodal Large Language Model – Caption Text Quality Classifier)는 UniFilter 프레임워크 내의 핵심 멀티모달 분류기
- 합성 이미지-텍스트 데이터의 텍스트 품질(문법 정확성, 어휘 다양성, 유창성, 가독성, 길이, 구조)을 평가하여 고품질 캡션과 인터리브 문서 데이터를 필터링
- 이 모델은 semi-synthetic 접근으로 원본 이미지에 4단계 품질 레벨의 텍스트를 생성해 훈련되며, LLaVA-13B 같은 MLLM을 기반으로 fine-tuning되어 DataComp 캡션 데이터셋에서 OCR·텍스트 렌더링 관련 pre-training 데이터 필터링에 최적화



[그림 III-37] UniFilter 전체 프로세스 흐름

* (semi-synthetic 데이터 생성 → MLLM-CTQ 필터링 → 고품질 데이터 큐레이션)

※ 출처: <https://arxiv.org/pdf/2510.15162#page=3>




[그림 III-38] UniFilter의 통합 모델 아키텍처

※ 출처: <https://arxiv.org/pdf/2510.15162#page=3>

4.4 (Synthetic ToT) Cosmos Predict (NVIDIA WFM)

- Cosmos Predict는 NVIDIA의 World Foundation Model (WFM) 플랫폼의 핵심 구성 요소로, Synthetic ToT 아키텍처를 통해 합성 데이터 기반의 미래 상태 예측을 수행하는 자기회귀 기반 비디오 생성 모델
- 이 모델은 입력 비디오 시퀀스나 텍스트 프롬프트를 트리 구조의 다중 경로로 탐색하며, 옴니버스 시뮬레이션에서 생성된 합성 데이터를 학습해 객체 궤적, 충돌 예측과 같은 물리적 상호작용을 예측
- 4B~12B 파라미터 규모로 훈련되며, 로보틱스·자율주행에서 Sim2Real 갭을 줄이는 데 특화되어 있으며, 2025년 기준 Hugging Face와 NVIDIA Cosmos에서 오픈 웨이트로 공개되어 fine-tuning이 용이



[그림 III-39] 트랜스포머 디코더 아키텍처를 사용한 Cosmos 자기회귀 모델

※출처:

<https://developer.nvidia.com/blog/advancing-physical-ai-with-nvidia-cosmos-world-foundation-model-platform/>

5

액션중심 데이터 추론모델

- 로봇/에이전트 행동 로그(상태-액션-보상)로 embodied 추론 학습

5.1 (MAR) PaLM-E (Embodied VLM)

- PaLM-E (Pathways Language Model – Embodied)는 Google DeepMind의 embodied multimodal VLM으로, Multimodal Algorithmic 추론 아키텍처를 통해 텍스트·이미지·센서 데이터를 언어 임베딩 공간에 주입해 로봇 조작·시각적 계획 같은 embodied 태스크를 처리
- Embodied 추론 태스크, 시각-언어 태스크, 순수 언어 태스크를 모두 수행하는 단일 범용 멀티모달 언어모델임
- 12B~562B 파라미터 규모로 PaLM-2 기반에 ViT 인코더와 프로젝션 레이어를 추가해 훈련되며, 알고리즘적 추론(예: 객체 조작 계획)을 멀티모달 입력으로 분해·추론하여 780B 토큰 웹 데이터 + 로봇 시뮬레이션 데이터로 fine-tuning되어 자율 에이전트에 특화된




[그림 III-40] PaLM-E 방식

※ 출처: <https://arxiv.org/pdf/2303.03378#page=3>

- PaLM-E는 시각-언어 도메인에서 얻은 지식을 물리적 환경에서의 로봇 계획·조작하는 embodied 추론으로 전이됨
- 즉, 복잡한 역학과 물리적 제약이 있는 환경에서의 로봇 계획부터 관찰 가능한 세계에 대한 질문에 답하는 것까지 가능
- PaLM-E는 멀티모달 문장(multimodal sentences)으로 동작으로 텍스트 토큰(주황색)과 함께 이미지, 신경망 기반 3D 표현, 로봇 상태 등의 임의의 모달리티 입력(초록색·파란색)을 토큰 시퀀스로 삽입해 LLM에 입력하며, end-to-end 방식으로 훈련

5.2 (ReAct) Voyager

- Voyager는 2023년 Northwestern University와 NVIDIA 연구자들이 개발한 개방형 embodied 에이전트
- GPT-4를 기반으로 ReAct 프레임워크를 확장해 마인크래프트 환경(블록 기반 3D 가상 세계에서 에이전트가 관측·행동·보상을 통해 학습하고 추론할 수 있도록 구성된 연구용 시뮬레이션 환경)에서 자율적으로 탐험·스킬 습득·발견을 수행
- 이 모델은 자동 커리큘럼(탐험 최대화), 실행 가능 코드 스킬 라이브러리(복잡 행동 저장), 환경 피드백·오류·자기검증 등으로 프로그램 개선)을 통해 평생 학습을 실현.
- Voyager는 blackbox GPT-4 쿼리를 사용해 파라미터 파인튜닝 없이 동작하며, 오픈소스 코드와 프롬프트가 공개되어 로컬 재현 가능
 - 오픈-엔드 탐험을 위한 자동 커리큘럼(automatic curriculum)
 - 점점 더 복잡해지는 행동을 위한 스킬 라이브러리(skill library)
 - 코드자체를 행동공간(action space)으로 사용하는 반복적 프롬프팅 메커니즘(iterative prompting mechanism)




[그림 III-41] VOYAGER 세 가지 핵심 구성 요소

※ 출처: <https://arxiv.org/pdf/2305.16291>

5.3 (RAR/TAR) GEN-0 (Generalist)

- GEN-0은 Generalist AI가 2025년 11월에 공개한 embodied foundation model로, RAR과 TAR을 통합한 Harmonic 추론 아키텍처를 기반으로 비전·언어 기반 인지·추론을 행동 생성으로 확장
- 또한 반사적(reactive) 행동과 물리적 상식 기반 추론을 포함한 기능을 제공하며 후속 분석을 위해 추론·행동 관련 출력의 원형데이터를 보존·기록하는 구성을 가짐
- 이 모델은 270,000시간의 실세계 로봇 조작 데이터(가정·창고·작업장 수천 곳에서 수집)로 훈련되어, 비동기적·연속 시간 스트림의 센싱과 행동 토큰을 동시에 처리하며, 크로스-embodiment를 지원
- GEN-0은 기존 모델 대비 현재 시점에서 미래까지 고려해야 하는 시간/행동의 범위 작업(예: 카메라 키트 조립)에서 2~3배 빠른 성능을 보이며, 데이터 규모 증가에 따른 예측 가능한 지능 향상을 입증




[그림 III-42] GEN-0 모델의 개념 또는 구조를 나타내는 다이어그램

※ 출처: <https://generalistai.com/blog/nov-04-2025-GEN-0>

5.4 PhysBench

- PhysBench는 2025년에 제안된 Vision-Language Model(VLM)의 ‘물리적 세계 이해(physical world understanding)’ 역량을 평가하기 위한 벤치마크로, embodied AI 에이전트의 물리 기반 추론(physical reasoning) 요구를 반영하여 설계
- 데이터는 10,002개의 비디오-이미지-텍스트 인터리브(interleaved) 엔트리로 구성되며, 물리적 객체 속성(object properties), 객체 관계(object relationships), 장면 이해(scene understanding), 물리 기반 동역학(physics-based dynamics)의 4개 도메인을 포괄한다. 또한 19개 하위 과업(subclasses)과 8개 능력 차원(capability dimensions)으로 세분화되어 평가 범위를 구조화
- 평가 관점에서 PhysBench는 다수 VLM 간 물리 세계 이해 성능을 비교·분석할 수 있도록 구성되었으며, 저자 보고에서는 물리 기반 문항에서 상대적으로 낮은 성능이 관찰되고 특히 ‘장면 이해’ 및 ‘물리 기반 동역학’ 범주가 취약 영역으로 제시
- 기존의 일반적 VQA 태스크가 주로 ‘시각적 내용 질의’와 ‘상식·일반지식’ 중심의 평가에 치우치는 반면, PhysBench는 물리적 속성·관계·환경 요인·동역학 등 ‘물리 세계 이해’ 요소를 4개 핵심 범주로 명시적으로 구성하여 평가하는 점에 차별성이 있음

Common VQA	Physical Object Property	Physical Object Relationships
 Q What are the things I should be cautious about when I visit here? A When visiting the pier over the lake, there are a few things you should be cautious about. First, ensure that you ...	 Q Which object has greater elasticity? A. Green ball ✓ B. White ball C. Same elasticity D. Cannot determine	 Q What is the object closest to the teacup in the Figure? A. The pastry B. The peach C. The knife D. The spoon ✓
	Physical Scene Understanding	Physics-based Dynamics
	 Q How does the viewpoint alter? A. Moves downward B. Rotates to the right ✓ C. Moves upward D. Rotates upward	 Q Which object will the cart hit first? A. The red cube ✓ B. The blue cube C. The green cube D. The yellow cube

[그림 III-43] PhysBench의 구성요소

※ 출처: <https://arxiv.org/pdf/2501.16411>

6

추론형 AI 데이터의 주요 벤치마크 데이터셋

6.1 수학 논리 추론

구분	내용
GSM8K	- 초등·중등 수준 산술 문제 8,500개로, 단계적 계산 추론 테스트 2025년 o3 모델 98% 달성; CoT 적용 시 +30% 향상
MATH	- 고등 수학 문제 12,500개 (대수·기하 등)로 복잡한 증명·추론 평가 - Qwen 3 8B 80%+; OpenThoughts 데이터셋으로 open 모델 53%
AIME 2025	- 고급 수학 올림피아드 문제로 고난도 추론 벤치마크 - GPT-5 94.6%, open 모델 80%대 (DeepPrune inference 적용)

[표 III-46] 수학 논리 추론 벤치마크 데이터셋

6.2 공상 상식 추론

구분	내용
CSQA (CommonsenseQA)	- 상식 기반 QA 12,000개로 일상적 논리 판단 테스트 - Claude 3.7 Sonnet 93%+; PIQA와 결합 시 실생활 적용 평가
HellaSwag	- 비디오 캡션 기반 NLI 70,000개로 다음 사건 예측 추론 - GPT-4o 95%+; commonsense NLI의 표준

[표 III-47] 공상 상식 추론 벤치마크 데이터셋

6.3 코딩 알고리즘 추론

구분	내용
HumanEva	- 코딩 문제 164개로 함수 완성·디버깅 추론 평가 - Grok 3 92%+; MBPP/LiveCodeBench와 연계
SWE-Bench	- 소프트웨어 엔지니어링 태스크 2,000+개로 복잡 코딩 추론 2025년 67.3% 향상 (o3 모델); 에이전트 평가 핵심

[표 III-48] 코딩 알고리즘 추론 벤치마크 데이터셋

6.4 멀티모달 물리추론

구분	내용
MMMU	- 멀티모달 다학제 QA 11,500개로 시각·텍스트 추론 통합 - Gemini 2.5 84.8%, 18.8% 향상 (2024-2025)
GPQA	- PhD 수준 과학 QA 448개로 물리·생물 등 전문 추론 - Claude 3.5 Sonnet 93%+ 48.9% 향상
PhysBench	- 물리 세계 이해 10,000+ 비디오-이미지 데이터로 embodied 추론 - VLMs 30~50% 저하 지적; 4개 도메인(객체·관계·동역학) 테스트

[표 III-49] 멀티모달 물리추론 벤치마크 데이터셋

6.5 일반 에이전트 추론

구분	내용
MMLU-Pro	- 고난도 지식·추론 12,000+ 문제로 다학제추론 - GPT-4o 98%; MMLU의 확장 버전
ARC-AGI-2	- 추상적 패턴 인식 1,000+ 문제로 AGI 수준 추론 2025년 여전히 unsolved human baseline 85%
Big-Bench Hard (BBH)	- 어려운 추론 태스크 23개로 멀티스텝 추론 평가 - PaLM 2 85%+ agentic 작업에 적합

[표 III-50] 일반 에이전트 추론 벤치마크 데이터셋

AI 데이터 품질관리 가이드라인 v4.0

제4권

추론형 AI 데이터를 중심으로

신기술 AI 데이터 품질관리 가이드 v1.0

IV

부록

부록1 | 품질관리 지표 기준

부록2 | 품질지표 설정 가이드

부록3 | 근거문헌

부록1

품질관리 지표 기준

1

품질관리 지표

1.1 품질관리 지표 정의

1.1.1 추론형 AI 데이터 품질관리 지표

- 추론형 AI 데이터 품질관리 지표는 모델이 안정적으로 논리를 전개하고 일관된 추론 과정을 생성할 수 있도록 데이터의 정확성, 근거성, 구조적 완전성을 평가하는 기준
- 이러한 지표는 데이터의 사실성·일관성·논리적 연결성뿐 아니라, 다양한 문제 유형에서의 일반화 가능성과 오류 전파 가능성 등을 정량적으로 점검
- 궁극적으로 이 지표들은 추론 데이터가 모델의 사고 과정에 왜곡·편향·모순 없이 작동하도록 보증하여 고신뢰·고품질의 추론형 모델을 개발하기 위한 핵심 기준이 됨

1.1.2 품질관리 지표 제공 목적

- AI 데이터 품질관리 가이드라인 v4.0'의 제1권에서 정의한 'AI 데이터 품질관리 가이드'와 AI-Hub를 통해 서비스하는 학습데이터 전반의 품질관리 기준을 준수하되, '추론형 AI 데이터'의 특성을 반영하여 품질관리 강화를 위해 지표 기준 설정 사례 제공
- 추후 구축된 데이터를 활용할 사용자의 요구사항을 만족하기 위해, 필요한 요소가 잘 갖추어졌는지 확인하며 객관적인 품질 수준을 제시하는데 활용

1.1.3 품질관리 지표 활용 시 유의사항

- 추론형 AI 기술의 발전 속도는 매우 빠르며, CoT·ToT·GoT ReAct 등 새로운 추론 아키텍처와 데이터 구축 방식이 지속적으로 등장하고 있음에 따라 추론형 데이터의 형태와 요구되는 난이도·정밀도 역시 빠르게 고도화되고 있음
- 본 가이드라인에서 제시하는 추론형 AI 데이터 품질관리 지표는 2025년 '초거대AI 확산 생태계 조성사업'의 추론형 데이터 구축 사례와 25년 추론형 데이터 기술 트렌드를 기반으로 공통 요소를 정리한 것이며, 향후 기술 변화나 개별 프로젝트의 목적·도메인에 따라 지표는 확장·조정될 수 있음
- 따라서 본 지표는 절대적 기준이 아니라 참고용으로 활용해야 하며, 모델의 추론 특성, 도메인 요구사항, 데이터의 복잡성에 따라 적절히 수정해 사용하는 것이 바람직함

1.2 품질관리 지표 구성

버전	기존 품질특성	추론형 AI 데이터 품질특성	비고
품질특성	준비성	준비성	• 데이터 형식, 구조, 메타데이터가 학습에 적합하게 준비되어 있는 정도
	완전성	확장 (추론과정 완전성)	• 정답뿐 아니라 사고과정(CoT/ToT)의 단계별 누락 여부 포함
	유용성	유용성	• 모델학습에 실제적 도움여부
	기준 적합성	기준적합성	• 도메인 기준·품질 기준 준수 여부
	다양성	다양성	• 질문/패턴의 다양성, 난이도 다양성
	유사성	유사성	• 답은 달라도 사고 과정의 구조적 유사성 검증 필요
	편향성	편향성	• 추론 편향·잘못된 논리 패턴 학습 방지
	합성데이터 유용성	조건부 유지	• 합성 CoT/시뮬레이션 기반 추론 데이터 활용 시에만 적용
	합성데이터 안전성	조건부 유지	• 신뢰도·사실성·환각 위험 여부 점검
	구문 정확성	유지	• 텍스트 CoT 문법적 오류·표현 구조 검증
	의미 정확성 (일치성, 정렬성 포함)	확장	• 일관성, 적절성 추가
	알고리즘 적정성	확장	• 문제유형에 적절한 아키텍처를 선택
	유효성	확장	• 추론결과의 검증가능성, 재현성 추가
추가 품질특성	-	• 완전성 : 사고 과정의 단계적 비약(누락)여부 확인 - 추론과정 완전성-의미 정확성의 적절성으로 대체의미정확성 - 일관성, 적절성 (TOT, GOT의 경우) 추론 오류 전파 방지 (의미정확성에 포함) • (Error Propagation Robustness) :초기에 작은 오답이 전체 reasoning을 왜곡하는 패턴이 있는지 점검 • 다단계 사고 다양성 (다양성에 포함) (Multi-step Reasoning Diversity) • 단일 사고 방식만 반복하지 않도록 균형 있는 사고 유형 확보	

[표 IV-1] 품질관리 지표 구성

- 본 가이드가 제시하는 사항을 참고하여 구축하고자 하는 추론형 AI 데이터의 목적에 따라 최적의 품질지표 선정 필요

※ 품질지표 및 산출물 작성 예시는 최신의 구축사업 사례 또는 논문 등을 이용하여 제시하고 있으며, 제시한 사례를 기반으로 더 우수한 논문/모델이 있는지 확인하고 최적의 방안 수립 권고

구분	품질특성	설 명
구축 공정 적정성	준비성	- 추론형 AI 데이터 품질관리를 위해 기본적으로 관리해야 하는 정책, 규정(저작권, 초상권, 개인정보보호 및 정보보호 등에 대한 검토 결과를 포함), 조직, 절차 등을 마련하고, 최신의 내용으로 충실하게 관리되는지를 검사 - 데이터 형식, 구조, 메타데이터가 학습에 적합하게 준비되어 있는 정도
	완전성	- 추론형 데이터를 구축과정에 물리적인 구조를 갖추고, 정의한 데이터 형식 및 입력값 범위에 맞게 데이터가 저장되도록 설계·구축되었는지를 검사 - 정답뿐 아니라 사고과정(CoT/ToT)의 단계별 누락 여부 포함
	유용성	발주기관(수요자)의 요구사항이 충분히 반영되었는지, 임무 정의에 적합한 추론형 AI 데이터의 범위와 상세화 정도를 충족시키는지 검사
데이터 적합성	기준 적합성	구축 데이터가 추론형 AI 학습용으로 적합한지 기준을 선정하기 위해, 분류 다양성, 신뢰성, 충분성, 균일성, 사실성, 형식성 등을 측정
	다양성	- 편향성 방지를 위한 문어체/구어체, 수집처별 분포, 문장 길이, 어휘 개수 등을 측정 - 질문/패턴의 다양성, 난이도 다양성 측정
	유사성 (중복성)	- 데이터의 중복, 유사 정도 및 내용적인 유사도를 측정 - 문서 내용에 중복된 텍스트가 얼마나 있는지 그 비율을 확인 - 답은 달라도 사고 과정의 구조적 유사성 검증 필요
	편향성 (유해성)	- 특정 성별, 인종, 나이 등에 대한 경향성 및 사회적으로 부정적 의미에 해당하는 데이터 또는 혐오 표현 등의 포함 여부 확인 - 텍스트 말뭉치 데이터 내 차별 및 혐오 등 유해표현이 포함된 문장 확인 - 추론 편향·잘못된 논리 패턴 학습 방지
	합성데이터 유용성	- 합성데이터와 원본데이터가 얼마나 유사한지, 동일한 목표를 달성할 수 있는지 등을 검증 - 합성 CoT/시뮬레이션 기반 reasoning 데이터 활용 시에만 적용
	합성데이터 안전성	- 생성된 합성데이터를 통해 원본데이터 내 개인이 식별·추론될 가능성이 있는지 등을 검증 - 신뢰도·사실성·환각 위험 여부 점검
가공 데이터 정확성	구문 정확성	- 기본적인 데이터 구조 및 형식 정확성을 측정하는 품질특성 - 텍스트 CoT 문법적 오류·표현 구조 검증
	의미 정확성 (전달성)	- 데이터의 의미가 명료하고 표현이 자연스러운지 측정 - 내용 전달성, 질의 적정성, 바운딩박스 정확성, 3D모델링 정확성, 일치성, 정렬성 등 측정 - 일치성 : 멀티모달 원천데이터의 모달리티간 내용이 서로 일치하는지 검사 - 정렬성 : 시계열 특성을 포함하는 멀티모달 간 시간적 요소 정렬 여부 확인 25년 추가된 품질지표 : 추론 적절성, 일관성 - 추론의 적절성: “CoT 데이터의 단계별 정보로부터 도출된 추론의 근거가 적절한지 확인” - 추론의 일관성: “CoT 데이터의 단계 간 흐름이 일관적인지 확인”

구 분	품질특성	설 명
학습모델 적합성	알고리즘 적정성	• 학습모델의 Task가 적정한지 판단 • 문제유형에 적절한 아키텍처를 선택
	유효성	• SI모델을 학습용 데이터로 훈련 후 측정된 성능이 유효한지 측정하는 품질특성

[표 IV-2] 품질관리 지표 구성 상세

1.3 품질관리 계획서 작성 요령

- 아래의 표를 참고하여 각 품질관리 검사기준 및 방법 작성

작성 예시					
구분	품질특성		검사항목	검사대상 산출물	검사방법
구축과정 적정성	준비성	계획 수립성	절차준비	사업수행계획서, 구축계획서, 품질관리계획서	체크리스트
			조직준비		
			도구준비		
			위험관리		
		체계 준수성	보안준수		
			법·제도 준수		
	완전성		수집 완전성	구축계획서, 구축 가이드라인	체크리스트
			정제 완전성		
			가공 완전성		
			추론생성 완전성		
	유용성		사용 편의성	구축계획서	체크리스트
			유연성		
데이터 적합성	기준 적합성		분류 다양성	구축 가이드라인, 원시데이터	체크리스트/ 전수검사
			신뢰성		체크리스트
			충분성		
			균일성		
			사실성		
			공평성		
			형식성	원시데이터, 원천데이터	전수검사
	다양성		다양성(요건)	원천데이터, 가공데이터	전수검사
			다양성(통계)		
	유사성 (중복성)		내용 중복성	원천데이터 가공데이터	문장 중복성 검증
			내용 유사성		전수검사
			도메인 유사성		
			사고과정 구조적 유사성		샘플링

구분	품질특성	검사항목	검사대상 산출물	검사방법
	편향성	경향성	테스트 코드	Know comment API 기반 테스트
		유해성	원시데이터 원천데이터	레퍼런스 데이터셋 기반 유해표현 검출
		추론 편향	가공데이터	데이터 편향성 정량 검증 출력 편향성 검증
	합성데이터 유용성	모델성능비교	원천데이터 (합성데이터)	원본과 합성데이터 간의 학습모델 성능 비교 평가
		이미지 생성 성능	원천데이터 (합성데이터)	- VTT : 관계자를 대상으로 원본데이터와 합성데이터를 구분하는 테스트를 수행하여 정답률 측정 - FID : 원본과 합성 데이터셋의 특징을 추출하여 수치화한 뒤, FID를 계산
		합성CoT/리즈닝 데이터 유용성	가공데이터	모델성능향상도 측정 Human-Model Gap Reduction Test
	합성데이터 안전성	구조적 유사성	원천데이터 (합성데이터)	원본-합성 이미지 간 형태적 유사성을 컴퓨터 지표로 검증
		지각적 유사성	원천데이터 (합성데이터)	원본-합성 이미지 간 시각적 유사성을 컴퓨터 지표로 검증
		주관적 검증	원천데이터 (합성데이터)	개인정보, 민감정보 식별성을 주관적으로 검증 Reasoning Bias Index (RBI)
	가공 데이터 정확성	구조 정확성	가공데이터	표본검사
		형식 정확성		
		내용 전달성	가공데이터	표본검사
		질의 적정성		
		바운딩 박스 정확성		
		3D모델링 정확성		
		분류 정확성		
	의미 정확성 (전달성)	일치성		모달리티 간 내용이 서로 일치하는지 검사
		정렬성		모달리티 간 시간적 요소 정렬 여부 확인
		추론 일관성		CoT 데이터의 단계 간 흐름이 일관적인지 확인
		추론 적절성		CoT 데이터의 단계 간 흐름이 일관적인지 확인

구분	품질특성	검사항목	검사대상 산출물	검사방법
학습모델 적합성	알고리즘 적정성	AI모델 알고리즘 작성	알고리즘 구조도	임무별 알고리즘 적정성 평가
		추론아키텍처 적절성	가공데이터	아키텍처 적정성 평가
	유효성	사전학습모델 PPL	- 사전학습모델 weight 파일 - 사 전 학 습 모 델 알고리즘 소스코드 - 사전학습모델 테스트 코드	- 테스트셋(구축 데이터 10%) - 테스트 (기구축 데이터 훈련 모델과 비교)
		SFT모델 Likert 척도	- SFT모델 weight 파일 - SFT모델 알고리즘 소스코드 - SFT모델 테스트 코드	Likert 테스트 작업자가 선호도 평가 (사전학습 모델과 비교)
		SFT모델 자연어 추론		KLUE-NLI 벤치마크 테스트
		RM모델 정확도	- RM모델 weight 파일 - RM모델 알고리즘 소스코드 - RM모델 테스트 코드	테스트셋 (구축 데이터 10%) 테스트
		PPO모델 Likert 척도	- PPO모델 weight 파일 - PPO모델 알고리즘 소스코드 - PPO모델 테스트 코드	Likert 테스트 작업자가 선호도 평가 (사전학습 모델과 비교)
		PPO모델 자연어 추론		KLUE-NLI 벤치마크 테스트
		추론의 유효성	출력 정답기반	Accuracy, EM(Exact Match) F1 Score BLEU / ROUGE / L EVA Score / Semantic Similarity Score FactScore / TruthfulQA Score
			과정 기반	Reasoning Consistency Score Step Validity Score 등
			복잡 추론 성능 기반	Multi-hop QA Score) Arithmetic Reasoning Long-context Reasoning Score (retrieval 필요 문제) Scientific/Commonsense Reasoning Score

2

구축 공정 적정성 품질관리 지표

2.1 추론 생성의 완전성 (Reasoning Generation Completeness)

2.1.1 개요

- 주어진 문제·조건·입력에 대해 모델이 도달해야 할 모든 추론 단계를 누락 없이, 그리고 논리적 비약 없이 포함하고 있는 정도
 - 추론단계: 전제 식별 → 하위 목표 → 중간 추론 → 검증 → 결론
- 추론 과정의 누락/비약으로 인한 오정보·오해·오답의 근원을 제거하고, 모델 학습·검증·운영 단계에서 재현 가능하고 검증 가능한 사고 흐름을 확보

2.1.2 추론생성 완전성 검사기준 및 방법

항목명	추론 생성의 완전성
설명	- 전체 커버리지 - 정의: 문제의 모든 필수 전제(조건, 변수, 제약)를 인식·열거했는가. - 측정: $\text{Premise Coverage Ratio} = (\text{식별된 필수 전제 수}) / (\text{참고 Gold 전제 수})$ - 하위목표 완전성 (Subgoal Completeness) - 정의: 문제 해결을 위해 필요한 하위목표들이 모두 설정되었는가. - 측정: Subgoal Recall (자동 추출된 하위목표와 Gold 매칭 비율) - 단계 연속성(연결성)(Step Continuity / Logical Flow) - 정의: 각 단계가 이전 단계의 결론을 근거로 자연스럽게 이어지는가. - 논리 도약률 (Logical Jump Rate) - 정의: 근거 없이 도약한 단계의 비율.
검사대상	가공 데이터
검사방법	체크리스트

[표 IV-3] 추론 생성의 완전성 검사기준 및 방법

3

데이터 적합성 품질관리 지표

3.1 유사성 (사고과정 구조적 유사성)

3.1.1 개요

- 사고과정의 유사성은 두 개(또는 복수)의 추론 트레이스(Chain-of-Thought, Tree-of-Thought, Graph-of-Thought 등)가 최종 답이 다르더라도 사용한 사고 구조(노드·하위목표·추론 유형·검증행위·인과 흐름 등)가 얼마나 닮았는지를 정량·정성으로 측정하는 개념
- 답이 맞더라도 잘못된(우연한) 사고로 도달했는지 판별하고, 작업자의 사고 전략의 일관성을 확인하여 여러 입력에 대해 동일한 합리적 전략을 쓰는지 평가

3.1.2 추론 사고 과정의 구조적 유사성 검사방법

항목명	추론 사고과정의 구조적 유사성
설명	- 구조적 유사성 (Structural) - 노드(스텝) 수, 분기(depth·breadth), 그래프 토폴로지(연결성) - 기능적 유사성 (Functional / Role-based) - 각 스텝의 역할: 전제 식별, 하위목표 설정, 계산, 검증, 반례검토 등 - 논리 흐름 유사성 (Logical Flow / Entailment) - 단계 간 인과·함의 관계의 유사성(Entailment patterns) - 패턴·전략 유사성 (Pattern / Strategy) - 귀납/연역/Case-split/Proof-by-contradiction 등 사용된 추론 기법 - 검증 행위 유사성 (Verification Behavior) - 검산, 단위검증, 경계조건 확인 등 검증 단계의 존재·위치·강도 - 타이밍/순서 유사성 (Temporal / Sequential) - 하위목표 등장 순서, 반복·루프 패턴의 유사성 - 의미적 유사성 (Semantic / Embedding) - 단계 텍스트 자체의 의미적 유사도(임베딩 기반 비교)
검사대상	가공 완전성: 데이터 가공
검사방법	체크리스트

[표 IV-4] 사고과정의 유사성 검사기준 및 방법

3.2 편향성 (추론편향)

3.2.1 개요

- 추론 편향성이란 모델이 추론 과정(단계·근거·전제 선택·검증행위 등)에서 특정 집단, 관점, 전제, 결론을 일관되게 우대하거나 배제하여, 합리적·중립적 추론을 손상시키는 현상을 말함
- 단순 출력 편향보다 CoT/ToT 단계에서 편향이 스며들어 모델이 ‘그럴듯한’ 근거로 편향 결론을 정당화할 수 있음
- 안전·윤리·법규 준수 측면에서 치명적(특히 의학·법률·채용·금융 도메인)

3.2.2 추론편향성의 검사 기준 및 검사방법

항목명	● 추론편향
설명	1. 검사기준 ● 평가축 - 노출(Exposure) 편향 — 데이터에 특정 그룹·관점이대표되는 정도. - 원인(Attribution) 편향 — 전제·근거 선택에서 편향적 연결이 발생 여부 - 결과(Outcome) 편향 — 동일 상황에서 그룹별 추론 결과·결론이 체계적으로 다른가의 여부 2. 검사방법 ● 데이터 편향성 - 분포분석:특정 속성(성별·인종·도메인·표현형 등)이 대표되는지 판단. - 레이블-어노테이터 편향 검사 (Annotation Bias) 가공 작업자가 일관되게 특정 결론·전제를 선호했는지 파악 - 프롬프트·출처 기반 편향(Generator Bias) : 합성 데이터(LLM 생성 등)가 자체 편향을 전파하는지 검사 - 하위요소(전제·하위목표) 편향 분석 (Step-level Exposure) 어떤 전제 또는 하위목표가 특정 그룹·상황과 과도하게 결합되어 있는지 확인 ● 출력편향성 검사 - Counterfactual Consistency Test - Group-wise Outcome Comparison (Statistical Test) - Step-level Attribution & Attention 검사 CoT 단계에서 특정 속성이 과도하게 영향을 미치는지 확인
검사대상	● 가공 데이터 가공
검사방법	● 체크리스트

[표 IV-5] 추론 편향 검사기준 및 방법

3.3 합성데이터의 유용성(합성CoT/추론 데이터 유용성)

3.3.1 개요

- 합성으로 생성된 CoT·추론 트레이스·시뮬레이션 산출물이 실제 학습(또는 평가) 과정에서 모델 성능 향상, 추론 품질 개선, 일반화(전이) 촉진, 그리고 안전성 유지(또는 개선)에 실질적으로 기여하는 정도를 의미
- 합성 데이터가 실제 모델 능력(결과·과정·안전성)에 긍정적 영향인지 검사하고, 합성 데이터의 편향, 환각, 오류전파와 같은 위험을 사전 탐지하여 합성 데이터의 비용 대비 효과(ROI)를 판단하고 운영·확대 여부를 결정

3.3.2 합성데이터의 유용성(합성CoT/추론 데이터 유용성)의 검사기준 및 검사방법

항목명	합성데이터의 유용성(합성CoT/추론 데이터 유용성)
설명	1. 검사기준 ● 평가축 - 내재적 품질(Intrinsic quality) 논리성, 완전성, 사실성, 구조적 합리성(전제·하위목표·검증 포함) 등 합성 trace 자체의 품질 - 외재적 유틸리티(Extrinsic utility) 합성 데이터를 포함해 학습했을 때 모델의 성능 향상(정답률 등), 과정 품질 개선(CoT 일관성·완전성), 일반화(Out-of-distribution), 복잡문제 처리능력 등이 개선되는지 - 안전성·위험(Adverse effects / Safety) 편향·환각·유해 추론·논리적 오류가 증가하지 않는지 (혹은 감소하는지) 2. 검사방법 ● 합성 CoT 자체 품질 - 각 스텝(전제→근거→결론)이 논리적으로 타당한 비율. (자동 NLI + 샘플 휴먼 검증) - 전제 커버리지, 하위목표 포함율, 검증 스텝 존재 여부의 가중합 - 비약·순환논증·잘못된 인과 등 오류 스텝 비율 - 근거 주장 중 검증 가능한 근거(데이터/문헌/계산)를 포함한 비율 - 문법·표현의 품질(보조 지표) ● 모델 성능 검사 - 합성데이터 포함 학습 전후 정답률 변화 (벤치마크별) - 모델이 생성한 CoT의 RCS / SVR 개선량 - 동일 데이터 예산 하에 합성데이터가 제공하는 effective-samples 증가비율 등
검사대상	가공 데이터
검사방법	체크리스트

[표 IV-6] 합성데이터 유용성 검사기준 및 방법

3.4 합성데이터로 생성한 추론데이터에서 안전성

3.4.1 개요

- 생성된 추론합성 데이터가 모델 학습 과정에서 새로운 위험(편향, 허위근거, 유해추론, 왜곡된 논리 패턴)을 유발하지 않고, 안전한 추론을 촉진하는 정도를 의미
- “잘 만들어진 합성 CoT는 모델을 더 똑똑하게 만들지만, 잘못된 합성 CoT는 모델을 더 위험하게 만든다”를 고려하여 평가하는 항목

3.4.2 합성데이터를 사용해서 만든 추론데이터에서 안전성의 검사 기준 및 검사방법

항목명	● 합성데이터를 사용해서 만든 추론데이터에서 안전성
설명	1. 검사기준 지표 ● 편향관련 지표 - Reasoning Bias Index 특정 속성(성별·국가·직업 등)에 대한 결론 패턴이 비대칭적으로 생성되는 정도 - Distributional Skew Score 정답이 동일해야 하는 문제군에서 특정 방향의 결론이 반복적으로 나타나는지 검사 - Stereotyped Reasoning Rate 편견적 결론(일반화, 고정관념)이 포함된 비율 ● 허위, 조작 관련 지표 - Fabrication Rate (FR) 근거가 사실과 불일치하거나 출처가 없는 정보 비율 - Evidence Attribution Error 출처를 있는 것처럼 꾸미거나, 존재하지 않는 통계·문헌을 언급하는 비율 ● 유해 추론 Harmful Reasoning - Harmful Reasoning Rate ‘해로운 행동을 조장’, ‘위험한 내용’, ‘차별/폭력 정당화’로 이어지는 추론 비율 - Risk Escalation Index 문제 자체는 안전한데, 합성 CoT가 불필요하게 위험한 결론으로 비약하는 정도 ● 사고 오류 논리 패턴(Logical Flaw / Fallacy) - Logical Fallacy Rate 순환논증, 잘못된 인과, 허수아비 공격, 성급한 일반화 등 논리오류 비율 - Error Propagation Risk CoT 초반 오류가 결론까지 오염되는 전파율
검사대상	● 가공 데이터
검사방법	● 편향검사, 허위근거 검사, 유해추론 자동탐지, 논리패턴 자동탐지, 휴먼오디트

[표 IV-7] 합성데이터를 사용해서 만든 추론데이터에서 안전성 검사기준 및 방법

4

가공데이터 정확성 품질관리 지표

4.1 의미 정확성

4.1.1 개요

- 문제(Input), 사고과정(CoT), 최종답변(Output) 사이의 의미적 일관성·적절성이 유지되고, CoT의 각 단계가 논리적으로 타당하고 실제 의미를 반영하며, 사실 기반으로 연결되어 있는 정도
- 즉, “단순히 답이 맞는지”가 아니라, 추론 과정 전체가 의미적으로 올바른가를 평가

4.1.2 추론 AI 데이터 의미정확성의 검사항목

품질특성	검사 항목
의미정확성	추론 일관성
	추론 적절성
	※ 그 외 검사 항목은 데이터의 유형 및 활용 목적에 따라 적절하게 선정하여 적용

[표 IV-8] 의미 정확성 검사 항목 구성

4.1.3 검사기준 및 방법

4.1.3.1 추론 일관성

항목명	• 추론 일관성
설명	• 추론 일관성 검사는 동일 문제나 동등 조건에서 모델이 논리적으로 일관된 사고 과정과 결론을 반복적으로 산출하는지를 확인
대상	• Q-CoT-A 단계 간의 일관성
기준	• 각 단계의 선후 관계가 명확하고 논리적으로 모순되지 않은가? • 전체적인 맥락에서 조화를 이루는가? • 질문과 추론을 기반으로 도출된 답변이 문제의 요구와 일치하며 적절한가?

**검사방법
(예시)**

- 1) 반복 생성 기반 검사(Repetition Consistency Test)
 - 동일한 입력을 여러 번 생성시키고, 사고 과정(CoT)·중간 스텝·최종 답의 재현성을 비교
 - CoT 구조 유사도(트리/그래프 정렬), 단계 누락 여부, 논리 순서 변화 등을 정량화해 변동성을 측정
- 2) 등가 문제 기반 검사(Equivalent Input Consistency Test)
 - 의미적으로 동일하지만 표현만 다른 문제(패러프레이즈·구조 변환)를 주고 동일한 논리적 결론과 유사한 추론 패턴이 나오는지 비교
 - 문제 변형에 따라 논리가 흔들리는지 확인하여 추론 구조의 안정성을 평가
- 3) 경로 중심 CoT 비교(Path-based CoT Consistency)
 - 모델의 사고 과정이 동일한 핵심 추론 경로(핵심 근거·중간 추론 노드)를 유지하는지 평가
 - 그래프 매칭(GOT), 트리 편집거리(Tree Edit Distance), 논리 패턴 정렬(Logical Pattern Alignment) 등을 활용
- 4) 결론-근거 정합성 검사(Conclusion-Reasoning Alignment)
 - 최종 답이 달라도 중간 추론과 결론 사이의 논리적 연결이 흔들림 없이 유지되는지 확인
 - 정답 기준이 아닌 논리 구조 기준 평가로 추론 모델 성능을 점검할 때 유용
- 5) 상대 비교 기반 검사(Pairwise Reasoning Consistency)
 - 서로 유사한 문제 묶음에 대해 모델의 추론 경향이 상대적으로 일관된 논리 패턴을 사용하는지 비교
- 6) 확률적 추론 흔들림 검사(Stochasticity Sensitivity Test)
 - 변동성(variance)과 CoT 패턴 분산을 계산하여 모델의 안정성을 정량화

[표 IV-9] 추론 일관성 검사기준 및 방법

4.1.3.2 추론 적절성

항목명	추론 적절성
설명	- 모델의 답변이 논리적으로 타당하고, 비약이나 모순 없이 잘 추론되었는지 평가 - 단계별 정보로부터 도출된 추론의 근거의 적절성을 평가
대상	Q(질문), CoT(추론)
기준	- Q(질문) - 질문이 명확하고 논리적인 사고를 요구하는가? - 해당하는 분야의 추론을 요구하는 질문인가? - 사람이 이해할 수 있도록 가독성과 명확성이 확보되는가? - CoT(추론) - 각 추론 단계가 사실 기반에 의하여 작성되었는가? - 해당하는 분야의 전문성 및 특성이 반영되어 있는가? - 사람이 이해할 수 있도록 가독성과 명확성이 확보되었는가?
검사방법	- 논리적 비약 여부 - 결론으로 가는 중간 단계가 빠졌거나 근거 없이 갑자기 결론으로 뛰었는가? - 모순 검사 - 답변 내에서 앞뒤 주장이나 사실이 서로 충돌하는가? - 과잉/과소 추론 검사 - 주어진 정보만으로 도달 가능한 결론을 넘어섰는가? (hallucination 포함) - 인과관계 왜곡 여부 - 상관관계를 인과로 잘못 해석했거나, 인과 방향이 뒤바뀌었는가? - 조건문·가정 누락 검사 “만약 ~라면” 같은 중요한 가정이나 조건을 생략하고 단정했는가? - 논리 구조 일관성 - 전제 → 추론 → 결론의 흐름이 자연스럽게 필연적인가?

[표 IV-10] 추론 적절성 검사기준 및 방법

4.1.4 추론 AI데이터의 의미정확성 측정지표

- 추론형 AI 데이터는 단답형, 장문형, 정규화된 후보가 포함되는 경우, 단계별 추론 등 다양한 유형이 존재하므로 데이터 유형별 주요 지표를 제시

품질특성	데이터종류/ 어노테이션방식	측정지표
의미 정확성	단답형	• Exact Match (EM)
		• F1 Token Overlap
	최종 답 과 정규화된 정답 후보 포함	• Normalized Accuracy
	단계별 추론 과정 (Chain-of-Thought)	• Step-level Exact Match
		• Step-wiseF1
		• Graph Edit Distance (추론 그래프 비교)
	장문형 답변 (Long-form Answer)	• Human Likert Score (1~5점)
		• GPT-4 Judge Accuracy (자동)
		• BERTScore
		• MoverScore/
		• LLM-as-a-Judge (Pairwise)
	사실기반 + 추론혼합	• Fact-Recall Accuracy + Reasoning Score (분리 측정)
		• Joint F1 (Entailment 기반)
	수학논리 문제 (정답+ 증명포함)	• Final Answer Accuracy + Proof Correctness
		• AlphaGeometry-style Step Accuracy
		• Lean Theorem Prover Verify (자동 검증 가능 시)
	복수참조 (Multi-reference)	• BLEURT
		• COMET
		• BARTScore
		• G-Eval
		• Prometheus (최근 LLM Judge)
	선호(비교) 데이터 (A better than B)	• Pairwise Win Rate (LLM Judge 일치율)
		• Bradley-Terry Modeling

[표 IV-11] 의미 정확성 측정지표 구성

4.1.4.1 단답형 데이터

- Exact Match (EM)

항목명	Exact Match (EM)
설명	- 모델의 출력 문자열이 정답 문자열과 완전히 일치하는 경우에만 1점, 하나라도 다르다면 0점으로 계산하는 가장 엄격한 정확도 지표 - 주로 단답형 QA, 수학 문제 최종 답, 사실형 질문 등에서 사용
검사방법	- 양쪽 문자열을 정규화(소문자 변환, 불필요 공백·구두점 제거, 숫자 형식 통일 등) - 정규화 후 문자열이 100% 동일하면 1, 아니면 0 → 전체 데이터에 대해 평균내어 EM(%) 산출

[표 IV-12] Exact Match (EM) 검사기준 및 방법

- F1 Token Overlap

항목명	F1 Token Overlap
설명	- 모델 출력과 정답의 토큰 단위 겹침 정도를 Precision과 Recall의 조화 평균(F1)으로 측정하는 지표. EM보다 유연해 부분 점수 부여 - 주로 단답형·추출형 QA에서 Exact Match의 보완 지표로 사용
검사방법	- 출력과 정답을 띄어쓰기·형태소 기준으로 토큰화 $Precision = (\text{공통 토큰 수} / \text{출력 토큰 수})$, $Recall = (\text{공통 토큰 수} / \text{정답 토큰 수})$ $F1 = 2 \times (P \times R) / (P + R) \rightarrow \text{데이터셋 평균으로 최종 F1(\%) 계산 (보통 소문자·구두점 정규화 후 수행)}$

[표 IV-13] F1 Token Overlap 검사기준 및 방법

4.1.4.2 최종 답변과 정규화된 정답 후보가 포함된 데이터

- Normalized Accuracy

항목명	Normalized Accuracy
설명	- 정답 후보군(동의어, 약어, 다양한 표기 등)을 미리 정의해 두고, 모델 출력이 그 후보 중 하나라도 정규화 후 일치하면 1점으로 인정하는 지표 - EM의 지나친 엄격함을 보완하며, “미국/USA/U.S.A” 등을 모두 정답 처리할 때 주로 사용
검사방법	- 모델 출력 → 소문자 변환, 공백·구두점 제거, 숫자/단위 정규화 등 사전 정의된 정규화 규칙 적용 - 정규화된 출력이 정답 후보 리스트 중 하나라도 정확히 일치하면 1, 아니면 0 → 데이터셋 평균으로 Normalized Accuracy(%) 산출

[표 IV-14] F1 Token Overlap 검사기준 및 방법

4.1.4.3 단계별 추론 과정(CoT, Chain-of-Thought)이 있는 데이터

- Step-level Exact Match

항목명	Step-level Exact Match
설명	- CoT 데이터에서 각 추론 단계별 출력이 정답 단계와 완전히 일치하는지 각각 EM으로 점검한 후 평균을 내는 지표 - 최종 답뿐 아니라 중간 추론 과정의 정확성을 엄격히 평가
검사방법	- 모델 CoT를 미리 정의된 k개 단계(보통 3~8단계)로 분리 - 각 단계별로 정답 단계 문자열과 정규화 후 EM(100% 일치) 계산 → 1 또는 0 - k개 단계의 평균 → Step-level EM(%) 산출 (최종 답 단계는 가중치 1.5~2배 주는 경우 많음)

[표 IV-15] Step-level Exact Match 검사기준 및 방법

- Step-wise F1

항목명	Step-wise F1
설명	- CoT의 각 추론 단계별로 모델 출력과 정답 단계 사이의 토큰 겹침 F1을 계산해 평균을 내는 지표 - Step-level EM보다 유연하게 부분 점수 부여 - 중간 추론의 의미적 정확성을 엄격하지 않게 측정할 때 주로 사용
검사방법	- 모델 CoT를 정답과 동일한 k개 단계로 분할 - 각 단계별로 토큰화 → 해당 단계의 F1 score 계산 (정규화 후) - k개 단계 F1의 평균 → Step-wise F1(%) 산출 (최종 단계는 보통 1.5~2배 가중)

[표 IV-16] Step-wise F1검사기준 및 방법

- Graph Edit Distance (추론 그래프 비교)

항목명	Graph Edit Distance (추론 그래프 비교)
설명	- CoT 추론을 논리 그래프(노드=주장/사실, 엣지=인과·조건 관계)로 변환한 뒤, 두 그래프의 일치화를 위한 필요한 최소 편집 연산(삽입·삭제·대체) 수를 거리 지표로 삼음 - 구조적·의미적 차이를 정량화해 비선형/분기 추론의 정확성을 평가
검사방법	- 모델 CoT와 정답 CoT를 각각 엔티티·관계 추출해 지식 그래프로 변환 (자동 파서 또는 LLM 사용) - 노드/엣지 정규화 후 Graph Edit Distance 계산 - 거리를 정규화(0~1)하거나 유사도로 변환 → 낮을수록(0에 가까울수록) 추론 구조가 정확함

[표 IV-17] Graph Edit Distance (추론 그래프 비교) 검사기준 및 방법

4.1.4.4 장문형 답변 (Long-form Answer) 데이터

- Human Likert Score

항목명	Human Likert Score
설명	- 인간 평가자가 장문 답변을 읽고 의미 정확성·논리 일관성·완전성을 1~5점 (또는 1~7점) Likert 척도로 직접 점수화한 지표 - 장문 생성 평가의 골드 스탠다드 - 자동 지표와 가장 높은 상관관계
검사방법	3명 이상의 전문 평가자에게 동일한 평가 기준서(정확성·완전성·일관성 등 3~5개 항목) 제공 - 각 항목별 1~5점 채점 후 평균 → 최종적으로 사람별 점수 평균 또는 majority vote로 하나의 Likert Score 산출 (데이터당 평균 계산)

[표 IV-18] Human Likert Score 검사기준 및 방법

- GPT-4 Judge Accuracy

항목명	GPT-4 Judge Accuracy
설명	- GPT-4(또는 GPT-4o)를 '자동 평가자'로 사용해 장문 답변을 정답과 비교하여 정확성 점수(보통 1~10점 또는 A~E 등급)를 부여하고, 이를 인간 판단과 비교하거나 직접 점수로 쓰는 지표 - 비용은 들지만 인간 Likert와 0.9 이상 상관관계를 보여 장문 평가의 실질적 대안으로 널리 사용
검사방법	- 미리 만든 프롬프트(정답 + 평가 기준 포함)로 GPT-4o에게 '모델 답변'과 '정답 참조'를 주고 점수/등급 출력 요청 - 동일 입력에 3~5회 반복 또는 temperature=0 고정 후 평균/최빈값 → 최종 GPT-4 Judge 점수 산출 (인간 점수와의 일치율로 Accuracy 계산하거나 그대로 사용)

[표 IV-19] GPT-4 Judge Accuracy 검사기준 및 방법

- BERTScore

항목명	BERTScore
설명	- 장문 답변과 정답 사이의 토큰별 BERT 임베딩 유사도를 계산해 Precision·Recall·F1으로 표현하는 지표 - n-gram 기반 BLEU와 달리 의미적 유사도를 보다 더 직접적으로 반영 - 장문 생성에서 사실 정확성 + 자연스러움을 동시에 측정할 때 널리 사용
검사방법	- 모델 출력과 정답을 동일한 BERT(RoBERTa 등)로 토큰 임베딩 추출 - 각 출력 토큰 → 정답 토큰 중 최대 코사인 유사도 → 평균 → Recall - 각 정답 토큰 → 출력 토큰 중 최대 유사도 → 평균 → Precision $F1 = 2 \times (P \times R) / (P + R)$ → BERTScore F1(보통 0~1 스케일, RoBERTa-large 기준) 계산 (소문자·구두점 정규화 후 수행)

[표 IV-20] BERTScore 검사기준 및 방법

- MoverScore

항목명	• MoverScore
설명	• BERT 임베딩 공간에서 정답 토큰들을 출력 토큰들로 옮기는 데 필요한 최소 비용(Wasserstein distance)을 측정하여 의미적 유사도를 계산하는 지표 • 단어 순서와 문맥 의존성을 BERTScore 보다 더 직접적으로 반영 • 장문 답변의 의미 정확성·유창성을 평가할 때 현재 가장 높은 인간 상관관계를 보이는 n-gram-free 지표 중 하나
검사방법	• 모델 출력과 정답 문장을 동일한 BERT(RoBERTa 등)로 토큰화 후 contextual 임베딩 추출 • 두 임베딩 집합 간 Earth Mover's Distance(또는 Word Mover's Distance + BERT) 계산 • 거리를 0~1 또는 0~100으로 정규화 → MoverScore(높을수록 더 유사, 보통 1-gram MoverScore 또는 n-gram powering 버전 사용)

[표 IV-21] MoverScore 검사기준 및 방법

- LLM-as-a-Judge (Pairwise)

항목명	• LLM-as-a-Judge (Pairwise)
설명	• LLM-as-a-Judge (Pairwise)는 두 개의 장문 답변(A vs B)을 강력한 LLM(GPT-4o, Claude-3.5 등)에게 보여주고 '어느 쪽이 의미적으로 더 정확하고 논리적인가'를 A win / B win / tie로 판단하게 하는 상대 평가 지표 • 단일 점수보다 인간 선호도와 0.93~0.96 수준의 매우 높은 상관관계를 보여 2025년 장문 평가의 실질적 표준으로 자리잡음
검사방법	• 동일 질문에 대해 답변 A(모델)와 B(정답 또는 다른 모델)를 랜덤 순서로 섞어 LLM Judge에게 제시 • '어느 답변이 더 정확하고 논리적인가? (A/B/tie, 이유 필수)' 프롬프트로 3~5회 반복 • Win Rate = (A win 횟수) / 총 비교 횟수 × 100 → Pairwise Win Rate(%) 산출 (temperature=0 고정, majority vote)

[표 IV-22] LLM-as-a-Judge (Pairwise) 검사기준 및 방법

4.1.4.5 사실 기반 + 추론 혼합 (Factoid + Reasoning)

- Fact-Recall Accuracy + Reasoning Score (분리 측정)

항목명	Fact-Recall Accuracy + Reasoning Score (분리 측정)
설명	- 사실형 질문+추론 혼합 데이터에서 사실 회상 정확도와 추론 과정 정확도를 각각 별도로 측정한 후 가중 평균하는 지표 - 두 요소의 기여도를 명확히 분리해 분석 - 보통 Fact 40~60%, Reasoning 40~60% 비율로 합산
검사방법	- Fact-Recall Accuracy - 답변에서 추출된 사실 엔티티·숫자·날짜 등을 정답 사실 리스트와 EM 또는 Normalized Match로 채점 하여 % 계산 - Reasoning Score - 동일 답변의 추론 단계(또는 체크리스트)를 Step-wise F1, Step-level EM, 또는 Human/LLM Reasoning Checklist(논리 비약·모순·과잉추론 등 5~8항목)로 채점하여 % 계산 - 최종 점수 = $w_1 \times \text{Fact-Recall}(\%) + w_2 \times \text{Reasoning}(\%)$ ($w_1+w_2=1$, 대표적 비율 0.5:0.5 또는 0.4:0.6)

[표 IV-23] Fact-Recall Accuracy + Reasoning Score (분리 측정)검사기준 및 방법

- Joint F1 (Entailment 기반)

항목명	Joint F1 (Entailment 기반)
설명	- 사실+추론 혼합 답변을 여러 개의 독립적인 원자 명제(atomic claims)로 분해 - 각 명제가 정답에 NLI 모델로 entail되는지 판단해 Precision·Recall·F1을 계산 - 사실 오류와 추론 오류를 모두 한꺼번에 잡아내며, 2024~2025년 HotpotQA, StrategyQA 등 복합 추론 벤치마크의 새로운 표준으로 자리잡음
검사방법	- 모델 답변을 LLM 또는 규칙 기반으로 “문장 → 원자 명제 리스트”로 분해 (보통 5~15개 claim) - 각 claim에 대해 강력한 NLI 모델(DeBERTa-v3-large, GPT-4o, Llama-3.1-70B 등)을 사용해 정답/지문과 entailed / contradicted / neutral 판단 - Precision = (entailed claims 수 / 전체 claims 수), Recall = (entailed claims 수 / 정답 내 모든 필요 claims 수) → Joint F1 계산 (contradicted는 명시적 패널티로 -1 처리하는 변형도 있음)

[표 IV-24] Joint F1 (Entailment 기반) 검사기준 및 방법

4.1.4.6 수학·논리 문제(정답+증명 포함) 데이터

- Final Answer Accuracy+Proof Correctness

항목명	Final Answer Accuracy + Proof Correctness
설명	- 수학·논리 문제에서 최종 답의 정확도와 증명/추론 과정의 정확도를 별도로 측정한 후 가중 합산하는 지표 - 보통 Final Answer 30~40%, Proof 60~70% 비율을 사용 - GSM8K-Hard, MATH, AIME 등 고난도 데이터셋의 표준 평가 방식
검사방법	- Final Answer Accuracy - 최종 답(숫자, 식, 정답 박스 등)을 정규화 후 EM 또는 Relaxed Match로 0/1 채점 - Proof Correctness - 증명 과정을 인간 평가자 또는 LLM Judge가 단계별·전체적으로 0~100점(또는 0/1)로 채점하거나, Step-wise EM/F1 또는 형식 검증기(Lean, Isabelle)로 자동 채점 - 최종 점수 = $w1 \times \text{Final Answer}(0 \text{ or } 1) + w2 \times \text{Proof Score}(0 \sim 1)$ (대표적 비율 0.3:0.7 또는 0.4:0.6)

[표 IV-25] Final Answer Accuracy + Proof Correctness 검사기준 및 방법

- AlphaGeometry-style Step Accuracy

항목명	AlphaGeometry-style Step Accuracy
설명	- AlphaGeometry-style Step Accuracy는 증명 문제를 보조 구성(auxiliary construction) 포함한 단계별 점수화로 평가 - 최종 답이 맞더라도 증명 단계 중 정확한 보조선·점추가 등 필수 단계를 하나라도 맞추면 부분 점수를 주는 지표 - AlphaGeometry 논문(2024)에서 도입해 IMO 수준 기하 문제 평가의 새로운 표준이 되었음
검사방법	- 정답 증명을 미리 정의된 k개 원자 단계(예: “점 D를 추가”, “삼각형 ABC와 동치 증명” 등)로 분해 - 모델이 생성한 증명에서 각 원자 단계를 정확히 포함했는지 EM 또는 Relaxed Match로 0/1 채점 - Step Accuracy = (정확히 매칭된 필수 단계 수 / 전체 필수 단계 수) * 100 - 최종 정답 정확도는 Step Accuracy와 별도 항목으로 산정하여 가중 합산 방식 - 예시: $0.7 \times \text{Step Accuracy} + 0.3 \times \text{Final Accuracy}$ 또는 정답 달성 시 추가가점 부여

[표 IV-26] AlphaGeometry-style Step Accuracy 검사기준 및 방법

- Lean Theorem Prover Verify

항목명	Lean Theorem Prover Verify
설명	- Lean Theorem Prover Verify는 모델이 작성한 수학·논리 증명을 Lean 4 같은 형식 증명 검증기에 삽입하여 컴파일·타입체크·증명 완료 여부로 0/1을 판단하는 완전 자동·객관적 지표 - 증명이 형식적으로 100% 맞아야 1점을 부여 - GSM8K-Lean, MiniF2F, ProofNet 등에서 ‘증명 능력’의 최종 기준으로 사용
검사방법	- 모델이 Lean 4 증명 스크립트 형식으로 출력을 생성하도록 프롬프트 설계 또는 미세조정(fine-tuning) 수행 - 생성된 스크립트를 Lean 컴파일러로 검증하여 증명 목표(theorem)가 완전 증명되면 아래와 같이 판정 - 컴파일/검증 오류·시간 초과 또는 증명 미완료 표시(예: sorry)가 포함되면 0으로 판정 - 데이터셋 단위 성공률(%)을 Lean Verify Accuracy(또는 Pass@1)로 산출·보고하며 검증 실행의 시간제한(timeout)은 사전 정의된 값(예: 30~60초)로 설정

[표 IV-27] Lean Theorem Prover Verify 검사기준 및 방법

4.1.4.7 복수참조 (Multi-reference) 데이터

- BLEURT

항목명	BLEURT
설명	- BERT 기반 학습된 평가 지표로, 모델 생성 텍스트와 참조 텍스트 간의 의미적·유창성 유사도를 0~1 스코어로 계산 - multi-reference 데이터에서 최대 참조 스코어를 취해 가장 잘 맞는 참조와 비교 - BLEU/ROUGE의 단점을 보완해 인간 판단과 높은 상관(0.9 이상)을 보이며, 2020 ACL 논문에서 제안된 표준 지표
검사방법	- 모델 출력과 각 참조 텍스트 쌍에 대해 미리 훈련된 BLEURT 모델 (BLEURT-20 checkpoint 등)로 유사도 스코어 계산 (TensorFlow 또는 Hugging Face 구현 사용) - Multi-reference의 경우 $\max(\text{BLEURT}(\text{candidate}, \text{ref}_i))$ ($i=1 \sim n$ 참조)하여 데이터셋 평균으로 최종 BLEURT 스코어(0~1) 산출 (정규화: 소문자 변환, 토큰화 후 수행)

[표 IV-28] BLEURT 검사기준 및 방법

- COMET

항목명	COMET
설명	- 다국어 환경에서 미세조정된 신경망 기반 기계번역(MT) 평가 지표 - source, candidate, reference를 평가 입력으로 활용하여 의미보존(adequacy), 유창성(fluency) 등 품질을 단일 점수 예측 - 다중 참조(multi-reference) 설정에서는 참조 문장들 중 가장 높은 점수에 해당하는 참조를 선택하는 방식으로 산출 가능 - WMT 등 공인 평가 캠페인에서 인간 평가와의 상관관계가 높게 보고되어 널리 사용되는 지표 중 하나
검사방법	- COMET 모델(예: wmt22-comet-da, Unbabel/wmt23-cometkiwi-da 등)을 로드 - 입력 형식: {"src": 원문, "mt": 모델 출력, "ref": 참조1} (또는 refs 리스트) - Multi-reference 시 자동으로 각 ref와 비교 후 최고 스코어를 해당 샘플 점수로 채택하여 데이터셋 전체 평균으로 최종 COMET 스코어 보고 (보통 0~100 스케일)

[표 IV-29] COMET 검사기준 및 방법

- BARTScore

항목명	BARTScore
설명	- BART를 활용해 reference → candidate 방향의 생성 확률과 candidate → reference 방향의 재구성 확률을 조합한 지표 - multi-reference 상황에서도 모든 참조에 대해 점수를 내고 최대값(max-ref)을 취함 - 사실 정확성과 유창성을 동시에 잘 반영하며, 참조 기반 평가 중 파라미터 효율이 높고 인간 판단과 상관관계가 뛰어남
검사방법	- 사전학습 또는 fine-tuned BART 모델(예: facebook/bart-large-cnn)을 로드 - 각 참조 ref_i에 대해 $P(\text{recall}): P(\text{candidate} \mid \text{ref}_i) / P(\text{precision}): P(\text{ref}_i \mid \text{candidate})$ / $P(F1)$: 조화 평균 또는 단순 합 - 모든 ref_i 중 최대 BARTScore(보통 F1 변형)를 해당 샘플 점수로 선택하여 데이터셋 평균으로 최종 BARTScore 보고 (값은 log-prob 스케일, 높을수록 긍정)

[표 IV-30] BARTScore 검사기준 및 방법

- G-Eval

항목명	● G-Eval
설명	● LLM(주로 GPT-4 시리즈)을 ‘평가자’로 사용해, 사전에 정의된 평가 기준 (예: 정확성, 논리성, 완전성 등)을 프롬프트에 명시하고 장문 답변에 대해 1~5점 또는 1~10점을 직접 부여하는 LLM-as-a-Judge 방식 ● Multi-reference일 때는 ‘모든 참조 중 가장 좋은 것’ 또는 ‘모든 참조를 동시에 제시하고 상대적 품질’을 판단하게 하여 최고 0.92~0.95의 인간 상관관계를 보임
검사방법	● 고정된 평가 프롬프트에 질문 + 평가 기준(Rubric) + 모든 참조 답변 + 모델 출력을 입력하여 LLM(GPT-4o 등)에게 1~10점 점수 출력 요청 ● 동일 입력에 temperature=0으로 1~3회 실행 후 평균 또는 최빈값 → 최종 G-Eval 점수 ● Multi-reference 상황에서는 참조갑을 ‘예시 정답’으로 제시하거나, ‘이 참조들보다 얼마나 더 정확한가’를 묻는 방식으로 사용 (데이터셋 평균으로 최종 점수 산출)

[표 IV-31] G-Eval 검사기준 및 방법

4.1.4.8 선호(비교) 데이터 (A better than B)

- Pairwise Win Rate

항목명	● Pairwise Win Rate
설명	● 동일 질문에 대한 두 답변 A와 B를 인간(또는 LLM Judge)이 직접 비교하여 ‘A가 더 정확하다 / B가 더 정확하다 / 동률’을 판단하고, A가 이긴 비율(%)을 의미 정확성 지표로 사용하는 상대 평가 방식 ● Preference 데이터(예: AlpacaEval, MT-Bench, Arena-Hard)에서 사실상 표준이며, 인간 선호도와 0.95 이상 상관관계
검사방법	● 동일 질문에 대해 답변 A(모델)와 B(기준 모델 또는 정답 근사)를 랜덤 순서로 혼합하여 인간 또는 LLM Judge(GPT-4o/Claude-3.5/Prometheus 등)에게 제시 ● ‘어느 쪽이 의미적으로 더 정확하고 논리적인가? (A win / B win / tie, 이유 필수)’ 프롬프트로 1~5회 판단 ● Win Rate (%) = (A win 횟수) / (총 비교 횟수 - tie 횟수) × 100 → tie는 제외하거나 0.5점 처리 (보통 temperature=0, majority vote)

[표 IV-32] Pairwise Win Rate 검사기준 및 방법

- Bradley-Terry Modeling

항목명	• Bradley-Terry Modeling
설명	• Bradley-Terry Modeling은 Pairwise 비교 결과($A \succ B$, $B \succ A$)를 바탕으로 각 모델에 강도(strength) 파라미터를 추정해 순위를 매기는 통계 모델 • Win Rate보다 더 정밀하고 일관된 상대적 의미 정확성 점수를 제공 • AlpacaEval, LMSYS Chatbot Arena, Arena-Hard 등 2024~2025년 주요 리더보드의 공식 순위 지표
검사방법	• 모든 모델 쌍에 대해 Pairwise 비교 결과(승/패/tie)를 수집 • Bradley-Terry 모델(또는 그 확장인 BT-LLM)을 MLE 또는 Bayesian으로 fitting → 각 모델에 Elo와 유사한 실력 점수(μ) 추정 • 최종 Bradley-Terry Score = 추정된 μ값(또는 $\exp(\mu)$로 변환한 odds) → 점수가 높을수록 의미 정확성 우수 (tie는 0.5로 처리, 95% 신뢰구간도 함께 보고)

[표 IV-33] Bradley-Terry Modeling검사기준 및 방법

4.1.5 의미 정확성 품질관리 계획서 작성요령

작성 요령

- 아래 [표]를 참고하여, 의미 정확성의 검사항목별 측정지표, 정량목표 및 검사대상 및 검사방법, 지표설정 근거에 대해서 작성

작성 예시							
품질 특성	검사 항목	측정 지표	정량 목표	검사대상			검사 방법
				산출물	데이터 종류	내용	
의미 정확성	추론의 일관성	Step-wise F1	단계 F1의 평균 → Step-wise F1(%) 산출	가공 데이터	단계별 추론과정 (Chain-of-Thought) 데이터	추론	- 모델 CoT를 정답과 동일한 k개 단계로 분할 - 각 단계별로 토큰화 → 해당 단계의 F1 score 계산 (정규화 후) - k개 단계 F1의 평균 → Step-wise F1(%) 산출 (최종 단계는 보통 1.5~2배 가중)
	추론의 적절성	Pairwise Win Rate	95%	가공 데이터	선호(비교) 데이터 (A better than B)	답변	- 동일 질문에 대해 답변 A(모델)와 B(기준 모델 또는 정답 근사)를 랜덤 순서로 섞어 인간 또는 LLM Judge (GPT-4o/Claude-3.5/Prometheus 등)에게 제시 “어느 쪽이 의미적으로 더 정확하고 논리적인가? (A win / B win / tie, 이유 필수)” 프롬프트로 1~5회 판단 - Win Rate (%) = (A win 횟수) / (총 비교 횟수 - tie 횟수) × 100 → tie는 제외하거나 0.5점 처리 (보통 temperature=0, majority vote)

5

학습모델 적합성 품질관리 지표

5.1 알고리즘(아키텍처) 적정성

- 인공지능 학습용 데이터를 구축할 때 추론 아키텍처(Inference Architecture)를 활용한다는 것은 단순히 데이터를 수집하는 것을 넘어 최종적으로 학습된 모델이 수행할 추론 과정과 환경에 최적화되도록 데이터를 설계하고 가공한다는 의미

5.2 아키텍처 유형별 고려사항

- 데이터 구축 목표가 곧 추론 아키텍처 선택의 기준

아키텍처의 종류	데이터 구축 시 주요 고려 사항	품질관리항목
CoT	- 논리적 흐름의 일관성 - 추론 단계(Chain) 간의 인과관계 및 비약 여부를 엄격하게 점검 - 단계별 상세화 - 각 중간 단계에서 제시하는 정보, 근거, 계산식 등이 최종 답변을 도출하기에 충분하도록 상세하게 라벨링.	- CoT 정합성 - 단계 간 논리적 연결성 및 흐름 일관성 - 단계별 정확도 - 중간추론단계의 사실적 정확도, 계산정확도 - 추론 길이(Length) - 문제 복잡도에 비례하는 적절 추론단계 수
CoT-SC	- 다중 경로 확보 - 하나의 문제에 대해 여러 개의 타당하고 독립적인 추론 경로(Multi-path)를 구축 - 정답 수렴성 - 다수 경로가 제시하는 최종 답안이 일관된 정답으로 수렴하는지 확인하고 라벨링 (일부 오답 경로는 다양성을 위해 허용 가능)	- 경로 다양성(Path Diversity) - 동일 문제에 대한 추론 경로들간의 내용적 차별성 및 다양성 수준 - 정답수렴도 (Convergence Rate) - 다중경로 중 정답으로 이어진 경로의 비율 - 가중치 유효성 - 각 경로 부여된 신뢰도/투표가중치 적절성
ToT	- 단계별 상태(State) 정의 - 각 노드(Node) 또는 생각 단위에서 현재 상태, 사용된 근거, 다음 탐색 방향을 명확히 정의하고 라벨링 - 가지치기(Pruning) 기준 - 실패하거나 불필요한 경로를 가지치기하는 기준을 모델이 학습할 수 있도록 해당 경로 및 판단 근거를 데이터로 구성	- 노드 유효성 (Node Validity) - 단계(Node)에서 도출된 정보, 판단 타당성 - 탐색효율성(Search Efficiency) - 정답 노드를 찾기 위해 탐색된 총 노드의 수 (최적의 탐색을 유도 여부 확인) - 전략의 다양성 - 문제 해결에 사용된 탐색 전략(예: BFS, DFS)의 균형 있는 분포
ReAct	- T-A-O 루프 명시 - Thought)-Action-Observation(관찰)의 각 단계를 명확히 구분하고 라벨링 - 정확한 액션 정의 - Action에 사용된 도구의 종류,	- 도구 호출 정확도(Tool Call Accuracy) - Action 단계에서 호출된 도구와 매개변수의 적절성 및 문법적 정확성. - 루프 효율성(Loop Efficiency) - 최종 답안 도출까지의 T-A-O 루프 반복

	매개변수(Arguments), 입력값 등을 정확하게 정의 • 외부 정보 연계성 Observation - Action을 통해 얻어진 외부 정보가 결과와 정확히 일치하는지 검증하고 라벨링	횟수 (최소 반복으로 정답을 얻는지) • 사고-행동 일치성 - Thought 내용이 다음 Action을 논리적으로 뒷받침하는지 여부
TAR	• 근거 자료(Grounding Source) 포함 - 추론 과정에서 사용된 외부 지식(검색 결과) 또는 도구 출력 결과를 데이터셋에 반드시 포함 • 검색 키워드 라벨링 - 외부 자료를 효과적으로 검색하기 위한 최적의 검색 키워드(Query)를 데이터에 함께 라벨링하여 검색 능력을 학습	• 근거 일치도(Grounding Fidelity) - 최종 답변의 사실 정보가 제공된 근거 자료 내의 정보와 정확히 일치하는 정도 • 검색 효율성 지표 - 라벨링된 검색 키워드가 정답 문서를 상위 순위로 검색하는 비율 • 도구 사용 효과성 - 도구 사용 전후의 정확도 향상 기여도

[표 IV-34] 아키텍처 유형별 고려사항

5.3 아키텍처 유형별 품질관리 지표

- CoT, CoT-SC 등 다양한 추론형 AI 아키텍처를 기준으로 유형별 품질관리 지표를 제시

구분	품질관리 지표	
CoT	정합성 논리적 연결성 및 흐름 일관성	• Logical Coherence Score (LCS) • Step Consistency Score • Faithfulness Score (or Attribution Faithfulness)
	단계별 정확도 (Step Accuracy)	• Fact Accuracy(Factual Correctness @ Step Level) • Calculation Accuracy(Arithmetic/Symbolic Accuracy) • Local Validity Score • Error Propagation Index
	추론 길이 (Length Appropriateness)	• CoT Length Appropriateness Score (LAS) • Problem-to-Reasoning Ratio (PRR) • Step Efficiency Score
	CoT 품질 종합적 평가	• CoT Quality Score (CQS) • Self-Evaluation / LLM-as-a-Judge Score • Self-Consistency Rate
CoT-SC	경로 다양성	• Semantic Diversity Score (SDS) • Entropy-based Diversity (Shannon Entropy) • Logical Diversity Index (LDI)
	정답수렴도	• Convergence Rate (CR) • Majority Vote Concentration (MVC) • Multi-Path Agreement Score (MAS)
	가중치 유효성	• Expected Calibration Error(ECE) • Weight-Outcome Correlation (WOC)

ToT	노드유효성	• Step Factual Accuracy (SFA) • Node Coherence / Consistency Score (NCS)
	탐색효율성	• Node Expansion Efficiency (NEE) • Branching Factor Control (BFC) • Search Cost per Solution (SCS)
	전략의 다양성	• Strategy Distribution Entropy (SDE) • Path Strategy Diversity Score (PSDS) • Heuristic Utilization Ratio (HUR)
ReAct	루프 효율성 (Loop Efficiency)	• Loop Count to Solution (LCS) • Step Efficiency Ratio (SER) • Decision Latency per Loop (DLL)
	사고-행동 일치성	• Thought-Action Consistency Score (TACS) • Justification Quality Score (JQS) • Action Rationality Index (ARI)
TAR	근거 일치도	• Evidence Support Score (ESS) • Attribution Accuracy (AA)
	검색 효율성	• Mean Reciprocal Rank (MRR) • Normalized Discounted Cumulative Gain (nDCG)
	도구사용효과성	• Δ Accuracy (Accuracy Gain) • Tool Contribution Score (TCS) • Effective Tool Call Rate (ETCR)

[표 IV-35] 아키텍처 유형별 품질관리 지표

5.3.1 CoT

5.3.1.1 Logical Coherence Score (LCS)

지표명	Logical Coherence Score (LCS)
설명	- 텍스트(추론 텍스트)가 논리적으로 모순되지 않고 일관되게 이어지는 정도를 0~100점으로 정량화한 지표 - 논리 오류, 사실 모순, 앞뒤 맥락 불일치 등이 적을수록 점수가 높음
측정산식	$LCS = (S_1 + S_2 + \dots + S_n) / n$ (S_i: i번째 평가자의 점수, n: 평가자 수, 보통 $n \geq 3$)
검사방법	- 사람 평가자(보통 3명 이상)가 주어진 텍스트를 읽고 논리적 모순이나 비일관성을 찾아 0~100점을 기준으로 점수를 부여 - 각 평가자의 점수를 평균 내어 최종 LCS를 산출하며, 점수 기준은 사전에 정의된 러브릭(예: 90점 이상=거의 완벽, 70점 미만=명확한 논리 오류)을 준수 - 자동화된 방법도 연구 중이나 현재는 인간 평가를 표준으로 적용

[표 IV-36] Logical Coherence Score (LCS) 정의 및 검사방법

5.3.1.2 Step Consistency Score

지표명	Step Consistency Score
설명	- AI 에이전트 또는 LLM이 다단계 추론 과정에서 각 단계의 논리적 연결과 일관성을 평가하는 지표 0~100점 규모로 측정 - 단계 간 모순이나 맥락 손실이 적을수록 높은 점수를 받으며, 전체 작업 성공성을 높이는 데 초점
측정산식	- 평가자별로 산정된 '단계단위 추론 흐름의 일관성' 점수를 산술평균하여 산출 $SCS = (S_1 + S_2 + \dots + S_n) / n$ S_i: i번째 평가자(또는 LLM Judge)가 해당 추론 과정의 단계별 추론 흐름 일관성에 대해 산정한 점수(사전 정의된 척도 적용, 예: 0~100) n: 평가자 수 (인간 평가 또는 LLM Judge 반복 평가 횟수 등으로 정의) - 예시: 인간 평가자는 보통 3~5명, LLM-as-a-Judge 사용 시 1~3회 반복 - 산정 방식은 운영 목적에 따라 다음 중 하나로 적용 할 수 있음 (방식 A) 샘플단위 종합 점수를 산정한 후 평가자 평균을 계산 (방식 B) 단계 k별 점수를 먼저 산정한 후 단계 평균을 계산하고 최종적으로 평가자 평균을 계산 - 동일하게 평균 산식을 사용하더라도 SCS는 평가 단위를 전체 텍스트가 아닌 단계 단위 추론 흐름으로 설정한다는 점에서 일반 텍스트 일관성 점수와 구분됨
검사방법	- 인간 평가자나 LLM-as-a-Judge가 에이전트의 단계별 추론 경로를 분석하여 명확성, 논리적 흐름, 맥락 유지 여부를 0~100점을 기준으로 점수를 부여 - 다중 턴 시뮬레이션(예: 대화나 작업 시나리오)을 통해 일관성을 테스트하며, G-Eval 등 프레임워크를 활용해 Chain-of-Thought(생각의 사슬)로 세부 평가 단계 생성 - 여러 버전 비교를 위해 평균 점수를 산출하고, 러브릭(평가 기준)을 적용해 객관성을 확보

[표 IV-37] Step Consistency Score 정의 및 검사방법

5.3.1.3 Faithfulness Score(or Attribution Faithfulness)

지표명	Faithfulness Score(or Attribution Faithfulness)
설명	- AI가 생성한 답변(특히 주장·사실)이 주어진 근거 문서(참조 텍스트)에 얼마나 정확히 기반하고 있는지를 0~100점으로 측정한 지표 - 환각(hallucination)이 적을수록 높은 점수를 부여
측정산식	- 기본 산식 (인간/LMM 평가 평균) $\text{Faithfulness Score} = (S_1 + S_2 + \dots + S_n) / n$ (S_i: i번째 평가자의 0~100점수, $n \geq 3$) - 자동화된 정밀 산식 (Claim-level) $\text{Faithfulness} = (\text{Number of Supported Claims}) / (\text{Total Number of Claims}) \times 100$ - 최종 점수로 환산하거나 그대로 %로 사용 (예: 92% → 92점)
검사방법	- 인간 평가자 또는 LLM Judge가 답변을 주장(claim) 단위로 분해한 뒤, 각 주장에 대해 근거 문서 대비 지지(Supported)·모순(Contradictory)·근거불충분(Neutral)여부를 판정 - 전체 주장 중 지지(Supported)로 판정된 비율을 핵심 산정 기준으로 하여 점수를 산출하며 필요시 이를 0~100 범위로 정규화하여 보고

[표 IV-38] Faithfulness Score(or Attribution Faithfulness) 정의 및 검사방법

5.3.1.4 Fact Accuracy(Factual Correctness @ Step Level)

지표명	Fact Accuracy(Factual Correctness@Step Level)
설명	- 다단계 추론 과정에서 각 단계마다 제시된 사실·계산·정보가 객관적으로 정확한지를 측정하는 지표 - 환각이나 계산 오류가 없어야 100점에 가까워짐
측정산식	- 기본 산식 $\text{Fact Accuracy} = (\text{Number of Correct Steps} / \text{Total Number of Steps}) \times 100$ 3단계 평가 사용 시 $\text{Fact Accuracy} = (2 \times \text{Fully Correct} + 1 \times \text{Partially Correct}) / (2 \times \text{Total Steps}) \times 100$ - 결과는 0~100점(또는 %)으로 표현되며, LongFact 등 벤치마크에서 널리 사용
검사방법	- 인간 전문가 또는 검증된 LLM Judge가 추론 과정을 단계(step)단위로 점검하여 각 단계의 사실 관계 또는 계산의 정확성을 판정 (Correct/Incorrect) - 운영 목적에 따라 부분 정확(Partially Correct) 범주를 추가하여 3수준 척도로 평가 가능

[표 IV-39] Fact Accuracy(Factual Correctness@Step Level) 정의 및 검사방법

5.3.1.5 Calculation Accuracy(Arithmetic/Symbolic Accuracy)

지표명	• Calculation Accuracy(Arithmetic/Symbolic Accuracy)
설명	- 모델이 제시한 수치 계산, 수식 전제, 기호 조작의 결과가 수학적으로 정확한지를 측정하는 지표 - 평가 기준은 사전 정의된 정답(또는 검증 가능한 참값)에 대해 완전 일치 여부로 판정하는 방식
측정산식	- Calculation Accuracy = $(\text{Number of Perfectly Correct Problems} / \text{Total Number of Problems}) \times 100$ - 문제 단위 판정에서 “Correct”는 중간 계산 및 최종 답이 모두 정확한 경우로 정의할 수 있으며 기준에 따라 중간 단계 오류 발생 시 해당 문제를 오답 처리하는 엄격한 기준을 적용할 수 있음 - 결과는 0~100% 범위로 산정 (예: GSM8K에서 89.7% 등)
검사방법	- 자동 검증 스크립트(예: Python 기반 수치 검증, SymPy 등 CAS 활용)를 통해 중간 계산 결과 및 최종 답의 정합성을 점검 - 단계별 검증 결과를 기반으로 문제 단위 최종 판정을 수행

[표 IV-40] Calculation Accuracy(Arithmetic/Symbolic Accuracy) 정의 및 검사방법

5.3.1.6 Local Validity Score

지표명	• Local Validity Score
설명	- 다단계 추론에서 ‘개별 추론 단계’가 바로 직전 단계로부터 논리적으로 타당하게 도출되는지를 측정하는 지표 - 전체 정답 여부와 관계없이 단계별 논리 연결의 건전함에 대해서만 평가
측정산식	- Local Validity Score = $(\text{Number of Valid Local Steps} / \text{Total Number of Steps}) \times 100$ - 또는 세부 버전: $LVS = (\sum_{i=1}^n V_i) / n \times 100$ ($V_i = 1$ if i번째 단계가 국소적으로 유효, else 0)
검사방법	- 인간 평가자 또는 LLM Judge가 추론 과정을 단계별로 분해하여, 각 단계 i가 $(i-1)$만을 입력으로 했을 때 자연스럽게 논리적으로 따라갈 수 있는지 “Valid / Invalid”로 판단 - 전체 과정이 맞든 틀리든 상관없이 오직 국소적 연결만 평가

[표 IV-41] Local Validity Score 정의 및 검사방법

5.3.1.7 Error Propagation Index

지표명	• Error Propagation Index(EPI)
설명	- 다단계 추론에서 초기 단계의 작은 오류가 이후 단계로 얼마나 증폭되어 전파되는지를 정량화한 지표 - 값이 높을수록 오류에 취약한 모델
측정산식	$EPI = (\text{Acc_clean} - \text{Acc_noisy}) / \text{Acc_clean} \times 100$ - Acc_clean: 오류 없이 정상 수행한 정확도(%) - Acc_noisy: 초기 단계에 오류 주입 후 정확도(%) - EPI 범위: 0~100 (0 = 오류에 강건, 100 = 완전 붕괴)
검사방법	- 동일한 문제에 대해 의도적으로 초기 단계에 미세한 오류(노이즈)를 주입한 뒤, 최종 답변의 정확도 하락 정도를 측정 - 오류 주입 없이 정상 수행한 정확도와 비교

[표 IV-42] Error Propagation Index 정의 및 검사방법

5.3.1.8 CoT Length Appropriateness Score (LAS)

지표명	CoT Length Appropriateness Score (LAS)
설명	- 주어진 문제의 난이도 및 요구되는 추론 복잡도에 비추어 Chain-of-Thought의 단계 수 (또는 단계별 서술량)가 과도하게 길거나 지나치게 축약되지 않고 적정 수준으로 구성되었는지 평가 - 평가 시 불필요한 상황함(불필요 단계, 반복, 중복)과 과도한 생략(핵심 단계 누락, 비약)을 모두 감점 요소로 반영
측정산식	$LAS = \max(0, 100 - 10 \times \text{Actual} - \text{Optimal})$ - 예시: 최적 8단계일 때 8단계 → LAS = 100 6단계 또는 10단계 → LAS = 80 4단계 또는 14단계 → LAS = 60 이하
검사방법	- 전문 평가자 또는 LLM Judge가 정답 CoT의 이상적인 권장 단계 수 (또는 최소 단계 수) (ground-truth optimal length)를 기준으로 모델이 생성한 CoT 단계 수 및 단계별 서술량을 비교하여 적정성을 평가 - 평가 시 핵심 단계 누락으로 인한 과도한 축약과 중복·불필요 설명에 따른 과도한 확장을 감점 요소로 반영

[표 IV-43] CoT Length Appropriateness Score (LAS) 정의 및 검사방법

5.3.1.9 Problem-to-Reasoning Ratio (PRR)

지표명	Problem-to-Reasoning Ratio (PRR)
설명	- 한 문제에 대해 모델이 생성한 추론(Chain-of-Thought)의 길이(토큰 수 또는 단계 수)를 문제 입력의 길이(토큰 수)로 정규화한 비율로 추론 서술의 규모/효율성을 정량적으로 파악하기 위한 지표 - 일반적으로 PRR 값이 낮을수록 동일한 문제 입력 대비 추론 서술이 상대적으로 간결함을 의미 (단, 정답 정확도와는 별개로 해석)
측정산식	- 토큰 기준 (표준) $PRR = (\text{Number of Reasoning Tokens}) / (\text{Number of Input Problem Tokens})$ - 단계 수 기준 변형 $PRR_steps = (\text{Number of Reasoning Steps}) / (\text{Problem Difficulty Tier})$ (Difficulty Tier: 보통 1~5로 사전 분류) - 예시 - 문제 50토큰, CoT 450토큰 → PRR = 9.0 (장황) - 문제 50토큰, CoT 120토큰 → PRR = 2.4 (효율적) - 현재 효율적 reasoning 연구(예: o1-mini vs o1 비교)에서 가장 널리 쓰이는 지표
검사방법	- 입력 문제의 토큰 수와, 모델 출력 중 추론 구간(CoT)의 토큰 수를 각각 산출한 후 비율을 계산 - 정답 여부와 무관하게 추론 서술의 길이 특성을 측정하므로 정확도 지표(예: 최종 정답 정확도, 단계 정확도 등)와 함께 해석하는 것을 원칙으로 함

[표 IV-44] Problem-to-Reasoning Ratio (PRR) 정의 및 검사방법

5.3.1.10 Step Efficiency Score

지표명	Step Efficiency Score
설명	- 정답에 도달하기 위해 사용한 추론 단계 수를 최소 필요 단계 수로 나눈 값의 역수를 점수화한 지표 - 값이 높을수록 더 적은 단계로 문제를 해결한 효율적인 추론을 의미
측정산식	$SES = 100 \times (1 / \text{Compression_Ratio})$ - where $\text{Compression_Ratio} = \text{Actual_Steps} / \text{Optimal_Steps}$ - 예시 - 최적 5단계, 실제 5단계 → $SES = 100$ - 최적 5단계, 실제 10단계 → $SES = 50$ - 최적 5단계, 실제 20단계 → $SES = 25$ - 오답 → $SES = 0$
검사방법	- 전문가나 LLM Judge가 각 문제의 '최소 필수 추론 단계 수'(ground-truth minimal steps)를 사전에 정의한 후, 모델이 실제 출력한 단계 수와 비교 - 정답인 경우에만 효율성을 측정하며 오답은 0점 처리

[표 IV-45] Step Efficiency Score 정의 및 검사방법

5.3.1.11 CoT Quality Score (CQS)

지표명	CoT Quality Score (CQS)
설명	- Chain-of-Thought 전체의 논리적 완결성, 사실 정확성, 단계 간 연결성, 간결함을 종합적으로 평가한 단일 점수 - 현재 reasoning 평가에서 가장 널리 쓰이는 통합 지표
측정산식	- 기본 산식 (다중 평가자 평균) $CQS = (S_1 + S_2 + \dots + S_n) / n$ (S_i: i번째 평가자의 0~100점 또는 1~10점, 보통 $n=3\sim5$) - LLM-as-a-Judge 자동 산식 예시 $CQS = 100 \times (0.4 \times \text{Logical_Coherence} + 0.3 \times \text{Fact_Accuracy} + 0.2 \times \text{Local_Validity} + 0.1 \times \text{Conciseness})$ - 실제는 0~10점 척도를 더 많이 쓰며, 최종점수는 평균 후 $\times 10$ 해서 0~100점으로 변환해 보고
검사방법	- 인간 전문가 또는 고성능 LLM Judge(GPT-4o, Claude-3.5 등)가 미리 정의된 7~10점 척도(또는 0~100점) 루브릭에 따라 CoT 전체를 한 번에 읽고 단일 점수로 채점 - 세부 항목(논리적 일관성, 사실 정확도, 중복 여부, 명료성 등)을 가중 평균하거나 종합 판단

[표 IV-46] CoT Quality Score (CQS)의 정의 및 검사방법

5.3.1.12 Self-Evaluation / LLM-as-a-Judge Score

지표명	Self-Evaluation / LLM-as-a-Judge Score (LLM 자가평가 점수)
설명	- 고성능 LLM(예: GPT-4o, Claude-3.5, Llama-3.1-405B)이 인간 대신 다른 모델의 답변·추론 과정을 평가하여 부여한 품질 점수 - 인간 평가와 80~95% 수준의 상관관계
측정산식	- 기본 산식 - LLM-as-a-Judge Score = $(S_1 + S_2 + \dots + S_n) / n$ (S_i: i번째 평가 LLM의 점수, 보통 $n=1\sim3$) - 실제 가장 많이 쓰이는 형태 - Score = 평균(3회 평가) → 1~10점 척도라면 ×10 해서 0~100점으로 변환 - 예: GPT-4o가 3번 평가해 8.7, 9.0, 8.3 → 최종 Score = 88.3 - 현재 거의 모든 최신 reasoning 논문(MATH, GPQA, AIME, FrontierMath 등)에서 인간 평가를 완전히 대체하거나 보완하는 표준 지표
검사방법	- 평가용 LLM에게 명확한 루브릭과 few-shot 예시를 제공한 프롬프트를 주고, 대상 모델의 CoT·답변을 입력으로 넣어 0~100점 또는 1~10점으로 채점 - 동일 답변에 대해 1~3회 반복 평가하거나 temperature=0으로 고정하여 일관성을 제고

[표 IV-47] Self-Evaluation / LLM-as-a-Judge Score 정의 및 검사방법

5.3.1.13 Self-Consistency Rate

지표명	Self-Consistency Rate
설명	- 동일한 문제를 서로 다른 추론 경로(또는 다른 샘플링)로 여러 번 풀었을 때, 최종 답변이 얼마나 일치하는지를 나타내는 지표 - 모델의 내부 불확실성과 환각 정도를 간접적으로 측정
측정산식	- Self-Consistency Rate (SCR) = $(\text{Number of Samples that match the Majority Answer}) / (\text{Total Number of Samples}) \times 100$ - 또는 정확도 형태로 최종 보고: Self-Consistency Accuracy = $(\text{Number of Problems where Majority Answer} = \text{Ground Truth}) / (\text{Total Problems}) \times 100$
검사방법	- 동일 문제에 대해 temperature > 0.7로 10~50회 독립적으로 CoT를 생성하고 최종 답변만 추출 - 다수결(majority vote)로 가장 많이 나온 답변을 대표 답변으로 선택

[표 IV-48] Self-Consistency Rate의 정의 및 검사방법

5.3.2 CoT-SC

5.3.2.1 Semantic Diversity Score (SDS)

지표명	Semantic Diversity Score (SDS)
설명	- 동일한 문제를 반복 수행할 때 생성되는 복수의 추론 경로(CoT)간 의미적 차이 (Semantic diversity) 수준을 정량화 하는 지표 - 지표 값이 높을수록 동일 문제에 대해 다양한 추론 전략·관점의 경로가 산출되는 경향을 의미
측정산식	- 대표 산정 방식(예시) - SDS = $100 \times (1 - \text{평균 pairwise similarity})$ - SDS = $100 \times (1 - \text{Self-BLEU@CoT})$ - 정밀 클러스터링 버전 - CoT 20개에 ego Sentence-BERT 임베딩 산출 - 평균 코사인 유사도 = $(\sum_{i < j} \text{sim}(\text{CoT}_i, \text{CoT}_j)) / (N \text{ choose } 2)$ - SDS = $100 \times (1 - \text{평균 코사인 유사도})$
검사방법	- 동일 문제에 대해 8~20개의 서로 다른 CoT를 생성한 뒤, 각 CoT를 문장·단어 단위로 임베딩하거나 클러스터링하여 의미적 유사도를 계산 - Self-BLEU, BERTScore, Sentence-BERT 코사인 유사도 등을 사용

[표 IV-49] Semantic Diversity Score (SDS) 정의 및 검사방법

5.3.2.2 Entropy-based Diversity (Shannon Entropy)

지표명	Entropy-based Diversity(Shannon Entropy)
설명	- 동일 문제를 반복 수행할 때 생성되는 최종 답변 또는 추론 전략 유형(클러스터링 결과 등)의 분포가 얼마나 고르게 분산되어 있는지를 Shannon Entropy로 정량화하는 지표 - 지표값이 높을수록 출력(답변/전략) 분포가 다양하게 분산되어 있음을 의미 (단, 다양성은 정답 정확도와 별개로 해석해야 함)
측정산식	- Shannon Entropy $H = - \sum_{i=1}^k p_i \times \log_2(p_i)$ p_i : i번째 답변(또는 전략 클러스터)의 출현 확률 k : 서로 다른 답변/전략 수 - 정규화된 Diversity 점수 (0~100) - Entropy-based Diversity Score = $(H / \log_2(k)) \times 100$ (최대 엔트로피일 때 100점, 완전 일관될 때 0점)
검사방법	- 동일 문제에 대해 독립 샘플링을 다회 수행 (예: 20~100회)하여 최종 답변을 수집한 뒤 각 답변의 출현빈도 및 확률 분포를 산출 - 산출된 확률 분포를 기반으로 Shannon Entropy를 계산하여 다양성 수준을 보고함 - 정답이 단일한 과제에서는 특정 답변(특히 정답)으로 출력이 집중될 경우 분포가 편향되어 Entropy가 낮아질 수 있으므로 정확도 지표와 분리하여 해석

[표 IV-50] Entropy-based Diversity (Shannon Entropy) 정의 및 검사방법

5.3.2.3 Logical Diversity Index (LDI)

지표명	Logical Diversity Index (LDI)
설명	- 동일 문제에 대해 다회 샘플링으로 생성된 복수의 추론 경로(CoT) 간 의미적, 구조적 차이를 정량화하는 지표 - 지표값이 높을수록 단일 서술 패턴에 편중되지 않고 서로 상이한 경로가 산출되는 경향을 의미 - 본 지표는 정답 정확도와 별개로 추론 경로의 분산/탐색 특성을 파악하기 위한 보조 지표로 활용
측정산식	$LDI = 100 \times (1 - \text{평균 pairwise logical similarity})$ - 평균 pairwise 유사도 = $(\sum_{i < j} \text{sim}(\text{CoT}_i, \text{CoT}_j)) / (N \text{ choose } 2)$ (선택) 엔트로피 기반 변형(클러스터링 전제): $LDI = - \sum_{i=1}^k p_i \times \log_2(p_i) / \log_2(k) \times 100$ (p_i: i번째 논리 클러스터의 출현 확률, k: 클러스터 수)
검사방법	- 동일 문제에 대해 독립 샘플링(예: 10~20회)으로 CoT를 생성한 뒤 각 CoT를 임베딩 또는 논리단위로 표현하여 pairwise 유사도를 산출 - 유사도 함수는 운영 목적에 따라 코사인 유사도(임베딩), 텍스트 기반 유사도(Self-BLEU 등), 또는 구조 기반 비교(단계 매칭/그래프 매칭 등)를 선택하여 적용 - 산출된 평균 유사도를 기반으로 점수를 계산하고 문제별 점수의 평균으로 데이터셋 단위 결과를 보고

[표 IV-51] Logical Diversity Index (LDI) 정의 및 검사방법

5.3.2.4 Convergence Rate (CR)

지표명	Convergence Rate (CR)
설명	- 동일 문제에 대해 독립 샘플링을 반복 수행할 때 샘플 수 N 증가에 따른 다수결(majority vote) 집계 답변의 정답률 변화를 측정하는 지표 - CoT-SC와 같이 다회 샘플링 후 가장 일관된 답을 선택하는 방식에서 집계 성능의 안정화 수준 및 샘플 효율을 점검하기 위한 지표로 활용
측정산식	$CR@N$ = Accuracy of majority vote using N samples N 회 생성 결과의 최종 답을 집계하여 정답 여부를 판정하고 데이터셋 평균 정답률로 보고 (선택: 수렴속도 지표) $N\pi$ 기반 수렴 속도 점수화 $N\alpha$: $CR@N$이 사전 정의한 목표 수준 α에 도달하는데 필요한 최소 샘플 수 (예시) Convergence Rate Score = $100 \times (1 - (N\alpha / N_{\max}))$ α(목표수준)와 $N_{\max}$(최대 샘플 수)는 과제/비용 제약을 고려해 사전 정의
검사방법	- 동일 문제에 대해 샘플 수를 단계적으로 증가시키며(예: 1, 3, 5, 10, 20 ..., $N_{\max}$) 독립 샘플링을 수행하고 각 N에서 다수결 답변을 산출 - 각 N에 대해 $CR@N$을 기록하여 수렴 추이를 확인하고 필요 시 수렴 곡선 또는 $N\alpha$(목표도달 샘플 수)를 함께 보고함 - 답변 정규화(표기 통일, 동치식 처리 등) 규칙을 사전 정의하여 다수결 집계가 일관되게 수행되도록 함 - CR은 샘플링 기반 집계 안정성/정확도 추이를 나타내며 단계별 추론 타당성을 직접 측정하지 않으므로 관련 지표와 병행하여 해석

[표 IV-52] Convergence Rate (CR) 정의 및 검사방법

5.3.2.5 Majority Vote Concentration (MVC)

지표명	Majority Vote Concentration (MVC)
설명	- 동일 문제에 대해 다회 샘플링으로 생성된 최종 답변들 중 최빈 답변이 차지하는 비율(집중도/합의 수준)을 측정하는 지표 - CoT-SC와 같이 다회 샘플링 후 최빈 답을 선택하는 운영에서 집계 결과의 안정성(합의도) 및 불확실성 신호를 점검하기 위한 보조 지표로 활용
측정산식	$MVC = (\text{최빈 답변 출현 횟수} / \text{전체 샘플 수 } N) \times 100$
검사방법	- 동일 문제에 대해 독립 샘플링을 N회 수행 (예:10~40회)하여 최종 답변을 수집 - 답변 정규화 규칙(표기 통일, 단위/형식 통일, 동치 표현 처리 등)을 사전 정의한 후 최빈 답변의 출현 비율을 MVC로 산출 - 최빈 답변이 동일 빈도로 복수 존재하는 동률(tie)여부를 함께 기록하여 해석 일관성 확보 - MVC는 샘플링 결과의 합의 수준(집중도)을 나타내며 정답 여부를 직접 보장하지 않으므로 CR@N 등 정확도 지표와 병행하여 해석

[표 IV-53] Majority Vote Confidence (MVC) 정의 및 검사방법

5.3.2.6 Multi-Path Agreement Score (MAS)

지표명	Multi-Path Agreement Score (MAS)
설명	- 동일 문제를 서로 상이한 경로(프롬프트/추론 전략/디코딩 설정)로 수행했을 때, 경로별 최종 답변이 동일 값으로 합의되는 정도를 측정하는 지표 - Self-Consistency와 같이 복수 산출 결과를 집계하는 방식에서 경로 간 답변 안정성을 점검하기 위한 보조 지표로 활용
측정산식	$MAS(\%) = (\text{최빈 최종답변에 동의한 경로 수} / \text{전체 경로 수 } K) \times 100$ - K: 사전에 정의한 경로의 수 (예: 3~5) - 경로별로 여러 번 샘플링을 수행하는 경우 - 경로 j에서 N회 샘플링 후 경로 대표답(예: 경로 내 다수결)을 먼저 산출한 뒤 경로 대표답들 간 MAS를 계산('경로 내 수렴'과 '경로 간 합의'를 분리)
검사방법	- 동일 문제에 대해 K개의 서로 다른 경로를 사전 정의하고 각 경로에서 최종 답변을 산출 - 답변 비교를 위해 정규화 규칙(표기/단위/등치 표현 처리 등)을 사전 정의한 후, 최빈 답에 동의한 경로 비율로 MAS를 계산 - 동률(tie)발생 여부를 별도 기록하여 해석의 일관성을 확보 - MAS는 경로 간 합의 수준을 나타내며 정답 여부를 직접 보장하지 않으므로 CR@N 등 정확도 지표와 병행하여 해석

[표 IV-54] Multi-Path Agreement Score (MAS) 정의 및 검사방법

5.3.2.7 Expected Calibration Error (ECE)

지표명	Expected Calibration Error(ECE)
설명	- 모델이 산출한 신뢰도와 실제 정답률 간의 차이를 구간별로 계산하여 예측 신뢰도의 보정 정도(calibration)를 측정하는 지표 - CoT-SC와 같이 복수 경로를 집계하는 운영에서는 경로별 가중치 또는 집계 기반 신뢰도를 예측 신뢰도 값으로 정의하여 적용할 수 있음
측정산식	$ECE = \sum_{m=1}^M \frac{ B_m }{N} \cdot acc(B_m) - conf(B_m)$ M: 구간 수 (사전정의하며 평균 10~15로 설정) B_m: 예측 신뢰도가 m번째 구간에 속하는 샘플 집합 $acc(B_m)$: 해당 구간의 실제 정확도 $conf(B_m)$: 해당 구간의 평균 신뢰도
검사방법	- GT(ground truth)값이 포함된 평가데이터를 대상으로 각 샘플의 예측 신뢰도를 산출 예) 가중치 기반 CoT-SC 집계 시 최종 선택 답안의 $conf(a^*)$를 예측신뢰도로 정의 - 예측 신뢰도를 M개 구간으로 분할하고 각 구간에서 평균 신뢰도와 실제 정확도의 차이를 계산하여 ECE를 산출

[표 IV-55] Expected Calibration Error(ECE) 정의 및 검사방법

5.3.2.8 Weight-Outcome Correlation (WOC)

지표명	Weight-Outcome Correlation (WOC)
설명	- 모델이 산출한 예측 신뢰도/가중치와 실제 정답 여부간의 선형적 연관성을 피어슨 상관계수로 측정하는 지표 - WOC 값이 클수록 높은 신뢰도(가중치)가 정답과 함께 증가하는 경향(정렬성)이 나타남 (보정(calibration)지표와는 구분하여 해석)
측정산식	$WOC = \rho(conf, correctness) = \frac{Cov(conf, correctness)}{\sigma_{conf}\sigma_{correctness}}$ - 범위: [-1,1] 1에 가까울수록 양의 선형 연관이 크며 0에 가까우면 선형 연관이 약함 - 음수이면 높은 신뢰도가 오답과 동반되는 경향을 의미
검사방법	- 정답(GT)값이 확보된 평가 데이터에 대해 각 샘플별로 예측 신뢰도를 산출 - 각 샘플의 예측신뢰도 목록과 정답 여부(1/0) 목록을 쌍으로 구성하여 피어슨 상관계수를 계산 - 신뢰도 값이 0~100으로 출력되는 경우, 계산 전 0~1로 정규화하여 적용할 수 있음

[표 IV-56] Weight-Outcome Correlation (WOC)의 의미 및 검사방법

5.3.3 ToT

5.3.3.1 Step Factual Accuracy (SFA)

지표명	Step Factual Accuracy (SFA)
설명	- 다단계 추론 또는 트리탐색(ToT)에서 각 단계 (또는 노드)에 포함된 사실, 진술, 수치, 계산 결과가 객관적 근거 또는 검증 절차에 의해 정확한 것으로 판정되는 비율을 측정하는 지표 - 중간 단계에서의 사실 불일치 또는 근거 불충분 요소를 단계(노드) 단위로 식별하기 위한 지표로 활용
측정산식	$SFA(\%) = (\text{사실 정확 단계 수} / \text{전체 단계 수}) \times 100$ (가중산식, 선택) 단계 I에 포함된 사실 진술 수 또는 중요도에 따라 가중치 부여할 수 있음 $SFA(\%) = (\sum \text{Correct}_i \times \text{Weight}_i) / (\sum \text{Weight}_i) \times 100$ - Weight_i: 단계 i의 사실 진술 (또는 사전 정의된 중요도)
검사방법	- 추론 과정을 단계(또는 ToT 노드) 단위로 분해한 후 각 단계에 포함된 사실/계산 항목을 정확/오류/판정불가(근거 불충분)로 판정 - 계산/수식 전개 단계는 자동 검증(예: 수치 계산 스크립트, CAS 도구 등)을 병행하여 정확성을 확인할 수 있음 - 최종 산출 시 판정불가의 처리 규칙을 사전정의하여 일관되게 적용 - ToT 방식에서는 노드(중간 해)의 유효성이 후속 탐색·선택에 영향을 주므로 SFA를 통해 노드 단위 사실/계산 정확성을 점검하고 임계값 미달 노드는 확장/선택 대상에서 제외하는 기준으로 활용할 수 있음

[표 IV-58] Step Factual Accuracy (SFA) 정의 및 검사방법

5.3.3.2 Node Coherence / Consistency Score (NCS)

지표명	Node Coherence / Consistency Score (NCS)
설명	- ToT 구조에서 각 노드가 부모노드로부터 논리적으로 도출 가능하며, 동시에 자식 노드들과 모순되지 않는지 등 노드 간 연결의 정합성을 측정하는 지표 - 본 지표는 노드 내용의 사실 정확도와는 구분되며 추론 구조(트리/그래프)의 일관성 품질을 점검하기 위한 지표로 활용
측정산식	$NCS(\%) = (\text{정합 노드 수} / \text{전체 노드 수}) \times 100$ - 정합 노드: 사전 정의된 기준에 따라 부모-자식 관계에서 모순/단절이 없다고 판정된 노드 (가중산식, 선택) 노드 깊이 또는 중요도에 따라 가중치를 부여할 수 있음 $NCS(\%) = (\sum \text{Coherence}_i \times \text{Weight}_i) / (\sum \text{Weight}_i) \times 100$ Coherence_i: 노드 i의 정합성 점수(이진 0/1 또는 부분 점수 0~1) Weight_i: 깊이(Depth) 또는 사전 정의된 중요도 가중치
검사방법	- 트리/그래프의 노드를 순화하면서, 각 노드에 대해 다음을 점검 - 부모 노드로부터의 도출 타당성(부모 내용과 논리적으로 연결되는지) - 자식 노드와의 정합성(자식이 부모내용과 모순되지 않는지, 논리적 단절이 없는지) - 평가 주체는 운영 정책에 따라 인간 평가자 또는 사전검증된 LLM Judge로 정의하며 정합성 판정기준(모순/단절/비약 등)은 사전 정의된 루브릭에 따라 적용 - 모순 또는 단절이 확인되면 해당 노드는 비정합으로 판정(또는 부분 점수 부여)하고, 전체 노드 대비 비율로 NCS를 산출 ※NCS는 노드 간 연결의 일관성을 평가하는 지표이며, 노드 내용의 사실 정확성 평가는 SFA 등 별도 지표와 병행하여 평가

[표 IV-59] Node Coherence / Consistency Score (NCS) 정의 및 검사방법

5.3.3.3 Node Expansion Efficiency (NEE)

지표명	Node Expansion Efficiency (NEE)노드 확장 효율성
설명	- 트리/그래프 탐색 기반 추론(ToT)에서 부모 노드를 확장하여 생성된 자식 노드 중 사전 정의한 기준에 따라 유용(목표 접근에 기여)으로 판정된 노드의 비율을 산출하는 지표 - 본 지표는 탐색 과정에서 불필요한 분기 생성 정도 및 계산 자원(토큰/시간) 사용 효율을 점검하기 위한 운영 지표로 활용
측정산식	$NEE(\%) = (\text{유용 자식 노드 수} / \text{전체 생성 자식 노드 수}) \times 100$ (선택) NEE@K: 각 부모 노드별로 상위 K개 자식(가치/검증 점수 기준)을 대상으로 유용 비율을 산출한 뒤 평균을 보고 - 유용(useful) 판정 기준은 아래 중 하나(또는 조합)하여 선정 - 기준A: 자식 노드가 검증/가치 점수 임계값 이상 (예:value estimator, PRM, 자체평가 점수 등) - 기준B: 해당 자식 노드를 포함한 후속탐색(롤아웃/후속 확장)에서 정답 도달가능성 확인 - 기준C: 부모 대비 논리적 단절/모순이 없고 목표에 더 근접한 중간 상태로 판단
검사방법	- 탐색 로그에서 부모-자식 확장 결과를 수집하고 각 자식 노드에 대해 '유용/비유용' 판정을 부여 - 판정 주체: 인간 평가자 또는 사전 검증된 LLM Judge - 자동 판정: value estimator/검증기 점수 또는 후속 성공 여부를 활용 - 전체(또는 표본) 노드에 대해 NEE를 계산하고 토큰/시간 예산과 함께 보고하여 효율성 해석

[표 IV-60] Node Expansion Efficiency(NEE) 정의 및 검사방법

5.3.3.4 Branching Factor Control (BFC)

지표명	Branching Factor Control (BFC)
설명	- Tree-of-Thought, MCTS 등 탐색 기반 추론에서 각 노드 확장 시 생성되는 자식 노드 수(분기 수)가 사전 정의된 목표 분기 수(또는 목표 범위)와 얼마나 부합하는지를 평가하는 지표 - 본 지표는 탐색 과정의 연산 예산(노드 수/토큰/시간) 관리 및 불필요 분기 억제 관점에서 활용하며 탐색 트리 크기 제어가 successor 수(b) 등의 제약으로 가능하다는 점에 근거하여 지표로 설정 할 수 있음
측정산식	$BFC(\%) = (\text{목표 범위에 포함되는 노드 수} / \text{전체 평가 노드 수}) \times 100$ - 목표 범위는 난이도 구간(또는 예산 정책)별로 사전 정의
검사방법	- 탐색 로그에서 각 확장 단계(부모 노드 별) 생성 자식 노드 수(분기 수)를 기록 - 문제 난이도(사전 라벨 또는 내부 기준) 및 탐색 예산 정책에 따라 노드별 목표 분기수/목표 범위를 매핑하고 위 산식으로 BFC를 산출 - 고정 폭(b)을 사용하는 구현이 일반적이거나 고정 width 간의 한계를 지적하고 노드별로 '더 넓게/더 깊게'를 적응적으로 결정하는 접근도 보고되므로 방식에 따라 목표 분기수 자체를 상향 의존적으로 정의할 수 있음 - BFC는 탐색 과정의 분기 제어 적정성을 평가하는 지표로 최종 정답 정확도/노드 유효성(SFA 등)과는 구분하여 병행 지표로 해석

[표 IV-61] Branching Factor Control (BFC) 정의 및 검사방법

5.3.3.5 Search Cost per Solution (SCS)

지표명	Search Cost per Solution (SCS)
설명	- 탐색 기반 추론(ToT, MCTS 등) 수행 시 정답(해결) 1건을 도출하는 데 소요된 연산 자원 (토큰 수, 확장 노드 수, 호출 수, 시간/비용 등)을 정답 건수로 정규화한 지표 - 동일(또는 유사) 정확도 조건에서 비용대비 효율을 비교하기 위한 운영 지표로 활용 (예:solved 1 건당 평균 비용)
측정산식	- 토큰기준 - SCS(토큰) = 탐색 과정에서 생성된 총 토큰 수 / 정답(해결) 건수 - 노드기준 - SCS(노드) = 탐색 과정에서 확장된 총 노드 수 / 정답(해결) 건수 - 비용/시간 기준(선택) - SCS(비용 또는 시간) = 총 추론 (비용 또는 시간) / 정답(해결) 건수
검사방법	- 탐색 수행 로그에서 총 사용량을 집계(예: 총 토큰, 총 확장 노드, 총 호출 수, 총 시간/비용) - 동일 실행(또는 동일 조건의 배치 평가)에서 정답(해결) 건수를 집계한 뒤 위 산식으로 SCS를 산출 - 정답 건수 = 0 인 경우 SCS는 정의되지 않으므로 처리 규칙을 사전정의(N/A 등) - SCS는 탐색 기반 추론의 효율(비용 대비 성과)을 나타내며 정확도(정답률) 지표와 병행하여 비용-성능 균형을 평가

[표 IV-62] Search Cost per Solution (SCS) 정의 및 검사방법

5.3.3.6 Strategy Distribution Entropy (SDE)

지표명	Strategy Distribution Entropy (SDE)
설명	- 동일 문제에 대해 복수의 추론 경로(또는 ToT 탐색 경로)를 생성했을 때, 각 경로가 속하는 추론 전략 범주(사전 정의)의 분포가 얼마나 균등한지를 Shannon Entropy로 산출하는 지표 - 본 지표는 탐색 기반 추론에서 전략적 탐색 다양성을 점검하기 위한 보조 지표로 활용하며 성능(정답률 등) 지표와 병행하여 활용
측정산식	- 기본 Entropy $SDE = \sum (p_i \times \log_2 p_i)$ p_i: i번째 전략 범주의 출현 비율, $i=1, \dots, k$ - 정규화 점수 (0~100, 선택) $SDE\ Score = (SDE \div \log_2(k)) \times 100$ k: 전략 범주 수
검사방법	- 동일 문제에 대해 N회(예: 10~50회) 독립 생성 또는 ToT 탐색으로 복수 경로를 확보한 뒤, 각 경로를 사전 정의된 전략 범주(예: 6~12개)로 분류 - 인간 평가자 분류, 기준이 고정된 LLM Judge 분류, 임베딩 기반 군집화 후 범주 매핑 등 - 범주별 출현 비율을 계산하여 SDE를 산출하고 데이터셋 단위로 평균/분포(평균, 중앙값, 분위)를 보고 - 전략 범주 정의 및 분류 기준, 판정 불가 처리 규칙을 사전 문서화하여 일관되게 적용 필요

[표 IV-63] Strategy Distribution Entropy (SDE) 정의 및 검사방법

5.3.3.7 Path Strategy Diversity Score (PSDS)

지표명	Path Strategy Diversity Score (PSDS)
설명	- 동일 문제에 대해 생성된 복수의 추론 경로(ToT 브랜치, MCTS 경로 등)가 사전 정의된 '추론 전략 범주' 관점에서 얼마나 다양한 전략을 포함하는지 정량화하는 지표 - 본 지표는 탐색 기반 추론에서 전략적 탐색 폭(커버리지)과 분포의 균등성(편향 여부)을 점검하기 위한 보조지표로 활용하며 정답률/비용 지표와 병행하여 해석
측정산식	- PSDS-Coverage (0~100점) - PSDS-Coverage = (관측된 고유 전략 범주 수 / 전체 전략 범주 수 k) × 100 - PSDS-Entropy (0~100점) $H = - \sum (p_i \times \log_2 p_i)$ - PSDS-Entropy = $(H \div \log_2(k)) \times 100$ (p_i: i번째 전략 범주 비율, $i=1 \cdots k$) - PSDS (0~100점) - PSDS = $w \times \text{PSDS-Coverage} + (1-w) \times \text{PSDS-Entropy}$
검사방법	- 각 경로를 사전 정의된 전략 범주(예: 6~12개)로 분류 - 분류 기준과 예시를 문서화하고 다중전략이 혼재하는 경우 처리 규칙을 사전 정의 - 범주별 출현 비율을 계산하여 PSDS-Coverage/PSDS-Entropy를 산출하고 데이터 셋 단위로 평균 및 분포를 보고

[표 IV-64] Search Cost per Solution (SCS)의 정의 및 검사방법

5.3.3.8 Heuristic Utilization Ratio (HUR)

지표명	Heuristic Utilization Ratio (HUR)
설명	- 탐색기반 추론(ToT)에서 생성된 추론 경로(브랜치/경로) 들이 사전 정의된 휴리스틱 범주를 얼마나 폭넓게 활용하는지 정량화한 지표 - 본 지표는 전략 다양성을 점검하기 위한 보조 지표로 활용하며 정답률, 비용지표와 병행하여 해석
측정산식	- HUR-Coverage(0~100) - HUR = (관측된 고유 휴리스틱 수 / 사전 정의된 휴리스틱 총수(H)) × 100 - 문제당 평균 활용의 경우 (0~100) - HUR = (문제당 평균 고유 휴리스틱 수 / 기준값(예: H_max 또는 목표범위)) × 100
검사방법	- 동일 문제에 대해 N회(예:10~50회) 경로를 생성하거나 탐색 로그에서 경로를 수집 - 각 경로를 사전 정의된 휴리스틱 목록(예: 20~50개)에 따라 태깅 - 휴리스틱별 출현 여부/비율을 집계하여 HUR을 산출하고 문제 단위 및 데이터셋 단위로 정리

[표 IV-65] Heuristic Utilization Ratio (HUR) 정의 및 검사방법

5.3.4 ReAct

5.3.4.1 Loop Count to Solution (LCS)

지표명	Loop Count to Solution (LCS)
설명	- Self-Refine, Reflexion, STaR, ReReading, iterative reasoning 등 반복형 에이전트가 정답에 도달하기까지 실제로 수행한 루프(iteration)·수정 횟수를 측정한 지표 - 값이 낮을수록 더 빠르고 효율적으로 수렴
측정산식	- 기본 산식 - LCS = Average number of loops required to reach correct answer (정답 도달 시의 루프 수 평균, 실패 시 max_loop 값 사용) - 실제 리더보드 보고 형태) - LCS@Correct = 평균 2.7 loops (정답 난 문제만 평균) - LCS@All = 전체 문제 평균 4.1 loops (실패 포함) - LCS ≤ k = k번 이하로 해결한 문제 비율 (예: LCS ≤ 3 = 78%)
검사방법	- 에이전트가 “생각 → 답변 → 검증 → 피드백 → 재시도” 과정을 반복할 때마다 루프 카운터를 1씩 증가 - 최종적으로 정답이 나오면 그때까지 누적된 루프 수를 기록 - 정답에 도달하지 못하면 최대 허용 루프 수(예: 10~20)로 제한

[표 IV-69] Loop Count to Solution (LCS) 정의 및 검사방법

5.3.4.2 Step Efficiency Ratio (SER)

지표명	Step Efficiency Ratio (SER)
설명	모델이 실제로 사용한 추론 단계 수를 인간 전문가(또는 ground-truth 최소 단계 수)로 나눈 비율의 역수로, 값이 1에 가까울수록 인간 수준으로 가장 적은 단계만을 사용해 정답에 도달했다는 뜻
측정산식	- 기본산식 $SER = (Optimal\ Steps / Actual\ Steps) \times 100$ (정답인 경우만 계산, 오답이면 SER = 0) - 정규화된 최종 점수 $SER = \min(100, 100 \times Optimal_Steps / Actual_Steps)$
검사방법	- 각 문제마다 인간 전문가(IMO 메달리스트, 교수 등)가 작성한 “최소 필수 단계 수”(optimal steps)를 미리 정의 - 모델의 CoT를 단계 단위로 분해해 실제 사용한 단계 수를 세고 비교 - 오답인 경우는 0 또는 매우 큰 패널티를 부여한다.

[표 IV-70] Step Efficiency Ratio (SER) 정의 및 검사 방법

5.3.4.3 Decision Latency per Loop (DLL)

지표명	Decision Latency per Loop (DLL) 루프당 결정 지연 시간
설명	- 반복형 에이전트(Self-Refine, Reflexion, ReAct 등)가 한 번의 루프(생각 → 행동 → 관찰 → 다음 생각)에서 결정을 내리는 데 걸린 평균 시간(또는 토큰 생성 시간)을 측정한 지표 - 값이 낮을수록 실시간 사용에 적합한 빠른 에이전트임을 나타냄
측정산식	- 시간 기반 (초) $DLL = (\text{Total Decision Time across all loops}) / \text{Total Number of Loops}$ - 단위: 초/루프 (seconds per loop) - 토큰 기반 (실제 리더보드에서 더 자주 사용) $DLL_tokens = (\text{Total Generated Tokens in Thinking Steps}) / \text{Total Number of Loops}$ - 단위: 토큰/루프
검사방법	- 각 루프가 시작해서 끝날 때까지의 실제 경과 시간(초) 또는 생성된 토큰 수를 로그로 기록 - 전체 루프 수로 나누어 평균을 구하며, 외부 도구 호출 시간은 제외하거나 별도 표시

[표 IV-71] Decision Latency per Loop (DLL) 정의 및 검사방법

5.3.4.4 Thought-Action Consistency Score (TACS)

지표명	Thought-Action Consistency Score (TACS) 사고-행동 일관성 점수
설명	- 에이전트가 “생각(Thought)” 단계에서 계획한 내용과 실제로 실행한 “행동(Action)”이 얼마나 정확히 일치하는지를 측정하는 지표 - 생각만 하고 행동을 안 하거나, 생각과 전혀 다른 행동을 하면 크게 감점
측정산식	- 기본산식 $TACS = (\text{Number of Consistent Thought-Action Pairs} / \text{Total Number of Thought-Action Pairs}) \times 100$ - 가중치 적용 정밀산식 $TACS = [2 \times \text{Fully_Consistent} + 1 \times \text{Partially_Consistent} + 0 \times \text{Inconsistent}] / (2 \times \text{Total Pairs}) \times 100$
검사방법	- 모든 Thought → Action 쌍을 추출한 뒤, 인간 평가자 또는 고성능 LLM Judge가 - Thought에서 명시적으로 언급한 행동을 Action이 100% 따랐는가 - 불필요한 추가 행동이 있었는가 - Thought를 완전히 무시했는가 를 판단 - ReAct, Toolformer, AgentTuning 형식 로그에서 자동 파싱 가능.

[표 IV-72] Thought-Action Consistency Score (TACS) 정의 및 검사방법

5.3.4.5 Justification Quality Score (JQS)

지표명	Justification Quality Score (JQS) 근거 품질 점수
설명	- 모델이 제시한 최종 답변에 대해 제공한 설명·근거·CoT가 얼마나 명확하고, 논리적으로 완결적이며, 설득력이 있는지를 종합 평가한 점수 - 단순히 정답 여부와는 별개로 “왜 이 답이 맞는지”를 얼마나 잘 설득하는지를 측정
측정산식	- 기본산식(초) $JQS = (S_1 + S_2 + \dots + S_n) / n$ (S_i: i번째 평가자의 0~100점, $n=3\sim5$) - 실제 리더보드 보고 형태 - JQS@10 scale → 평균 후 ×10 해서 0~100점으로 변환
검사방법	- 인간 전문가(수학·과학 교수, 올림피아드 심사위원 등) 또는 고성능 LLM Judge가 미리 정의된 0~10점 또는 0~100점 루브릭(명확성·완결성·논리적 연결·불필요 중복 여부·설득력)을 기준으로 전체 근거를 한 번에 읽고 단일 점수로 채점 - 보통 3~5명 평균을 최종 JQS로 사용

[표 IV-73] Justification Quality Score (JQS) 정의 및 검사방법

5.3.4.6 Action Rationality Index (ARI)

지표명	Action Rationality Index (ARI) 행동 합리성 지수
설명	- AI 에이전트가 각 행동(도구 호출, 결정 등)을 목표 달성과 위험 최소화 측면에서 얼마나 논리적·최적화된 선택을 하는지를 0~100점으로 측정한 지표 - 비합리적 행동(예: 불필요한 위험 감수)이 적을수록 높은 점수를 받음
측정산식	- 기본산식 $ARI = (\text{Number of Rational Actions} / \text{Total Number of Actions}) \times 100$ - 가중치 적용 버전 $ARI = [3 \times \text{Fully_Rational} + 2 \times \text{Partially_Rational} + 0 \times \text{Irrational}] / (3 \times \text{Total Actions}) \times 100$
검사방법	- 인간 평가자 또는 LLM Judge가 에이전트의 전체 행동 로그를 검토하여, 각 행동의 목적·위험·기대 유틸리티를 분석하고 “합리적 / 부분 합리적 / 비합리적”으로 분류 - 행동이 목표에 기여하는 정도와 대안 행동과의 비교를 통해 점수를 부여

[표 IV-74] Action Rationality Index (ARI) 정의 및 검사방법

5.3.5 TAR

5.3.5.1 Evidence Support Score (ESS)

지표명	Evidence Support Score (ESS)증거 지원도 점수
설명	- 모델이 제시한 주장·답변·결론 각각이 제공된 근거 문서(또는 외부 검색 결과, 도구 출력 등)에 얼마나 명확하고 충분히 뒷받침되는지를 측정한 지표 - 환각이나 근거 없는 주장 비율이 낮을수록 100점에 가까움
측정산식	- 기본산식(초) $ESS = (\text{Number of Fully Supported Claims} / \text{Total Number of Claims}) \times 100$ - 가중치 적용 버전 $ESS = (2 \times \text{Fully_Supported} + 1 \times \text{Partially_Supported}) / (2 \times \text{Total Claims}) \times 100$
검사방법	- 답변 속 모든 주장(claim)을 문장 단위로 추출한 뒤, 인간 평가자 또는 LLM Judge가 각 주장이 - Fully Supported (근거에 명시적으로 존재) - Partially Supported (간접적으로 유추 가능) - Not Supported (근거에 없거나 모순)으로 분류 - RAG, LongFact, Tool-use 로그 등에서 자동으로 근거와 매핑해 평가

[표 IV-75] Evidence Support Score (ESS) 정의 및 검사방법

5.3.5.2 Attribution Accuracy (AA)

지표명	Attribution Accuracy (AA)
설명	- 모델이 제시한 사실·인용·정보가 실제 근거 문서(또는 검색 결과, 도구 출력)의 어느 위치·문장에 정확히 존재하는지를 측정한 지표 “해당 문장에서 나온다”고 한 인용이 정말 해당하는 문장에 있는지를 100% 검증
측정산식	- 기본산식 $ARI = (\text{Number of Rational Actions} / \text{Total Number of Actions}) \times 100$ - 가중치 적용 버전 $ARI = [3 \times \text{Fully_Rational} + 2 \times \text{Partially_Rational} + 0 \times \text{Irrational}] / (3 \times \text{Total Actions}) \times 100$
검사방법	- 모델이 답변에 포함시킨 모든 인용·참조·귀인(attribution)을 추출한 뒤, 인간 평가자 또는 자동 스크립트가 해당 인용이 - 정확한 위치·문장에 존재하는가 (Exact Match) - 비슷하지만 약간 다르거나 요약된 경우 (Paraphrased) - 완전히 틀리거나 없는 경우 (Hallucinated) 로 분류 - RAG 시스템에서는 citation ID나 문장 번호까지 정확히 맞춰야 함

[표 IV-76] Attribution Accuracy (AA) 정의 및 검사방법

5.3.5.3 Top-K Retrieval Accuracy (R@K)

지표명	Top-K Retrieval Accuracy (R@K) 상위 K 검색 정확도
설명	- 검색·RAG 시스템이 쿼리에 대해 반환한 상위 K개 문서 중 실제로 정답·근거가 포함된 문서가 하나라도 있는지를 측정한 지표 - 값이 높을수록 검색 성능이 우수
측정산식	- 기본산식 $R@K = (\text{Number of Queries where at least one relevant document is in Top-K} / \text{Total Number of Queries}) \times 100$ - 실제 리더보드 - GAIA Level-4: $R@5 = 96.3\%$, $R@100 = 99.7\%$ - LongRAG-100K: $R@10 = 94.8\%$ - FreshRAG: $R@3 = 91.2\%$
검사방법	- 각 질문에 대해 ground-truth 정답 문서(또는 정답을 포함한 최소 문서 세트)를 미리 정의 - 시스템이 반환한 상위 K개 문서 리스트를 보고, 그 안에 ground-truth 문서가 포함되어 있는지 여부를 1/0으로 판단

[표 IV-77] Top-K Retrieval Accuracy (R@K) 정의 및 검사방법

5.3.5.4 Mean Reciprocal Rank (MRR)

지표명	Mean Reciprocal Rank (MRR) 평균 역순위 (또는 평균 역수 랭킹)
설명	- 검색·RAG 시스템이 정답 문서를 몇 번째 순위에 배치했는지를 전체 쿼리에 대해 평균화한 지표 - 값이 1에 가까울수록 거의 항상 1위에 정답을 배치한다는 뜻 - R@K와 함께 가장 중요한 검색 성능 지표
측정산식	$MRR = (1 / Q) \times \sum_{i=1}^Q (1 / \text{rank}_i)$ - Q: 전체 쿼리 수 - rank_i: i번째 쿼리에서 정답 문서가 처음 등장한 순위 - 정답이 없으면 $1/\text{rank}_i = 0$
검사방법	- 각 쿼리마다 시스템이 반환한 순위 리스트에서 최초로 등장하는 정답 문서의 순위(rank)를 찾음 - 정답이 아예 없으면 해당 쿼리는 0으로 처리

[표 IV-78] Mean Reciprocal Rank (MRR) 정의 및 검사방법

5.3.5.5 Normalized Discounted Cumulative Gain (nDCG)

지표명	Normalized Discounted Cumulative Gain (nDCG)정규화 할인 누적 이득
설명	- 검색·RAG 시스템이 반환한 상위 결과 리스트 전체의 순위 품질을 0~1(또는 0~100점)으로 측정한 지표 - 정답 문서가 높을수록·여러 개일수록·빠르게 나올수록 1에 가까워짐 - MRR보다 훨씬 정밀하게 전체 랭킹 품질을 평가 - 현재 BEIR, MTEB, GAIA, RGB, LongRAG, 모든 학술·산업 검색·RAG 리더보드에서 MRR과 함께 공동 1위인 절대적 표준 지표이며, nDCG@100이 0.95를 넘어야 “최상위 실용 수준”으로 인정
측정산식	- 기본산식 $DCG@K = \sum_{i=1}^K (rel_i / \log_2(i+1))$ - IDCG@K = 이상적인 순위로 계산한 DCG $nDCG@K = DCG@K / IDCG@K$
검사방법	- 각 쿼리마다 모든 문서에 대해 0~3점의 관련도 점수(ground-truth relevance grade)를 미리 부여 - 시스템이 반환한 순위 리스트를 가지고 DCG를 계산한 뒤, 이상적인 순위(완벽 정렬)로 얻을 수 있는 IDCG로 나누어 정규화

[표 IV-79] Normalized Discounted Cumulative Gain (nDCG) 정의 및 검사방법

5.3.5.6 Δ Accuracy (Accuracy Gain)

지표명	Δ Accuracy (Accuracy Gain) 정확도 증가량 (또는 정확도 향상)
설명	- 검색·RAG 시스템이 정답 문서를 몇 번째 순위에 배치했는지를 전체 쿼리에 대해 평균화한 지표 - 값이 1에 가까울수록 거의 항상 1위에 정답을 배치한다는 뜻 - R@K와 함께 가장 중요한 검색 성능 지표
측정산식	- 기본 산식 $\Delta \text{Accuracy} = \text{Acc_improved} - \text{Acc_baseline}$ (Acc_improved: 개선된 방법의 정확도(%), Acc_baseline: 기본 방법의 정확도(%))
검사방법	- 동일한 벤치마크 데이터셋(예: GSM8K, MATH)에서 베이스라인 모델의 정확도를 먼저 측정 - 개선된 모델이나 기법을 적용한 후 정확도를 다시 계산하고, 두 값을 뺀 차이를 Δ Accuracy로 기록

[표 IV-80] Δ Accuracy (Accuracy Gain) 정의 및 검사방법

5.3.5.7 Tool Contribution Score (TCS)

지표명	Tool Contribution Score (TCS) 도구 기여도 점수
설명	- AI 에이전트나 LLM이 외부 도구(검색, 계산기, API 등)를 사용한 경우, 그 도구 호출이 전체 작업 성공(정답 도달)에 얼마나 직접적으로 기여했는지를 0~100점으로 측정한 지표 - 도구 없이도 풀 수 있는 문제에서 불필요한 호출은 낮은 점수를 받음
측정산식	- 기본산식 $TCS = (Acc_with_Tools - Acc_without_Tools) / Acc_without_Tools \times 100$ (Acc_with_Tools: 도구 사용 시 정확도, Acc_without_Tools: 도구 미사용 시 정확도; 0~100점으로 캡 처리)
검사방법	- 인간 평가자 또는 LLM Judge가 에이전트의 전체 로그를 분석해 각 도구 호출의 입력·출력·후속 추론을 검토 - 도구 결과가 없었을 때와 비교해 성능 향상 정도(예: 정확도 상승, 오류 수정)를 판단하고, 기여 비율을 산출

[표 IV-81] Tool Contribution Score (TCS) 정의 및 검사방법

5.3.5.8 Effective Tool Call Rate (ETCR)

지표명	Effective Tool Call Rate (ETCR) 유효도구 호출 비율
설명	- 에이전트가 실제로 실행한 모든 도구 호출 중 정답 도달에 실질적으로 기여한 (필수적이거나 결정적 도움을 준) 호출의 비율을 측정한 지표 - 값이 높을수록 도구를 “불필요하게 많이” 부르지 않고 정확히 필요한 순간에만 부른다는 뜻
측정산식	- 기본산식 $TCS = (Acc_with_Tools - Acc_without_Tools) / Acc_without_Tools \times 100$ (Acc_with_Tools: 도구 사용 시 정확도, Acc_without_Tools: 도구 미사용 시 정확도; 0~100점으로 캡 처리)
검사방법	- 전체 로그에서 모든 도구 호출을 추출한 뒤, 인간 평가자 또는 LLM Judge가 각각의 호출을 - Essential (이 호출 없으면 틀렸을 것) - Helpful but not essential (도움은 됐지만 없어도 맞았을 것) - Useless / Harmful (불필요하거나 오히려 방해)로 분류 - Essential + Helpful만 유효로 인정한다.

[표 IV-82] Effective Tool Call Rate (ETCR) 정의 및 검사방법

5.4 유효성

- 추론형 AI 데이터를 학습하기 적합한 모델인지 평가할 때는, 단순 정답률이 아니라 추론 과정(reasoning process)을 얼마나 잘 이해·재현·활용·일반화하는지가 핵심

5.4.1 추론형 AI 데이터의 유효성 평가 범주와 지표

구분	TASK	측정지표	학습모델	정량목표 범주(예시)
출력정답 기반	수학·논리 추론 (Math & Logical Reasoning)	Exact Match (EM)	GPT-Style Decoder LLM	70% 이상
		Accuracy	DeepSeekMath, MathGLM	65% 이상
		GSM8K Score	Llama-3 Math, Qwen-Math	80% 이상
	지식 기반 질의응답 (Knowledge QA)	F1-Score	Fusion-in-Decoder, RAG	80% 이상
		EM	RAG-Llama, Atlas	70% 이상
		Precision/Recall	DPR-BERT	0.8 이상
	멀티턴 QA	ROUGE-L	T5/Flan-T5	0.7 이상
		BLEU	Llama-3, Mistral	0.25 이상
		EVA Score	OpenAI o1-mini 기반	0.75 이상
	지문 기반 추론 (Reading Comprehension)	QA-F1	Longformer, LLaMA2-Long	75% 이상
		EM	UL2 / Gemma-Long	60% 이상
과정기반	단계적 추론 (Step-by-step Reasoning)	Step Validity Score	CoT-SFT Llama, 1-preview	0.8 이상
		CoT Completeness	DeepSeek-R1, llama-Reasoner	85% 이상
	그래프 기반추론	Node Accuracy	GoT (Graph-of-Thought)	75% 이상
		Path Consistency	ToT(Llama-3), GraphRAG	70% 이상
	계산형 문제 해결	Step Error Rate	Qwen2.5-Math	0.2 이하
		CoT Robustness	GPT-NeoX CoT	0.75 이상
복잡추론 생성기반	멀티홉 추론 (Multi-hop QA)	HotpotQA	F1, FiD, LLaMA-3 RAG	70% 이상
		Multi-hop Consistency	ReAct-Llama	0.75 이상
	상식 추론	CSQA Accuracy	UnifiedQA, COMET	75% 이상
		SocialQA Score	T5-11B, Llama-3	70% 이상
	인과추론	CausalQA Accuracy	Causal-BERT, LaMA-Causal	60% 이상
	계획·전략 추론	Plan Validity	ReAct, Toolformer, Reflexion	0.75 이상
		Action Success Rate	LLM-Agent / o1-mini	70% 이상

	멀티모달 추론	Temporal Reasoning Accuracy	Video-LLaVA, Video-7B	65% 이상
		Event Order Consistency	CoT-Video Reasoner	80% 이상
	물리·상식 기반 공간 추론 (Physical Reasoning)	Physics Consistency Score	PHYS-CoT, Physical-LLaMA	0.7 이상

[표 IV-83] 추론 AI 데이터 Task 분야별 유효성 측정지표

부록2

품질지표 설정 가이드

1

의미정확성 품질지표 설정 가이드

1.1 개요

- 추론형 AI 데이터는 의미 정확성 지표를 선정하기 위해, 구축 목표 또는 임무에 적합한 학습 Task를 결정

구분	TASK	설명
출력정답 기반	수학·논리 추론 (Math & Logical Reasoning)	- 출력정답기반 수학논리 추론 태스크는 SM8K·MATH·AIME·GPQA 등에서 명확한 최종 정답을 갖는 문제를 단계별 추론으로 풀도록 하는 태스크 - 정답이 객관적이므로 Pass@1, CQS, 지표로 의미 정확성 (논리·사실·계산 오류)을 가장 정밀하게 측정 가능 - 현재 모든 추론형 AI의 핵심 성능 비교 및 의미 정확성 지표 선정의 표준 태스크
	지식 기반 질의응답 (Knowledge QA)	- 명확한 사실 정답을 갖는 질문에 대해 AI가 정확한 단일 답변을 내도록 하는 태스크로, HotpotQA·Natural Questions·TriviaQA·GAIA 등에서 표준 정답이 객관적이어서 자동 평가가 가능하며, 의미 정확성의 핵심 지표인 Faithfulness Score, Attribution Accuracy, Evidence Support Score를 가장 정밀하게 측정 - RAG·Tool-use·LongContext 모델의 환각 억제 및 충실도 성능을 비교하는 필수 태스크
	멀티턴 QA	- 대화 흐름 속에서 최종 정답(사실·숫자·선택지)이 명확히 존재하는 다중 턴 질문을 AI가 맥락을 유지하며 풀도록 하는 태스크 - MultiHop·CoQA·QuAC·GAIA Level-4 등이 대표적 - 정답이 객관적이면서도 맥락·추론·지식 결합을 동시에 요구해 Logical Coherence, Faithfulness, Step Consistency 등 의미 정확성 핵심 지표를 종합적으로 측정 - 현재 장기 추론·대화형 에이전트의 실질적 의미 정확성을 평가하는 최고 난도 표준 태스크
	지문 기반 추론 (Reading Comprehension)	- 주어진 지문에서 명확한 정답(숫자·날짜·사람·단어 등)을 추출하거나 추론하여 단일 정답으로 답변하도록 하는 태스크로, SQuAD·HotpotQA·DROP·RACE 등이 대표적 - 정답이 객관적이며 지문에 대한 충실도·추론 정확도를 동시에 요구해 Faithfulness, Attribution Accuracy, Evidence Support Score 등 의미 정확성 핵심 지표를 정밀하게 측정 - 현재 LongContext·RAG·추론형 모델의 지문 이해 및 의미 정확성을 평가하는 가장 기본적이고 필수적인 표준 태스크
과정기반	단계적 추론 (Step-by-step Reasoning)	과정기반 단계적 추론(Step-by-step Reasoning) 태스크는 최종 정답뿐만 아니라 각 추론 단계를 모두 ground-truth로 제공하거나 인간·LLM Judge가 검증하는 방식

IV

부록

		- PRM800K·MATH·Shepherd·GSM8K·Hard with Process 등 - Step Consistency, Local Validity, Fact Accuracy@Step, Argument Correctness Rate 등 의미 정확성의 가장 세밀한 지표들을 직접 측정할 수 있어 최종 정답만 보는 것보다 훨씬 정밀함 - 현재 추론형 AI의 과정 수준 의미 정확성을 평가하는 최고 권위 표준 태스크로 자리잡음
	그래프 기반 추론	• Tree-of-Thought, Graph-of-Thought, MCTS 등에서 생성된 전체 추론 그래프(노드·엣지·경로)를 ground-truth 또는 전문가 검증으로 평가하는 방식 - GraphRAG·GoT-Bench·PRM-Graph 등이 대표적 - Node Coherence, Local Validity, Path Reliability, Strategy Diversity 등 그래프 구조 수준의 의미 정확성 지표를 정밀하게 측정할 수 있어 선형 CoT보다 훨씬 풍부한 과정 품질을 드러냄 - 현재 최첨단 탐색형·다경로 추론 AI의 실질적 의미 정확성을 판단하는 최고 난도 표준 태스크
	계산형 문제 해결	• GSM8K·Hard, MATH, AIME 등에서 각 중간 계산식·단계별 수치·기호 조작까지 모두 ground-truth로 제공하거나 자동 실행 검증하는 방식 - Calculation Accuracy, Step Factual Accuracy, Local Validity 등 계산 오류와 논리 오류를 동시에 정밀하게 잡아내며, 의미 정확성의 가장 엄격한 지표를 제공 - 현재 추론형 AI의 계산 신뢰성과 과정 수준 의미 정확성을 판단하는 필수 표준 태스크
복잡추론 성능기반	멀티홉 추론 (Multi-hop QA)	• 복잡추론 성능기반 멀티홉 추론(Multi-hop QA) 태스크는 HotpotQA, MuSiQue, 2WikiMultihop 등에서 여러 문서·단계를 결합해야 도달 가능한 정답을 요구하는 태스크 - 단일 환각·논리 오류가 전체 정답을 무너뜨리기 때문에 Faithfulness, Step Consistency, Evidence Support Score 등 의미 정확성 지표를 극도로 민감하게 측정 - 현재 장거리·복합 추론형 AI의 실질적 의미 정확성을 판단하는 가장 엄격한 표준 태스크
	상식 추론	• CommonsenseQA, SocialQA, PIQA, HellaSwag, ARC-Challenge 등에서 일상적·사회적·물리적 상식을 다단계로 결합해 정답을 도출해야 하는 태스크 - 사실적 근거가 명시적이지 않아 환각·논리 비약이 쉽게 드러나며, Logical Coherence, Step Consistency, Faithfulness 등 의미 정확성 지표를 극도로 민감하게 측정 - 현재 추론형 AI의 실생활 적용 가능성과 인간 수준 의미 정확성을 판단하는 핵심 표준 태스크
	인과추론	• e-SNLI, CausalQA, CRASS, COPA 등에서 원인-결과 관계나 개입 효과를 다단계로 추론해 정답을 도출해야 하는 태스크 - 잘못된 인과 방향성·혼동 변수 무시가 즉시 오류로 드러나 Logical Coherence, Step Consistency, Faithfulness 등 의미 정확성

		지표를 극도로 엄격하게 측정 - 현재 추론형 AI의 진정한 인과 이해 능력과 의미 정확성을 판단하는 최고 난도 표준 태스크
	계획·전략 추론	• PlanBench, Blocksworld, ALFRED, ToolBench, GAIA Level-4 등에서 최적의 행동 순서·전략을 세워 목표를 달성해야 하는 태스크 - 단계별 의사결정이 누적으로 최종 실패로 이어지기 쉬워 Thought-Action Consistency, Local Validity, Step Efficiency 등 의미 정확성 지표를 극도로 민감하게 측정 - 현재 에이전트·장기 추론형 AI의 실질적 계획 능력과 의미 정확성을 판단하는 최고 난도 표준 태스크
	멀티모달 추론	• ScienceQA, MathVista, ChartQA, MMMU, LLaVA-Bench-Wild 등에서 이미지·표·그래프·도식 등 시각 자료와 텍스트를 결합해 다단계 추론으로 정답을 도출해야 하는 태스크 - 시각 정보의 오독·텍스트와의 불일치·환각이 즉시 드러나 Visual Faithfulness, Cross-modal Coherence, Step Consistency 등 의미 정확성 지표를 극도로 엄격하게 측정 - 현재 추론형 멀티모달 AI의 실생활 적용 가능성과 인간 수준 의미 정확성을 판단하는 최고 난도 표준 태스크 - 단일 모달보다 오류 전파가 훨씬 빠르고 복잡해, 의미 정확성 지표 선정 시 가장 민감하고 포괄적인 테스트베드로 활용
	물리·상식 기반 공간 추론 (Physical Reasoning)	• PIQA, PhysicalQA, OpenPI, ARC-Challenge(시각 버전), PhysWorld 등에서 물리 법칙·공간 관계·직관적 상식을 다단계로 결합해 정답을 도출해야 하는 태스크 - 시각·물리적 환각과 논리 비약이 즉시 드러나 Logical Coherence, Step Factual Accuracy, Cross-modal Consistency 등 의미 정확성 지표를 극도로 민감하게 측정 - 현재 추론형 AI의 실생활 물리 직관 능력과 인간 수준 의미 정확성을 판단하는 최고 난도 표준 태스크 - 단순 상식보다 오류 전파가 빠르고 복잡해, 의미 정확성 지표 선정 시 가장 엄격하고 포괄적인 테스트베드로 활용

[표 IV-84] 추론형 AI 데이터 학습 Task(의미 정확성) 예시

1.2 의미정확성 지표 설정

- 학습 Task가 결정되면 적합한 가공 유형과 품질측정항목을 참고하여 데이터 품질과 관련된 측정지표 및 목표치를 선택하여 활용

1.2.1 출력 정답 기반

TASK	데이터 가공유형	측정지표	품질검사 항목	정량목표 범주(예시)
수학·논리 추론 (Math & Logical Reasoning)	최종정답 + CoT 단계	Pass@1, CQS, Calculation Accuracy, Step Consistency, Local Validity	계산식 정확성, 논리 연결, 환각 여부, 단계 완결성	Pass@1 $\geq$ 92%, CQS $\geq$ 94, Calc.Acc $\geq$ 98%, Step Consistency $\geq$ 96%
지식 기반 질의응답 (Knowledge QA)	단일 정답 (short answer/ 선택지)	EM, Faithfulness, Attribution Accuracy, Evidence Support Score	사실 정확성, 인용 정확도, 환각 여부, 근거 충실도	EM $\geq$ 94%, Faithfulness $\geq$ 95%, Attribution Acc $\geq$ 93%, ESS $\geq$ 96%
멀티턴 QA	턴(turn) 별 정답 + 최종 정답	Final EM, Logical Coherence, Faithfulness, Step Consistency	맥락 유지, 대화 일관성, 환각 누적, 근거 추적	Final EM $\geq$ 90%, LCS $\geq$ 92%, Faithfulness $\geq$ 93%, Step Consistency $\geq$ 94%
지문 기반 추론 (Reading Comprehension)	추출/단일 정답 (span or short)	EM/F1, Faithfulness, Attribution Accuracy, Evidence Support	지문 충실도, 추론 정당성, 인용 정확도, 과도한 외부지식 사용	EM $\geq$ 93% , F1 $\geq$ 95%, Faithfulness $\geq$ 94%, Attribution Acc $\geq$ 92%

[표 IV-85] 출력정답기반의 의미정확성 지표 설정

1.2.2 과정 기반

TASK	데이터 가공유형	측정지표	품질검사 항목	정량목표 범주(예시)
단계적 추론(Step-by-step Reasoning)	최종정답 + 단계별 ground-truth CoT	Step Consistency, Local Validity, CQS, Argument Correctness Rate	단계 간 논리 연결, 사실 오류, 중복/생략, 환각	Step Consistency $\geq 96\%$, Local Validity $\geq 97\%$, CQS ≥ 94 , ACR $\geq 95\%$
그래프 기반추론	최종정답 + 노드·엣지·경로 ground-truth	Node Coherence, Path Reliability, Strategy Diversity, PSDS	노드 일관성, 경로 타당성, 전략 중복, 연결 오류	NCS $\geq 95\%$, PRS $\geq 92\%$, PSDS ≥ 85 , SDE ≥ 90
계산형 문제 해결	최종정답 + 모든 중간 계산식·수치	Calculation Accuracy, Step Factual Accuracy, Local Validity	계산식 100% 일치, 단위소수점오류, 중간값 정확성	Calc.Acc $\geq 99\%$, SFA $\geq 98\%$, Local Validity $\geq 97\%$

[표 IV-86] 과정 기반의 의미정확성 지표 설정

1.2.3 복잡 추론 성능기반

TASK	데이터 가공유형	측정지표	품질검사 항목	정량목표 범주(예시)
멀티홉 추론 (Multi-hop QA)	최종정답 + 중간 증거 경로	EM, Faithfulness, Step Consistency, ESS	증거 체인 완전성, 중간 단계 환각, 논리 연결	EM $\geq 88\%$, Faithfulness $\geq 93\%$, ESS $\geq 94\%$, Step Cons $\geq 92\%$
상식 추론 (Commonsense Reasoning)	최종 선택지 + CoT 설명	Accuracy, Logical Coherence, CQS	비약 최소화, 상식 위반 여부, 설명 설득력	Acc $\geq 93\%$, LCS $\geq 94\%$, CQS $\geq 92\%$
인과 추론 (Causal Reasoning)	정답 + 인과 그래프 또는 CoT	Accuracy, Step Consistency, Argument Correctness	인과 방향 오류, 혼동 변수 처리, 반사실 추론 정확성	Acc $\geq 90\%$, Step Cons $\geq 94\%$, ACR $\geq 93\%$
계획·전략 추론 (Planning & Strategy)	최종 성공 여부 + 전체 계획 시퀀스	Success Rate, TACS, Step Efficiency, JQS	행동-생각 일치, 불필요 행동 최소, 최적성	Success $\geq 85\%$, TACS $\geq 93\%$, SER ≥ 80 , JQS ≥ 92

멀티모달 추론 (Multimodal Reasoning)	최종정답 + 시각-텍스트 CoT	Accuracy, Visual Faithfulness, Cross-modal Coherence	이미지 오독, 모달 간 모순, 시각 근거 누락	Acc $\geq$ 89%, Visual Faith $\geq$ 94%, Coherence $\geq$ 93%
물리·공간 추론 (Physical Reasoning)	정답 + 물리 법칙 적용 CoT	Accuracy, Step Factual Accuracy, Logical Coherence	물리 법칙 위반, 공간 관계 오류, 직관 위반	Acc $\geq$ 91%, SFA $\geq$ 95%, LCS $\geq$ 94%

[표 IV-87] 과정 기반의 의미정확성 지표 설정

- 복잡 추론은 단일 % 오류가 전체 실패로 이어지므로 모든 지표가 90% 이상을 목표로 설정하며, 특히 Faithfulness/Coherence류는 93~95% 이상을 인간 수준으로 간주

2

유효성 품질지표 설정 가이드

2.1 개요

- 데이터 유효성이란 학습데이터가 모델학습에 적합하고, 예측 모델이 실제 환경에서 정확하게 작동하도록 하는 데 필요한 품질 기준을 충족하는지를 의미
- 유효성 측정지표는 매우 다양한 측정 방법 및 지표가 존재하므로, 데이터 구축목적에 따라 적절한 측정지표 및 목표를 정의

2.2 유효성 지표 설정

2.2.1 유효성 목표 설정 원칙

- 목표치는 최근(2년 이내)년 공식 리더보드·논문·공개 기술보고서에 보고된 해당 태스크의 SoTA(예: o1-full, Claude-3.7-Thinking, DeepSeek-R2, Gemini-2.0 등) 수치를 직접 기준으로 설정
- 동일 태스크·동일 평가 프로토콜(예: AIME 2024, GAIA Level-4, MATH-500 등)에서 보고된 최고 성능 수치의 90~95% 수준을 최소 목표, 97~100% 수준을 최종 목표로 설정
- 모든 목표치 제안 시 반드시 출처 논문·리더보드 URL·페이지 번호를 명기하며, 지적재산권 침해 우려가 없는 공개 모델만 참조
- SoTA 수치가 존재하지 않거나 새로운 서브태스크일 경우, 해당 도메인 최고 전문가 2인 이상의 공동 합의치를 기준으로 목표를 설정
- Faithfulness, Step Consistency, Calculation Accuracy 등 의미 정확성 핵심 지표는 반드시 94% 이상을 기본 목표로 설정(2025년 인간 수준 기준).
- 이해관계자 회의 시 모든 목표치에 대해 “SoTA 출처 + 달성 예정 모델 대비 예상 달성률”을 함께 제시하여 투명성을 확보
- 최종 목표치는 SoTA 달성일로부터 6개월 이내 성능을 기준으로 지속 갱신하며, 갱신 시 근거 자료를 반드시 문서화해야함

2.2.3 유효성 주요지표 설정 절차

구분	TASK	주요 성능지표
출력 정답 기반	수학·논리 추론(Math & Logical Reasoning)	• Pass@1 • EM • CQS
	지식 기반 질의응답(Knowledge QA)	• EM • Faithfulness • Attribution Accuracy
	멀티턴 QA	• Final EM • Logical Coherence
	지문 기반 추론(Reading Comprehension)	• EM/F1 • Faithfulness
과정 기반	단계적 추론(Step-by-step Reasoning)	• Step Consistency • Local Validity • CQS
	그래프 기반추론	• Node Coherence • Path Reliability
	계산형 문제 해결	• Calculation Accuracy • SFA
복잡 추론 성능 기반	멀티홉 추론(Multi-hop QA)	• EM • Faithfulness • Step Consistency
	상식 추론	• Accuracy • Logical Coherence
	인과추론	• Accuracy • Step Consistency
	계획·전략 추론	• Success Rate • TACS
	멀티모달 추론	• Accuracy • Visual Faithfulness
	물리·상식 기반 공간 추론(Physical Reasoning)	• Accuracy • SFA

[표 IV-88] 유효성 주요 성능지표

부록3

근거문헌

1

근거문헌 세부내용

● 1. 개요작성 부문

1. <https://arxiv.org/pdf/2201.11903>
2. Jason Wei, et al - 'Chain-of-Thought Prompting Elicits Reasoning in Large Language Models'
3. <https://arxiv.org/pdf/2203.11171>
4. Xuezhi Wang et al.,-'Self-Consistency Improves Chain of Thought Reasoning in Language Models'
5. <https://arxiv.org/abs/2310.10686>
6. Zheyu Zhang, et ai.-'Autonomous Tree-search Ability of Large Language Models'
7. <https://arxiv.org/abs/2308.09687>
8. Maciej Besta,et ai.-'Graph of Thoughts: Solving Elaborate Problems with Large Language Models'
9. <https://www.ibm.com/kr-ko/think/topics/chain-of-thoughts>
10. 생각의 사슬(CoT - Chain of Thought) 프롬프트란 무엇인가?
11. <https://verityai.co/blog/gsm8k-math-benchmarks-mathematical-reasoning>
12. GSM8K & MATH: Benchmarking Mathematical Reasoning
13. <https://huggingface.co/datasets/openai/gsm8k> GSM8K(수학 문제)
14. <https://aclanthology.org/2021.acl-long.238.pdf>
15. Shourya Aggarwal etc "Explanations for CommonsenseQA: New Dataset and Models, aclanthology,2021.acl-long.238
16. <https://gluebenchmark.com/> GLUE
17. <https://arxiv.org/pdf/2103.03874>
18. Dan Hendrycks et al, "Measuring Mathematical Problem Solving With the MATH Dataset" arxiv 2103.03874
19. <https://huggingface.co/datasets/voidful/StrategyQA> StrategyQA
20. <https://arxiv.org/pdf/2506.08817>
21. Shuyi Zhang et al., " Video-CoT: A Comprehensive Dataset for Spatiotemporal Understanding of Videos Based on Chain-of-Thought" arxiv 2506.08817
22. <https://arxiv.org/pdf/2411.14794>
23. Songhao Han et al., "VideoEspresso: A Large-Scale Chain-of-Thought Dataset for Fine-Grained Video Reasoning via Core Frame Selection" arxiv. 2411.14794
24. <https://cocodataset.org/#home> MS COCO(Microsoft Common Objects in Context)
25. <https://arxiv.org/pdf/1505.04870>
26. Bryan A. Plummer et al., "Flickr30k Entities: Collecting Region-to-Phrase Correspondences for Richer Image-to-Sentence Models"
27. <https://arxiv.org/pdf/1904.03493>
28. Wang et al., "VaTeX: A Large-Scale, High-Quality Multilingual Dataset for Video-and-Language Research," ACL 2019
29. <https://openai.com/ko-KR/index/learning-to-reason-with-llms> LLM으로 추론하는 법 배우기
30. <https://cookbook.openai.com/articles/gpt-oss/handle-raw-cot>
31. How to handle the raw chain of thought in gpt-oss
32. <https://arxiv.org/pdf/2305.04388>
33. Miles Turpin et al., "Language Models Don't Always Say What They Think: Unfaithful Explanations in Chain-of-Thought Prompting"
34. <https://deepmind.google/research/publications/64816>
35. Large Language Models Self-Discover Reasoning Structures
36. <https://deepmind.google/research/publications/63605>
37. RoboVQA: Multimodal Long-Horizon Reasoning for Robotics
38. <https://duststorage.tistory.com/51>
39. Towards System 2 Reasoning in LLMs: Learning How to Think With Meta Chain-of-Thought
40. <https://www.marktechpost.com/2025/09/21/meta-ai-proposes-metacognitive-reuse-turning-llm-chains-of-thought-into-a-procedural-handbook-that-cuts-tokens-by-46>

41. Meta AI Proposes 'Metacognitive Reuse': Turning LLM Chains-of-Thought into a Procedural Handbook that Cuts Tokens by 46%
42. <https://arxiv.org/pdf/2509.13237>
43. Aniket Didolkar, et al.-'Metacognitive Reuse: Turning Recurring LLM Reasoning Into Concise Behaviors'
44. <https://deepseek.csdn.net/67ab1f1979aaf67875cb9ce7.html>
45. DeepSeek-R1: How Did They Make an OpenAI-Level Reasoning Model So Damn Efficient?
46. <https://huggingface.co/datasets/ruggsea/wsdm2024-deepseek-cot/blob/main/README.md> DeepSeek 데이터 구축 방식 및 규모
47. <https://bytebridge.medium.com/deepseek-ai-company-overview-founding-team-culture-and-deepseek-r1-model-ea87f711b4b3>
48. DeepSeek AI: Company Overview, Founding team, Culture and DeepSeek R1 Model
49. https://www.kcmi.re.kr/kcmifile/CapitalMarketFocus/1839/webzinepdf_1839.pdf 노성호, DeepSeek(深度求索) AI와 금융산업의 혁신, 자본시장 포커스, 2025-07호
50. <https://data.x.ai/2025-08-20-grok-4-model-card.pdf>
51. Grok 4 Model Card
52. <https://philliphong0724.tistory.com/104>
53. Grok3 심층분석 : 차세대 AI모델의 기술, 기능, 활용 및 타모델 비교
54. <https://www.innovatiana.com/en/datasets/openthoughts-114k>
55. OpenThoughts 114k
56. Structured reasoning corpus covering math, science, programming, and puzzles. Used to refine and test OpenThinker models.
57. <https://www.innovatiana.com/en/datasets/openmathreasonin>
58. <https://arxiv.org/abs/2508.01977>
59. TIBSTC-CoT: A Multi-Domain Instruction Dataset for Chain-of-Thought Reasoning in Language Models
60. <https://github.com/OpenBioLink/ThoughtSource>
61. GitHub 오픈소스 공개 데이터
62. <https://www.innovatiana.com/en/datasets/openseek-synthetic-reasoning-data> OpenSeek Synthetic Reasoning Data
63. <https://aclanthology.org/2025.acl-industry.85.pdf>
64. One Missing Piece for Open-Source Reasoning Models: A Dataset to Mitigate Cold-Starting Short CoT LLMs in RL
65. https://magazine.hankyung.com/job-joy/article/202105172004d?utm_source
66. 국내 한국어 평가용 데이터셋 구축 흐름
67. <https://v.daum.net/v/20250717120209789>
68. 과기정통부, 독자 AI 모델 성능평가 위한 데이터셋 구축 착수
69. <https://arxiv.org/abs/2509.11303>
70. Ko-PIQA: A Korean Physical Commonsense Reasoning Dataset with Cultural Context
71. <https://arxiv.org/abs/2510.24150>
72. Ko-MuSR: A Multistep Soft Reasoning Benchmark for LLMs Capable of Understanding Korean
73. <https://www.etnews.com/20240722000312>
74. 플리토, 한국어 LLM 리더보드에 '감성평가'·'지시준수' 데이터셋 제공
75. <https://www.fnnews.com/news/202409271027516771>
76. 카카오, 한국어 기반 '평선클 성능 평가 데이터셋' 구축
77. <https://arxiv.org/pdf/2309.11054>
78. DESIGN OF CHAIN-OF-THOUGHT IN MATH PROBLEM SOLVING
79. <https://arxiv.org/pdf/2504.16891>
80. AIMO-2 Winning Solution: Building State-of-the-Art Mathematical Reasoning Models with OpenMathReasoning dataset
81. <https://arxiv.org/abs/2506.05331>
82. MINT-CoT: Enabling Interleaved Visual Tokens in Mathematical Chain-of-Thought Reasoning
83. <https://arxiv.org/abs/2501.04686>
84. Unlocking Multimodal Mathematical Reasoning via Process Reward Model
85. <https://openai.com/index/improving-mathematical-reasoning-with-process-supervision/>
86. Improving mathematical reasoning with process supervision
87. <https://odsc.medium.com/the-rise-of-reasoning-models-unlocking-the-next-phase-of-ai-8d82683cb5ec> The Rise of Reasoning Models: Unlocking the Next Phase of AI
88. <https://arxiv.org/html/2503.00483v1>
89. Christoph Treude et al., "Interacting with AI Reasoning Models: Harnessing "Thoughts" for AI-Driven Software Engineering"

90. <https://www.gocodeo.com/post/what-is-ai-reasoning-and-why-its-transforming-intelligence-in-2025>
91. What Is AI Reasoning and Why It's Transforming Intelligence in 2025
92. <https://www.vktr.com/ai-technology/what-are-reasoning-models-and-why-they-matter/>
93. What Are Reasoning Models? And Why They Matter
94. <https://www.cas.org/resources/article/the-importance-of-data-quality-in-ai-applications> 'The importance of data quality in AI applications'
95. <https://bigid.com/blog/understanding-the-ai-model-lifecycle/>
96. AI Model Lifecycle: Streamlining Data Management for AI Success
97. <https://www.acceldata.io/blog/how-ai-is-transforming-data-quality-management> How AI Is Transforming Data Quality Management
98. <https://elifesciences.org/articles/106187>
99. Critique of impure reason: Unveiling the reasoning behaviour of medical large language models
100. <https://www.nature.com/articles/s41599-024-03811-x>
101. AI hallucination: towards a comprehensive classification of distorted information in artificial intelligence-generated content
102. <https://www.sciencedirect.com/science/article/pii/S0148296325006277>
103. Llewellyn D.W. Thomas et al., 'Jagged competencies: Measuring the reliability of generative AI in academic research'
104. <https://www.dotcompliance.com/blog/artificial-intelligence/can-ai-really-benefit-quality-management-processes> / Can AI Really Benefit Quality Management Processes?

● II. 품질관리체계 작성 부문

1. <https://aclanthology.org/2023.findings-emnlp.416.pdf>
2. Explainable Claim Verification via Knowledge-Grounded Reasoning with Large Language Models
3. <https://arxiv.org/html/2508.10523v1>, Reasoning in Computer Vision: Taxonomy, Models, Tasks, and Methodologies
4. Ayushman Sarkar et al., 'Reasoning in Computer Vision: Taxonomy, Models, Tasks, and Methodologies'
5. <https://nebius.com/blog/posts/what-it-takes-to-build-a-reasoning-model>
6. What it takes to build a reasoning model
7. <https://arxiv.org/abs/2301.13379>, Faithful Chain-of-Thought Reasoning
8. Lyu et al., 2023 'Faithful Chain-of-Thought Reasoning'
9. <https://arxiv.org/abs/2307.13702>, Measuring Faithfulness in Chain-of-Thought Reasoning
10. Tamera Lanham et al., 'Measuring Faithfulness in Chain-of-Thought Reasoning'
11. <https://arxiv.org/abs/2207.14529>, The Effects of Data Quality on Machine Learning Performance on Tabular Data
12. Sedir Mohammed et al., The Effects of Data Quality on Machine Learning Performance (2025)
13. <https://arxiv.org/abs/2004.10157>, Logic-Guided Data Augmentation and Regularization for Consistent Question Answering
14. Logic-Guided Data Augmentation and Regularization for Consistent Question Answering (Asai & Hajishirzi, 2020)
15. https://papers.nips.cc/paper_files/paper/2023/file/72393bd47a35f5b3bee4c609e7bba733-Supplemental-Conference.pdf
16. Zhan Ling et al., 'Deductive Verification of Chain-of-Thought Reasoning'(Ling et al., 2023)
17. https://papers.neurips.cc/paper_files/paper/2023/file/ed3fea9033a80fea1376299fa7863f4a-Paper-Conference.pdf
18. Turpin, M., et al. (2023). Unfaithful Explanations in Chain-of-Thought Prompting. NeurIPS Paper.
19. <https://arxiv.org/html/2404.05692v1>, Explainable Generative AI (GenXAI): A Survey, Conceptualization, and Research Agenda
20. Evaluating Mathematical Reasoning Beyond Accuracy (Xia et al., 2024)
21. <https://arxiv.org/html/2510.20603v1>, What Defines Good Reasoning in LLMs? Dissecting Reasoning Steps with Multi-Aspect Evaluation
22. What Defines Good Reasoning in LLMs? Dissecting Reasoning Steps with Multi-Aspect Evaluation (Do et al., 2025)
23. <https://arxiv.org/abs/2211.09110>, Holistic Evaluation of Language Models
24. Holistic Evaluation of Language Models (Liang et al., 2022)
25. <https://arxiv.org/pdf/2311.05232>, A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions

26. A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions (Huang et al., 2023)
27. <https://aclanthology.org/2024.emnlp-main.1088.pdf>
28. Factuality of Large Language Models: A Survey (Wang et al., 2024)
29. <https://arxiv.org/abs/2311.14648>, Calibrated Language Models Must Hallucinate
30. Calibrated Language Models Must Hallucinate (Kalai & Vempala, 2023)
31. <https://arxiv.org/abs/2402.00559>, A Chain-of-Thought Is as Strong as Its Weakest Link: A Benchmark for Verifiers of Reasoning Chains
32. A Chain-of-Thought Is as Strong as Its Weakest Link: A Benchmark for Verifiers of Reasoning Chains (Jacovi et al., 2024)
33. <https://www.ijcai.org/proceedings/2025/1155.pdf>
34. Empowering LLMs with Logical Reasoning (F. Cheng et al., 2025)
35. <https://aclanthology.org/anthology-files/pdf/bea/2025.bea-1.65.pdf>
36. Evaluation of Chain-of-Thought Reasoning with Signal Temporal Logic (Z. Mao et al., 2025)
37. <https://arxiv.org/pdf/2504.01282v1>
38. LLM Self-Inconsistency Beyond Generative Randomness (Errica et al., 2025)
39. <https://arxiv.org/abs/2305.14279>
40. Two Failures of Self-Consistency in the Multi-Step Reasoning of LLMs (Chen et al., 2024)
41. <https://aclanthology.org/2024.naacl-long.11.pdf>
42. Yangyi Chen et al. — Measuring and Improving Chain-of-Thought Reasoning in Language Models (Chen et al., 2024)
43. <https://arxiv.org/pdf/2506.04810v1>
44. Dissecting Logical Reasoning in LLMs: A Fine-Grained Evaluation and Supervision Study (Zhou et al., 2025)
45. https://proceedings.neurips.cc/paper_files/paper/2023/file/72393bd47a35f5b3bee4c609e7bba733-Supplemental-Conference.pdf
46. Deductive Verification of Chain-of-Thought Reasoning (Ling et al., 2023)
47. <https://openreview.net/forum?id=V61nluxFIR&utm>
48. Aligning with Logic: Measuring, Evaluating and Improving Logical Preference Consistency in Large Language Models (Liu et al., 2025)
49. <https://arxiv.org/pdf/2509.19489v1>
50. Estimating the Self-Consistency of LLMs (Nowak 2025)
51. <https://openreview.net/pdf?id=LjsjHF7nAN>
52. Universal Self-Consistency for Large Language Models (Chen et al., 2024)
53. <https://arxiv.org/pdf/2310.13439>
54. Self-Consistency of Large Language Models under Ambiguity (Bartsch et al., 2023)
55. <https://arxiv.org/pdf/2305.11499>
56. Xue, T et al., 2023 RCOT: Detecting and Rectifying Factual Inconsistency in Reasoning by Reversing Chain-of-Thought.
57. <https://arxiv.org/pdf/2504.00180>
58. Gokul, V et al., 2024 'Contradiction Detection in RAG Systems: Evaluating LLMs as Context Validators for Improved Information Consistency.'
59. <https://arxiv.org/pdf/2502.20790>
60. Chain-of-Thought Matters: Improving Long-Context Language Models with Reasoning Path Supervision (Zhu D. et al., 2025)
61. <https://arxiv.org/pdf/2510.10013>
62. Path Drift in Large Reasoning Models: How First-Person Commitments Override Safety (Huang Y. et al., 2025)
63. <https://www-cdn.anthropic.com/827afa7dd36e4afb1a49c735fbb2c69749756e/measuring-faithfulness-in-chain-of-thought-reasoning.pdf>
64. Measuring Faithfulness in Chain-of-Thought Reasoning
65. <https://openreview.net/pdf?id=1OyE9IK0kx>
66. Tanneru et al. 'On the Hardness of Faithful Chain-of-Thought Reasoning in Large Language Models'
67. <https://alineaaainsights.com/chain-of-thought-ai-understanding-faithfulness-in-reasoning>
68. Chain-of-Thought AI: Understanding Faithfulness in Reasoning
69. <https://aclanthology.org/2023.ijcnlp-main.20.pdf>
70. Faithful Chain-of-Thought Reasoning (Lyu et al., 2023)
71. <https://arxiv.org/pdf/2307.13702>
72. Measuring Faithfulness in Chain-of-Thought Reasoning (Lanham et al., 2023)
73. <https://aclanthology.org/2024.findings-emnlp.882.pdf>
74. Making Reasoning Matter: Measuring and Improving Faithfulness of Chain-of-Thought Reasoning (Paul et al., 2024)
75. <https://arxiv.org/pdf/2311.09069>
76. Lee, H et al., (2023) 'How Well Do Large Language Models Truly Ground?'

77. <https://aclanthology.org/2024.findings-emnlp.496.pdf>
78. Fang, J., et al. (2024). Constructing Knowledge-Grounded Reasoning Chains for Retrieval-Augmented Generation
79. <https://aclanthology.org/2025.findings-acl.875.pdf>
80. Sorodoc et al. (2025). GaRAGE: A Benchmark with Grounding Annotations for RAG Evaluation
81. <https://arxiv.org/pdf/2404.10513>
82. Berchansky, M et al., 2024 'CoTAR: Chain-of-Thought Attribution Reasoning with Multi-level Granularity'
83. <https://www.sciencedirect.com/science/article/pii/S0957417425028891>
84. He, G. (2025). Enhancing belief consistency of large language models via attribution process. Information & Management
85. <https://arxiv.org/pdf/2505.14684>
86. Xu, H.,et al.,2025 'Mind the Gap: Bridging Thought Leap for Improved Chain-of-Thought Tuning.'
87. <https://aclanthology.org/2023.emnlp-main.622.pdf>
88. Prasad, A., Saha, S., Zhou, X., & Bansal, M. (2023). ReCEval: Evaluating Reasoning Chains via Correctness and Informativeness
89. <https://aclanthology.org/2024.findings-acl.168.pdf>
90. Nguyen, M-V., Luo, L., Shiri, F., Phung, D., Li, Y-F., Vu, T-T., & Haffari, G. (2024). Direct Evaluation of Chain-of-Thought in Multi-hop Reasoning with Knowledge Graphs
91. <https://arxiv.org/pdf/2505.14684v2>
92. Mind the Gap: Bridging Thought Leap for Improved Chain-of-Thought Tuning (Xu et al. 2025)
93. <https://arxiv.org/pdf/2502.12289v3>
94. Evaluating Step-by-step Reasoning Traces: A Survey (Lee & Hockenmaier, 2025)
95. <https://arxiv.org/pdf/2503.09567>
96. Towards Reasoning Era: A Survey of Long Chain-of-Thought for Reasoning Large Language Models (Chen et al., 2025)
97. <https://arxiv.org/pdf/2502.17419>
98. A Survey of Reasoning Large Language Models (Li et al., 2025)
99. <https://arxiv.org/pdf/2506.09853>
100. Causal Sufficiency and Necessity Improves Chain-of-Thought Reasoning (Yu X., Wang Z., Yang L. et al., 2025)
101. <https://aclanthology.org/2024.emnlp-main.478.pdf>
102. Nico Daheim et al., Stepwise Verification and Remediation of Student Reasoning Errors with Large Language Model Tutors
103. <https://arxiv.org/pdf/2510.21884>
104. Avinash Patil, 2025 'Framework for Machine Evaluation of Reasoning Completeness in Large Language Models'
105. <https://arxiv.org/pdf/2511.07083v1>
106. Marc Jansen, "Increasing AI Explainability by LLM Driven Standard ..." (Anonymous, 2025)
107. <https://www.sciencedirect.com/science/article/pii/S0950584923000514>
108. "Transparency and Explainability of AI Systems: From ethical ..." (Balasubramaniam, N., 2023)
109. https://aigi.ox.ac.uk/wp-content/uploads/2025/07/Cot_Is_Not_Explainability.pdf
110. "Chain-of-Thought Is Not Explainability — Paper Review" (Barez, 2025)
111. <https://www.frontiersin.org/journals/computer-science/articles/10.3389/fcomp.2023.1114806/full>
112. Evaluating machine-generated explanations: a "Scorecard" for explanation quality (Hoffman et al., 2023)
113. <https://arxiv.org/pdf/2109.05327>
114. An Objective Metric for Explainable AI: How and Why to Estimate the Degree of Explainability (Sovrano & Vitali, 2021)
115. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11586978>
116. Readability Metrics in Patient Education: Where Do We Innovate?
117. Som Singh, Aleena Jamal, Fawad Qureshi
118. <https://www.mdpi.com/1424-8220/25/13/4166>
119. Zhihan Chen et al., 'A Comprehensive Review of Explainable Artificial Intelligence (XAI) in Computer Vision'
120. <https://dl.acm.org/doi/10.1145/3233231>
121. ZACHARY C. LIPTON (2018). "The Mythos of Model Interpretability." Communications of the ACM, 61(10)
122. <https://arxiv.org/pdf/1706.07269>
123. Miller, T. (2019). "Explanation in Artificial Intelligence: Insights from the Social Sciences." Artificial Intelligence, 267, 1–38.
124. <https://arxiv.org/pdf/2102.12060>
125. Wiegrefe et al. (2021). "Teach Me to Explain: A Review of Datasets for Explainable NLP." EMNLP 2021.
126. <https://arxiv.org/pdf/2201.08164>

127. A Systematic Review on Evaluating Explainable AI — Nauta et al., 2022 (arXiv)
128. <https://dl.acm.org/doi/pdf/10.1145/3639372>
129. Explainability for Large Language Models: A Survey (ACM / 2024 survey article)
130. <https://www.mdpi.com/2078-2489/15/1/4>
131. Explainable AI Evaluation: A Top-Down Approach (MDPI, 2023)
132. <https://arxiv.org/pdf/2412.05145v1>
133. “Explaining AI Predictions using Large Language Models” (arXiv, 2024)
134. <https://arxiv.org/pdf/2407.17125>
135. Analyzing Self-Consistency of Large Language Models under Ambiguity (Sedova et al., 2024)
136. https://www.researchgate.net/publication/390570103_Beyond_Single-Turn_A_Survey_on_Multi-Turn_Interactions_with_Large_Language_Models
137. Beyond Single-Turn: A Survey on Multi-Turn Interactions with Large Language Models (Li Y. et al., 2025)
138. <https://aclanthology.org/2023.blackboxnlp-1.7.pdf>
139. Bartsch H. et al. (2023) 논문 Self-Consistency of Large Language Models under Ambiguity
140. <https://arxiv.org/pdf/2505.00268>
141. Consistency in Language Models (Novikova J., 2025)
142. <https://openreview.net/pdf/e9166b80a9d56f3aa23252f614e755720189a5d3.pdf>
143. Firm or Fickle? Evaluating Large Language Models ... (2024)
144. <https://arxiv.org/pdf/2501.17399v1>
145. MultiChallenge: A Realistic Multi-Turn Conversation Evaluation Benchmark (2025)
146. <https://arxiv.org/pdf/2503.08815v1>
147. “Cross-Examiner: Evaluating Consistency of Large Language Model-Generated Explanations” (2025)
148. <https://arxiv.org/pdf/2310.07088v2>
149. Diversity of Thought Improves Reasoning Abilities of LLMs
150. <https://aclanthology.org/2025.acl-long.191.pdf>
151. Fine-Tuning on Diverse Reasoning Chains Drives Within-Inference CoT Refinement in LLMs (2025)
152. <https://openreview.net/pdf?id=VIUisLx8lQ>
153. “Diversify Large Language Model Reasoning with TypedThinker” (D Wang et al.,)
154. https://proceedings.neurips.cc/paper_files/paper/2024/file/00d80722b756de0166523a87805dd00f-Paper-Conference.pdf
155. “Improving Chain-of-Thought Reasoning in LLMs” (Z Xiang et al., 2024)
156. <https://arxiv.org/pdf/2411.19862v1>
157. Ajay Krishna Vajjala., et al. ‘Cross-Domain Recommendation Meets Large Language Models’
158. <https://dl.acm.org/doi/pdf/10.1145/3708497>
159. Towards Trustworthy Machine Learning in Production: An Overview of the Robustness in MLOps Approach
160. <https://www.nature.com/articles/s41746-024-01420-1>
161. A scoping review of robustness concepts for machine learning in healthcare
162. <https://arxiv.org/pdf/2509.04013v1>
163. On Robustness and Reliability of Benchmark-Based Evaluation of LLMs
164. <https://dl.acm.org/doi/10.1145/3459637.3482204>
165. Towards Robustness to Label Noise in Text Classification via Noise Modeling
166. <https://www.sciencedirect.com/science/article/abs/pii/S0952197625001575>
167. Zhang, H. et al., A survey on learning with noisy labels in NLP (2025)
168. <https://arxiv.org/pdf/2402.14897>, Chain-of-Thought Unfaithfulness as Disguised Accuracy
169. Chain-of-Thought Unfaithfulness as Disguised Accuracy
170. <https://openreview.net/pdf?id=60a1SAth4e>
171. Li et al., Measuring and Controlling Instruction Instability (2024)
172. <https://arxiv.org/pdf/2302.00093>, Large Language Models Can Be Easily Distracted by Irrelevant Context
173. Sclar et al., Large Language Models can be Easily Distracted by Irrelevant Context (ICLR 2024)
174. <https://arxiv.org/pdf/2501.08203v1>
175. Evaluating Robustness of LLMs to Noisy Context in Math Problem Solving (2025)
176. <https://dl.acm.org/doi/10.1145/3696410.3714511>
177. Evaluating Robustness of LLMs on Crisis-Related Microblogs across Events, Information Types, and Linguistic Features (ACL 2025)

178. <https://arxiv.org/pdf/2305.07722>, InSearchofVerifiability:ExplanationsRarelyEnable
1. ComplementaryPerformanceinAI-AdvisedDecisionMaking
179. In Search of Verifiability: Explanations Rarely Enable Complementary Performance in AI-Advised Decision Making (Fok & Weld, 2023)
180. <https://aclanthology.org/2024.acl-long.254.pdf>
181. A Benchmark for Verifiers of Reasoning Chains (Jacovi et al., 2024)
182. <https://arxiv.org/pdf/2511.01425>, Learning to Seek Evidence: A Verifiable Reasoning Agent with
2. Causal Faithfulness Analysis
183. Learning to Seek Evidence: A Verifiable Reasoning Agent with Causal Faithfulness Analysis (Huang et al., 2025)
184. <https://arxiv.org/pdf/2510.09312>, Verifying Chain-of-Thought Reasoning via Its
3. Computational Graph
185. Verifying Chain-of-Thought Reasoning via Its Computational Graph (Zhao et al., 2025)
186. <https://www.nature.com/articles/s42256-024-00878-8>
187. A large-scale audit of dataset licensing and attribution in AI
188. <https://arxiv.org/pdf/2303.15889v2>, Where are we in the search for an Artificial Visual
4. Cortex for Embodied Intelligence?
189. Metrics for Dataset Demographic Bias: A Case Study on Facial Expression Recognition
190. <https://ceur-ws.org/Vol-3118/p02.pdf>
191. Metrics for Identifying Bias in Datasets
192. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11031231>
193. Unmasking bias in artificial intelligence: a systematic review of bias detection and mitigation strategies in
electronic health record-based models
194. <https://arxiv.org/pdf/2404.12691v1>
195. Data Authenticity, Consent, & Provenance for AI are all broken: what will it take to fix them?
196. <https://www.nature.com/articles/s41467-019-10933-3>
197. Rocher et al. Estimating the success of re-identification in incomplete datasets.
198. <https://frodo.github.io/pub/An%20Improved%20Dataset%20for%20Logical%20Reasoning%20in%20Natural%20Language%20Understanding.pdf>
199. H. Liu et al. — “LogiQA 2.0: An Improved Dataset for Logical Reasoning in Natural Language Understanding”
200. <https://arxiv.org/pdf/2505.10937>
201. W. Cai et al. — “Reasoning with OmniThought: A Large CoT Dataset with Verbosity and Cognitive Difficulty Annotations”
202. <https://arxiv.org/pdf/2004.04494>, MuTual: A Dataset for Multi-Turn Dialogue Reasoning
203. L. Cui et al. — “MuTual: A Dataset for Multi-Turn Dialogue Reasoning”
204. <https://arxiv.org/pdf/2110.14168>, Training Verifiers to Solve Math Word Problems
205. K. Cobbe et al. ‘Training Verifiers to Solve Math Word Problems’
206. <https://aclanthology.org/2020.emnlp-main.272.pdf>
207. X. Zhao et al. — “Knowledge-Grounded Dialogue Generation with Pre-trained Language Models
208. <https://aclanthology.org/2024.acl-long.73.pdf>
209. Shiyue Diao et al. ‘Active Prompting with Chain-of-Thought for Large Language Models.’
210. <https://arxiv.org/pdf/2305.06599>, Structured Chain-of-Thought Prompting for Code Generation
211. J. Li, et al. — Structured Chain-of-Thought Prompting for Code Generation
212. https://openaccess.thecvf.com/content/CVPR2024/papers/Mitra_Compositional_Chain-of-Thought_Prompting_for_Large_Multimodal_Models_CVPR_2024_paper.pdf
213. C. Mitra, et al. — Compositional Chain-of-Thought Prompting for Large Multimodal Models.
214. https://www.researchgate.net/publication/35351827_Quality_by_Prompt_LLM-Powered_Transformation_of_Data_Quality_Requirements_Into_Great_Expectations
215. Abughazala et al. ‘Quality by Prompt: LLM-Powered Transformation of Data Quality Requirements Into Great Expectations’
216. <https://arxiv.org/pdf/2504.02052v2>, From Prompts to Templates: A Systematic Prompt Template Analysis for Real-world
LLMapps
217. Gorissen et al. ‘A Systematic Prompt Template Analysis for Real-world LLMapps’
218. <https://arxiv.org/pdf/2303.08896>, SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for
Generative Large Language Models
219. Wang, Z., Kordi, Y., Mishra, S., et al. — “SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection
for Generative Large Language Models”
220. <https://arxiv.org/pdf/2303.17651>, Self-Refine: Iterative Refinement with Self-Feedback

- 221.M. Madaan et al. Self-Refine: Iterative Refinement with Self-Feedback
- 222.<https://arxiv.org/pdf/2308.16901>, Eclectic flavor group $\Delta(27)\backslash \text{rtimes } S_3$ and lepton model building
- 223.K. Shinn et al. Reflexion: an autonomous agent with dynamic memory and self-reflection
- 224.<https://aclanthology.org/2023.findings-acl.126.pdf>, indings of the Association for Computational Linguistics: ACL 2023
- 225.Y. Kim et al. 'Self-Correction of Large Language Model Outputs using an External Knowledge Base'
- 226.<https://arxiv.org/pdf/2401.14003>, Multi-Modal Hallucination Control by Visual Information Grounding
227. Quyet V. Do et al. 'ConstraintChecker: A Plugin for Large Language Models to Reason on Commonsense Knowledge Bases'
- 228.<https://arxiv.org/pdf/2406.13892>, Adaptable Logical Control for Large Language Models
- 229.Honghua Zhang,et al. 'Adaptable Logical Control for Large Language Models'
- 230.<https://arxiv.org/pdf/2405.00204>, General Purpose Verification for Chain of Thought Prompting
- 231.Robert Vacareanu, et al. General Purpose Verification for Chain of Thought Prompting
- 232.<https://arxiv.org/pdf/2506.13639>, An Empirical Study of LLM-as-a-Judge: How Design Choices Impact Evaluation Reliability
- 233.Yusuke Yamauchi, et al. 'An Empirical Study of LLM-as-a-Judge: How Design Choices Impact Evaluation Reliability'
- 234.<https://arxiv.org/pdf/2509.13332>
235. Pratik Jayarao, et al. 'Explicit Reasoning Makes Better Judges: A Systematic Study on Accuracy, Efficiency, and Robustness'
- 236.<https://aclanthology.org/2024.acl-long.649.pdf>
- 237.huiyuan Lai, Malvina Nissim, 'mCoT: Multilingual Instruction Tuning for Reasoning Consistency in Language Models'
- 238.<https://arxiv.org/pdf/2405.18711>, Calibrating Reasoning in Language Models with Internal Consistency
- 239.Zhihui Xie, et ai. 'Calibrating Reasoning in Language Models with Internal Consistency'
- 240.<https://aclanthology.org/2025.acl-long.243.pdf>
- 241.Yaxi Lu, et al., 'Learning to Generate Structured Output with Schema Reinforcement Learning;
- 242.<https://arxiv.org/pdf/2502.14905>, Think Inside the JSON: Reinforcement Strategy for Strict LLM
5. Schema Adherence
- 243.Bhavik Agarwal, et al., 'Think Inside the JSON: Reinforcement Strategy for Strict LLM Schema Adherence'
- 244.<https://arxiv.org/pdf/2510.24940>
- 245.Yinhan He, et al., 'SemCoT: Accelerating Chain-of-Thought Reasoning through Semantically-Aligned Implicit Tokens,
- 246.<https://arxiv.org/pdf/2511.06168>
- 247.Boxuan Wang, et al., 'Chasing Consistency: Quantifying and Optimizing Human-Model Alignment in Chain-of-Thought Reasoning'
- 248.<https://arxiv.org/pdf/2211.11875>
249. Eric Mitchell, et al., 'Enhancing Self-Consistency and Performance of Pre-Trained Language Models through Natural Language Inference'
250. <https://arxiv.org/pdf/2111.09525>
- 251.Philippe Laban, et al., 'SummaC: Re-Visiting NLI-based Models for Inconsistency Detection in Summarization'
- 252.<https://arxiv.org/pdf/2510.01249>
- 253.You-Le Fang, et al. 'LOCA: Logical Chain Augmentation for Scientific Corpus Cleaning'
- 254.<https://arxiv.org/pdf/2502.11546>
255. Yingli Shen, et al. 'DCAD-2000: A Multilingual Dataset across 2000+ Languages with Data Cleaning as Anomaly Detection'
- 256<https://www.cambridge.org/core/journals/natural-language-engineering/article/an-unsupervised-perplexitybased-method-for-boilerplate-removal/5E589D838F1D1E0736B4F52001150339>
257. Marcos Fernández-Piche et al., 'An Unsupervised Perplexity-Based Method for Boilerplate Removal' (Natural Language Engineering, 2023)
- 258.<https://arxiv.org/html/2405.20541v1>
- 259.Zachary Ankner et al., 'Perplexity-Based Data Pruning With Small Reference Models' (arXiv, 2024)
- 260https://papers.neurips.cc/paper_files/paper/2024/file/370df50ccfd8bde18f8f9c2d9151bda-Paper-Datasets_and_Benchmarks_Track.pdf
- 261.Guilherme Penedo et al., 'The FineWeb Datasets: Decanting the Web for the Finest Text Data' (NeurIPS, 2024)
- 262.<https://arxiv.org/abs/2209.07662>
- 263.Nathaniel Weir et al., 'NELLIE: A Neuro-Symbolic Inference Engine for Grounded, Compositional, and Explainable Reasoning' (IJCAI, 2024)
- 264.<https://arxiv.org/html/2509.18577v1>
- 265.Yeongbin Seo et al., 'Prior-based Noisy Text Data Filtering: Fast and Strong Alternative for Perplexity' (arXiv, 2025):
- 266.<https://aclanthology.org/2024.lrec-main.1372.pdf>

- 267.Jón Friðrik Daðason et al., 'Text Filtering Classifiers for Medium-Resource Languages' (aclanthology, 2024)
- 268.<https://www.mdpi.com/2078-2489/16/6/424>
- 269.Alaa Mohasseb et al., 'Enhancing Text Classification Through Grammar-Based Feature Engineering and Learning Models' (MDPI, 2024; ResearchGate PDF, 2025)
- 270.<https://www.sciencedirect.com/science/article/pii/S1574013724000480>
271. Kamal Taha et al., 'A Comprehensive Survey of Text Classification Techniques and Their Applications' (Applied Soft Computing, 2024):
- 272.<https://arxiv.org/pdf/1803.09010>
- 273.Timnit Gebru, et al., 'Datasheets for Datasets.'
- 274.<https://arxiv.org/pdf/1810.03993>
- 275.Margaret Mitchell, et al., 'Model Cards for Model Reporting'
- 276.<https://arxiv.org/pdf/2508.01543>
- 277.Derin Cayir, et al., 'Refine-n-Judge: Curating High-Quality Preference Chains for LLM-Fine-Tuning'
- 278.https://www.vldb.org/2025/Workshops/VLDB-Workshops-2025/DaSH/DaSH25_5.pdf
- 279.Lav Rajgarhia, et al. — Large scale Data Curation For Multilingual Guardrails.
- 280.<https://arxiv.org/pdf/2509.23564>
281. Samuel Yeh, Sharon Li — Clean First, Align Later: Benchmarking Preference Data Cleaning for Reliable LLM Alignment
- 282.<https://arxiv.org/pdf/2308.03188>
- 283.Liangming Pan, et al. — Automatically Correcting Large Language Models: Surveying the Landscape of Diverse Self-Correction Strategies
- 284.<https://arxiv.org/pdf/2303.09540>
- 285.Amro Abbas, et al. — SemDeDup: Data-efficient learning at web-scale through semantic deduplication
- 286.<https://arxiv.org/pdf/2406.13695>
- 287.tefan Pasch, Dimitrios Petridis, Jannic Cutura — Multilingual De-Duplication Strategies: Applying scalable similarity search with monolingual & multilingual embedding models
- 288.<https://arxiv.org/pdf/2412.11142>
- 289.Tiankai Yang, et al.,— AD-LLM: Benchmarking Large Language Models for Anomaly Detection
- 290.<https://arxiv.org/pdf/2406.16308>
- 291.Aodong Li, et al., — Anomaly Detection of Tabular Data Using LLMs
- 292.<https://aclanthology.org/2025.findings-emnlp.67.pdf>
- 293.Jiahao Cheng, et al. — Chain-of-Thought Prompting Obscures Hallucination Cues in Large Language Models: An Empirical Evaluation
- 294.<https://aclanthology.org/2024.emnlp-main.837.pdf>
- 295.Shayan A. Akbar, et al. — HalluMeasure: Fine-grained Hallucination Measurement Using Chain-of-Thought Reasoning
- 296.<https://arxiv.org/pdf/2508.03860v1>
297. Subhey Sadi Rahman, et al. — Hallucination to Truth: A Review of Fact-Checking and Factuality Evaluation in Large Language Models
- 298.<https://nlp.stanford.edu/pubs/xie2018denoising.pdf>
- 299.Ziang Xie et al. — Noising and Denoising Natural Language: Diverse Backtranslation for Grammar Correction.
- 300.<https://arxiv.org/pdf/2311.00619>
- 301.U. Jinadu et al. — Noise Correction on Subjective Datasets.
- 302.<https://arxiv.org/pdf/2505.15684>
- 303.Gengyang Li et al. — ThinkLess: A Training-Free Inference-Efficient Method for Reducing Reasoning Redundancy.
- 304.<https://arxiv.org/pdf/2508.03346>
- 305.Zeju Li et al. — Compressing Chain-of-Thought in LLMs via Step Entropy.
- 306.<https://arxiv.org/pdf/2109.03910>
- 307.Emily Reif et al. — A Recipe For Arbitrary Text Style Transfer with Large Language Models
- 308.<https://aclanthology.org/2025.findings-acl.403.pdf>
- 309.Chaona Kong et al. — Neuron Activation Modulation for Text Style Transfer: Guiding Large Language Model
- 310.<https://arxiv.org/html/2403.19167v1>
- 311.Yexin Wu et al., 'Mitigating Misleading Chain-of-Thought Reasoning with Selective Filtering' (arXiv, 2024):
- 312.<https://arxiv.org/pdf/2509.06024>
313. Haoyang He et al. — Rethinking Reasoning Quality in Large Language Models through Enhanced Chain-of-Thought via RL
- 314.<https://arxiv.org/pdf/2502.09621>

315. Dongzhi Jiang et al. — MME-CoT: Benchmarking Chain-of-Thought in Large Multimodal Models for Reasoning Quality, Robustness, and Efficiency
316. <https://arxiv.org/pdf/2312.14769>
317. Abiodun Finbarrs Oketunji, Muhammad Anas, Deepthi Saina — Large Language Model (LLM) Bias Index — LLMBI
318. <https://arxiv.org/pdf/2403.13925>
319. Deam Mordil, Carlo Lipizi — Reducing Large Language Model Bias with Emphasis on 'Restricted Industries': Automated Dataset Augmentation and Prejudice Quantification
320. <https://arxiv.org/pdf/2310.16787>
321. Shayne Longpre, et al. — The Data Provenance Initiative: A Large Scale Audit of Dataset Licensing & Attribution in AI
322. <https://www.nature.com/articles/s42256-024-00884-w>
323. Nicholas Vincent, et al. — A Step Forward in Tracing and Documenting Dataset Provenance
324. <https://arxiv.org/pdf/2510.18909>
325. Hongyi He, Xiao Liu, et al. — Learning from the Best, Differently: A Diversity-Driven Rethinking on Data Selection
326. <https://arxiv.org/pdf/2210.02410>
327. Dan Friedman, Adji Bousso Dieng — The Vendi Score: A Diversity Evaluation Metric for Machine Learning
328. <https://arxiv.org/pdf/2301.08846>
329. Xu Tan et al. — Regeneration Learning: A Learning Paradigm for Data Generation.
330. <https://arxiv.org/pdf/2007.10762>
331. Kaidi Xu et al. — “Adversarial Training and Robustness for Deep Learning”
332. <https://arxiv.org/pdf/1909.12434>
333. Divyansh Kaushik et al. — “Learning the Difference that Makes a Difference with Counterfactually-Augmented Data”
334. <https://arxiv.org/pdf/2101.10382>
335. Yarin Gal et al. — “Curriculum Learning: A Survey”
336. <https://tijer.org/tijer/papers/TIJER2506049.pdf>
337. Yashwanth Boddu, Self-Healing Data Pipelines with Autonomous Error Correction
338. https://www.researchgate.net/publication/396166742_The_Impact_of_Self-Healing_Data_Pipelines_on_the_Performance_and_Fairness_of_AI_Models_in_Production
339. The Impact of Self-Healing Data Pipelines on the Performance and Fairness of AI Models in Production
340. <https://burrsettles.com/pub/settles.activelearning.pdf>
341. Settles — “Active Learning” (Foundational Survey), Morgan & Claypool
342. <https://arxiv.org/pdf/1706.03741>
343. Paul F. Christiano et al. — Deep Reinforcement Learning from Human Preferences.
344. <https://arxiv.org/pdf/2203.02155>
345. Long Ouyang et al. — Training language models to follow instructions with human feedback.
346. <https://arxiv.org/pdf/2210.11416>
347. Hyung Won Chung et al. — “Scaling Instruction-Finetuned Models”

● III. 추론형 AI 기술 작성부문

1. <https://arxiv.org/pdf/2205.11916>, Large Language Models are Zero-Shot Reasoners
2. Kojima et al. (2022), “Large Language Models are Zero-Shot Reasoners”, arXiv:2205.11916.
3. <https://arxiv.org/pdf/2112.00114>, SHOW YOUR WORK: SCRATCHPADS FOR INTERMEDIATE COMPUTATION WITH LANGUAGE MODELS
4. Nye et al. (2021), “Show Your Work: Scratchpads for Intermediate Computation with Language Models”, arXiv:2112.00114.
5. <https://arxiv.org/pdf/2404.14963>, Achieving >97% on GSM8K: Deeply Understanding the Problems Makes LLMs Better Solvers for Math Word Problems
6. Qihuang Zhong, et al.— Achieving >97 % on GSM8K: Deeply Understanding the Problems Makes LLMs Better Solvers for Math Word Problems
7. <https://arxiv.org/pdf/2210.03493>, Automatic Chain of Thought Prompting in Large Language Models
8. Kojima et al. (2022); Zhang et al. (2022), “Automatic Chain of Thought Prompting in Large Language Models”
9. <https://aclanthology.org/2024.alvr-1.8.pdf>, VideoCoT: A Video Chain-of-Thought Dataset with Active Annotation Tool
10. Yan Wang et al. (2024), “VideoCoT: A Video Chain-of-Thought Dataset with Active Annotation Tool
11. <https://arxiv.org/pdf/2502.21030v1>, Beyond Words: A Latent Memory Approach to Internal Reasoning in LLMs
12. José I. Orlicki – Beyond Words: A Latent Memory Approach to Internal Reasoning in LLMs
13. <https://arxiv.org/pdf/2411.12591>, Thinking Before Looking: Improving Multimodal LLM Reasoning via Mitigating Visual Hallucination
8. Improving Multimodal LLM Reasoning via Mitigating Visual Hallucination

14. Haojie Zheng et al. – Thinking Before Looking: Improving Multimodal LLM Reasoning via Mitigating Visual Hallucination
15. <https://medium.com/@johannes.koeppern/self-consistency-with-chain-of-thought-cot-sc-2f7a1ea9f941> MEDIUM, Self-Consistency with Chain of Thought (CoT-SC)
16. <https://arxiv.org/abs/2311.17311>, Universal Self-Consistency for Large Language Model Generation
17. Chen et al., Universal Self-Consistency for Large Language Model Generation,
18. <https://arxiv.org/abs/2408.13457>, Make Every Penny Count: Difficulty-Adaptive Self-Consistency for Cost-Efficient Reasoning
19. Wang et al., Make Every Penny Count: Difficulty-Adaptive Self-Consistency for Cost-Efficient Reasoning,
20. <https://aclanthology.org/2023.ad-long.304.pdf>
21. Peifeng Wang et al., Self-Consistency Improves Chain-of-Thought Distillation,
22. <https://arxiv.org/pdf/2305.10601>, Tree of Thoughts: Deliberate Problem Solving with Large Language Models
23. Yao et al., 2023, "Tree of Thoughts: Deliberate Problem Solving with Large Language Models"
24. <https://www.ibm.com/think/topics/tree-of-thoughts>
25. What is tree of thoughts?
26. <https://github.com/princeton-nlp/tree-of-thought-llm>
27. Yao et al., ToT GitHub Official Repository (코드 포함)
28. <https://arxiv.org/pdf/2505.14099v2>
29. Yihua Zhu et al. (2025), Beyond Chains: Bridging Large Language Models and Knowledge Bases in Complex Question Answering
30. <https://arxiv.org/abs/2305.14325>
31. Yilun Du et al., Improving Factuality and Reasoning in Language Models through Multiagent Debate
32. https://www.researchgate.net/publication/384365500_A_Character-Centric_Creative_Story_Generation_via_Imagination
33. Yang et al., A Character-Centric Creative Story Generation via Imagination
34. <https://arxiv.org/pdf/2502.16235>
35. Zhang et al.– Dynamic Parallel Tree Search for Efficient LLM Reasoning
36. <https://arxiv.org/pdf/2505.12717>
37. Wu et al. – ToTRL: Unlock LLM Tree-of-Thoughts Reasoning Potential through Puzzles Solving
38. <https://arxiv.org/pdf/2409.11527>
39. Haji et al.– Improving LLM Reasoning with Multi-Agent Tree-of-Thought Validator Agent
40. <https://arxiv.org/pdf/2310.04406>
41. Zhou et al.– Language Agent Tree Search: Unifying Reasoning, Acting, and Planning in Language Models
42. <https://www.diva-portal.org/smash/get/diva2:1897029/FULLTEXT01.pdf>
43. ANTON JANSBAGEN. Reasoning with Large Language Models using Tree-of-Thought and Symbolic Solvers
44. <https://aclanthology.org/2024.findings-naacl.183.pdf>
45. Yao et al – GoT: Effective Graph-of-Thought Reasoning in Language Models
46. <https://arxiv.org/pdf/2502.05078>
47. Tushar Pandey, et al.– Adaptive Graph of Thoughts: Test-Time Adaptive Reasoning Unifying Chain, Tree, and Graph Structures (AGoT)
48. <https://arxiv.org/pdf/2401.14295>
49. Maciej Besta et al. – Demystifying Chains, Trees, and Graphs of Thoughts
50. <https://aclanthology.org/2025.findings-acl.317.pdf>
51. R. Bai et al. Self-attention-based Graph-of-Thought for Math Problem Solving (SaGoT)
52. <https://arxiv.org/pdf/2404.04538>
53. J. Yang et al. Soft-Prompting / Aggregation variants with Graph-of-Thought
54. https://www.researchgate.net/publication/388284495_ESCARGOT_An_AI_Agent_Leveraging_Large_Language_Models_Dynamic_Graph_of_Thoughts_and_Biomedical_Knowledge_Graphs_for_Enhanced_Reasoning
55. ESCARGOT: An AI Agent Leveraging Large Language Models, Dynamic Graph of Thoughts, and Biomedical Knowledge Graphs for Enhanced Reasoning
56. <https://arxiv.org/pdf/2403.17491>
57. Xinyu Ning et al., – "DGoT: Dynamic Graph of Thoughts for Scientific Abstract Generation"
58. <https://arxiv.org/pdf/2402.09390>
59. Yihao Fang et al., "HGOT: Hierarchical Graph of Thoughts for Retrieval-Augmented In-Context Learning in Factuality Evaluation"
60. <https://arxiv.org/pdf/2509.16136>
61. Changwei Yao et al.,– Reward Evolution with Graph-of-Thoughts: A Bi-Level Language Model Framework for Reinforcement Learning
62. <https://arxiv.org/pdf/2412.12152v1>
63. Rongzheng Wang et al., 'GraphTool-Instruction: Revolutionizing Graph Reasoning in LLMs through Decomposed Subtask Instruction'

64. <https://www.analyticsvidhya.com/blog/2024/09/graph-of-thought/>
65. Mounish V, What is Graph of Thought in Prompt Engineering?
66. <https://wandb.ai/sauravmaheshkar/prompting-techniques/reports/Chain-of-thought-tree-of-thought-and-graph-of-thought-Prompting-techniques-explained—Vm1ldzo4MzQvNjMx>
67. Saurav Maheshkar, 'Chain-of-thought, tree-of-thought, and graph-of-thought: Prompting techniques explained'
68. <https://www.kdnuggets.com/graph-of-thoughts-a-new-paradigm-for-elaborate-problem-solving-in-large-language-models>
69. Matthew Mayo, Graph of Thoughts: A New Paradigm for Elaborate Problem-Solving in Large Language Models
70. <https://cameronwolfe.substack.com/p/graph-based-prompting-and-reasoning>
71. Cameron R. Wolfe, Graph-Based Prompting and Reasoning with Language Models
72. <https://arxiv.org/pdf/2504.02670v6>
73. Maciej Besta et al., - 'Affordable AI Assistants with Knowledge Graph of Thoughts'
74. <https://arxiv.org/pdf/2411.02382v1>
75. Guangzhi Xiong, et al., - 'Improving Scientific Hypothesis Generation with Knowledge Grounded Large Language Models'
76. <https://www.emergentmind.com/topics/graph-of-thoughts-got>
77. Philip, Graph of Thoughts (GoT) Framework
78. <https://academic.oup.com/bioinformatics/article/41/2/btaf031/7972741>
79. Nicholas Matsumoto et al., - 'ESCARBOT: an AI agent leveraging large language models, dynamic graph of thoughts, and biomedical knowledge graphs for enhanced reasoning'
80. <https://aclanthology.org/2025.findings-emnlp.864.pdf>
81. Runsong Jia, et al., - 'HetGCOT: Heterogeneous Graph-Enhanced Chain-of-Thought LLM Reasoning for Academic Question Answering'
82. <https://arxiv.org/pdf/2305.14992>
83. Shibo Hao et al., - 'Reasoning with Language Model is Planning with World Model'
84. <https://web3.arxiv.org/pdf/2303.11366v1>
85. Noah Shinn et al. Reflexion: An Autonomous Agent with Dynamic Memory and Self-Reflection.
86. <https://arxiv.org/pdf/2305.18323>
87. Binfeng Xu et al. ReWOO: Decoupling Reasoning from Observations for Efficient LLM Tool Use.
88. <https://arxiv.org/pdf/2310.08560>
89. Charles Packer, et al., - 'MemGPT: Towards LLMs as Operating Systems'
90. <https://arxiv.org/pdf/2303.11366>
91. Noah Shinn, et al., - 'Reflexion: Language Agents with Verbal Reinforcement Learning'
92. <https://magazine.sebastianraschka.com/p/the-state-of-llm-reasoning-model-training>
93. Sebastian Raschka, The State of Reinforcement Learning for LLM Reasoning
94. <https://arxiv.org/pdf/2504.11536>
95. Jiazhan Feng, et al., 'ReTool: Reinforcement Learning for Strategic Tool Use in LLMs'
96. <https://arxiv.org/pdf/2312.10003>
97. Renat Aksitov et al. - 'ReST meets ReAct: Self-Improvement for Multi-Step Reasoning LLM Agent'
98. <https://arxiv.org/pdf/2505.24726>
99. Shelly Bensaï et al. - 'Reflect, Retry, Reward: Self-Improving LLMs via Reinforcement Learning'
100. <https://arxiv.org/pdf/2504.08837>
101. Haozhe Wang et al. - 'VL-Rethinker: Incentivizing Self-Reflection of Vision-Language Models with Reinforcement Learning'
102. <https://arxiv.org/pdf/2511.02303>
103. Zhiwei Zhang et al. - 'Unlocking the Power of Multi-Agent LLM for Reasoning: From Lazy Agents to Deliberation'
104. <https://isolutions.medium.com/language-model-agents-in-2025-897ec15c9c42>
105. iSolutions, Language Model Agents in 2025: Society of Mind Revisited,
106. <https://arxiv.org/pdf/2510.04311>
107. Bohan Tang, et al. - 'On the Importance of Task Complexity in Evaluating LLM-Based Multi-Agent Systems'
108. <https://dl.acm.org/doi/pdf/10.1145/3712003>
109. Junda He, et al. - 'LLM-Based Multi-Agent Systems for Software Engineering: Literature Review, Vision, and the Road Ahead'
110. <https://arxiv.org/pdf/2503.13657>
111. Mert Cemri et al. - 'Why Do Multi-Agent LLM Systems Fail?,'
112. <https://arxiv.org/pdf/2508.04691>
113. Yuanchen Bai et al. - 'From MAS to MARS: Coordination Failures and Reasoning Trade-offs in Hierarchical Multi-Agent Robotic Systems'

- within a Healthcare Scenario'
114. <https://arxiv.org/pdf/2503.18869>, Reimagining Memory Access for LLM Inference: Compression-Aware Memory Controller Design
 115. Rui Xie et al.-'Reimagining Memory Access for LLM Inference: Compression-Aware Memory Controller Design'
 116. <https://arxiv.org/pdf/2508.12265>, Fast, Slow, and Tool-augmented Thinking for LLMs: A Review
 117. Ying Nian Wu et al.-'Fast, Slow, and Tool-augmented Thinking for LLMs: A Review'
 118. <https://link.springer.com/article/10.1007/s41019-025-00296-9>
 119. Weikai Xu, et al.-'LLM-Based Agents for Tool Learning: A Survey'
 120. <https://arxiv.org/pdf/2302.04761>
 121. Schick et al. - 'Toolformer: Language Models Can Teach Themselves to Use Tools.'
 122. <https://arxiv.org/pdf/2005.11401>, Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks
 123. Lewis et al. - RAG: Retrieval-Augmented Generation for Knowledge-Intensive
 124. <https://arxiv.org/pdf/2302.12128>
 125. Tobias Norlund et al. - 'On the Generalization Ability of Retrieval-Enhanced Transformers,
 126. <https://arxiv.org/pdf/2506.04625>, Advancing Tool-Augmented Large Language Models via Meta-Verification and Reflection Learning
 127. Zhiyuan Ma et al.-'Advancing Tool-Augmented Large Language Models via Meta-Verification and Reflection Learning'
 128. <https://arxiv.org/pdf/2304.09842>
 129. Pan Lu et al.-'Chameleon: Plug-and-Play Compositional Reasoning with Large Language Models'
 130. <https://arxiv.org/pdf/2506.10408>
 131. Jintao Liang et al.-'Reasoning RAG via System 1 or System 2: A Survey on Reasoning Agentic Retrieval-Augmented Generation for Industry Challenges'
 132. <https://arxiv.org/pdf/2410.01782>
 133. Shayekh Bin Islam et al.-'OPEN-RAG: Enhanced Retrieval-Augmented Reasoning with Open-Source Large Language Models'
 134. <https://arxiv.org/pdf/2310.19750>
 135. Joseph Gatto et al.-'Chain-of-Thought Embeddings for Stance Detection on Social Media'
 136. <https://arxiv.org/pdf/2410.13640>
 137. Yining Wang et al.-'Latent Space Chain-of-Embedding Enables Output-free LLM Self-Evaluation'
 138. <https://arxiv.org/pdf/2412.13171>
 139. Jeffrey Cheng, Benjamin Van Durme - 'Compressed Chain of Thought: Efficient Reasoning Through Dense Representations'
 140. <https://arxiv.org/pdf/2505.08243>
 141. Mees et al.-Training Strategies for Efficient Embodied Reasoning
 142. <https://arxiv.org/pdf/2503.22020>
 143. CoT-VLA: Visual Chain-of-Thought Reasoning for Vision-Language-Action Models,
 144. <https://arxiv.org/pdf/2407.08693>
 145. Zavalski et al.- Robotic Control via Embodied Chain-of-Thought Reasoning
 146. <https://arxiv.org/pdf/2507.00917>
 147. Wang et al. A Survey: Learning Embodied Intelligence from Physical Simulators and World Models
 148. <https://arxiv.org/pdf/2407.06886>
 149. Zhang et al.-Aligning Cyber Space with Physical World: A Comprehensive Survey on Embodied AI
 150. https://openaccess.thecvf.com/content/CVPR2024/papers/Ni_Generate_Subgoal_Images_before_Act_Unlocking_the_Chain-of-Thought_Reasoning_in_CVPR_2024_paper.pdf
 151. Ni et al.-'Generate Subgoal Images before Act: Unlocking the Chain-of-Thought Reasoning in Diffusion Model for Robot Manipulation with Multimodal Prompts'

AI 데이터 품질관리 가이드라인 v4.0

제4권 신기술 AI 데이터 품질관리 가이드 v1.0

2025년 02월 발행

발행처: 한국지능정보사회진흥원

작성 참여진

한국지능정보사회진흥원 신신애 본부장

한국지능정보사회진흥원 유호진 팀장

한국지능정보사회진흥원 이창민 수석

한국지능정보사회진흥원 윤주미 선임

한국지능정보사회진흥원 조연제 선임

(주)티지 최광민 이사

(주)티지 허다영 책임

자문 위원

세종대학교 구영현 교수

인하대학교 김승환 교수

건양대학교 김종엽 교수

연세대학교 김현중 교수

경희대학교 홍아름 교수

한양대학교 강하예진 박사

(주)셀렉트스타 김세엽 대표이사

(주)드위치 이태석 대표이사

- 본 『제4권 신기술AI 데이터 품질관리 가이드 v1.0』 내용의 무단전재 및 재배포를 금하며, 가공·인용 시에는 반드시 과학기술정보통신부, 한국지능정보사회진흥원의 「AI 데이터 품질관리 가이드라인 v4.0 - 제4권 신기술AI 데이터 품질관리 가이드 v1.0」임을 밝혀주시기 바랍니다.
- 본 『제4권 신기술AI 데이터 품질관리 가이드 v1.0』는 ‘2025년 초거대AI 확산 생태계 조성사업’ 중 ‘초거대AI 확산 생태계 조성 사업관리 전문지원’ 용역 사업의 결과 산출물입니다.
 - 한국지능정보사회진흥원 인공지능데이터본부 AI데이터사업팀 품질유닛 : aidq@nia.or.kr